Universidade Estadual de Campinas

PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

FACULDADE DE ENGENHARIA ELÉTRICA E DE COMPUTAÇÃO

RELATÓRIO FINAL

Desagregação não intrusiva de cargas residenciais utilizando inteligência computacional

Pesquisador: Wesley Angelino de Souza

Supervisor: Prof. Dr. Luiz Carlos Pereira da Silva

julho de 2019

Sumário

1 Introdução **8**

2 Revisão da Literatura **17**

2.1 Trabalhos Pioneiros 17

2.2 Detecção de eventos 18

2.3 Extração de características 22

2.4 Características de baixa frequência 23

2.5 Características de alta frequência 27

2.5.1 DFT - Método da Borboleta 28

2.5.2 Distorção Harmônica Total 31

2.5.3 Teorias de Potência 31

2.5.4 Transformada wavelet 34

2.6 Características independentes da taxa de amostragem 38

2.7 Considerações 40

3 Proposta de medidor cognitivo residencial **41**

3.1 Caracterização do sistema 41

3.2 Descrição dos elementos de hardware 41

3.2.1 Plataforma de desenvolvimento 42

3.2.2 Condicionamento dos sinais analógicos 43

3.2.3 Conversor analógico/digital 45

3.3 Aquisição de dados 45

3.4 Algoritmos implementados 48

3.4.1 Procedimento de cálculo da CPT 48

3.4.2 Algoritmo de Goertzel 51

3.4.3 Algoritmo de classificação KNN 51

3.4.4 Monitoramento de cargas 53

3.4.5 Desagregação do consumo de energia 58

3.5 Sistema supervisório 58

3.6 Considerações 61

4 Coleta de dados **63**

Classe 1 –Lâmpada Incandescente 65

Classe 2 – Ar condicionado 66

Classe 3 – Refrigerador 66

Classe 4 – Forno Micro-ondas 67

Classe 5 – TV CRT de 29 polegadas 67

Classe 6 – TV LCD de 49 polegadas 68

Classe 7 – TV de plasma de 60 polegadas 68

Classe 8 – Chuveiro 127 volts, com potência de 5000 watts 69

Classe 9 – Carga RL 1 69

Classe 10 – Carga não linear 1 70

Classe 11 – Carga não linear 2 70

Classe 12 – Carga RL 2 71

Classe 13 – Ferro de passar 71

Classe 14 – Máquina de lavar roupas 71

Classe 15 – Secador de cabelos 72

Classe 16 – Lâmpada Fluorescente Tubular 72

Classe 17 – Lâmpada mista 73

Classe 18 – Lâmpada de vapor de mercúrio 73

Classe 19 – Lâmpada de vapor de sódio 74

Classe 20 – Secadora de roupas regulável 74

Classe 21 – Refrigerador regulável 75

Classe 22 – Liquidificador 75

Classe 23 – Panificadora Elétrica 76

Classe 24 – Computador pessoal (Desktop PC) 76

Classe 25 – Lâmpada fluorescente compacta 77

Classe 26 – Processador de alimentos 77

Classe 27 – Freezer 78

Classe 28 – Forno Elétrico 79

Classe 29 – Portão automático de garagem 79

Classe 30 – Laptop 80

Classe 31 – Monitor LCD 80
Classe 32 – Secadora de roupas convencional 81
Classe 33 – Refrigerador regular 81
Classe 34 – Aspirador de pó 82
Classe 35 – Máquina de lavar roupas regulável 82

5 Proposta de extração de atributos para identificação de cargas 84

5.1 Extração das características da CPT 84
5.2 Conceitos 91
5.2.1 k-fold Estratificado 91
5.2.2 K-NN 92
5.2.3 Random Forest 93
5.2.4 SVM - Support Vector Machine 95
5.2.5 Métricas de desempenho 97
5.3 Análise de qualidade dos atributos 98
5.3.1 Caso A1 - k-folds (folds=5), KNN sem PCA e dados não normalizados . . . 98
5.3.2 Caso A2 - k-folds (folds=5), KNN sem PCA e dados normalizados 99
5.3.3 Caso A3 - k-folds (folds=5), KNN com PCA=0.99 100
5.3.4 Caso B1 - k-folds (folds=5), Random Forest sem PCA e dados não normalizados 100
5.3.5 Caso B2 - k-folds (folds=5), Random Forest sem PCA e dados normalizados 100
5.3.6 Caso B3 - k-folds (folds=5), Random Forest com PCA=0.99 101
5.3.7 Caso C1 - k-folds (folds=5), SVM/RBF sem PCA e dados não normalizados 102
5.3.8 Caso C2 - k-folds (folds=5), SVM/RBF sem PCA e dados normalizados . . . 102
5.3.9 Caso C3 - k-folds (folds=5), SVM/RBF com PCA=0.99 102
5.3.10 Caso D1 - k-folds (folds=5), SVM/Linear sem PCA e dados normalizados . . 106
5.3.11 Caso D2 - k-folds (folds=5), SVM Linear com PCA=0.99 106
5.3.12 Caso E1 - k-folds (folds=5), DT sem PCA e dados não normalizados 106
5.3.13 Caso E2 - k-folds (folds=5), DT sem PCA e dados normalizados 106
5.3.14 Caso E3 - k-folds (folds=5), DT com PCA=0.99 106
5.3.15 Comparação entre os classificadores 106
5.3.15.1 K-fold estratificado com 5 folds, sem PCA e sem normalização dos dados 109

5.3.15.2 K-fold estratificado com 5 folds, sem PCA e sem normalização dos dados . . . 109
5.3.15.3 K-fold estratificado com 5 folds e PCA com representatividade de 99% dos dados . . . 110
5.4 Extração de características baseadas na literatura . . . 110

6 Detecção de eventos **116**
6.1 Assinatura de potência . . . 116
6.2 Categorização das técnicas de monitoramento . . . 117
6.2.1 Abordagem intrusiva ou distribuída - ILM . . . 117
6.2.2 Abordagem não intrusiva ou concentrada - NILM . . . 118
6.3 Base de dados baseado em atributos de alta frequência . . . 119
6.4 Assinatura de potência das cargas . . . 120
6.5 A técnica PSB . . . 122
6.6 Validation Results . . . 125
6.6.1 Resultados por simulação . . . 125
6.6.2 Resultados experimentais com electrodomésticos . . . 128
6.7 Considerações sobre a proposta . . . 131

7 Trabalhos futuros **132**
7.1 Aprimoramento dos sistemas de aquisição e coleta de grandezas de energia elétrica . 136
7.2 Melhoria do sistema de reconhecimento de cargas . . . 137
7.3 Levantamento de características (atributos) de cargas (oito meses) . . . 138
7.4 Reavaliação da metodologia para aplicação em medidores inteligentes de baixo custo em redes inteligentes . . . 139
7.5 Análise histórica de consumo de cargas para a verificação do desgaste e da eficiência energética . . . 140
7.6 Sistemas de ludificação . . . 141
7.7 Considerações . . . 142

8 Considerações finais **143**

9 Artigos publicados no período de pós-doutorado **145**

9.1 Artigos publicados em periódicos 145
9.1.1 *Energies* – Load Disaggregation Using Microscopic Power Features and Pattern Recognition 145
9.1.2 *RBER* – Arquitetura do Medidor Cognitivo de Energia 146
9.1.3 *JCAES* – A NILM Dataset for Cognitive Meters Based on Conservative Power Theory and Pattern Recognition Techniques 146
9.1.4 *JCAES* – Evaluation of Pattern Recognition Algorithms for Applications on Power Factor Compensation 147
9.1.5 *IEEE TSG* – Intelligent Expert System for Power Quality Improvement Under Distorted and Unbalanced Conditions in Three-Phase AC Microgrids 148
9.2 Artigos aceitos para publicação em periódicos 148
9.2.1 *IEEE LAT* – Automatic Consumption Management for Prepaid Electricity Meter with NILM 149
9.3 Artigos publicados em anais de eventos / congressos 149
9.3.1 *CBA 2018* – Comparação das técnicas de monitoramento de cargas para a desagregação do consumo de energia elétrica 149
9.3.2 *CBA 2018* – Gerenciamento de Consumo Elétrico Baseado em Medidores Cognitivos de Energia Elétrica 150
9.3.3 *GreenTech 2017* – Power Metering: History and Future Trends 151
9.3.4 *CITENEL 2017* – Refrigeradores residenciais: monitoramento e análise comparativa entre modelos distintos 151
9.3.5 *CBA 2016* – Análise Comparativa entre Medições de Energia Elétrica para Cargas Não Lineares de Iluminação: Medição Comercial x Teoria CPT . . . 152
9.3.6 *ICHQP 2016* – Analysis of the influence of non-linear loads on the measurement and billing of electrical energy compared with the CPT 153

10 Coorientações no período de pós-doutorado 154
10.1 Coorientações de Iniciação Científica 154
10.1.1 Estudo e desenvolvimento de tecnologias para automação residencial com foco na gestão de energia elétrica nas instalações 154
10.1.2 Determinação de alertas de evasão de cliente numa empresa de software como serviço 155

10.2 Coorientações de Mestrado 156
10.2.1 Medidor cognitivo de energia para aplicações em eficiência energética 156
10.2.2 Metodologia para desagregação de cargas em instalações residenciais através de medidores cognitivos de energia 157
10.3 Coorientações de Doutorado 158
10.3.1 Medidores Cognitivos de energia e aplicações em gerenciamento de energia elétrica 158

11 Anexo I – Artigos publicados em periódicos no período de pós-doutorado 171

12 Anexo II – Artigos publicados em congressos ou eventos no período de pós-doutorado 248

1 Introdução

A energia elétrica é um pilar importante para o desenvolvimento socioeconômico [1–3] e a crescente demanda exige o seu uso cada vez mais otimizado, eficiente e sustentável [3]. Para isso, intensifica-se a necessidade de detalhar o uso da energia para suportar alternativas que permitam a eficiência energética.

Neste contexto, surgem os medidores de energia elétrica como elementos importantes para o modelo de redes inteligentes [1, 4, 5], sendo utilizados em qualquer ponto do sistema, seja na geração, transmissão, distribuição ou no uso final de energia elétrica. Como estes pontos de medição necessitam informar dados confiáveis e precisos para a gestão de energia elétrica, os equipamentos de medição devem ser capazes de: armazenar dados e transmiti-los a centrais de controle e monitoramento; integrar-se com os dispositivos elétricos existentes no sistema; realizar procedimentos remotamente; e permitir a implantação de "inteligência" no mesmo [1, 5, 6].

Em síntese, dentro do cenário de medidores inteligentes, um sistema de medição inteligente é caracterizado por utilizar dispositivos capazes de obter mais informações sobre consumo de energia elétrica em comparação aos medidores tradicionais. Além disso, estes dispositivos também utilizam de meios de comunicação para enviar e receber dados. Essas informações reunidas são vistas como essenciais para transformar o sistema elétrico tradicional em uma rede inteligente de energia. Atualmente, com a liberalização do mercado de energia e as necessidades latentes relacionadas ao desenvolvimento sustentável e a eficiência energética, torna-se necessário o desenvolvimento de equipamentos e normas que potencializem tais aplicações [7].

Tem-se, neste âmbito, os medidores inteligentes de energia elétrica, que são dispositivos eletrônicos com comunicação bidirecional e medição de energia em quadrantes [2, 8]. Mesmo não aparentando nenhuma característica que torne o medidor "inteligente", o conceito para esta categoria de medidores é amplamente aceito.

Porém, tem-se buscado na última década a evolução que de fato atribua inteligência ao medidor e uma das propostas que mais se destaca é o monitoramento do consumo por cargas (eletrodomésticos) [2, 6, 8–12], que corresponde a um processo de identificação e aquisição da medição elétrica de uma carga em um sistema de energia em um certo período de tempo [13], estabelecendo o consumo de energia e o estado de funcionamento de cada equipamento, promovendo a compreensão do comportamento, manutenção, controle e monitoramento [14].

Existem três principais metodologias de desagregação do consumo: a técnica de monitoramento

não-intrusiva ou concentrada; a técnica de monitoramento intrusivo ou distribuído e; a técnica de monitoramento semi-intrusivo ou parcialmente distribuído.

A técnica de monitoramento concentrado, conhecida na literatura como NILM (*Non-intrusive Load Monitoring* – Monitoramento não intrusivo de cargas), envolve um único medidor alocado no Ponto de Acoplamento Comum (PAC), nas residenciais é o ponto de entrada de energia do consumidor, que liga a energia oferecida da concessionária com o ponto de consumo. Desta forma, através da análise do consumo total, das formas de onda da tensão e corrente e da identificação da assinatura de potência característica para cada carga, é possível implementar algoritmos no medidor para realizar a desagregação do consumo elétrico por equipamento e também implementar outras funções (por exemplo, identificação de faltas e perdas não técnicas) [6, 12]. O consumo separado por cargas possibilita o desenvolvimento de interfaces amigáveis para o usuário final, que forneça sugestões para a eficiência energética e estratégias de economia de energia, em conjunto com relatórios que permitam o gerenciamento do uso da energia elétrica [6]. Na literatura, a técnica de monitoramento concentrado tem direcionado a novas nomenclaturas de medidores, entre elas, o conceito de medidor cognitivo [6, 12, 15].

A segunda técnica de monitoramento é a distribuída, conhecida na literatura como ILM (*Intrusive Load Monitoring* – Monitoramento intrusivo de cargas), isto é, existem diversos pontos de medição distribuído no prédio, sendo cada ponto voltado diretamente a uma única carga. A desagregação ocorre por meio de *hardware* (sensores individuais), diferente da técnica concentrada que se baseia na desagregação por *software*. Deste modo, possui maior precisão e possibilidade de interação com os equipamentos (automação), porém o custo de implantação e manutenção é maior e há a necessidade de tempo para a completa instalação dentro da residência, por essa necessidade esta técnica é amplamente conhecida como "intrusiva".

A última técnica é a mescla das duas anteriores, a técnica de monitoramento parcialmente distribuído, conhecida na literatura como SILM (*Semi-intrusive Load Monitoring* – Monitoramento semi-intrusivo de cargas) que consiste na medição por circuitos ou grupo de cargas (e.g. um cômodo da residência). Por ser intermediária, apresenta a desagregação baseada em *hardware* e *software* integrados e instalação semelhante à do sistema distribuído.

As três técnicas de monitoramento permitem gerar relatórios de detalhamento do consumo por eletrodomésticos, conforme apresenta a Figura 1, através de um sistema supervisório com relatórios de consumo total ou por cargas. Este conceito de desagregação do consumo de energia elétrica in-

dica a tendência da nova geração de monitoramento e medição da energia, podendo assim beneficiar tanto aos consumidores quanto às concessionárias através de medidas que envolvem a redução do consumo através de análises desagregada do uso de equipamentos elétricos ou na otimização da gestão de demanda energética de regiões ou cidades [16].

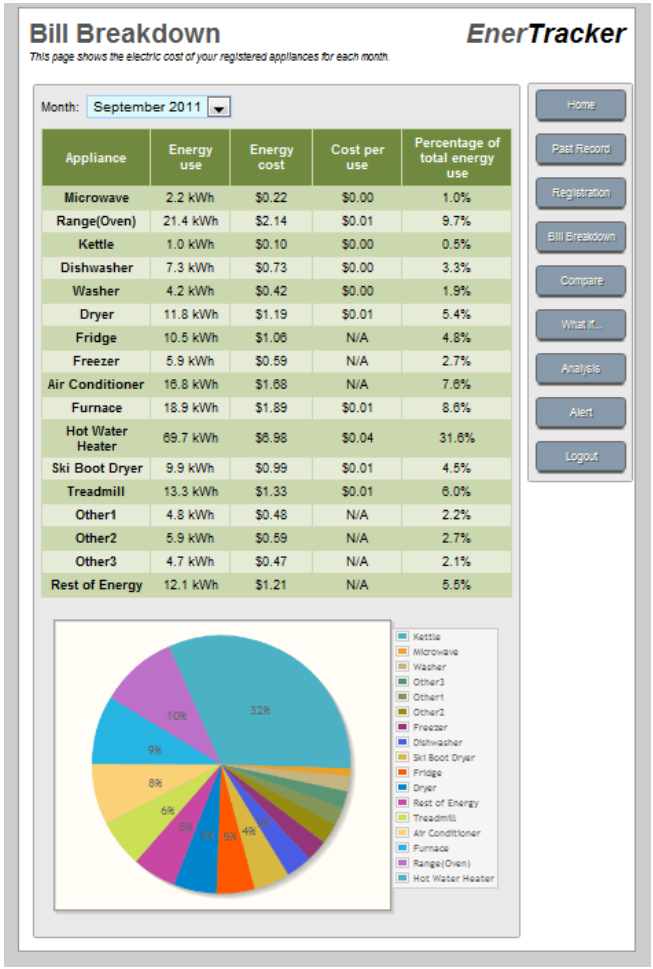

Appliance	Energy use	Energy cost	Cost per use	Percentage of total energy use
Microwave	2.2 kWh	$0.22	$0.00	1.0%
Range(Oven)	21.4 kWh	$2.14	$0.01	9.7%
Kettle	1.0 kWh	$0.10	$0.00	0.5%
Dishwasher	7.3 kWh	$0.73	$0.00	3.3%
Washer	4.2 kWh	$0.42	$0.00	1.9%
Dryer	11.8 kWh	$1.19	$0.01	5.4%
Fridge	10.5 kWh	$1.06	N/A	4.8%
Freezer	5.9 kWh	$0.59	N/A	2.7%
Air Conditioner	16.8 kWh	$1.68	N/A	7.6%
Furnace	18.9 kWh	$1.89	$0.01	8.6%
Hot Water Heater	69.7 kWh	$6.98	$0.04	31.6%
Ski Boot Dryer	9.9 kWh	$0.99	$0.01	4.5%
Treadmill	13.3 kWh	$1.33	$0.01	6.0%
Other1	4.8 kWh	$0.48	N/A	2.2%
Other2	5.9 kWh	$0.59	N/A	2.7%
Other3	4.7 kWh	$0.47	N/A	2.1%
Rest of Energy	12.1 kWh	$1.21	N/A	5.5%

Figura 1: Desagregação do consumo mensal por uso individual de equipamentos (*EnergyTracker*).

Neste projeto, será abordada a técnica concentrada, também chamada de NILM (*Non-Intrusive Load Monitoring* - Monitoramento não intrusivo de cargas). Esta técnica é baseada na extração e identificação de características elétricas específicas: por assinaturas ou grandezas elétricas para aplicações em baixa frequência ou; pelos atributos (ou características) extraídos das formas de onda da tensão e corrente para aplicações em alta frequência. Estas características permitem identificar qual carga foi ligada ou desligada e o instante em que elas operaram. É importante destacar que o termo "não intrusivo" está relacionado simplesmente com a ausência de acesso físico ao interior da instalação elétrica e, consequentemente, a cada uma das cargas que se encontra dentro da residência.

A Figura 2 ilustra a técnica de monitoramento concentrado (ou intrusivo) de cargas. Desta forma, é colocado um medidor no ponto de acoplamento comum da residência (a), onde se encontra o medidor de energia na residência. Com o uso dos equipamentos na residência (b) utilizam-se as técnicas para a extração de características e para a detecção dos equipamentos ligados (c) como, por exemplo, de decomposição de harmônicas com rede neurais artificiais [17], decomposição em indicadores elétricos com aprendizado de máquina [18], técnicas de monitoramento de janelas de potências [10, 16, 17], obtendo nestas técnicas exatidão satisfatória e que encontra-se evoluindo nas últimas três décadas, desde o trabalho pioneiro de Hart [11].

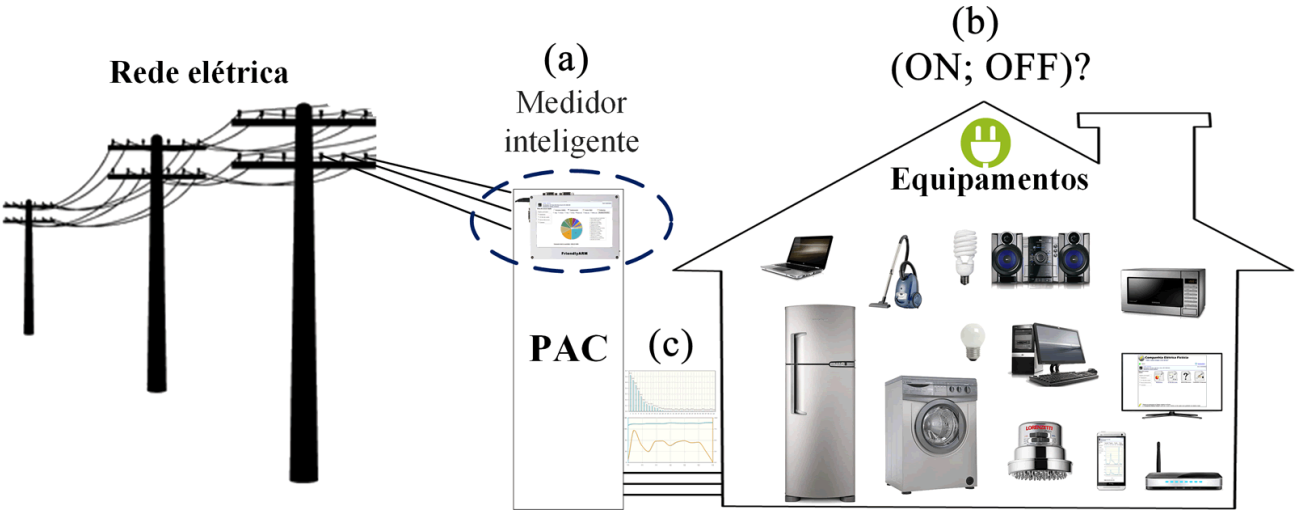

Figura 2: Representação do sistema de monitoramento concentrado.

Na abordagem concentrada, apenas um sensor é colocado no ramal principal e a desagregação é realizada através de algoritmos que efetuam a análise dos dados e separam as informações de cada carga. Este modelo, baseado em *software*, é mais complexo e justifica a atribuição do termo "medidor inteligente", quando integrado com um único *hardware*, reduzindo custos com aquisição e instalação de sensores. Um sistema de monitoramento concentrado, geralmente, tem precisão inferior a um sistema de monitoramento distribuído, contudo, o grau de imprecisão pode ser tolerado para muitas aplicações, sobretudo em virtude do custo menor em hardware. Tal abordagem não permite a gestão remota das cargas, mas viabiliza mudanças de hábitos dos consumidores de maneira a resultar em ganhos em termos de conservação de energia [19].

Recentemente, o monitoramento concentrado tem recebido atenção significativa no contexto de redes inteligentes, devido ao desenvolvimento da nova geração de medidores [20, 21]. Mas, como indicado em [16], existem algoritmos capazes de detectar eventos de ligar/desligar para todos os tipos de

cargas em residência, mesmo nem sempre indicando a exata carga que foi ligada ou desligada. Entretanto, devido ao potencial apresentado pelo monitoramento concentrado, o tema tem sido pesquisado intensamente por vários grupos de pesquisa e ainda existem diferentes empresas oferecendo este tipo de serviço. Como evidência do interesse e do potencial existente para a área, tem-se em [22] a lista de mais de 50 empresas, que têm trabalhado com monitoramento concentrado que estão espalhadas ao redor do mundo.

A desagregação de cargas se torna, indubitavelmente, uma área promissora na área de medição de energia elétrica, na qual concessionárias e empresas estão buscando em desenvolver soluções de desagregação de cargas em sistemas embarcados compostos por sensores e medidores [23]. Quanto a novos medidores, tem-se o medidor cognitivo [2, 6, 12, 24] e nos dispositivos sem fio o *In Home Display* [2, 12, 25].

Define-se como medidor cognitivo a evolução do medidor inteligente convencional, munido de técnicas de reconhecimento de cargas, desagregação do consumo de energia elétrica e resposta a demanda [2]. A cognição está associada a desagregação de cargas realizada pelo medidor, que através de medições de tensão e corrente no PAC, tem a proposta de identificar quais cargas estão inseridas no sistema, e explicitar a influência de cada carga quanto ao consumo em cada ponto de medição [18, 26].

Os medidores cognitivos se referem a uma nova geração de medidores eletrônicos inteligentes com a capacidade de desagregação de cargas [2]. A desagregação de cargas poder dar subsídios em decisões que permeiam desde a conscientização do usuário sobre seu consumo até informações que contribua para a gestão da energia elétrica na rede. Assim o consumidor recebe informações do consumo de energia desagregada. Dentro do cenário de uma residência comum, tais informações podem ser inúteis ao consumidor, pois este precisa entender o consumo próprio e observar o uso sobre cada equipamento.

Com o cenário sobre as técnicas de monitoramento, junto aos medidores inteligentes cognitivos, às técnicas de qualidade da energia elétrica e, com a possibilidade do medidor inteligente se tornar uma ferramenta que traga benefícios ao consumidor e à concessionária, este trabalho propõe um sistema para medidores inteligentes que permita a desagregação e que repasse ao consumidor e à concessionária informações de desagregação de consumo utilizando técnicas de inteligência computacional, por algoritmos de reconhecimento de padrões e algoritmos de inteligência artificial para a gestão e previsão de eventos, sejam de consumo desagregado, como a estimativa de demanda.

A desagregação das cargas, seguindo o conceito do medidor cognitivo, apresenta ao consumidor

informações diretas de consumo por cargas, auxiliando o consumidor a compreender seu consumo da energia elétrica. Relatórios de consumo e sugestões de economia auxiliam o consumidor a buscar a redução do consumo com energia elétrica. Indicadores de QEE permitem que se avalie a qualidade da energia fornecida. Atualmente, para o consumidor residencial, a única compreensão com a baixa qualidade da energia elétrica é quando existe a interrupção demorada de energia, ou seja, o consumidor residencial tolera interrupções de energia por alguns minutos [27] e começa a reclamar quando a interrupção permanece por um longo tempo. Apresentando uma ferramenta com indicadores de QEE e instruindo o consumidor a entendê-la [28], levantar questões a respeito de eficiência energética, de qualidade da tensão fornecida, de continuidade do fornecimento de energia elétrica, entre outros.

Portanto, a aplicação dos medidores inteligentes de energia é vista como essencial tanto para consumidores, quanto para concessionárias. Nesse sentido, a aplicação de medidores inteligentes pode trazer diversos benefícios aos consumidores, incluindo a redução de despesas, melhor qualidade de serviço das concessionárias ou mesmo, novos modelos de tarifação de energia [29].

Juntamente à aplicação dos medidores inteligentes de energia, tem-se que as ações voltadas à eficiência energética são de grande potencial para a criação, manutenção e monitoramento de equipamentos e serviços que favoreçam consumidores e concessionárias. De modo geral, todos os setores envolvidos são beneficiados, pois enquanto os consumidores podem melhorar o "nível de conscientização" em relação aos hábitos de consumo, fazendo uso mais racional da energia elétrica [7, 18]; informações detalhadas sobre o consumo de energia elétrica dos equipamentos são pré-requisitos para a criação de novas tecnologias, equipamentos e políticas energéticas que visem a melhoria da eficiência energética em sistemas modernos de energia [30, 31].

Nesse contexto, tem-se a fusão de técnicas de medição de energia com conceitos de eficiência energética, através da aplicação de técnicas que permitam a análise e desagregação do consumo de cargas. Tal metodologia tem ganho atenção significativa nos últimos anos [32]. Com a utilização da técnica de desagregação, o conceito de medidor inteligente pode ser redefinido, sendo chamado de medidor cognitivo de energia [18]. Com isso, o próprio medidor de energia pode ser utilizado como ferramenta para fornecer sugestões de consumo, com base em informações extraídas do monitoramento das cargas e do conhecimento de hábitos dos consumidores [2, 30].

Considerando os temas destacados, este projeto de pós-doutorado visou o aprimoramento do conceito e da metodologia relacionada ao medidor cognitivo de energia elétrica proposto em [18], tendo em vista sua aplicação nas redes inteligentes. Em [18] foi utilizado o método chamado de monitora-

mento de carga não intrusivo, o qual fez o uso de técnicas de reconhecimento de padrões de assinaturas de potências e da decomposição harmônica de corrente das cargas. Além disto, uma das principais contribuições do trabalho foi a utilização da decomposição da potência elétrica em diversas subcomponentes, através da técnica conhecida como Teoria de Potência Conservativa (CPT —- *Conservative Power Theory*) [33], para melhoria da técnica de desagregação. Tal proposta foi voltada aos consumidores residenciais e apresentou resultados bastante interessantes. No entanto, o sistema ainda pode ser aprimorado através de novas técnicas de reconhecimento de padrões e diversas novas aplicações dos medidores cognitivos de energia ainda podem ser exploradas.

Uma questão importante foi a preocupação com a redução do custo computacional da metodologia proposta, visando sua aplicação em microcontroladores de baixo custo. O objetivo desta análise é permitir com que a metodologia seja aplicável, viável e implementável nos medidores inteligentes comerciais. Desta forma, um dos objetivos deste projeto é tornar a técnica implementável em sistemas de custo baixo, aproximando a tecnologia dos consumidores, em especial os residenciais.

Outra contribuição desta proposta fofoii viabilizar o uso do medidor cognitivo no âmbito das redes inteligentes de energia. Para isso, será utilizado o conceito de usina virtual de energia elétrica. Neste caso, o concentrador de dados faz a tomada de decisão do funcionamento otimizado de uma rede através da coleta de informações dos medidores cognitivos, em conjunto com a tarifação de energia, produção energética, dados meteorológicos e com o uso de algoritmos de inteligência artificial e de análises estatísticas.

Pretendeu-se, portanto, estender o trabalho proposto em [18] para o nível de um medidor flexível para uso em diversos pontos das redes inteligentes. Para isto, foram realizadas quatro etapas principais neste projeto:

1. Aprimoramento dos sistemas de aquisição e coleta de grandezas de energia elétrica. Esta etapa será feita em conjunto com a equipe do projeto temático, buscando a criação de uma versão que seja de amplo uso e tendo um referencial de medidor que possa ser utilizado em diversas etapas da rede de energia;

2. Melhoria do sistema de reconhecimento de cargas através do estudo de novos algoritmos de reconhecimento de padrões, visando a criação de um modelo de classificação com maior exatidão. Também será aumentada a base de dados de cargas (equipamentos) baseada em [18];

3. Levantamento de mais características (atributos) das cargas, podendo assim melhorar a exatidão

na identificação de cargas. Serão também identificadas possíveis grandezas elétricas ou novos indicadores que possam facilitar a desagregação de cargas ou ainda a caracterização da eficiência energética dos equipamentos;

4. Proposição de um sistema supervisório, com foco na central de controle de uma rede inteligente, o qual fará a gestão de todas as camadas de medição da rede inteligente, desde a camada dos consumidores residenciais, até a tomada de decisões para a gestão da rede inteligente.

Desta forma, este projeto tem como objetivo a proposição de um novo conceito de medidor cognitivo inteligente. Esta proposta baseia-se, inicialmente, em uma técnica para o reconhecimento de equipamentos, utilizando o sistema de monitoramento concentrado. Desta forma, utilizam-se algoritmos de reconhecimento de padrões como base de pré-processamento ao sistema NILM. Para isso será criada e expandida uma base de dados de equipamentos utilizando o conceito de treinamento e classificação (sistema supervisório). Após a análise dos algoritmos, aplica-se a análise de assinatura de potências no tempo, utilizando parcelas de potência ativa, reativa e residual, obtidas através da chamada Teoria de Potência Conservativa (CPT- Conservative Power Theory) [33] junto a outros possíveis indicadores de energia, como distorção harmônica na corrente.

Após o reconhecimento dos equipamentos, tem-se como objetivo o desenvolvimento de um sistema supervisório que apresente vantagens ao consumidor e à concessionária. Através de uma interface com relatórios de consumo da energia, do consumo desagregado por equipamentos, estratégias de economia, estimativa de demanda, entre outras ferramentas.

Para este fim, tem-se o uso do medidor de energia elétrico como desagregador de cargas e posteriormente a construção de um método que permita a construção de um sistema que forneça relatórios para a economia de energia, bem como seu uso eficiente e racional.

Portanto, teve-se a preocupação de reformular e expandir as técnicas e metodologia propostas em [18], focando na redução do custo computacional e na expansão de funcionalidades dos medidores cognitivos e respectiva central de controle para as redes inteligentes de energia, com vistas ao conceito de usinas virtuais. Tendo este principal objetivo, este relatório está dividido conforme a seguir:

- **Revisão bibliográfica** – serão apresentados os estudos dos últimos anos a respeito das técnicas de desagregação de cargas, focando, sobretudo, nas características do comportamento das cargas que são extraídas em baixa e alta frequência, bem como aquelas características que independem das taxas de amostragem;

- **Conceito do medidor cognitivo** – nesta seção é apresentado o conceito do medidor cognitivo, indicando seus propósitos, conceitos e objetivos;
- **Coleta de dados e extração de características** – nesta seção, serão apresentadas as cargas medidas e os atributos extraídos;
- **Análise dos dados** – nesta seção, os classificadores são analisados e seus resultados são apresentados. Juntamente, o detector de eventos também será apresentado e validado;
- **Considerações** – serão levantadas algumas considerações e trabalhos futuros para o prosseguimento desta pesquisa;
- **Artigos publicados e coorientações no período** – nesta seção, são apresentados os resultados científicos e de orientações realizadas pelo pesquisador no período.

2 Revisão da Literatura

Os artigos que compõem o referencial bibliográfico foram selecionados a partir da base de dados Scopus, da Editora Elsevier. Utilizando o mecanismo de busca, realizou-se a pesquisa empregando como critério[1] de busca o termo monitoramento de carga não intrusivo e variantes, ordenando os resultados conforme a quantidade de citações recebidas por outros autores.

Em 10 de dezembro de 2019, a pesquisa realizada retornou 1784 resultados, sendo que o artigo *Nonintrusive Appliance Load Monitoring*, escrito por Hart [11], é o mais antigo e recebeu a maior quantidade de citações.

Considerando o trabalho de Hart [11] como pioneiro, realizou-se uma segunda busca indexando todas as publicações que contém tal como referência, obtendo como resultado 1249 trabalhos. Conforme ilustrado na Figura 3, ao ordenar os resultados por data de publicação até 2018, verifica-se o crescimento do interesse na área abordada neste projeto nos últimos dez anos.

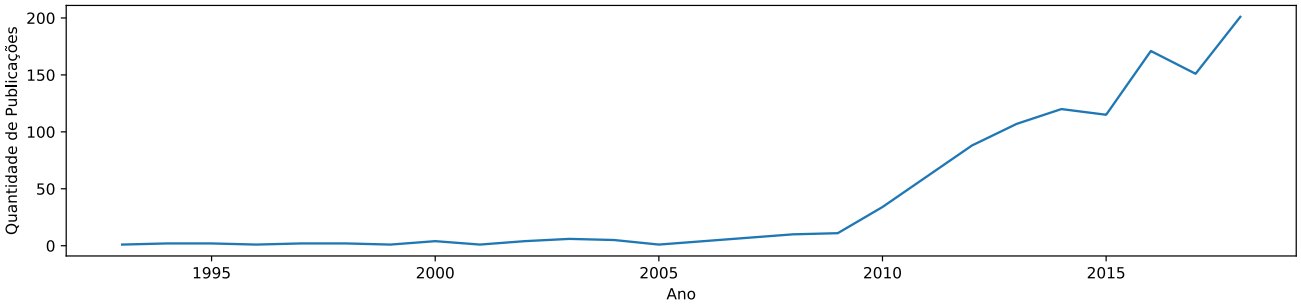

Figura 3: Resultados ordenados pelo ano de publicação.

Embora divulgado no início da década de 1990, o tema de pesquisa começa ser estudado com mais frequência a partir de 2005, ascendendo de 2010 em diante. Cabe então analisar os trabalhos pioneiros para fundamentar a teoria do monitoramento não intrusivo de cargas.

2.1 Trabalhos Pioneiros

G. W. Hart iniciou sua pesquisa em 1982 com patrocínio do *Electric Power Research Institute* (EPRI), conduzindo-a em instituições como MIT e a universidade de Columbia. Na literatura, o resultado de seus estudos é marcado com a publicação do artigo *Nonintrusive Appliance Load Monitoring*, em 1992. No mesmo período, Sultanem [34] publicou um estudo independente, possivelmente inspirado em um simpósio realizado pela EPRI, com propostas semelhantes.

[1] *Query String: "Nonintrusive Appliance Load Monitoring"OR "Nonintrusive Load Monitoring".*

Sultanem [34] apresenta um estudo indicando que ao analisar os sinais de tensão e corrente elétrica no ponto de ligação do medidor de energia elétrica, pode-se observar variações (eventos) relacionadas ao uso de eletrodomésticos que são reconhecíveis e identificáveis por um conjunto de parâmetros, formando uma assinatura de carga.

Na mesma linha, Hart [11] descreve que o monitoramento não intrusivo de cargas consiste de uma análise sofisticada das formas de onda de corrente e tensão de um circuito elétrico que contém cargas usadas arbitrariamente, tal que é possível estimar a quantidade e o tipo, entre outras informações relevantes: tempo e período de uso. O procedimento é dividido em 5 estágios:

- Detecção de eventos: coleta dados de potência ativa (P) e reativa (Q) em 1 Hz, detectando variações (Δ) acima de um valor limiar predefinido. O estado é dito estacionário quando não varia durante três amostras consecutivas.

- Formação de agrupamentos: os eventos detectados são agrupados em um espaço bidimensional, denominado espaço $\Delta P - \Delta Q$;

- Combinação de eventos: os eventos positivos (carga ligada) com negativos (carga desligada) de magnitude (Δ) semelhante;

- Análise de anomalias: analisa os eventos e as combinações geradas;

- Cálculo de consumo: estima o consumo individual de cada carga com base no tempo de uso.

Com base no trabalho de Hart [11], o princípio do monitoramento não intrusivo está condicionado às técnicas de identificação de eventos, representação de cargas e métodos de classificação. Assim, a partir dos trabalhos pioneiros e de novas publicações, o desenvolvimento de técnicas de monitoramento não intrusivo foi se especializando. A seção seguinte apresenta o estado da arte das técnicas aplicadas para detecção de eventos.

2.2 Detecção de eventos

A identificação de estados estacionários é um procedimento fundamental do monitoramento não intrusivo baseado em eventos. Embora seja possível analisar quando cargas são ligadas e desligadas, a análise em estado estacionário apresenta algumas desvantagens, tais como: sobreposição de eventos devido à taxa de amostragem, complexidade para tratar cargas de consumo variável e impossibilidade de identificar cargas de baixo consumo ou que estão sempre ligadas.

Os algoritmos de detecção de eventos são categorizados na literatura de três maneiras [35]: detectores heurísticos, probabilísticos e baseados em mascaras.

- Heurísticos — empregam um conjunto de regras para identificação de eventos. Por exemplo, o limiar de potência entre amostras consecutivas [11].
- Probabilísticos — utilizam distribuições de probabilidade para detectar o ponto de mudança entre dois conjuntos de amostras [36].
- Máscaras — empregam filtros para detectar características específicas. Segundo Laughman et al. [37], cada carga tem uma assinatura distinta que tende a ser repetível.

Além desses três métodos, cabe destacar as abordagens baseadas em agrupamentos [38–40] que utilizam tais métodos para identificar estados estacionários adjacentes.

Para avaliar o desempenho de algoritmos, Anderson et al. [35] propuseram métricas de avaliação e uma base de dados (BLUED[2]) que contém 2482 eventos registrados em duas fases e aproximadamente 30 eletrodomésticos [41].

Como referência para trabalhos futuros, Anderson et al. [35] avaliaram o desempenho de um detector baseado no modelo estatístico GLR (em inglês, *Generalized Likelihood Ratio*) que utiliza teste LLR (em inglês, *Log Likelihood Ratio*) e votação. A descrição do método e os resultados obtidos são apresentados nas Tabelas 1 e 2, respectivamente.

A diferença dos resultados citados advém da distribuição das cargas que estão em maior quantidade na fase B e afetam a detecção de eventos devido ao espaçamento entre transições. Devido a curta duração de um estado transiente, Wild et al. [42] descrevem um evento como um estado ativo que é mantido até que os atributos monitorados entrem em regime estacionário. Para tal, Wild et al. [42] propuseram o uso de duas janelas móveis consecutivas para avaliar variações na corrente harmônica utilizando o método KFDA (em inglês, *Kernel Fisher Discriminant Analysis*).

Barsim et al. [39] utilizaram agrupamentos no espaço $\Delta P_l - \Delta Q_l$ para definir estados estacionários adjacentes, já os transientes são considerados *outliers*. Para reduzir o efeito das oscilações, os autores utilizaram a escala logarítmica nos atributos monitorados, dividindo-os em segmentos (*bins*) de tamanho predefinido.

[2] *Building-Level fUlly-labeled dataset for Electricity Disaggregation (BLUED).*

De maneira semelhante, Zheng et al. [40] propuseram o método DBSCAN (em inglês, *Density-Based Spatial Clustering of Applications with Noise*) para realizar o agrupamento de atributos e localizar estados estacionários adjacentes.

Tabela 1: Descrição dos algoritmos.

Autor	**Descrição**
Anderson et al. [35]	Utilizando duas janelas de amostras consecutivas, calcula-se o LLR para cada amostra de potência, sendo transformados em valores binários com base na comparação de um valor limiar. Posteriormente, a presença de um evento nas janelas vizinhas é determinada a partir do log natural da razão entre as funções de densidade de probabilidade das duas janelas.
Wild et al. [42]	As janelas são formadas por amostras de corrente elétrica representada por conjunto de componentes harmônicas. Posteriormente, calcula-se a dissimilaridade entre as duas janelas que é obtida a partir de uma projeção linear dos conjuntos que melhor separa os atributos das duas janelas. O evento é detectado se o valor de dissimilaridade for maior que um valor limiar.
Barsim et al. [39]	Utiliza uma janela de amostras contendo valores de potência ativa e reativa. Em seguida, os atributos são convertidos para escala logarítmica e agrupados no espaço $\Delta P_l - \Delta Q_l$ de modo que contenha dois estados estacionários e um transiente. Após essa etapa, calcula-se o tamanho dos agrupamentos e a variação de potência para validar o evento. Por fim, um algoritmo de agrupamento EM (em inglês, *Expectation Maximization*) é utilizado para aprimorar a definição do período transiente.
Zheng et al. [40]	O algoritmo de agrupamento é executado em uma janela móvel e não requer a especificação da quantidade de agrupamentos. Baseado na densidade dos agrupamentos, o método utiliza uma parâmetro para definir um raio de cobertura das amostras que satisfazem os critérios de densidade (quantidade de vizinhos). Para reduzir a dispersão, utiliza-se um filtro de média móvel para determinar os valores médios de potência ativar e corrente elétrica eficaz.

Considerando a sequência de eventos como um procedimento necessário para modelagem de cargas, Dong et al. [38] propuseram um conjunto de filtros para detectar eventos suspeitos que posterior-

Tabela 2: Resultados obtidos.

Autor	Eventos	TP	FP	FN	TPP	FPP	TPR	Fase
Anderson et al. [35]	871	855	16	18	98.16%	2.07%	98.16%	A
Wild et al. [42]	NI	NI	NI	NI	NI	NI	98.78%	
Barsim et al. [39]	886	NI	NI	NI	98.50%	0.55%	NI	
Zheng et al. [40]	846	835	11	6	98.70%	0.71%	98.70%	
Anderson et al. [35]	1551	1092	459	159	70.41%	10.25%	70.41%	B
Wild et al. [42]	NI	NI	NI	NI	NI	NI	92.17%	
Barsim et al. [39]	1579	NI	NI	NI	70.50%	8.75%	NI	
Zheng et al. [40]	1498	1316	182	598	87.85%	39.92%	87.85%	

TP e FP: verdadeiro positivo e falso positivo.

FN: falso negativo.

TPP e FPP: razão entre TP/FP e quantidade de eventos.

TPR: sensibilidade.

NI: não informado.

mente são validados usando técnicas de agrupamento, *Mean Shift* e *Weight-Based*, pois o número de cargas é inicialmente desconhecido. Após essa etapa, os eventos são rotulados com base na frequência em que ocorrem e associados para formar o registro de operação da carga. Para trabalhos futuros os autores indicam a ampliação do conjunto de características de cada evento, devido às particularidades de cada instalação residencial.

Em suma, os filtros probabilísticos necessitam de treinamento para selecionar os parâmetros de configuração que obtém melhor desempenho na detecção de um conjunto de cargas; já os filtros baseados em técnicas de agrupamento, requerem configuração para determinar o tamanho dos agrupamentos. De modo geral, o ajuste dos parâmetros é realizado considerando a granularidade espacial e temporal dos eventos que devem ser detectados. Além disso, o uso de janelas móveis com filtros de média atenuam informações importantes para identificação de eventos.

Para Ruano et al. [36], os atributos monitorados na detecção de eventos também fornecem informações que permitem identificar a carga. Há um consenso na literatura de que a análise microscópica das formas de onda de tensão e corrente elétrica aprimoraram a identificação de cargas [43].

A análise microscópica também possibilita a identificação do estado transiente que corresponde ao distúrbio causado no sinal de corrente quando uma carga é ligada. Para Norford and Leeb [44, p.61], "a detecção do transiente aproveita mais as informações disponíveis na inicialização do equipamento do que a detecção de carga em estado estacionário, ao custo de mais processamento".

Cabe ressaltar que cargas distintas podem apresentar formas de onda de corrente elétrica semelhantes. Chang et al. [45] afirmam que cargas sem componentes harmônicas não podem ser monitoradas de modo adequado em estado estacionário. Par tal, é necessário combinar propriedades observáveis nos dois estados para aprimorar a detecção de eventos e reconhecimento das cargas [44, 45].

Considerando aplicações comerciais, Armel et al. [20] opinam que a frequência de amostragem entre 60 Hz e 2 kHz é interessante devido ao potencial de aplicação em medidores eletrônicos, pois exigem pouca ou nenhuma alteração de *hardware*. Nessa faixa, é possível analisar as harmônicas de baixa ordem que são importantes para distinção de cargas [34, 37, 38, 46], e identificar um conjunto abrangente de cargas residenciais e transitórios com menor nível de granularidade.

É com base na revisão da literatura e das principais dificuldades que ainda permeiam a detecção de eventos e extração de atributos de classificação, que este projeto de pesquisa objetiva desenvolver um detector de eventos considerando atributos microscópicos relativos à corrente elétrica.

2.3 Extração de características

O trabalho pioneiro de Hart [11], correspondente à análise comportamental da potência de cada eletrodoméstico, tem inspirado diversas pesquisas acerca da abordagem de desagregação de cargas de forma não intrusiva (NILM). Destas pesquisas, em sua grande parte, buscam-se extrair características provenientes das grandezas elétricas de tensão e corrente e implementam-se algoritmos que consiga realizar a desagregação.

Os tipos de características que são extraídas das grandezas elétricas são dependentes ou independentes da taxa de amostragem, podendo ser dividida em três categorias: de baixa frequência de amostragem, de alta frequência de amostragem e características que independem da frequência da taxa de amostragem.

A Tabela 3 apresenta uma coletânea de características em diversos trabalhos encontrados na literatura, ordenados de acordo com a categoria da característica. A Tabela 4 apresenta as siglas e significados breves das características (atributos) das técnicas indicadas na Tabela 3, tais características serão explicadas nas subseções 2.4, 2.5 e 2.6.

Tabela 3: Resumo e categorização dos trabalhos relevantes de desagregação de cargas e características utilizadas nos métodos.

Amostragem de sinais	Técnica de amostragem de sinais	Características (Atributos)	Referências
Baixa frequência	Assinatura e variação de potência ativa/reativa	P, Q	[11, 44, 47–50]
	Assinatura e variação de potência ativa	P	[51–54]
	Assinatura de potência ativa e indicadores	P, I_{RMS},U_{RMS},P_{MAX},$T_{MIN_{ON}}$,$T_{MIN_{OFF}}$	[55, 56]
	Assinatura de potência ativa e indicadores	P, $PF(\lambda)$	[57]
Alta frequência	Decomposição harmônica	P, Q, $H_{1,3,5,\cdots,N}$	[34, 37, 58–60]
	Assinatura de potência e distorção harmônica	P, DHT	[10, 61, 62]
	Assinatura de potência e Teorias de Potência	P, Q, S ou A, H, $CPT_{componentes}$	[18, 24, 63–65]
	Wavelets	W_{coef},W_e	[66–71]
Independentes	Trajetória Tensão e Corrente	VI_{traj}	[72–75]
	Corrente inativa	I_f	[63]
	Ruído harmônico em transitórios	H_f, $36 \leq f \leq 500Hz$	[76, 77]
	Probabilidade de cargas ligadas ou desligadas	P^{ON}_{carga}, P^{OFF}_{carga}	[78]
	Pulsos discretos temporais de potência	$P_{pulso}(t)$	[79]
	Combinação de características independentes	VI_{traj}, $i(t)$, $p(t)$ e outros	[62]

Talvez útil para tempo do evento

Útil na detecção do evento e possivelmente classificação

Interessantes para detecção, classificação e anomalias

Nas subseções 2.4, 2.5 e 2.6 serão apresentadas as características extraídas das grandezas elétricas em baixa frequência (características extraídas a 1 kHz ou menos – também conhecidas como aproximações ou valores médios das grandezas [80]), alta frequência (características extraídas em frequência de kHz e MHz – também conhecidas como detalhamento das grandezas elétricas [24, 80]) e independentes da frequência (características de observação temporal ou comportamental de cargas em valores que independe do valor da frequência). Nestas próximas seções será também mostrada uma breve definição das características sob cada categoria e conjuntamente os trabalhos relevantes para cada categoria e características extraídas.

2.4 Características de baixa frequência

A amostragem de sinal de baixa frequência permite com que sejam calculadas características que não necessitam extrair rigorosos detalhes das formas de onda de tensão e corrente, tampouco de *hardware* com poder de aquisição em alta frequência. Dentro do arcabouço de desagregação de cargas, esta técnica é chamada de análise macroscópica [24, 81].

Outra característica das características de baixa frequência é a sua facilidade para ser calculada,

Tabela 4: Notações e descrições dos atributos encontrados na literatura.

Característica (Atributo)	**Descrição**
P	Potência Ativa
Q	Potência Reativa
I_{RMS}	Corrente eficaz
U_{RMS}	Tensão eficaz
P_{MAX}	Potência Ativa Máxima
$T_{MIN_{ON}}$	Tempo mínimo da carga ligada
$T_{MIN_{OFF}}$	Tempo mínimo da carga desligada
$PF(\lambda)$	Fator de Potência
$QF(\lambda_Q)$	Fator de Reatividade
$VF(\lambda_D)$	Fator de não linearidade
$H_{1,3,5,\cdots,n}$	Componente harmônica de ordem $1,3,5,\cdots,n$
$DHTv$	Distorção Harmônica Total da Tensão
$DHTi$	Distorção Harmônica Total da Corrente
S	Potência Aparente
H	Potência Harmônica
W_{coef}	Coeficientes extraídos das wavelets
W_e	Coeficiente equivalente das wavelets
VI_{traj}	Trajetória da tensão x corrente
I_f	Corrente Inativa
H_f	Componentes harmônicas e inter-harmônicas
P_{carga}^{ON}	Probabilidade da carga estar ligada
P_{carga}^{OFF}	Probabilidade da carga estar desligada
$P_{pulso}(t)$	Potência de pulso temporal
$i(t)$	Corrente instantânea
$p(t)$	Potência ativa instantânea

pois depende de contas simples e, consequentemente, não possui a necessidade de processadores com melhor poder computacional. Portanto, dados como a potência ativa, potência reativa, potência aparente, tensão e corrente eficaz, duração do ciclo e formato da assinatura de potência são exemplos

das características típicas do sistema de baixa frequência.

Hart [11], Drenker e Kader [47] foram os primeiros que apresentaram trabalhos que utilizam a variação da potência aparente (P) e da potência reativa (Q) como características para a desagregação de cargas. Por definição, tem-se a potência ativa como aquela correspondente ao consumo médio de potência do circuito e representando a realização de trabalho útil na carga. Em sistemas discretos, uma forma de cálculo para a potência ativa é expressa por:

$$P = \frac{1}{N} \sum_{k}^{k+N} u[k] * i[k]$$

na qual:

P corresponde à Potência Ativa;

u[k] corresponde ao valor da tensão instantânea, no instante ***k*** de aquisição;

i[k] corresponde ao valor da corrente instantânea, no instante ***k*** de aquisição;

N é a quantidade de amostras em um ciclo, no caso em questão, em *60Hz*.

Os valores eficazes de tensão e corrente são obtidos por:

$$U = \sqrt{\frac{1}{N} \sum_{k}^{k+N} u[k]^2}$$

$$I = \sqrt{\frac{1}{N} \sum_{k}^{k+N} i[k]^2}$$

Estas servem de base para o cálculo da potência aparente (S), que é:

$$S = U * I$$

E tem-se a potência reativa pela teoria do triângulo de potência:

$$Q = \sqrt{S^2 - P^2}$$

Ambos trabalhos identificavam instantes de cargas ligadas ou desligadas, sobretudo daquelas que consomem maior potência. Entretanto, para cargas com menor consumo não são facilmente reconhecidas e eram sobrepostas pelas cargas de maior consumo no sistema de desagregação de ambos trabalhos. Em [11] foi construída uma máquina finita de estados e em [47] foi indicado o uso de um algoritmo de reconhecimento de padrões, mesmo não indicando qual foi o algoritmo utilizado. Em

ambos casos, haviam somente a análise da assinatura de potência e o uso de duas características: potência ativa e reativa. Nguyen *et al.* [64] utilizaram as mudanças no tempo das parcelas de potência ativa, reativa e aparente e aplicou uma árvore de decisão para desagregar algumas cargas, obtendo acurácia em torno de 95%.

Powers *et al.* [51] fizeram o registro do tempo e frequência de uso de cargas com alto consumo, com amostras de potência ativa a cada 15 minutos. Os trabalhos de Norford e Leeb [44], de Biansoongnern e Plungklang [49] e de Xiao e Cheng [50] analisaram o comportamento da potência ativa no tempo e construíram um algoritmo baseado em máquina de estados para o reconhecimento de cargas pelas rampas de mudança da potência ativa. Farinaccio e Zmeureanu [52] também utilizam a potência ativa com um sistema de identificação de padrões baseado em regras, sendo expandida em [53] através do uso de um sistema de filtro de sinais (com a intenção de remover ruídos ou oscilações de baixo valor de potência). Nesta mesma abordagem de utilizar somente a potência ativa, Baranski [54] propôs um desagregador de cargas utilizando lógica fuzzy e histograma das mudanças de potência durante o funcionamento das cargas. Nos projetos apresentados até agora, os erros oscilam de equipamento para equipamento e em todos, as cargas estudadas são aquelas que possuem um alto consumo de energia elétrica. Marceau e Zmeureanu [53] fizeram um programa que realiza a estimativa de consumo por formas geométricas, analisando somente a potência ativa e obtiveram acurácia nas cargas em teste por volta de 90%.

Ruzzelli *et al.* [55] utilizaram os indicadores de valores eficazes em conjunto à potência ativa e adicionou o recurso do pico de potência e o reconhecimento em tempo real. Segundo os autores, os valores de exatidão para aplicações na cozinha foram consideravelmente satisfatórios, mas os autores concluíram e sugeriram que é necessária a extração de características que vão além das análises de potência e de assinatura de potência. Kelly e Knottenbelt levantaram indicadores como potência máxima, mínima duração do ciclo da carga ligada, mínima duração da carga desligada, limiar de potência de funcionamento e, com estes indicadores, utilizaram redes neurais profundas e obtiveram acurácia por carga que oscila entre 40% a 99%. Figueiredo [57] *et al.* desenvolveram algo semelhante, porém foi adicionado mais um indicador, o fator de potência, que corresponde basicamente a:

$$FP = \frac{P}{S}$$

Mas houve também a conclusão em Figueiredo *et al.* [57] da necessidade da extração de características que detalham melhor os equipamentos, sobretudo àquelas que possuem a mesma potência e o

mesmo comportamento de circuito equivalente.

Desta forma, começaram a serem extraídas características de alta frequência, que analisam sobretudo os eventos existentes nas formas de onda de tensão e de corrente. Tais características serão apresentadas na subseção a seguir.

2.5 Características de alta frequência

A amostragem de sinal de alta frequência permite com que sejam calculadas características provenientes de pormenorizados detalhes das formas de onda de tensão e corrente. Dentro da área de desagregação de cargas, as características de alta frequência também são chamadas de características microscópicas [24].

Na literatura, a primeira característica extraída para a aplicação de desagregação de cargas voltada à alta frequência de amostragem é o espectro harmônico da corrente de uma carga. Em [34] a corrente da carga foi decomposta em ordens harmônicas múltiplas da fundamental (neste projeto, foi considerada a frequência fundamental de 50Hz - frequência diferente do Brasil, porém majoritária em aspecto mundial).

A principal técnica de decomposição de sinais pelo espectro harmônico surgiu no século XIX, quando o físico francês Jean Baptiste Joseph Fourier publicou um estudo sobre ondas e calor no qual propõe que um sinal periódico qualquer pode ser representado por uma única expressão analítica, derivada da soma de sinais harmônicos senoidais. Com este estudo ele criou uma das ferramentas mais utilizadas na análise de sinais e que leva seu nome, a "Análise de Fourier" ou no método matemático Transformada de Fourier (FT – Fourier Transform). A partir do método matemático proposto por Fourier, tem-se a seguinte equação:

$$X(k) = \sum_{n=0}^{N-1} x(n)e^{-j\omega_n n}, \quad k = \{0, 1, 2, \cdots, N-1\}$$

no qual:

$x(k)$ é a amostra do sinal;

ω é a frequência angular (*rad/s*);

$X(k)$ é o sinal integralizado, contínuo na frequência ω.

A Figura 4 representa a função acima, tendo $X(k)$ como o sinal total, representado na sub-figura a) e cada elemento da somatória como um sinal correspondente à ordem harmônica (n=1, n=3, n=5 e n=7), representados na sub-figura b).

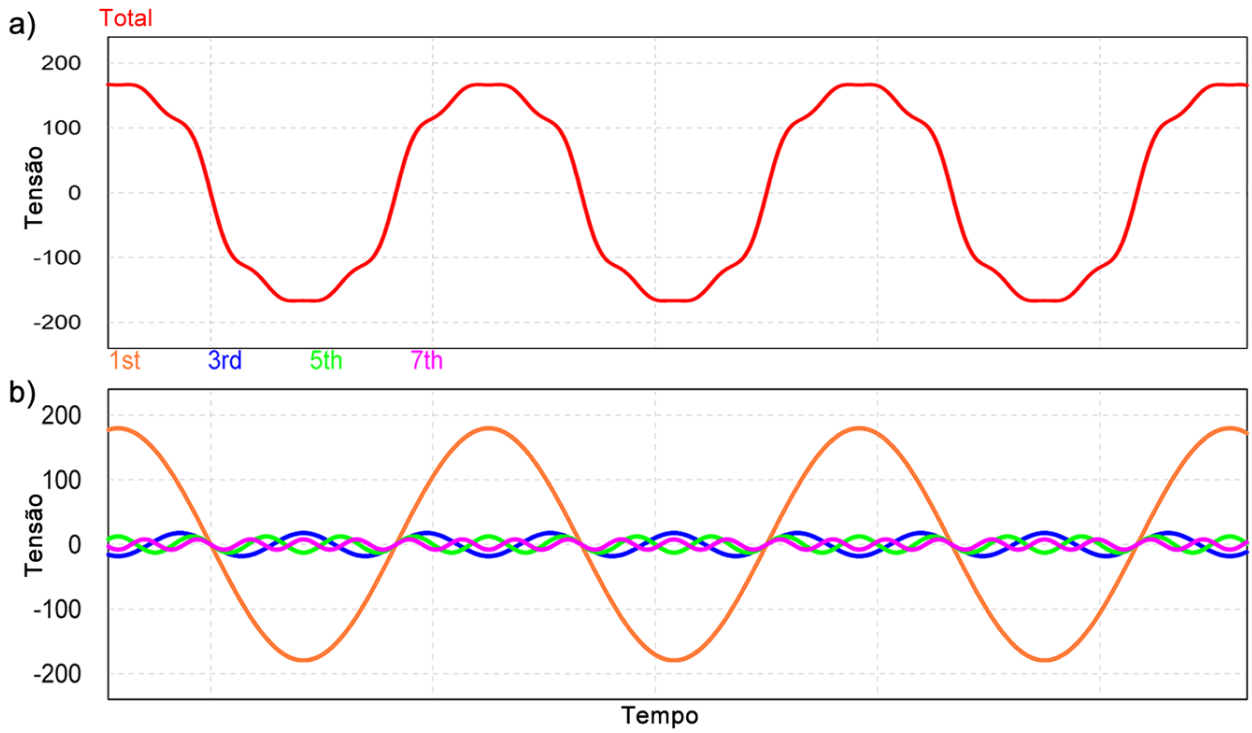

Figura 4: a) Representação de um sinal no tempo contínuo; b) Decomposição por sinais harmônicos do sinal de a).

Para a implementação da equação objetivo acima, um dos métodos para se obter o espectro harmônico é o uso da transformada discreta de Fourier (DFT - Discrete Fourier Transform), que analisa uma sequência de sinais e a decompõe em frequências, amplitude e ângulo para cada ordem harmônica e que possibilita a reconstrução do sinal. O algoritmo baseado no método da borboleta é o mais utilizado em aplicações embarcadas e tem a abordagem matemática apresentada na subseção 2.2.1.

2.5.1 DFT - Método da Borboleta

Basicamente, o problema computacional para o DFT é calcular a sequência $X(k)$ de N números de valores do conjunto complexo, dada outra sequência de dados $x(n)$ de comprimento N, de acordo com a equação:

$$X(k) = \sum_{n=0}^{N-1} x(n) W_N^{kn}$$

no qual, tem-se: $0 \leq k \leq N-1$

W_N como fator de giro, e $W_N = e^{-j2\pi/N}$.

W_N tem uma grande importância para definir a simetria e periodicidade do sinal que se deseja

transformar.

Para a decomposição, tem-se o método da decimalização no tempo, que recursivamente divide os N pontos do vetor de medições em dois sub-vetores de tamanho N/2. Essa divisão é feita separando elementos de índices pares de um lado e ímpares de outro. Os N/2 pontos são então adicionalmente divididos em N/4 pontos e esta decomposição continua até restarem dois pontos da transformada. Desde que $W_N^2 = [e^{-j(2\pi/N)}]^2 = [e^{-j2\pi(N/2)}]^2 = W_{N/2}$, a equação de $X(k)$ pode ser reajustada para:

$$X(k) = \sum_{n=0}^{N/2-1} x(2n)W_N^{2nk} + \sum_{n=0}^{N/2-1} x(2n+1)W_N^{(2n+1)k} =$$

$$= \sum_{n=0}^{N/2-1} x(2n)W_{N/2}^{nk} + W_N^k \sum_{n=0}^{N/2-1} x(2n+1)W_{N/2}^{nk} = Y(k) + W_N^k Z(k)$$

no qual $k = 0, 1, 2, ..., N-1$, $Y(k)$ e $Z(k)$ são as amostras de índice par e ímpar respectivamente. Consequentemente, restringindo k na faixa entre 0 e $(N/2)-1$, e equação acima pode ser reescrita em duas partes, uma para o intervalo de k entre 0 a $N/2-1$ e outro intervalo de $N/2-1$ a $N-1$, que é a expressão $X(k) = Y(k) + W_N^k Z(k)$.

$$X(k+N/2) = \sum_{n=0}^{N/2-1} x(2n)W_{N/2}^{n(k+N/2)} + \sum_{n=0}^{N/2-1} x(2n+1)W_{N/2}^{n(k+N/2)} W_N^{k+N/2} = Y(k) - W_N^k Z(k)$$

Como há sempre a separação e o cruzamento dos valores, este método é chamado de método da borboleta e se torna eficiente para vetores que possuem 2^n amostras. Neste caso, tem-se em $X(k)$ o conjunto das componentes de parte real e imaginária da decomposição FFT. Portanto:

$$X(k) = X_{real}(k) + jX_{imag}(k)$$

É possível obter a quantificação (em amplitude de sinal) de cada elemento harmônico, bem como o seu ângulo. A amplitude é derivada da equação:

$$|X(k)| = \sqrt{X_{real}(k)^2 + X_{imag}(k)^2}$$

Cada índice k se refere à ordem harmônica, ou seja, ao componente fundamental do sinal e seus múltiplos. Tem-se como exemplo a Figura 5 que apresenta a decomposição harmônica (sub-figura **b)**) do sinal total (sub-figura **a**).

A Tabela 5 apresenta informações quantitativas da decomposição harmônica do sinal da sub-figura a) da Figura 5.

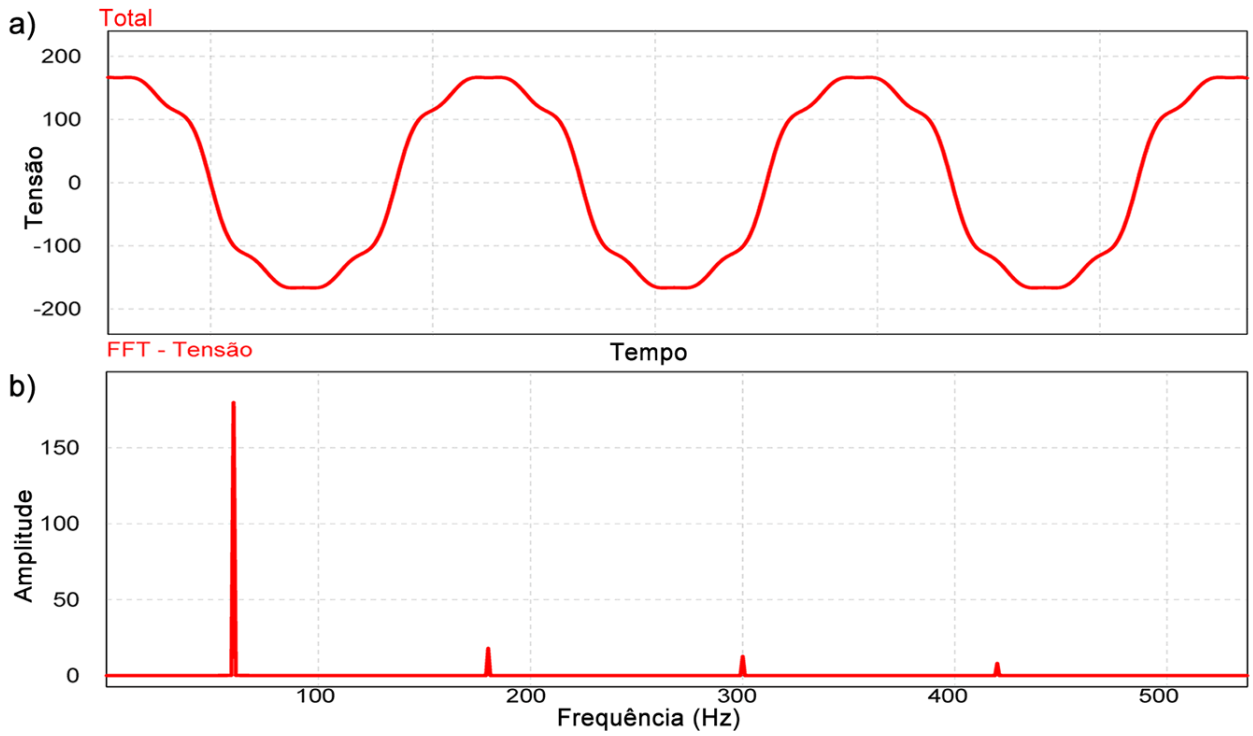

Figura 5: a) Representação de um sinal no tempo contínuo; b) Decomposição DFT/FFT do sinal a).

Tabela 5: Valores da decomposição de sinal com base no sinal a) da Figura 5.

Harmônica (h)	Amplitude (H_h)	Ângulo de fase
1ª	179,05	0°
3ª	17,82	0°
5ª	14,41	0°
7ª	7,92	0°

O uso da decomposição harmônica é essencial, pois houve nos últimos anos a proliferação de cargas não lineares, sobretudo em residências e estabelecimentos comerciais. Sultanem [34] se baseou nestas características, mas não apresentou desempenho de métodos. Já Srinivasan *et al.* [58] utilizaram algoritmos classificadores: MLP (*Multilayer Perceptron*), rede RBF (*Radial Basis Function*) e SVM (*Support Vector Machine*).

Laughman *et al.* [37] também fez a análise de cargas utilizando decomposições harmônicas, sobretudo da terceira harmônica para distinguir cargas (lâmpada fluorescente e computador desktop) que possuem a mesma potência, mas não possuem a mesma característica na terceira harmônica. Outros projetos, como Dong *et al.* [10], utilizaram a assinatura de potência com informações de harmônicas e implementaram redes neurais para a classificação, Shaw *et al.* [59] desenvolveram a combinação das

características de harmônicas com as potências ativas e reativas, dentro do cenário de transitório de cargas. Bouhouras *et al.* [60] utilizou as três primeiras componentes ímpares da decomposição pela DFT/FFT (ordem harmônica, amplitude e ângulo) para descrever as assinaturas de carga de corrente elétrica para algumas cargas e obteve acurácia em torno de 90%.

2.5.2 Distorção Harmônica Total

Uma outra forma de representar a decomposição harmônica do sinal é calcular um fator que corresponde à distorção harmônica total - DHT (em inglês THD - *Total Harmonic Distortion*). A equação equivalente do DHT é:

$$DHT = \frac{\sqrt{\sum_{h=2}^{N} H_h^2}}{H_1}$$

no qual:

H_1 é a amplitude harmônica da componente fundamental;

N é a máxima componente harmônica do sinal da transformada;

H_h é a amplitude harmônica das componentes de ordem maiores ou iguais a 2.

Dong *et al.* [10] utilizaram a DHT como característica de desagregação de cargas, bem como Chang [61] que levantou a DHT como parâmetro que auxilia a desagregação de cargas. Lin *et al.* [62] utilizou redes neurais como base do algoritmo de desagregação de cargas e a característica da DHT foi utilizada como atributo a esta base. Desta forma, a DHT está sendo bem aceita e utilizada em pesquisas sobre NILM com extração de características de alta frequência de amostragem.

Também existe na literatura uma forma diferente de retirada de características, utilizando parâmetros das chamadas Teorias de Potência, que tentam caracterizar uma carga em relação ao seu circuito equivalente.

2.5.3 Teorias de Potência

Apesar de terem sido debatidas por mais de um século, diversos trabalhos ainda são publicados a cada ano para tentar descrever propriedades que ocorrem na rede elétrica e para caracterizar uma carga em seu circuito equivalente. Neste sentido, a tentativa de explicar a diferença entre a potência ativa e aparente deu origem ao tema de “Teoria de Potência”.

Ao decorrer dos últimos 150 anos, diversas teorias de potência foram sendo desenvolvidas e aprimoradas. Tem-se em 1865 a pesquisa de Maxwell [82] que introduziu o conceito de defasagem causado por elementos reativos, que foi base para o cálculo de potência reativa.

Budeanu, em 1927, apresentou o conceito de potência distorcida, que vem de componentes não ativos e não reativos [83], tal teoria era apresentada no domínio da frequência e Fryze, em 1931 [84], apresentou a mesma abordagem, mas no domínio do tempo e foi comprovada a ortogonalidade entre cada parcela de potência, permitindo a independência entra cada parcela. Tal trabalho foi base para Teshome *et al.* [63] criar um método NILM com componentes de potência ativa, reativa, distorcida e aparente. Huang *et al.* [65] apresentaram que a aplicação de teorias de potência podem ser ferramentas úteis para a desagregação de cargas, sobretudo àquelas que possuem o mesmo valor de potência ativa.

Nos anos posteriores, foram apresentadas outras teorias de potência. Em 2003, Tenti e Mattavelli [85] propuseram a Teoria de Potência Conservativa (CPT - *Conservative Power Theory*), que permite a caracterização de cargas em parcelas de potência. Tal trabalho foi base para o levantamento de características para o NILM proposto por Souza *et al.* [4, 18, 24].

Considerando a amostra de sinal k, as componentes básicas definidas pela CPT são as conhecidas como instantâneas, que são encontradas como produtos escalares. A potência ativa instantânea é definida pelo produto escalar entre a tensão $u[k]$ e corrente $i[k]$ no momento da amostragem:

$$p[k] = u[k]\ i[k]$$

E a energia reativa instantânea é definida pelo produto escalar entre a integral imparcial da tensão no instante $\hat{u}[k]$ e a corrente $i[k]$ no instante de amostragem:

$$w[k] = \hat{u}[k]\ i[k]$$

A integral imparcial $\hat{u}[k]$ é definida como:

$$\hat{u}[k] = u_{\int}[k] - \bar{u_{\int}}[k]$$

No qual:

$u_{\int}[k] = \sum_{k}^{k+N} u[k]$ é a integral da tensão no período e $\bar{u_{\int}}[k] = \frac{1}{N}\sum_{k}^{k+N} u_{\int}[k]$ é o valor médio da integral da tensão no tempo. Neste caso, N corresponde à quantidade de aquisições (amostras) em um ciclo de onda.

A potência ativa (P) corresponde ao valor médio de $p[k]$ e a energia reativa (W) corresponde ao valor médio de $w[k]$, conforme se apresenta a seguir:

$$P = \bar{p} = \frac{1}{N} \sum_{k}^{k+N} p[k]$$

$$W = \bar{w} = \frac{1}{N} \sum_{k}^{k+N} w[k]$$

Baseada nas quantidades de potência ativa P e energia reativa W, tem-se a decomposição em correntes em parcelas ortogonais. A proposição matemática é apresentada em [33] e as componentes de correntes em sistemas monofásicos são:

- **corrente ativa** (i_a): é a parcela responsável pelo trabalho útil da carga;
- **corrente reativa** (i_r): é a parcela de corrente que flui entre a fonte e a carga;
- **corrente residual** (i_v): é a parcela que não realiza trabalho e nem flui entre fonte e carga, mas que aparece ao existir componentes não lineares na carga;

Os valores eficazes das correntes podem ser calculados e tem-se a corrente equivalente como:

$$I^2 = I_a^2 + I_r^2 + I_v^2$$

Ao multiplicar cada componente eficaz com o valor de tensão eficaz, tem-se:

- **Potência Ativa** $P = U\ I_a$
- **Potência Reativa** $Q = U\ I_r$
- **Potência Residual** $V = U\ I_v$
- **Potência Aparente** $A = U\ I$ ou $A = P + Q + V$

E, através da relação entre estas parcelas de potência, tem-se os indicadores de conformidade da CPT, que existem para quantificar as propriedades que cada carga existe em relação a componentes quantificantes a elementos resistivos, reativos (resistivos/indutivos) e não lineares.

Assim, tem-se o fator de não linearidade:

$$\lambda_D = 1 - \frac{V}{I}$$

Pela análise de cargas, o fator de não linearidade representa a presença de elementos não lineares, que distorcem a corrente. É também chamado de **Fator Nulo** pois não apresenta nenhuma contribuição ativa ou reativa ao circuito. Este fator é diretamente relacionado às componentes não lineares no circuito, que podem afetar a eficiência de um sistema elétrico e causar perdas no sistema. O valor unitário deste fator indica que não há nenhum elemento não linear na carga.

O fator de reatividade é indicado por:

$$\lambda_Q = 1 - \frac{I_r^b}{I}$$

Este fator indica a presença de componentes reativos, que podem ser elementos indutivos ou capacitivos na carga. Considerando o sistema monofásico, este fator corresponde a $\lambda_Q = sin(\varphi)$, sendo φ o ângulo de fase entre tensão e corrente.

O fator geral (também chamado de fator de potência) equivale a:

$$\lambda = \frac{I_a}{I}$$

O fator de potência relaciona a proporção entre o trabalho útil da carga com elementos reativos e não lineares. É uma forma de quantificar o quanto a carga não gera algum problema na rede elétrica e o seu valor unitário indica que existem elementos puramente resistivos e que não trazem qualquer problema de qualidade de energia elétrica na rede.

Esta abordagem permitiu com que fosse criada uma base de dados em [24], na qual foram utilizados algoritmos de aprendizado de máquina para realizar a classificação de cargas.

Existe outra abordagem que tem diversas publicações, que é a correspondente ao uso transformadas *wavelets*, que é uma metodologia flexível para representar uma carga que pode possuir sinais variáveis no tempo de funcionamento.

2.5.4 Transformada wavelet

A transformada de Fourier apresenta uma interessante forma de resumir sinais por componentes quantitativas, porém ela possui a grande desvantagem de não fornecer informações de variações no tempo. A transformada de Fourier serve como resumo do momento da forma de onda. Em sistemas de desagregação de cargas a decomposição de harmônicas se torna interessante para cargas que

funcionam em regime permanente e estacionário, não indo bem em cargas que apresentam múltiplos estágios de potência durante o funcionamento.

Matematicamente, a Transformada Wavelet Contínua (CWT - *Continuous Wavelet Transform*) é expressa como:

$$F(a,b) = \sum_{t=0}^{N-1} f(t)\ \psi_{a,b}(t)$$

Na qual:

$f(t)$ é a amostra do sinal contínuo no tempo t;

$\psi_{a,b}(t)$ é a *wavelet* "mãe", base da transformada.

Neste caso, os parâmetros a e b variam continuamente, dentro do conjunto dos números reais, e $\psi_{a,b}$ corresponde à *wavelet* mãe, definida como:

$$\psi_{a,b}(t) = \frac{1}{\sqrt{a}}\psi\left(\frac{t-b}{a}\right)$$

Na qual:

a é o parâmetro de escala ou de dilatação. Quando $a < 1$ existe o efeito de dilatação da função *wavelet* mãe. Quando $a > 1$ há o efeito de contração da função *wavelet* mãe;

b é o parâmetro de tempo ou de translação.

Tem-se de $f(t)$, amostragem de sinal no tempo e unidimensional, uma transformada para $F(a,b)$, sinal transformado bidirecional, transformando em tempo por frequência. Tal transformação permite uma análise aprofundada do comportamento de um sinal em sua escala de diversas frequências [86].

Uma *wavelet* vem de termos "oscilatório" (onda) e "curta duração" (pequena onda), ou seja, é um sinal em forma de uma onda e em curto espaço de tempo. Um dos critérios para aceitar e validar o uso de uma *wavelet* é provar que ela possui comportamento oscilatório curto e que seu valor médio seja nulo, obedecendo a seguinte função [87]:

$$\int_{-\infty}^{+\infty} \psi(t)dt = 0$$

A amplitude da onda, ou energia de propagação da *wavelet* deve ser limitada, obedecendo a seguinte função [87]:

$$\int_{-\infty}^{+\infty} |\psi(t)|^2\, dt < \infty$$

A Tabela 6 apresenta as *wavelets* mais utilizadas na literatura [86] e são classificadas por:

Tabela 6: Tipos de *wavelets* e famílias [87].

Família (Tipo de *wavelet*) (*h*)	Família
a) Biortogonais	bior1.3 bior1.5 bior2.2 bior2.4 bior2.6 bior2.8
b) Daubechies	db2 db3 db4 db5 db6 db7 db8 db9 db10
c) Symlets	sym2 sym3 sym4 sym5 sym6 sym7 sym8
d) Coiflets	coif1 coif2 coif3 coif4 coif5

- **a) Biortogonais:** A família de *wavelets* biortogonais exibe a propriedade de fase linear, a qual é necessária para a reconstrução do sinal. Usa duas *wavelets*, uma para a decomposição e outra

para a reconstrução. As *wavelets* biortogonais são definidas como pares de bases mutuamente ortogonais, mais nenhum desses pares é ortogonal.

- **b) Daubechies:** As *wavelets* ortogonais de Daubechies, "dbN", são compactas no tempo, porém, no domínio da frequência, tem um alto grau de superposição espectral entre as escalas. Sua maior vantagem é serem ortogonais, o que significa que um erro no sinal de entrada não cresce com a transformação e a estabilidade numérica é assegurada. Por outro lado, não possuem fase linear, como na *biortogonal*.

- **c) Symlets:** Esta família de wavelet foi proposto por Daubechies como uma modificação à família "dbN", com possuem propriedades similares, e tendem a ser simétricas.

- **d) Coiflets:** Esta família de wavelets é altamente simétrica. Foi construído também por Daubechies, por requerimentos de buscar a maior simetria possível nas formas de ondas.

Com a aplicação das *wavelets*, aplica-se a decomposição e aplica-se filtros em sub-bandas, obtendo-se, para cada ordem de filtro, uma informação. Ao final, tem-se um conjunto de $F(a,b)$ por cada ordem de filtro e ela se torna uma característica de um sinal. No contexto de NILM, ela se torna uma característica de desagregação de cargas.

O uso da transformada *wavelets* é o tema que mais anda sendo utilizado em NILM, pois decompõe um sinal no domínio do tempo (tensão e corrente) e escalona usando *wavelets*, é possível obter características para cada carga e no contexto de desagregação são comparadas tais características. Nesta aplicação, Chan *et al.* [66] fizeram o estudo pioneiro, foi feita a transformada até o 4º nível, com *wavelets* Daubechies como *wavelets* mães, porém obteve acurácia em torno de 70%. Tanto Su *et al.* [67] quanto Duarte et a. [68] compararam a FFT com a CWT, apresentaram vantagens da CWT em momentos transitórios (quando a carga foi ligada e quando foi desligada) e recomendaram o uso da CWT para a extração de características para aplicações de desagregação de cargas.

Chang *et al.* [61, 88] complementaram a implementação utilizando potências ativa e reativa com a CWT, os autores extraíram características de cargas em cinco filtros e aplicaram algoritmo genético para a identificação de cargas. Eles alcançaram a acurácia próxima a 100%, porém foram feitos estudos de casos nos quais há discrepância em níveis de potência das cargas.

Gray e Morsi [69] utilizaram o consumo de energia no tempo para obter a decomposição pela CWT com *wavelet* mãe Daubechie. Os autores apresentaram resultados comparando a acurácia ao aplicar cada ordem das Daubechies, segundo b) da Tabela 6 e chegaram à conclusão de que, quanto

maior o db, maior a acurácia. Tabatabaei [70] fez um estudo similar, mas utilizou as características de energia para criar atributos classificatórios e obteve acurácia em torno de 85%.

Gillis *et al.* [71] propôs uma nova *wavelet* para aplicações NILM, utilizando projetos que já existem e que foram publicados nos últimos anos. Com a criação da nova CWT, ele criou regras adaptadas para a aplicação e obteve acurácia de quatro cargas conectadas ao mesmo tempo em torno de 94%.

Portanto, os estudos com as transformadas *wavelets* estão se tornando mais fortes na área de desagregação de cargas. Como outra abordagem, tem as características que não são consideradas de baixa ou alta frequência de amostragem, pois independem deste tipo de aquisição por analisarem comportamentos de regime permanente, de transitórios ou de estado de funcionamento da carga medida.

2.6 Características independentes da taxa de amostragem

Entre as características independentes da taxa de amostragem, tem-se como exemplo a assinatura da potência e tendência de comportamento.

Entre os estudos destas características, tem-se:

- **Análise da trajetória da corrente e tensão:** Através da análise comportamental da trajetória dos valores de corrente pela tensão. Hassan et al [72] fizeram um método que analisa a trajetória da tensão pela corrente e aplicaram algoritmos de aprendizado de máquina - SVM, AdaBoost e Redes Neurais - e obtiveram índices de acurácia acima de 98%, para a desagregação de uma única carga. Baets *et al.* [75] utilizaram redes neurais convolucionais para classificação de trajetórias de tensão e corrente e obteve, no geral, acurácia de 77%. Du *et al.* [73] aplicaram mapas auto-organizáveis em um sistema supervisionado e a acurácia por equipamento oscilou entre 70% a 95%. Também, utilizando a trajetória tensão x corrente, Gao *et al.* [74] propuseram um método que reconhece o gráfico de trajetória tensão x corrente como uma imagem binária e alcançou acurácia entre 70% a 80%. A Figura 6 apresenta o gráfico de trajetória de tensão por corrente e a ideia de transformar em imagem binária de [74].

- **Corrente inativa:** Com o aumento de cargas com características não lineares no sistema elétrico, as teorias de potência vêm ganhando destaque, sobretudo aquelas que propõem a decomposição da potência aparente em características não lineares. A subseção 2.2.3 indicou algumas teorias e seu uso em aplicações de desagregação de cargas. Porém, existem trabalhos que uti-

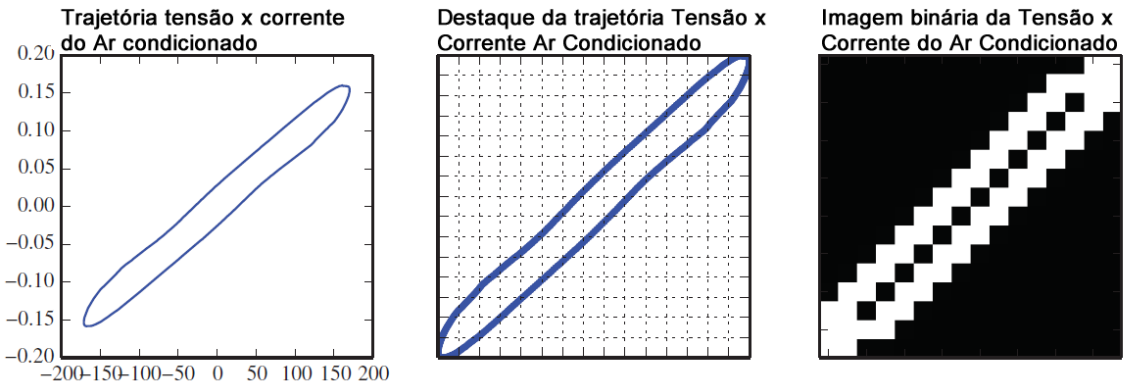

Figura 6: Conversão da trajetória Tensão x Corrente em imagem binária [74].

lizaram somente a característica da trajetória da componente não ativa, como Teshome *et al.* [63], que perceberam que a componente não ativa possui um baixo valor de similaridade entre os diferentes eletrodomésticos, consequentemente esta seria uma forte candidata para a extração de características para a desagregação de cargas.

- **Características não convencionais:** Existem outros trabalhos que levantaram características que poucos trabalhos (ou somente o próprio) utilizaram. Tem-se, entre as características chamadas aqui de "não convencionais" as:

  1. **Ruído harmônico:** Patel *et al.* [76, 77] utilizaram o ruído de sinal por extração harmônica da tensão (FFT), considerando ruídos e interferências eletromagnéticas na faixa entre 36 a 500 *kHz*. Porém, este estudo destacou somente aqueles equipamentos que possuem múltiplos estágios de funcionamento.

  2. **Distribuição probabilística de carga ligada ou desligada:** Kim *et al.* [78] construíram um método não supervisionado utilizando os eventos de carga ligada ou desligada. A correlação entre o uso de várias cargas com a potência ativa auxiliou na melhoria da acurácia do método, que chegou a cerca de 80%.

  3. **Pulsos discretos baseados na série temporal de potência:** Koutitas e Tassiulas [79] substituíram a série temporal de sinal contínuo da potência em conjuntos de pulsos discretos. Juntamente a estes dados, os autores utilizaram dados probabilísticos comportamentais (probabilidade de uso, tempo de operação, pulsos vizinhos, entre outros) para aprimorar a acurácia do método, que chegou a 90%.

  4. **Combinação de características:** Lin *et al.* [62] propuseram o uso combinatório de mé-

todos não convencionais com características de baixa e alta frequência de aquisição. A acurácia do método chega aos 90%, porém não indica quais são estas características na metodologia.

Como indicado, a metodologia deste projeto tem como base o proposto por Souza *et al.* [18, 24] e a seguir será destacada a coleta de dados realizada, as características que foram coletadas e quais são as potenciais características que podem ser adicionadas ao conjunto de dados de desagregação para o projeto.

2.7 Considerações

Como apresentado neste capítulo, tal assunto vem chamando a atenção na literatura e diversos trabalhos estão apresentando abordagens para a identificação de cargas, utilizando extração de atributos em baixa, alta frequência e independentes da frequência. Entre os trabalhos apresentados, tem-se níveis de assertividade que variam entre 70% a 98%.

Entre diversos estudos, tem-se o de Souza et al. [18], que possui a extração de características em alta frequência, baseada em uma teoria de potência criada na última década – a CPT. Esta teoria de potência permite caracterizar as cargas em quantidades de potência, de acordo com o comportamento da carga, como se fosse um circuito equivalente. Tendo em consideração os estudos feitos por Souza et al, tem-se a proposta de aprimoramento dele, para isso a seção a seguir apresentará a proposta nova do medidor cognitivo residencial.

3 Proposta de medidor cognitivo residencial

3.1 Caracterização do sistema

O modelo proposto é composto por um conjunto de hardware, software e sistemas de instrumentação. De modo geral, o protótipo pode ser divido nos seguintes módulos: sensoriamento e condicionamento de sinais, modulo de conversão analógico-digital (A/D) e unidade de processamento, conforme ilustrado na Figura 7.

A unidade de sensoriamento e condicionamento dos sinais é utilizada para adequar as grandezas medidas. Isso se faz necessário, pois o circuito de conversão A/D opera com níveis específicos de tensão. Esses sinais são convertidos e transmitidos para unidade de processamento, que tem como tarefa processar e armazenar essas informações.

Para desenvolver o medidor foi escolhida a plataforma Beagle Bone Black (BBB). Um dos principais elementos presentes na BBB é a unidade de tempo real, que opera em paralelo com o processador, tendo acesso a sua memória interna e aos periféricos. Isso possibilita a criação de procedimentos que são executados paralelamente as aplicações executadas pelo sistema operacional. Nesse projeto, as unidades de tempo real foram utilizadas para coletar os dados do conversor A/D.

Figura 7: Diagrama da plataforma desenvolvida.

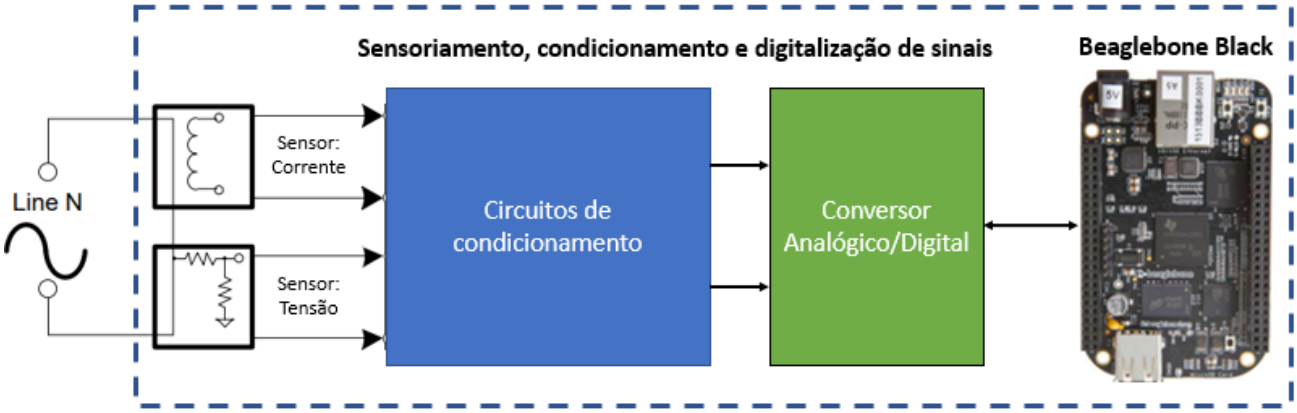

3.2 Descrição dos elementos de hardware

Para a construção do medidor cognitivo, alguns elementos de hardware são essenciais, estes serão apresentados nas próximas subseções.

3.2.1 Plataforma de desenvolvimento

Atualmente, a BBB (BeagleBone Black rev.C) é bem popular, principalmente devido ao baixo custo e suporte dado pela comunidade de desenvolvedores. Tal plataforma é mostrada na Figura 8 e suas principais características são listadas abaixo:

- Processador Texas Instruments Sitara AM3358.
- Core ARM® Cortex-A8 com frequência de até 1GHz;
- Acelerador NEON com ponto flutuante integrado ao processador;
- Memória DRAM de 512MB DDR3L;
- Memória Flash eMMC 4GB 8-bit;
- Duas unidades progrmáveis de tempo real (PRU-ICSSs - RISC de 32-bits com clock de 200MHz);
- Acelerador gráfico 3D.

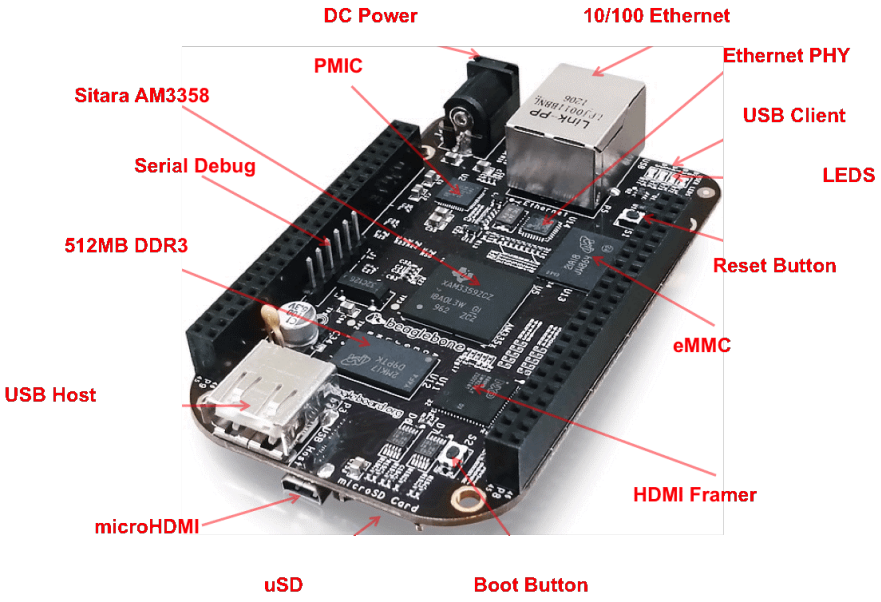

Figura 8: Plataforma de Desenvolvimento – BBB.

Além disso, a BBB é rica em interfaces que possibilitada conectar uma variedade de dispositivos:

- USB Client e Host;

- Conector Ethernet para conexão de rede cabeada;
- Conector para vídeo tipo Micro HDMI;
- Possui dois headers de 46 pinos.

A disposição dos headers é ilustrada na Figura 9.

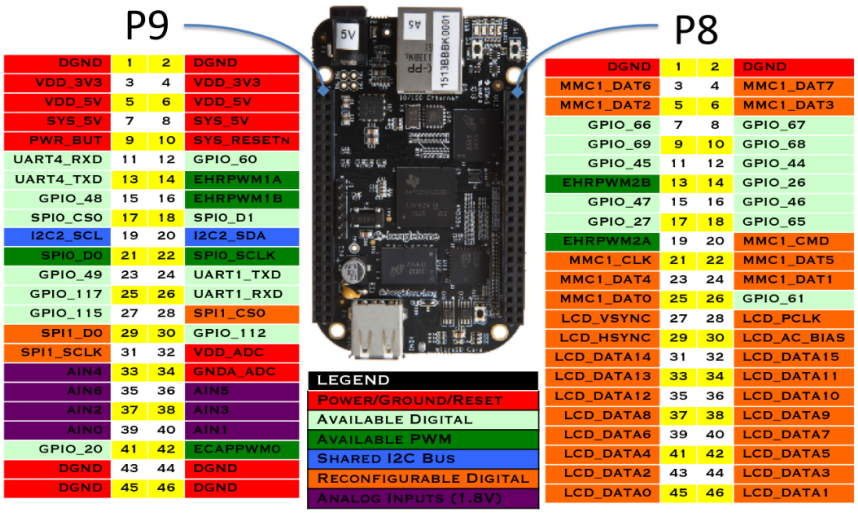

Figura 9: Headers disponíveis para conexão.

3.2.2 Condicionamento dos sinais analógicos

O condicionamento dos sinais é realizado por um circuito desenvolvido com a colaboração dos integrantes dos grupos de pesquisa GASI/UNESP de Sorocaba (Grupo de Automação e de Sistemas Integráveis) e da FEEC/UNICAMP [18]. A função desse circuito (vide Anexo A) no sistema é adequar o nível de tensão gerado na saída dos sensores de tensão e corrente para as entradas do conversor A/D. As principais características desse circuito são listadas a seguir:

- Suporta até 4 sensores;
- Possui um sensor de temperatura integrado;
- Ajuste do valor máximo da saída analógico:
  - Automático - usa como referência o fundo de escala do conversor A/D ou o valor gerado pelo gerador de referência interno;

  - Offset fixo - metade do valor máximo, sendo independente para cada canal.

- Limitação dos valores máximos e mínimos de saída para proteção do conversor A/D;

- Ajuste de ganho para cada canal;

No desenvolvimento deste projeto de mestrado, foram utilizados os sensores LV25-P e LA25-P. Uma fonte de alimentação simétrica é necessária para fornecer os níveis de tensão +15V e -15V usados nos circuitos. Na Figuras 10a e 10b são mostradas as faces da placa de condicionamento dos sinais de tensão.

Figura 10: Placa para condicionamento dos sinais de tensão.

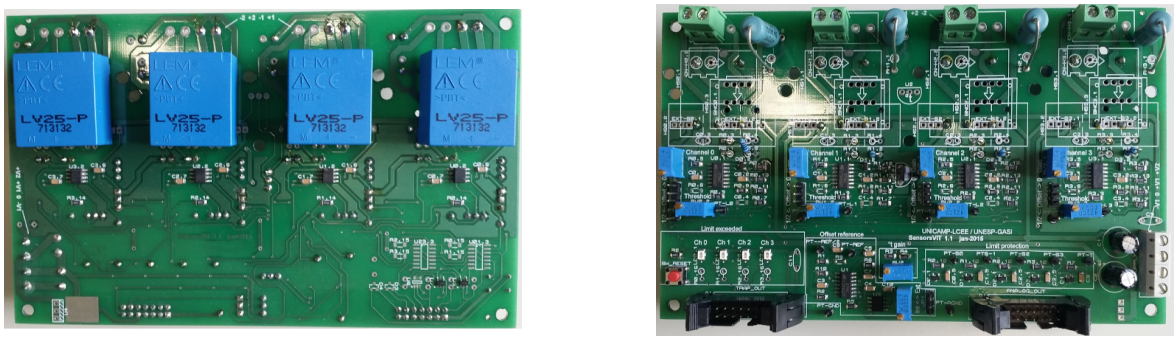

(a) Sensores LV25-P.

(b) Visão frontal - Circuitos de condicionamento.

Na Figura 11 é mostrada a placa de condicionamento dos sinais de corrente.

Figura 11: Placa para condicionamento dos sinais de corrente - Sensores LA25-P.

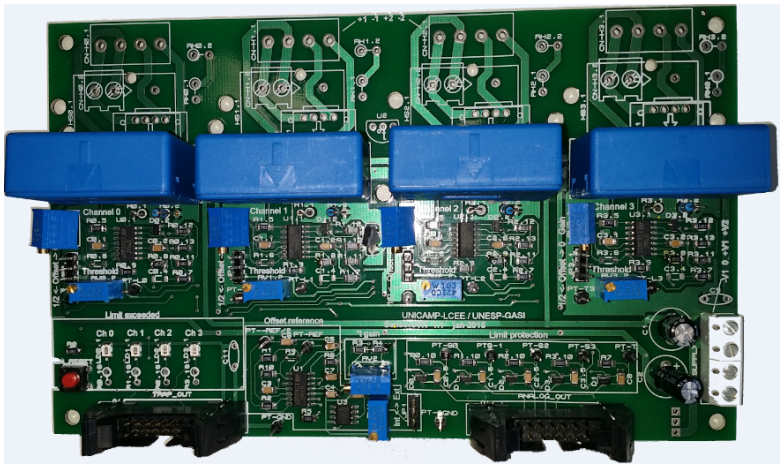

3.2.3 Conversor analógico/digital

O conversor analógico-digital ADS131E08S utilizado nesse projeto é da família ADS131E0x. Essa família de dispositivos é caracterizada por apresentar vários canais de conversão simultâneos do tipo delta-sigma ($\Delta\Sigma$). Além disso, tal conversor possui resolução de 24 bits, referência de tensão interna, controle de ganho e oscilador interno. As principais aplicações desse conversor são da área de energia como: medição de sinais de tensão e corrente de fase, monitoramento, controle e proteção.

Em comparação com o trabalho desenvolvido por [18], o conversor A/D opera em modo diferencial com faixa de conversão entre +2.5V e -2.5V, e resolução de 24 bits. A frequência de conversão é determinada por um oscilador externo de 3,93216 MHz. Essa frequência é necessária para que a conversão de amostras durante um período seja uma potência de 2. O diagrama do utilizado montado é mostrado na Figura 12.

3.3 Aquisição de dados

Para a aquisição de dados, as unidades de tempo real são utilizadas de forma sincronizada. Nesse caso, uma unidade de tempo real (PRU1) é programada para transferir os dados do conversor AD para um buffer temporário. Para isso, a PRU1 controla os pinos de entrada e saída digital (do inglês, input/output - I/O) da BBB para realizar a transferência de dados utilizando o protocolo de comunicação serial entre periféricos, denominado SPI (do inglês, Serial Peripheral Communication).

A comunicação SPI é caracterizada por apresentar dois sinais de controle, sendo um deles utilizado como sinal de sincronismo SCLK (do inglês, Serial Clock) e outro como sinal de seleção CS (do inglês, Chip Select). De acordo com o sinal SCLK, as informações são transferidas pelos pinos MISO (do inglês, Master Input / Slave Output) e MOSI (do inglês, Master Output / Slave Input). Isto é, ocorre transferência bidirecional entre os dispositivos. O protocolo de comunicação é ilustrado na Figura 13. No conversor AD, os sinais MISO e MOSI são indicados como DIN e DOUT, respectivamente.

Além da aquisição de dados, o mesmo protocolo é utilizado para configuração do conversor AD. Isto é realizado a partir de comandos de configuração. Assim, na inicialização da PRU1 o conversor AD é configurado para o modo de operação desejado. Após a configuração, o conversor AD entra em modo de operação contínuo, sendo monitorado a partir do sinal DRDY (Data Ready), que tem como função indicar quando uma amostra está disponível. Quando o conversor AD sinaliza o fim de uma conversão, os dados dos 8 canais mais a palavra de estados são transferidas para a PRU1. O diagrama

Figura 12: Circuito do conversor A/D.

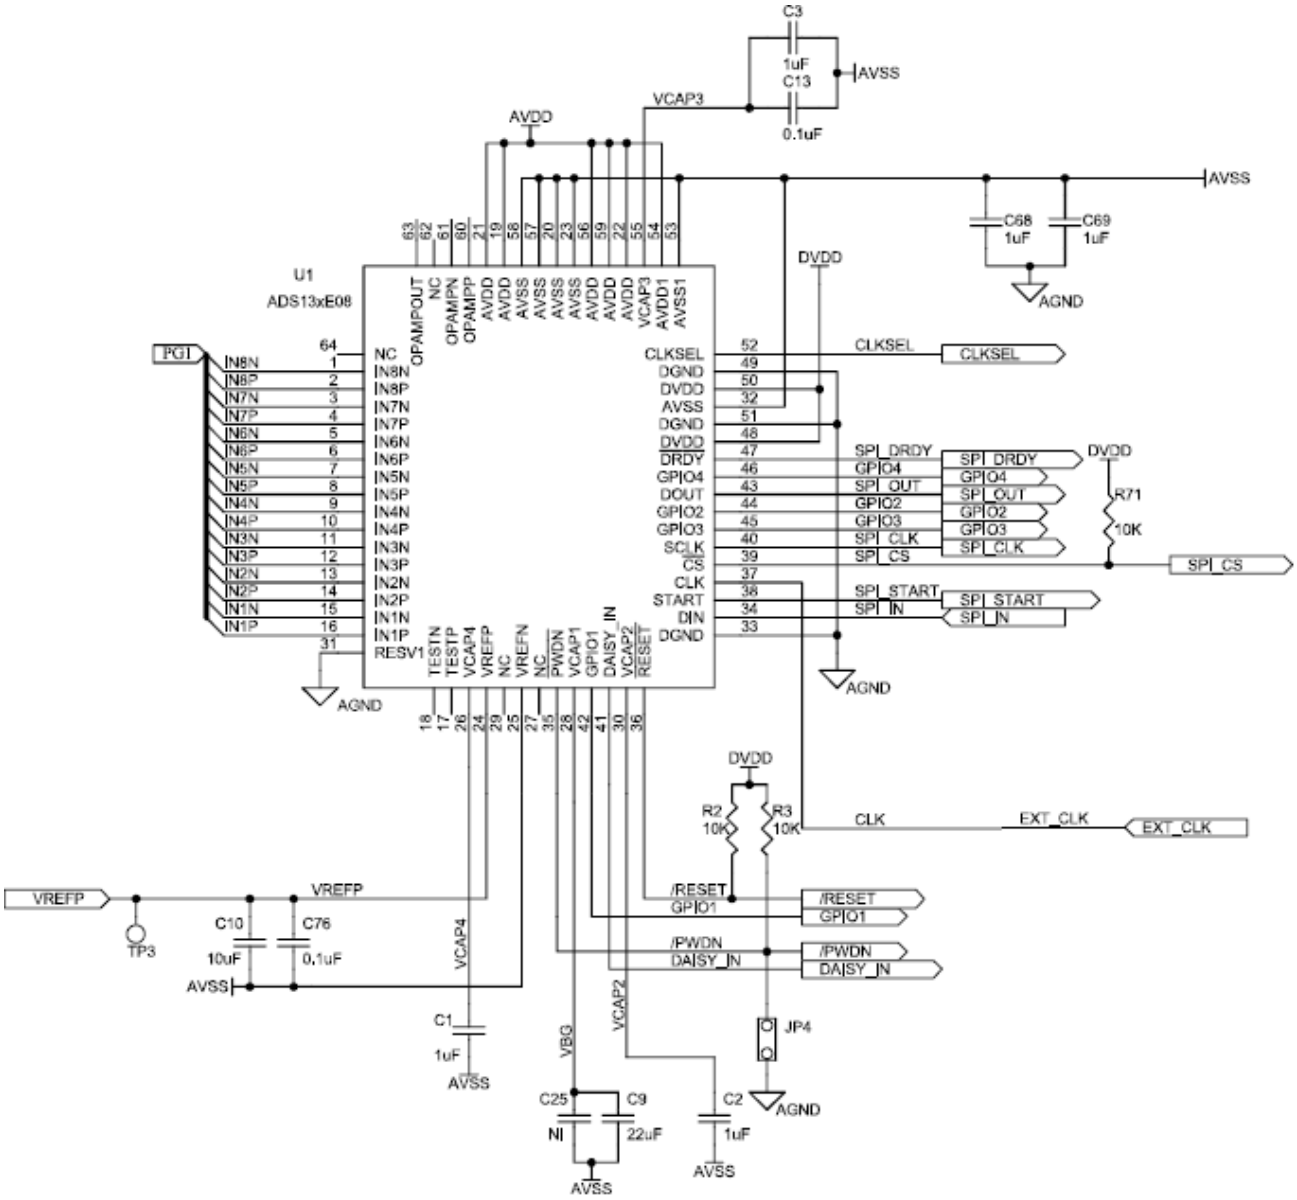

de transferência é mostrado na Figura 14.

A transferência de dados é executada na PRU1 a partir de um procedimento responsável por capturar as amostras dos oito canais de conversão, totalizando 28 bytes. Tal procedimento é realizado 4 vezes, formando um pacote de dados com 4 amostras de cada canal.

Durante esse procedimento, os bytes que são transferidos do ADC para a PRU são armazenados em registradores. Todos os registradores envolvidos nesse processo estão localizados em região de memória compartilhada entre as unidades de tempo real, denominada scratch pad memory. Essa

Figura 13: Conexão entre a PRU1 e o conversor AD.

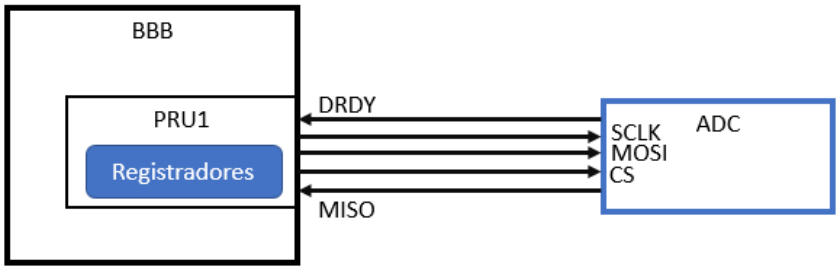

Figura 14: Leitura dos canais de conversão após a sinalização de uma amostra convertida.

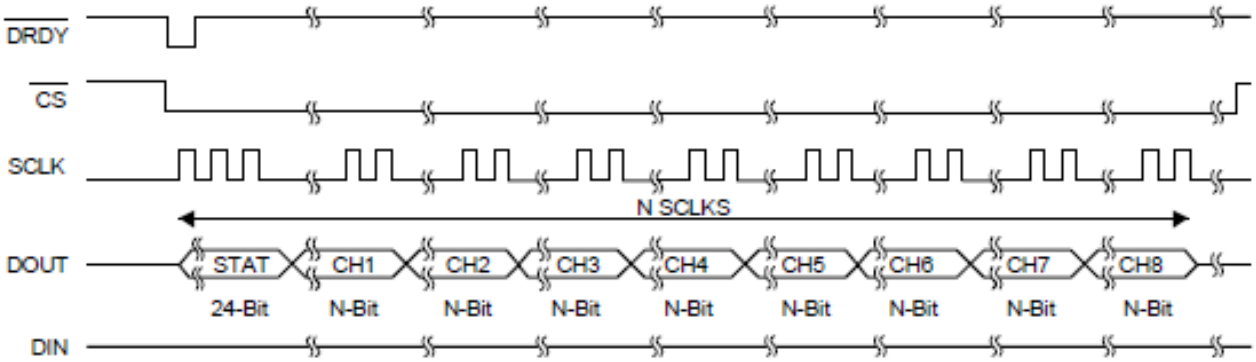

região possui instruções específicas para realizar transferência de dados entre as unidades de tempo real, facilitando a transferência de blocos de dados.

O procedimento executado pela PRU1 é apresentado na Figura 15.

Ao mesmo tempo, a outra unidade de tempo real (PRU0) monitora um evento de interrupção que é gerado pela PRU1, indicando que os dados foram capturados. Diante disso, a PRU0 copia os dados transferidos e armazena-os em outra região da memória.

Esse procedimento é repetido 3840 vezes, totalizando 15360 amostras por segundo para cada canal. Posteriormente, a PRU0 emite um sinal de interrupção que é capturado pela aplicação principal. O procedimento executado pela PRU0 é apresentado na Figura 16.

Nesse ponto, a aplicação pode processar as informações enquanto as unidades de tempo real voltam a capturar as próximas amostras. Devido a taxa de aquisição e ao volume de dados, as unidades de tempo real utilizam uma região de memória compartilhada com a CPU. Para auxiliar nesse processo, uma estrutura de registros foi criada para garantir que o processamento dos dados pela CPU não seja interferido pela coleta de dados nas unidades de tempo real. Isto é, enquanto a unidade de tempo real escreve em um determinando buffer a CPU processa outro. Esse processo é mostrado na Figura 17.

Figura 15: Fluxo de operações da PRU0.

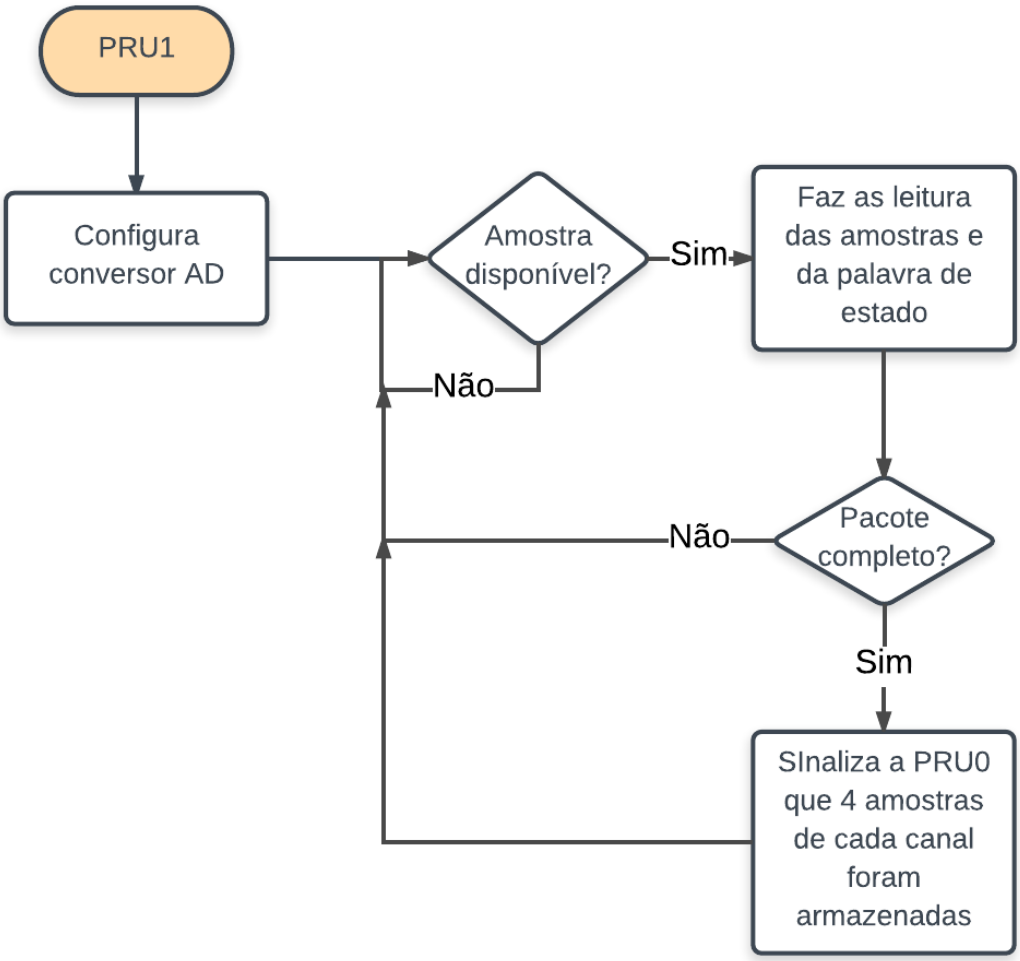

Por fim, a arquitetura geral do sistema é ilustrada na Figura 18.

3.4 Algoritmos implementados

Na construção da proposta, tem-se a implementação de software como base fundamental. Os algoritmos responsáveis pela extração de atributos e de detecção de eventos serão apresentados nas subseções a seguir.

3.4.1 Procedimento de cálculo da CPT

Tendo em vista a aplicação da CPT para análise das cargas, desenvolveu-se um algoritmo para realizar todo procedimento matemático necessário conforme o equacionamento apresentado no capítulo 4.

Figura 16: Fluxo de operações da PRU0.

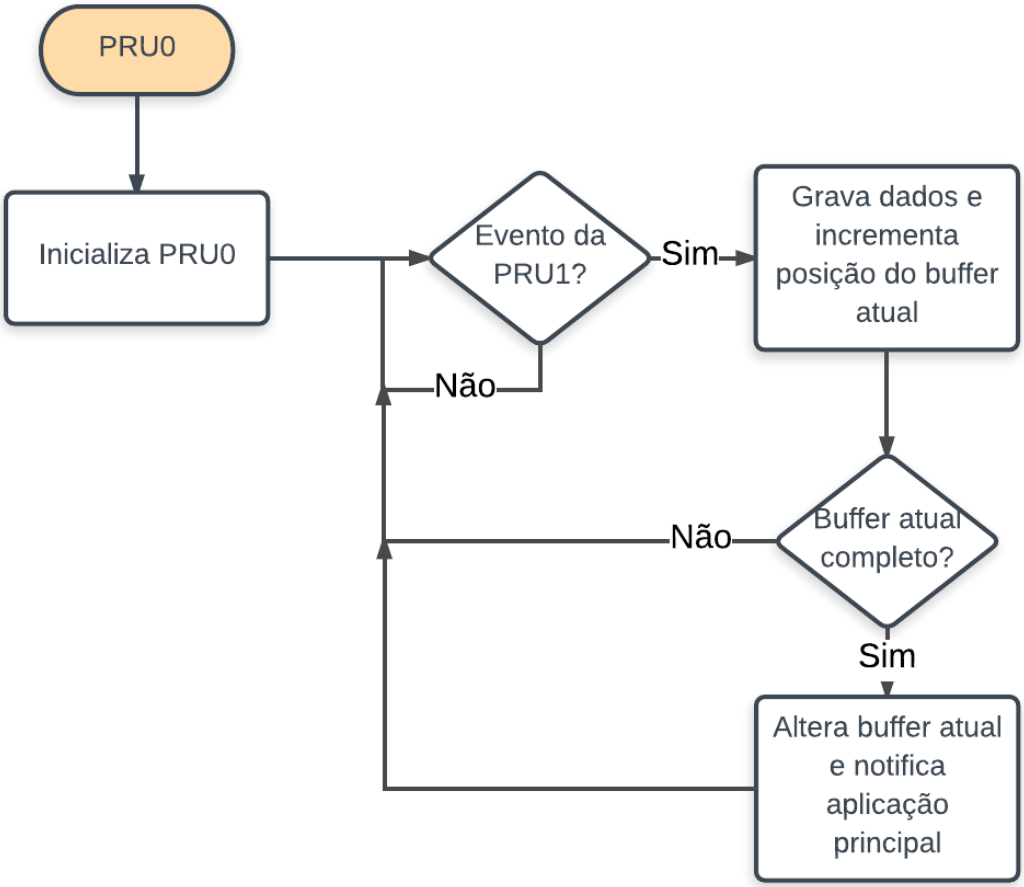

Data: Amostras de Tensão V, Amostras de Corrente I, Quantidade de Amostras N

Result: Decomposição da potência e corrente

for $i \leftarrow 0$ **to** $N-1$ **do**

```
    //Cálcula valor RMS de tensão e corrente
    //Atualiza o valor da integral e integral imparcial
    UpdateVoltagesAndCurrents(V[i], I[i]);
    //Cálcula potência ativa e energia reativa da fase
    UpdatePowerAndEnergy(V[i], I[i]);
    //Realiza a decomposição da corrente
    CurrentDecomposition(I[i]);
    //Cálcula os termos de potência
    PowerDecomposition();
    //Cálcula os indicadores
    EvaluateFactors();
end
```

Algorithm 1: Procedimento de cálculo da CPT.

Figura 17: Fluxo de operações da aplicação principal.

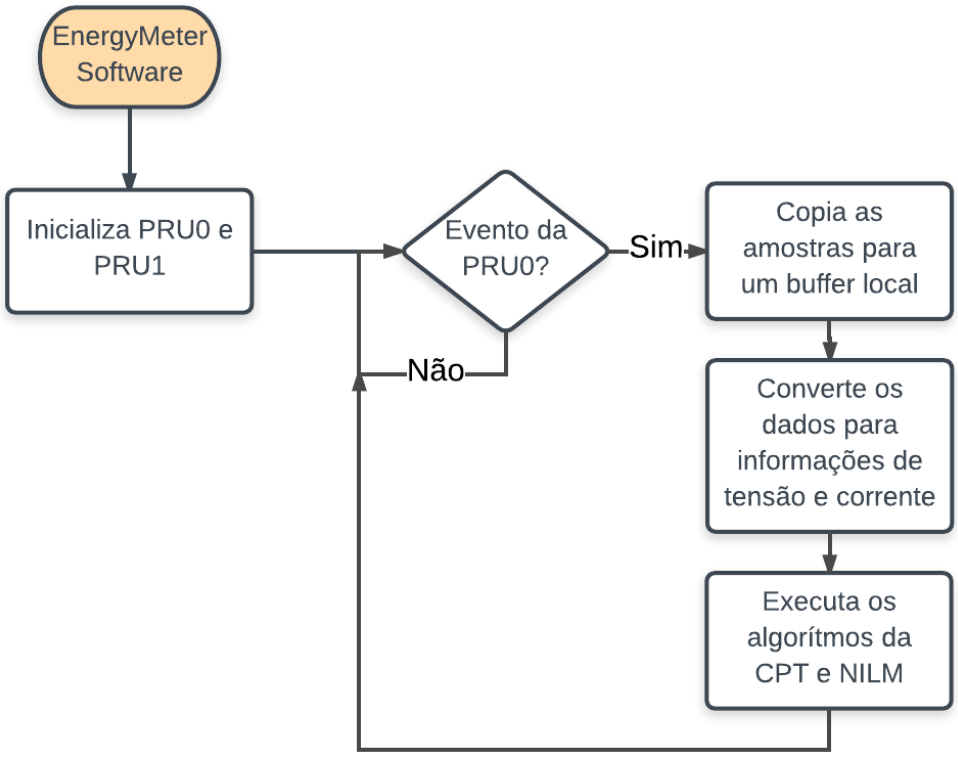

Figura 18: Conexão entre os elementos do sistema.

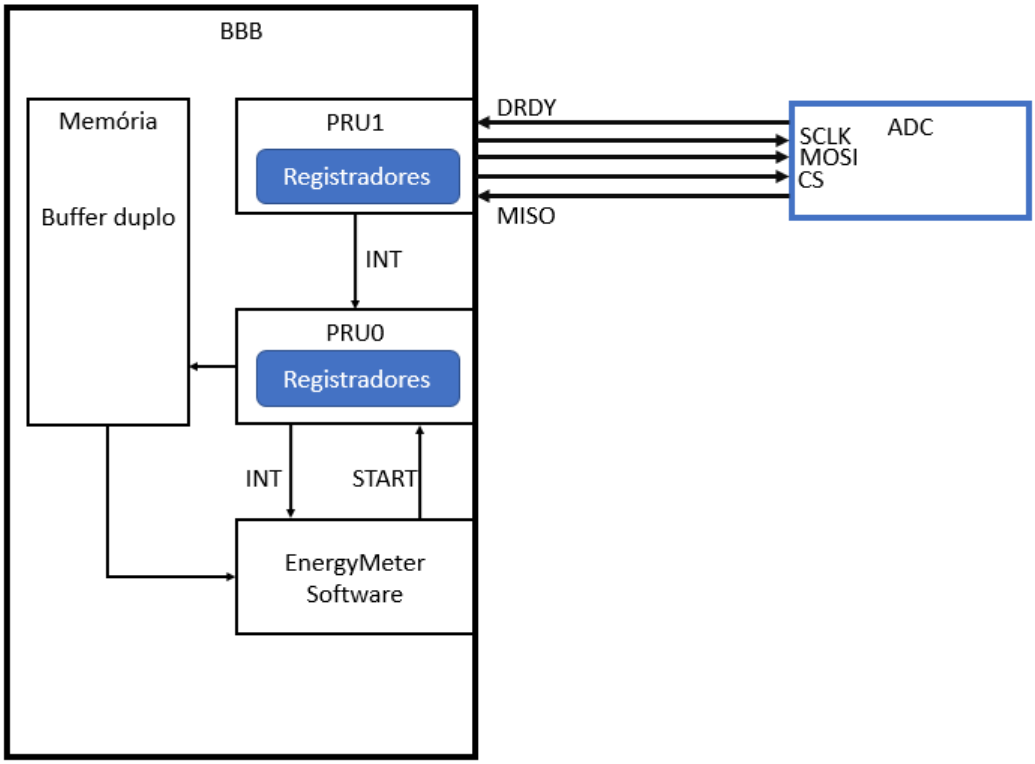

3.4.2 Algoritmo de Goertzel

Para o cálculo das componentes harmônicas utilizou-se o algoritmo de Goertzel. Assim como na transformada rápida de Fourier (FFT) e na transformada discreta (DFT), o algoritmo de Goertzel calcula as componentes do domínio da frequência.

Se a informação de fase não é necessária, tal algoritmo pode ser melhorado para diminuir a quantidade de operações. Nesse caso, a resposta do algoritmo para cada componente calculada é equivalente ao quadrado de sua magnitude.

De modo geral, o algoritmo de Goertzel implementa a DFT a partir da recursão de equações diferenciais. Para isso, a DFT é calculada como sendo a convolução de um sinal x(n) com uma janela h(n). O sinal x(n) possui N pontos, enquanto a janela h(n) é equivalente a frequência Wn. Tal procedimento é mostrado abaixo.

Data: Amostras, N, F, Fs

Result: Magnitude das componentes de frequência

k = floor(0.5 + ((N * F) / Fs));

w = (2*π/N)*k;

coeff = 2 * cos(w);

V2 = V1 = 0;

for $i \leftarrow 0$ **to** $N-1$ **do**

  V0 = (coeff * V1) - Q2 + x(i);

  V2 = V1;

  V1 = V0;

end

magnitude^2 = V1^2 + V2^2 - V1*V2*coeff;

Algorithm 2: Algoritmo de Goertzel adaptado para calcular somente a magnitude da fase.

O diagrama do algoritmo implementado é mostrado na Figura 19.

3.4.3 Algoritmo de classificação KNN

O algoritmo conhecido como KNN, criado por Hart e Cover [11], é um classificador sub ótimo que não necessita de treinamento, portanto é um classificador não paramétrico. Tal abordagem também é

Figura 19: Forma direta 2.

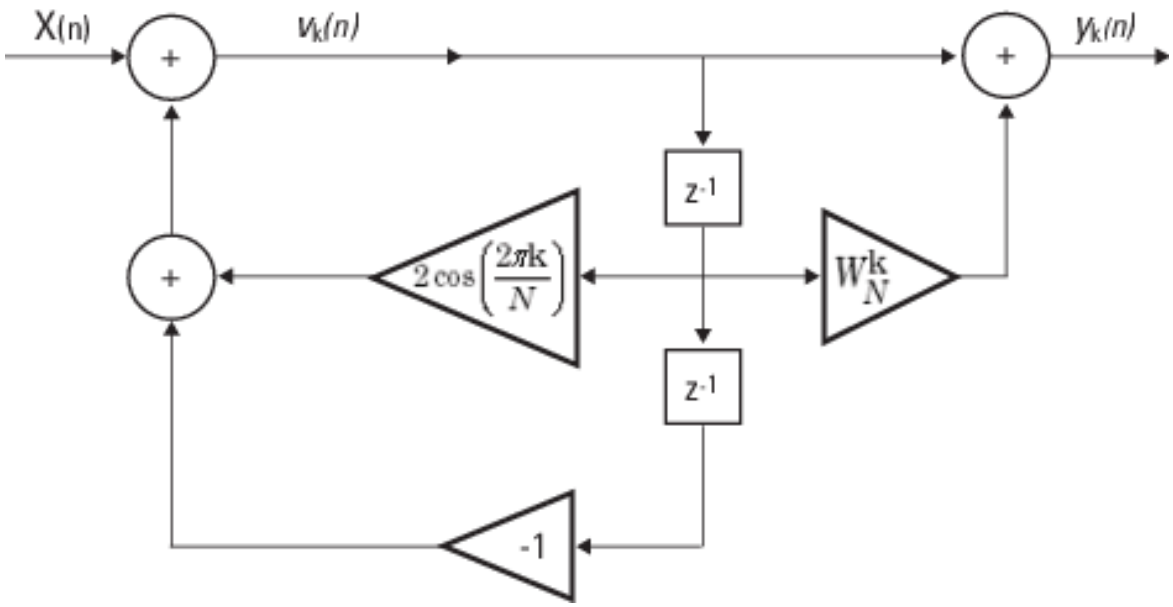

conhecida como método de aprendizagem baseada em exemplos ou aprendizagem baseada em memória [89]. No algoritmo KNN, a classificação de uma amostra é realizada a partir da relação existente entre a amostra e seus K vizinhos mais próximos, sendo os vizinhos previamente classificados [11]. Assim, dado uma amostra 'xq' o algoritmo pesquisa o conjunto de vizinhos mais próximos VP(k, xq). Esse conjunto é utilizado para determinar a classe que aparece com mais frequência no conjunto de amostras. Além disso, 'k' é sempre um número ímpar para evitar casos de empate, isto é, conjuntos que contenham quantidades iguais de elementos de classes diferentes [89].

Como o problema implica em determinar o vizinho mais próximo, isso estabelece uma relação de distância entre os elementos [89], podendo ser calculada usando a métrica euclidiana 1. Na equação, 'm' representa a quantidade de atributos do conjunto.

$$d(X,xq) = \sqrt{\sum_{\mu=1}^{m}(X_u - xq_u)^2} \tag{1}$$

Diante disso, o algoritmo para k igual a 1, implica em encontrar o vizinho mais próximo entre todos de um conjunto (Z). Para outros valores de k, a classe vencedora é a que aparece mais vezes entre os k–vizinhos mais próximos.

$$VP(k,xq) = \arg\min_{\forall X_i \in Z}(d(X_i,xq)) \tag{2}$$

Figura 20: Exemplo de classificação de uma amostra utilizando o algoritmo KNN.

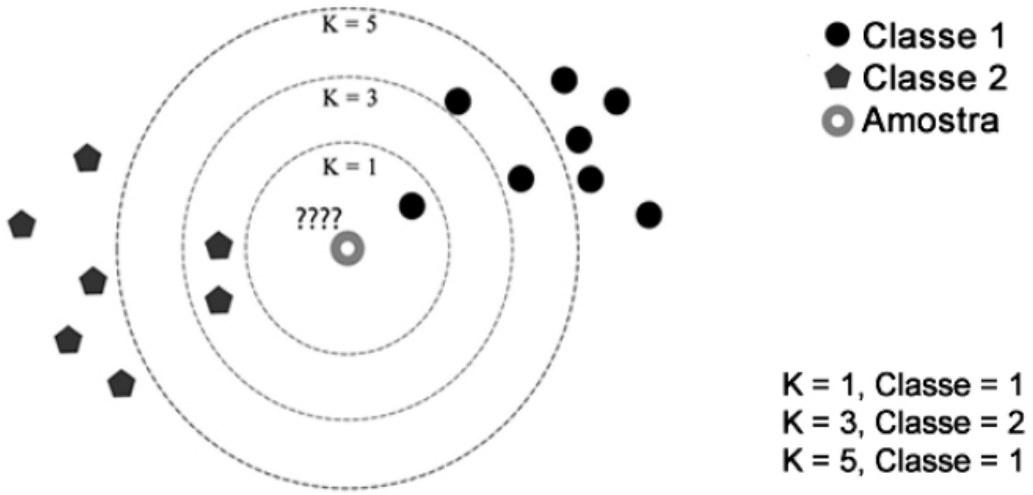

No exemplo ilustrado, a amostra pertence a classe 1 para k igual a 1; classe 2, para k igual a 3; classe 1, para k igual a 5.

3.4.4 Monitoramento de cargas

Para o desenvolvimento da técnica de monitoramento de cargas optou-se por analisar um quarto das amostras obtidas em um ciclo de execução do sistema (15360 amostras). Nesse processo, a potência ativa é monitorada tendo em vista a detecção de eventos que indiquem quando uma carga é ligada ou desligada.

Especificamente, tais eventos são caracterizados por apresentar uma transição entre dois segmentos de dados (amostras de potência ativa) contíguos e consecutivos. Contudo, nem toda mudança indica, definitivamente, uma carga sendo ligada ou desligada. Pois, alguns equipamentos apresentam consumo variável.

Na Figura 21 é mostrado o comportamento de 6 tipos de cargas.

Assim, considerando que um evento representa uma mudança no consumo de potência ativa, determinou-se um valor limiar. Isso é necessário para que o algoritmo possa identificar alterações provenientes de ruídos intrínsecos do sistema de aquisição. Sabendo disso, qualquer variação maior que o valor estabelecido pode representar um evento. No entanto, o consumo de um equipamento pode oscilar em torno de um valor médio, sendo que a oscilação pode ser maior que o valor limiar.

Para tratar esses casos, desenvolveu-se um algoritmo para detectar as oscilações. Tal condição é obtida com duas amostras de atraso, verificando sua diferença com valores anteriores e posteriores.

Figura 21: Padrões de consumo para diferentes cargas.

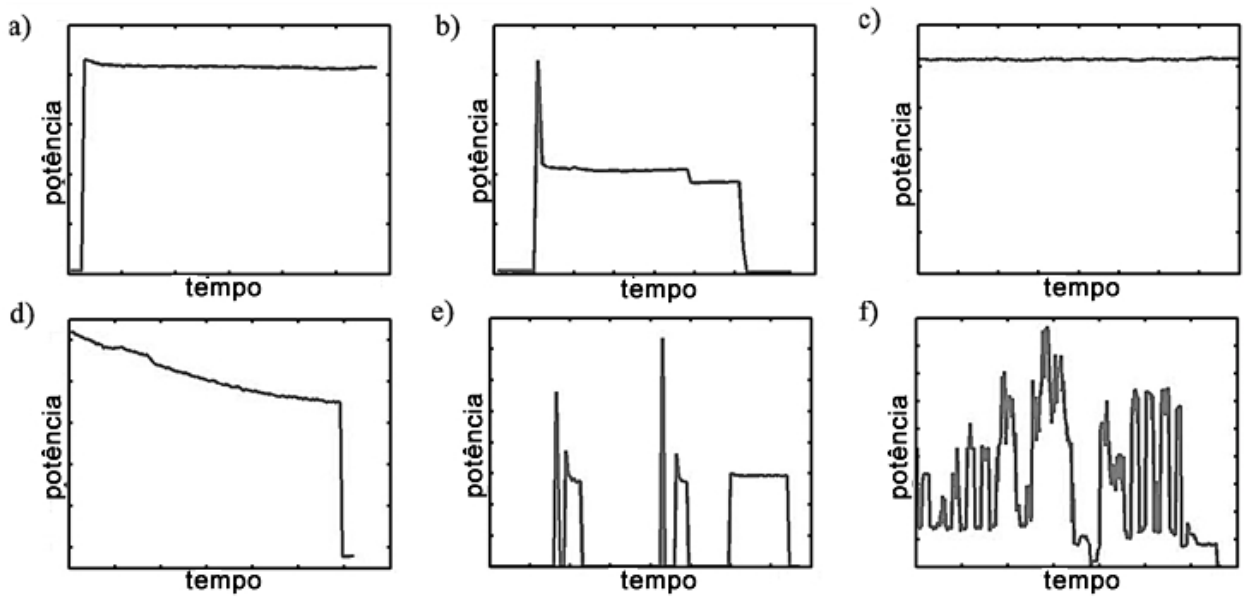

Assim, obtém-se como resultado indicadores de picos positivos e negativos.

```
Data: P (potência ativa), N=4
begin
    Panterior = Janela[0];

    for i = 0; i < (N-1); i++ do
        Janela[i] = Janela[i+1];
    end

    Janela[N-1] = P;

    PicoNegativo1 = Janela[N/2-1] - Panterior;
    PicoNegativo2 = Janela[N/2-1] - Janela[N-4];

    PicoPositivo1 = Janela[N/2-1] - Janela[N-2];
    PicoPositivo2 = Janela[N/2-1] - Janela[N-1];
end
```

Algorithm 3: Procedimento para verificar eventos.

Tais indicadores são comparados com valores limiares, definindo se o processo de monitoramento deve ser iniciado.

```
Data: P (potência ativa)
if Estado 0 then
    if Picos Positivos e Negativos, contíguos e consecutivos then
        Estado = Estado 0;
    else
        if Picos Positivos maiores que o limiar then
            Estado = Estado 1;
        else
            if Picos Negativos maiores que o limiar then
                Estado = Estado 2;
            else
                Estado = Estado 3;
            end
        end
    end
end
```

Algorithm 4: Procedimento para verificar se ocorreu algum evento.

De modo geral, todo pico detectado tem o tempo registrado. Durante esse procedimento a potência é monitorada e, se permanecer estável durante determinado período, o evento é validado. Esse procedimento é mostrado abaixo.

```
Data: Picos positivos, Picos negativos, Estado atual
if Estado 1 then
    if PicoPDetectado = falso then
        PicoPDetectado = verdadeiro
    else
        //Verifica possibilidade de uma nova carga mudar de estado
        CargaLigada();
    end

    //Inicia procedimento para aguardar estabilização Estado = Estado 3;
else
    if Estado 2 then
        if PicoNDetectado = falso then
            PicoNDetectado = verdadeiro
        else
            //Verifica possibilidade de uma nova carga mudar de estado
            CargaDesligada();
        end

        //Inicia procedimento para aguardar estabilização
        Estado = Estado 3;
    end
end
```

Algorithm 5: Procedimento para iniciar o monitoramento.

Cabe ressaltar que enquanto a estabilização é aguardada outro evento pode acontecer. Considerando isso, o algoritmo faz uma verificação para identificar se outra carga está mudando de estado. Se essa condição é verdadeira, a estabilização atual é encerrada e outro processo é iniciado.

O procedimento de estabilização após a detecção de uma transição é mostrado abaixo. Nesse estado, a cada iteração do procedimento de monitoramento uma variação temporizadora é incrementada. Ao atingir o tempo de estabilização, o procedimento para adicionar ou remover uma carga do processo é executado.

```
Data: Picos positivos, Picos negativos, Estado atual
if Estado 3 then
    if PicoPDetectado = verdadeiro then
        if TempoLigado < Testab then
            TempoLigado++;
        else
            CargaLigada();
        end
    end
    if PicoNDetectado = verdadeiro then
        if TempoDesligado < Testab then
            TempoDesligado++;
        else
            CargaDesligada();
        end
    end

    //Finaliza procedimento de estabilização e retorna para o estado inicial
    Estado = Estado 0;
end
```

Algorithm 6: Procedimento para estabilização dos eventos.

Se mais de uma carga está presente no sistema, a carga que gerou o evento deve ser analisada desconsiderando as demais. Isso é realizado fazendo a diferença entre a forma de onda da corrente no instante de detecção com a registrada no último evento. Com a forma de onda resultante, o algoritmo da CPT pode ser executado somente para o período analisado, resultando numa aproximação da carga que gerou o evento.

Quando o consumo de potência ativa está estabilizado e nenhuma carga foi detectada, o procedimento é reiniciado. Essa condição pode ocorrer quando um evento de carga ligada não é detectado. Outra situação é quando o consumo de potência ativa é menor que o limiar e o sistema indica que uma ou mais cargas estão ligadas. Nesse caso, as cargas são removidas do processo de monitoramento.

Por fim, as informações de tempo marcadas em cada evento são usadas para identificar o período de operação do equipamento. Sabendo disso, o modelo de comportamento da carga (Figura 21) pode

ser utilizado para estimar o consumo de energia para um determinado período. Tal procedimento é chamado desagregação de consumo de energia por cargas.

3.4.5 Desagregação do consumo de energia

A abordagem empregada para realizar a desagregação do consumo é a seguinte: quando um evento de carga ligada é detectado, inicia-se um processo para armazenar o valor médio de potência a cada segundo. Se outro evento é detectado, verifica-se se a carga foi desligada ou se outra carga foi ligada.

Para a primeira situação – em que a carga é desligada – o processo que está registrando o consumo é encerrado, formando um bloco de amostras de potência ativa durante um determinado período. Nesse caso, o bloco é atribuído a carga que foi classificada durante o período e a energia consumida é calculada.

Para a segunda situação – em que outra carga é ligada – as amostras armazenadas até o momento do segundo evento formam um bloco que é atribuído para a carga classificada no período. Esse bloco é mantido para análise posterior. Enquanto isso, as amostras de potência ativa continuam sendo armazenadas até que ocorra outro evento.

De modo geral, qualquer evento de carga ligada causará a formação de um novo bloco. Com isso, o bloco estará associado a uma ou mais cargas. Considerando tal procedimento, a desagregação será realizada somente quando um evento de carga desligada for detectado. Então, o consumo desagregado é calculado considerando todos os blocos associados a carga que foi desligada.

Para os blocos que estão associados com mais de uma carga, a potência média e a assinatura de carga são levados em consideração. Para tal, essas informações são registradas e atualizadas durante a formação dos blocos.

Por fim, cabe ressaltar que a metodologia proposta para desagregação foi desenvolvida utilizando um banco de dados no próprio sistema, facilitando a manipulação das informações e a integração com o sistema de monitoramento de eventos.

3.5 Sistema supervisório

Para apresentar as informações obtidas, criou-se um sistema de gerenciamento de consumo. Como destacado, as informações de consumo desagregado são as que possibilitam maior redução de consumo. Sabendo disso, optou-se por disponibilizar informações referentes ao próprio dia, sendo atualizadas sempre após a operação de um eletrodoméstico.

No modelo proposto, as seguintes funções foram implementadas – visualização do consumo desagregado, características de operação para cada carga monitorada, perfil de consumo diário e relatório de operação das cargas de interesse.

O sistema é mostrado na Figura 22. A interface apresentada é uma página WEB e as informações apresentadas são definidas a partir de consultas em um banco de dados.

Figura 22: Sistema supervisório – Interface com o usuário.

Consumo desagregado

Nesta função foi explorada a exibição de informações de consumo desagregado sem mencionar termos específicos. Assim, é apresentada percentualmente a parcela de participação dos eletrodomésticos no consumo total mensurado no dia. Cabe destacar que essas informações são atualizadas a cada evento detectado.

Relatório diário

No relatório diário são apresentados informações sobre tempo de uso (em horas) e consumo (em kWh). Tais informações são apresentadas para cada equipamento monitorado e também são atualizadas a cada evento detectado.

Figura 23: Consumo desagregado apresentado percentualmente.

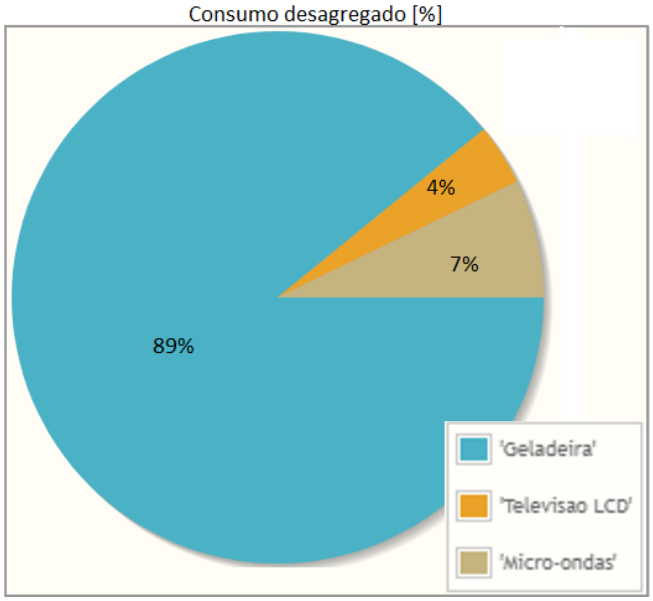

Figura 24: Consumo desagregado em kWh e tempo de uso dos eletrodomésticos.

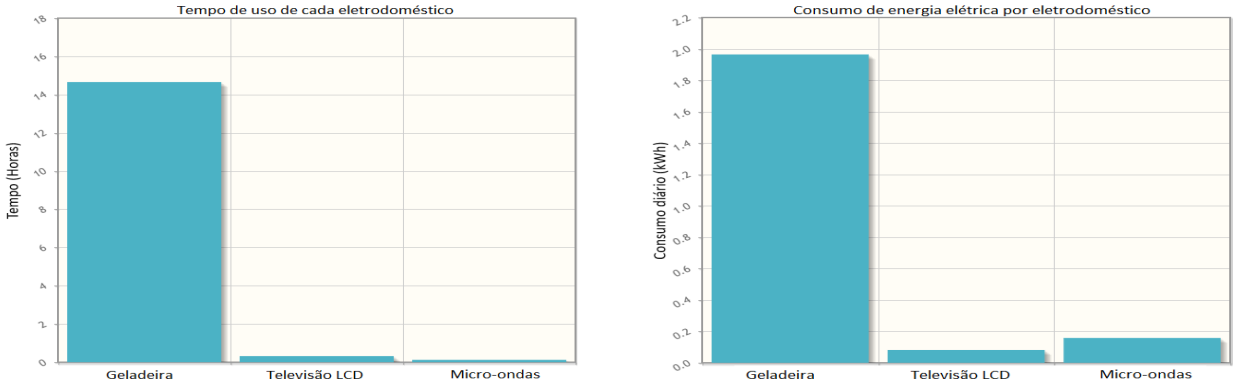

(a) Equipamento 1

(b) Equipamento 1

Relatório de operação

O relatório de operação compara o consumo desagregado dos eletrodomésticos de interesse com consumo padrão especificado na ENCE. Tais informações também são utilizadas para gerar sugestões e recomendações.

Perfil de carga

Essa função apresenta o consumo total da residência durante o dia. Com isso, torna-se possível visualizar a variação de consumo ao longo do dia.

Figura 25: Supervisão do consumo das cargas de interesse.

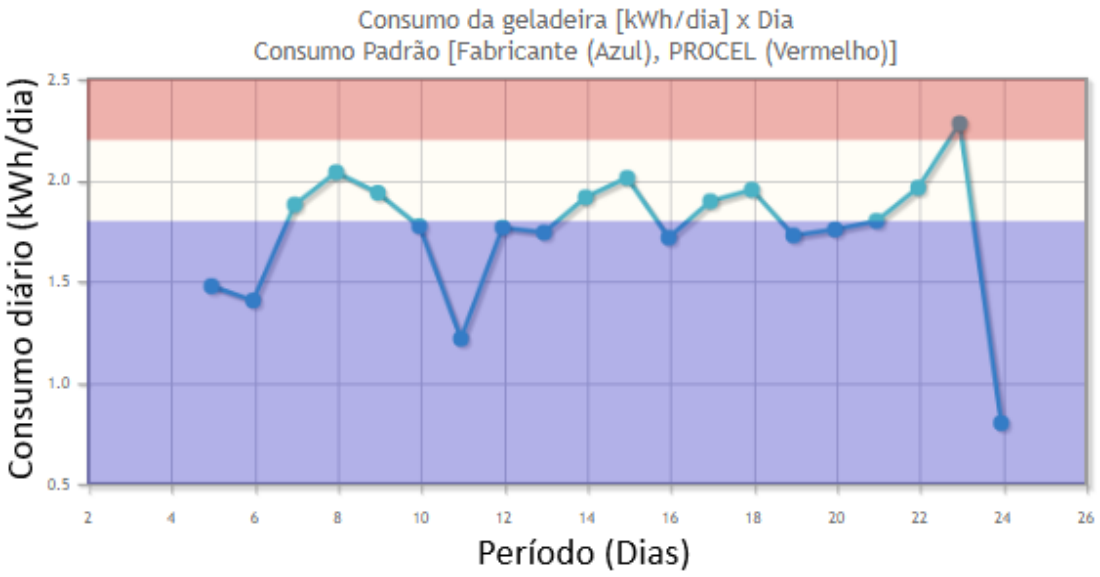

3.6 Considerações

As técnicas e metodologias apresentadas neste capítulo, bem como sua implementação, evidenciam que medidores digitais podem executar aplicações em prol da eficiência energética. Tal proposta se diferencia do modelo conceitual do medidor inteligente destacado na literatura. Assim, o medidor é denominado cognitivo, indicando novas funções e aplicações para o consumidor residencial.

Com a montagem do protótipo, a metodologia apresentada no capítulo 4 pôde ser implementada. Diante disso, o medidor foi utilizado para coletar informações sobre a operação individual de cada equipamento, tendo como objetivo a criação de uma base de dados para ser utilizada na etapa de classificação de cargas.

Utilizando os algoritmos propostos para monitoramento de cargas, os eventos que ocorrem quando uma carga é ligada ou desligada são detectados. Nesse contexto, o medidor consegue identificar qual carga gerou tal evento consultando o banco de dados. Uma vez que os eventos são registrados e as cargas são classificadas, o consumo de energia é desagregado. Isto é, sabendo o tempo em as cargas permaneceram ligadas, bem como seu modo de operação, estima-se o consumo utilizando a técnica de desagregação por blocos.

Figura 26: Variação do consumo de potência ativa.

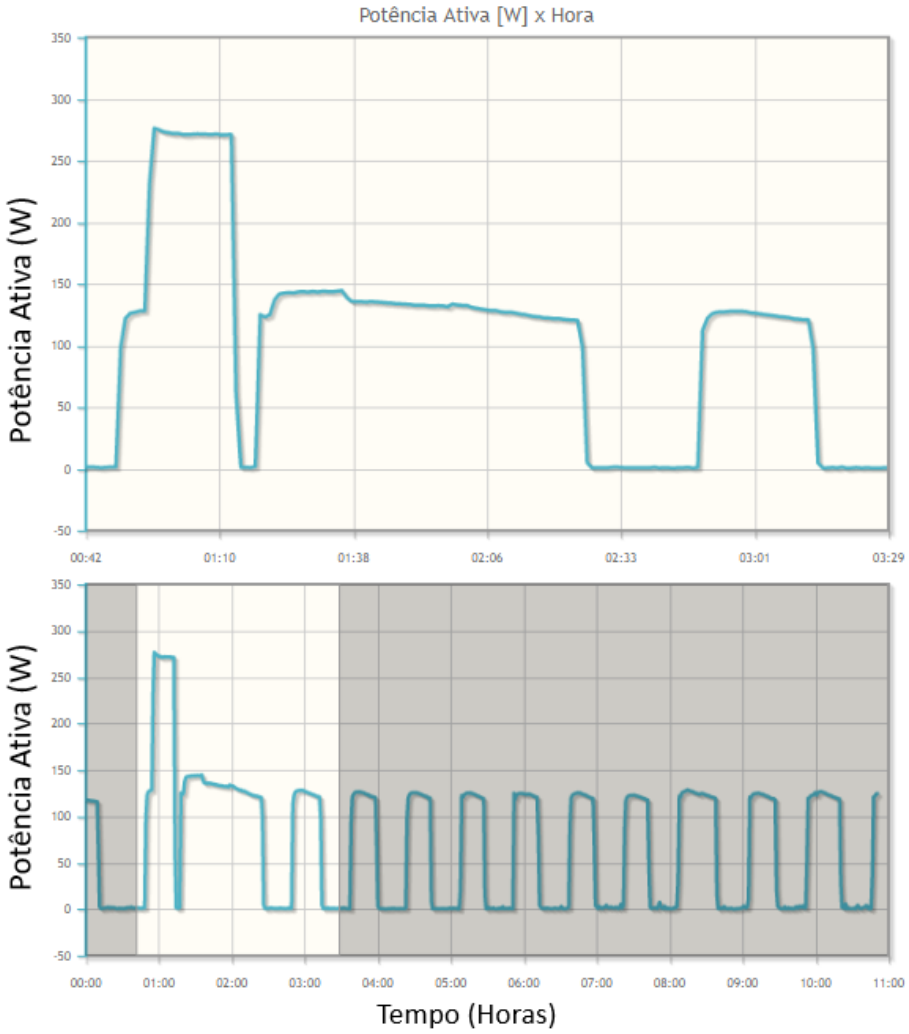

4 Coleta de dados

O conjunto de dados foi construído através de medições de tensão e corrente de uma instalação real, considerando circuitos monofásicos, com tensão nominal possui uma forma de onda senoidal de 127 Volts a 60 Hz. A corrente foi adquirida através de um sensor *SCT-03* com taxa de amostragem igual a 15 kHz (250 amostras para cada ciclo de 60 Hz) e no protótipo final através da placa de condicionamento de sinais construído pelo DSEE/FEEC/UNICAMP e GASI/UNESP. Portanto, foi construído um medidor para realizar a coleta dos dados brutos (formas de onda de tensão e corrente). A Figura 27 apresenta o diagrama do *hardware* construído. Neste *hardware*, a fonte CA/CC realiza a alimentação da placa de condicionamento de sinais e do dispositivo embarcado. Tal fonte oferece saídas de tensão contínua de +5V, +/-15V, sendo as três tensões para a placa de condicionamento e +5V para o dispositivo embarcado, no caso um *BeagleBone Black* (BBB).

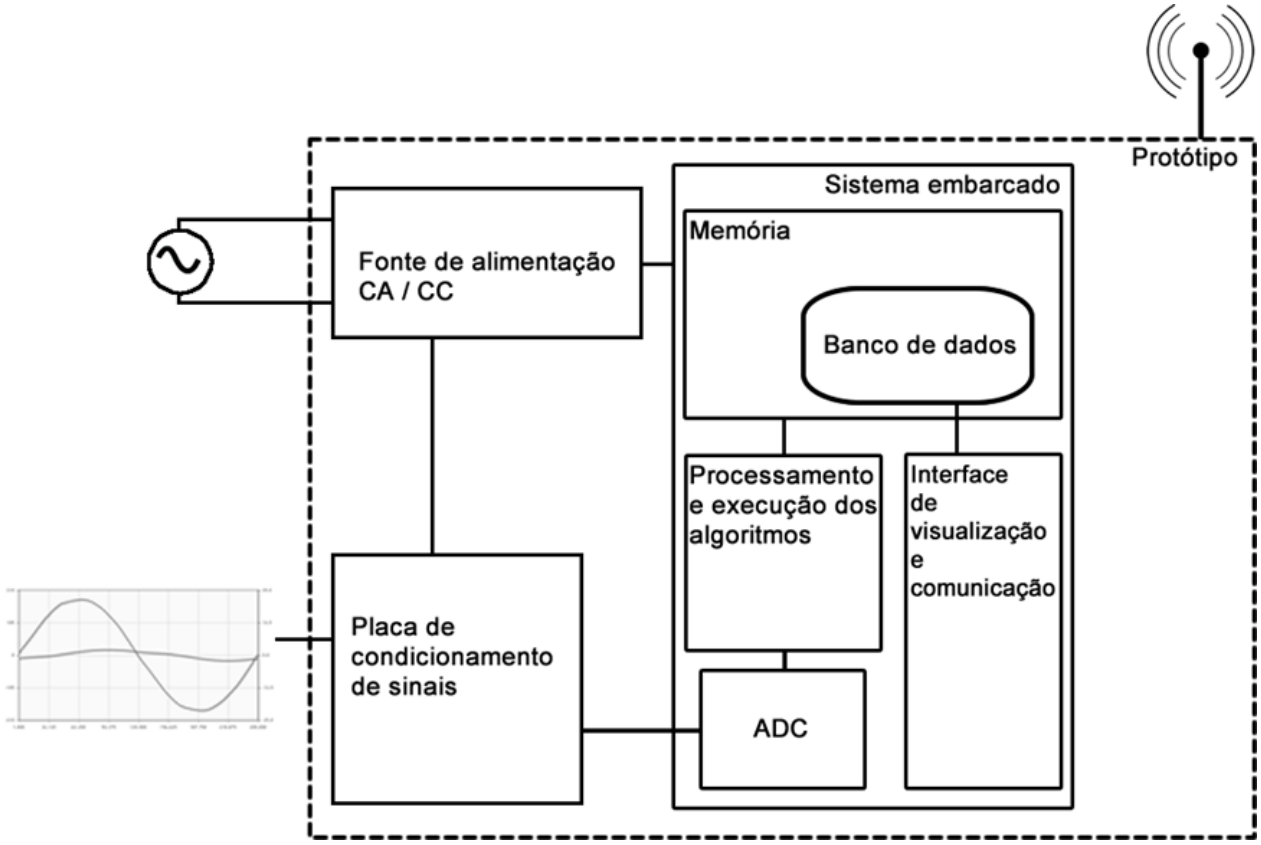

Figura 27: Diagrama do hardware do medidor cognitivo [18].

Na placa de condicionamento, os sensores recebem os sinais de tensão e corrente e o condicionamento do sinal para a saída compatível com o conversor AD do BBB é realizado, que é entre 0 a 1,8 V e possui a resolução de 12 bits. Os canais condicionados da placa são enviados ao BBB.

O BBB é o um dispositivo embarcado que possui 512MB de RAM, memória flash interna de 4GB (eMMC) e entrada para cartão MicroSD, portas USB, interface Ethernet, saída HDMI via um conector microHDMI e pode ser alimentada pela porta USB ou por uma fonte externa de 5V. O BBB é responsável pela aquisição e conversão analógica para digital do sinal condicionado, realiza os cálculos, aplica as técnicas de extração de características, executa os algoritmos de desagregação de cargas e armazena os dados em um banco de dados localizado na memória interna do dispositivo, podendo também enviar os dados para a nuvem.

Para esta etapa de coleta de dados, foram coletadas cerca de uma hora de oscilografia de tensão e corrente para 35 cargas, apresentadas na Tabela 7.

Tabela 7: Equipamentos com oscilografias coletadas para a base de dados.

Classe	Observação	Classe	Observação
1	Lâmpada incandescente de 60W	18	Lâmpada vapor de mercúrio
1	Lâmpada incandescente de 100W	19	Lâmpada vapor de sódio
2	Ar condicionado	20	Secadora de roupas regulável
3	Refrigerador	21	Refrigerador regulável
4	Micro-ondas	22	Liquidificador
5	TV CRT	23	Panificadora elétrica
6	TV LCD	24	Desktop PC
7	TV Plasma	25	Lâmpada fluorescente compacta
8	Chuveiro	26	Processador de alimentos
9	Carga RL	27	Freezer
10	Carga não linear 1	28	Forno elétrico
11	Carga não linear 2	29	Portão garagem
12	Carga RL 2	30	Laptop (notebook)
13	Ferro de passar	31	Monitor LCD
14	Máquina de lavar roupas	32	Secadora de roupas
15	Secador de cabelos	33	Refrigerador regular
16	Lâmpada fluorescente	34	Aspirador de pó
17	Lâmpada mista	35	Lavadora de roupas regulável

O momento da coleta das formas de onda de tensão e corrente foi na estabilização de potência da

carga ligada, conforme exemplifica a Figura 28. A seguir serão apresentadas as oscilografias referentes a cada carga.

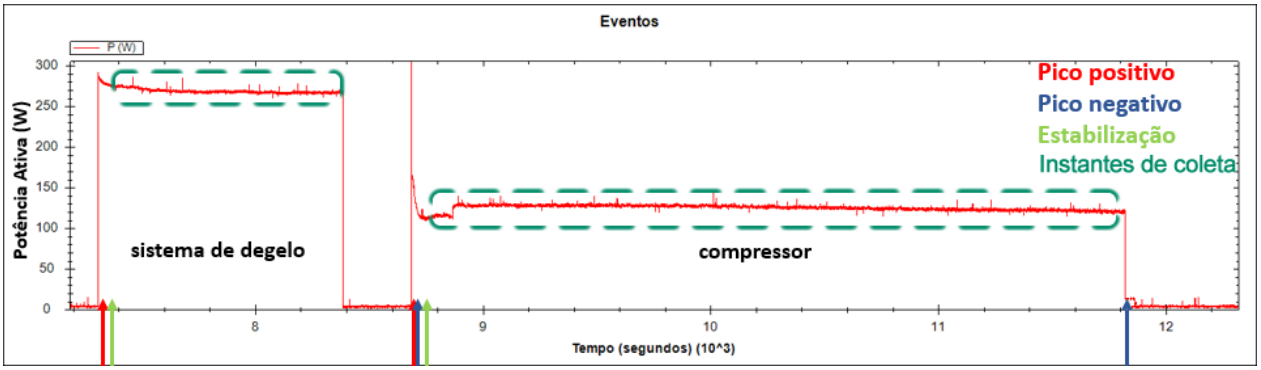

Figura 28: Exemplo de estabilização e de coleta da oscilografia da geladeira em suas fases de funcionamento.

Classe 1 – Lâmpada Incandescente

Para a criação da base de dados foram utilizadas duas lâmpadas incandescentes com filamento de tungstênio: de 60W e 100W. A Figura 29 apresenta a forma de onda de tensão e corrente para a lâmpada de 60W, com a máxima intensidade de luz (sem dimmer). A Figura 30 apresenta a forma de onda de tensão e corrente para a lâmpada de 100W. Pelas Figuras 29 e 30 é possível observar o comportamento resistivo da lâmpada incandescente, existindo só potência ativa.

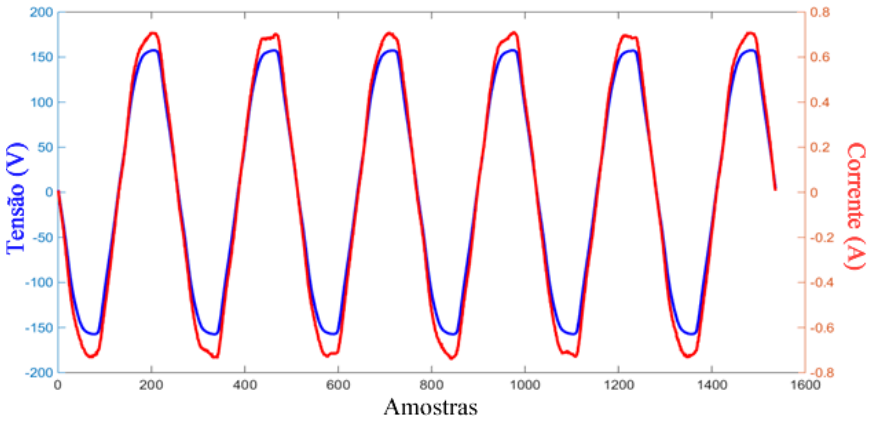

Figura 29: Tensão (azul) e Corrente (vermelha) da Lâmpada incandescente de 60W.

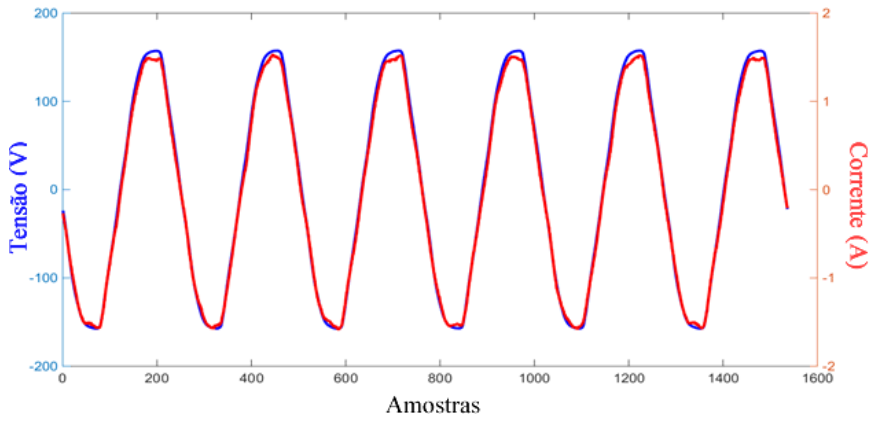

Figura 30: Tensão (azul) e Corrente (vermelha) da Lâmpada incandescente de 100W.

Classe 2 – Ar condicionado

O ar condicionado utilizado foi de 1000 Watts de potência e foi atribuído a classe 2 às leituras deste equipamento. A Figura 31 apresenta as formas de onda de tensão e corrente para um dos casos de leitura. Existe um atraso na forma de onda da corrente em relação à tensão. Desta forma, existe potência reativa.

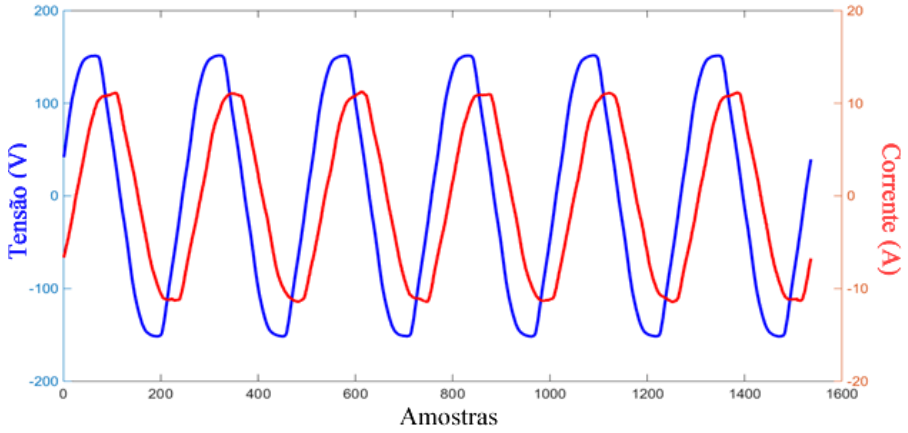

Figura 31: Tensão (azul) e Corrente (vermelha) do Ar Condicionado.

Classe 3 – Refrigerador

A classe 3, correspondente ao refrigerador convencional, tem a forma de onda apresentada na Figura 32. Neste caso, é possível verificar um atraso na corrente em relação à tensão e a forma de onda da corrente é diferente da tensão.

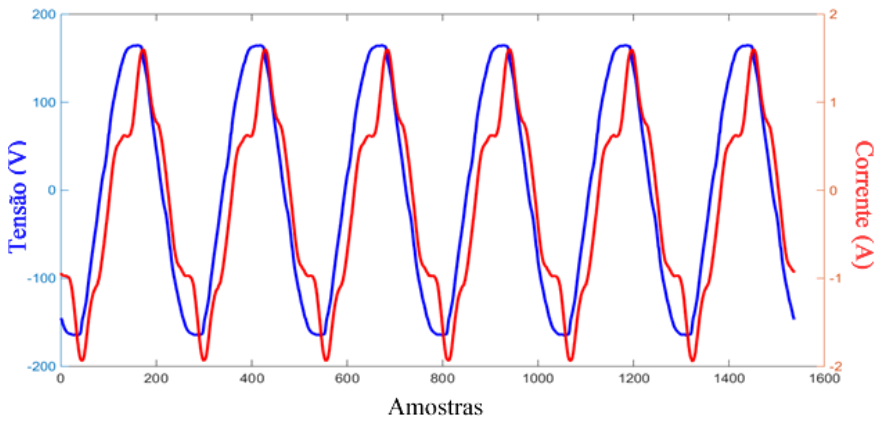

Figura 32: Tensão (azul) e Corrente (vermelha) do Refrigerador.

Classe 4 – Forno Micro-ondas

As formas de onda de tensão e corrente de um tipo de forno micro-ondas são apresentadas na Figura 33. Neste caso é perceptível que a tensão sofre interferência da corrente proveniente do micro-ondas, provavelmente em função de um projeto inadequado da instalação elétrica.

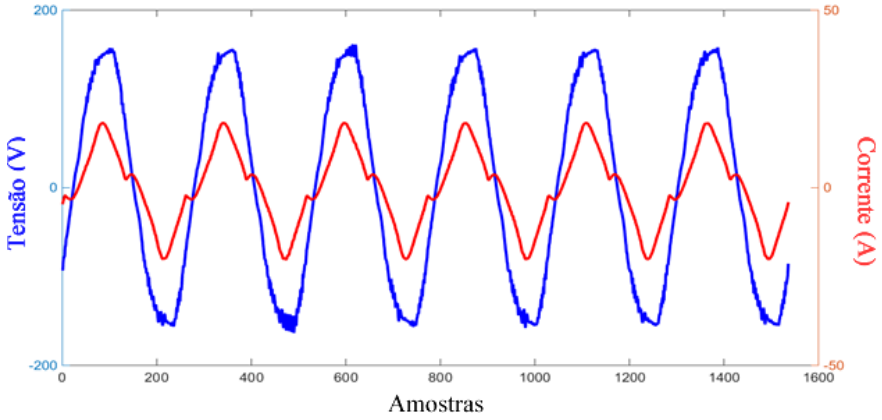

Figura 33: Tensão (azul) e Corrente (vermelha) do forno micro-ondas.

Classe 5 – TV CRT de 29 polegadas

A Classe 5, correspondente à TV de tubo catódico (CRT) de 29 polegadas, possui comportamento de regime permanente e as formas de onda de tensão e corrente são apresentadas na Figura 34. Na TV CRT é possível perceber componentes harmônicas na corrente.

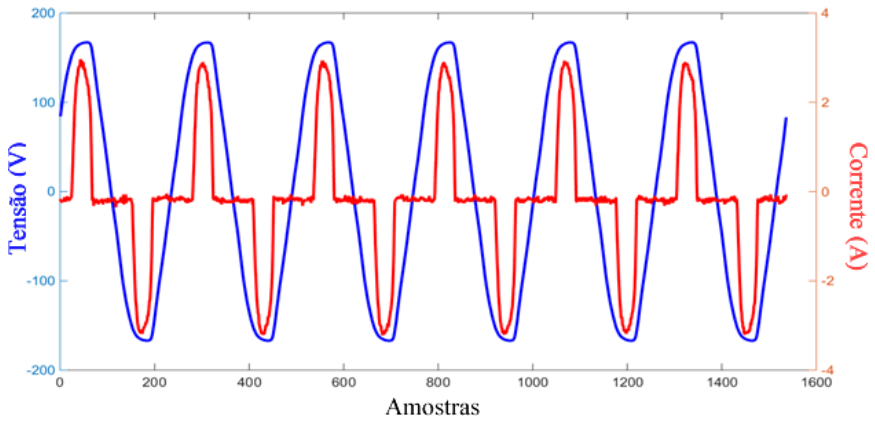

Figura 34: Tensão (azul) e Corrente (vermelha) da TV CRT.

Classe 6 – TV LCD de 49 polegadas

É possível perceber forma de onda semelhante da corrente em relação à tensão, o que indica que esse equipamento utiliza um corretor de fator de potência. A TV LCD de 49 polegadas, na qual pertence a classe 6, apresenta a forma de onda da tensão e corrente em um determinado instante de funcionamento equivalente à Figura 35.

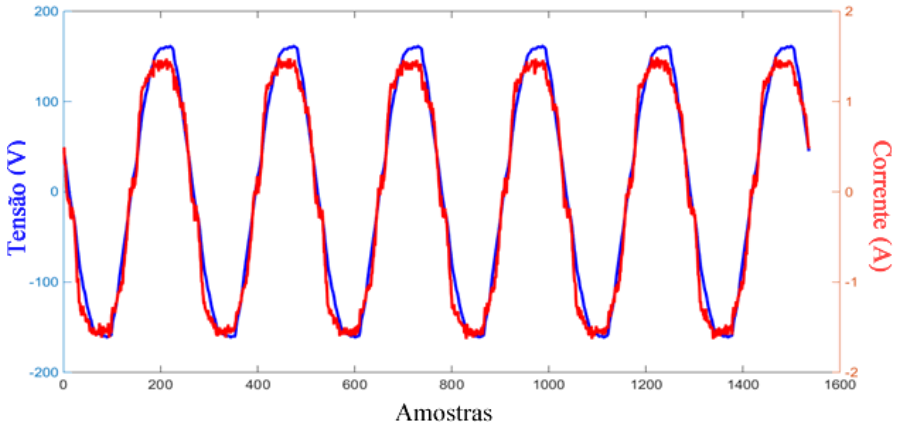

Figura 35: Tensão (azul) e Corrente (vermelha) da TV LCD.

Classe 7 – TV de plasma de 60 polegadas

A forma de onda da corrente da TV de plasma, de 60 polegadas, assemelha-se à TV LCD com correção de fator de potência, porém a potência é maior, conforme apresenta a Figura 36.

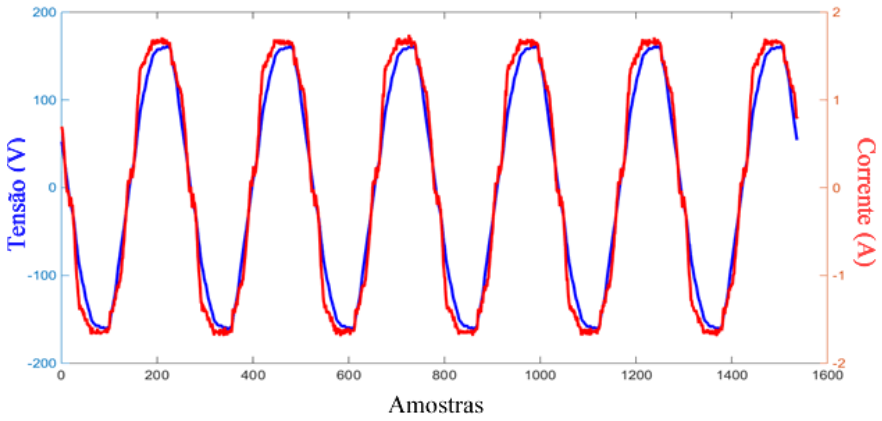

Figura 36: Tensão (azul) e Corrente (vermelha) da TV de plasma.

Classe 8 – Chuveiro 127 volts, com potência de 5000 watts

O chuveiro, correspondente à classe 8, apresenta as formas de onda de tensão e corrente apresentadas na Figura 37.O chuveiro elétrico possui comportamento resistivo.

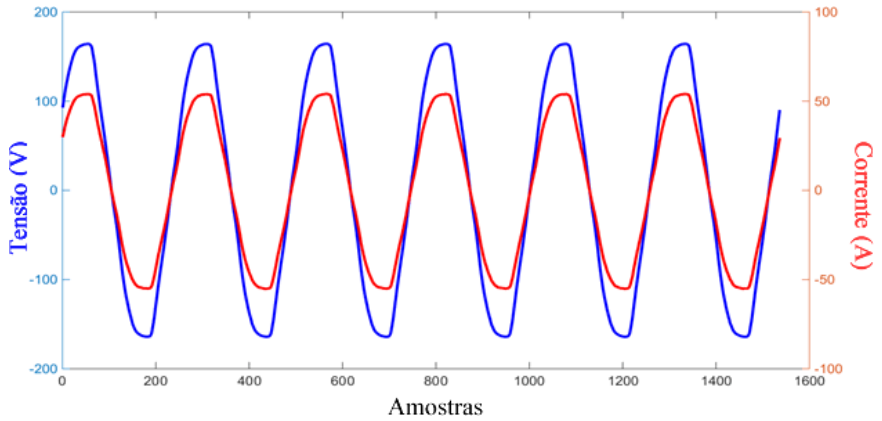

Figura 37: Tensão (azul) e Corrente (vermelha) do chuveiro elétrico.

Classe 9 – Carga RL 1

A classe 9, bem como as classes 10, 11 e 12, foram criadas propositalmente para que a base de dados possa ter comportamentos de diversos tipos de cargas. Desta forma, são dados utilizados para testes, porém foram mantidos na base de dados. Neste caso, procurou-se uma potência ativa perto de 1 kW e com atraso na corrente. A Figura 38 apresenta a tensão e corrente medida para a carga RL (resistiva-indutiva).

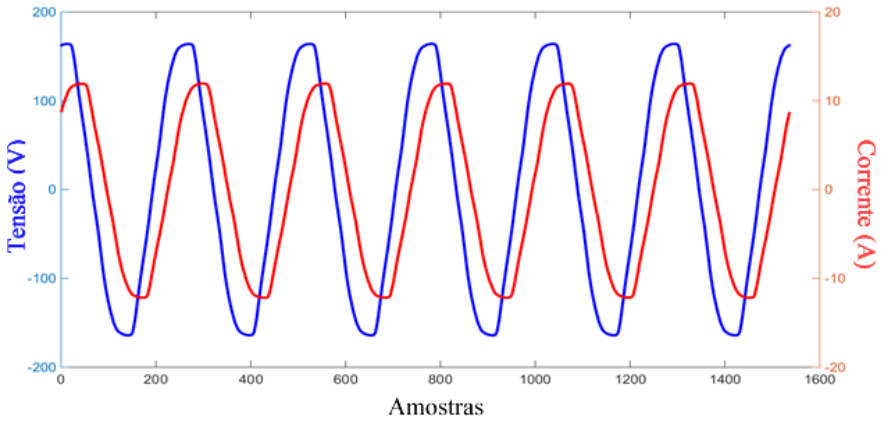

Figura 38: Tensão (azul) e Corrente (vermelha) da carga RL 1.

Classe 10 – Carga não linear 1

Da mesma forma que a classe 9, foi criada uma carga não linear para testes e esta foi mantida na base de dados. A Figura 39 apresenta a forma de onda para este tipo de equipamento.

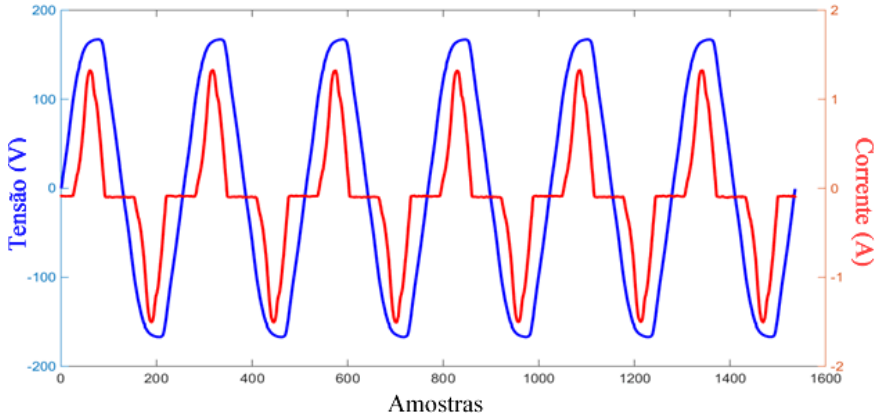

Figura 39: Tensão (azul) e Corrente (vermelha) da carga não linear 1.

Classe 11 – Carga não linear 2

A classe 11, carga não linear 2, segue o mesmo critério da classe 10, porém a corrente é maior e a não linearidade é menor. A Figura 40 apresenta a forma de onda da tensão e corrente quando esta carga está em funcionamento.

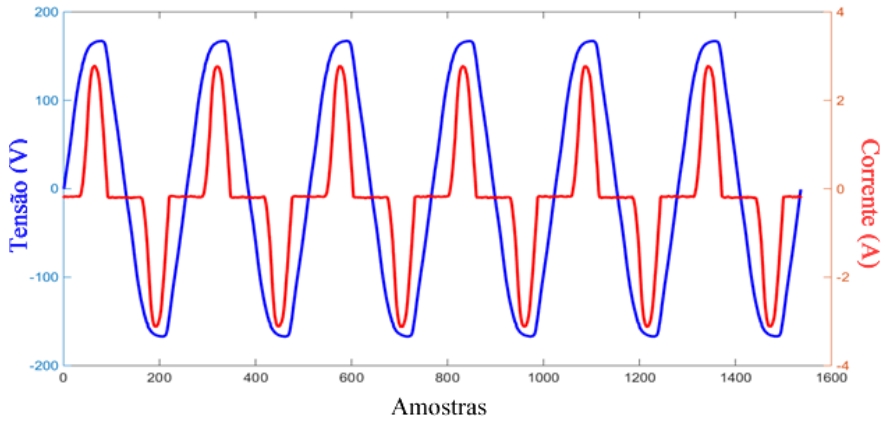

Figura 40: Tensão (azul) e Corrente (vermelha) da carga não linear 2.

Classe 12 – Carga RL 2

A classe 12, composta por um circuito RL, tem leve atraso da corrente e um comportamento senoidal na corrente, conforme é possível perceber na Figura 41.

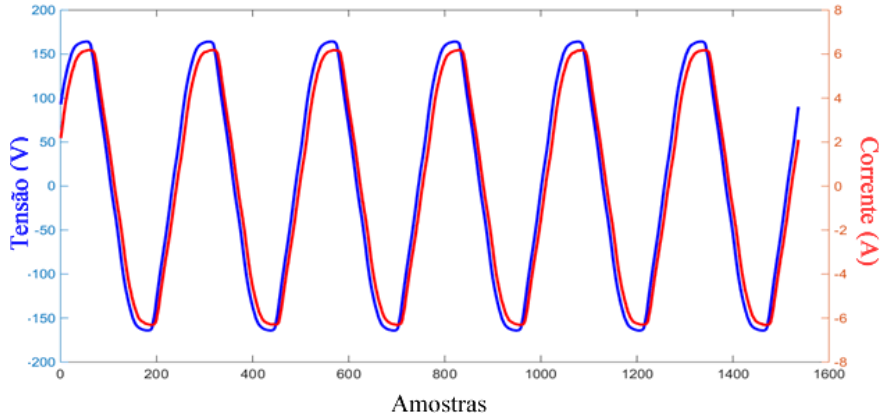

Figura 41: Tensão (azul) e Corrente (vermelha) da carga RL 2.

Classe 13 – Ferro de passar

O ferro de passar simples, classe 13, possui comportamento resistivo conforme é possível observar na Figura 42. Neste caso a forma de onda da corrente segue a forma de onda da tensão.

Classe 14 – Máquina de lavar roupas

A máquina de lavar roupas de 15 kg, durante a programação de lavagem de roupas, classe 14, apresenta atraso na corrente e deformidades na forma de onda da corrente, conforme é possível observar

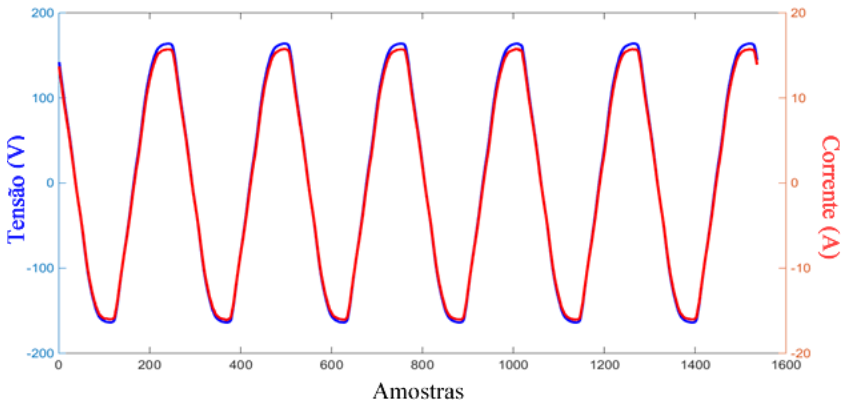

Figura 42: Tensão (azul) e Corrente (vermelha) do ferro de passar roupas.

na Figura 43.

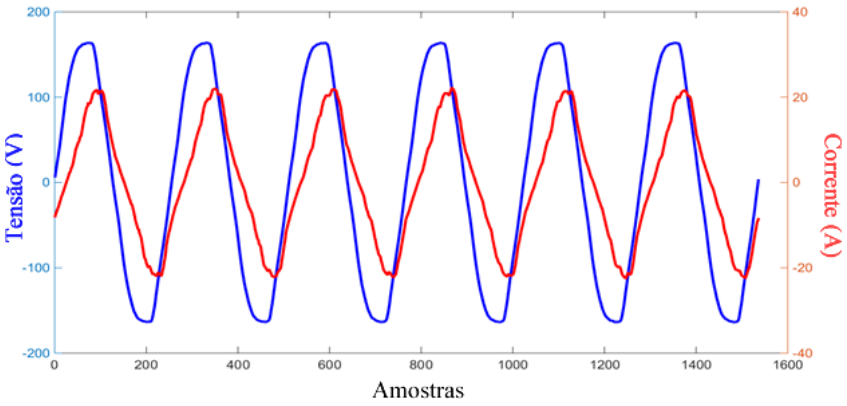

Figura 43: Tensão (azul) e Corrente (vermelha) da máquina de lavar roupas.

Classe 15 – Secador de cabelos

Observa-se, que para o secador de cabelos, classe 15, há um leve atraso na corrente e nos picos uma pequena deformidade, conforme apresenta a Figura 44.

Classe 16 – Lâmpada Fluorescente Tubular

A lâmpada fluorescente possui uma forma de onda de corrente com considerável distorção harmônica, conforme apresenta a Figura 45.

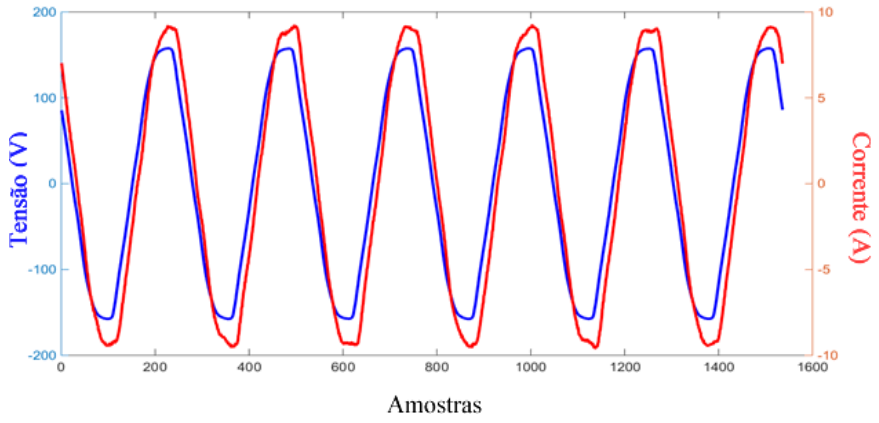

Figura 44: Tensão (azul) e Corrente (vermelha) do secador de cabelos.

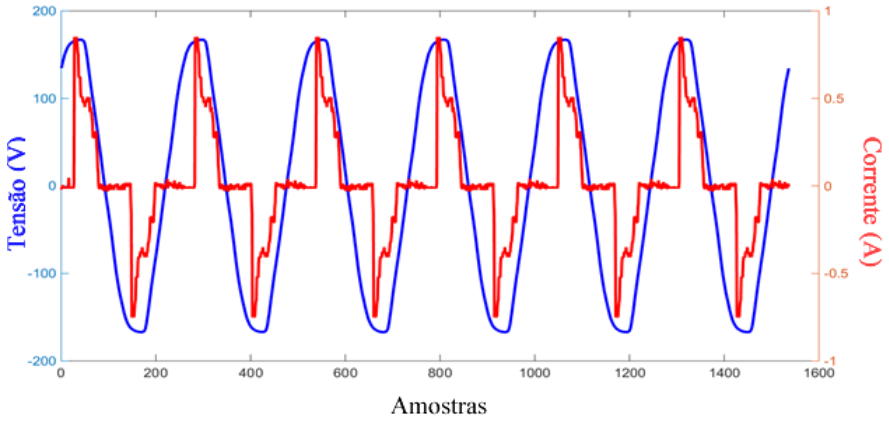

Figura 45: Tensão (azul) e Corrente (vermelha) da lâmpada fluorescente.

Classe 17 – Lâmpada mista

A lâmpada mista possui características mistas de lâmpadas incandescentes, fluorescentes e de vapor de mercúrio. Neste tipo de lâmpada possui um bulbo preenchido com gás e a parede revestida com fósforo. No bulbo existe um tubo de descarga em série com um filamento de tungstênio. O filamento, quando ligado, serve como um reator e a lâmpada mantém a corrente e o funcionamento. Essa lâmpada possui uma forma de onda da corrente conforme apresenta a Figura 46.

Classe 18 – Lâmpada de vapor de mercúrio

A lâmpada de vapor de mercúrio, classe 18, possui a forma de onda da corrente conforme é apresentada na Figura 47. É possível observar que a corrente possui distorção harmônica, diferindo assim a sua forma de onda em relação à tensão.

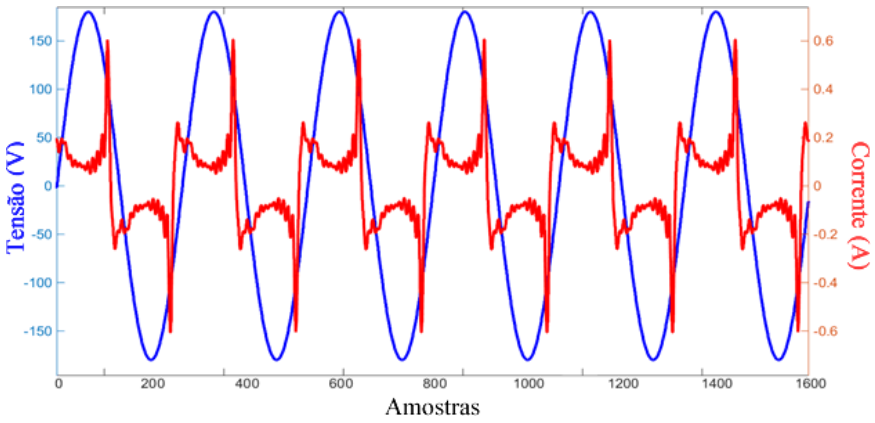

Figura 46: Tensão (azul) e Corrente (vermelha) da lâmpada mista.

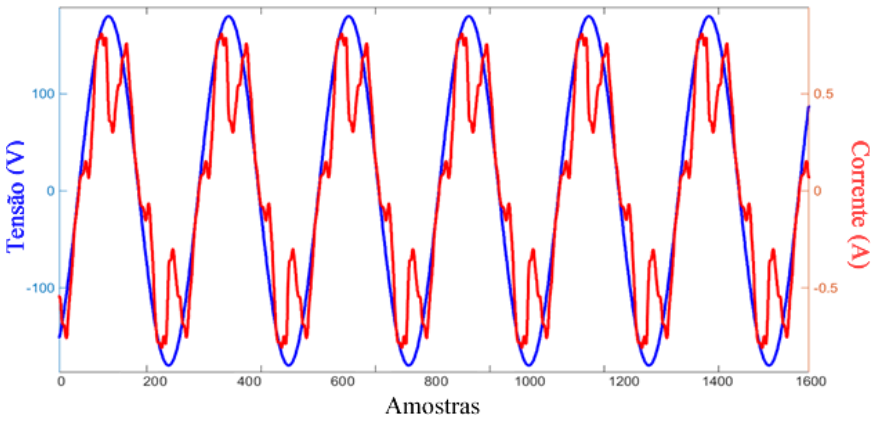

Figura 47: Tensão (azul) e Corrente (vermelha) da lâmpada vapor de mercúrio.

Classe 19 – Lâmpada de vapor de sódio

A lâmpada vapor de sódio, classe 19, possui características na forma de onda da corrente muito próximas às da lâmpada vapor de mercúrio, tendo como diferença uma potência sutilmente maior e não linearidades maiores, segundo os cálculos da CPT. A Figura 48 apresenta as formas de onda de tensão e corrente na medição da classe 19.

Classe 20 – Secadora de roupas regulável

A classe 20, correspondente à secadora de roupas regulável, possui o controle de temperatura e desta forma se difere da secadora de roupas não regulável, da classe 32, que será apresentada. A forma de onda da corrente, na classe 20, apresenta uma distorção harmônica alta na corrente, também há defasagem da corrente em relação a tensão, conforme apresenta a Figura 49.

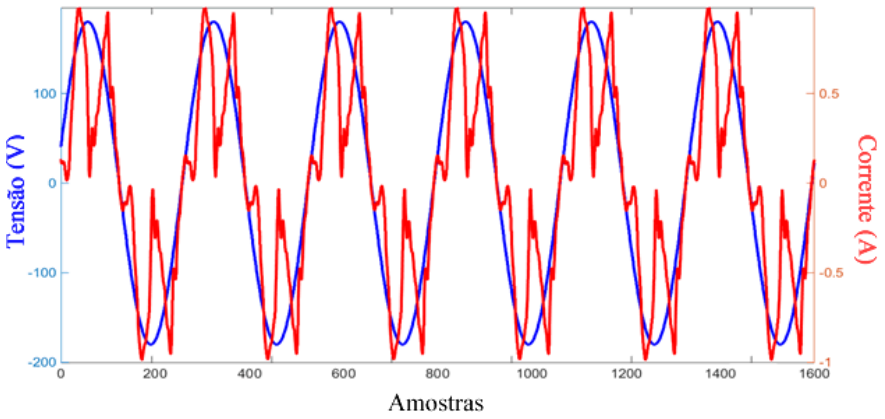

Figura 48: Tensão (azul) e Corrente (vermelha) da lâmpada vapor de sódio.

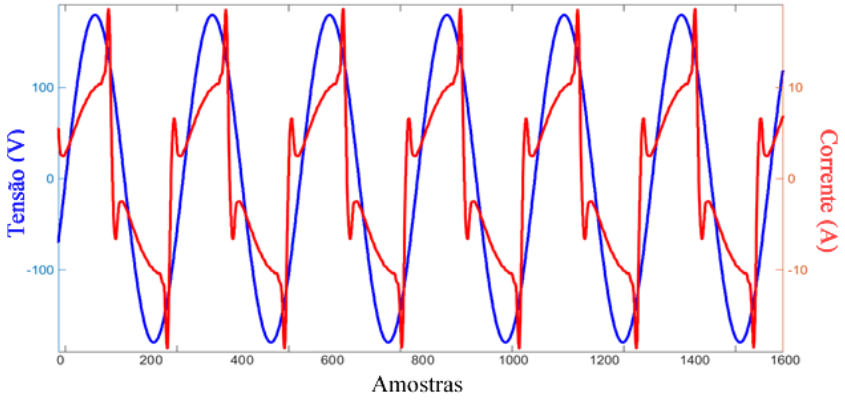

Figura 49: Tensão (azul) e Corrente (vermelha) da secadora de roupas regulável.

Classe 21 – Refrigerador regulável

O refrigerador regulável também possui o controle de intensidade e temperatura. Esse controle eletrônico difere a classe 3 da classe 21. A Figura 50 apresenta a forma de onda de tensão de alimentação e da corrente desta classe, na qual percebe-se não linearidades na forma de onda da corrente e atraso da corrente em relação à tensão.

Classe 22 – Liquidificador

O liquidificador, classe 22, possui motor AC escovado, desta forma a forma de onda da corrente apresenta componentes harmônicas diferentes da tensão. Também existe um atraso da corrente em relação à tensão. A Figura 51 apresenta o seguinte comportamento.

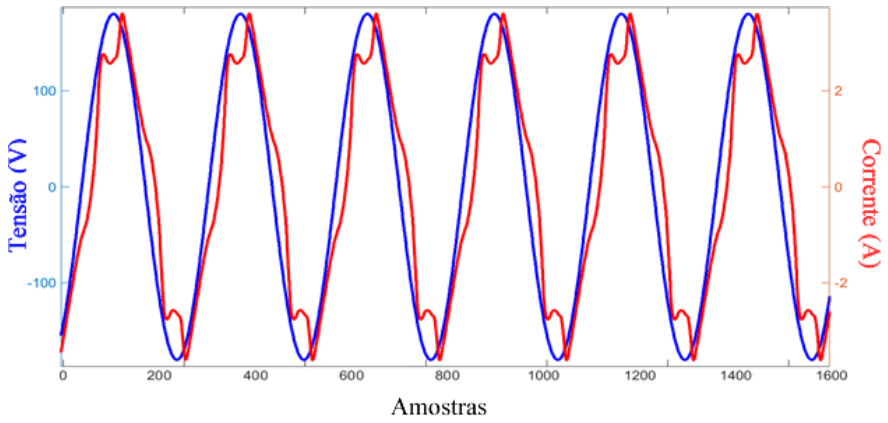

Figura 50: Tensão (azul) e Corrente (vermelha) do refrigerador regulável.

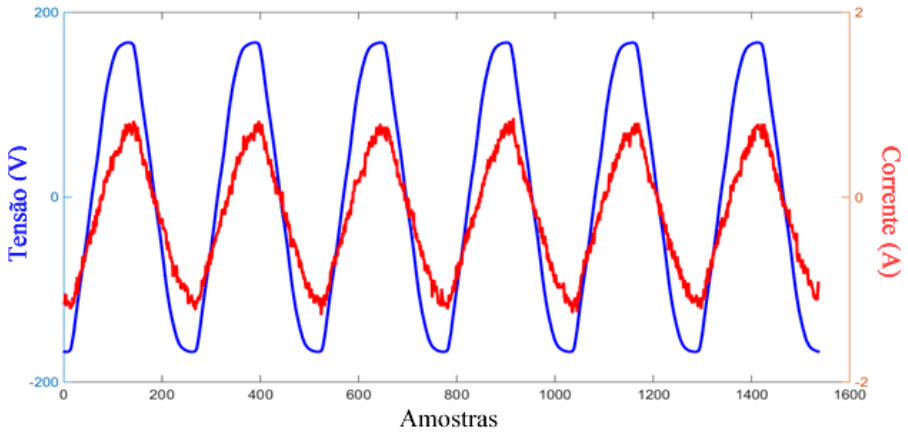

Figura 51: Tensão (azul) e Corrente (vermelha) do liquidificador.

Classe 23 – Panificadora Elétrica

A panificadora elétrica possui formas de onda de corrente que são em alguns momentos indutivas e em outras com linearidades, conforme apresenta a Figura 52, em que a corrente tem uma forma de onda triangular e com atraso em relação a tensão.

Classe 24 – Computador pessoal (Desktop PC)

O computador pessoal (PC) possui a forma de onda da corrente conforme a Figura 53. Foi considerado nesta classe o conjunto todo do PC, formado pelo gabinete e monitor LCD de 15 polegadas. Neste caso, a corrente possui distorção harmônica considerável.

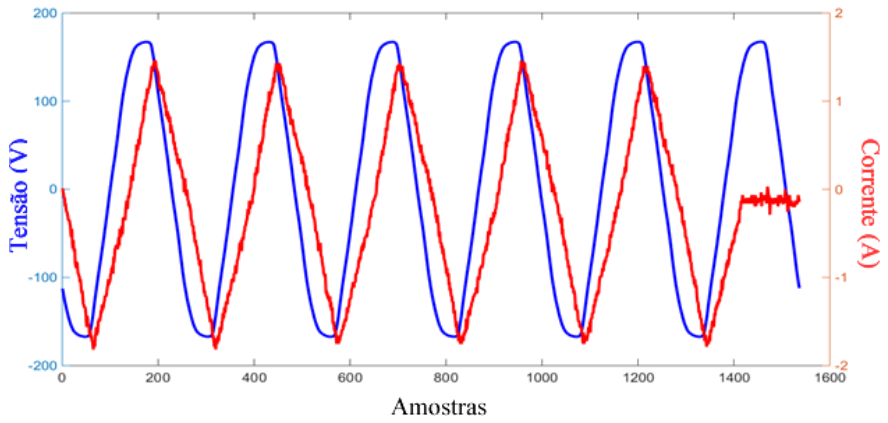

Figura 52: Tensão (azul) e Corrente (vermelha) da panificadora elétrica.

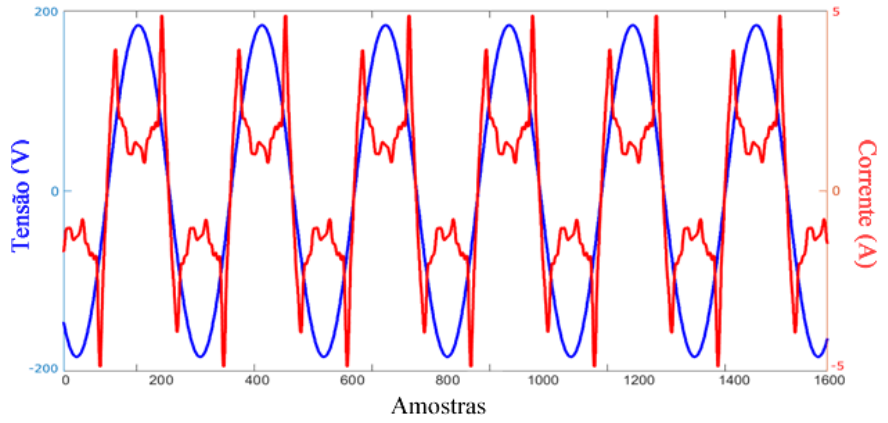

Figura 53: Tensão (azul) e Corrente (vermelha) do computador pessoal.

Classe 25 – Lâmpada fluorescente compacta

A lâmpada fluorescente compacta, classe 25, possui a forma de onda da corrente apresentada na Figura 54. Neste caso, existe uma alta distorção harmônica na corrente e uma defasagem em relação com a tensão de alimentação.

Classe 26 – Processador de alimentos

A classe 26, correspondente ao processador de alimentos, possui forma de onda da corrente conforme apresenta na Figura 55. Existe uma distorção harmônica na corrente diferente da tensão e também um atraso na corrente em relação à tensão.

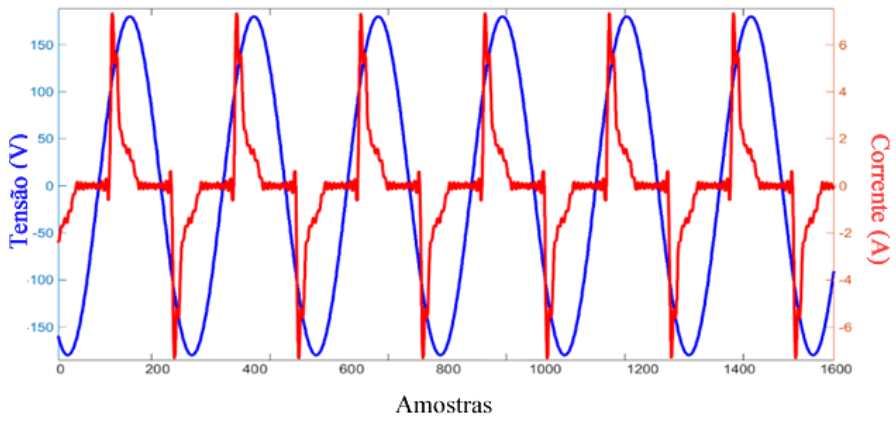

Figura 54: Tensão (azul) e Corrente (vermelha) da lâmpada compacta fluorescente.

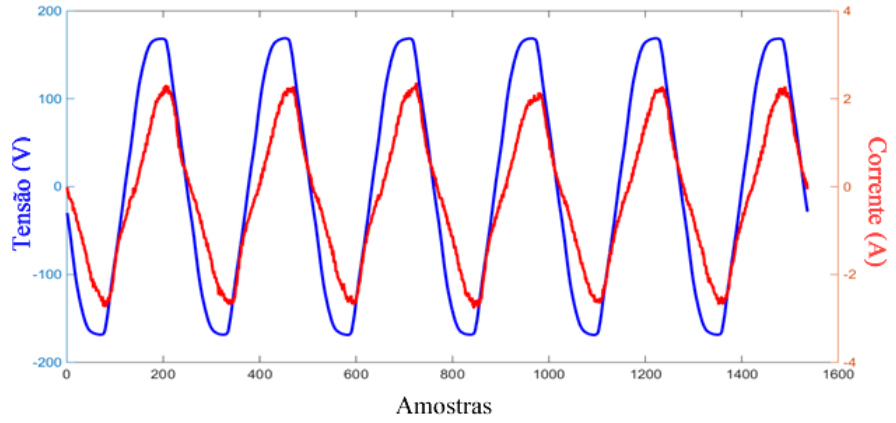

Figura 55: Tensão (azul) e Corrente (vermelha) do processador de alimentos.

Classe 27 – Freezer

O freezer, classe 27, possui não linearidades na corrente e a corrente se encontra atrasada em relação a tensão. A Figura 56 apresenta a forma de onda para este equipamento.

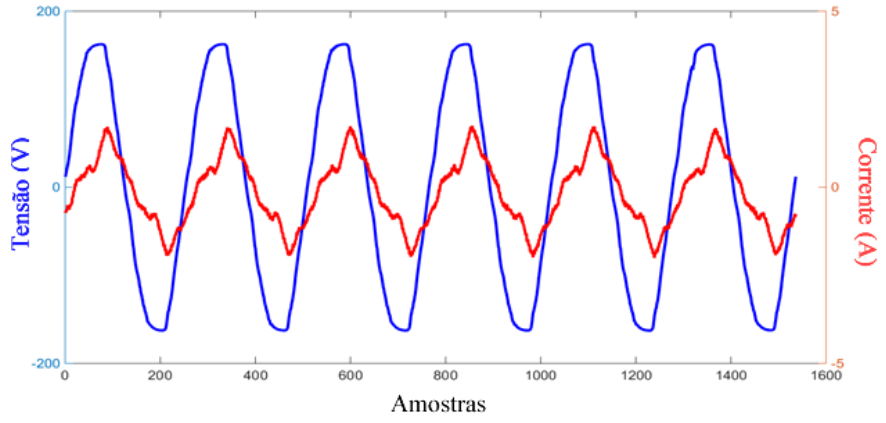

Figura 56: Tensão (azul) e Corrente (vermelha) do freezer.

Classe 28 – Forno Elétrico

As formas de onda de tensão e corrente que foram coletadas no funcionamento do forno elétrico, correspondente à classe 28, apresentam-se na Figura 57. O comportamento do forno elétrico é tipicamente resistivo.

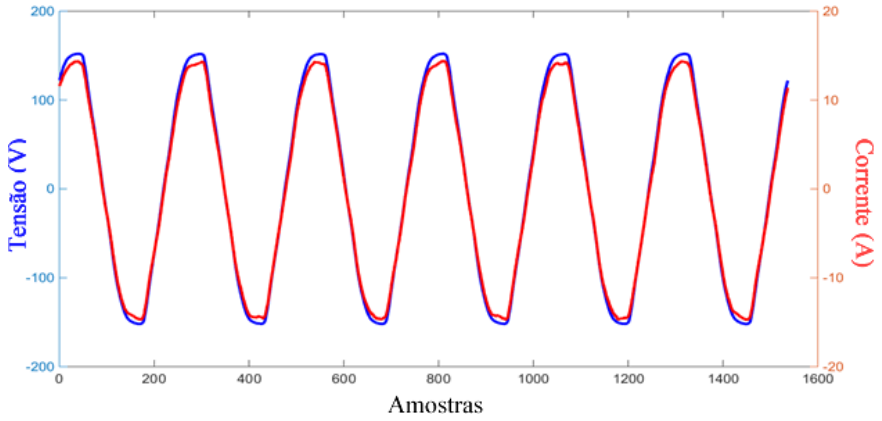

Figura 57: Tensão (azul) e Corrente (vermelha) do forno elétrico.

Classe 29 – Portão automático de garagem

A classe 29, correspondente ao portão automático de garagem, possui a corrente atrasada em relação à tensão e a distorção harmônica da corrente é maior que o da tensão, conforme é possível observar na Figura 58.

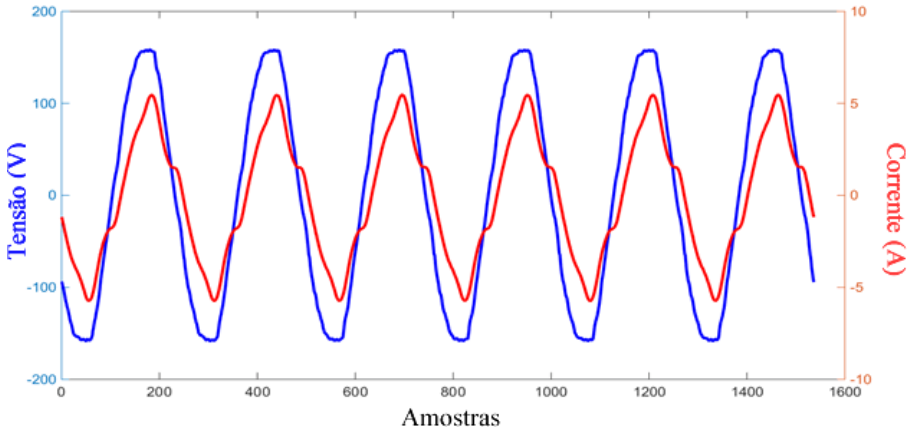

Figura 58: Tensão (azul) e Corrente (vermelha) do portão automático de garagem.

Classe 30 – Laptop

O laptop, ou notebook, possui em um dos seus estágios (quando está em alto processamento), a forma de onda da corrente conforme apresenta a Figura 59. Também possui dois outros estágios, quando se está carregando a bateria e quando o processamento está mais baixo. Neste caso, existe uma distorção harmônica alta na corrente e uma defasagem em relação com a tensão de alimentação.

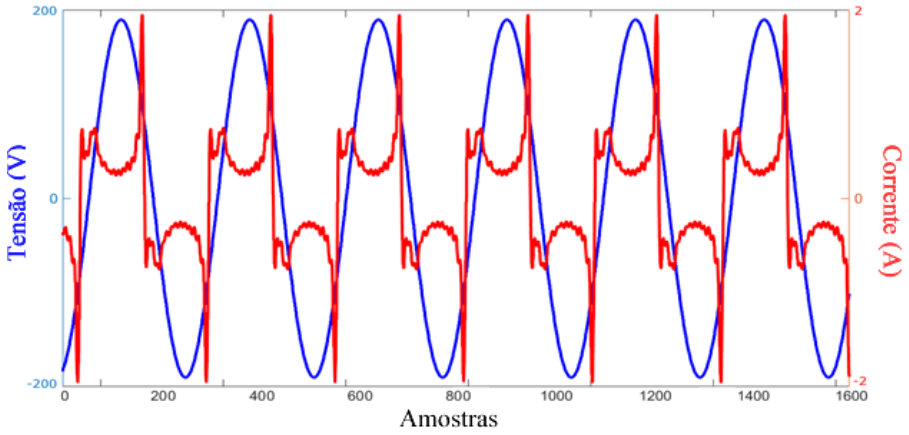

Figura 59: Tensão (azul) e Corrente (vermelha) do laptop no estágio de processamento alto.

Classe 31 – Monitor LCD

O monitor LCD, sem correção de fator de potência, possui a forma de onda da corrente conforme é apresentada na Figura 60. Neste caso existe distorção harmônica alta na corrente e defasagem em relação à tensão de alimentação.

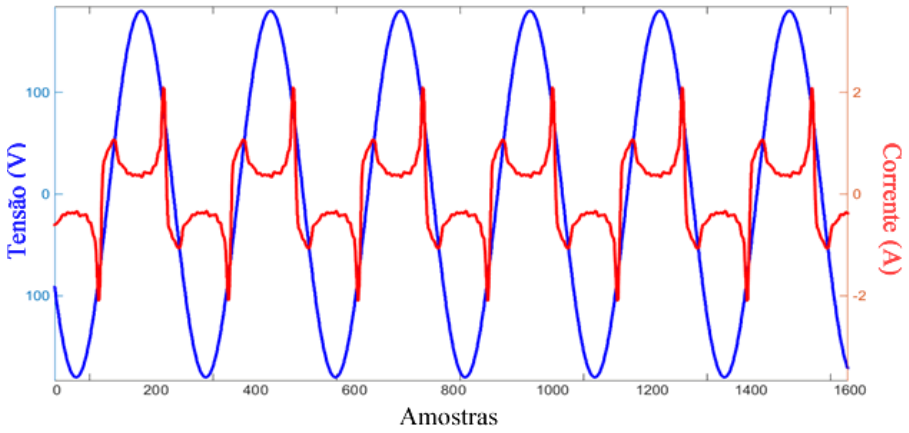

Figura 60: Tensão (azul) e Corrente (vermelha) de um monitor LCD de 15 polegadas.

Classe 32 – Secadora de roupas convencional

A classe 32, correspondente à secadora de roupas convencional, possui um pico de corrente alto, influenciando na tensão e por possuir um motor também possui um atraso da corrente em relação à tensão, conforme apresenta a Figura 61. A classe 32 difere da classe 20 pois na classe 20 existe o controle da velocidade e temperatura no processo de secagem da roupa.

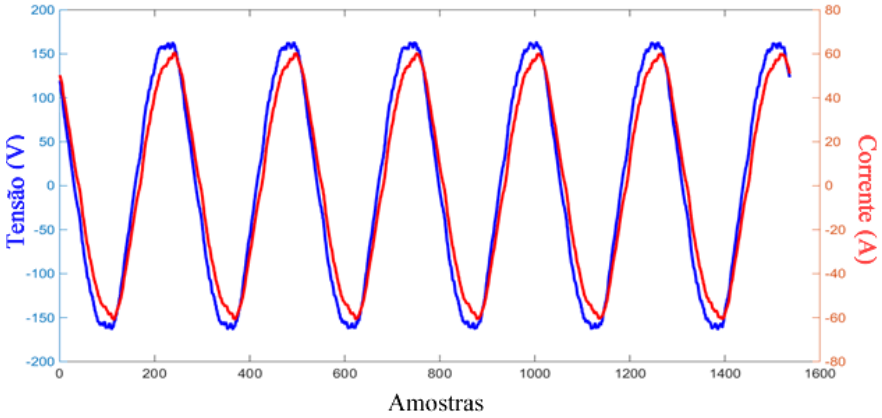

Figura 61: Tensão (azul) e Corrente (vermelha) da secadora de roupas regulável.

Classe 33 – Refrigerador regular

Esta classe, correspondente ao refrigerador regular moderno, corresponde a um refrigerador no qual existe somente o controle de temperatura. A diferença entre a classe 33 e a classe 3 é porque a classe 3 trata-se de um refrigerador mais antigo. É possível observar, através da Figura 62, não linearidades na corrente, bem como uma defasagem em relação à tensão.

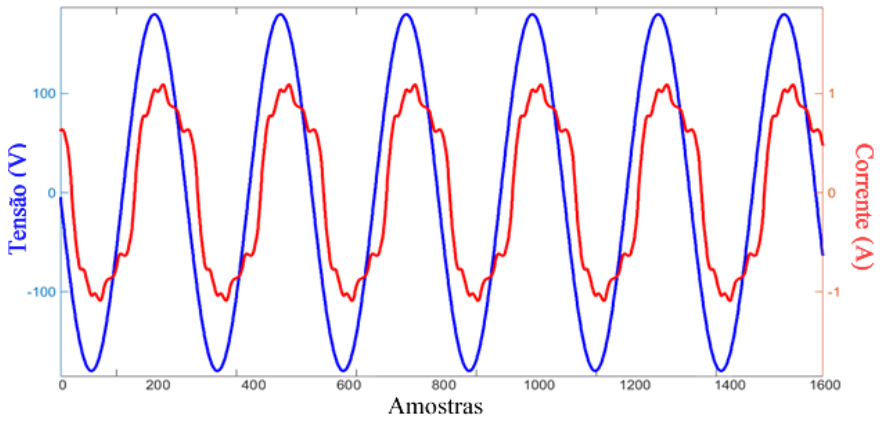

Figura 62: Tensão (azul) e Corrente (vermelha) do refrigerador regular.

Classe 34 – Aspirador de pó

O aspirador de pó possui um atraso da corrente em relação à tensão e a distorção harmônica da corrente é maior do que o da tensão medida, desta forma apresentará componentes reativos e de não linearidade, conforme pode-se observar na Figura 63.

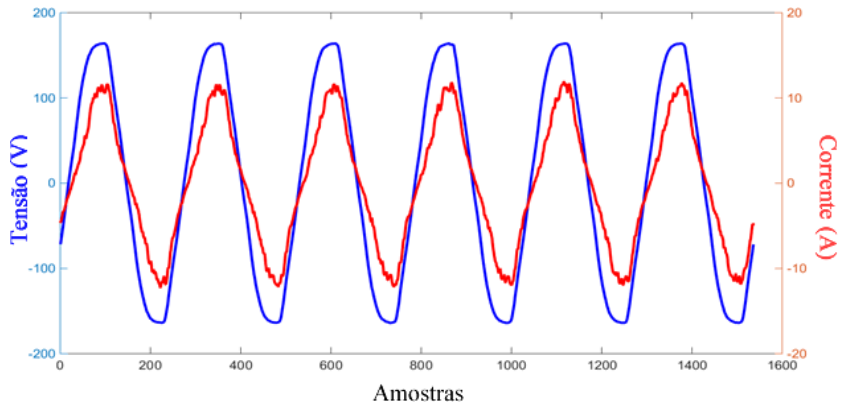

Figura 63: Tensão (azul) e Corrente (vermelha) do aspirador de pó.

Classe 35 – Máquina de lavar roupas regulável

A máquina de lavar roupas regulável, correspondente à classe 35, apresenta um controle de intensidade e a Figura 64 apresenta um dos estágios do equipamento. É possível perceber não linearidades na forma de onda de corrente, bem como uma defasagem em relação à tensão fornecida para alimentação.

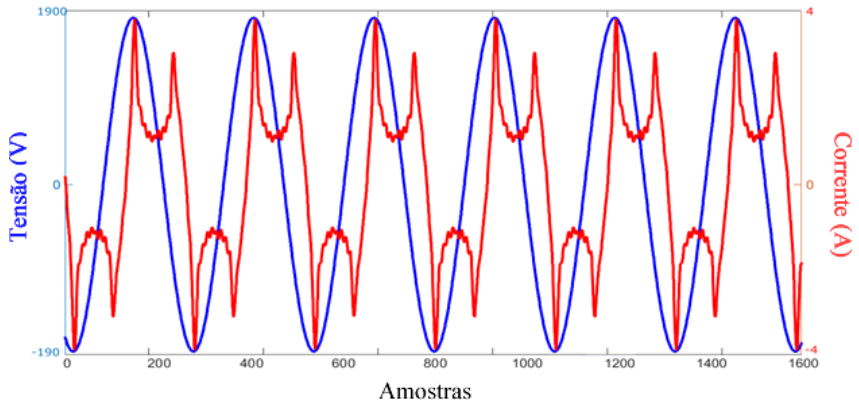

Figura 64: Tensão (azul) e Corrente (vermelha) da lavadora regulável.

Para cada equipamento, foram armazenados as amostras de tensão e corrente, a cada $6,5104\ x\ 10^{-5}$

segundos (15,36 kHz), em um arquivo .csv. Em outro arquivo .csv foram coletados os dados de temperatura, geolocalização e *timestamp* a cada minuto, para futuras implementações de aperfeiçoamento da máquina de estados. O capítulo a seguir apresentará as abordagens de extração de atributos em duas abordagens, a primeira realizada em [18, 24] e a segunda através da nova proposta de criação de um novo conjunto de dados.

5 Proposta de extração de atributos para identificação de cargas

Em Souza [18], foram extraídos quatro atributos quantitativos referentes às características de cargas, que são os termos de potência e os fatores de conformidade da CPT, conforme a subseção 2.2.3.

Portanto, os resultados dessa extração e a análise destes dados serão apresentados na subseção 5.1 e a nova coleta de dados e a sua análise serão apresentadas na subseção 5.4.

5.1 Extração das características da CPT

O diagrama do modo em que os dados foram coletados é apresentado na Figura 65 e a Tabela 8 mostram as informações mais relevantes para cada coleta de aparelho da base de dados.

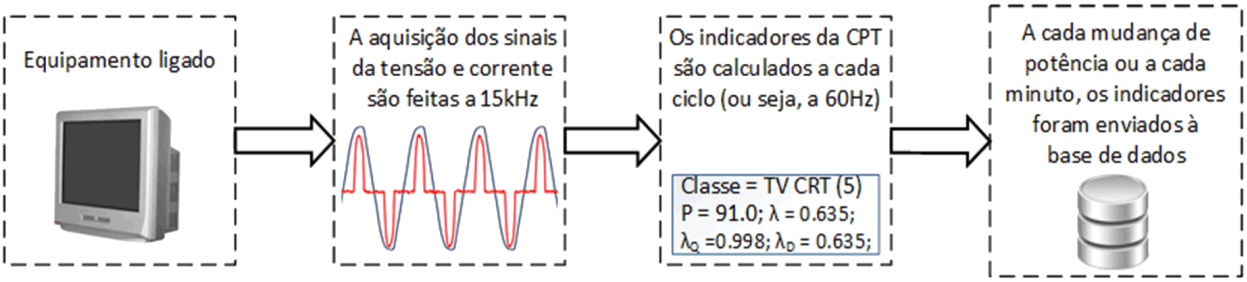

Figura 65: Diagrama de extração de características de [24].

Cada amostra coletada e registrada no conjunto de dados foi feita de acordo com o diagrama de aquisição da Figura 65 e os indicadores da CPT, após serem calculados, são armazenados como características (ou atributos). A base de dados possui o padrão: Classe; P - Potência ativa; λ - Fator de Potência; λ_Q - Fator de reatividade e λ_D - Fator de não linearidade. 100 instâncias para cada classe (ou carga) foram armazenados na base de dados. Seus valores médios são apresentados na Tabela 8 e auxiliam a entender a representatividade dos dados e o comportamento das parcelas calculadas com base na CPT. Os dados armazenados foram utilizados como entrada para as etapas de treinamento e classificação para a desagregação de cargas. O diagrama de funcionamento do bloco de reconhecimento de cargas para o medidor é apresentado na Figura 66.

A base de dados possui cinco colunas, sendo a primeira correspondente à classe e as outras quatro referentes às características. A primeira coluna, corresponde ao número da classe de aparelhos, possui valores que variam entre 1 a 35, de acordo com a Tabela 8 (por exemplo, se o valor nesta coluna é 5,

Tabela 8: Lista de cargas e valores médios de cada característica.

Classe	**Carga**	**P (W)**	**PF**	**QF**	**VF**
1	Lâmpada 60W	59,94	0,998	0,999	0,999
1	Lâmpada 60W com dimmer	42,78	0,710	0,846	0,840
1	Lâmpada 100W	100,00	0,998	0,999	0,999
2	Ar condicionado	928,29	0,804	0,804	1,000
3	Refrigerador	113,93	0,605	0,656	0,922
4	Micro-ondas	1071,4	0,942	0,990	0,950
5	TV CRT	91,00	0,635	0,998	0,635
6	TV LCD	143,10	0,997	0,997	0,988
7	TV Plasma	176,10	0,988	0,992	0,996
8	Chuveiro	4765,4	1,000	1,000	1,000
9	Carga RL	1012,7	0,844	0,844	1,000
10	Carga não linear 1	74,03	0,537	0,994	0,539
11	Carga não linear 2	145,17	0,615	0,993	0,621
12	Carga RL 2	504,67	0,967	0,967	1,000
13	Ferro de passar	1424,9	0,999	0,999	0,999
14	Máquina de lavar roupas	1951,3	0,703	0,732	0,960
15	Secador de cabelos	812,54	0,938	0,942	0,984
16	Lâmpada fluorescente	9,98	0,607	0,814	0,752
17	Lâmpada mista	93,25	0,950	0,995	0,952
18	Lâmpada vapor de mercúrio	64,55	0,929	0,991	0,938
19	Lâmpada vapor de sódio	69,51	0,860	0,988	0,871
20	Secadora de roupas regulável	633,29	0,844	0,961	0,878
21	Refrigerador regulável	102,13	0,856	0,873	0,983
22	Liquidificador	118,55	0,861	0,912	0,944
23	Panificadora elétrica	140,44	0,782	0,847	0,922
24	Desktop PC	102,28	0,710	0,999	0,710
25	Lâmpada fluorescente compacta	22,45	0,560	0,932	0,601
26	Processador de alimentos	146,88	0,903	0,935	0,966
27	Freezer	135,33	0,733	0,886	0,827
28	Forno elétrico	968,17	0,989	0,995	0,995
29	Portão garagem	433,59	0,851	0,858	0,991
30	Laptop (notebook)	72,11	0,597	0,962	0,622
31	Monitor LCD	38,45	0,592	0,965	0,624
32	Secadora de roupas	4332,9	0,934	0,954	0,979
33	Refrigerador regular	119,62	0,938	0,942	0,987
34	Aspirador de pó	954,54	0,945	0,966	0,978
35	Lavadora de roupas regulável	356,65	0,355	0,441	0,805

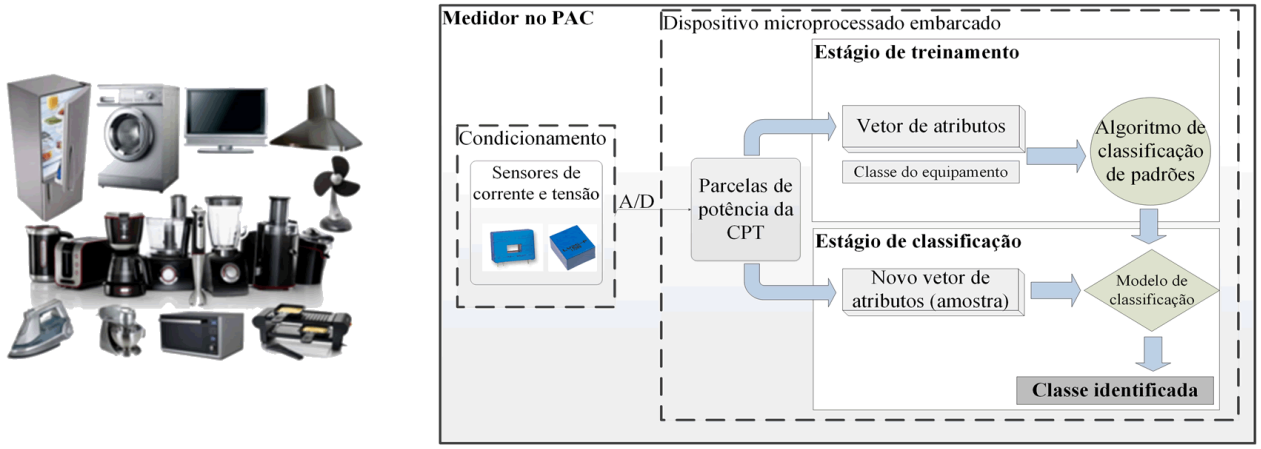

Figura 66: Bloco de reconhecimento de cargas para a desagregação do medidor cognitivo [18].

a instância corresponde a uma medição de uma "TV CRT"). As amostras foram coletadas de diferentes modelos e tipos de eletrodomésticos, portanto, tentou-se tornar a base mais abrangente possível. Também se optou em utilizar algoritmos de aprendizado de máquina para permitir a flexibilidade do reconhecimento de padrões por aproximação de classes.

Foi feito um processo de normalização dos dados em virtude da segunda coluna, a potência ativa, que se apresenta em valores absolutos enquanto as outras características apresentam valores entre 0 e 1. Portanto, a característica de potência ativa (P) foi normalizada em p.u. (por unidade) para melhorar o desempenho da função métrica dos métodos de aprendizado de máquina.

A distribuição dos dados é apresentada na Figura 67. Foram colocadas em grupos de duas dimensões para facilitar o agrupamento dos pontos. É possível observar pela Figura 67 que algumas classes não são linearmente separáveis, desta forma, alguns algoritmos de classificação de padrões com comportamento linear não apresentariam acurácia maior do que os métodos que se ajustam a comportamentos não lineares.

A Tabela 9 apresentam os dados estatísticos dos dados e a Tabela 10 apresenta a matriz de correlação entre os atributos. A Figura 68 apresenta o diagrama de Box para cada atributo.

De acordo com a Tabela 10, há baixa correlação entre os atributos do conjunto de dados, não havendo, portanto, alta dependência entre os dados. Pela Figura 68 é possível perceber a dispersão dos dados e é evidente a existência de alguns *outliers*, sendo necessária a avaliação destes pontos e talvez a remoção para a melhoria do conjunto de dados.

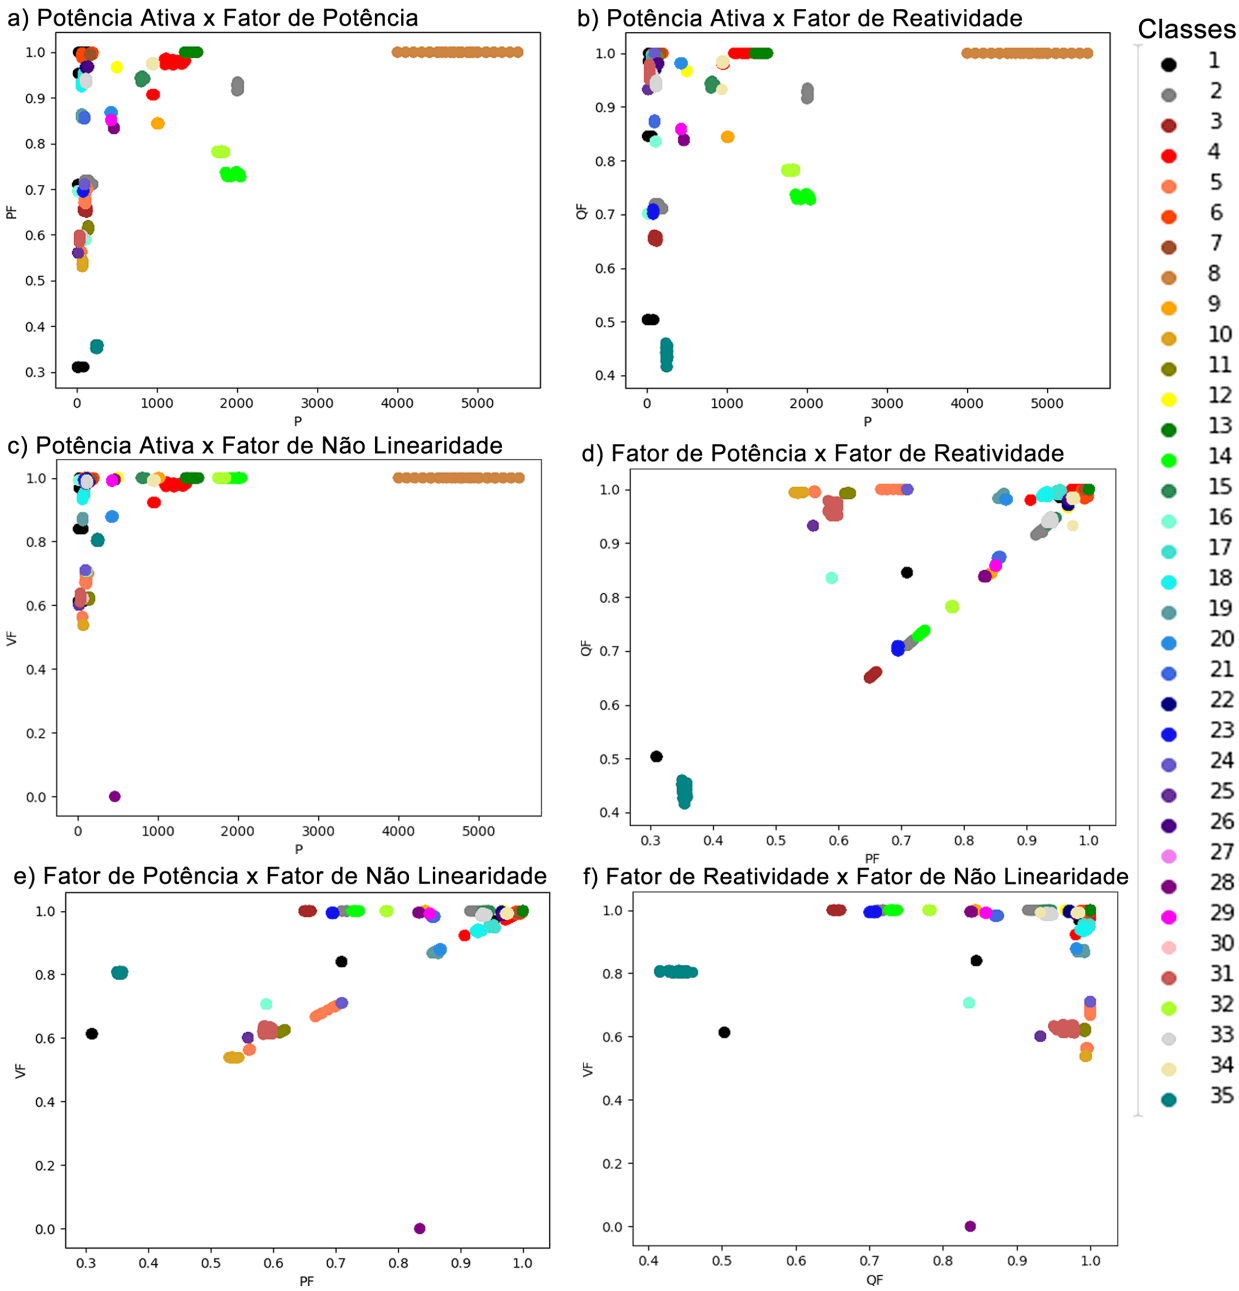

Figura 67: Representação gráfica dos dados

Com base nos estudos feitos em [18], o algoritmo KNN, com *k=3*, apresentou o melhor desempenho para a classificação do conjunto de dados, tendo a acurácia em torno de 98%. A Figura 69 apresenta a matriz de confusão do KNN (K=3) aplicado no conjunto de dados e a Figura 70 apresenta as fronteiras de decisão para a visualização do comportamento do algoritmo para a base de dados.

É possível observar na Figura 70 que alguns padrões estão próximos e não permitem a separação linear, de forma que alguns algoritmos de reconhecimento de padrões podem não ter uma precisão ra-

Tabela 9: Dados estatísticos dos dados.

	P	λ	λ_Q	λ_D
Média ($\bar{X}$)	552,771	0,803	0,904	0,889
Desvio Padrão (σ)	913,999	0,174	0,131	0,156
Mínimo	12,401	0,310	0,416	0,000
Q1	85,799	0,668	0,844	0,803
Q2	143,174	0,852	0,968	0,987
Q3	505,723	0,965	0,993	0,999
Máximo	5500,000	1,000	1,000	1,000

Tabela 10: Correlação entre os atributos.

	P	λ	λ_Q	λ_D
P	1,0000	0,3079	0,0327	0,3381
λ	0,3079	1,0000	0,5594	0,7379
λ_Q	0,0327	0,5594	1,0000	-0,1153
λ_D	0,3381	0,7379	-0,1153	1,0000

zoável. Há também alguns casos de sobreposição, mas as classes são separáveis por alguns algoritmos de reconhecimento de padrões.

Ao analisar os erros de classificação, foi possível perceber que existem algumas confusões do classificador, especialmente porque as formas de onda atuais de algumas cargas residenciais possuem características muito semelhantes, conforme discutido a seguir:

- **Lâmpada incandescente, TV LCD e TV de Plasma:** a lâmpada incandescente sem dimmer tem um comportamento puramente resistivo, de modo que os fatores de potência, de reatividade e não-linearidade estarão próximos de 1. Além disso, TVs LCD e Plasma com pré-reguladores de fator de potência tem o comportamento próximo ao da característica resistiva das lâmpadas incandescentes.

- **Lâmpada incandescente com dimmer e lâmpada fluorescente:** o dimmer usado na lâmpada incandescente diminui consideravelmente o fator de potência e o fator de não-linearidade. Devido ao baixo valor da potência ativa de uma lâmpada incandescente, alguns classificadores

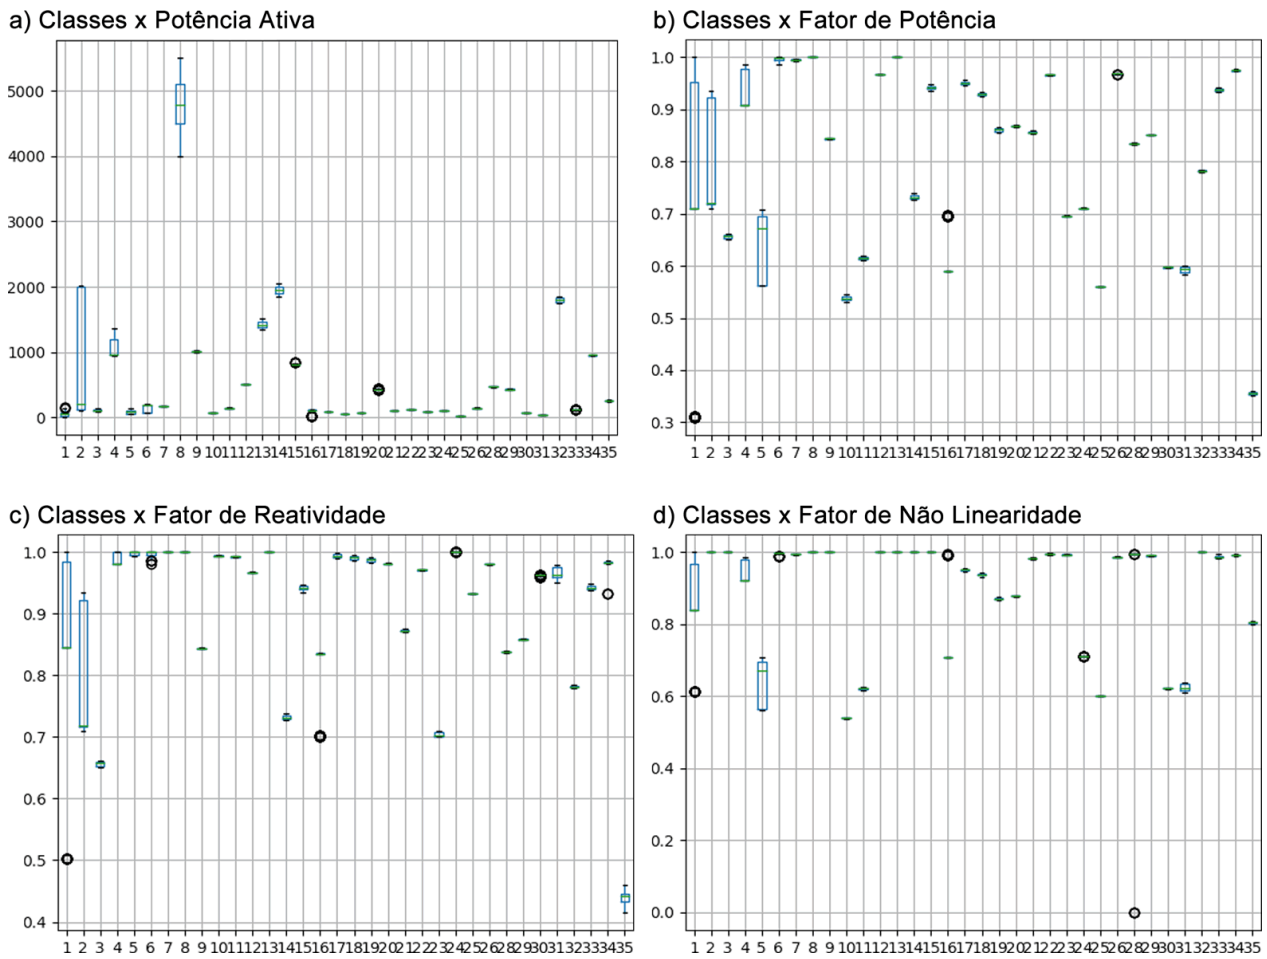

Figura 68: Diagramas de Box (Dispersão de dados).

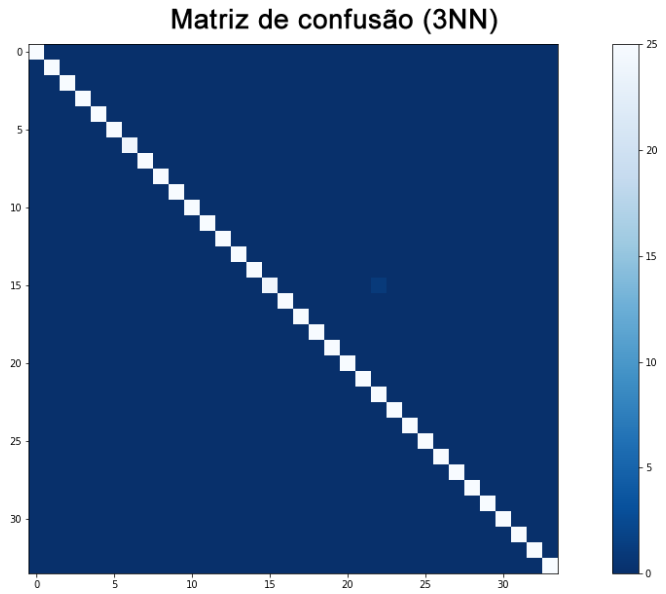

Figura 69: Matriz de confusão (3NN).

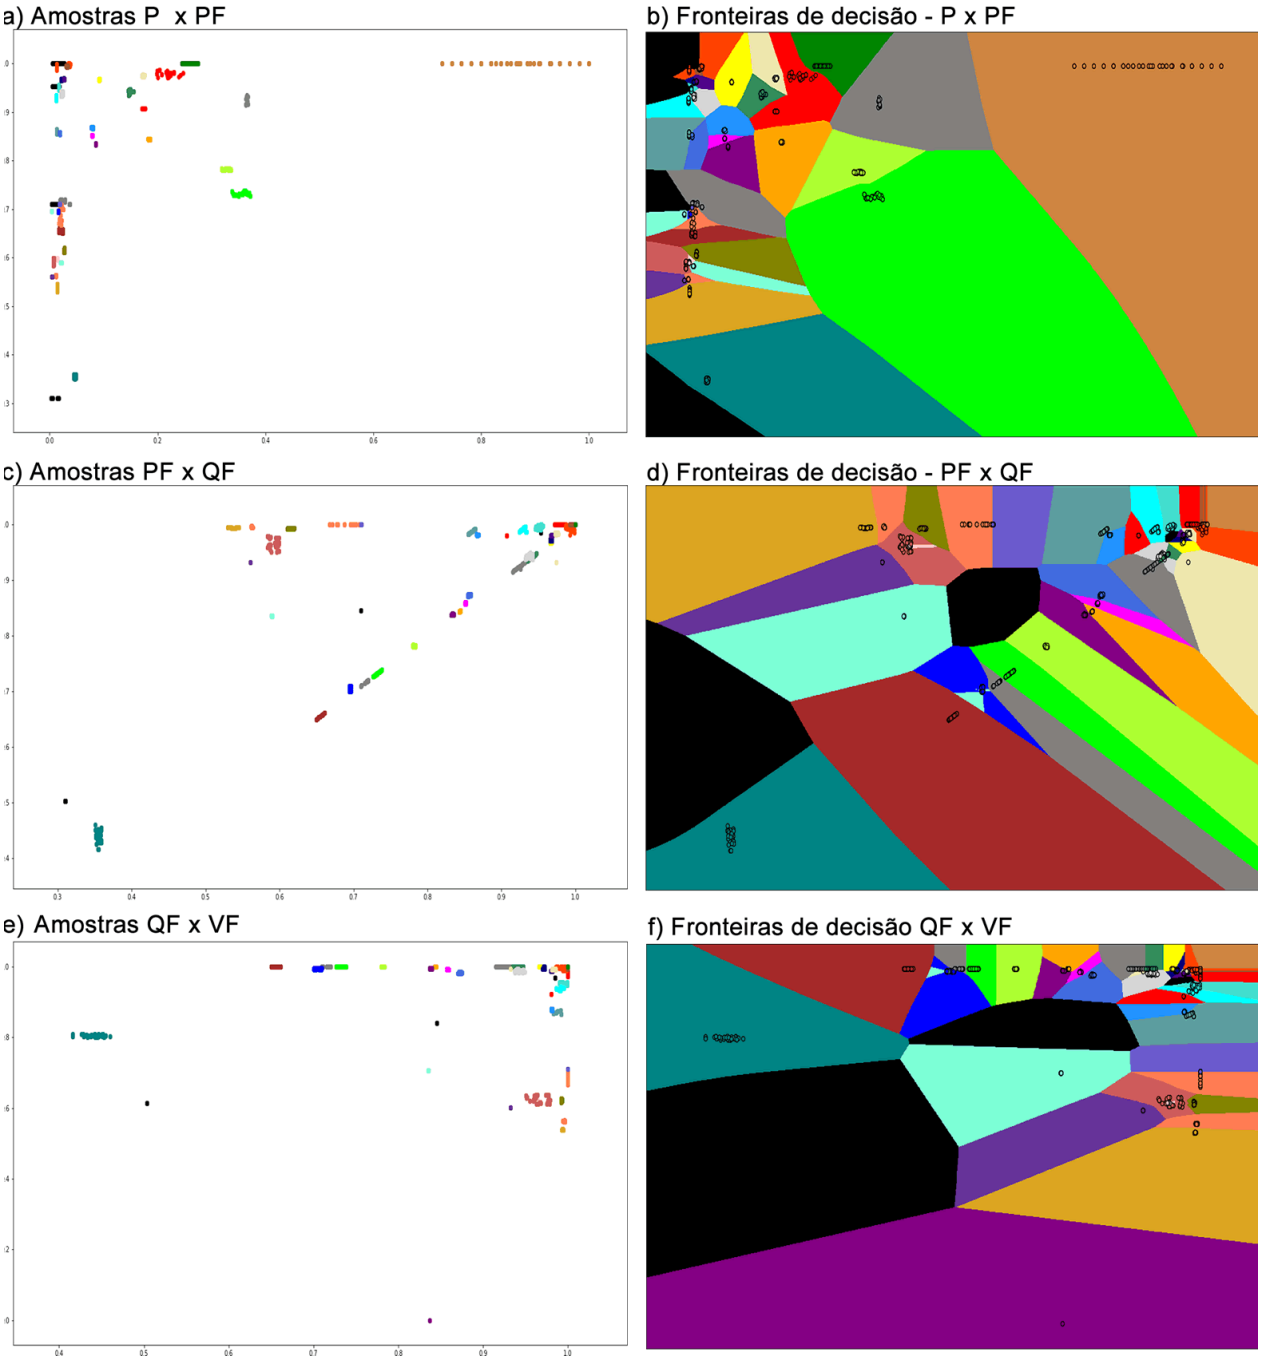

Figura 70: Fronteiras de decisão (3NN).

podem misturá-la com a lâmpada fluorescente.

- **Forno e porta da garagem:** seus fatores de conformidade e termos de potência têm valores mais próximos, como pode ser visto na Tabela 8. Assim, alguns métodos confundem estas duas classes. O mesmo acontece com o vácuo e micro-ondas, o RL1 e a máquina de lavar roupa, e entre as lâmpadas mistas, vapor de mercúrio e vapor de sódio.

Na próxima subseção será apresentada a base de análise dos resultados para a base de dados construída.

5.2 Conceitos

Nesta próxima subseção, são apresentados os conceitos para a análise dos dados para a verificação da qualidade dos atributos da base de dados que foi construída na coleta do medidor cognitivo.

5.2.1 k-fold Estratificado

A estratificação é o processo de reorganizar os dados em dobras para garantir que cada dobra seja um bom representante do conjunto todo de dados e considerando um ajuste proporcional na escolha de cada amostra em relação às classes. Por exemplo, em um problema de classificação binária em que cada classe compreende 50% dos dados, é melhor organizar os dados de forma que, em cada dobra, cada classe compreenda cerca de metade das instâncias.

Segundo Kohavi [90], a estratificação é geralmente o melhor método, tanto em termos de coeficientes quanto de variância, quando comparado à validação cruzada regular.

Desta forma, a estratificação procura assegurar que cada dobra seja representativa para todos os dados. Geralmente isso é feito de forma supervisionada para garantir que cada classe esteja aproximadamente ou igualmente representada em cada dobra de teste (que são naturalmente combinadas de forma complementar para formar dobras de treinamento). Um exemplo do funcionamento do k-fold estratificado é apresentado na Figura 71.

O objetivo da estratificação visa auxiliar a maioria dos algoritmos de classificação, pois estes algoritmos tendem a ponderar cada instância de forma igualitária, o que significa que as classes super-representadas recebem muito peso no processo de treinamento e podem atrapalhar no processo de classificação [92].

Vale lembrar que o k-fold tem como parâmetro o número de dobras (n_{folds}, sendo $n_{folds} - 1$ dobras utilizadas para o processo de treinamento e 1 dobra para o processo de classificação).

Para os resultados, o k-fold estratificado será utilizado, com o número de dobras equivalente a 5 e a 10.

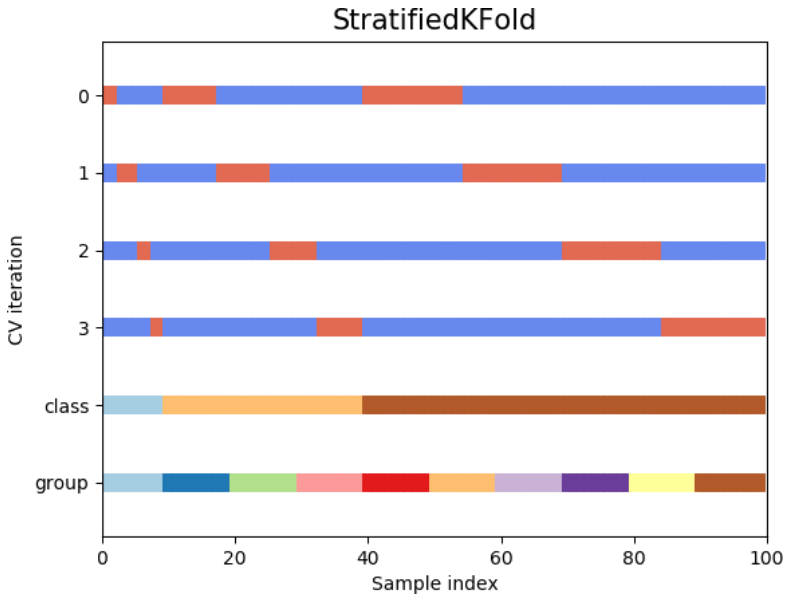

Figura 71: Exemplo do resultado do k-fold com número de dobras igual a 4 [91].

5.2.2 K-NN

O K-enésimo vizinho mais próximo (K-NN - *K-Nearest Neighbor*) [93] é um algoritmo que não constrói um modelo interno generalizado para a classificação (ou seja, não possui fase de treinamento – também chamado de método preguiçoso, pois memoriza objetos de treinamento e adia a computação para a fase de classificação). O K-NN tem sido extensivamente estudado e usado na literatura, pois atende como um excelente classificador em diversas aplicações [24, 93, 94]. A sua heurística é simples de se entender e de se implementar [95]. No algoritmo KNN, uma nova amostra é classificada e rotulada de acordo com a classe que mais se apresenta entre os K vizinhos mais próximos, conforme se apresenta na Figura 72, quando o grau de vizinhança é um, três e cinco. Na Figura 72 deve-se observar a distância entre os pontos utilizando a métrica euclidiana.

O 1NN, KNN com grau de vizinhança igual a um (k=1), pode ser expressada em termos matemáticos. Um rótulo $\theta(X)$ de uma amostra X a ser classificada no espaço Z é atribuída através da equação:

$$\theta(X) = \theta(X_{nn})$$

Enquanto X_{nn} é escolhido por:

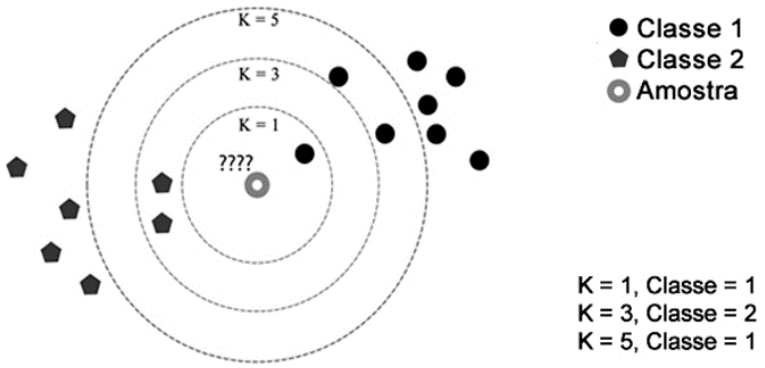

Figura 72: Comportamento do Classificador KNN quando K=1, K=3 e K=5 com a função de distância euclidiana [18].

$$X_{nn} = arg\ min_{\forall X^i \in Z} \left\{ d_x(X - X^i) \right\}$$

No grau de vizinhança maior do que um (K>1) é calculada a distância entre os pontos, são selecionados os K pontos mais próximos e olha-se para os rótulos destes pontos. O rótulo que aparece com mais frequência é o que será atribuído para a amostra a ser classificada.

A vantagem principal do KNN é justamente no processo de treinamento que é inexistente, isso pode ser bom para alguns conjuntos de dados. A desvantagem é que, dependendo da quantidade de amostras ou de dimensões, o método pode se tornar lento ou sofrer do problema da dimensionalidade [96].

5.2.3 Random Forest

Floresta aleatória (em inglês *random forest*) é um método de aprendizado de máquina utilizado para classificação. Ela é feita de muitas árvores de decisão, na qual cada árvore de decisão é criada usando um subconjunto dos atributos usados para classificar uma determinada população (sub-árvores) [97]. Essas árvores de decisão votam sobre como classificar uma determinada instância de dados de entrada, e a floresta aleatória inicializa esses votos para escolher a melhor previsão. Isso é feito para evitar *overfitting*, uma falha comum das árvores de decisão. O algoritmo da floresta aleatória foi desenvolvido por Breiman e Cutler [98].

Para isso, é necessário entender o que é uma árvore de decisão. As árvores de decisão, assim como o nome sugere, possuem uma estrutura hierárquica ou semelhante a uma árvore com ramificações

que atuam como nós. Chega-se a decisão percorrendo esses nós que são baseados nas respostas dos parâmetros relacionados aos nós (geralmente aos atributos ou conjunto de atributos). No entanto, as árvores de decisão sofrem com um problema de *overfitting*. O *Overfitting* basicamente aumenta a especificidade dentro da árvore para chegar a uma certa conclusão, aumentando assim a profundidade da árvore e tornando-a mais complexa. Criando um conjunto de árvores de decisão, elimina-se este problema de *overfitting*, e a floresta aleatória é uma solução para este problema.

A floresta aleatória é, portanto, um algoritmo de aprendizado de máquina para classificação. Simplificando, uma floresta aleatória é composta de várias árvores de decisão e ajuda a resolver o problema do *overfitting* em árvores de decisão. Essas árvores de decisão são construídas aleatoriamente, selecionando recursos aleatórios do conjunto de dados fornecido. A floresta aleatória chega a uma decisão ou previsão com base no número máximo de votos recebidos das árvores de decisão. O resultado a que se chega, por um número máximo de votos de um rótulo é considerado como o resultado final pela floresta aleatória.

As florestas aleatórias são baseadas em técnicas de aprendizado em ensemble. Ensemble significa grupo ou coleção, que nesse caso é uma coleção de árvores de decisão. A precisão dos modelos ensemble é melhor do que a precisão de modelos individuais devido ao fato de que compila os resultados dos modelos individuais e fornece um resultado final.

Os atributos, dentro do algoritmo de árvores aleatórias, são selecionados de forma aleatória usando um método conhecido como agregação de *bootstrap* ou ensacamento. A partir do conjunto de atributos disponíveis no conjunto de dados, vários subconjuntos de treinamento são criados escolhendo atributos aleatórios com substituição. O que isso significa é que um atributo pode ser repetido em diferentes subconjuntos de treinamento ao mesmo tempo.

Por exemplo, se um conjunto de dados contiver 20 atributos e subconjuntos de 5 atributos a serem selecionados para construir diferentes árvores de decisão, esses 5 atributos serão selecionados aleatoriamente e qualquer atributo poderá fazer parte de mais de um subconjunto. Isso garante a aleatoriedade, diminuindo a correlação entre as árvores, superando assim o problema do *overfitting*.

Depois que os atributos são selecionados, as árvores são construídas com base na melhor divisão. Cada árvore fornece uma saída que é considerada como um "voto" dessa árvore para a saída dada. A saída que recebe o máximo de votos é escolhida pela floresta aleatória como saída ou, no caso de

variáveis contínuas, a média de todas as saídas é considerada como a saída final. A Figura 73 mostra uma representação gráfica do funcionamento do algoritmo de florestas aleatórias.

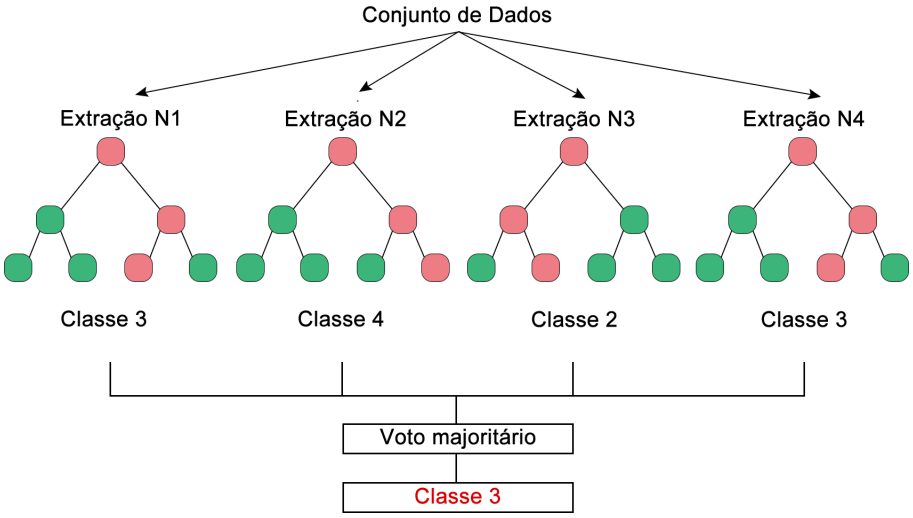

Figura 73: Comportamento do Classificador *Random Forest* para um exemplo de base de dados com quatro classes.

5.2.4 SVM - Support Vector Machine

As máquinas de vetores de suporte (em inglês SVM - Support Vector Machine) são baseadas no conceito de planos de decisão que definem fronteiras de decisão para a classificação. Um plano de decisão é aquele que separa um conjunto de objetos com diferentes participações de classe. Um exemplo esquemático é mostrado na Figura 74, (a). Neste exemplo, os objetos pertencem à classe VERDE ou VERMELHO. A linha de separação define um limite no lado direito do qual todos os objetos são VERDES e, à esquerda, todos os objetos são VERMELHOS. Qualquer objeto novo (círculo branco) caindo à direita é rotulado, ou seja, classificado como VERDE (ou classificado como VERMELHO, caso caia à esquerda da linha de separação).

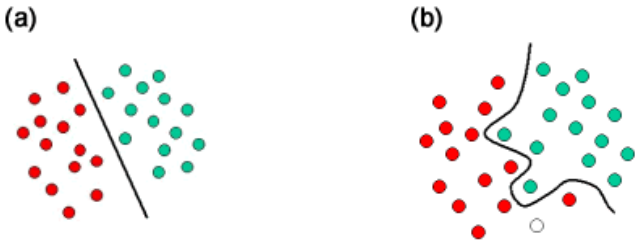

Figura 74: Exemplo de amostras e idealização da fronteira de decisão.

A Figura 74 é um exemplo clássico de um classificador linear, ou seja, um classificador que separa um conjunto de objetos em seus respectivos grupos (VERDE e VERMELHO, neste caso) com uma linha. A maioria das tarefas de classificação, no entanto, não é tão simples, e muitas vezes são necessárias estruturas mais complexas para fazer uma separação ideal, ou seja, classificar corretamente as novas amostras (como nos casos de teste/classificação) com base nos exemplos disponíveis (casos de treinamento) [99]. Essa situação é descrita na Figura 74, (b). Comparado exemplo (a), fica claro que uma separação completa dos objetos VERDE e VERMELHO exigiria uma curva (sendo assim um problema não linear). As tarefas de classificação baseadas no desenho de linhas de separação para distinguir entre objetos de diferentes participações de classe são conhecidas como classificadores de hiperplano. As máquinas de vetores de suporte são particularmente adequadas para lidar com essas tarefas.

A Figura 75 mostra a ideia básica por trás das máquinas de vetores de suporte. Tem-se os objetos originais (indicado por (a) na Figura 75) mapeados, isto é, rearranjados, usando um conjunto de funções matemáticas, conhecidas como *kernels*. O processo de reorganizar os objetos é conhecido como mapeamento (transformação). Nesta nova configuração, os objetos mapeados (indicado por (b) na Figura 75) são linearmente separáveis e, assim, ao invés de construir a curva complexa ((a) de 75), encontra-se uma linha ótima que possa separar a Objetos VERDES e VERMELHOS.

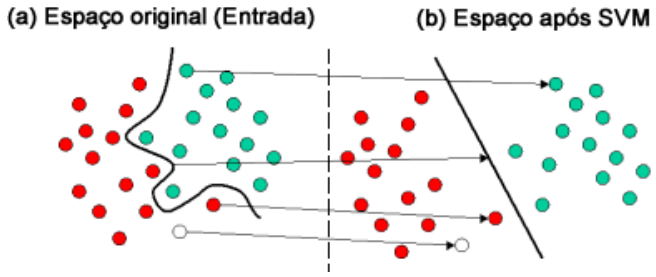

Figura 75: Exemplo da transformada do espaço multidimensional do SVM.

Neste projeto foi utilizado a função gaussiana radial (RBF) para realizar a aplicação do treinamento e classificação porque ela apresenta uma eficiência comprovada na literatura. A função objetivo é expressa como:

$$K(x^i, x^j) = exp(-1 * \gamma \left\| x^i - x^j \right\|^2)$$

No qual γ é o parâmetro do núcleo (*kernel*) RBF. Tal técnica possui eficiência em espaços de muitas

dimensões (ou seja, em amostras com muitas características), sendo também versátil, pois é possível modificar facilmente a função de *kernel*, podendo assim se adaptar de acordo com a aplicação.

A subseção a seguir apresentará os resultados obtidos com os classificadores apresentados no conjunto de dados criado neste projeto.

5.2.5 Métricas de desempenho

Para explicar as métricas de desempenho dos classificadores, tais conceitos devem ser apresentados:

- **Positivos verdadeiros (TP)**: Esses são os valores positivos preditos corretamente, o que significa que o valor da classe real é sim e o valor da classe prevista também é sim. Por exemplo, se o valor real da classe indica que o paciente está doente e a classe prevista lhe diz a mesma coisa.
- **Verdadeiros Negativos (TN)**: Estes são os valores negativos previstos corretamente, o que significa que o valor da classe real é não e o valor da classe prevista também é não. Por exemplo, se a classe real diz que este paciente está saudável e previu que a classe lhe dirá a mesma coisa.
- **Falsos Positivos (FP)**: Quando a classe real é não e a classe prevista é sim, ou seja, houve um erro. Por exemplo, se a classe real disser que o paciente está saudável, mas a classe previu que esse paciente está doente.
- **Falsos Negativos (FN)**: Quando a classe real é sim, mas a classe prevista é não. Por exemplo, se o valor real da classe indicar que esse paciente está doente e a classe prevista informa que o paciente está saudável.

Depois de entender esses conceitos, é possível calcular a precisão, revocação e F1-medida.

Precisão - A precisão é uma medida de desempenho intuitiva e é proporção da observação corretamente prevista para o total de observações. Pode-se pensar que, se há alta precisão, o modelo é o melhor. Porém, a precisão é considerada uma ótima medida se há um tem conjuntos de dados simétricos em que os valores de falso positivo e falso negativo são quase iguais. Portanto, é necessário examinar outras métricas de desempenho para avaliar o modelo. O valor da precisão é dado pela seguinte fórmula:

$$Precision = \frac{TP + TN}{TP + FP + FN + TN}$$

Recall (Revocação) - *Recall* é a razão de observações positivas preditas corretamente para todas as observações na classe real - sim. Um exemplo de recall é: de todos os pacientes que realmente estavam doentes, quantos foram corretamente rotulados?

$$Recall = \frac{TP}{TP + FN}$$

F1-medida - A F1-medida é a média ponderada de Precisão e Revocação. Portanto, essa pontuação leva em conta tanto os falsos positivos quanto os falsos negativos. A F1-medida é geralmente mais útil que a precisão, principalmente se há uma distribuição desigual de classes.

$$F1 = 2 * \frac{Recall * Precision}{Recall + Precision}$$

5.3 Análise de qualidade dos atributos

Os resultados serão apresentados conforme a organização apresentada na Tabela 11.

Os resultados foram feitos utilizando a linguagem python 3.7, com scikit-learn. Foram utilizados os classificadores implementados na biblioteca e para a execução dos resultados foi utilizado o modelo seletor GridSearchCV (com cv=5). A seguir serão apresentados os indicadores de desempenho para cada classificador e alguns indicadores de desempenho e de qualidade dos resultados.

Foi omitido por hora os resultados com o PCA com representatividade de dados equivalente a 95%, pois os com representatividade igual a 0,99% já apresenta queda de valores dos indicadores.

5.3.1 Caso A1 - k-folds (folds=5), KNN sem PCA e dados não normalizados

Para este resultado, o KNN obteve melhor resultado com o grau de vizinhança igual a um ($k = 1$). A Tabela 12 apresenta as métricas de desempenho do algoritmo classificador.

Tabela 11: Organização dos resultados.

k-folds estratificado	Classificador	Parâmetros	Dados Normalizados?	PCA?	Caso
folds = 5	KNN	K={1,3,5}	Não	Não	A1
			Sim	-	A2
			-	Sim	A3
	Random Forest	Árvores = {50,60,70,80,90,100}	Não	Não	B1
			Sim	-	B2
			-	Sim	B3
	SVM com RBF	C={10e-3,10e-2,...,10e2, 10e3} gamma={10e-3,10e-2,...,10e2, 10e3}	Não	Não	C1
			Sim	-	C2
			-	Sim	C3
	SVM Linear	C={10e-3,10e-2,...,10e2, 10e3} gamma={10e-3,10e-2,...,10e2, 10e3}	-*	-	-
			Sim	-	D1
			-	Sim	D2
	DT		Não	Não	E1
			-	Sim	E2
			Sim	-	E3

Tabela 12: KNN – Caso A1 – resultados para a base de dados sem normalização.

KNN (K)	$t_{classif.}(s)$	Revocação	Precisão	F-medida
1	0,1995	0,9784	0,9784	0,9815
3	0,2234	0,9534	0,9534	0,9571
5	0,2194	0,9409	0,9409	0,9408

5.3.2 Caso A2 - k-folds (folds=5), KNN sem PCA e dados normalizados

Para este resultado, o KNN obteve melhor resultado com o grau de vizinhança igual a um ($k = 1$). A Tabela 13 apresenta as métricas de desempenho do algoritmo classificador.

Tabela 13: KNN – Caso A2 – resultados para a base de dados com normalização.

KNN (K)	$t_{classif.}(s)$	Revocação	Precisão	F-medida
1	0,2181	0,9945	0,9945	0,9947
3	0,2264	0,9915	0,9915	0,9935
5	0,2354	0,9886	0,9886	0,9916

5.3.3 Caso A3 - k-folds (folds=5), KNN com PCA=0.99

Para este resultado, foi antes aplicada a transformada PCA, com representatividade de dados equivalente a 99%. O KNN obteve melhor resultado com o grau de vizinhança igual a um ($k = 1$). A Tabela 14 apresenta as métricas de desempenho do algoritmo classificador.

Tabela 14: Resultados caso A2.

KNN (N)	$t_{classif.}(s)$	Revocação	Precisão	F-medida
1	0,2304	0,9927	0,9927	0,9951
3	0,2364	0,9862	0,9862	0,9911
5	0,2433	0,9847	0,9847	0,9900

5.3.4 Caso B1 - k-folds (folds=5), Random Forest sem PCA e dados não normalizados

Para este resultado, o algoritmo Random Forest obteve melhor resultado com o número de árvores igual a vinte ($arvores = 20$). A Tabela 15 apresenta as métricas de desempenho do algoritmo classificador.

5.3.5 Caso B2 - k-folds (folds=5), Random Forest sem PCA e dados normalizados

Para este resultado, o algoritmo Random Forest obteve melhor resultado com o número de árvores igual a dez ($arvores = 10$). A Tabela 16 apresenta as métricas de desempenho do algoritmo classificador.

Tabela 15: Resultados caso B1.

Árvores	$t_{treinamento}$	$t_{classif.}$	Revocação	Precisão	F-medida	Ranking
10	0,0778	0,0289	0,9995	0,9995	0,9996	9
20	0,1486	0,0509	0,9996	0,9996	0,9998	1
30	0,2194	0,0788	0,9996	0,9996	0,9998	1
40	0,2912	0,0918	0,9996	0,9996	0,9998	1
50	0,3710	0,1117	0,9996	0,9996	0,9998	1
60	0,4419	0,1336	0,9995	0,9995	0,9995	10
70	0,5665	0,1546	0,9996	0,9996	0,9998	1
80	0,5934	0,1715	0,9996	0,9996	0,9998	1
90	0,6612	0,1925	0,9996	0,9996	0,9998	1
100	0,7370	0,2134	0,9996	0,9996	0,9998	1

Tabela 16: Resultados caso B2.

Árvores	t_treinamento	t_classif	Revocação	Precisão	F-medida
10	0,0778	0,0289	0,9996	0,9996	0,9998
20	0,1606	0,0568	0,9996	0,9996	0,9998
30	0,2374	0,0708	0,9996	0,9996	0,9998
40	0,3012	0,0928	0,9996	0,9996	0,9998
50	0,3800	0,1127	0,9996	0,9996	0,9998
60	0,4458	0,1346	0,9996	0,9996	0,9998
70	0,5226	0,1536	0,9996	0,9996	0,9998
80	0,6034	0,1755	0,9996	0,9996	0,9998
90	0,6792	0,1945	0,9996	0,9996	0,9998
100	0,7500	0,2174	0,9996	0,9996	0,9998

5.3.6 Caso B3 - k-folds (folds=5), Random Forest com PCA=0.99

Para este resultado, foi antes aplicada a transformada PCA, com representatividade de dados equivalente a 99%. O algoritmo Random Forest obteve melhor resultado com o número de árvores igual a trinta ($arvores = 30$). A Tabela 17 apresenta as métricas de desempenho do algoritmo classificador.

Tabela 17: Resultados caso B3.

Árvores	t_treinamento	t_classif	Revocação	Precisão	F-medida	Ranking
10	0,0578	0,0299	0,9909	0,9909	0,9926	10
20	0,1097	0,0509	0,9932	0,9932	0,9945	8
30	0,1705	0,0768	0,9960	0,9960	0,9960	1
40	0,2224	0,0997	0,9927	0,9927	0,9943	9
50	0,2842	0,1316	0,9945	0,9945	0,9958	2
60	0,3341	0,1476	0,9937	0,9937	0,9950	4
70	0,3949	0,1666	0,9938	0,9938	0,9949	7
80	0,4368	0,1895	0,9941	0,9941	0,9950	6
90	0,4967	0,2124	0,9941	0,9941	0,9951	3
100	0,5525	0,2334	0,9940	0,9940	0,9950	5

5.3.7 Caso C1 - k-folds (folds=5), SVM/RBF sem PCA e dados não normalizados

Para este resultado, o algoritmo SVM com *kernel* RBF obteve melhor resultado com os parâmetros $C = 1000$ e $gamma = 0,1$. A Tabela 18 apresenta as métricas de desempenho do algoritmo classificador.

5.3.8 Caso C2 - k-folds (folds=5), SVM/RBF sem PCA e dados normalizados

Para este resultado, o algoritmo SVM com *kernel* RBF obteve melhor resultado com os parâmetros $C = 1000$ e $gamma = 100$. A Tabela 19 apresenta as métricas de desempenho do algoritmo classificador.

5.3.9 Caso C3 - k-folds (folds=5), SVM/RBF com PCA=0.99

Para este resultado, foi antes aplicada a transformada PCA, com representatividade de dados equivalente a 99%. O algoritmo SVM com *kernel* RBF obteve melhor resultado com os parâmetros $C = 100$ e $gamma = 100$. A Tabela 20 apresenta as métricas de desempenho do algoritmo classificador.

Tabela 18: Resultados caso C1.

C	gamma	$t_{treinamento}$	$t_{classif.}$	Revocação	Precisão	F-medida	Ranking
0,001	0,001	1,5638	3,4218	0,0054	0,0054	0,0089	41
0,001	0,01	1,6735	3,1466	0,0054	0,0054	0,0089	41
0,001	0,1	2,4883	3,7380	0,0054	0,0054	0,0089	41
0,001	1	2,5113	3,9258	0,0054	0,0054	0,0089	41
0,001	10	2,3796	3,6675	0,0054	0,0054	0,0089	41
0,001	100	2,2999	3,6634	0,0054	0,0054	0,0089	41
0,001	1000	2,2240	3,4747	0,0054	0,0054	0,0089	41
0,01	0,001	1,4711	3,3251	0,0401	0,0401	0,0554	37
0,01	0,01	1,4960	2,8793	0,0573	0,0573	0,0696	36
0,01	0,1	2,4844	3,6057	0,0959	0,0959	0,0905	35
0,01	1	2,9162	3,7999	0,0580	0,0580	0,0416	38
0,01	10	3,5615	3,9165	0,0324	0,0324	0,0111	40
0,01	100	4,5788	3,7015	0,0054	0,0054	0,0089	41
0,01	1000	5,2759	3,6838	0,0054	0,0054	0,0089	41
0,1	0,001	0,6862	2,7934	0,4407	0,4407	0,4329	33
0,1	0,01	0,7809	2,4169	0,5482	0,5482	0,5283	30
0,1	0,1	1,7403	2,7577	0,5716	0,5716	0,5176	31
0,1	1	2,7357	2,8653	0,6432	0,6432	0,5369	29
0,1	10	4,3923	3,1867	0,5533	0,5533	0,4350	32
0,1	100	6,0608	3,6361	0,3846	0,3846	0,1688	34
0,1	1000	6,1066	3,6553	0,0866	0,0866	0,0325	39
1	0,001	0,3850	2,2995	0,6069	0,6069	0,5693	28
1	0,01	0,4976	1,8359	0,6885	0,6885	0,6718	27
1	0,1	1,2806	1,9498	0,8795	0,8795	0,8610	22
1	1	2,3248	1,9817	0,9347	0,9347	0,9217	17
1	10	4,4651	2,2041	0,9749	0,9749	0,9435	12
1	100	6,3171	2,6698	0,9830	0,9830	0,9161	18
1	1000	6,6672	3,1037	0,9570	0,9570	0,8547	23
10	0,001	0,3251	1,8101	0,7026	0,7026	0,6752	26
10	0,01	0,4578	1,4571	0,8673	0,8673	0,8439	24
10	0,1	1,1928	1,4053	0,9346	0,9346	0,9316	13
10	1	2,2889	1,6236	0,9730	0,9730	0,9693	6
10	10	4,4102	2,0206	0,9861	0,9861	0,9631	10
10	100	6,5914	2,4943	0,9894	0,9894	0,9301	14
10	1000	6,7520	2,8773	0,9846	0,9846	0,8732	21
100	0,001	0,3331	1,5040	0,8372	0,8372	0,8230	25
100	0,01	0,5106	1,1100	0,9454	0,9454	0,9452	11
100	0,1	1,2307	1,1998	0,9754	0,9754	0,9753	5
100	1	2,2500	1,4940	0,9816	0,9816	0,9809	4
100	10	4,4801	1,9887	0,9865	0,9865	0,9648	9
100	100	6,3211	2,5053	0,9891	0,9891	0,9295	15
100	1000	7,0352	2,8833	0,9851	0,9851	0,8735	19
1000	0,001	0,4857	0,9604	0,9624	0,9624	0,9659	7
1000	0,01	0,7151	0,7470	0,9847	0,9847	0,9835	2
1000	0,1	1,3005	1,0891	0,9886	0,9886	0,9893	1
1000	1	2,2779	1,5060	0,9834	0,9834	0,9821	3
1000	10	4,6416	2,0465	0,9872	0,9872	0,9653	8
1000	100	6,6223	2,6000	0,9891	0,9891	0,9295	15
1000	1000	6,8048	2,8604	0,9851	0,9851	0,8735	19

Tabela 19: Resultados caso C2.

C	gamma	$t_{treinamento}$	$t_{classif.}$	Revocação	Precisão	F-medida	Ranking
0,001	0,001	0,9863	2,7016	0,0054	0,0054	0,0089	42
0,001	0,01	0,9883	2,7770	0,0054	0,0054	0,0089	42
0,001	0,1	1,0023	2,7503	0,0054	0,0054	0,0089	42
0,001	1	1,0312	2,7062	0,0184	0,0184	0,0273	41
0,001	10	1,0013	2,7584	0,0254	0,0254	0,0323	40
0,001	100	2,8773	2,7487	0,0054	0,0054	0,0089	42
0,001	1000	2,8016	4,2635	0,0054	0,0054	0,0089	42
0,01	0,001	0,9894	2,7726	0,0054	0,0054	0,0089	42
0,01	0,01	1,0023	2,7768	0,0054	0,0054	0,0089	42
0,01	0,1	0,9474	2,4248	0,0446	0,0446	0,0551	38
0,01	1	0,8388	2,2380	0,0865	0,0865	0,0797	35
0,01	10	0,8706	2,2443	0,1044	0,1044	0,1010	34
0,01	100	2,9162	2,4245	0,1325	0,1325	0,1015	33
0,01	1000	4,6082	3,9825	0,0577	0,0577	0,0356	39
0,1	0,001	0,9983	2,7321	0,0054	0,0054	0,0089	42
0,1	0,01	0,9335	2,3953	0,0450	0,0450	0,0553	37
0,1	0,1	0,7390	2,1862	0,0999	0,0999	0,1134	30
0,1	1	0,4398	2,1017	0,3987	0,3987	0,3567	26
0,1	10	0,3770	1,8192	0,8162	0,8162	0,7848	21
0,1	100	1,4770	1,5025	0,9318	0,9318	0,9264	18
0,1	1000	4,6585	2,7118	0,9853	0,9853	0,9356	15
1	0,001	0,9335	2,4089	0,0450	0,0450	0,0553	36
1	0,01	0,7350	2,2041	0,0995	0,0995	0,1130	31
1	0,1	0,3959	1,9488	0,3407	0,3407	0,3143	27
1	1	0,2015	1,6921	0,7580	0,7580	0,7283	22
1	10	0,2045	0,9425	0,9587	0,9587	0,9348	16
1	100	1,0392	0,7849	0,9886	0,9886	0,9902	11
1	1000	4,4292	1,5150	0,9941	0,9941	0,9929	10
10	0,001	0,7669	2,1712	0,0995	0,0995	0,1130	31
10	0,01	0,4289	1,9767	0,3285	0,3285	0,2961	29
10	0,1	0,2184	1,8191	0,6744	0,6744	0,6425	24
10	1	0,1197	1,0492	0,9539	0,9539	0,9322	17
10	10	0,2004	0,5894	0,9843	0,9843	0,9835	12
10	100	1,0253	0,5715	0,9968	0,9968	0,9977	4
10	1000	4,4720	1,6735	0,9958	0,9958	0,9952	6
100	0,001	0,4179	2,0466	0,3311	0,3311	0,2967	28
100	0,01	0,2314	1,8016	0,6885	0,6885	0,6554	23
100	0,1	0,1536	1,1859	0,9476	0,9476	0,9236	19
100	1	0,0997	0,5984	0,9812	0,9812	0,9804	13
100	10	0,1925	0,3840	0,9968	0,9968	0,9970	5
100	100	1,0412	0,4986	0,9992	0,9992	0,9995	2
100	1000	4,3893	1,3574	0,9959	0,9959	0,9951	7
1000	0,001	0,2334	1,7959	0,6298	0,6298	0,6111	25
1000	0,01	0,1666	1,2456	0,9387	0,9387	0,9083	20
1000	0,1	0,1297	0,7071	0,9743	0,9743	0,9745	14
1000	1	0,1047	0,3860	0,9945	0,9945	0,9949	9
1000	10	0,2025	0,2943	0,9987	0,9987	0,9990	3
1000	100	1,0153	0,4837	0,9996	0,9996	0,9998	1
1000	1000	4,3907	1,3563	0,9961	0,9961	0,9951	8

Tabela 20: Resultados caso C3.

C	gamma	$t_{treinamento}$	$t_{classif.}$	Revocação	Precisão	F-medida	Ranking
0,001	0,001	0,9405	2,7357	0,0054	0,0054	0,0089	43
0,001	0,01	0,9405	2,7227	0,0054	0,0054	0,0089	43
0,001	0,1	0,9584	2,7176	0,0054	0,0054	0,0089	43
0,001	1	0,9844	2,7077	0,0202	0,0202	0,0288	42
0,001	10	1,6047	2,7369	0,0054	0,0054	0,0089	43
0,001	100	3,1117	3,9387	0,0054	0,0054	0,0089	43
0,001	1000	2,4564	3,6981	0,0054	0,0054	0,0089	43
0,01	0,001	0,9445	2,7020	0,0054	0,0054	0,0089	43
0,01	0,01	0,9574	2,7185	0,0516	0,0516	0,0576	39
0,01	0,1	0,8667	2,2221	0,0849	0,0849	0,0999	36
0,01	1	0,7929	2,1432	0,0734	0,0734	0,0885	37
0,01	10	1,3663	2,3882	0,1862	0,1862	0,1334	33
0,01	100	3,5206	3,5959	0,0825	0,0825	0,0673	38
0,01	1000	4,9627	3,6229	0,0316	0,0316	0,0344	41
0,1	0,001	0,9554	2,7094	0,0508	0,0508	0,0572	40
0,1	0,01	0,7999	2,1748	0,0856	0,0856	0,1004	34
0,1	0,1	0,5615	2,1245	0,2950	0,2950	0,2768	30
0,1	1	0,3421	1,9408	0,5275	0,5275	0,5083	26
0,1	10	0,5805	1,5578	0,8630	0,8630	0,8365	20
0,1	100	2,4076	2,1217	0,9465	0,9465	0,9445	16
0,1	1000	5,6169	2,8351	0,9592	0,9592	0,8314	22
1	0,001	0,7849	2,1473	0,0857	0,0857	0,1004	35
1	0,01	0,5376	2,0885	0,2563	0,2563	0,2574	31
1	0,1	0,2793	1,8581	0,5017	0,5017	0,4916	27
1	1	0,1626	1,5319	0,8500	0,8500	0,8324	21
1	10	0,3361	0,7968	0,9635	0,9635	0,9670	14
1	100	1,8102	0,9913	0,9877	0,9877	0,9904	9
1	1000	5,5790	1,6785	0,9947	0,9947	0,9887	12
10	0,001	0,5475	2,0922	0,2563	0,2563	0,2574	31
10	0,01	0,3321	1,8620	0,4716	0,4716	0,4622	28
10	0,1	0,1745	1,5040	0,8061	0,8061	0,7866	23
10	1	0,1087	0,8996	0,9410	0,9410	0,9434	17
10	10	0,3080	0,4686	0,9864	0,9864	0,9888	11
10	100	1,7912	0,8368	0,9928	0,9928	0,9957	3
10	1000	5,6489	1,5549	0,9951	0,9951	0,9911	6
100	0,001	0,3301	1,9807	0,4670	0,4670	0,4572	29
100	0,01	0,2065	1,5506	0,7828	0,7828	0,7734	24
100	0,1	0,1346	0,9237	0,9206	0,9206	0,9209	18
100	1	0,1017	0,4438	0,9837	0,9837	0,9866	13
100	10	0,3221	0,3581	0,9895	0,9895	0,9913	5
100	100	1,7743	0,8119	0,9948	0,9948	0,9968	1
100	1000	5,5571	1,5548	0,9951	0,9951	0,9911	6
1000	0,001	0,2663	1,5318	0,7732	0,7732	0,7442	25
1000	0,01	0,1775	1,0617	0,9044	0,9044	0,8965	19
1000	0,1	0,1277	0,5465	0,9505	0,9505	0,9549	15
1000	1	0,1117	0,2992	0,9860	0,9860	0,9892	10
1000	10	0,3261	0,3252	0,9924	0,9924	0,9953	4
1000	100	1,7404	0,8008	0,9943	0,9943	0,9963	2
1000	1000	5,5611	1,5588	0,9947	0,9947	0,9908	8

5.3.10 Caso D1 - k-folds (folds=5), SVM/Linear sem PCA e dados normalizados

Para este resultado, o algoritmo SVM linear obteve melhor resultado com o parâmetro $C = 1000$. A Tabela 21 apresenta as métricas de desempenho do algoritmo classificador.

5.3.11 Caso D2 - k-folds (folds=5), SVM Linear com PCA=0.99

Para este resultado, foi antes aplicada a transformada PCA, com representatividade de dados equivalente a 99%. O algoritmo SVM linear obteve melhor resultado com o parâmetro $C = 100$. A Tabela 22 apresenta as métricas de desempenho do algoritmo classificador.

5.3.12 Caso E1 - k-folds (folds=5), DT sem PCA e dados não normalizados

A árvore de decisão (DT) não recebe parâmetros, portanto a Tabela 23 apresenta as métricas de desempenho do algoritmo classificador DT.

5.3.13 Caso E2 - k-folds (folds=5), DT sem PCA e dados normalizados

A árvore de decisão (DT) não recebe parâmetros, portanto a Tabela 24 apresenta as métricas de desempenho do algoritmo classificador DT.

5.3.14 Caso E3 - k-folds (folds=5), DT com PCA=0.99

Para este resultado, foi antes aplicada a transformada PCA, com representatividade de dados equivalente a 99%. A árvore de decisão (DT) não recebe parâmetros, portanto a Tabela 25 apresenta as métricas de desempenho do algoritmo classificador DT.

5.3.15 Comparação entre os classificadores

A seguir são comparados os melhores resultados dos classificadores para o conjunto de dados com 32 atributos e de acordo com os casos A1, A2, B1, B2, C1, C2, D1, D2, E1, E2, F1 e F2. As comparações são organizadas de acordo com o número de dobras (*folds*) do k-fold estratificado

Tabela 21: Resultados caso D1.

C	gamma	$t_{treinamento}$	$t_{classif.}$	Revocação	Precisão	F-medida	Ranking
0,001	0,001	0,5276	2,1972	0,0449	0,0449	0,0547	43
0,001	0,01	0,5256	2,1921	0,0449	0,0449	0,0547	43
0,001	0,1	0,5296	2,1841	0,0449	0,0449	0,0547	43
0,001	1	0,5266	2,1772	0,0449	0,0449	0,0547	43
0,001	10	0,5246	2,2560	0,0449	0,0449	0,0547	43
0,001	100	0,5177	2,1736	0,0449	0,0449	0,0547	43
0,001	1000	0,5196	2,4401	0,0449	0,0449	0,0547	43
0,01	0,001	0,4249	1,8204	0,0942	0,0942	0,0849	36
0,01	0,01	0,4318	1,8353	0,0942	0,0942	0,0849	36
0,01	0,1	0,4219	1,9538	0,0942	0,0942	0,0849	36
0,01	1	0,4218	1,8461	0,0942	0,0942	0,0849	36
0,01	10	0,4198	1,8211	0,0942	0,0942	0,0849	36
0,01	100	0,4329	1,8254	0,0942	0,0942	0,0849	36
0,01	1000	0,4169	1,8231	0,0942	0,0942	0,0849	36
0,1	0,001	0,2623	1,6625	0,2738	0,2738	0,2640	29
0,1	0,01	0,2643	1,7244	0,2738	0,2738	0,2640	29
0,1	0,1	0,2663	1,6944	0,2738	0,2738	0,2640	29
0,1	1	0,2633	1,6626	0,2738	0,2738	0,2640	29
0,1	10	0,2643	2,0276	0,2738	0,2738	0,2640	29
0,1	100	0,2643	1,7604	0,2738	0,2738	0,2640	29
0,1	1000	0,2653	1,7217	0,2738	0,2738	0,2640	29
1	0,001	0,1516	1,5647	0,5789	0,5789	0,5769	22
1	0,01	0,1546	1,5599	0,5789	0,5789	0,5769	22
1	0,1	0,1556	1,5209	0,5789	0,5789	0,5769	22
1	1	0,1516	1,5361	0,5789	0,5789	0,5769	22
1	10	0,1506	1,5431	0,5789	0,5789	0,5769	22
1	100	0,1546	1,5369	0,5789	0,5789	0,5769	22
1	1000	0,1556	1,6159	0,5789	0,5789	0,5769	22
10	0,001	0,1207	1,2148	0,8734	0,8734	0,8682	15
10	0,01	0,1187	1,2247	0,8734	0,8734	0,8682	15
10	0,1	0,1207	1,2150	0,8734	0,8734	0,8682	15
10	1	0,1197	1,2257	0,8734	0,8734	0,8682	15
10	10	0,1197	1,2248	0,8734	0,8734	0,8682	15
10	100	0,1207	1,2152	0,8734	0,8734	0,8682	15
10	1000	0,1207	1,2197	0,8734	0,8734	0,8682	15
100	0,001	0,1416	0,7999	0,9588	0,9588	0,9521	8
100	0,01	0,1396	0,7989	0,9588	0,9588	0,9521	8
100	0,1	0,1406	0,7999	0,9588	0,9588	0,9521	8
100	1	0,1416	0,7989	0,9588	0,9588	0,9521	8
100	10	0,1406	0,7999	0,9588	0,9588	0,9521	8
100	100	0,1436	0,8068	0,9588	0,9588	0,9521	8
100	1000	0,1376	0,7979	0,9588	0,9588	0,9521	8
1000	0,001	0,2843	0,6094	0,9645	0,9645	0,9615	1
1000	0,01	0,2802	0,6094	0,9645	0,9645	0,9615	1
1000	0,1	0,2946	0,6113	0,9645	0,9645	0,9615	1
1000	1	0,3002	0,6113	0,9645	0,9645	0,9615	1
1000	10	0,2832	0,6173	0,9645	0,9645	0,9615	1
1000	100	0,2823	0,6233	0,9645	0,9645	0,9615	1
1000	1000	0,2853	0,6164	0,9645	0,9645	0,9615	1

Tabela 22: Resultados caso D2.

C	gamma	$t_{treinamento}$	$t_{classif.}$	Revocação	Precisão	F-medida	Ranking
0,001	0,001	0,4358	1,9366	0,0865	0,0865	0,1002	43
0,001	0,01	0,4289	1,9280	0,0865	0,0865	0,1002	43
0,001	0,1	0,4328	1,9206	0,0865	0,0865	0,1002	43
0,001	1	0,4338	1,9193	0,0865	0,0865	0,1002	43
0,001	10	0,4298	1,9129	0,0865	0,0865	0,1002	43
0,001	100	0,4338	1,9124	0,0865	0,0865	0,1002	43
0,001	1000	0,4338	1,9019	0,0865	0,0865	0,1002	43
0,01	0,001	0,3341	1,7832	0,1525	0,1525	0,1694	36
0,01	0,01	0,3252	1,6795	0,1525	0,1525	0,1694	36
0,01	0,1	0,3241	1,7399	0,1525	0,1525	0,1694	36
0,01	1	0,3241	1,7439	0,1525	0,1525	0,1694	36
0,01	10	0,3221	1,7324	0,1525	0,1525	0,1694	36
0,01	100	0,3211	1,7433	0,1525	0,1525	0,1694	36
0,01	1000	0,3191	1,6828	0,1525	0,1525	0,1694	36
0,1	0,001	0,1815	1,6097	0,4710	0,4710	0,4407	29
0,1	0,01	0,1835	1,6206	0,4710	0,4710	0,4407	29
0,1	0,1	0,1835	1,6197	0,4710	0,4710	0,4407	29
0,1	1	0,1835	1,6117	0,4710	0,4710	0,4407	29
0,1	10	0,1825	1,6087	0,4710	0,4710	0,4407	29
0,1	100	0,1815	1,6369	0,4710	0,4710	0,4407	29
0,1	1000	0,1815	1,6187	0,4710	0,4710	0,4407	29
1	0,001	0,1297	1,3414	0,6895	0,6895	0,6383	22
1	0,01	0,1277	1,3304	0,6895	0,6895	0,6383	22
1	0,1	0,1287	1,3245	0,6895	0,6895	0,6383	22
1	1	0,1307	1,3265	0,6895	0,6895	0,6383	22
1	10	0,1296	1,3344	0,6895	0,6895	0,6383	22
1	100	0,1307	1,3345	0,6895	0,6895	0,6383	22
1	1000	0,1306	1,3324	0,6895	0,6895	0,6383	22
10	0,001	0,1327	1,0593	0,8479	0,8479	0,8412	15
10	0,01	0,1326	1,0633	0,8479	0,8479	0,8412	15
10	0,1	0,1326	1,0677	0,8479	0,8479	0,8412	15
10	1	0,1306	1,0655	0,8479	0,8479	0,8412	15
10	10	0,1307	1,0653	0,8479	0,8479	0,8412	15
10	100	0,1297	1,0363	0,8479	0,8479	0,8412	15
10	1000	0,1386	1,0691	0,8479	0,8479	0,8412	15
100	0,001	0,2653	0,9225	0,8818	0,8818	0,8824	1
100	0,01	0,2773	1,0811	0,8818	0,8818	0,8824	1
100	0,1	0,2603	0,8926	0,8818	0,8818	0,8824	1
100	1	0,2643	0,8930	0,8818	0,8818	0,8824	1
100	10	0,2643	0,9186	0,8818	0,8818	0,8824	1
100	100	0,2633	0,9136	0,8818	0,8818	0,8824	1
100	1000	0,2633	0,8970	0,8818	0,8818	0,8824	1
1000	0,001	57,6705	0,8188	0,8792	0,8792	0,8784	8
1000	0,01	56,5497	0,8040	0,8792	0,8792	0,8784	8
1000	0,1	56,4572	0,7460	0,8792	0,8792	0,8784	8
1000	1	56,1897	0,7540	0,8792	0,8792	0,8784	8
1000	10	56,3294	0,7560	0,8792	0,8792	0,8784	8
1000	100	56,3922	0,7862	0,8792	0,8792	0,8784	8
1000	1000	56,2018	0,7510	0,8792	0,8792	0,8784	8

Tabela 23: DT – Caso E1 – resultados para a base de dados sem normalização.

$t_{treinamento}$	$t_{classif.}$	Revocação	Precisão	F-medida
0,0180	0,0070	0,9941	0,9941	0,9965

Tabela 24: DT – Caso E2 – resultados para a base de dados com normalização.

$t_{treinamento}$	$t_{classif.}$	Revocação	Precisão	F-medida
0,0180	0,0070	0,9971	0,9971	0,9983

Tabela 25: DT – Caso E3 – resultados para a base de dados com PCA.

$t_{treinamento}$	$t_{classif.}$	Revocação	Precisão	F-medida
0,0209	0,0070	0,9817	0,9817	0,9842

e no uso da transformada PCA. As comparações são feitas de acordo com os melhores resultados das métricas de desempenho do classificador e o tempo computacional de cada classificador, tanto no processo de treinamento quanto de classificação.

5.3.15.1 K-fold estratificado com 5 folds, sem PCA e sem normalização dos dados Para estes parâmetros, com o k-fold estratificado com 5 dobras (*folds*) e sem o uso do PCA na transformada dos dados e tendo os dados não normalizados, o RF (com 20 árvores) apresentou os melhores resultados, considerando os indicadores de desempenho e o tempo computacional, conforme apresenta a Tabela 26.

Tabela 26: Comparação entre os classificadores (5 folds, sem PCA e dados não normalizados).

Classificador	Parâmetros	$t_{treinamento}$	$t_{classificacao}$	Revocação	Precisão	F-medida
KNN	k=1	–	0,1995	0,9784	0,9784	0,9815
RF	árvores=20	0,1486	0,0509	0,9996	0,9996	0,9998
SVM/RBF	C=1000; gamma=0,1	1,3005	1,0891	0,9886	0,9886	0,9893
DT	–	0,0180	0,0070	0,9941	0,9941	0,9965

5.3.15.2 K-fold estratificado com 5 folds, sem PCA e sem normalização dos dados Para estes parâmetros, com o k-fold estratificado com 5 dobras (*folds*) e sem o uso do PCA na transformada dos dados e tendo os dados não normalizados, o RF (com 10 árvores) apresentou os melhores resultados, considerando os indicadores de desempenho e o tempo computacional, conforme apresenta a Tabela

27.

Tabela 27: Comparação entre os classificadores (5 folds, sem PCA e dados normalizados).

Classificador	Parâmetros	$t_{treinamento}$	$t_{classificacao}$	Revocação	Precisão	F-medida
KNN	k=1	-	0,2181	0,9945	0,9945	0,9947
RF	árvores=10	0,0778	0,0289	0,9996	0,9996	0,9998
SVM/RBF	C=1000; gamma=100	1,0153	0,4837	0,9996	0,9996	0,9998
SVM Linear	C=1000	0,2843	0,6094	0,9645	0,9645	0,9615
DT		0,0180	0,0070	0,9971	0,9971	0,9983

5.3.15.3 K-fold estratificado com 5 folds e PCA com representatividade de 99% dos dados

Para estes parâmetros, com o k-fold estratificado com 5 dobras e com o uso do PCA com representatividade de 99% nos dados, o RandomForest (com o parâmetro número de árvores = 30) apresentou os melhores resultados, considerando os indicadores de qualidade e o tempo computacional, conforme apresenta a Tabela 28.

Tudo isso foi feito com supervisão e de apenas cada classe perfeitamente separada

Tabela 28: Comparação entre os classificadores (5 folds, com PCA).

Classificador	Parâmetros	$t_{treinamento}$	$t_{classificacao}$	Revocação	Precisão	F-medida
KNN	k=1	-	0,2304	0,9927	0,9927	0,9951
RF	árvores=30	0,1705	0,0768	0,9960	0,9960	0,9960
SVM/RBF	C=100; gamma=100	1,7743	0,8119	0,9948	0,9948	0,9968
SVM Linear	C=100	0,2653	0,9225	0,8818	0,8818	0,8824
DT		0,0209	0,0070	0,9817	0,9817	0,9842

5.4 Extração de características baseadas na literatura

O objetivo da criação de uma nova base de dados neste projeto é melhorar a caracterização das cargas elétricas residenciais e consequentemente aumentar a assertividade dos algoritmos classificadores. Preliminarmente, as formas de onda de tensão e corrente das cargas foram coletadas, conforme apresentadas no capítulo 4, e os atributos foram obtidos através dos cálculos apresentados no capítulo 2. Alguns dos atributos não foram extraídos porque demandam uma metodologia diferente da

construção de um sistema de reconhecimento de cargas através de uma base de dados com atributos e amostras.

A Figura 76 apresenta o diagrama da metodologia de extração de atributos para a nova base de dados. O método é semelhante ao apresentado na subseção 5.1, tendo como principal mudança a implementação dos algoritmos responsáveis pelos cálculos dos novos atributos.

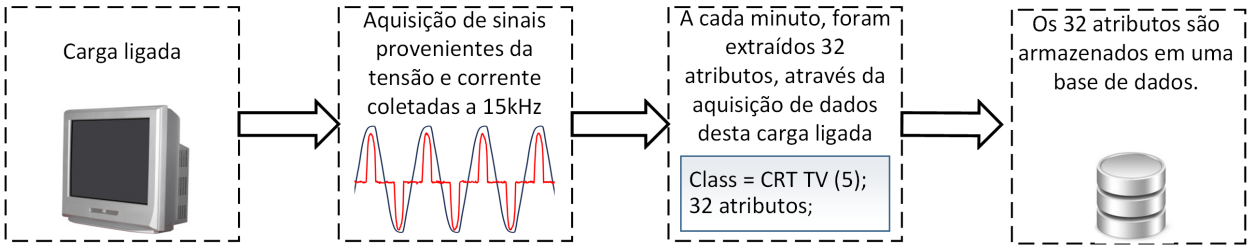

Figura 76: Diagrama de extração dos novos atributos.

Como destacado na Figura 76, foram calculados 32 atributos daqueles apresentados na Tabela 4. Tais atributos extraídos são os indicados na Tabela 29.

Complementarmente, os seguintes dados foram extraídos também como auxílio no algoritmo desagregador (máquina de estados):

- **Timestamp:** O atributo de tempo será adicionado para auxiliar na probabilidade de uso do equipamento. Por exemplo, o uso do chuveiro em uma residência tende a ser em um determinado horário do dia, o mesmo em relação ao uso de equipamentos diferentes no final de semana, também em relação aos equipamentos que tendem a serem utilizados no começo ou no final do mês, entre outros. Outro ponto que o *timestamp* pode contribuir é na criação de novas bases de dados contendo informações que independem da frequência da amostragem de sinais. Pela Tabela 4, existem as características que podem ser extraídas, havendo o detalhamento temporal. São estas características:

  - P_{MAX} **– Potência Ativa Máxima:** Durante o funcionamento da carga, armazena-se o instante de potência ativa máxima. Em conjunto com informações do instante de carga ligada ou de carga desligada, tem-se informações de tempo do ciclo de funcionamento em conjunto com a potência ativa máxima;

[3]Em condições senoindais de tensão

Tabela 29: Atributos da nova base de dados.

Atributo	Método	Descrição
A / S	Baixa e alta frequência: Teoria de Potência	Potência aparente (A na CPT e S em outras teorias de potência)
P	Baixa e alta frequência: Teoria de Potência	Potência ativa (equivalente em todas teorias de potência)
Q	Alta frequência: Teoria de Potência - CPT	Potência reativa (semelhante em outras teorias de potência)
V	Alta frequência: Teoria de Potência - CPT	Potência residual (semelhante a H em outras teorias de potência[3])
PF / λ	Baixa frequência	Fator de potência
QF / λ_Q	Alta frequência: Teoria de Potência - CPT	Fator de reatividade
VF / λ_U	Alta frequência: Teoria de Potência - CPT	Fator de não linearidade
I_f	Característica independente da frequência	Corrente inativa (valor eficaz ou quadrático médio)
I_{RMS} / I	Baixa e alta frequência	Valor eficaz da corrente
U_{RMS} / U	Baixa e alta frequência	Valor eficaz da tensão
I_1	Alta frequência	Componente harmônica fundamental (h=1) da corrente
I_3	Alta frequência	Componente harmônica de 3ª ordem (h=3) da corrente
I_5	Alta frequência	Componente harmônica de 5ª ordem (h=5) da corrente
I_7	Alta frequência	Componente harmônica de 7ª ordem (h=7) da corrente
I_9	Alta frequência	Componente harmônica de 9ª ordem (h=9) da corrente
I_{11}	Alta frequência	Componente harmônica de 11ª ordem (h=11) da corrente
I_{13}	Alta frequência	Componente harmônica de 13ª ordem (h=13) da corrente
I_{15}	Alta frequência	Componente harmônica de 15ª ordem (h=15) da corrente
I_{17}	Alta frequência	Componente harmônica de 17ª ordem (h=17) da corrente
I_{19}	Alta frequência	Componente harmônica de 19ª ordem (h=19) da corrente
DHT_I	Alta frequência	Distorção harmônica total de corrente (semelhante a H_f)
U_1	Alta frequência	Componente harmônica fundamental (h=1) da tensão
U_3	Alta frequência	Componente harmônica de 3ª ordem (h=3) da tensão
U_5	Alta frequência	Componente harmônica de 5ª ordem (h=5) da tensão
U_7	Alta frequência	Componente harmônica de 7ª ordem (h=7) da tensão
U_9	Alta frequência	Componente harmônica de 9ª ordem (h=9) da tensão
U_{11}	Alta frequência	Componente harmônica de 11ª ordem (h=11) da tensão
U_{13}	Alta frequência	Componente harmônica de 13ª ordem (h=13) da tensão
U_{15}	Alta frequência	Componente harmônica de 15ª ordem (h=15) da tensão
U_{17}	Alta frequência	Componente harmônica de 17ª ordem (h=17) da tensão
U_{19}	Alta frequência	Componente harmônica de 19ª ordem (h=19) da tensão
DHT_U	Alta frequência	Distorção harmônica total de tensão

– $T_{MIN_{ON}}$ **– Tempo mínimo da carga ligada e** $T_{MIN_{OFF}}$ **– Tempo mínimo da carga desligada:** Tais informações podem ser coletadas através da extração do tempo;

– W_{coef} **– Coeficientes extraídos das wavelets:** a extração de coeficientes de *wavelets* ne-

cessitam da análise temporal de eventos microscópicos provenientes da forma de onda da corrente da carga e é criado um histograma comportamental temporal das *wavelets*, portanto o tempo é um fator influente para esta extração de características;

- VI_{traj} **– Trajetória da tensão x corrente:** Dados de tempo são importantes para construir a análise comportamental da trajetória tensão x corrente;
- P_{carga}^{ON} **– Probabilidade da carga estar ligada e** P_{carga}^{OFF} **– Probabilidade da carga estar desligada:** Para que se levante informações probabilísticas, é necessária a coleta com a observação temporal das cargas e uma análise com grau de segurança com que se pode esperar a realização de um evento de cargas ligadas ou desligadas, determinado pela frequência relativa dos eventos do mesmo tipo numa série de tentativas e de levantamentos de dados em uma determinada residência;

- **Temperatura:** A temperatura é um dado que pode auxiliar na questão de hipóteses de uso de um determinado equipamento elétrico nas quais tem relação com a temperatura, como ar condicionado, ventilador (condições de conforto) ou geladeira, freezer (em relação a quantidade de ciclos de controle de temperatura). A coleta da temperatura auxiliará também em trabalhos correlatos referentes à eficiência energética e no uso eficiente de cargas, com base no conforto térmico e no conjunto com outros objetos e percepções humanas, como limiar de calor, deixar a janela aberta ou abrir a persiana. Outro ponto que a temperatura pode ajudar se refere à troca de partes de eletrodomésticos, como a borracha da geladeira caso haja a percepção de temperatura externa (coletada pelo medidor) e perda de temperatura interna da geladeira (inferidas pelos ciclos de funcionamento do sistema de resfriamento do refrigerador);

- **Geolocalização:** A geolocalização pode auxiliar na desagregação de cargas ao descrever em quais regiões ou países os equipamentos tendem a ser mais utilizados. A Figura 77 apresenta um exemplo de curva de carga (consumo médio de equipamentos elétricos residenciais por região) de acordo com o recenseamento de 2005, realizado do Sinpha (Sistema de Informações de Posses de Eletrodomésticos e Hábitos de Consumo) [100], órgão de coleta de dados da Procel Info (Centro Brasileiro de Informação de Eficiência Energética), da ANEEL (Agência Nacional de Energia Elétrica).

  Por exemplo, observando a Figura 77, tem-se que o chuveiro elétrico na posição de aquecimento é pouco utilizado na região norte, bem como a iluminação durante o dia na região sul é pouco

utilizada. Também pode-se inferir a probabilidade baixa do uso do chuveiro na região Sul entre 10:00 até as 17:00 ou a probabilidade baixa do uso da TV entre 01:00 até as 07:00 em todas as regiões.

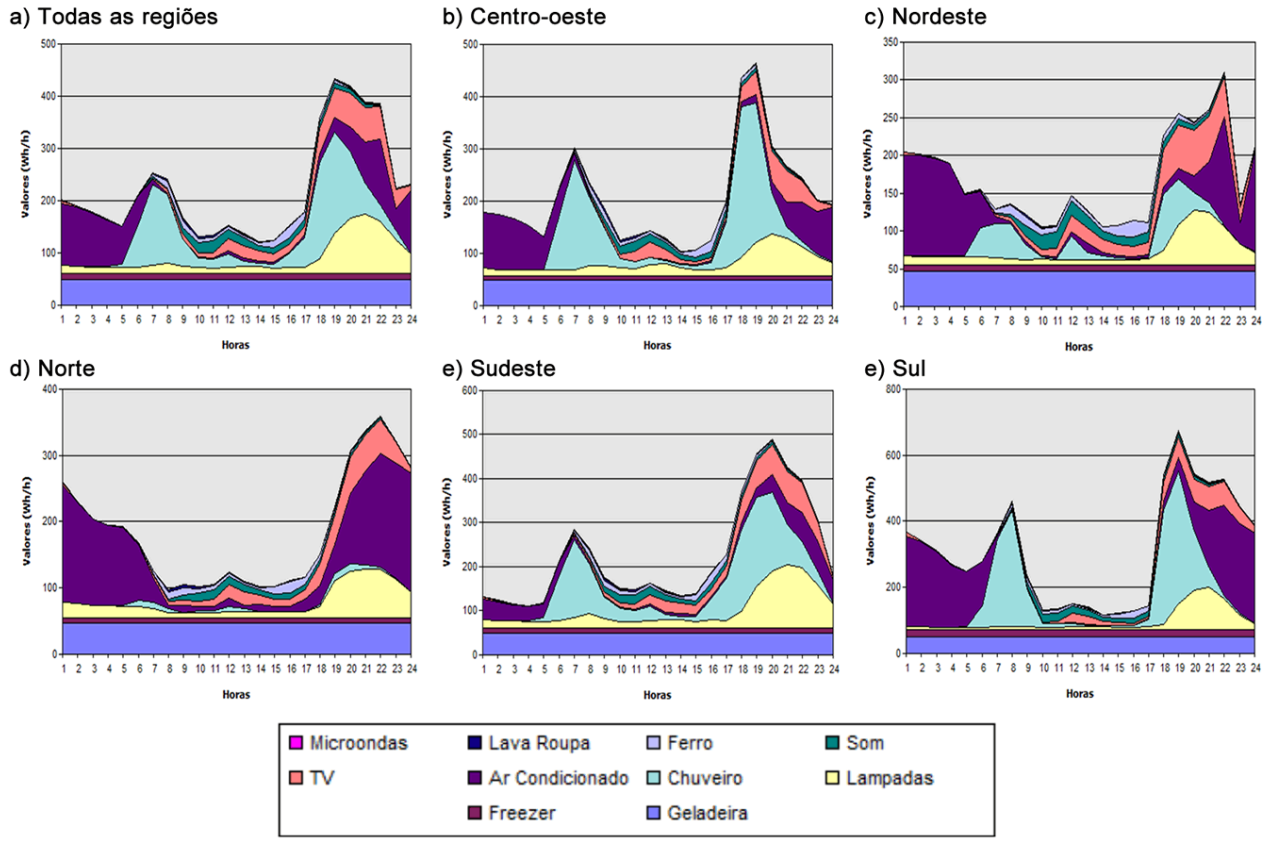

Figura 77: Perfis de consumo de cargas por regiões.

Os dados de *timestamp*, temperatura e geolocalização não foram utilizados nesta etapa, como atributos extraídos da aquisição das formas de onda da tensão e corrente durante o funcionamento das cargas e para construção da nova base de dados.

Quanto a base de dados desta subseção, todos os atributos são quantitativos racionais. O atributo Classe é qualitativo nominal e representa as cargas que foram coletadas as formas de onda de tensão e corrente. Portanto, a base de dados serve para o problema de aprendizado supervisionado, de classificação.

Toda a análise feita neste capítulo determina o conjunto de dados utilizado no momento da classificação de cargas. Junto a este conceito, tem-se a detecção de eventos, que indica o momento no qual

o classificador deve ser disparado para reconhecer a carga que está ligada ou que foi desligada. Tal método será apresentado na seção a seguir.

6 Detecção de eventos

Devido a participação significativa no consumo de energia elétrica, tanto residencial como comercial, o monitoramento de equipamentos (do inglês, ALM – Appliance Load Monitoring) tornou-se essencial para entender os hábitos de consumo, bem como para reduzir gastos com energia elétrica [101].

O monitoramento de cargas pode, de modo geral, ser categorizado em duas abordagens. A primeira é dita intrusiva, sendo denominada monitoramento intrusivo de cargas (do inglês, ILM – Intrusive Load Monitoring). A segunda é caracterizada por não ser intrusiva e é chamada de monitoramento não intrusivo de cargas (do inglês, NILM – Non-intrusive Load Monitoring) [10, 11].

6.1 Assinatura de potência

A assinatura de potência de um equipamento representa um conjunto de amostras de potência elétrica armazenadas ao longo do tempo. Embora simples, essas assinaturas carregam informação importante para os algoritmos de classificação, pois cada equipamento possui uma assinatura de potência única [79].

De modo geral, as cargas podem ser categorizadas conforme sua dinâmica de operação [11]:

- ON/OFF - dois estados conhecidos;
- Variável - múltiplos estados com padrões e repetições conhecidas;
- Operação contínua e comportamento variável - sem padrão fixo;
- Operação contínua e comportamento permanente - ativos constantemente e por um longo tempo.

Uma das características que podem ser observadas em uma assinatura de potência é a questão da periodicidade. Nesse cenário, transições de estados entre ligado e desligado ocorrem de maneira periódica. Exemplo disso é a operação de geladeiras e freezers. Além disso, alguns equipamentos podem apresentar outros estados antes de entrar no modo de operação supracitado. São exemplos disso os equipamentos condicionadores de ar, e outros que geralmente utilizam termostatos. Nesses equipamentos ocorre um estágio de preparo que é caracterizado por possuir consumo constante. Os

equipamentos já destacados também podem apresentar spikes (pulso rápido de alta tensão), sendo causado pela indução gerada por motores. Outra característica relacionada a indução é chamada de variância e representa uma flutuação da potência em torno da potência média consumida. Além disso, quando ativadas essas cargas indutivas podem apresentar picos de potência durante poucos segundos. Essas inclinações (slope) são características na operação de condicionadores de ar [79].

6.2 Categorização das técnicas de monitoramento

Como dito anteriormente o monitoramento de carga tem duas abordagens principais. Em síntese, essas duas técnicas diferenciam-se em dois pontos específicos: Exatidão e Praticidade. Isto é, as técnicas ILM apresentam boa exatidão sobre o consumo individual de cada carga, enquanto as técnicas NILM conseguem realizar uma aproximação desse valor de consumo. A questão da praticidade está relacionada com a forma de obter as informações que possibilitam determinar os valores de consumo. Nesse sentido, as técnicas ILM necessitam de mais instrumentos para que cada carga seja monitorada, enquanto as técnicas NILM necessitam de apenas um. Além da praticidade, pode-se também citar o custo de implementação dessas técnicas, sendo a ILM mais dispendiosa devido à quantidade de elementos utilizados [11].

6.2.1 Abordagem intrusiva ou distribuída - ILM

O ILM pode medir o consumo de uma ou mais cargas. De modo geral, é utilizado um elemento de medição próximo aos equipamentos de que se deseja monitorar. Alguns tipos de medição intrusiva são destacados a seguir [101]:

- Monitoramento de zonas de uma residência/instalação;
- Equipamentos conectados em tomadas (plug) – é dito direto, pois abrange somente os equipamentos conectados no ponto de medição;
- Monitor de consumo embarcado ou diretamente conectado no equipamento.

Por apresentar mais de um ponto de medição, esse método também pode ser chamado de multisensor, ou abordagem distribuída. Pode ser utilizado para analisar o comportamento e o consumo de um

equipamento específico, compreender e caracterizar o consumo global de uma instalação, reconhecer e aprender hábitos de consumo, localização de cargas, entre outros. Além disso, pode ser utilizado para gerar ambientes de simulação e validação de técnicas NILM [101].

6.2.2 Abordagem não intrusiva ou concentrada - NILM

Atualmente, a técnica NILM tem recebido atenção especial, principalmente pela praticidade [11]. Essa técnica foi apresentada por Hart, em 1992. Em síntese, tal técnica propõe que a partir da análise detalhada das formas de onda das tensões e correntes é possível de estimar a quantidade e o tipo das cargas presentes, bem como o consumo individual das mesmas [11]. Isso é ilustrado na Figura 78.

Figura 78: Identificação de equipamentos a partir da análise de eventos — variação de consumo [11].

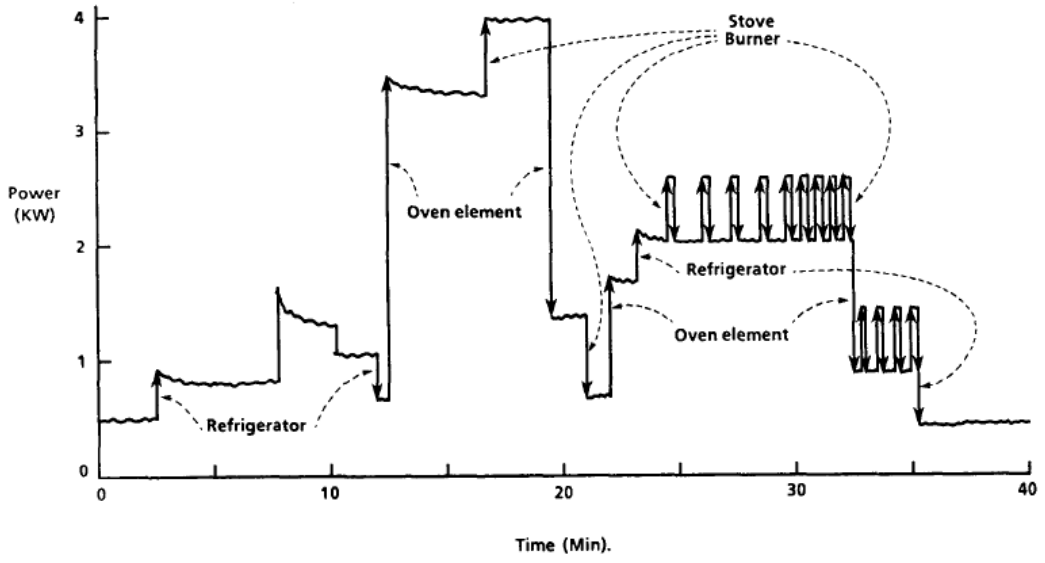

De modo geral, o NILM pode ser caracterizado por 6 estágios de execução. No primeiro estágio os valores de tensão e corrente são amostrados. Em seguida esses dados são processados e preparados para análise. Essa análise envolve a detecção de eventos na assinatura de potência, por exemplo, transição de estados. Com a assinatura de potência e a identificação de eventos é executado um algoritmo para extrair informações que permitam identificar a carga. Por fim, ocorre a execução de um algoritmo para classificação da carga e estimação do consumo individual para cada carga identificada. Isso é ilustrado na Figura 79.

Nesse contexto, os estudos atuais têm como objetivo principal a elaboração de métodos que possibilitem monitorar grande quantidade de cargas e que aumentem a exatidão das aferições [11, 18].

Figura 79: Etapas do método NILM.

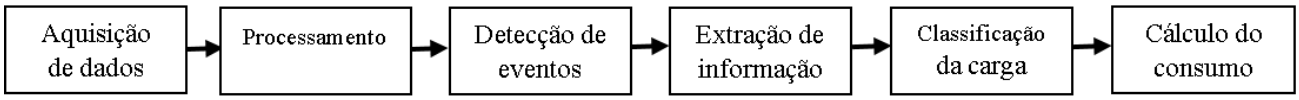

Nos capítulos anteriores deste relatório, tem-se as partes referentes à **aquisição de dados**, **processamento**, **extração de informação (atributos)** e **classificação da carga**. Esta seção apresenta a fase de **detecção de eventos**. Por utilizar somente um ponto de medição, o método NILM apresenta as assinaturas de potência sobrepostas, isto é, compreende o consumo total de todos equipamentos. Por isso, é necessário utilizar técnicas que permitam desagregar o consumo de energia elétrica. Em outras palavras, tais métodos são necessários para identificar o consumo individual para cada equipamento [101].

Diferentes métodos de identificação não intrusiva são apresentados na literatura. De modo geral, os métodos mais tradicionais envolvem a análise de transitórios e acompanhamento de estados. Outras abordagens propõe a modelagem da operação de cada carga [18]. Cabe ainda destacar que a abordagem NILM apresenta algumas deficiências, principalmente para detectar cargas em stand-by ou que apresentam comportamento com diversos estados [101].

6.3 Base de dados baseado em atributos de alta frequência

Em Souza [18] algumas técnicas de aprendizado de máquina para a desagregação de cargas foram analisadas e foi apresentada a factibilidade da implementação em dispositivos medidores que permitem a desagregação de cargas. Entre os algoritmos de classificação apresentados, dois apresentaram os melhores resultados: Optimum-Path Forest (OPF) e K-Nearest Neighbor (K-NN). O 1NN (KNN com grau de vizinhança equivalente a 1) foi o escolhido por possui baixo custo computacional e apresentar o melhor resultado dentre os classificadores analisados. A tensão e corrente de diversos eletrodomésticos foram coletados e tais sinais foram decompostos em parcelas de potência provenientes de cálculos da CPT [33]. Neste caso, a CPT permite separar a potência em componentes ativa, reativa, de desbalanço e de parcelas residuais. Essas parcelas ajudam a interpretar o comportamento da carga como um circuito equivalente, como apresentado na Figura 80, no qual vm é a tensão de fase, a corrente i_{Af} coincide com a corrente ativa, i_{Rf} coincide com a corrente reativa e j coincide com a corrente

residual. G_f é a condutância equivalente de fase e pode ser representado como uma resistência, L_m é a indutância equivalente de fase e pode ser representada como um indutor. Toda a base matemática para este circuito equivalente pela CPT pode ser encontrada em [33].

Figura 80: Circuito equivalente pela CPT.

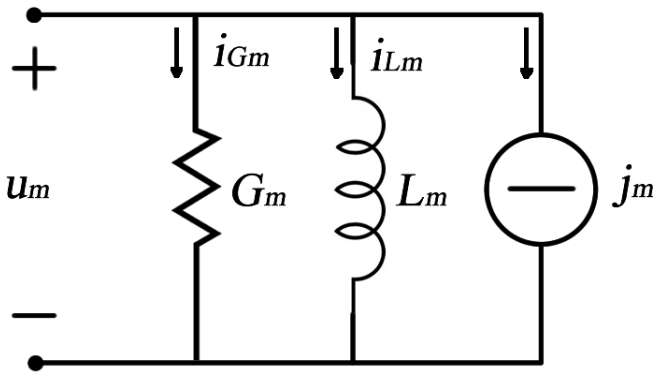

Usando a decomposição da potência pela CPT, Souza et al. [24] criou uma base de dados com diversos equipamentos, entre eles ferro de passar, micro-ondas, refrigeradores, máquinas de lavar, entre outros. Cada atributo (Potência ativa, fator de potência, fator de reatividade e fator de não linearidade). Posteriormente, através de algoritmos de reconhecimento de padrões, tem-se a identificaçõ de cargas. Porém, é necessária a identificação no momento em que existir um evento, ou seja, quando alguma carga for ligada ou desligada. Em outros termos, este é o conceito de assinatura de cargas, e ele possui grande relevância por auxiliar na identificação de cargas, sobretudo em condições com mais de uma carga ligada ou para equipamentos que não operam em regime permanente. A seção a seguir apresenta o método proposto para a detecção de eventos.

6.4 Assinatura de potência das cargas

Como inicialmente indicado por Hart [11], cada carga possui uma determina assinatura de potência, que não necessariamente seja em valor constante de potência (regime permanente). A Figura 81 apresenta os diferentes comportamentos de potência das cargas, e que isso permite que sejam feitas as categorizações delas [10, 11, 16, 18, 60].

Pela Figura 81, uma carga pode possuir assinatura de potência com:

a) **Constante**: Neste caso, durante o tempo de funcionamento da carga, a potência se apresentou

Figura 81: Diferentes tipos de assinatura de potência das cargas. (a) Comportamento constante; (b) Múltiplos estágios; (c) Constante; (d) Pequena variação linear; (e) Vários estágios de operações; and (f) Comportamento de difícil detecção.

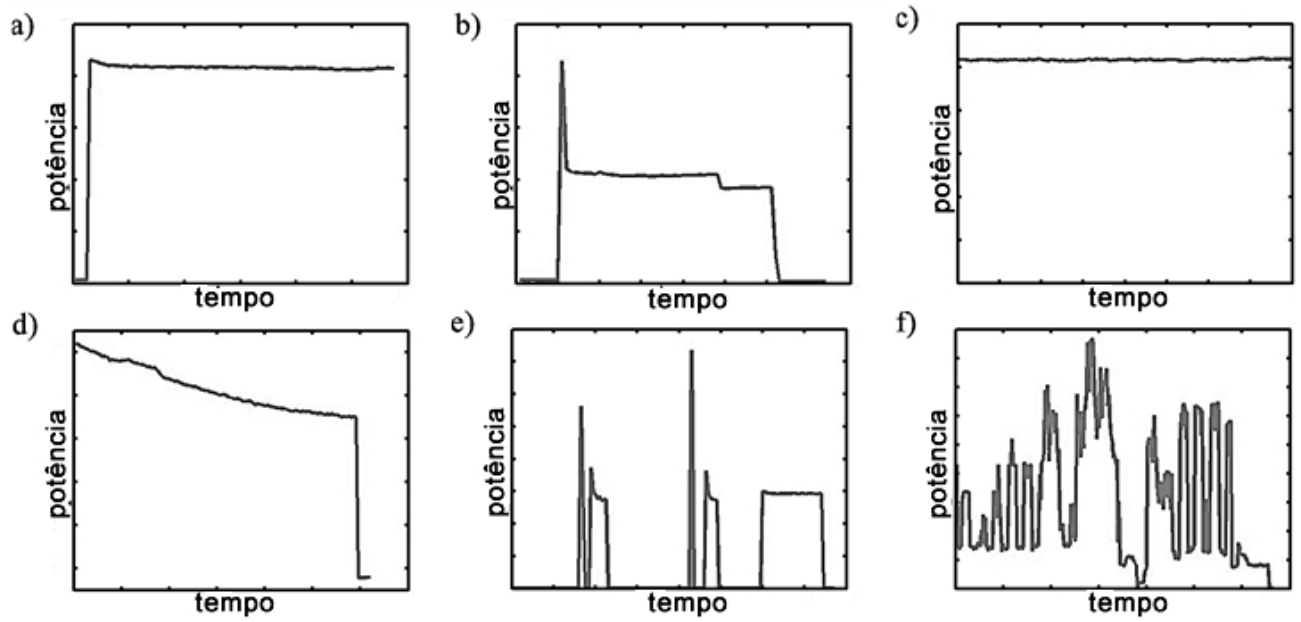

constante no tempo. Tal característica pode corresponder a uma carga puramente resistiva ou a algum equipamento que funcione em regime permanente e constante de potência;

b) **Múltiplos estágios**: A carga possui um estágio inicial com um pico de potência e depois estabiliza. Também pode apresentar diversos comportamentos de potências (com ou sem transitórios) sem existir necessariamente o desligamento do equipamento. Esta particularidade tem grande possibilidade de ser uma carga com um motor elétrico;

c) **Sempre constante**: Este comportamento representa as cargas que estão em modo de espera (stand-by). Alguns aparelhos são colocados no modo de espera pela comodidade (como televisores, aparelhos de DVD, rádios e outros – que possuam controle remoto) e o montante de consumo no final do mês também deve ser considerado;

d) **Aproximadamente linear**: É característica de uma carga com variação linear de potência e pode ser agrupada em equipamentos com gradadores ou que apresente uma fase de desligamento suavizada. Um exemplo dessa classe é uma lâmpada incandescente com controle eletrônico dimmer;

e) **Vários estágios de operação**: Alguns equipamentos possuem diversas fases de operação, podendo

ou não ter períodos no qual não está se consumindo energia. Neste grupo tem-se, por exemplo, lavadoras de roupa com diversos estágios, como lavagem, enxague, centrífuga, aquecimento de água e outros.

f) **Cargas com diversos estágios de operação e de difícil detecção**: Esta característica é de difícil reconhecimento por existirem diversos valores de potência no tempo, com cargas sendo ligadas e desligadas com variações rápidas. Um bom exemplo de carga nesta categoria é uma impressora, que apresenta diversos estágios de potência.

Desta forma, entre as diversas cargas existentes no contexto residencial, tem-se o agrupamento nestas seis categorias de assinatura de potência. Em Souza [18], tem-se a categorização das 35 cargas em estudo conforme apresentada na Tabela 30. A etapa correspondente ao detector de eventos é apresentada na seção a seguir.

6.5 A técnica PSB

A base de dados criada e estudada nas seções anteriores ajuda para detectar a carga após a análise das formas de onda de tensão e corrente, mas isso pode ser um problema, sobretudo quando existe mais de uma carga que pode ser ligada simultaneamente – cenário comum em uma residência. Neste caso, com o intuito de decompor o consumo por cargas de forma individual, é necessário saber quantas cargas estão ligadas e identificar os momentos corretos em que elas foram ligadas e desligadas, bem como fornecer meios que permitam o reconhecimento da carga de forma precisa.

Desta forma, é proposto um algoritmo baseado em máquina de estados que leva em consideração o valor médio de cada bloco associado com a classe identificada. Os blocos que possuem mais de um aparelho ligado devem utilizar o valor médio histórico de cada um deles. Este procedimento é chamado de desagregação por blocos, neste caso PSB – Power Signature Blob. O algoritmo de identificação de carga utiliza atributos de classificação extraídos da diferença entre dois cenários: antes e depois que um aparelho é ligado. Assim, o passo é apenas um divisor entre estados estáveis. Isso garante que os classificadores representem os aparelhos em conjunto, mitigando o ruído gerado no estado transitório.

Ao subtrair as formas de onda destes passos cria-se uma aproximação da forma de onda de carga. Em seguida, o algoritmo CPT gera os atributos através do processamento das formas de onda de

Tabela 30: Assinatura de potências das cargas em estudo.

ID	Carga	Tipo de evento
1	Lâmpada incandescente	A
2	Ar condicionado	B
3	Refrigerador	E
4	Micro-ondas	B
5	TV CRT	A
6	TV LCD	A
7	TV de Plasma	A
8	Chuveiro Elétrico	A
9	Carga RL 1	A
10	Carga não linear 1	A
11	Carga não linear 2	A
12	Carga RL 2	A
13	Ferro de passar	D
14	Máquina de lavar roupas	B
15	Secador de cabelos	B
16	Lâmpada fluorescente	D
17	Lâmpada mista	D
18	Lâmpada de mercúrio	D
19	Lâmpada de sódio	D
20	Secadora de roupas regulável	E
21	Refrigerador regulável	E
22	Liquidificador	B
23	Fazedor de pães	A
24	Computador pessoal	E
25	Lâmpada compacta	A
26	Processador de alimentos	B
27	Freezer	E
28	Forno elétrico	A
29	Portão de garagem	A/E
30	Laptop	E
31	Monitor LCD	A
32	Secadora de roupas	B
33	Refrigerador regular	E
34	Aspirador de pó	E
35	Máquina de lavar roupas	B

tensão e corrente. Adotando essa abordagem, quatro atributos são calculados: potência ativa, fator de potência, fator de potência, fator reativo e fator de não-linearidade. Usando esses elementos como atributos em um espaço tetradimensional, cada carga resultará em um bloco. Portanto, os algoritmos de classificação, como o KNN, podem ser usados para definir as fronteiras de cada carga no espaço de reconhecimento.

O diagrama da Figura 82 mostra o algoritmo Estado-máquina com o conjunto de dados de desagregação do aparelho a partir de Souza [18]. Pode-se observar a existência de assinaturas de potência do aparelho, que filtram e podem tornar a desagregação do aparelho mais precisa. Além disso, a metodologia possui algoritmos para manipulação dos eventos ON e OFF, apresentados nos diagramas da Figura 83 e Figura 84. A metodologia armazena os quinze ciclos anteriores (0,25 s de amostras totais) de formas de onda de tensão e corrente para detectar os eventos do aparelho se houver dois ou mais aparelhos ligados.

Figura 82: Estado de máquinas - PSB.

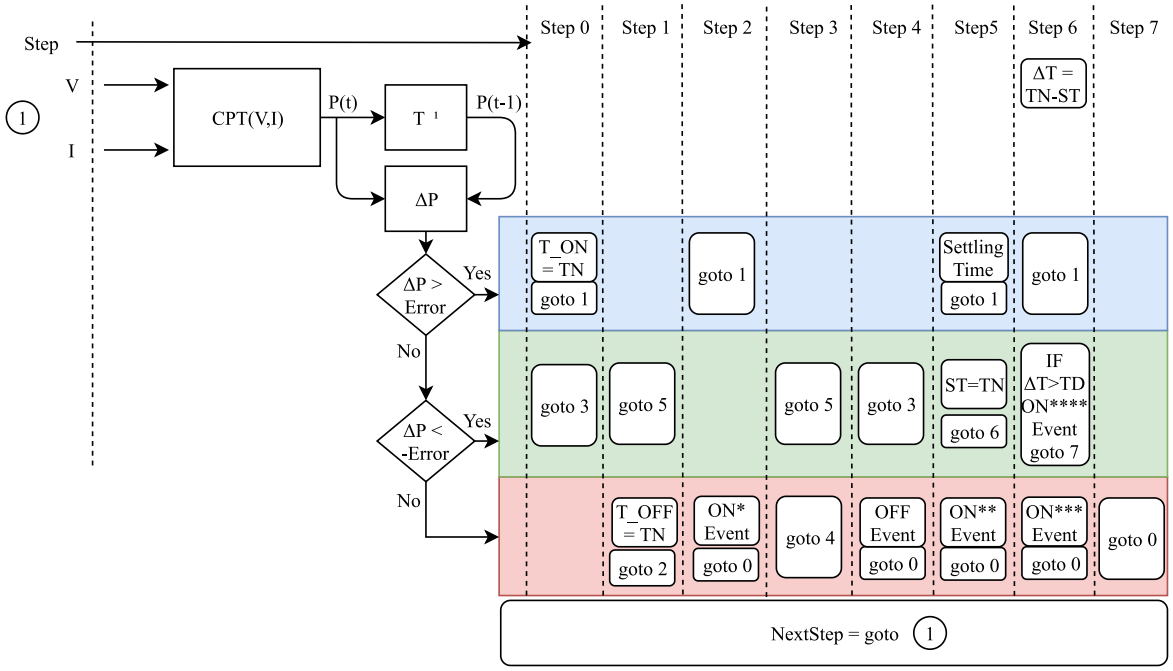

Figura 83: PSB – diagrama do evento de carga ligada.

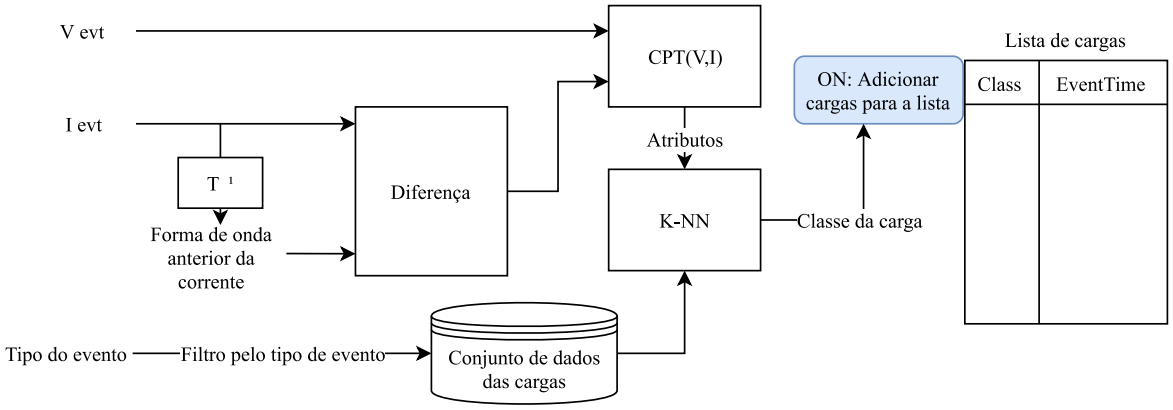

A subseção a seguir apresenta alguns resultados de validação e integração dos métodos de detecção

Figura 84: PSB – diagrama do evento de carga desligada.

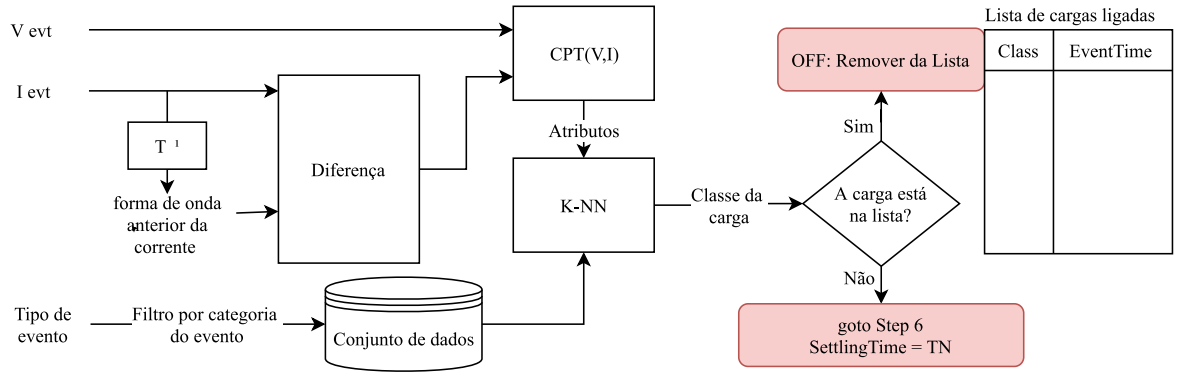

de eventos com o classificador.

6.6 Validation Results

Neste trabalho, a avaliação do PSB foi baseada em simulações e resultados experimentais, conforme descrito nas próximas subseções.

6.6.1 Resultados por simulação

A Tabela 31 apresenta a programação diária do aparelho para a simulação de acordo com o comportamento do usuário na residência.

Tabela 31: Estudo de caso para validação do PSB.

Carga	Horário em que foi ligada	Tempo total de operação
Chuveiro elétrico	07:15 e 19:40	00:20 e 00:15
Ar condicionado	22:00	08:00
TV de tubo	12:15 e 18:15	01:00 e 05:00
Refrigerador	Durante todo o dia	00:30 cada ciclo
Ferro de passar roupas	18:30	00:15
Lâmpada incandescente 100W	18:30	05:30
Lâmpada incandescente 60W	19:00	04:30
Notebook	19:00	04:00
Micro-ondas	07:45	00:05
Máquina de lavar roupas	13:00 (Sábados)	02:00

Assim, foi criado um modelo de circuito elétrico no software PSIM para simular o comportamento de potência de uma residência durante um dia inteiro, ligando cada aparelho de acordo com o tempo de execução programado da Tabela 31.

A simulação coleta 256 amostras por ciclo das formas de onda de corrente e tensão e as envia para um bloco da Dynamic Link Library (DLL). O bloco geral de DLL no PSIM permite aos usuários escrever códigos em C ou C++, compilá-los como uma DLL do Windows e vinculá-los ao PSIM usando os recursos de entrada (do PSIM) e saída (retornando ao PSIM). Ao contrário dos blocos DLL simples com um número fixo de entradas e saídas, o bloco DLL geral fornece mais flexibilidade e capacidade na interface PSIM com arquivos DLL personalizados. Neste trabalho, os códigos DLL foram utilizados para implementar o CPT, o KNN e a máquina de estado NILM, de acordo com os algoritmos da Figura 82, Figura 83 e Figura 84. A máquina de estado da Figura 82 é uma malha responsável pela decisão do evento quando há mudança no consumo de energia. Se houver mudança de potência, a máquina de estado flui em etapas até detectar o evento de potência e acionar o "evento ON"(Figura 83) ou o "evento OFF"(Figura 84). Se for detectado um "evento ON", o sistema executa o algoritmo Figura 83 responsável pela classificação do aparelho. Depois disso, o algoritmo adiciona o aparelho à lista de aparelhos ligados e salva o status da forma de onda para comparações futuras quando um novo evento é acionado. Se for detectado um "evento OFF", o sistema executa o algoritmo Figura 84 que é responsável por classificar a solução e remover a solução da lista de soluções ativadas e salva o status da forma de onda para comparação quando um novo evento é acionado.

Simultaneamente, o PSB cuida de quatro outras características:

- Uma base de dados recebe o consumo de energia atual em kWh a cada minuto;
- Em cada evento de ativação da aparelhagem, o sistema faz o reconhecimento do padrão e envia todas as informações de potência da aparelhagem para a base de dados e, em seguida, inicia o funcionamento do tempo da aparelhagem detectada;
- Em cada evento de desligamento, o sistema reconhece a aparelhagem que foi desligada e atualiza a base de dados, armazenando a informação desde o momento em que a carga foi desligada;
- Se houver mudanças de energia, o sistema verifica a assinatura de energia de cada aparelho que está ligado e reconhece-a como uma mudança de nível de energia do aparelho.

A Figura 85 apresenta os resultados da simulação. A máquina de estado com o algoritmo classificador aceitou todas as cargas de acordo com a Tabela 31. A Figura 85 mostra a decomposição da

Figura 85: PSB – Consumo diário de energia elétrica por eletrodomésticos. (a) Comportamento da desagregação da carga na simulação; (b) Comportamento dos componentes de potência do CPT na simulação.

potência do CPT e, consequentemente, os momentos em que o algoritmo realizou a identificação do aparelho (eventos ligar e desligar).

A Figura 86 mostra um exemplo da operação do PSB entre 09:27 e 10:03 da Figura 8. Neste intervalo, há o funcionamento de uma geladeira, conforme a programação da Tabela 3. Seguindo os algoritmos da Figura 82, Figura 83 e Figura 84, a máquina de estados tem o seguinte comportamento:

09:27 to 09:30: Potência ativa está estável, nada a ser feito neste instante;

09:30: (ΔP>Error); TON=TN, goto 1;

09:30: (ΔP>Error); // aguardando pela estabilização da potência;

09:31: (ΔP>Error); // aguardando pela estabilização da potência;

09:31: (ΔP>Error); // aguardando pela estabilização da potência;

09:32: (ΔP<-Error); goto 5;

09:32: (ΔP<Error) and (ΔP>-Error); ON** Evento;

- Extração dos atributos pela CPT;

- Classificador KNN;

- Reconhecimento de carga;

- Carga reconhecida adicionada na lista de cargas ligadas;

- goto 0;

09:32 to 10:00: Potência ativa está estável, nada a ser feito neste instante;

10:00: (ΔP<-Error); TOFF=TN; goto 3;

10:01: (ΔP<Error) and (ΔP>-Error); goto 4;

10:02: (ΔP<Error) and (ΔP>-Error); OFF evento;

- Cálculo da diferença da forma de onda;

- Extração de atributos pela CPT;

- Classificador KNN;

- Reconhecimento de carga;

- Carga reconhecida removida na lista de cargas ligadas;

- goto 0;

10:02 to 10:03: Potência ativa está estável, nada a ser feito neste instante;

Portanto, o PSB funcionou como esperado e não houve erro no processo de desagregação nas simulações. Neste estudo, não houve erro porque é utilizado um conjunto de dados do aparelho com alta precisão e as cargas simuladas operam em estado estacionário. No entanto, a seção a seguir apresentará casos reais de aparelhos, incluindo variações de potência.

6.6.2 Resultados experimentais com electrodomésticos

O PSB opera em loop a 15.360 amostras por segundo. Então, um procedimento de quatro passos rastreia as variações rápidas de potência. Cada etapa atualiza a média da potência ativa avaliada com o último bloco de amostras: 0,25 segundos das amostras totais.

Figura 86: PSB – Detalhe do consumo e comportamento do algoritmo PSB entre 09:27 e 10:03. (a) Desagregação de cargas; (b) Potência ativa.

Portanto, um nível de limiar predefinido compara a variação da potência ativa durante o tempo. Em seguida, o procedimento utiliza a diferença entre a potência ativa média atual e a última utilizada para definir a direção do estado: quando existe o estágio "ligado" ou "desligado" do aparelho. A Figura 87 mostra o comportamento dos algoritmos da Figuras 82, 83 e 84 deste experimento.

Figura 87: PSB – Estudo de caso para validação do algoritmo PSB.

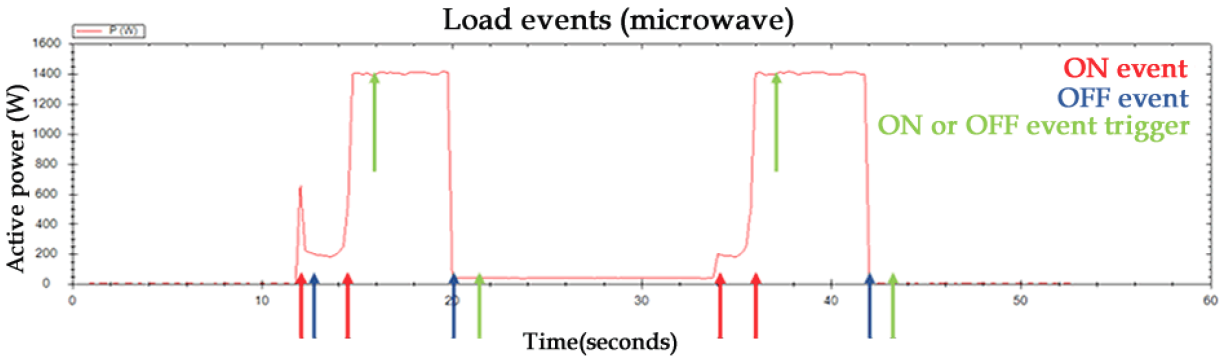

Nos eventos de gatilho – das Figuras 83 e 84 – o algoritmo armazena as formas de onda de corrente e tensão dos últimos 0,25 s, extrai a corrente a ser considerada no evento e calcula os quatro elementos que representam o aparelho: potência ativa, fator de potência, fator reativo e fator de não-linearidade.

Com estes elementos (atributos), o algoritmo utiliza o algoritmo classificador (o KNN) por meio do conjunto de dados de conhecimento de [18]. O classificador retorna a classe do aparelho, ou seja, o algoritmo prevê qual aparelho está ligado (algoritmo da Figura 83) ou desligado (algoritmo da Figura 84). Se for um "evento ON", o aparelho reconhecido é adicionado à lista de aparelhos. Se for um "evento OFF", o aparelho reconhecido é removido da lista de aparelhos. Em seguida, o sistema armazena os quinze ciclos de forma de onda do estado a utilizar num novo disparo de evento. Ao longo do tempo, os aparelhos podem ser identificados, como mostrado na Figura 88.

Figura 88: PSB – Estudo de caso para validação do algoritmo PSB.

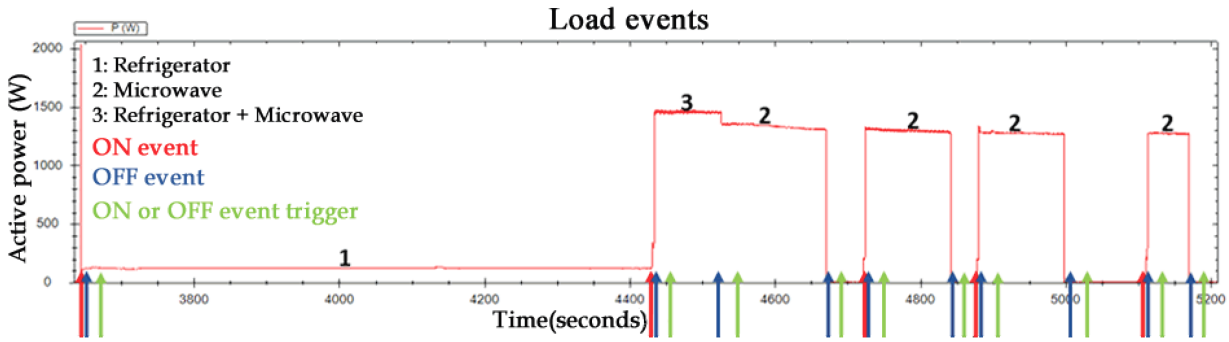

Considerando esses experimentos, o PSB atingiu 95% de precisão. O principal problema encontrado no método corresponde às cargas com várias mudanças de potência sem a existência de um instante de zero potência (ou seja, um evento de desligamento real). A Figura 89 mostra um exemplo de um aparelho de ar condicionado com um driver de velocidade ajustável (ASD). Neste caso, o método de desagregação da carga realiza a identificação da carga no gatilho do evento ON e, no decorrer da operação, a potência muda sem a ativação de um novo gatilho. Quando o dispositivo é desligado, o nível de potência é diferente do início da operação e o classificador pode identificar incorretamente o aparelho desligado. Se houver mais de um aparelho ligado, o algoritmo pode remover o equipamento errado da lista. Se houver apenas um aparelho, o algoritmo esvazia a lista.

Para resolver este problema, o conjunto de dados do aparelho deve ter uma vasta gama de tempos de medição do aparelho e as formas de onda devem considerar o último estado (no trigger de evento OFF). O algoritmo da Figura 82 também pode ser adaptado para melhorar a precisão em tais situações.

Figura 89: PSB – Estudo de caso do ar condicionado.

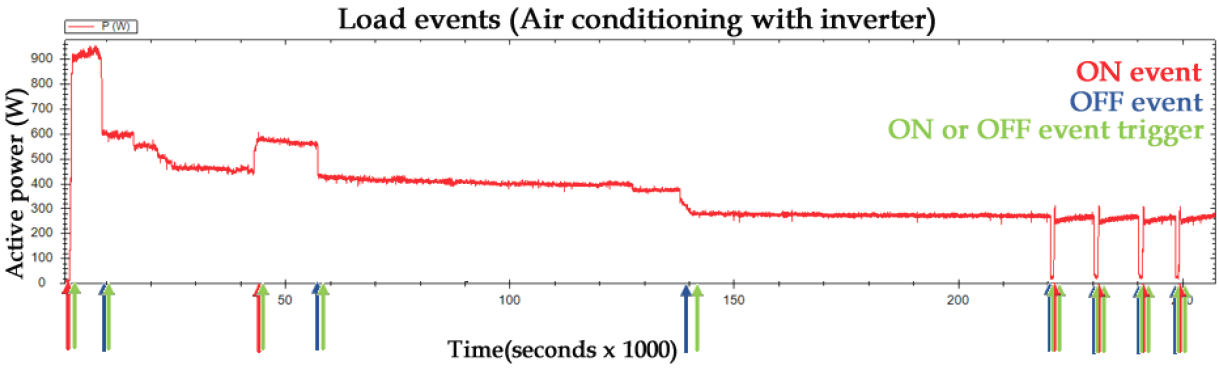

6.7 Considerações sobre a proposta

Esta seção apresentou o novo algoritmo baseado em estado de máquina para a detecção de eventos para a desagregação de cargas. Tal algoritmo permite com que sejam identificadas mais de uma carga, em condições de regime permanente ou em outros comportamentos de potência. Em conjunto com a extração de atributos e a qualidade dos atributos, tem-se o conjunto de desagregação de cargas para sistemas não intrusivos (NILM).

A próxima seção apresenta futuros trabalhos como prosseguimento deste projeto.

7 Trabalhos futuros

Os sistemas de energia elétrica estão passando por profundas modificações em razão da aplicação de novas tecnologias, modelos de negócios e revisões regulatórias. No contexto dos sistemas de distribuição, um dos principais vetores dessas modificações são os medidores inteligentes, os quais integram a medição eletrônica com uma rede de comunicação. De fato, a infraestrutura resultante dessa integração correspondente à "medição-comunicação" é denominada *AMI*, a qual consiste na instalação de medição eletrônica e dispositivos de comunicação nas unidades consumidoras, possibilitando um canal direto de comunicação entre os centros de medição das empresas de energia e o consumidor. Isto permite o conhecimento em tempo real de informações básicas, como a ausência de energia em um certo ponto de conexão, ou a tarifação por horário de uso no consumo, além de viabilizar que o consumidor também forneça energia ao sistema, através da instalação de sistemas de microgeração distribuída de energia.

Os sistemas AMI estão sendo instalados em diversos países, sendo que algumas concessionárias já atingem todos os consumidores neste formato. Os medidores utilizados nos sistemas AMI atuais representam grande avanço em relação à medição convencional, fornecendo informações em uma base de tempo muito mais rápida (a cada 15 minutos), ao invés de mensal como nos medidores eletromecânicos e, transmitindo as informações remotamente, ao invés da coleta manual. Tais medidores são ainda capazes de repassar os dados sobre demanda ativa e reativa, tensão, informações sobre a qualidade da energia e transitórios, ao invés de contabilizar somente o consumo de energia; permitir a conexão e desconexão remota, ao invés de local; permitir a adoção de postos tarifários, ao invés de tarifa fixa; e são bidirecionais, viabilizando o monitoramento da troca de energia entre sistemas de microgeração do cliente, com a rede elétrica.

No entanto, os medidores utilizados nos sistemas AMI atuais ainda necessitam de mais inteligência. Na verdade, esses medidores somente realizam as medições convencionais e transmitem esses dados para um centro de dados, com pouca ou nenhuma inteligência embarcada nos medidores. Diversas pesquisas no mundo inteiro visam a ampliação das funcionalidades dos novos medidores, resultando realmente na implementação de técnicas inteligentes voltadas aos medidores atualmente ditos como *inteligentes*. Um medidor inteligente deve ser capaz de fornecer muito mais informação para o consumidor e para a concessionária do que simplesmente o consumo e o comportamento das variáveis elétricas, de forma que todos possam administrar e planejar suas demandas e ações, aprimorando a

operação de uma rede inteligente e auxiliando a tomada de decisões. E, este é o contexto da presente proposta de pós-doutorado.

Mais especificamente, este projeto é aderente ao conceito de desagregação de consumo por equipamento/eletrodoméstico, ou seja, ao invés de simplesmente fornecer o consumo total mensal agregado de todos os equipamentos do cliente, o medidor poderá fornecer uma conta totalmente desagregada contendo o consumo individualizado dos equipamentos que existem na instalação (em princípio, residencial). Com isto, a relação do cliente com a concessionária de energia será muito mais transparente e dinâmica, aproximando-se de certa forma, da relação existente com as operadoras de telefonia celular ou de TV a cabo, o que pode viabilizar novos modelos de negócios.

Além da decomposição percentual do consumo para cada equipamento, o sistema proposto também poderá apresentar ao consumidor e à concessionária, o perfil de uso diário para cada equipamento, de forma a subsidiar o deslocamento do consumo para adequação à tarifa branca, por exemplo. Com base em informações detalhadas, o consumidor será capaz de identificar gargalos em sua instalação, tendo mais embasamento para a gestão do consumo, para a substituição de equipamentos, ou para a escolha da melhor política tarifária a ser aderida. O próprio sistema, por fazer parte no futuro de uma rede com milhares ou milhões de medidores, poderá auxiliar no diagnóstico de eficiência de cada equipamento, quando comparado ao padrão médio de todos os outros similares presentes na rede, através de um grande banco de dados em nuvem.

Tendo acesso à informação disponível na base de medição, o sistema poderá indicar ao consumidor sua classificação comparada ao padrão médio de consumo do seu grupo, e indicar ações que este consumidor possa considerar com foco à melhora de suas características de consumo em comparação ao grupo. Um sistema com essas características poderá ainda incluir outras funcionalidades, por exemplo, associadas à segurança, pois será capaz de monitorar a abertura de portões automáticos, ou associadas à saúde de pessoas com dificuldades de comunicação e locomoção, por exemplo, idosos, pois pode enviar alarmes em caso de inoperância de determinados equipamentos por tempo prolongado. Vale ressaltar que este nível de detalhamento quanto ao consumo de energia elétrica poderá trazer diversos benefícios também para a concessionária, que poderá operar e planejar sua rede elétrica de forma eficiente. A redução do consumo nos horários de pico regional ou nacional, por exemplo, pode trazer enormes vantagens para a concessionária, pois resultará em redução das perdas técnicas, em postergação de investimentos nas redes, melhora no perfil de tensão e facilidades de

controle. Ainda vale lembrar que a redução do pico não implica em redução do consumo, e sim em seu deslocamento. Portanto, o gerenciamento da demanda não necessariamente implica em perda de faturamento para a empresa fornecedora. Outro aspecto importante é que os medidores inteligentes criarão oportunidades para novos modelos de negócios, dos quais as concessionárias poderão encontrar maneiras de participar ativamente, de forma a compensar eventuais perdas de mercado associadas à conservação de energia e à micro ou mini geração distribuída.

O maior benefício para as concessionárias, no entanto, refere-se ao nível de detalhamento que a empresa passa a ter sobre o consumo de eletricidade do seu cliente, chegando ao conhecimento do consumo e perfil de cada equipamento. Este aspecto deverá ser bastante relevante no contexto das redes inteligentes. O que se espera é que a aplicação dessas novas tecnologias resulte na diminuição da desinformação que existe atualmente, dos consumidores em relação à rede elétrica, bem como da concessionária em relação aos consumidores. Trata-se de uma mudança importante, onde as decisões passarão a ser tomadas em um ambiente de fartura de dados (em aspectos do termo de *BigData*), ou seja, com posse das informações necessárias para subsidiar a melhor decisão, com base no enriquecimento de dados. Neste ambiente, haverá ganhos para ambas as partes.

Um exemplo claro da diferença entre os dois ambientes diz respeito ao conhecimento da curva de carga dos consumidores. No modelo atual as concessionárias realizam uma campanha de medição, por amostragem, para compor curvas de cargas típicas para cada classe e sub-classe de consumidor. Esta campanha é realizada a cada quatro anos, e mede o consumo a cada 15 minutos pelo período de uma semana. Este pequeno conjunto de curvas amostradas é utilizado para compor curvas típicas usadas para representar qualquer consumidor da empresa, as quais são atualizadas, na melhor das hipóteses, a cada quatro anos. O resultado disso é um erro significativo nos estudos de planejamento e operação das redes, uma vez que existe erro importante nas curvas de carga. No ambiente de redes inteligentes de energia, supondo maior monitoramento da demanda, as concessionárias terão condições de coletar curvas de carga de forma contínua, ao invés dos intervalos de quatro anos. Além disso, no caso especifico deste projeto, o período de aquisição dos dados é muito menor do que 15 minutos, de forma a permitir a desagregação do consumo. Desta forma, a resolução das curvas de carga também será muito mais elevada.

Mas, além da discussão sobre as curvas de carga, importante também é o conhecimento da composição da carga. Ou seja, a concessionária passará a ter o conhecimento dos equipamentos e eletrodo-

mésticos utilizados pelos seus clientes, bem como sobre o perfil de uso de cada um deles, sem que seja necessário realizar campanhas para levantamento de posse de equipamentos e hábitos de consumo. Este tipo de informação também é exigido pela ANEEL em cada ciclo de revisão tarifária, e também tem um custo elevado, em função da grande quantidade de consumidores que devem ser entrevistados. Isto sem falar na perda de precisão da informação, pelo fato de ser uma entrevista longa e cansativa para o consumidor.

Finalmente, o conhecimento da composição da carga para um grande número de consumidores permite a realização de mais uma tarefa complexa e importante para as concessionárias, que é a modelagem das cargas. Este aspecto é fundamental para qualquer estudo de planejamento ou operação, por exemplo, para o cálculo de perdas técnicas, para estudo de alocação de capacitores, para dimensionamento de redes e transformadores, etc. A correta modelagem da carga é um assunto negligenciado por muitas empresas distribuidoras pela sua complexidade e variabilidade. No entanto, conhecendo a composição da carga e seu perfil de uso torna-se simples obter modelos de carga precisos para estudos de regime permanente. Isto porque o modelo individual para cada equipamento é conhecido através de testes em laboratório, e para obter o modelo de carga para um determinado consumidor em determinado período do dia basta fazer a agregação dos diversos modelos individuais dos equipamentos em uso, resultando em um modelo agregado que representa todo o consumo do cliente naquele intervalo. Este tipo de informação pode ajudar a diminuir erros de planejamento e operação, resultando em economia significativa para as distribuidoras, além da melhoria nos indicadores de desempenho.

Esses aspectos representam motivadores importantes para o desenvolvimento de sistemas de monitoramento e gerenciamento do consumo, resultando em ganhos claros para consumidores e concessionárias de energia elétrica. Visando maior entendimento e aceitação por parte dos consumidores, este tipo de monitoramento será denominado neste projeto por **Monitoramento Concentrado**, por ser baseado na instalação de um único sensor inteligente no ramal principal da residência. Neste caso, o objetivo básico é determinar o consumo individual de cada carga sem ter acesso físico a cada equipamento. Isto é feito a partir da análise detalhada da tensão e da corrente na interface da instalação elétrica com a concessionária. As formas de onda da corrente e da tensão no ramal principal são registradas e analisadas. Tal análise das formas de onda da carga total gera estimativas do consumo individual das cargas e outras estatísticas. Esta análise é baseada na identificação de características elétricas específicas, comumente chamadas de assinaturas, que permitam identificar a carga que foi ligada ou desligada em determinados instantes. É importante destacar que o termo “não intrusivo”

está relacionado à ausência de acesso físico ao interior da instalação elétrica e, consequentemente, a cada uma das cargas.

Na abordagem concentrada apenas um sensor é colocado no ramal principal. Contudo o software que efetua a análise dos dados, a fim de desagregar as informações de cada carga, é bem complexo e justifica a atribuição do termo "medidor inteligente". Alguns softwares são baseados em ferramentas de reconhecimento de padrões e técnicas de inteligência artificial.

Tendo em vista as técnicas de inteligência voltadas aos medidores inteligentes de energia, como a desagregação de cargas e indicadores de eficiência e conservação de energia, tem-se ainda grande dificuldade em torná-las viáveis aos consumidores, em virtude da tecnologia não estar absolutamente consolidada, como também existir um custo considerável. Por mais que existam trabalhos na literatura quem abordem estas técnicas, há a dificuldade ao transformá-las em soluções factíveis. No aspecto científico, tem-se que as técnicas concentradas (NILM) não possuem boa exatidão e custo computacional considerável. Em [**?**] foi proposta uma técnica que analisa e retira indicadores das formas de onda de tensão e corrente. Esta técnica possui algumas deficiências como a necessidade de aquisição com precisão, alta taxa de amostragem e o uso de um microcontrolador com alto processamento.

Pode-se, portanto, rever esta técnica e buscar algoritmos que possibilitem aumentar a exatidão e diminuir o custo computacional associado. Após o aprimoramento da técnica, o nível da aplicação do medidor será elevado ao nível da central de controle. As estratégias para essa etapa são apresentadas nas próximas subseções.

7.1 Aprimoramento dos sistemas de aquisição e coleta de grandezas de energia elétrica

Como observado em [18], a placa de aquisição construída possui pequenas falhas de projeto, de forma que pretende-se aprimorar seu projeto com a intenção de diminuir ruídos de medição. Outra estratégia é o uso de sensores com menor custo.

7.2 Melhoria do sistema de reconhecimento de cargas

Considerando sistemas monofásicos, quatro parcelas de potência podem ser identificadas através da CPT, proposta em [**?**] e em [**?**]:

$A = P^2 + Q^2 + D^2$

Na qual:

Potência Aparente (A): Tendo em vista a caracterização da potência total do sistema, o produto dos valores RMS de tensão e de corrente determina a potência da fonte de alimentação, denominada potência aparente (A).

Potência Ativa (P): Corresponde ao consumo médio de potência de um circuito é definido como potência ativa (P), e sua unidade é watts $[W]$. Essa componente está associada a parcela de corrente ativa balanceada, representando a realização de trabalho útil na carga.

Potência Reativa (Q): Todo fluxo de potência reativa em um circuito é definido como potência reativa (Q), e sua unidade é Volt-Ampere $[VA]$. Essa componente está associada a parcela de corrente reativa balanceada, representando o deslocamento, entre tensões e correntes no circuito.

Potência Residual (D): A potência residual (D) representa as não linearidades entre as tensões e correntes, em geral provocadas por cargas não lineares. Portanto, não transporta potência ativa, nem energia reativa.

Tais parcelas permitem a caracterização momentânea de uma determinada carga e favorece principalmente à identificação de cargas que funcionam com um regime constante de potência consumida. Para grande parte das cargas residenciais, a CPT ajuda na identificação porque consegue extrair características próprias para cada equipamento. Para cargas que possuem variação de potência, a CPT não se torna a ferramenta que melhor descreve as descrevem.

Tais tipos de assinatura de potência auxiliam na identificação de cargas, porém há a necessidade de implementação de dois algoritmos a parte. Se for implementado um algoritmo de identificação de cargas através da análise de estados, pode-se obter a redução no tempo computacional e também na simplificação de implementação.

Para que haja uma evolução na metodologia proposta e na melhoria da análise, existem algoritmos

como os probabilísticos de processos estocásticos com estados discretos, como a cadeia de Markov.

Uma cadeia de Markov é um sistema matemático que realiza transições de um estado para outro de acordo com certas regras probabilísticas. A característica definidora de uma cadeia de Markov é que, independentemente de como o processo chegou ao seu estado atual, os possíveis estados futuros serão fixos. Em outras palavras, a probabilidade de transição para qualquer estado particular depende apenas do estado atual e do tempo decorrido. O espaço de estados, ou conjunto de todos os estados possíveis, pode ser aplicado em diversas áreas: sugestão de letras, sequência de números, condições meteorológicas, resultados de tênis ou desempenho das ações em bolsas de valores.

As cadeias de Markov podem ser modeladas por máquinas de estados finitos, e os passos aleatórios fornecem um exemplo prolífico de sua utilidade na matemática. Eles surgem amplamente em contextos estatísticos e teóricos da informação e são amplamente empregados em economia, teoria dos jogos, teoria de enfileiramento (para comunicação), genética e finanças. Embora seja possível discutir cadeias de Markov com qualquer tamanho de espaço de estado, a teoria inicial e a maioria das aplicações são focadas em casos com um número finito de estados.

7.3 Levantamento de características (atributos) de cargas (oito meses)

Em [18], as características utilizadas foram as parcelas de potência da CPT e o filtro em relação às assinaturas de potência. Pretende-se extrair mais características das cargas, como as ordens harmônicas da corrente de cada carga através da transformada rápida de Fourier, e aprimorar a base de dados de conhecimento de cargas.

Tal etapa fará com que toda a metodologia proposta em [18] seja revalidada, pois a cada novo atributo o modelo de classificação pode sofrer alterações que podem melhorar ou piorar o nível de exatidão.

Uma outra abordagem é a criação de histogramas referentes à passagem da corrente em intervalos. Tal técnica tem custo computacional baixo e permite criar também a assinatura microscópica de eletrodomésticos. Durante um ciclo, iniciando ao cruzamento pelo zero da tensão, saindo do zero para um, à cada amostra coletada, verifica-se o intervalo da medição da corrente e incrementa-se a um vetor de índices dos intervalos. Também é armazenado o intervalo final na coleta da corrente.

A Figura 90 apresenta um exemplo da criação do histograma. Tem-se 200 amostras por ciclo (taxa de amostragem 12kHz). A cada amostra, verifica-se em qual intervalo pertence o sinal coletado e incrementa-se em um o índice correspondente do vetor. No exemplo, a posição 0 do vetor corresponde ao intervalo entre -30.4 e -32 amperes. A posição 1 do vetor corresponde ao intervalo entre -28.8 e -30.4 amperes e assim por diante, até a posição 39 do vetor que corresponde ao intervalo entre 30.4 a 32 amperes. Na última amostra do ciclo também coleta-se o índice, para ajudar na detecção de defasagem entre tensão e corrente.

Esta nova metodologia utiliza apenas um simples comando e pretende-se analisar a factibilidade para a implementação em sistemas embarcados mais simples e próximos ao hardware encontrado nos medidores inteligentes comerciais.

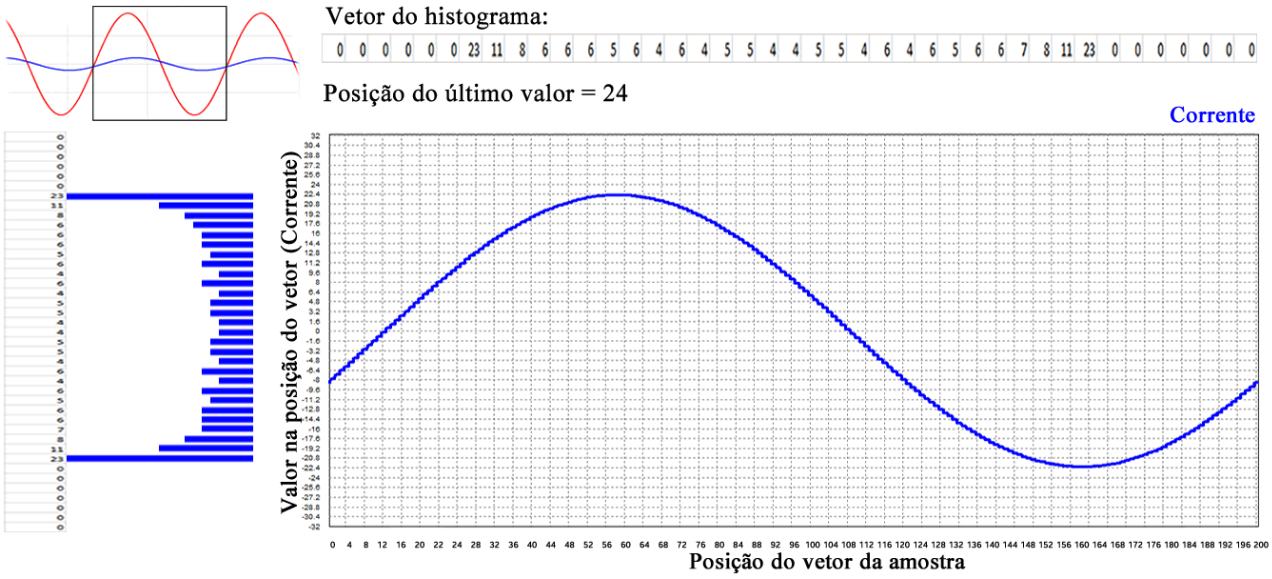

Figura 90: Exemplo da extração de atributos por histograma.

7.4 Reavaliação da metodologia para aplicação em medidores inteligentes de baixo custo em redes inteligentes

Tem-se como objetivo analisar cada parte da metodologia proposta em [18], focando a redução do tempo computacional e permitindo sua aplicação para medidores inteligentes de menor custo. Para isso serão refeitas as seguintes técnicas:

1. **Extração das características e revisão da máquina de estados:** como apresentado na subse-

ção anterior, uma nova metodologia será aplicada para a extrair características das cargas, bem como será refeita a máquina de estados para que esta permita o aumento do acerto na análise da assinatura de potência das cargas;

2. **Dados de medição:** diferentemente de [18], em que os dados eram armazenados no dispositivo, pretende-se utilizar os serviços de dados em nuvem (em inglês, *cloud*) para que se possa diminuir o espaço ocupado pelos dados no microcontrolador. O serviço em nuvem também será testado para o sistema de classificação. A empresa Google, por exemplo, oferece um pacote de aplicações para a computação em nuvem (*cloud computing*), incluindo serviços de aprendizagem de máquina.

3. **Sistema supervisório / Gerenciador:** Da mesma forma que os dados serão enviados à nuvem, o sistema será executado em um servidor externo ao medidor. Tal sistema será *full-stack* web responsivo, ou seja, acessível e adaptável a qualquer dispositivo que tenha acesso à internet e que tenha permissões de acesso aos dados (controle de usuários).

4. **Criação do sistema de gestão da rede inteligente através dos dados coletivos dos medidores cognitivos:** Será criado um sistema baseado em SCADA (Supervisory Control and Data Acquisition) relativo ao painel de controle da chamada usina virtual, o qual será acessado via web, onde serão apresentados relatórios e monitorados o comportamento da rede inteligente..

7.5 Análise histórica de consumo de cargas para a verificação do desgaste e da eficiência energética

A médio e a longo prazo, o medidor poderá realizar comparativos de consumo de um mesmo equipamento, apresentando assim o desgaste do mesmo com relação a redução da eficiência energética. Em [102], foram avaliados os efeitos de temperatura ambiente e degradação de eficiência energética dos equipamentos como geladeiras e freezers domésticos.

Tendo uma análise de geladeira, por exemplo, tais equipamentos sofrem desgastes ao longo da vida útil [102]. Como consequência disso, o desempenho é reduzido e o consumo de energia aumenta. As principais causas dessa degradação são: vedação, isolamento, termostato e compressor. Assim, com base na pesquisa realizada, o autor define que tais equipamentos começam a apresentar alteração

de eficiência energética a partir de 5 anos. Entre 5 e dez anos a degradação pode chegar a 20%, tendo como principal causa o isolamento e a vedação. Para equipamentos mais velhos esse índice pode chegar a 60%, principalmente, por causa do compressor e do termostato.

Para outros equipamentos, como ar condicionado, máquina de lavar roupas, secadora de roupas, entre outros, há formas de indicar comparativos de eficiência energética e consequentemente indicar o momento ideal para a troca do equipamento.

Outra estratégia que busque a eficiência energética pode envolver a coleta de outras grandezas, como temperatura, iluminação e umidade relativa do ar. Desta forma, pretende-se analisar a relação entre diversas grandezas com o desempenho de equipamentos.

7.6 Sistemas de ludificação

É possível propor técnicas para analisar o padrão de consumo desagregado de energia elétrica e gerar automaticamente sugestões de desafios personalizados, visando oferecer soluções para a redução do consumo com energia elétrica, bem como buscar meios para aumentar a eficiência energética, oferecer *feedbacks* e apresentar estratégias dentro no contexto de ludificação. Para isso, serão utilizados técnicas de aprendizado de máquina que possam identificar padrões de consumo e prever demanda de energia dentro de uma residência.

Podem ser estudados os padrões de assinatura de potência, dados de desagregação de consumo e criação de novos conjuntos de dados que auxiliem na criação de estratégias de ludificação, tanto no incentivo quanto no envolvimento do consumidor em buscar soluções para o uso eficiente e consciente da energia elétrica. Com os dados criados, serão aplicados algoritmos de aprendizado de máquina para identificar padrões e prever comportamentos. Com base nas técnicas, pretende-se desenvolver uma aplicação que realize a ludificação com o consumidor e a validação será realizada através da implementação do sistema em um protótipo do medidor cognitivo.

Como resultados, através da ludificação, pode-se haver interação e consciência do consumidor em relação ao seu consumo de energia elétrica. O consumidor receberá incentivos para se envolver em uma “espécie de jogo”, ao cumprir etapas que buscam a economia de energia elétrica e aumento da eficiência energética.

Para isso, podem ser criadas, validadas e otimizadas as bases de dados de: caracterização de cargas, parâmetros comportamentais de consumo, mecanismos de redução de consumo e eficiência energética, itens de ludificação e de jogabilidade. Após a etapa de construção e análise das bases de dados, os algoritmos de aprendizado de máquina podem ser utilizados para detectar padrões de consumo, gerar regras de ludificação e prever metas de consumo.

Por fim, pode ser oferecida uma plataforma de interação com o consumidor, que será responsável por envolver o usuário em metas e objetivos, tendo recompensas como parâmetro motivador.

7.7 Considerações

Tem-se trabalhos voltados ao nível do medidor na rede inteligente, de estratégias para melhorar a eficiência energética e de estratégias para envolver o consumidor no comprometimento de redução de consumo e de formas otimizadas do consumo de energia.

Desta forma, este projeto contribuiu na melhoria do projeto de desagregação de cargas de sistemas de monitoramento não intrusivos e existem novos projetos a serem continuados. A próxima seção apresenta as considerações finais sobre este projeto.

8 Considerações finais

Durante o período de pós-doutorado do candidato na FEEC / UNICAMP, foi desenvolvido o estudo das técnicas e levantamento das tecnologias de desagregação de cargas para consumidores residenciais. O estudo estava diretamente ligado ao projeto de P&D ANEEL-0063-3020/2017, fomentado pela CPFL – Companhia Paulista de Força e Luz.

Como o foco é a contribuição tecnológica e factibilidade de implantação dos métodos de desagregação nas residências, o pós-doutorando fez o estudo comparativo das técnicas de desagregação de cargas - ILM (Intrusive Load Monitoring - Monitoramento Intrusivo de Cargas, ou simplesmente Monitoramento Distribuído), s-ILM (semi-Intrusive Load Monitoring - Monitoramento semi intrusivo de cargas, ou simplesmente Monitoramento semi-distribuído) e NILM (Non-intrusive Load Monitoring - Monitoramento Não-Intrusivo de cargas, ou simplesmente Monitoramento Concentrado).

Foram feitas as comparações das tecnologias das três técnicas e quais os dispositivos disponíveis no mercado que possuem potencial para uso para o consumidor residencial. O foco principal do projeto se baseou nas metodologias para identificação do consumo individualizado de cargas residenciais, ou seja, a desagregação do consumo mensal por equipamento, bem como o perfil diário de uso de cada equipamento. Buscou-se apresentar quais são os ganhos claros para consumidores e concessionárias de energia elétrica, caso a desagregação se torne algo comum nas residências. Com base nisto, tem-se na literatura e nas soluções comerciais as três técnicas.

No projeto realizado de pós-doutorado, os sistemas de monitoramento concentrado, parcialmente distribuído e distribuído foram investigados. Teve como foco o monitoramento não intrusivo – NILM.

Houve a melhoria no sistema de desagregação de cargas proposto por Souza [18], com uma análise profunda dos atributos, na melhoria do estado de máquina e no aumento dos níveis de assertividade do método. Este é um passo importante para a correta identificação do consumo individualizado por equipamento ou família de equipamentos, para assim fornecer ao consumidor propostas para melhorar o seu desempenho energético, ou seja, melhorar a eficiência energética. O sistema NILM pode sugerir diferentes estratégias dependendo do tipo de equipamento e do sistema de tarifação escolhido pelo consumidor. Entre as estratégias possíveis destacam-se:

- **Redução de uso:** dependendo do tipo de equipamento, é possível melhorar o desempenho

energético e econômico através da redução do uso do dispositivo sem causar transtornos ao consumidor. Por exemplo, no caso do chuveiro elétrico, o sistema pode indicar a economia gerada a cada minuto de redução do uso diário.

- **Substituição de equipamento:** O sistema pode sugerir a substituição por outro equipamento similar mais eficiente. Para esta solução, o sistema calcula a redução do custo mensal com a substituição e o retorno do investimento em função do custo do novo equipamento.

- **Alteração de sistema tarifário e horário de uso:** no caso de equipamentos que podem ter seu horário de uso alterado, como por exemplo, máquina de lavar e secar roupas, o sistema pode sugerir ao usuário, por exemplo, a adesão ao sistema de tarifa branca, bem como o melhor horário de uso. Neste caso, o sistema informará a redução do custo mensal, cabendo ao usuário acatar ou não as recomendações sugeridas.

Portanto, o foco deste pós-doutorado no arcabouço do P&D foi o estudo das técnicas e tecnologias de desagregação, sendo nas vertentes ILM, s-ILM e NILM. Após a análise das tecnologias, o projeto teve como objetivo apresentar à CPFL a importância desta tecnologia e como ela pode trazer benefícios para a concessionária e para o consumidor.

9 Artigos publicados no período de pós-doutorado

Durante o período de pós-doutorado, o pesquisador teve artigos aceitos de trabalhos derivados do projeto de pós-doutorado, de trabalhos correlatos no grupo de pesquisa e provenientes de co-orientações de mestrados. As seções a seguir apresentam os trabalhos publicados e também os aceitos para publicação. Todos estes artigos encontram-se no Anexo I.

9.1 Artigos publicados em periódicos

No período de pós-doutorado, cinco artigos foram aceitos e publicados em periódicos:

9.1.1 *Energies* – Load Disaggregation Using Microscopic Power Features and Pattern Recognition

Autores: Wesley Angelino de Souza, Fernando Deluno Garcia, Fernando Pinhabel Marafão, Luiz Carlos Pereira da Silva, Marcelo Godoy Simões

Revista: Energies (ISSN: 1996-1073, IF: 2,707), Q1 - Electrical and Electronic Engineering

Resumo: A new generation of smart meters are called cognitive meters, which are essentially based on Artificial Intelligence (AI) and load disaggregation methods for Non-Intrusive Load Monitoring (NILM). Thus, modern NILM may recognize appliances connected to the grid during certain periods, while providing much more information than the traditional monthly consumption. Therefore, this article presents a new load disaggregation methodology with microscopic characteristics collected from current and voltage waveforms. Initially, the novel NILM algorithm—called the Power Signature Blob (PSB)—makes use of a state machine to detect when the appliance has been turned on or off. Then, machine learning is used to identify the appliance, for which attributes are extracted from the Conservative Power Theory (CPT), a contemporary power theory that enables comprehensive load modeling. Finally, considering simulation and experimental results, this paper shows that the new method is able to achieve 95% accuracy considering the applied data set.

Descrição: Trabalho resultante do pós-doutorado do pesquisador, primeiro autor. O autor e o supervisor foram os responsáveis pela pesquisa deste artigo. Nele se encontra uma metodologia nova

para a desagregação de cargas elétricas em um único ponto de medição. Para isso, tem-se uma análise de atributos extraídos de sinais de energia elétrica e faz-se uma análise de eventos baseado em máquina de estados e de algoritmos de classificação de padrões.

9.1.2 *RBER* – Arquitetura do Medidor Cognitivo de Energia

Autores: Felipe Leite Paes, Fernando Pinhabel Marafão, Wesley Angelino de Souza, Fernando Deluno Garcia

Revista: Revista Brasileira de Energia Renováveis (ISSN: 2237-9711)

Resumo: As Redes Inteligentes de Energia indicam para uma nova arquitetura dos sistemas de distribuição de energia elétrica, a qual deve se consolidar nas próximas décadas, em um cenário repleto de dispositivos e sistemas dotados de algum grau de "inteligência" artificial. Neste cenário, a possibilidade de comunicação bidirecional entre o usuário e a rede de energia elétrica será imprescindível para integração dos vários dispositivos e agentes em uma Rede Inteligente. Atualmente, há muita pesquisa e desenvolvimento sobre os chamados medidores inteligentes de energia e sobre os medidores cognitivos de energia, que possibilitam a integração e comunicação dos dispositivos numa rede de dados e facilita a atuação de uma Rede Inteligente de Energia. Nesse contexto, este trabalho propõe um tutorial sobre as tecnologias, métodos e etapas que podem ser utilizadas no desenvolvimento de medidores cognitivos de energia.

Descrição: Este artigo apresenta a concepção de arquitetura dos medidores cognitivos e foi fruto de um convite da revista após a apresentação de um artigo no ConER 2017 – Congresso de Energias Renováveis. O primeiro autor foi coorientado do pesquisador de pós-doutorado do memorial durante o seu período de mestrado.

9.1.3 *JCAES* – A NILM Dataset for Cognitive Meters Based on Conservative Power Theory and Pattern Recognition Techniques

Autores: Wesley Angelino de Souza, Fernando Pinhabel Marafão, Eduardo Verri Liberado, Marcelo Godoy Simões, Luiz Carlos Pereira da Silva

Revista: Journal of Control, Automation and Electrical Systems (ISSN: 2195-3899, IF 1,237), Q2

– Electrical and Electronic Engineering

Resumo: This paper presents a novel dataset capable of classifying and disaggregating residential appliances for the development of smart or cognitive power meters. This novel dataset uses power indicators (also denoted as conformity factors) from the conservative power theory (CPT), which are calculated from measured voltage and current waveforms during the operation of residential loads. The association of CPT power indicators with suitable pattern recognition algorithms (PRA) and a power signature state machine provides proper identification of each appliance. So, the paper also presents a detailed evaluation of possible PRA for this application, especially the SVM—support vector machine, OPF—optimum-path forest, MLP—multilayer perceptron, KNN—K-nearest neighbor and DT—decision tree. All these algorithms have been compared regarding accuracy and computational time. Validation results point out that KNN would be the best choice for dealing with the proposed dataset, leading to an accuracy higher than 98%.

Descrição: Este artigo apresenta a base de dados de cargas elétricas construída pelo pesquisador de pós-doutorado. Esta base vem da coleta de sinais elétricos de equipamentos elétricos e com o cálculo de atributos, tem-se uma base de dados para ser utilizada no processo de desagregação de cargas.

9.1.4 *JCAES* – Evaluation of Pattern Recognition Algorithms for Applications on Power Factor Compensation

Autores: Alexandre Cândido Moreira, Helmo Kelis Morales Paredes, Wesley Angelino de Souza, Pedro Henrique Juliano Nardelli, Fernando Pinhabel Marafão, Luiz Carlos Pereira da Silva

Revista: Journal of Control, Automation and Electrical Systems (ISSN: 2195-3899, IF 1,237), Q2 – Electrical and Electronic Engineering

Resumo: This paper assesses different applied pattern recognition algorithms to decide the most appropriate power factor compensator for a particular point of common coupling. Power factor, current unbalance factor, total demand distortion, voltage harmonic distortion and reactive power daily variation, as well as human expertise, are the key parameters used to set each recognition algorithm. These algorithms are then trained with a series of both simulation and experimental data. Numerical results consistently indicate the decision-tree algorithm with depth 20 as the best classifier for power factor improvement in terms of all metrics considered in this work.

Descrição: Neste artigo, o pesquisador de pós-doutorado, por conhecer as técnicas de aprendizado de máquina, foi o responsável pelo tratamento da base de dados de um especialista, depois foi responsável pela avaliação dos algoritmos de aprendizado de máquina.

9.1.5 *IEEE TSG* – Intelligent Expert System for Power Quality Improvement Under Distorted and Unbalanced Conditions in Three-Phase AC Microgrids

Autores: Alexandre Cândido Moreira, Helmo Kelis Morales Paredes, Wesley Angelino de Souza, Fernando Pinhabel Marafão, Luiz Carlos Pereira da Silva

Revista: IEEE Transactions on Smart Grids (ISSN: 1949-3053, IF 10,492), Q1 – Computer Science (miscellaneous)

Resumo: This paper presents an expert system (ES) based on decoupled power/current decomposition and the k-nearest neighbor pattern recognition method to identify and choose the correct mitigation solution for power quality improvement in three-phase ac microgrids under non-sinusoidal current and voltage operations. By using power/current terms, load conformity factors and a k-nearest neighbor classifier, the proposed ES achieved 99.98% classification accuracy. Simulation studies were carried out in a PSCAD/EMTDC environment, where the IEEE 13-bus feeder test system was in a grid connected microgrid mode. The obtained results indicate that the proposed ES is robust and able to easily select an appropriate/adequate compensation solution.

Descrição: Neste artigo, o pesquisador de pós-doutorado realizou a análise de dados, implementação dos classificadores de padrões e contribuiu na análise dos resultados. O primeiro autor tinha implementações utilizando árvores de decisão e teve a preocupação de utilizar técnicas de aprendizado de máquina para tornar o método mais robusto e com maior assertividade, o que foi realizado com o auxílio fundamental do terceiro autor (do pesquisador de pós-doutorado).

9.2 Artigos aceitos para publicação em periódicos

No período de pós-doutorado, um artigo também foi aceitos e está na fila do periódico para publicação:

9.2.1 *IEEE LAT* – Automatic Consumption Management for Prepaid Electricity Meter with NILM

Autores: Wesley Angelino de Souza, Fernando Deluno Garcia, Alexandre Cândido Moreira, Fernando Pinhabel Marafão, Luiz Carlos Pereira da Silva

Revista: IEEE Latin America Transactions (ISSN: 1548-0992, IF: 1,042), Q2 - Computer Science (miscellaneous)

Resumo: Recently, the Brazilian Electricity Regulatory Agency (ANEEL) regularized the electricity prepayment system and opened a general discussion about the technologies, resources, and implementations for the prepayment metering system. In several countries, the consumer charges the value equivalent to the kilowatt-hours that he wishes to buy for use. However, some consumers purchase credit with the expectation that the charge remains for a specific time, but they may be surprised with the credit end before the expected time. For this reason, this paper proposes automatic consumption management for prepaid meters that analyzes the consumer appliance behavior, performs the temporal analysis of consumption by appliances, defines the cost management per load with high energy consumption and sends sound signals to the consumer ends the appliance usage. The objective of this management system is to ensure that the credit will be used for the consumer expected time.

Descrição: Artigo no qual o pesquisador de pós-doutorado explorou a hipótese do uso do medidor cognitivo em um medidor pré-pago. Análises foram feitas em uma residência para mostrar que o medidor pode ser um diferencial para que se possa atingir metas de consumo pré-estabelecidos.

9.3 Artigos publicados em anais de eventos / congressos

No período de pós-doutorado, seis artigos foram aceitos e publicados em anais de eventos:

9.3.1 *CBA 2018* – Comparação das técnicas de monitoramento de cargas para a desagregação do consumo de energia elétrica

Autores: Hader Aguiar Dias Azzini, João Guilherme Ito Cypriano, Wesley Angelino de Souza, Rafael Cuerda Monzani, Luiz Carlos Pereira da Silva, Augusto Chierice Venerando da Silva

Evento/Congresso: XXII Congresso Brasileiro de Automática, João Pessoa - PB, 2018

Resumo: Este artigo compara e avalia as três abordagens para o monitoramento de cargas mais conhecidas, indicando os benefícios e dificuldades encontradas na implementação. O monitoramento não intrusivo (concentrado) indica o uso de um único medidor por residência, instalado no Ponto de Acoplamento Comum (PAC), local onde os dados de consumo coletivo são coletados e depois é realizada a desagregação de cargas. O monitoramento intrusivo (distribuído) usa pontos de sensoriamento por cada eletrodoméstico instalado na residência. A terceira proposta - monitoramento semi intrusivo (parcialmente distribuído) - é intermediária às duas anteriores, com os dados sendo coletados por cada circuito, no quadro de distribuição. Este artigo também apresenta vantagens, custos, benefícios e as tecnologias disponíveis no mercado para estas abordagens e é apresentado um exemplo aplicado para cada técnica. Entretanto, a técnica concentrada, baseada na identificação das cargas elétrica por software, apresentou-se como a mais adequada e com maior potencial entre as três.

Descrição: O autor foi o responsável pela construção dos resultados na comparação entre as técnicas de desagregação (ILM, s-ILM e NILM).

9.3.2 *CBA 2018* – Gerenciamento de Consumo Elétrico Baseado em Medidores Cognitivos de Energia Elétrica

Autores: Wesley Angelino de Souza, Fernando Pinhabel Marafão, Fernando Deluno Garcia, Felipe Leite Paes

Evento/Congresso: XXII Congresso Brasileiro de Automática, João Pessoa - PB, 2018

Resumo: Medidores cognitivos de energia elétrica indicam para uma nova geração de medidores eletrônicos, com elevada capacidade de processamento, armazenamento e comunicação de dados, os quais fazem uso de técnicas avançadas de mineração, tratamento e processamento de dados, visando dentre outras coisas, a desagregação do consumo de energia para prover consumidores e fornecedores de energia de informações mais detalhadas que possam ser utilizadas no gerenciamento energético das instalações e redes. Neste contexto, este trabalho faz uma revisão dos principais subsistemas envolvidos e, descreve a proposta de um sistema de gerenciamento de consumo de energia, baseado em medidores cognitivos de energia.

Descrição: Este trabalho apresenta a construção da nova geração de medidores cognitivos e im-

portância da informação, para que se possa ser construído um gerenciador que possa auxiliar o consumidor a estar ciente do consumo de energia por equipamentos elétricos e como um sistema pode indicar meios de reduzir o consumo com energia elétrica.

9.3.3 *GreenTech 2017* – Power Metering: History and Future Trends

Autores: Fernando Deluno Garcia, Fernando Pinhabel Marafão, Wesley Angelino de Souza, Luiz Carlos Pereira da Silva

Evento/Congresso: 2017 Ninth Annual IEEE Green Technologies Conference (GreenTech), Denver, CO, USA, 2017

Resumo: Considering the rising demand for electricity around the world, several technologies have been developed to provide a more efficient and modern power system. In this context, the smart grid concept is related to the integration and management of different power system devices, aiming to provide technical, economic, social and environmental benefits. Thus, the smart meter has become one of the main elements in smart grids and it may provide much more capabilities than the conventional electromechanical and electronic energy meters. Therefore, this paper discusses the main differences between smart and conventional power meters, pointing to the new features, methodologies and applications of modern smart meters. Moreover, this paper deals with the definition of "smart", introducing possible functionalities and applications that can effectively impact on the understanding of the energy consumption, while allowing to improve power management and energy efficiency.

Descrição: Este artigo apresenta o estudo crítico realizado na construção da dissertação de Fernando Deluno Garcia, co-orientado de mestrado do pesquisador de pós-doutorado.

9.3.4 *CITENEL 2017* – Refrigeradores residenciais: monitoramento e análise comparativa entre modelos distintos

Autores: Rafael Cuerda Monzani, João Guilherme Ito Cypriano, Hader Aguiar Dias Azzini, Wesley Angelino de Souza, Augusto Chierice Venerando da Silva, Rodrigo Marssola Garbelotti, Luiz Carlos Pereira da Silva

Evento / Congresso: Congresso de Inovação Tecnológica em Energia Elétrica – CITENEL 2017

Resumo: A presença de refrigeradores em residências no Brasil superou a margem de 96% do total existente, com crescimento linear desde 2001. O uso de refrigeradores representa uma parcela significativa do consumo de energia elétrica, atingindo em certos casos, proporções em torno de 25% do total consumido. Este artigo analisa o consumo de energia de diferentes tipos de refrigeradores, observando aspectos qualitativos como característica de funcionamento, modelos e quantitativos como capacidade, número de portas e comportamento dos residentes. A aquisição dos sinais de tensão e corrente foi obtida por meio de um analisador de energia. Dados complementares (potência ativa e reativa, fator de potência, correntes harmônicas) responsáveis por construir o perfil elétrico de cada refrigerador também foram fornecidos. Com base na curva de carga e nas características da assinatura elétrica, premissas são estabelecidas visando obter recursos para avaliar os diferentes modelos monitorados, estabelecendo uma análise comparativa entre capacidade, consumo e eficiência.

Descrição: Este artigo apresenta o estudo e análise de refrigeradores, em relação à sua assinatura de potência e seu comportamento durante os seus diferentes ciclos de operação. Neste trabalho, o pesquisador de pós-doutorado foi responsável pela análise dos resultados e pelo ajuste dos resultados.

9.3.5 *CBA 2016* – Análise Comparativa entre Medições de Energia Elétrica para Cargas Não Lineares de Iluminação: Medição Comercial x Teoria CPT

Autores: Mateus Siqueira Quinalia, Mateus Alécio Sachetti, Vinicius Henrique Farias Brito, Guilherme Yuji Kume, Roberto Perillo Barbosa da Silva, Wesley Angelino de Souza, Luiz Carlos Pereira da Silva

Evento / Congresso: XXI Congresso Brasileiro de Automática, Vitória - ES, 2016

Resumo: Através de medições de lâmpadas fluorescente compacta e LED tubular, realizadas em laboratório, e utilizando medidores e analisadores de energia elétrica, pôde-se aferir os valores de potências destas cargas, os quais foram comparados com os parâmetros apresentados através da simulação computacional com base na Teoria de Potência Conservativa (TPC ou CPT, em inglês). Este artigo discute a diferença entre os valores encontrados para a CPT e os dados dos medidores comerciais, com enfoque no valor da potência reativa, uma vez que esta grandeza é a que apresenta maior divergência entre os resultados. Além disso, foi realizada análise referente ao impacto desta discrepância no faturamento da energia elétrica.

Descrição: O pesquisador de pós-doutorado, neste caso, foi o responsável pela construção de um medidor de energia com a CPT (teoria de potência) implementada e com um supervisório construído com base em back-end php/mysql e front-end html/javascript/css. Tal protótipo foi doado para o desenvolvimento de projetos na UFMT. Posteriormente, o pesquisador analisou os resultados e fez os comentários críticos. Os demais autores do artigo são colaboradores da Universidade Federal do Mato Grosso e o Prof. Dr. Luiz Carlos da UNICAMP.

9.3.6 *ICHQP 2016* – Analysis of the influence of non-linear loads on the measurement and billing of electrical energy compared with the CPT

Autores: Vinicius Henrique Farias Brito, Guilherme Yuji Kume, Mateus Siqueira Quinalia, Mateus Alécio Sachetti, Roberto Perillo Barbosa da Silva, Wesley Angelino de Souza, Luiz Carlos Pereira da Silva

Evento / Congresso: 17th International Conference on Harmonics and Quality of Power (ICHQP), Belo Horizonte, MG, Brazil, 2016.

Resumo: This article analyzes the impact of electronic loads, particularly CRT, LCD and LED televisions, regarding the measurements of reactive power in energy meters of Brazilian Electric Power companies and consequently the influence of those measurements in the reactive surplus Billing (Reactive Energy Excess and Demand Energy Excess). Later, the values obtained from the energy meter are compared to the CPT power components. For the reactive surplus calculation, it is considered not only the reactive power, but also the distortion in the system. It is concluded that the harmonic distortion causes significant interference in measurements of reactive power in energy meters, and that the calculation of reactive power surplus through power factor allows certain inconsistencies in the billing.

Descrição: Idem ao artigo supracitado. O pesquisador de pós-doutorado foi o responsável pela construção de um medidor de energia com a CPT (teoria de potência) implementada e com um supervisório construído com base em back-end php/mysql e front-end html/javascript/css. Tal protótipo foi doado para o desenvolvimento de projetos na UFMT. Posteriormente, o pesquisador analisou os resultados e fez os comentários críticos. Os demais autores do artigo são colaboradores da Universidade Federal do Mato Grosso e o Prof. Dr. Luiz Carlos da UNICAMP.

10 Coorientações no período de pós-doutorado

Durante o período de pós-doutorado, o pesquisador coorientou dois trabalhos de iniciação científica, duas dissertações de mestrado e uma tese de doutorado. Estas estão listadas a seguir:

10.1 Coorientações de Iniciação Científica

No período, o pesquisador realizou duas coorientações de iniciação científica, uma com bolsa FAPESP e outra com bolsa PIBIC - UNESP. No primeiro, o pesquisador ofereceu os dados provenientes do doutorado para a implementação da análise dos dados voltados para a gestão de energia elétrica. No segundo, o pesquisador ajudou o bolsista na construção de um medidor de qualidade da energia elétrica de baixo custo. O pesquisador também foi orientador do trabalho de graduação do aluno Otávio Giannotti Lunardi.

10.1.1 Estudo e desenvolvimento de tecnologias para automação residencial com foco na gestão de energia elétrica nas instalações

Processo FAPESP: 18/11643-3

Vigência (Início): De 01/08/2018 a 28/02/2019

Pesquisador responsável: Fernando Pinhabel Marafão

Beneficiária: Marcella de Sant' Ana

Assunto(s): Inteligência artificial; Microrredes inteligentes; Modelagem computacional; Distribuição de energia elétrica; Consumo de energia elétrica; Redução de custos; Conjuntos residenciais; Geração de energia elétrica

Resumo: Considerando a crescente inserção de fontes renováveis de energia nas instalações residenciais, em especial a fonte solar através de sistemas de microgeração de energia, bem como o uso de técnicas de automação residencial (domótica), este projeto prevê o estudo de técnicas e tecnologias de automação residencial que possam ser utilizadas em metodologias de gerenciamento energético, visando o uso mais eficiente da energia elétrica, com consequente redução de despesas para o consumidor. Neste contexto, também serão estudadas técnicas de identificação (desagregação) de cargas, em

especial as técnicas não intrusivas (NILM) que vêm sendo desenvolvidas pelo Grupo de Automação e Sistemas Integráveis (GASI) da UNESP/Sorocaba e pelo grupo da Faculdade de Engenharia Elétrica e de Computação (FEEC) da UNICAMP. De forma mais ampla, o projeto visa preparar o aluno do curso de engenharia de controle e automação para abordagem de temas correlatos ao gerenciamento de energia em redes inteligentes, em especial no contexto de instalações residenciais microgeração de energia, as quais disponham de dispositivos de controle automático das cargas e outros subcircuitos da instalação. Após os estudos bibliográficos e das tecnologias disponíveis no mercado, será desenvolvido um modelo computacional que permita avaliar e propor diferentes estratégias para o controle ativo do consumo de energia em função de parâmetros pré-definidos e da caracterização dinâmica das cargas em operação e do sistema de geração local. Acredita-se que o trabalho pode indicar eventuais contribuições futuras na área, além de contribuir significativamente para a formação do aluno, em virtude de envolver temas totalmente correlatos ao curso de Engenharia de Controle e Automação. Vale ressaltar que o projeto está relacionado ao projeto temático vigente sobre redes inteligentes de energia e será o primeiro estudo do grupo do GASI/UNESP com relação ao uso de tecnologias ativas (intrusivas) para o controle e gestão de energia em instalações residenciais.

Outras informações: Houve uma publicação no 10º CONICT - Congresso de Inovação, Ciência e Tecnologia do IFSP. A aluna está desenvolvendo o trabalho de graduação na mesma área, sob a coorientação do pesquisador.

10.1.2 Determinação de alertas de evasão de cliente numa empresa de software como serviço

Vigência (Início): De 01/02/2018 a 10/02/2019

Pesquisador responsável: Helmo Kelis Morales Paredes

Beneficiária: Otávio Giannotti Lunardi

Assunto(s): SaaS, XaaS, customer success, churn, orders, crm, usage fee, client health, confusion matrix, assertiveness, performance.

Resumo: O presente Trabalho de Graduação corresponde a um tipo estudo aplicado em ambientes de empresas de tecnologia e software como serviço denominado Churn Analysis. Tal estudo em sua maioria é realizado em empresas do segmento de Software como serviço, e tem por finalidade detectar em meio a base de clientes da empresa de tecnologia em questão, neste caso, denominada Goomer

(autoatendimento para restaurantes) quais deles permanecerão ativos e quais deles sinalizarão quebra de contrato de acordo com o resultado da submissão dos dados referentes ao perfil característico de cada cliente, quantidade de pedidos enviados por licença e taxa de uso de licenças a algoritmos de aprendizagem de máquina, responsáveis por aprender os padrões comportamentais das bases de clientes e classificar os dados submetidos ao modelo criado em Ativo e Churn. Ao fim do projeto, serão determinados três classificadores, cada um com modelo aplicado a uma das bases de dados que serão apresentadas, os quais apresentarão o melhor desempenho e assertividade na classificação, de acordo com o principal objetivo proposto.

Outras informações: Tal trabalho foi base para o trabalho de graduação, sob a orientação do pesquisador (o orientador se encontrava em período de pós-doutorado no exterior e o pesquisador se tornou o orientador do aluno).

10.2 Coorientações de Mestrado

10.2.1 Medidor cognitivo de energia para aplicações em eficiência energética

Aluno: Fernando Deluno Garcia

Orientador: Prof. Dr. Fernando Pinhabel Marafão

Coorientador: Wesley Angelino de Souza

Período: 2016-2018

Descrição: Este trabalho apresenta o desenvolvimento de um medidor cognitivo de energia elétrica, enfatizando sua aplicação para avaliação da eficiência energética e consumo padrão de eletrodomésticos classificados pelo PROCEL e de acordo com a Etiqueta Nacional de Conservação de Energia. Para tal, é proposta uma metodologia de desagregação do consumo de energia que possibilita estimar o consumo individual de cada eletrodoméstico em uma residência. Os eletrodomésticos são classificados e identificados a partir de indicadores que caracterizam a operação de um equipamento, sendo calculados através das formas de onda de tensão e corrente e da Teoria de Potência Conservativa (CPT). Com isso, foi criada uma base de dados composta por indicadores de diversos eletrodomésticos para que se pudesse identificá-los a partir do algoritmo K-enésimo vizinho mais próximo (KNN). Tendo em vista o engajamento do consumidor residencial em relação aos seus hábitos de consumo,

o trabalho proposto faz uso do medidor cognitivo de energia elétrica para fornecer recomendações e diagnósticos sobre os eletrodomésticos utilizados na residência. Por fim, o teste do protótipo possibilitou validar a metodologia proposta, estabelecendo um novo conceito e aplicação de medidores inteligentes de energia.

10.2.2 Metodologia para desagregação de cargas em instalações residenciais através de medidores cognitivos de energia

Aluno: Felipe Leite Paes

Orientador: Prof. Dr. Fernando Pinhabel Marafão

Coorientador: Wesley Angelino de Souza

Período: 2016-2018

Descrição: As redes inteligentes de energia indicam para uma nova arquitetura dos sistemas de distribuição de energia elétrica, a qual deve se consolidar nas próximas décadas, em um cenário repleto de dispositivos e sistemas dotados de "inteligência". Atualmente, os medidores inteligentes de energia possibilitam a integração e comunicação dos dispositivos em uma rede de dados, propiciando a concepção de uma rede inteligente de energia. Neste contexto, o medidor cognitivo de energia vem sendo apresentado como a evolução do medidor inteligente de energia e tem como diferencial a capacidade de desagregação de cargas, que do ponto de vista de redes inteligentes de energia pode fornecer informações importantes para sua operação. Assim, esse trabalho propõe uma metodologia de desagregação de cargas para o medidor cognitivo de energia em um cenário com cargas monofásicas, bifásicas e trifásicas. O estudo inclui a criação de uma base de dados para cargas bifásicas, implementação de um sistema de monitoramento / detecção de eventos com identificação das fases ligadas ao evento e o processo de classificação do KNN, que a partir da base de dados consegue desagregar as cargas nesse novo cenário.

10.3 Coorientações de Doutorado

10.3.1 Medidores Cognitivos de energia e aplicações em gerenciamento de energia elétrica

Aluno: Fernando Deluno Garcia

Orientador: Prof. Dr. Fernando Pinhabel Marafão

Coorientador: Wesley Angelino de Souza

Período: 2018 - Atual

Descrição: Tese de doutorado em andamento. Redes Elétricas Inteligentes é um tema amplamente discutido em todo o mundo, com o objetivo de desenvolver técnicas, produtos e padrões que permitam monitorar e gerenciar o fluxo de energia de forma eficaz. No cenário residencial, o consumo de energia elétrica pode ser reduzido com a utilização de dispositivos de monitoramento. Isso se torna possível com a substituição dos medidores convencionais para os chamados inteligentes. Nesse contexto, a literatura sugere que desagregação do consumo de cargas tem potencial para fornecer informações detalhadas de consumo de energia elétrica. Com isso, o medidor de energia pode ser utilizado como ferramenta para fornecer sugestões de consumo, com base em informações extraídas pelo monitoramento de cargas e do conhecimento de hábitos dos consumidores. Considerando que o tema de pesquisa é recente e com problemas em aberto, este projeto de doutorado propõe o desenvolvimento de técnicas de detecção de eventos e extração de assinaturas de cargas, baseando-se em atributos relativos à corrente elétrica para realizar o reconhecimento de cargas diretamente no medidor de energia.

Referências

[1] G. R. Barai, S. Krishnan, and B. Venkatesh. Smart metering and functionalities of smart meters in smart grid - a review. In *2015 IEEE Electrical Power and Energy Conference (EPEC)*, pages 138–145, Oct 2015. doi: 10.1109/EPEC.2015.7379940.

[2] S. Makonin, F. Popowich, and B. Gill. The cognitive power meter: Looking beyond the smart meter. In *2013 26th IEEE Canadian Conference on Electrical and Computer Engineering (CCECE)*, pages 1–5, May 2013. doi: 10.1109/CCECE.2013.6567686.

[3] G. Platt, S. West, and T. Moore. The real-world challenges and opportunities of distributed generation. In *2015 IEEE Energy Conversion Congress and Exposition (ECCE)*, pages 1112–1116, Sept 2015. doi: 10.1109/ECCE.2015.7309814.

[4] W. A. Souza, F. P. Marafao, E. V. Liberado, I. S. Diniz, and P. J. A. Serni. Power quality, smart meters and additional information from different power terms. *IEEE Latin America Transactions*, 13(1):158–165, Jan 2015. ISSN 1548-0992. doi: 10.1109/TLA.2015.7040643.

[5] J. Zheng, D. W. Gao, and L. Lin. Smart meters in smart grid: An overview. In *2013 IEEE Green Technologies Conference (GreenTech)*, pages 57–64, April 2013. doi: 10.1109/GreenTech.2013.17.

[6] I. Opris and L. Caracasian. The relation between smart meters and electricity consumers. In *2013 12th International Conference on Environment and Electrical Engineering*, pages 325–329, May 2013. doi: 10.1109/EEEIC.2013.6549536.

[7] Javier Leiva, Alfonso Palacios, and JosÃ© A. Aguado. Smart metering trends, implications and necessities: A policy review. *Renewable and Sustainable Energy Reviews*, 55:227 – 233, 2016. ISSN 1364-0321. doi: 10.1016/j.rser.2015.11.002.

[8] I. Opris and L. Caracasian. On the implementation of the functionalities of smart metering systems. In *2013 8TH INTERNATIONAL SYMPOSIUM ON ADVANCED TOPICS IN ELECTRICAL ENGINEERING (ATEE)*, pages 1–6, May 2013. doi: 10.1109/ATEE.2013.6563366.

[9] K. Basu, V. Debusschere, S. Bacha, U. Maulik, and S. Bondyopadhyay. Nonintrusive load

monitoring: A temporal multilabel classification approach. *IEEE Transactions on Industrial Informatics*, 11(1):262–270, Feb 2015. ISSN 1551-3203. doi: 10.1109/TII.2014.2361288.

[10] M. Dong, P. C. M. Meira, W. Xu, and W. Freitas. An event window based load monitoring technique for smart meters. *IEEE Transactions on Smart Grid*, 3(2):787–796, June 2012. ISSN 1949-3053. doi: 10.1109/TSG.2012.2185522.

[11] G. W. Hart. Nonintrusive appliance load monitoring. *Proceedings of the IEEE*, 80(12):1870–1891, Dec 1992. ISSN 0018-9219. doi: 10.1109/5.192069.

[12] F. D. Garcia, F. P. Marafao, W. A. d. Souza, and L. C. P. d. Silva. Power metering: History and future trends. In *2017 Ninth Annual IEEE Green Technologies Conference (GreenTech)*, pages 26–33, March 2017. doi: 10.1109/GreenTech.2017.10.

[13] M. Rathmair and J. Haase. Load identification and management framework for private households. In *IECON 2013 - 39th Annual Conference of the IEEE Industrial Electronics Society*, pages 5729–5734, Nov 2013. doi: 10.1109/IECON.2013.6700073.

[14] I. Abubakar, S.N. Khalid, M.W. Mustafa, Hussain Shareef, and M. Mustapha. Application of load monitoring in appliances' energy management - a review. *Renewable and Sustainable Energy Reviews*, 67:235–245, 2017. ISSN 1364-0321. doi: https://doi.org/10.1016/j.rser.2016.09.064.

[15] M.R. Durling, Z. Ren, N. Visnevski, and L.E. Ray. Cognitive electric power meter, 2010.

[16] M. Zeifman. Disaggregation of home energy display data using probabilistic approach. *IEEE Transactions on Consumer Electronics*, 58(1):23–31, February 2012. ISSN 0098-3063. doi: 10.1109/TCE.2012.6170051.

[17] R. A. S. Fernandes, I. N. da Silva, and M. Oleskovicz. Load profile identification interface for consumer online monitoring purposes in smart grids. *IEEE Transactions on Industrial Informatics*, 9(3):1507–1517, Aug 2013. ISSN 1551-3203. doi: 10.1109/TII.2012.2234469.

[18] W. A. Souza. *Estudo de Tecnicas de Analise e Tecnologias para o Desenvolvimento de Medidores Inteligentes de Energia Residenciais*. PhD thesis, FEEC/UNICAMP, 2016.

[19] D. Alahakoon and X. Yu. Smart electricity meter data intelligence for future energy systems: A survey. *IEEE Transactions on Industrial Informatics*, 12(1):425–436, Feb 2016. ISSN 1551-3203. doi: 10.1109/TII.2015.2414355.

[20] K. Carrie Armel, Abhay Gupta, Gireesh Shrimali, and Adrian Albert. Is disaggregation the holy grail of energy efficiency? the case of electricity. *Energy Policy*, 52:213–234, 2013. ISSN 0301-4215. doi: https://doi.org/10.1016/j.enpol.2012.08.062. Special Section: Transition Pathways to a Low Carbon Economy.

[21] A. Ipakchi and F. Albuyeh. Grid of the future. *IEEE Power and Energy Magazine*, 7(2):52–62, March 2009. ISSN 1540-7977. doi: 10.1109/MPE.2008.931384.

[22] Companies offering nilm products and services, 2018.

[23] Hampden Kuhns, Peter R Edwards, George Nikolich, and Morien W Roberts. Utility monitoring and disaggregation systems and methods of use, February 8 2011. US Patent 7,885,917.

[24] W. A. Souza, F. P. Marafão, E. V. Liberado, M. G. Simões, and Luiz C. P. Silva. A nilm dataset for cognitive meters based on conservative power theory and pattern recognition techniques. *Journal of Control, Automation and Electrical Systems*, 29(6):742–755, Dec 2018. ISSN 2195-3899. doi: 10.1007/s40313-018-0417-4. URL `https://doi.org/10.1007/s40313-018-0417-4`.

[25] L. C. Saikia, H. Das, N. B. Dev Choudhury, and T. Malakar. Gprs enabled smart energy meter with in-home display and application of time of use pricing. In *2016 IEEE Annual India Conference (INDICON)*, pages 1–5, Dec 2016. doi: 10.1109/INDICON.2016.7839068.

[26] Mario E. Berges, Ethan Goldman, H. Scott Matthews, and Lucio Soibelman. Enhancing electricity audits in residential buildings with nonintrusive load monitoring. *Journal of Industrial Ecology*, 14(5):844–858, 2010. doi: 10.1111/j.1530-9290.2010.00280.x.

[27] Prodist—Procedimentos de Distribuição. Módulo 8–qualidade da energia elétrica. *Agência Nacional de Energia Elétrica–ANEEL.*, 2018.

[28] H. R. P. M. de Oliveira, C. E. C. Figueiredo, N. C. de Jesus, E. X. Batista, and M. L. B. Martinez. Analysis of power quality problems in low-voltage circuits. In *2004 11th International*

Conference on Harmonics and Quality of Power (IEEE Cat. No.04EX951), pages 174–179, Sep. 2004. doi: 10.1109/ICHQP.2004.1409349.

[29] K. S. K. Weranga, D. P. Chandima, and S. P. Kumarawadu. Smart metering for next generation energy efficiency amp; conservation. In *IEEE PES Innovative Smart Grid Technologies*, pages 1–8, May 2012. doi: 10.1109/ISGT-Asia.2012.6303334.

[30] S. Barker, S. Kalra, D. Irwin, and P. Shenoy. Empirical characterization, modeling, and analysis of smart meter data. *IEEE Journal on Selected Areas in Communications*, 32(7):1312–1327, July 2014. ISSN 0733-8716. doi: 10.1109/JSAC.2014.2332107.

[31] F. D. Garcia, F. P. Marafão, W. A. d. Souza, and L. C. P. d. Silva. Power metering: History and future trends. In *2017 Ninth Annual IEEE Green Technologies Conference (GreenTech)*, pages 26–33, March 2017. doi: 10.1109/GreenTech.2017.10.

[32] Y. Xu and J. V. Milanović. Artificial-intelligence-based methodology for load disaggregation at bulk supply point. *IEEE Transactions on Power Systems*, 30(2):795–803, March 2015. ISSN 0885-8950. doi: 10.1109/TPWRS.2014.2337872.

[33] Paolo Tenti, Helmo Kelis Morales Paredes, and Paolo Mattavelli. Conservative power theory, a framework to approach control and accountability issues in smart microgrids. *IEEE Transactions on Power Electronics*, 26(3):664–673, 2011.

[34] F. Sultanem. Using appliance signatures for monitoring residential loads at meter panel level. *IEEE Transactions on Power Delivery*, 6(4):1380–1385, Oct 1991. ISSN 0885-8977. doi: 10.1109/61.97667.

[35] K. D. Anderson, M. E. Bergés, A. Ocneanu, D. Benitez, and J. M. F. Moura. Event detection for non intrusive load monitoring. In *IECON 2012 - 38th Annual Conference on IEEE Industrial Electronics Society*, pages 3312–3317, Montreal, Canadá, October 2012. IEEE.

[36] Antonio Ruano, Alvaro Hernandez, Jesus Ureña, Maria Ruano, and Juan Garcia. Nilm techniques for intelligent home energy management and ambient assisted living: A review. *Energies*, 12(11), 2019.

[37] C. Laughman, , R. Cox, S. Shaw, S. Leeb, L. Norford, and P. Armstrong. Power signature analysis. *IEEE Power and Energy Magazine*, 99(2):56–63, March 2003. ISSN 1540-7977. doi: 10.1109/MPAE.2003.1192027.

[38] M. Dong, P. C. M. Meira, W. Xu, and C. Y. Chung. Non-intrusive signature extraction for major residential loads. *IEEE Transactions on Smart Grid*, 4(3):1421–1430, September 2013.

[39] Karim Said Barsim, Roman Streubel, and Bin Yang. Unsupervised adaptive event detection for building-level energy disaggregation. Stuttgart, Alemanha, January 2014.

[40] Zhuang Zheng, Hainan Chen, and Xiaowei Luo. A supervised event-based non-intrusive load monitoring for non-linear appliances. *Sustainability*, 10, 2018.

[41] Kyle Anderson, Adrian Ocneanu, Derrick R. Carlson, Anthony Rowe, and Mario Bergés. BLUED : A fully labeled public dataset for event-based non-intrusive load monitoring research. In *Proceedings of the 2nd KDD workshop on data mining applications in sustainability (SustKDD)*, Pequim, China, August 2012. ACM.

[42] B. Wild, K. S. Barsim, and B. Yang. A new unsupervised event detector for non-intrusive load monitoring. In *2015 IEEE Global Conference on Signal and Information Processing (GlobalSIP)*, pages 73–77, Orlando, Estados Unidos da América, December 2015. IEEE.

[43] M. Zeifman and K. Roth. Nonintrusive appliance load monitoring: Review and outlook. *IEEE Transactions on Consumer Electronics*, 57(1):76–84, February 2011. ISSN 0098-3063. doi: 10.1109/TCE.2011.5735484.

[44] Leslie K. Norford and Steven B. Leeb. Non-intrusive electrical load monitoring in commercial buildings based on steady-state and transient load-detection algorithms. *Energy and Buildings*, 24(1):51 – 64, 1996. ISSN 0378-7788. doi: https://doi.org/10.1016/0378-7788(95)00958-2. URL `http://www.sciencedirect.com/science/article/pii/0378778895009582`.

[45] H. Chang, C. Lin, and J. Lee. Load identification in nonintrusive load monitoring using steady-state and turn-on transient energy algorithms. In *The 2010 14th International Conference on Computer Supported Cooperative Work in Design*, Xangai, China, April 2010. IEEE.

[46] A. Zoha, A. Gluhak, M.A. Imran, and S. Rajasegarar. Non-intrusive load monitoring approaches for disaggregated energy sensing: A survey. *Sensors (Switzerland)*, 12(12):16838–16866, 2012.

[47] S. Drenker and A. Kader. Nonintrusive monitoring of electric loads. *IEEE Computer Applications in Power*, 12(4):47–51, Oct 1999. ISSN 0895-0156. doi: 10.1109/67.795138.

[48] Agnim I Cole and Alexander Albicki. Data extraction for effective non-intrusive identification of residential power loads. In *IMTC/98 Conference Proceedings. IEEE Instrumentation and Measurement Technology Conference. Where Instrumentation is Going (Cat. No. 98CH36222)*, volume 2, pages 812–815. IEEE, 1998.

[49] Somchai Biansoongnern and Boonyang Plungklang. Non-intrusive appliances load monitoring (nilm) for energy conservation in household with low sampling rate. *Procedia Computer Science*, 86:172 – 175, 2016. ISSN 1877-0509. doi: https://doi.org/10.1016/j.procs.2016.05.049. URL `http://www.sciencedirect.com/science/article/pii/S1877050916303854`. 2016 International Electrical Engineering Congress, iEECON2016, 2-4 March 2016, Chiang Mai, Thailand.

[50] Peng Xiao and Samuel Cheng. Neural network for NILM based on operational state change classification. *CoRR*, abs/1902.02675, 2019. URL `http://arxiv.org/abs/1902.02675`.

[51] J. T. Powers, B. Margossian, and B. A. Smith. Using a rule-based algorithm to disaggregate end-use load profiles from premise-level data. *IEEE Computer Applications in Power*, 4(2): 42–47, April 1991. ISSN 0895-0156. doi: 10.1109/67.75875.

[52] Linda Farinaccio and Radu Zmeureanu. Using a pattern recognition approach to disaggregate the total electricity consumption in a house into the major end-uses. *Energy and Buildings*, 30 (3):245 – 259, 1999. ISSN 0378-7788. doi: https://doi.org/10.1016/S0378-7788(99)00007-9. URL `http://www.sciencedirect.com/science/article/pii/S0378778899000079`.

[53] M.L. Marceau and R. Zmeureanu. Nonintrusive load disaggregation computer program to estimate the energy consumption of major end uses in residential buildings. *Energy Conversion and Management*, 41(13):1389 – 1403, 2000. ISSN 0196-8904. doi: https://doi.org/10.1016/S0196-8904(99)00173-9. URL `http://www.sciencedirect.com/science/article/pii/S0196890499001739`.

[54] M. Baranski and J. Voss. Genetic algorithm for pattern detection in nialm systems. In *2004 IEEE International Conference on Systems, Man and Cybernetics (IEEE Cat. No.04CH37583)*, volume 4, pages 3462–3468 vol.4, Oct 2004. doi: 10.1109/ICSMC.2004.1400878.

[55] A. G. Ruzzelli, C. Nicolas, A. Schoofs, and G. M. P. O'Hare. Real-time recognition and profiling of appliances through a single electricity sensor. In *2010 7th Annual IEEE Communications Society Conference on Sensor, Mesh and Ad Hoc Communications and Networks (SECON)*, pages 1–9, June 2010. doi: 10.1109/SECON.2010.5508244.

[56] Jack Kelly and William Knottenbelt. Neural nilm: Deep neural networks applied to energy disaggregation. In *Proceedings of the 2Nd ACM International Conference on Embedded Systems for Energy-Efficient Built Environments*, BuildSys '15, pages 55–64, New York, NY, USA, 2015. ACM. ISBN 978-1-4503-3981-0. doi: 10.1145/2821650.2821672. URL `http://doi.acm.org/10.1145/2821650.2821672`.

[57] Marisa B. Figueiredo, Ana de Almeida, and Bernardete Ribeiro. An experimental study on electrical signature identification of non-intrusive load monitoring (nilm) systems. In Andrej Dobnikar, Uroš Lotrič, and Branko Šter, editors, *Adaptive and Natural Computing Algorithms*, pages 31–40, Berlin, Heidelberg, 2011. Springer Berlin Heidelberg. ISBN 978-3-642-20267-4.

[58] D. Srinivasan, W. S. Ng, and A. C. Liew. Neural-network-based signature recognition for harmonic source identification. *IEEE Transactions on Power Delivery*, 21(1):398–405, Jan 2006. ISSN 0885-8977. doi: 10.1109/TPWRD.2005.852370.

[59] S. R. Shaw, S. B. Leeb, L. K. Norford, and R. W. Cox. Nonintrusive load monitoring and diagnostics in power systems. *IEEE Transactions on Instrumentation and Measurement*, 57(7): 1445–1454, July 2008. ISSN 0018-9456. doi: 10.1109/TIM.2008.917179.

[60] Aggelos S. Bouhouras, Paschalis A. Gkaidatzis, Evangelos Panagiotou, Nikolaos Poulakis, and Georgios C. Christoforidis. A nilm algorithm with enhanced disaggregation scheme under harmonic current vectors. *Energy and Buildings*, 183:392 – 407, 2019. ISSN 0378-7788. doi: https://doi.org/10.1016/j.enbuild.2018.11.013. URL `http://www.sciencedirect.com/science/article/pii/S0378778817340094`.

[61] Hsueh-Hsien Chang. Non-intrusive demand monitoring and load identification for energy ma-

nagement systems based on transient feature analyses. *Energies*, 5(11):4569–4589, 2012. ISSN 1996-1073. doi: 10.3390/en5114569. URL http://www.mdpi.com/1996-1073/5/11/4569.

[62] Shunfu Lin, Lunjia Zhao, Fangxing Li, Qingqiang Liu, Dongdong Li, and Yang Fu. A nonintrusive load identification method for residential applications based on quadratic programming. *Electric Power Systems Research*, 133:241 – 248, 2016. ISSN 0378-7796. doi: https://doi.org/10.1016/j.epsr.2015.12.014. URL http://www.sciencedirect.com/science/article/pii/S0378779615003910.

[63] D. F. Teshome, T. D. Huang, and K. Lian. Distinctive load feature extraction based on fryze's time-domain power theory. *IEEE Power and Energy Technology Systems Journal*, 3(2):60–70, June 2016. ISSN 2332-7707. doi: 10.1109/JPETS.2016.2559507.

[64] M. Nguyen, S. Alshareef, A. Gilani, and W. G. Morsi. A novel feature extraction and classification algorithm based on power components using single-point monitoring for nilm. In *2015 IEEE 28th Canadian Conference on Electrical and Computer Engineering (CCECE)*, pages 37–40, May 2015. doi: 10.1109/CCECE.2015.7129156.

[65] T. D. Huang, W. Wang, and K. Lian. A new power signature for nonintrusive appliance load monitoring. *IEEE Transactions on Smart Grid*, 6(4):1994–1995, July 2015. ISSN 1949-3053. doi: 10.1109/TSG.2015.2415456.

[66] W. L. Chan, A. T. P. So, and L. L. Lai. Harmonics load signature recognition by wavelets transforms. In *DRPT2000. International Conference on Electric Utility Deregulation and Restructuring and Power Technologies. Proceedings (Cat. No.00EX382)*, pages 666–671, April 2000. doi: 10.1109/DRPT.2000.855745.

[67] Y. Su, K. Lian, and H. Chang. Feature selection of non-intrusive load monitoring system using stft and wavelet transform. In *2011 IEEE 8th International Conference on e-Business Engineering*, pages 293–298, Oct 2011. doi: 10.1109/ICEBE.2011.49.

[68] C. Duarte, P. Delmar, K. W. Goossen, K. Barner, and E. Gomez-Luna. Non-intrusive load monitoring based on switching voltage transients and wavelet transforms. In *2012 Future of Instrumentation International Workshop (FIIW) Proceedings*, pages 1–4, Oct 2012. doi: 10.1109/FIIW.2012.6378333.

[69] M. Gray and W. G. Morsi. Application of wavelet-based classification in non-intrusive load monitoring. In *2015 IEEE 28th Canadian Conference on Electrical and Computer Engineering (CCECE)*, pages 41–45, May 2015. doi: 10.1109/CCECE.2015.7129157.

[70] S. M. Tabatabaei, S. Dick, and W. Xu. Toward non-intrusive load monitoring via multi-label classification. *IEEE Transactions on Smart Grid*, 8(1):26–40, Jan 2017. ISSN 1949-3053. doi: 10.1109/TSG.2016.2584581.

[71] J. M. Gillis, S. M. Alshareef, and W. G. Morsi. Nonintrusive load monitoring using wavelet design and machine learning. *IEEE Transactions on Smart Grid*, 7(1):320–328, Jan 2016. ISSN 1949-3053. doi: 10.1109/TSG.2015.2428706.

[72] T. Hassan, F. Javed, and N. Arshad. An empirical investigation of v-i trajectory based load signatures for non-intrusive load monitoring. *IEEE Transactions on Smart Grid*, 5(2):870–878, March 2014. ISSN 1949-3053. doi: 10.1109/TSG.2013.2271282.

[73] L. Du, D. He, R. G. Harley, and T. G. Habetler. Electric load classification by binary voltage–current trajectory mapping. *IEEE Transactions on Smart Grid*, 7(1):358–365, Jan 2016. ISSN 1949-3053. doi: 10.1109/TSG.2015.2442225.

[74] J. Gao, E. C. Kara, S. Giri, and M. Bergés. A feasibility study of automated plug-load identification from high-frequency measurements. In *2015 IEEE Global Conference on Signal and Information Processing (GlobalSIP)*, pages 220–224, Dec 2015. doi: 10.1109/GlobalSIP.2015.7418189.

[75] Leen De Baets, Joeri Ruyssinck, Chris Develder, Tom Dhaene, and Dirk Deschrijver. Appliance classification using vi trajectories and convolutional neural networks. *Energy and Buildings*, 158:32 – 36, 2018. ISSN 0378-7788. doi: https://doi.org/10.1016/j.enbuild.2017.09.087. URL `http://www.sciencedirect.com/science/article/pii/S0378778817312690`.

[76] Shwetak N. Patel, Thomas Robertson, Julie A. Kientz, Matthew S. Reynolds, and Gregory D. Abowd. At the flick of a switch: Detecting and classifying unique electrical events on the residential power line (nominated for the best paper award). In John Krumm, Gregory D. Abowd, Aruna Seneviratne, and Thomas Strang, editors, *UbiComp 2007: Ubiquitous Computing*, pages 271–288, Berlin, Heidelberg, 2007. Springer Berlin Heidelberg. ISBN 978-3-540-74853-3.

[77] Sidhant Gupta, Matthew S. Reynolds, and Shwetak N. Patel. Electrisense: Single-point sensing using emi for electrical event detection and classification in the home. In *Proceedings of the 12th ACM International Conference on Ubiquitous Computing*, UbiComp '10, pages 139–148, New York, NY, USA, 2010. ACM. ISBN 978-1-60558-843-8. doi: 10.1145/1864349.1864375. URL `http://doi.acm.org/10.1145/1864349.1864375`.

[78] Hyungsul Kim, Manish Marwah, Martin Arlitt, Geoff Lyon, and Jiawei Han. *Unsupervised Disaggregation of Low Frequency Power Measurements*, pages 747–758. 2011. doi: 10.1137/1.9781611972818.64. URL `https://epubs.siam.org/doi/abs/10.1137/1.9781611972818.64`.

[79] G. C. Koutitas and L. Tassiulas. Low cost disaggregation of smart meter sensor data. *IEEE Sensors Journal*, 16(6):1665–1673, March 2016. ISSN 1530-437X. doi: 10.1109/JSEN.2015.2501422.

[80] J. M. Gillis and W. G. Morsi. Non-intrusive load monitoring using semi-supervised machine learning and wavelet design. *IEEE Transactions on Smart Grid*, 8(6):2648–2655, Nov 2017. ISSN 1949-3053. doi: 10.1109/TSG.2016.2532885.

[81] A. K. Jain, S. S. Ahmed, P. Sundaramoorthy, R. Thiruvengadam, and V. Vijayaraghavan. Current peak based device classification in nilm on a low-cost embedded platform using extra-trees. In *2017 IEEE MIT Undergraduate Research Technology Conference (URTC)*, pages 1–4. IEEE, 2017.

[82] James Clerk Maxwell. Viii. a dynamical theory of the electromagnetic field. *Philosophical transactions of the Royal Society of London*, (155):459–512, 1865.

[83] CI Budeanu. The different options and conceptions regarding active power in nonsinusoidal systems. *Instytut Romain de l'Energie*, 4, 1927.

[84] S Fryze. Moc rzeczywista, urojona i pozorna w obwodach elektrycznych o przebiegach odkształconych prądu i napięcia. *Przegląd Elektrotechniczny*, 7:193–203, 1931.

[85] Paolo Tenti and Paolo Mattavelli. A time-domain approach to power term definitions under non-sinusoidal conditions. In *Sixth international workshop on power definitions and measurements under non-sinusoidal conditions*, number 35, page 34, 2003.

[86] OF DELMONT, EF ARRUDA, M OLESKOVICZ, AAFM CARNEIRO, and DV COURY. Utilização da transformada wavelet e rnas para caracterização de distúrbios na qualidade da energia elétrica. *Seminário Brasileiro sobre Qualidade da Energia Elétrica*, 5:381–386, 2003.

[87] Hélio de Oliveira Magalhães. Análise de sinais para engenheiros: Uma abordagem via wavelet, 2007.

[88] H. Chang, K. Lian, Y. Su, and W. Lee. Power-spectrum-based wavelet transform for nonintrusive demand monitoring and load identification. *IEEE Transactions on Industry Applications*, 50(3):2081–2089, May 2014. ISSN 0093-9994. doi: 10.1109/TIA.2013.2283318.

[89] Katti Faceli, Ana Carolina Lorena, João Gama, André Carlos Ponce de Leon Carvalho, et al. Inteligência artificial: Uma abordagem de aprendizado de máquina. 2011.

[90] Ron Kohavi et al. A study of cross-validation and bootstrap for accuracy estimation and model selection. In *Ijcai*, volume 14, pages 1137–1145. Montreal, Canada, 1995.

[91] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.

[92] David MW Powers. What the f-measure doesn't measure: Features, flaws, fallacies and fixes. *arXiv preprint arXiv:1503.06410*, 2015.

[93] Thomas M Cover, Peter E Hart, et al. Nearest neighbor pattern classification. *IEEE transactions on information theory*, 13(1):21–27, 1967.

[94] Belur V Dasarathy. Nearest neighbor ({NN}) norms:{NN} pattern classification techniques. 1991.

[95] M. Rahmatian, B. Vahidi, A.J. Ghanizadeh, G.B. Gharehpetian, and H.A. Alehosseini. Insulation failure detection in transformer winding using cross-correlation technique with ann and k-nn regression method during impulse test. *International Journal of Electrical Power and Energy Systems*, 53:209 – 218, 2013. ISSN 0142-0615. doi: https://doi.org/10.1016/j.ijepes.2013.04.020. URL `http://www.sciencedirect.com/science/article/pii/S0142061513001889`.

[96] Piotr Indyk and Rajeev Motwani. Approximate nearest neighbors: towards removing the curse of dimensionality. In *Proceedings of the thirtieth annual ACM symposium on Theory of computing*, pages 604–613. ACM, 1998.

[97] Tin Kam Ho. The random subspace method for constructing decision forests. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 20(8):832–844, Aug 1998. ISSN 0162-8828. doi: 10.1109/34.709601.

[98] Eugene M Kleinberg. On the algorithmic implementation of stochastic discrimination. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(5):473–490, 2000.

[99] Vladimir Vapnik. *The nature of statistical learning theory*. Springer science & business media, 2013.

[100] Sistema de informações de posses de eletrodomésticos e hábitos de consumo - curvas de carga distribuídos por regiões, 2005. URL `http://www.procelinfo.com.br/Sinpha/Sobre.asp`.

[101] Antonio Ridi, Christophe Gisler, and Jean Hennebert. A survey on intrusive load monitoring for appliance recognition. *22nd International Conference on Pattern Recognition*, 2014.

[102] R. B. Cardoso. Avaliação da economia de energia atribuída ao programa selo procel em freezers e refrigeradores. Dissertação de mestrado, Federal University of Itajuba, 2008.

11 Anexo I – Artigos publicados em periódicos no período de pós-doutorado

energies

MDPI

Article

Load Disaggregation Using Microscopic Power Features and Pattern Recognition

Wesley Angelino de Souza [1], Fernando Deluno Garcia [2], Fernando Pinhabel Marafão [2,*], Luiz Carlos Pereira da Silva [3] and Marcelo Godoy Simões [4,*]

1 Department of Computer Science, Federal University of São Carlos (UFSCar), Sorocaba SP 18052-780, Brazil
2 Institute of Science and Technology of Sorocaba, São Paulo State University (UNESP), Sorocaba SP 18087-180, Brazil
3 School of Electrical and Computer Engineering (FEEC), University of Campinas (UNICAMP), Campinas SP 13083-852, Brazil
4 Department of Electrical Engineering, Colorado School of Mines, Golden, CO 80401, USA
* Correspondence: fernando.marafao@unesp.br (F.P.M.); msimoes@mines.edu (M.G.S.)

Received: 29 May 2019; Accepted: 5 July 2019; Published: 10 July 2019

Abstract: A new generation of smart meters are called cognitive meters, which are essentially based on Artificial Intelligence (AI) and load disaggregation methods for Non-Intrusive Load Monitoring (NILM). Thus, modern NILM may recognize appliances connected to the grid during certain periods, while providing much more information than the traditional monthly consumption. Therefore, this article presents a new load disaggregation methodology with microscopic characteristics collected from current and voltage waveforms. Initially, the novel NILM algorithm—called the Power Signature Blob (PSB)—makes use of a state machine to detect when the appliance has been turned on or off. Then, machine learning is used to identify the appliance, for which attributes are extracted from the Conservative Power Theory (CPT), a contemporary power theory that enables comprehensive load modeling. Finally, considering simulation and experimental results, this paper shows that the new method is able to achieve 95% accuracy considering the applied data set.

Keywords: load disaggregation; artificial intelligence; cognitive meters; machine learning; state machine; NILM

1. Introduction

Eectricity metering has undergone significant technological progress over the last 30 years, from electromechanical to electronic metering. An essential stage of this evolution arose with Automatic Meter Reading (AMR) [1], which includes the following main features [2,3]:

- Improved accuracy in terms of energy readings when compared to the preceding electromechanical meters, in which the measuring errors were quite susceptive and dependent on human operators;
- Automatic and frequent meter readings;
- Customer support improvement;
- More consumption information;
- Support to hourly price charges.

Moreover, the AMR was the basis for the succeeding evolution called Advanced Metering Infrastructure (AMI), which includes the following characteristics [4–6]:

- Bidirectional communication;
- A power consumption monitoring system;

- Advanced and accurate sensors;
- The embedded system is responsible for data collection and manages the required information between meter and utility.

AMI is related to the entire metering infrastructure and 'smart meter' is the popular name for the power metering device in this infrastructure. The term "smart" makes sense in the data processing approach, that is, the meter might process input data (voltage and current), transforming it into useful output information (e.g., energy consumption, power quality indicators, efficiency, and others). However, the concept of "smart" is not usually well defined, since most of the smart meters on the market do not have any smart functionality. Thus, there is a current demand for innovative and intelligent techniques to provide different sorts of information to utilities and consumers, improving their knowledge about energy use, efficiency, costs, consequently improving energy management. Therefore, researchers all over the world are proposing new tools and methods to provide further information about energy consumption [7,8], as well as proposing innovative ways to save energy [9–12].

In this context, a new generation of smart meters are called cognitive meters, which propose to use artificial intelligence and load disaggregation methods, also known as Non-Intrusive Load Monitoring (NILM). They recognize appliances connected to the grid during certain periods, while providing much more information to consumers than the traditional monthly consumption. Consequently, consumers' operations can be inspected to provide them with detailed information about their electrical consumption [13] so they can make better decisions concerning saving electricity, as well as implementing energy management systems for automatic generation/consumption regulation. This is certainly a meaningful advance concerning the relationship between utilities and consumers [11–13]. Moreover, "c-meters" can provide advanced functionalities, such as detailed recommendation of when to use some particular appliances (according to statistical behavior, real-time consumption or hourly-energy price) and they can also suggest some tip to save electricity over weeks, months and years.

Hart [14] initially introduced the NILM method, considering active power levels and distributing them into individual appliance data. With such a type of cognition, the consumer profile can be mapped and by using artificial intelligence techniques, new methodologies can be proposed for modern smart meters [7,8,10,14–22]. However, although NILM is quite a good approach to detect home appliances, it does not always present a reasonable accuracy, demanding other signal analysis or AI to improve detection accuracy.

Therefore, this paper introduces the Power Signature Blob (PSB)—a novel methodology that correlates a hybrid load disaggregation technique, which is based on feature extraction from current and voltage waveforms with power signatures. In this context, a predefined threshold level is compared to the active power variation, in addition to the power signatures. The procedure uses the difference between the actual active power and the last active power value used to define the step level direction—when the appliance is turned on or turned off. Considering that every step level detection is a new event, the novel NILM method calculates the proper features to classify the load and then, applies machine learning for appliance recognition. For classification, the NILM dataset from [15] was used, including instances of 35 appliances (In this paper, the term sample is defined as a signal acquisition from the voltage and current waveforms, and the term instance represents a dataset sample with the respective features.). Each appliance instance comprises active power and other power components (power factor, reactivity factor, and distortion factor). The features to classify and from the dataset are calculated using a contemporary power theory called Conservative Power Theory (CPT) [23,24]. Hence, the novelty of this paper is a new state-machine NILM that uses and acknowledges a dataset of 35 appliances with features based on power components by the CPT.

The next section discusses the main concept of load disaggregation and different techniques from the literature. Afterwards, the PSB method, using the power decompositions from CPT [23–25], is presented. Finally, simulations and experimental results depict the performance of the proposed approach.

2. NILM State-of-the-Art Review

Considering current and voltage acquisition and processing, the literature on NILM can be divided into two main categories—"high-frequency" and "low-frequency". The low-frequency is the category in which the features are extracted at 1 kHz or less. The high-frequency is the category in which features are extracted at kHz or MHz [15,19]. Table 1 presents a list of NILM studies and the features extracted from the point of view of the attributes.

Table 1. Summary and categorization of some Non–Intrusive Load Monitoring (NILM) techniques—relevant works and their main features.

Sampling	Signal Sampling Technique	Features (Attributes)	References
Low-frequency (Macroscopic)	Active/reactive power signature and variation	P, Q	[14,26–30]
	Active power signature and variation	P	[31–34]
	Power signature and power indicators	P, I_{RMS},U_{RMS},I_{MAX},U_{MAX},$PF(\lambda)$	[35,36]
	Power signature and power quality indicators	P, $PF(\lambda)$	[37]
	Load on or off probability	P_{load}^{ON}, P_{load}^{OFF}	[38]
	Temporal discrete power pulses	$P_{pulse}(t)$	[39]
High-frequency (Microscopic)	Harmonic decomposition	P, Q, $H_{1,3,5,\cdots,N}$	[40–43]
	Power signature and harmonic decomposition	P, THD	[7,17]
	Power signatures and Power Theory	P, Q, S or A, H, I_f, $CPT_{components}$	[15,44–46]
	Wavelets	W_{coef},W_e	[19,47–53]
	Voltage and current trajectory	VI_{traj}	[18,54–56]
	Harmonic noise in power transients	H_f, $36 \leq f \leq 500Hz$	[57,58]
	Combination of independent features	VI_{traj}, $i(t)$, $p(t)$ and others	[17]

Note: P: active power; Q: reactive power; I_{RMS}: effective current; U_{RMS}: effective voltage; U_{MAX}: maximum voltage; I_{MAX}: maximum current; $PF(\lambda)$: power factor; P_{load}^{ON}: load on probability; P_{load}^{OFF}: load off probability; $P_{pulse}(t)$: time power pulse; $H_{1,3,5,\cdots,N}$: nth harmonic components (n = 1, 3, ..., N); THD: voltage or current total harmonic distortion; S or A: apparent power; H: harmonic power; I_f: inactive current; $CPT_{components}$: CPT power components; W_{coef}: wavelet coefficients; W_e: wavelet equivalent coefficients; VI_{traj}: voltage vs current trajectory; H_f: non-fundamental power components; $i(t)$: instantaneous current; $p(t)$: instantaneous power.

In 1992, Hart [14] did some pioneering work on load disaggregation, in which he defined Nonintrusive Appliance Load Monitoring (NALM)—NILM is a derivative term from NALM. Such work showed that it is possible to separate power consumption by appliances observing the collective power consumption. To do this, it is necessary to discover the power behavior of each load or appliance. For a long time, this research did not draw attention due to digital device limitations for embedded algorithms. At the same time, Sultanem [40] proposed a different algorithm to Hart's work and used the PQ trajectory with harmonic decomposition.

Considering the P-Q (active and reactive power) analysis, Drenker and Kader [26] validated their NILM method with six loads that operate in steady mode, obtaining an accuracy of around 95%. Cole and Albicki [27] studied the steady-state loads and some loads with slow power changing (such as heat pump compressors) and they considered the total consumption of each load as geometrical shape forms. Norford and Leeb [28] also detected transient status of some loads and created an approximation for these transient statuses. Biansoongnem and Plungklang [29] created a NILM method with 90% of accuracy when testing air conditioning and refrigerators. Using deep learning to detect operational load changes, Xiao and Cheng proposed a method and validated it using the Reference Energy Disaggregation Dataset (REDD) [59].

Powers et al. [31] applied a rule-based algorithm to detect loads with high consumption, such as air conditioning, water heaters and electric space heaters. Likewise, rule-based algorithms were proposed by Farinaccio and Zmeureanu [32] to detect power load behavior, as well as by Marceau and Zmeureanu [33] with the indication of 90% accuracy. With regards to genetic algorithms, Baranski and Voss [34] proposed their employment to detect patterns based on the use of loads frequency.

Ruzzelli et al. [35] created a dataset with low-frequency features of voltages and currents (I_{RMS}, V_{RMS}, I_{MAX}, V_{MAX}) and the power factor (PF) to describe load behavior, and with the P-Q analysis they carried out load disaggregation. Kelly and Knottenbelt [36] used a deep neural network for load disaggregation, as well as the UK Domestic Appliance-Level Electricity (UK-DALE) dataset [60], achieving an excellent performance for that dataset. Figueiredo et al. [37] used the load step changes in active power and the PF to create a dataset and concluded that there is a need to extract other attributes that can better detail the loads, especially those that have the same power and the same behavior as the equivalent circuit.

Kim et al. [38] combined frequency independent features, such as the distribution probability of ON/OFF duration, frequency of appliance usage and the correlation between the usage of various appliances with the active power feature, achieving between 64% to 99.8% accuracy in terms of load disaggregation. Koutitas and Tassiulas [39] replaced time-series power analysis for a set of discrete pulses. They created features based on pulses, such as variance, spike, slope, periodicity, multi-state, and sequence of operation. They reached an accuracy of 85%.

Sultanem [40] is the pioneer of the high-frequency use on NILM applications. Srinivasan et al. [41] used machine learning to recognize the harmonic signatures of 8 loads, and they obtained an accuracy of 99% or more for the load disaggregation. Laughman et al. [42] used the P-Q analysis for similar loads and increased the 3rd harmonic to distinguish them. Bouhouras et al. [43] used harmonic components to create a dataset for load disaggregation with stand-alone loads or combined loads, and the accuracy was between 85% and 95%.

Dong et al. [7] adopted Total Harmonic Distortion (THD) of current waveforms and P-Q analysis for load discrimination, and they used some pulse-based features. Lin et al. [17] created a NILM using features including the THD, P-Q analysis, voltage-current trajectory, current indicators and quadratic programming. The accuracy of this work is generally more than 90%.

Using power theory concepts, Teshome et al. [44] proposed a NILM with components of active, reactive, apparent power, and nonactive currents. Nguyen et al. [45] created a NILM method based on active, reactive and apparent power and used a decision tree (DT) to disaggregate five loads, achieving more than 98.8% accuracy. Huang et al. [46] pointed out that the application of power theories can be a useful tool for load disaggregation, especially for loads that have the same value of active power. In 2003, Tenti and Mattavelli [23,24] proposed the Conservative Power Theory, which allows load modelling in terms of power components. This work was the basis for the load characterization in the NILM dataset proposed by Souza et al. [15,25].

Considering the Continuous Wavelet Transform (CWT), Chan et al. [47] applied it up to the 4th level for the loads, and used *Daubechies* as mother wavelets, achieving an accuracy of 70%. Su et al. [48], and Duarte et al. [49] compared the Fast Fourier Transform (FFT) with CWT, pointing out the advantages of the CWT during load transients and recommended using CWT for feature extraction for load disaggregation. Chang et al. [52,53] implemented a NILM using active and reactive power with CWT. The authors extracted load features from five filters and applied a genetic algorithm for load identification. They reached almost 100% accuracy but the studies were carried out considering situations of significant discrepancy in power levels.

Gray and Morsi [50] used time-consuming energy to obtain CWT decomposition with Daubechies mother wavelets. The authors presented results comparing the accuracy of applying each order of the Daubechies order and concluded that the higher the Daubechie, the greater the accuracy. Tabatabaei [51] did a similar study, but used power characteristics to create classificatory features and obtained accuracy at around 85%. Gillis et al. [19] proposed a new CWT for NILM applications, obtaining around 94% accuracy for four connected loads at the same time.

Hassan et al. [54] created a NILM method based on V-I trajectory, which used wave-shape features along with the REDD dataset. Similarly, V-I trajectories were mapped to a grid of cells (as a matrix) by Du et al. [18], having a binary value assigned to each of them. On the other hand, 83% of accuracy was achieved by Gao et al. [55] by converting V-I trajectory into a binary image,

while using combined features, and considering 11 appliances. Finally, convolutional neural networks were proposed to be used with V-I trajectory by Baets et al. [56], reaching 77.6% of accuracy for the PLAID dataset [61], and 75.46% for the WHITED dataset [62]. Voltage harmonic (FFT) noise has also been used by Patel et al. [57,58], taking into account noise and electromagnetic interference in the range of 36 to 500 kHz. Nonetheless, such a study only highlighted the types of equipment that present multiple operational stages.

To summarize, there are many other studies regarding NILM with different methodologies, feature extraction, different appliances in the validation and different load disaggregation algorithms. Nevertheless, in Teshome et al. [44], the authors indicate the importance of modern power theories and the lack of these elegant circuit analyses to improve the NILM systems. One of these elegant power theories pointed out in Teshome et al. [44] was the CPT. Thus, such a modern power theory is applied in this work to improve the load disaggregation and present a novel NILM technique.

Accordingly, the next section presents the PSB, a new NILM methodology based on a state machine, which analyzes the active power signature (a low-frequency feature), and on the event detection, which finds features from the CPT and triggers the machine learning algorithm that uses the high-frequency attribute dataset proposed by Souza et al. [15].

3. The Power Signature Blob Method

3.1. Dataset with the Microscopic Features Extraction

In Souza et al. [15] some techniques for appliance disaggregation were evaluated, and the feasibility of identifying home appliances using pattern recognition algorithms was shown. Two pattern recognition algorithms achieved significant results: Optimum-Path Forest (OPF) [63] and K-Nearest Neighbor (KNN) [64] and the KNN (with $K = 1$) was chosen because of its lower computational time. The voltage and current waveforms from several appliances were measured and decomposed in power components using CPT [23,24]. The CPT allows splitting the power into active, reactive, unbalance and residual parts. These power components help to interpret an appliance as an equivalent circuit, as shown in Figure 1, where v_m is the phase voltage, the current i_{Gm} coincides with the active current, i_{Lm} coincides with the reactive current, and the current source j_m coincides with the void current. G_m is the equivalent phase conductance and could be represented as a resistance, L_m is the equivalent phase inductance and could be represented as an inductor. All the mathematical background of the equivalent circuit can be found in Reference [65].

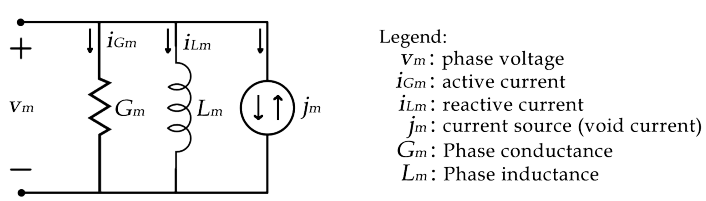

Figure 1. Load equivalent circuit by Conservative Power Theory (CPT).

Using the CPT power decomposition, Souza et al. [15] created a dataset of 35 home appliances such as irons, microwaves, refrigerators, washing machines, lamps and others. Each appliance features (CPT active power, power factor, reactivity factor, and nonlinearity factor [25]) refer to a set dimension and each collected instance as a point in the multidimensional space. The pattern recognition algorithm uses this dataset for the classification purpose of the appliance.

Figure 2 shows the Voronoi diagram concerning the 1NN results for the appliance dataset of [15], where each class number represents an appliance. It shows three Voronoi diagrams for the four attributes (P—Active power, PF—power factor, QF—reactivity factor, and VF—nonlinearity factor) from the dataset, presented in two dimensions to help visualize the decision boundaries.

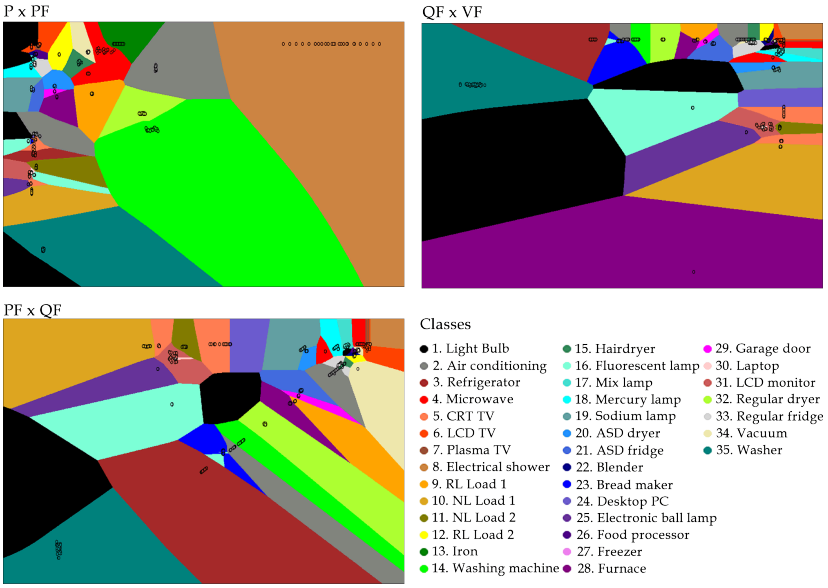

Figure 2. K-Nearest Neighbor (KNN) decision boundaries of the CPT appliance dataset.

The supervised classification algorithm identifies which appliances consume electricity, according to CPT power terms calculation. However, it is likely that some false positives could be detected (when the appliance is identified mistakenly due to the similarity with others, for example, a 100 W bulb lamp and a 100 W LCD TV with high power factor). Another potential issue concerns some appliances with multiple power stages during the power operation, such as washing machines (with washing, spinning and rinsing). This occurs because the classifier needs to observe various levels of "ON" and "OFF" and could not perform the correct classification. Some methodologies [7,8,10,16,22,37,42,66] were created to solve the multiple power steps problem, and both observe the appliance behavior during time operation. The load power signature is relevant because some appliances do not operate in steady-state, and the method needs to disaggregate with high accuracy. Thus, in Reference [15] there was a microscopic feature dataset for the load classification, but it is required to create a method to observe the appliance power behavior before using the appliance classification.

3.2. Load Power Signatures

As initially pointed out in Reference [14], each appliance has a power signature that is not necessarily a steady-state power, thus Figure 3 presents different appliances' power behaviors, and the appliances can be classified using power signatures [7,10,14,16,22], as shown in Figure 4.

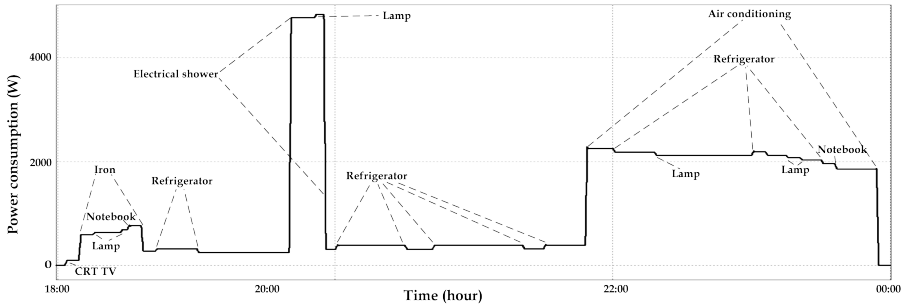

Figure 3. Individual appliance events.

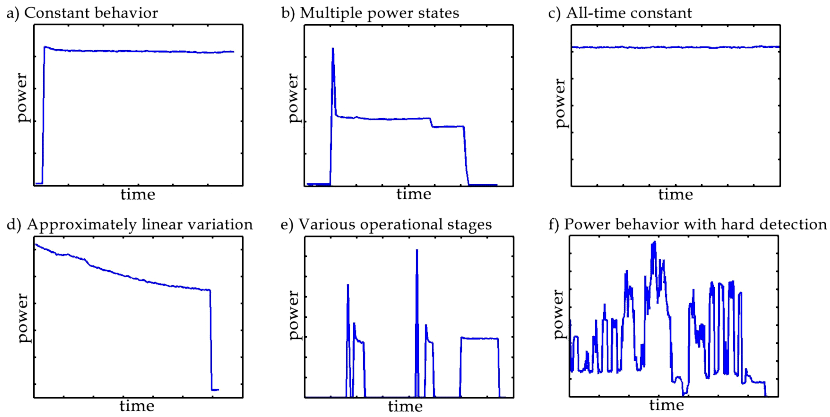

Figure 4. Different appliance power signatures. (**a**) Constant behavior; (**b**) Multiple power states; (**c**) All-time constant; (**d**) Approximately linear variation; (**e**) Various operational stages; and (**f**) Power behavior with hard detection.

From Figure 4, an appliance can have a power signature with:

(a) Constant behavior: In this case, the appliance has steady power behavior over time. It has a high probability of being an appliance with the resistive equivalent circuit, or the appliance is in steady state;
(b) Multiple power states: The appliance has a high-power peak when starting the operation. This characteristic could be linked to a starting engine, and after such a power step, it presents some power variations without turning off. This case can be related to a motorized appliance such as a washing machine;
(c) All-time constant: in this case, the appliance is always connected as a standby mode device;
(d) Approximately linear variation: in this case, there is a linear power variation over time. This variation corresponds to a transitional period until stabilization, such as by temperature (such as an iron) or gas (such as mercury lamp);
(e) Various operational stages: Some appliances have several power characteristics over time, which can be inductive, resistive or non-linear, etc. Besides, the power could also be switched on and off during the operation. For example, a clothes dryer has a motor that can rotate at different speeds and can also have a heating system to facilitate the drying process;
(f) Power behaviors with hard sequence detection: This type of appliance is usually electronic, and there are several fast operation stages, making it difficult to recognize the power signature

over time. The noises from current and voltage sensors are also aggregated into this power signature category. The printer is an example of this type of load, which has some power steps that vary and switch very quickly.

Hence, considering the possibility of such different appliances' signatures, it would be important to have a preliminary filter before using any appliance recognition technique, so as to increase the disaggregation accuracy. Thus, the next section presents the proposed approach, which uses CPT power terms and NILM techniques to detect the power signatures, before using the appliance classification method by means of the KNN algorithm.

The power signature behavior was aggregated into the 35 appliances dataset, as can be seen in Table 2. This characteristic is not used as features into the pattern recognition algorithm [15], but it is used to filter and increase accuracy in load detection.

Table 2. Household appliance dataset.

Order (Class)	Load	Event Type (Based on Figure 4)
1	Light bulb	a
2	Air conditioning	b
3	Refrigerator	e
4	Microwave	b
5	CRT TV	a
6	LCD TV	a
7	Plasma TV	a
8	Electrical shower	a
9	RL Load 1	a
10	NL Load 1	a
11	NL Load 2	a
12	RL Load 2	a
13	Iron	d
14	Washing machine	b
15	Hairdryer	b
16	Fluorescent lamp	a
17	Mix lamp	d
18	Mercury lamp	d
19	Sodium lamp	d
20	ASD Dryer	e
21	ASD Fridge	e
22	Blender	b
23	Bread maker	a
24	Desktop PC	e
25	Electronic ball lamp	d
26	Food processor	b
27	Freezer	e
28	Furnace	a
29	Garage door	a or e
30	Laptop	e
31	LCD monitor	a
32	Regular dryer	b
33	Regular fridge	e
34	Vacuum	e
35	Washer	b

3.3. The PSB Technique

The appliance dataset helps to detect one appliance by execution but might result in a problem, since more than one appliance may be ON during a certain period of time. In such a case, the active power would contain the aggregated value. Therefore, in order to decompose the consumption of each individual load, it is necessary to know how many loads are operating at that time.

Thus, considering the existence of an algorithm to classify the appliances that generate a power event, the set of instances and the appliance class create a new key-pair value. Therefore, a set of instances may contain several classes associated, and the aggregated set of instances can be decomposed considering the type of appliances.

To obtain a more accurate value of load energy consumption, the PSB takes the mean value of each block associated with each class to evaluate the mean active power during that period. Blocks that contain more than one active appliance should use the historical average value from each of them. This procedure is called disaggregation by blocks.

The load identification algorithm uses classification attributes extracted from the difference between two scenarios: before and after an appliance is turned ON. Hence, the step is just a divider between stable states. This guarantees that classifiers represent the appliances altogether, mitigating the noise generated in the transition state.

Subtracting the waveforms of these steps creates an approximation of the load waveform. Then, the CPT algorithm generates the attributes by processing the waveform. Adopting this approach, four features represent the appliances: active power, power factor, reactive factor, and non-linearity factor. Using these elements as attributes in a four-dimensional space, each load will result in a cluster. Therefore, the classification algorithms, such as KNN, can be used to set the frontiers of each load in the space.

The diagram from Figure 5 shows the state-machine algorithm with the appliance disaggregation dataset from [15]. The existence of appliance power signatures can be observed, which filter and can make the appliance disaggregation more accurate. Moreover, the methodology has algorithms for handling the ON and OFF events, presented in the diagrams from Figures 6 and 7. The methodology stores the fifteen previous cycles (0.25 s of total samples) of voltage and current waveforms to detect the appliance events if there are two or more appliances turned ON.

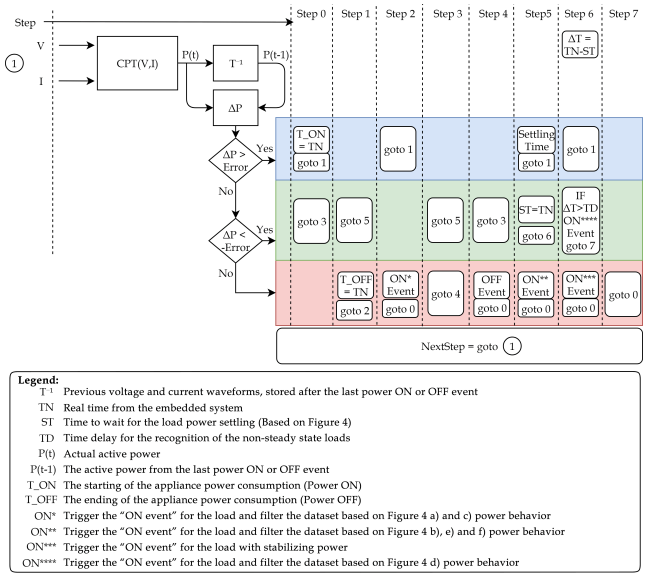

Figure 5. State-machine algorithm of the PSB.

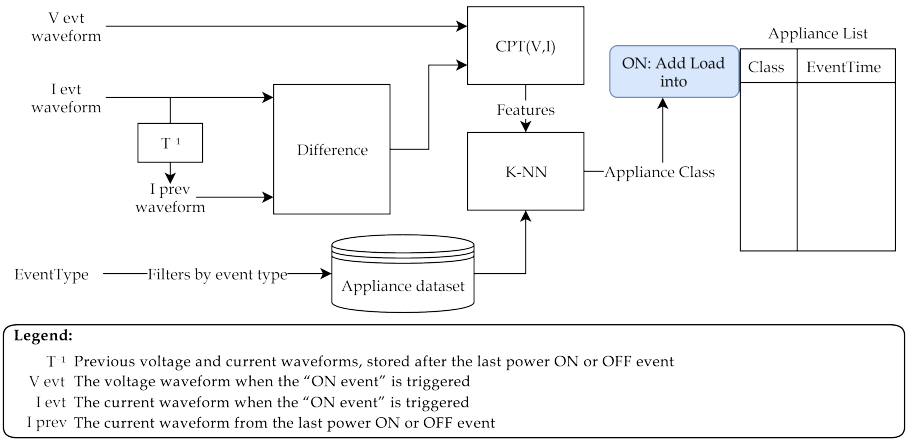

Figure 6. Event ON Trigger.

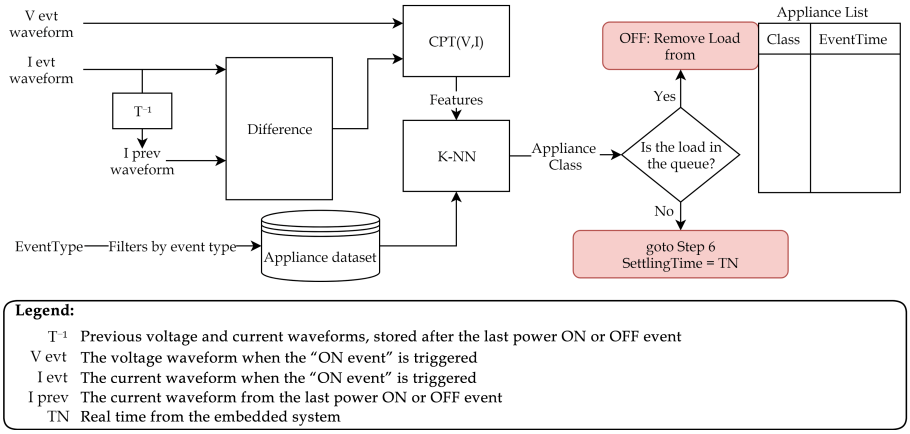

Figure 7. Event OFF Trigger.

4. Validation Results

In this paper, the PSB evaluation was based on simulations and experimental results, as depicted in the next subsections.

4.1. Simulation Results

Table 3 presents the daily appliance schedule for the simulation according to user behavior in the residence.

Table 3. Simulation: Appliance Schedule Runtime.

Appliance	"Turn on" Time	Total Time
Electrical shower	07:15 and 19:40	00:20 and 00:15
Air conditioner	22:00	08:00
CRT TV	12:15 and 18:15	01:00 and 05:00
Refrigerator	All the day	00:30 each cycle
Iron	18:30	00:15
Lamp1 (bulb 100 W)	18:30	05:30
Lamp2 (bulb 60 W)	19:00	04:30
Notebook	19:00	04:00
Microwave	07:45	00:05
Washing Machine	13:00 (Saturday)	02:00

Therefore, an electrical circuit model was created in PSIM software in order to simulate the power behavior of a residence during an entire day, turning on each appliance according to the scheduled runtime of Table 3.

The simulation collects 256 samples per cycle from current and voltage waveforms and sends them to a Dynamic Link Library (DLL) block. The general DLL block in PSIM allows users to write codes in C or C++, compile them as a Windows DLL, and link them to PSIM using the features of input (from PSIM) and outputs (returning to PSIM). Unlike the simple DLL blocks with a fixed number of inputs and outputs, the general DLL block provides more flexibility and capability in interfacing PSIM with custom DLL files. In this paper, the DLL codes were used to implement the CPT, the KNN and state-machine NILM, according to the algorithms from Figures 5–7. The state machine from Figure 5 is a loop responsible for the event decision when there is power consumption changing. If there is power changing, the state machine flows in steps until it detects the power event and triggers the "ON event" (Figure 6) or the "OFF event" (Figure 7). If an "ON event" is detected, the system runs algorithm Figure 6 responsible for classifying the appliance. After that, the algorithm adds the appliance to the turned-on appliance list and saves the waveform status for future comparisons when a new event is triggered. If an "OFF event" is detected, the system runs algorithm Figure 7 that is responsible for classifying the appliance and removing the appliance from the turned on appliance list and saves the waveform status for comparison when a new event is triggered.

Simultaneously, the PSB takes care of four other characteristics:

- A database receives the current power consumption in kWh every minute;
- At every turn ON appliance event, the system makes the pattern recognition and sends all the appliance power information to the database, and then, it starts the detected appliance time operation;
- At every turn OFF event, the system recognizes the appliance that was turned off and updates the database, storing the information from the time the load was switched OFF;
- If there are power changes, the system verifies the power signature of each appliance that is turned ON and recognizes it as appliance power level changes.

Figure 8 presents the simulation results. The state machine with the classifier algorithm accepted all the loads according to Table 3. Figure 8 shows the CPT power decomposition and, consequently, the moments in which the algorithm performed the appliance identification (turn on and turn off triggers).

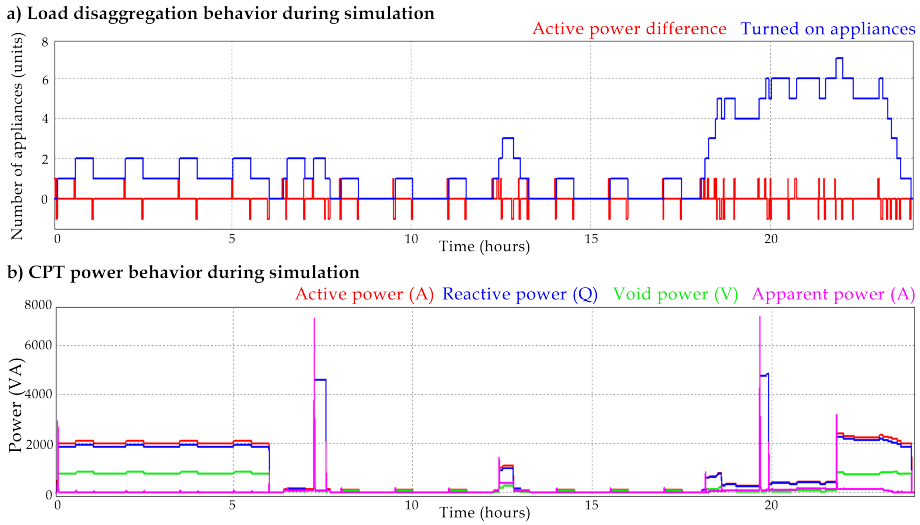

Figure 8. Daily consumption of electricity by household appliances. (**a**) Load disaggregation behavior in simulation; (**b**) CPT power components behavior in simulation.

Figure 9 shows an example of the operation of the PSB between 09:27 and 10:03 from Figure 8. In this interval, there is the operation of a refrigerator, according to the schedule of Table 3. Following the algorithms of Figures 5–7, the state machine has the following behavior:

- **09:27 to 09:30:** Active power is stable, and there is nothing to be done at this time;
- **09:30:** ($\Delta P > Error$); $T_{ON} = TN$, goto 1;
- **09:30:** ($\Delta P > Error$); // waiting for power stabilization;
- **09:31:** ($\Delta P > Error$); // waiting for power stabilization;
- **09:31:** ($\Delta P > Error$); // waiting for power stabilization;
- **09:32:** ($\Delta P < -Error$); goto 5;
- **09:32:** ($\Delta P < Error$) and ($\Delta P > -Error$); ON** Event;
  - CPT Features extraction;
  - KNN classifier;
  - Appliance recognition;
  - Recognized appliance added to the appliance list;
  - goto 0;
- **09:32 to 10:00:** Active power is stable, and there is nothing to be done at this time;
- **10:00:** ($\Delta P < -Error$); $T_{OFF} = TN$; goto 3;
- **10:01:** ($\Delta P < Error$) and ($\Delta P > -Error$); goto 4;
- **10:02:** ($\Delta P < Error$) and ($\Delta P > -Error$); OFF event;
  - Waveform difference;
  - CPT feature extraction;
  - KNN classifier;
  - Appliance recognition;
  - Recognized appliance removed from the appliance list;
  - goto 0;

- **10:02 to 10:03:** Active power is stable, and there is nothing to be done at this time;

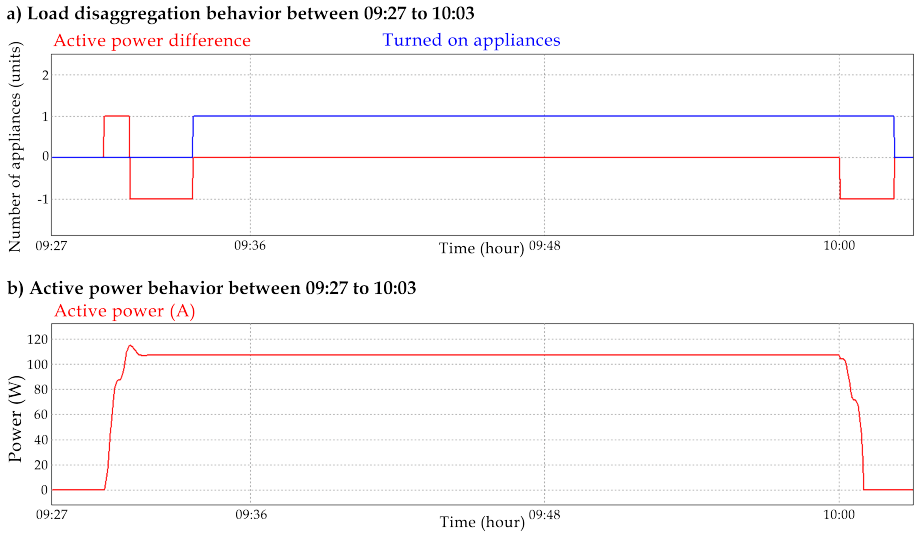

Figure 9. Detailed consumption and state-machine behavior between 09:27 and 10:03. (**a**) Load disaggregation behavior between 09:27 and 10:03; (**b**) Active power behavior between 09:27 and 10:03.

Therefore, the PSB worked as expected, and there was no error in the disaggregation process in the simulations. In this study, there was no error because it is used an appliance dataset with high accuracy and the simulated loads operate in a steady state. However, Section 4.2 will present real appliance cases, including power variations.

4.2. Experimental Results with Household Appliances

The PSB operates with a main loop of 15,360 collected samples. Hence, with a fixed fundamental frequency, this loop takes a second to perform. Then, a four-step procedure tracks rapid power variations. Each step updates the average of the active power evaluated with the last block of samples: 0.25 s of total samples.

Therefore, a predefined threshold level compares the active power variation during the time. Then, the procedure uses the difference between the current average active power and the last one used to define the step level direction: when there is the "power on" or "power off" state of the appliance. Figure 10 shows the behavior of the algorithms from Figures 5–7 in this experiment.

In the trigger events—from Figures 6 and 7—the algorithm stores current and voltage waveforms of the last 0.25 s, extracts the current to be considered in the event and calculates the four elements that represent the appliance: active power, power factor, reactive factor, and non-linearity factor. With these elements (attributes), the algorithm uses the classifier algorithm (the KNN) by means of the knowledge dataset from [15]. The classifier returns the label of the appliance, i.e., the algorithm predicts which appliance is turned on (algorithm from Figure 6) or turned off (algorithm from Figure 7). If it is an "ON event" the recognized appliance is added to the appliance list. If it is an "OFF event", the recognized appliance is removed from the appliance list. After this, the system stores the fifteen waveform cycles of the state to use in a new event trigger. Over time, appliances can be identified, as shown in Figure 11.

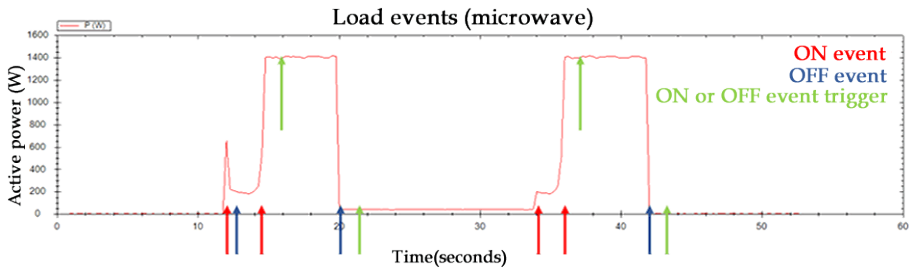

Figure 10. Trigger algorithm validation.

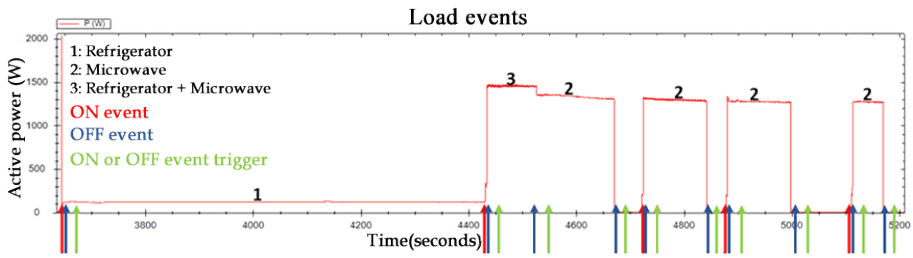

Figure 11. Trigger and load disaggregation validation.

Considering such experiments, the PSB reached 95% of accuracy. The main problem encountered in the method corresponds to the loads with several power changes without the existence of a zero-power instant (i.e., a real turn OFF event). Figure 12 shows an example of an air conditioner with an adjustable speed driver (ASD). In this case, the method of load disaggregation carries out the load identification in the ON event trigger and, in the course of the operation, the power changes without the activation of a new trigger. When the device is turned off, the power level is different from the start of the operation, and the classifier may incorrectly identify the turned off appliance. If there is more than one appliance that is turned on, the algorithm may remove the wrong equipment from the list. If there is only one appliance, the algorithm empties the list.

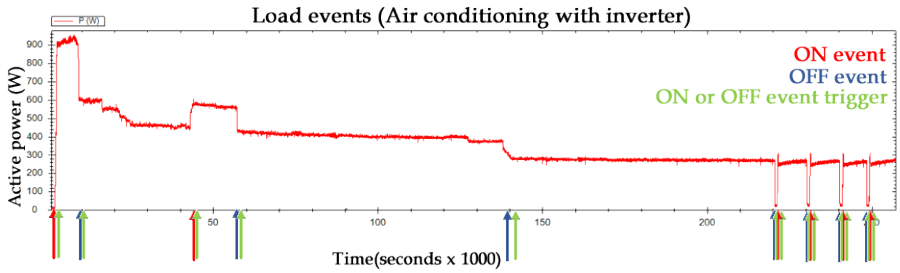

Figure 12. Air conditioning with an inverter example.

To solve this problem, the appliance dataset must have a wide range of appliance measuring times and waveforms should consider the last state (in the OFF event trigger). The algorithm from Figure 5 could also be adapted to improve the accuracy in such situations.

5. Conclusions

This work presented a novel load disaggregation method to be used in cognitive meters, making the "smart" concept from smart meters more reasonable.

The novel methodology called PSB uses the power signature technique with a load recognition from an appliance dataset. The method detects the appliance ON and OFF events during the power signature observation, and the method uses classification algorithms to detect the appliance. The association of the classification algorithm and the power signature recognizes appliances that present power variation during their regular operation. The method also recognizes several loads simultaneously.

When evaluating the proposed method through computational simulations, all the loads were classified correctly. The PSB obtained an accuracy of 95% for real data from a typical residence.

In the future, the authors intend to work on energy efficiency evaluation, associated to identifying appliances. Moreover, the authors would like to apply the PSB to other smart grid applications, such as energy management using the concept of Virtual Power Plants and NILM applied to a group of residential installations. Future papers will deal with such ideas and prominent results.

Author Contributions: Conceptualization, W.A.d.S., F.D.G., F.P.M., L.C.P.d.S. and M.G.S.; Formal analysis, F.P.M.; Funding acquisition, F.P.M. and L.C.P.d.S.; Investigation, W.A.d.S.; Methodology, W.A.d.S., F.D.G. and F.P.M.; Project administration, W.A.d.S. and L.C.P.d.S.; Resources, F.P.M.; Software, W.A.d.S. and F.D.G.; Supervision, F.P.M.; Validation, W.A.d.S., F.D.G. and M.G.S.; Writing—original draft, W.A.d.S.; Writing—review & editing, W.A.d.S., F.D.G., F.P.M., L.C.P.d.S. and M.G.S.

Funding: This research was supported by FAPESP (Sao Paulo Research Foundation) grants number 2012/19375-1 and 2016/08645-9, as well as by the Coordenação de Aperfeiçoamento de Pessoal de Nível Superior—Brasil (CAPES)—Finance Code 001.

Conflicts of Interest: The authors declare no conflict of interest. The funders had no role in the design of the study; in the collection, analyses, or interpretation of data; in the writing of the manuscript, or in the decision to publish the results.

References

1. Tamarkin, T.D. Automatic meter reading. *Public Power* **1992**, *50*, 934–937.
2. Mahmood, A.; Aamir, M.; Anis, M.I. Design and implementation of AMR Smart Grid System. In Proceedings of the IEEE Canada Electric Power Conference, Vancouver, BC, Canada, 6–7 October 2008; pp. 1–6. [CrossRef]
3. Ali, A.; Saad, N.H.; Razali, N.A.; Vitee, N. Implementation of Automatic Meter Reading (AMR) using radio frequency (RF) module. In Proceedings of the IEEE International Conference on Power and Energy, Kota Kinabalu, Malaysia, 2–5 December 2012; pp. 876–879. [CrossRef]
4. Gungor, V.C.; Sahin, D.; Kocak, T.; Ergut, S.; Buccella, C.; Cecati, C.; Hancke, G.P. Smart Grid Technologies: Communication Technologies and Standards. *IEEE Trans. Ind. Inform.* **2011**, *7*, 529–539. [CrossRef]
5. Mohassel, R.R.; Fung, A.; Mohammadi, F.; Raahemifar, K. A survey on Advanced Metering Infrastructure. *Int. J. Electr. Power Energy Syst.* **2014**, *63*, 473–484. [CrossRef]
6. Chien, Y.R.; Yu, H.C. Mitigating Impulsive Noise for Wavelet-OFDM Powerline Communication. *Energies* **2019**, *12*, 1567. [CrossRef]
7. Dong, M.; Meira, P.C.M.; Xu, W.; Chung, C.Y. Non-Intrusive Signature Extraction for Major Residential Loads. *IEEE Trans. Smart Grid* **2013**, *4*, 1421–1430. [CrossRef]
8. Fagiani, M.; Bonfigli, R.; Principi, E.; Squartini, S.; Mandolini, L. A Non-Intrusive Load Monitoring Algorithm Based on Non-Uniform Sampling of Power Data and Deep Neural Networks. *Energies* **2019**, *12*, 1371. [CrossRef]
9. Carroll, J.; Lyons, S.; Denny, E. Reducing household electricity demand through smart metering: The role of improved information about energy saving. *Energy Econ.* **2014**, *45*, 234–243. [CrossRef]
10. Bouhouras, A.S.; Gkaidatzis, P.A.; Chatzisavvas, K.C.; Panagiotou, E.; Poulakis, N.; Christoforidis, G.C. Load Signature Formulation for Non-Intrusive Load Monitoring Based on Current Measurements. *Energies* **2017**, *10*, 538. [CrossRef]

11. Geelen, D.; Mugge, R.; Silvester, S.; Bulters, A. The use of apps to promote energy saving: A study of smart meter–related feedback in the Netherlands. *Energy Effic.* **2019**. [CrossRef]
12. Chui, K.T.; Lytras, M.D.; Visvizi, A. Energy Sustainability in Smart Cities: Artificial Intelligence, Smart Monitoring, and Optimization of Energy Consumption. *Energies* **2018**, *11*, 2869. [CrossRef]
13. Raj, K.B. Smart Grid Technology for Smart Homes—Risks and Benefits. In Proceedings of the International Conference on Recent Trends in Engineering, Materials, Management and Sciences, Khammam, India, 25–27 October 2018; Swarna Bharathi lnstitute of Science and Technology: Khammam, India, 2018; Volume 634, pp. 634–640.
14. Hart, G.W. Nonintrusive appliance load monitoring. *Proc. IEEE* **1992**, *80*, 1870–1891. [CrossRef]
15. Souza, W.A.; Marafão, F.P.; Liberado, E.V.; Simões, M.G.; Da Silva, L.C.P. A NILM Dataset for Cognitive Meters Based on Conservative Power Theory and Pattern Recognition Techniques. *J. Control Autom. Electr. Syst.* **2018**, *29*, 742–755. [CrossRef]
16. Zeifman, M. Disaggregation of home energy display data using probabilistic approach. *IEEE Trans. Consum. Electron.* **2012**, *58*, 23–31. [CrossRef]
17. Lin, S.; Zhao, L.; Li, F.; Liu, Q.; Li, D.; Fu, Y. A nonintrusive load identification method for residential applications based on quadratic programming. *Electr. Power Syst. Res.* **2016**, *133*, 241–248. [CrossRef]
18. Du, L.; He, D.; Harley, R.G.; Habetler, T.G. Electric Load Classification by Binary Voltage–Current Trajectory Mapping. *IEEE Trans. Smart Grid* **2016**, *7*, 358–365. [CrossRef]
19. Gillis, J.M.; Alshareef, S.M.; Morsi, W.G. Nonintrusive Load Monitoring Using Wavelet Design and Machine Learning. *IEEE Trans. Smart Grid* **2016**, *7*, 320–328. [CrossRef]
20. Le, T.T.H.; Kim, H. Non-Intrusive Load Monitoring Based on Novel Transient Signal in Household Appliances with Low Sampling Rate. *Energies* **2018**, *11*, 3409. [CrossRef]
21. He, H.; Liu, Z.; Jiao, R.; Yan, G. A Novel Nonintrusive Load Monitoring Approach based on Linear-Chain Conditional Random Fields. *Energies* **2019**, *12*, 1797. [CrossRef]
22. Kwak, Y.; Hwang, J.; Lee, T. Load Disaggregation via Pattern Recognition: A Feasibility Study of a Novel Method in Residential Building. *Energies* **2018**, *11*, 1008. [CrossRef]
23. Tenti, P.; Mattavelli, P.; Morales Paredes, H.K. Conservative Power Theory, sequence components and accountability in smart grids. In Proceedings of the International School on Nonsinusoidal Currents and Compensation, Lagow, Poland, 15–18 June 2010; pp. 37–45. [CrossRef]
24. Tenti, P.; Paredes, H.K.M.; Mattavelli, P. Conservative Power Theory, a Framework to Approach Control and Accountability Issues in Smart Microgrids. *IEEE Trans. Power Electron.* **2011**, *26*, 664–673. [CrossRef]
25. Souza, W.A.; Liberado, E.V.; da Silva, L.C.P.; Paredes, H.K.M.; Marafão, F.P. Load analyser using conservative power theory. In Proceedings of the International School on Nonsinusoidal Currents and Compensation, Zielona Gora, Poland, 20–21 June 2013; pp. 1–6. [CrossRef]
26. Drenker, S.; Kader, A. Nonintrusive monitoring of electric loads. *IEEE Comput. Appl. Power* **1999**, *12*, 47–51. [CrossRef]
27. Cole, A.I.; Albicki, A. Data extraction for effective non-intrusive identification of residential power loads. In Proceedings of the IEEE Instrumentation and Measurement Technology Conference, St. Paul, MN, USA, 18–21 May 1998; Volume 2, pp. 812–815.
28. Leeb, L.K.N.S.B. Non-intrusive electrical load monitoring in commercial buildings based on steady-state and transient load-detection algorithms. *Energy Build.* **1996**, *24*, 51–64. [CrossRef]
29. Plungklang, S.B.B. Non-Intrusive Appliances Load Monitoring (NILM) for Energy Conservation in Household with Low Sampling Rate. *Procedia Comput. Sci.* **2016**, *86*, 172–175. [CrossRef]
30. Xiao, P.; Cheng, S. Neural Network for NILM Based on Operational State Change Classification. *arXiv* **2019**, arXiv:1902.02675.
31. Powers, J.T.; Margossian, B.; Smith, B.A. Using a rule-based algorithm to disaggregate end-use load profiles from premise-level data. *IEEE Comput. Appl. Power* **1991**, *4*, 42–47. [CrossRef]
32. Zmeureanu, L.F.R. Using a pattern recognition approach to disaggregate the total electricity consumption in a house into the major end-uses. *Energy Build.* **1999**, *30*, 245–259. [CrossRef]
33. Zmeureanu, M.M.R. Nonintrusive load disaggregation computer program to estimate the energy consumption of major end uses in residential buildings. *Energy Convers. Manag.* **2000**, *41*, 1389–1403. [CrossRef]

34. Baranski, M.; Voss, J. Genetic algorithm for pattern detection in NIALM systems. In Proceedings of the IEEE International Conference on Systems, Man and Cybernetics, The Hague, The Netherlands, 10–13 October 2004; Volume 4, pp. 3462–3468. [CrossRef]
35. Ruzzelli, A.G.; Nicolas, C.; Schoofs, A.; O'Hare, G.M.P. Real-Time Recognition and Profiling of Appliances through a Single Electricity Sensor. In Proceedings of the IEEE Communications Society Conference on Sensor, Mesh and Ad Hoc Communications and Networks, Boston, MA, USA, 21–25 June 2010; pp. 1–9. [CrossRef]
36. Kelly, J.; Knottenbelt, W. Neural NILM: Deep Neural Networks Applied to Energy Disaggregation. In Proceedings of the ACM International Conference on Embedded Systems for Energy-Efficient Built Environments, Seoul, Korea, 4–5 November 2015; ACM: New York, NY, USA, 2015; pp. 55–64. [CrossRef]
37. Figueiredo, M.B.; de Almeida, A.; Ribeiro, B. An Experimental Study on Electrical Signature Identification of Non-Intrusive Load Monitoring (NILM) Systems. In *Adaptive and Natural Computing Algorithms*; Springer: Berlin/Heidelberg, Germany, 2011; pp. 31–40.
38. Kim, H.; Marwah, M.; Arlitt, M.; Lyon, G.; Han, J. Unsupervised Disaggregation of Low Frequency Power Measurements. In Proceedings of the SIAM International Conference on Data Mining, Mesa, AZ, USA, 28–30 April 2011; pp. 747–758. [CrossRef]
39. Koutitas, G.C.; Tassiulas, L. Low Cost Disaggregation of Smart Meter Sensor Data. *IEEE Sens. J.* **2016**, *16*, 1665–1673. [CrossRef]
40. Sultanem, F. Using appliance signatures for monitoring residential loads at meter panel level. *IEEE Trans. Power Deliv.* **1991**, *6*, 1380–1385. [CrossRef]
41. Srinivasan, D.; Ng, W.S.; Liew, A.C. Neural-network-based signature recognition for harmonic source identification. *IEEE Trans. Power Deliv.* **2006**, *21*, 398–405. [CrossRef]
42. Laughman, C.; Lee, K.; Cox, R.; Shaw, S.; Leeb, S.; Norford, L.; Armstrong, P. Power signature analysis. *IEEE Power Energy Mag.* **2003**, *99*, 56–63. [CrossRef]
43. Bouhouras, A.S.; Gkaidatzis, P.A.; Panagiotou, E.; Poulakis, N.; Christoforidis, G.C. A NILM algorithm with enhanced disaggregation scheme under harmonic current vectors. *Energy Build.* **2019**, *183*, 392–407. [CrossRef]
44. Teshome, D.F.; Huang, T.D.; Lian, K. Distinctive Load Feature Extraction Based on Fryze's Time-Domain Power Theory. *IEEE Power Energy Technol. Syst. J.* **2016**, *3*, 60–70. [CrossRef]
45. Nguyen, M.; Alshareef, S.; Gilani, A.; Morsi, W.G. A novel feature extraction and classification algorithm based on power components using single-point monitoring for NILM. In Proceedings of the IEEE Canadian Conference on Electrical and Computer Engineering, Halifax, NS, Canada, 3–6 May 2015; pp. 37–40. [CrossRef]
46. Huang, T.D.; Wang, W.; Lian, K. A New Power Signature for Nonintrusive Appliance Load Monitoring. *IEEE Trans. Smart Grid* **2015**, *6*, 1994–1995. [CrossRef]
47. Chan, W.L.; So, A.T.P.; Lai, L.L. Harmonics load signature recognition by wavelets transforms. In Proceedings of the International Conference on Electric Utility Deregulation and Restructuring and Power Technologies, London, UK, 4–7 April 2000; pp. 666–671. [CrossRef]
48. Su, Y.; Lian, K.; Chang, H. Feature Selection of Non-intrusive Load Monitoring System Using STFT and Wavelet Transform. In Proceedings of the IEEE International Conference on e-Business Engineering, Beijing, China, 19–21 October 2011; pp. 293–298. [CrossRef]
49. Duarte, C.; Delmar, P.; Goossen, K.W.; Barner, K.; Gomez-Luna, E. Non-intrusive load monitoring based on switching voltage transients and wavelet transforms. In Proceedings of the Future of Instrumentation International Workshop, Gatlinburg, TN, USA, 8–9 October 2012; pp. 1–4. [CrossRef]
50. Gray, M.; Morsi, W.G. Application of wavelet-based classification in non-intrusive load monitoring. In Proceedings of the IEEE Canadian Conference on Electrical and Computer Engineering, Halifax, NS, Canada, 3–6 May 2015; pp. 41–45. [CrossRef]
51. Tabatabaei, S.M.; Dick, S.; Xu, W. Toward Non-Intrusive Load Monitoring via Multi-Label Classification. *IEEE Trans. Smart Grid* **2017**, *8*, 26–40. [CrossRef]
52. Chang, H.H. Non-Intrusive Demand Monitoring and Load Identification for Energy Management Systems Based on Transient Feature Analyses. *Energies* **2012**, *5*, 4569–4589. [CrossRef]
53. Chang, H.; Lian, K.; Su, Y.; Lee, W. Power-Spectrum-Based Wavelet Transform for Nonintrusive Demand Monitoring and Load Identification. *IEEE Trans. Ind. Appl.* **2014**, *50*, 2081–2089. [CrossRef]

54. Hassan, T.; Javed, F.; Arshad, N. An Empirical Investigation of V-I Trajectory Based Load Signatures for Non-Intrusive Load Monitoring. *IEEE Trans. Smart Grid* **2014**, *5*, 870–878. [CrossRef]
55. Gao, J.; Kara, E.C.; Giri, S.; Bergés, M. A feasibility study of automated plug-load identification from high-frequency measurements. In Proceedings of the IEEE Global Conference on Signal and Information Processing, Orlando, FL, USA, 14–16 December 2015; pp. 220–224. [CrossRef]
56. De Baets, L.; Ruyssinck, J.; Develder, C.; Dhaene, T.; Deschrijver, D. Appliance classification using VI trajectories and convolutional neural networks. *Energy Build.* **2018**, *158*, 32–36. [CrossRef]
57. Patel, S.N.; Robertson, T.; Kientz, J.A.; Reynolds, M.S.; Abowd, G.D. *At the Flick of a Switch: Detecting and Classifying Unique Electrical Events on the Residential Power Line (Nominated for the Best Paper Award);* UbiComp 2007 Ubiquitous Computing; Springer: Berlin/Heidelberg, Germany, 2007; pp. 271–288.
58. Gupta, S.; Reynolds, M.S.; Patel, S.N. ElectriSense: Single-point Sensing Using EMI for Electrical Event Detection and Classification in the Home. In Proceedings of the ACM International Conference on Ubiquitous Computing, Copenhagen, Denmark, 26–29 September 2010; pp. 139–148. [CrossRef]
59. Kolter, J.Z.; Johnson, M.J. REDD: A public data set for energy disaggregation research. In Proceedings of the Workshop on Data Mining Applications in Sustainability, San Diego, CA, USA, 21 August 2011; Volume 25, pp. 59–62.
60. Kelly, J.; Knottenbelt, W. The UK-DALE dataset, domestic appliance-level electricity demand and whole-house demand from five UK homes. *Sci. Data* **2015**, *2*, 150007. [CrossRef]
61. Gao, J.; Giri, S.; Kara, E.C.; Bergés, M. PLAID: A Public Dataset of High-resoultion Electrical Appliance Measurements for Load Identification Research: Demo Abstract. In Proceedings of the ACM Conference on Embedded Systems for Energy-Efficient Buildings, Memphis, Tennessee, 3–6 November 2014; pp. 198–199. [CrossRef]
62. Kahl, M.; Haq, A.U.; Kriechbaumer, T.; Jacobsen, H.A. Whited-a worldwide household and industry transient energy data set. In Proceedings of the International Workshop on Non-Intrusive Load Monitoring, Vancouver, BC, Canada 14–15 May 2016.
63. Papa, J.P.; Falcão, A.X.; Suzuki, C.T.N. Supervised pattern classification based on optimum-path forest. *Int. J. Imaging Syst. Technol.* **2009**, *19*, 120–131. [CrossRef]
64. Cover, T.M.; Hart, P.E. Nearest neighbor pattern classification. *IEEE Trans. Inf. Theory* **1967**, *13*, 21–27. [CrossRef]
65. Tenti, P.; Paredes, H.K.M.; Marafao, F.P.; Mattavelli, P. Accountability in Smart Microgrids Based on Conservative Power Theory. *IEEE Trans. Instrum. Meas.* **2011**, *60*, 3058–3069. [CrossRef]
66. Bouhouras, A.S.; Milioudis, A.N.; Labridis, D.P. Development of distinct load signatures for higher efficiency of NILM algorithms. *Electr. Power Syst. Res.* **2014**, *117*, 163–171. [CrossRef]

© 2019 by the authors. Licensee MDPI, Basel, Switzerland. This article is an open access article distributed under the terms and conditions of the Creative Commons Attribution (CC BY) license (http://creativecommons.org/licenses/by/4.0/).

REVISTA BRASILEIRA DE ENERGIAS RENOVÁVEIS

ARQUITETURA DO MEDIDOR COGNITIVO DE ENERGIA[1]

FELIPE LEITE PAES[2], FERNANDO PINHABEL MARAFÃO[2], WESLEY ANGELINO DE SOUZA[3], FERNANDO DELUNO GARCIA[2]

[1] Apresentado no Congresso de Energias Renováveis da UFSCar: 23 a 26 de maio de 2017 – Sorocaba-SP, Brasil

[2] Universidade Estadual Paulista, Grupo de Automação e Sistemas Integráveis, Sorocaba, SP, Brasil

E-mail: paes.felipe@hotmail.com

[3] Universidade Estadual de Campinas, Departamento de Sistemas e Energia, Campinas, SP, Brasil

RESUMO

As Redes Inteligentes de Energia indicam para uma nova arquitetura dos sistemas de distribuição de energia elétrica, a qual deve se consolidar nas próximas décadas, em um cenário repleto de dispositivos e sistemas dotados de algum grau de "inteligência" artificial. Neste cenário, a possibilidade de comunicação bidirecional entre o usuário e a rede de energia elétrica será imprescindível para integração dos vários dispositivos e agentes em uma Rede Inteligente. Atualmente, há muita pesquisa e desenvolvimento sobre os chamados medidores inteligentes de energia e sobre os medidores cognitivos de energia, que possibilitam a integração e comunicação dos dispositivos numa rede de dados e facilita a atuação de uma Rede Inteligente de Energia. Nesse contexto, este trabalho propõe um tutorial sobre as tecnologias, métodos e etapas que podem ser utilizadas no desenvolvimento de medidores cognitivos de energia.

Palavras-chave: Inteligência Artificial, Medidores Inteligentes de Energia, Redes Inteligentes de Energia.

COGNITIVE POWER METER ARCHITECTURE

ABSTRACT

The smart grids point us to a new model of distribution systems of electrical power, which must be consolidated in the next decades, in a scenery full of devices and systems that bring us a new level of artificial intelligence. In this scene, the possibility of a two hands way of communication between the final user and the electrical energy network will be indispensable to compose the many devices and agents into a smart grid. Nowadays, there is a lot of research and development about new smart power meters and cognitive energy meters, allowing the integration and the communication among some devices in a data network, enhancing the performance of a smart grid. In this context, the efforts of this work is to purpose a tutorial about technology, methods and steps that may be used to develop new cognitive power meters.

Keywords: Artificial Intelligence, Smart Meters, Smart Grids.

INTRODUÇÃO

Os primeiros medidores de energia datam de 1872, consistindo de simples temporizadores que controlavam o tempo da carga conectada à rede (QUEEN, 2011). Novos medidores foram desenvolvidos, químicos e eletromecânicos, sendo que os medidores eletromecânicos ainda estão presentes em muitas instalações, devido sua simplicidade, facilidade de manutenção e por ter sido predominante no Brasil por quase todo o século XX (SOUZA, 2016).

Com a evolução da eletrônica e suas possibilidades de aplicação, surgiu o medidor eletrônico de energia com sensores de medição de tensão e corrente, criando possibilidades de armazenamento de informações, apresentação dos dados em display, comunicação unidirecional (o ponto consumidor pode enviar automaticamente informações de consumo à concessionária). Com a medição de tensão e corrente, tornou-se possível realizar cálculos de

potência instantânea, energia consumida, fator de deslocamento e outros indicadores de energia elétrica (QUEEN, 2011).

Em um cenário em ascensão de novas fontes de energias renováveis sendo aplicadas, com a chegada do prossumidor, o usuário que consome e fornece energia, com a popularização das redes inteligentes de energia e a necessidade do fornecimento de informações adicionais sobre a energia elétrica, houve a necessidade da existência de comunicação bidirecional no medidor. Essa nova evolução do medidor eletrônico ganhou o nome de medidor inteligente (GARCIA et al., 2017; QUEEN, 2011).

A evolução do medidor inteligente surge com a prospecção de um novo cenário no mercado de energia, com novas políticas de tarifação e de consumo otimizado, sobretudo pela eficiência energética. Assim vem surgindo os medidores cognitivos de energia, os quais aliam as capacidades de um medidor inteligente realizar a desagregação do consumo de energia elétrica através de técnicas de cognição, na qual possibilita a inclusão do consumidor no cenário de gestão de energia elétrica, controlado anteriormente apenas pelos agentes concessionários e distribuidores de energia elétrica (MAKONIN; POPOWICH; GILL, 2013).

Dentro do cenário proposto em redes inteligentes de energia, tem o medidor inteligente de energia como uma das peças fundamentais para integração do sistema. A evolução do medidor inteligente convencional (medidor eletrônico com tecnologia de comunicação bidirecional), para um medidor de energia cognitivo pode ser o diferencial para a operação otimizada das redes inteligentes de energia (SOUZA, 2016).

As políticas adotadas em vários países de resposta a demanda e que já estão sendo discutidas no Brasil, são propulsoras para desenvolvimento dessas ferramentas e contribuem para definições nas pesquisas em andamento na área (HU et al., 2016; LI et al., 2016).

Segundo MAKONIN, POPOWICH e GILL (2013) e SOUZA (2016), os medidores cognitivos seriam medidores inteligentes com capacidade de desagregação de cargas, característica que pode contribuir para proposição de estratégias de controle de consumo em uma instalação ou parâmetro de decisão para responder a uma política de controle de demanda de energia.

A investigação de técnicas associadas aos mecanismos de cognição em inteligência artificial e processamento estatísticos é crucial para determinar a arquitetura de um medidor cognitivo de energia, no âmbito de atender as expectativas do problema (desagregação de cargas), como também a sua exequibilidade.

Esse trabalho propõe um tutorial sobre as tecnologias, métodos e etapas que podem ser utilizadas no desenvolvimento de medidores cognitivos de energia, na próxima seção será abordado sobre a concepção do medidor cognitivo de energia.

Medidor cognitivo

Um medidor cognitivo de energia pode ser estruturado por etapas, que somadas poderão propor uma tecnologia que atenda aos requisitos de confiabilidade das informações geradas e factibilidade de integração que essa aplicação apresenta. Na Figura 1 é apresentado a sugestão de uma arquitetura do medidor cognitivo.

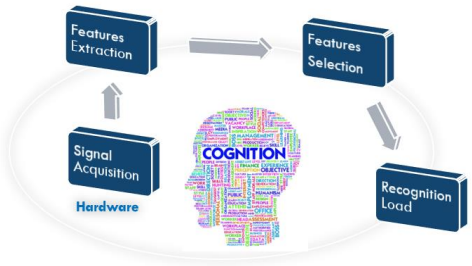

Figura 1: Arquitetura do sistema do medidor cognitivo de energia.
Fonte: adaptado pelo autor.

A definição do hardware adequado é imprescindível para a factibilidade da arquitetura apresentada na Figura 1. Como alternativa a destacar, pesquisas na área de Internet das Coisas e Computação em nuvem mostram oportunidades para execução do tratamento dos dados fora da plataforma de hardware, o que poderia viabilizar upgrades em medidores atuais, permitindo que etapas como extração de informações, seleção de atributos e reconhecimento de carga fossem realizadas numa outra plataforma (YU et al., 2016).

As subseções a seguir: Aquisição de sinais, Extração de atributos, Seleção de Atributos, Reconhecimento de cargas e Hardware foram criadas para apresentar informações sobre a arquitetura sugerida na Figura 1.

Aquisição de sinais

A aquisição de sinais é uma etapa importante do processo para a confiabilidade do resultado final de um sistema cognitivo. Os sinais que forem armazenados serão a base de dados para a inteligência do sistema. É crucial a obtenção do sinal em sua integridade, pois o comportamento do sistema de energia pode ser dinâmico, com transitórios que poderão trazer informações relevantes para caracterização das cargas, o principal objetivo de um medidor cognitivo (YU et al., 2016).

O sistema deve ser compatível para o tipo de análise de dados que seja pretendido fazer. Deve ser considerado que os sinais de tensão e corrente possuem componentes harmônicas e as suas respectivas frequências também devem ser respeitadas. Uma componente harmônica pode trazer muita informação para caracterização de carga e pode tornar-se algo primordial para definição de uma classe em uma fronteira de decisão (YU et al., 2016). Segundo TUOMISTO (2016), considerando que harmônicas acima da 20ª não estão usualmente presentes em equipamentos domésticos, em um sistema comercial de 60 Hz para garantir uma boa qualidade da amostragem, deve-se trabalhar com uma frequência de amostragem equivalente ou maior que 2400 Hz para atender o teorema da amostragem de Nyquist (OGATA, 1982). Frequências de amostragem menores que esta podem omitir assinaturas de cargas que apresentem componentes harmônicas mais altas, sendo que maiores frequências de amostragem, permitem maior precisão, beneficiando o sistema de reconhecimento de padrões (YU et al., 2016).

A corrente elétrica traz bastante informação a respeito, com o aumento ou diminuição de seu módulo, como também o comportamento numa janela de tempo, que pode ser caracterizada por um pico acentuado na partida, pequenas oscilações durante a carga. O grande desafio é desagregar cargas a partir de uma medição de entrada, pois há sobreposição de cargas com suas respectivas características (YU et al., 2016).

Extração de atributos

Para estruturar um dispositivo inteligente é necessária uma base de dados representativa. Para aplicação em medidores cognitivos, a ideia de extrair informações limita-se a entender o comportamento das diferentes cargas, com objetivo de obter um dispositivo com capacidade de desagregar as cargas do sistema. Nas pesquisas em monitoramento de cargas, têm-se basicamente três linhas de objetivos: Sistema de Monitoramento de Cargas Intrusivo (também chamado de Sistema de monitoramento distribuído), Sistema de

Monitoramento Semi-Intrusivo (ou sistema parcialmente distribuído) e Sistema de Monitoramento de Cargas Não Intrusivo (ou Sistema de Monitoramento Concentrado) (GARCIA et al., 2017; YU et al., 2016).

Segundo YU et al. (2016) é possível adotar diferentes estratégias para extração de características da carga, sendo uma baseada na análise no domínio do tempo, outra baseada na análise no domínio da frequência e para complementar, a terceira baseada na assinatura de potência (ciclo on-off).

Uma outra opção para a obtenção dos padrões trata-se da Teoria da Potência Conservativa (CPT) descrita em Tenti, Mattavelli e Paredes (2010), que é capaz de quantificar e caracterizar a carga em um determinado tempo de funcionamento. Desta forma, são calculadas parcelas de potência, o que permite a criação de padrões com maior precisão, e consequentemente torna o processo de desagregação mais eficiente. Segundo proposto por Souza (2016), utiliza-se para a desagregação, a potência ativa P, o fator de potência (λ), fator de reatividade (λ_Q), e fator de não linearidade (λ_D), todos calculados a partir das proposições da CPT.

Seleção de atributos

Na área de sistemas inteligentes, com a possibilidade de aplicação de diversas ferramentas que possuem um viés probabilístico, pode ser aplicável técnicas de seleção de atributos e pré-processamento de sinais.

Pode-se pensar, a princípio, que se trata de uma etapa “supérflua”, pois bastaria processar todos os atributos possíveis, e o sistema inteligente dependendo da técnica intrínseca e com seu poder de aproximação, se encarregaria de realizar a seleção necessária. No entanto, do ponto de vista prático, essa noção pode ser inadequada por uma série de razões. Entre as razões defendidas por Guyon e Elisseeff (2003) está a simplicidade de compreender os dados e as necessidades do projeto se o espaço de entrada for relativamente pequeno, utilizar um conjunto compacto de atributos podem possibilitar que o treinamento e a operação do sistema ocorram num período de tempo compatível com a aplicação.

Para caracterizar um problema, equacionar um modelo físico, espera-se que as variáveis ou a interação entre elas possa representar o comportamento do sistema. As

variáveis podem ser caracterizadas por diversas maneiras e existem alguns métodos que procuram identificar essas características (DUCH, 2006).

Reconhecimento de cargas

Os requisitos para caracterização de um medidor cognitivo de energia estão na associação de um medidor que possua tecnologia para processamento de dados, comunicação bidirecional e mecanismos de reconhecimento de cargas agregados.

Conforme SOUZA (2016) e YU et al. (2016) existem duas estratégias para monitoramento e identificação de cargas, uma de caráter intrusiva (ou distribuída), ou seja, é necessário a instalação de dispositivos de medição em cada carga e com comunicação estabelecida com o Smart Meter para possibilitar a concentração de medições e utilizar esses dados para fornecer ao usuário dados de consumo instantâneo de cada dispositivo acoplado a rede (por exemplo). Outra estratégia que vem sendo utilizada refere-se a não intrusiva (ou concentrada), que tem como objetivo realizar a medição no PAC (Ponto de Acoplamento Comum), e com a aplicação de técnicas de reconhecimento de padrões, detecção de eventos, entre outras, conseguir desagregar as diferentes cargas inseridas na rede, trazendo os dados de maneira independente das cargas conectadas. Observa-se que o problema não é trivial e exige que todas as etapas sejam executadas com precisão.

Geralmente, devido à complexidade de implementar um sistema que possua um desempenho ótimo em generalização, opta-se por iniciar o desenvolvimento de um sistema cognitivo treinando-o com cargas separadamente, e depois realizam a etapa de validação também colocando as cargas separadas. Para essas situações os resultados tendem a ser bons, pois não há sobreposição de características, e o algoritmo consegue resolver os problemas propostos com um EQM (Erro quadrático médio) pequeno. Esse método é utilizado como base para avanço no estudo de desagregação de cargas, porém sua aplicação prática possui limitações (SOUZA, 2016).

Um sistema de reconhecimento de cargas pode ser comparado a um sistema genérico de reconhecimento de padrões e um requisito básico para operabilidade de um sistema de reconhecimento de padrões é o estabelecimento das classes. Com base em algumas características o algoritmo classificador deve definir qual classe de dados aquela referida amostra pertence. A criação de classes é imprescindível, pois define as regiões no espaço de dados para estrutura de decisão do algoritmo (YU et al., 2016).

Em seu estudo, SOUZA (2016) utilizou a técnica de detecção de cargas por eventos e na existência de um determinado evento é utilizado um algoritmo de reconhecimento de padrões. Neste estudo, foram utilizados cinco algoritmos classificadores que são: máquina de vetores de suporte (SVM), floresta de caminhos ótimos (OPF), perceptron multicamadas (MLP), K-enésimo vizinho mais próximo (KNN) e a árvore de decisões (DT). Destes classificadores, o KNN obteve maior exatidão e custo computacional baixo.

Hardware

Conceitualmente, um medidor cognitivo é diferente de um Smart Meter apenas no que tange a capacidade de cognição. Esse avanço em cognição não significa exatamente na troca de hardware, e sim a utilização de um processamento que até então era limitado. Os avanços na área de Internet das Coisas (IOT) e Computação em nuvem podem possibilitar a implementação de medidores cognitivos para os casos onde o hardware tenha limitação de processamento para um algoritmo e/ou limitação em memória para os dados, pois essas novas tecnologias permitem a operação do algoritmo ou a alocação do banco de dados em nuvem (YU et al., 2016).

Em Ganiyu e Anthony (2014) apresentam-se as principais características de hardware para um smart meter, com aplicação de diferentes tipos de tecnologias de comunicação, tais como PLC (Power Line Communication), ZigBee, entre outras. A arquitetura tem como base um sistema embarcado, que basicamente é um processador, periféricos e uma interface para o usuário. A concepção dessa arquitetura possibilita a criação e desenvolvimento de softwares, com foco na utilização dos periféricos (para medição, condicionamento dos sinais, comunicação, entre outras aplicações). No hardware deve constar canais para aquisição dos sinais medidos e conversores AD para possibilitar o processamento desses dados. A inteligência do sistema (capacidade de cognição) pode ser implementada no próprio processador, ou numa aplicação em paralelo.

RESULTADOS E DISCUSSÃO

A capacidade de desagregação de cargas em um medidor inteligente define um medidor cognitivo. No entanto, ainda há muito espaço para ser explorado, desde as técnicas que poderão ser testadas e aplicadas, como também as diferentes aplicações que poderão ser

viabilizadas por um medidor cognitivo. Especialmente no caso de circuitos trifásicos, acredita-se que muitas contribuições ainda devem surgir, inclusive com atributos mais representativos, no caso da utilização da CPT.

Diferentes tipos de cargas caracterizam diferentes comportamentos numa rede de energia e podem ser decisivos para a definição de quais técnicas utilizar no desenvolvimento do medidor cognitivo de energia, desde a extração de atributos ao reconhecimento de cargas.

CONCLUSÕES

A capacidade de cognição é uma característica que poderá ser ainda muito investigada e explorada na área de monitoramento e controle de energia, mas devido à falta de definições na área, ainda não é possível afirmar que as novas abrangências de cognição farão parte do medidor de energia.

As informações geradas por um sistema de desagregação de cargas podem ser utilizadas de diversas formas, além do tratamento de gestão de energia e QEE, pois são dados que poderão ser utilizados para estimação de perfil (com diferentes objetivos), inclusive para fins de espionagens. Certamente ainda virão muitas pesquisas nesse tema, conforme os requisitos de segurança forem sendo assegurados, possivelmente as aplicações vão ganhando espaço.

Os medidores cognitivos de energia possuem versatilidade na aplicação, pois poderão ser úteis tanto para o usuário como também para a concessionária de energia, focando em diferentes aplicações, entre elas o controle de consumo de energia por carga numa residência ou empresa, como também trazendo informações importantes para a gestão de resposta a demanda ou até mesmo para o controle e estabilidade da rede elétrica de energia.

REFERÊNCIAS

DUCH, W., Filter Methods, in I. Guyon et al. (eds.), **Feature Extraction:** Foundations and Applications, Springer, 2006.

GANIYU A. A., ANTHONY A. O.; Hardware Design of a Smart Meter, Department of Electronic & Electrical Engineering, Ladoke Akintola University of Technology, P.M.B. 4000, Ogbomoso, Nigeria **Int. Journal of Engineering Research and Applications**, 2014.

GARCIA F. D., SOUZA W. A., MARAFAO F. P., SILVA L. C. P.; **Power Metering:** History and Future Trends. 9th Annual Green Technologies Conference (IEEE GreenTech), 2017.

GUYON, I; ELISSEEFF, A., An Introduction to Variable and Feature Selection, **Journal of Machine Learning Research**, Vol. 3, pp. 1157 – 1182, 2003.

HU, J.; CAO, J.; YONG, T.; GUERRERO, J. M.; CHEN, M. Z. Q.; LI, Y. **Demand Response Load Following of Source and Load Systems.** IEEE, Transactions on Smart Grid. 2016.

LI, Z.; WANG. S.; ZHENG, X.; LÉON, F.; HONG, T. **Dynamic Demand Response using Customer Coupons Considering Multiple Load Aggregators to Simultaneously Achieve Efficiency and Fairness.** IEEE, Transactions on Smart Grid. 2016.

MAKONIN, S.; POPOWICH, F.; GILL, B.; **The Cognitive Power Meter: Looking Beyond the Smart Meter.** School of Computing Science, SFU Technology Centre, BCIT. Canadian Conference on Electrical and Computer Engineering (CCECE). 2013.

OGATA, K. **Engenharia de Controle Moderno**, Prentice Hall, 1982.

QUEEN, E. E., **Smart Meters and Smart Meter Systems:** A Metering Industry Perspective. An EEI-AEIC-UTC White Paper. EEI. Washington, D.C. Março de 2011.

SOUZA, W. A.; **Estudos de Técnicas de Análise e Tecnologias para o Desenvolvimento de Medidores Inteligentes de Energia Residenciais.** Unicamp. Campinas, São Paulo. 2016.

TENTI, P.; MATTAVELLI, P.; PAREDES, H.K.M., **Conservative Power Theory, sequence components and accountability in smart grids**, in Nonsinusoidal Currents and Compensation (ISNCC), 2010 International School on , vol., no., pp.37-45, 15-18 June 2010.

TUOMISTO, M.; Non-intrusive Appliance Load Monitoring (NIALM) System with the Possibility for Users to Follow the Consumption of Individual Electricity Appliances from the Calendar. **International Journal of Energy and Power Engineering**. 12 de junho de 2016.

YU, L.; LI, H.; FENG, X.; DUAN, J.; **Nonintrusive Appliance Load Monitoring for Smart Homes:** Recent Advances and Future Issues. IEEE Instrumentation & Measurement Magazine. Junho de 2016.

Journal of Control, Automation and Electrical Systems (2018) 29:742–755
https://doi.org/10.1007/s40313-018-0417-4

A NILM Dataset for Cognitive Meters Based on Conservative Power Theory and Pattern Recognition Techniques

Wesley A. Souza[1] · Fernando P. Marafão[2] · Eduardo V. Liberado[2] · Marcelo G. Simões[3] · Luiz C. P. Da Silva[1]

Received: 21 March 2018 / Revised: 16 August 2018 / Accepted: 26 August 2018 / Published online: 30 August 2018
© Brazilian Society for Automatics--SBA 2018

Abstract
This paper presents a novel dataset capable of classifying and disaggregating residential appliances for the development of smart or cognitive power meters. This novel dataset uses power indicators (also denoted as conformity factors) from the conservative power theory (CPT), which are calculated from measured voltage and current waveforms during the operation of residential loads. The association of CPT power indicators with suitable pattern recognition algorithms (PRA) and a power signature state machine provides proper identification of each appliance. So, the paper also presents a detailed evaluation of possible PRA for this application, especially the SVM—support vector machine, OPF—optimum-path forest, MLP—multilayer perceptron, KNN—K-nearest neighbor and DT—decision tree. All these algorithms have been compared regarding accuracy and computational time. Validation results point out that KNN would be the best choice for dealing with the proposed dataset, leading to an accuracy higher than 98%.

Keywords Cognitive meter · Conservative power theory · Pattern recognition algorithms · Residential appliance recognition dataset · Smart meter

1 Introduction

The application of signal processing and artificial intelligence techniques has been of great importance for the development and efficient operation of power grids (Bollen 2000; Dugan et al. 2000; Bamachandran et al. 2013; Lima et al. 2012; Souza et al. 2015; Liberado et al. 2015; Moreira et al. 2018). Moreover, the capability of producing, manipulating and using relevant information becomes a crucial matter on planning and operating modern power grids, such as those called smart grids.

In this scenario, modern power meters, recently referred as smart meters, have been developed to calculate much more than usual power or energy terms (Souza et al. 2015; Bilal Shahid et al. 2012; Nanlin et al. 2014) and frequently, to do more than merely performing revenue metering (Bilal Shahid et al. 2012; Nanlin et al. 2014; Depuru et al. 2011; Fernandes et al. 2013; Dong et al. 2012).

Smart meters should be able to perform power quality monitoring, connect and disconnect consumers, send and receive information to/from the utility, interact with load sharing controllers, measure bidirectional energy flow, estimate hourly seasonal demand, and several other intelligent functions.

It is important to point out that most of these modern functionalities, associated with the smart meters, usually benefits the utility operation, bringing minor or no advantages to the consumers. Thus, it is expected that new generations of smart meters would also carry possible features to benefit both, consumers and utilities.

Wesley A. Souza
wesley@dsee.fee.unicamp.br

Fernando P. Marafão
fernando.marafao@unesp.br

Eduardo V. Liberado
eduardo.verri.liberado@gmail.com

Luiz C. P. Da Silva
lui@dsee.fee.unicamp.br

1 Department of Energy and Systems (DSE), School of Electrical and Computer Engineering (FEEC), University of Campinas (UNICAMP), Av. Albert Einstein, 400, Campinas, SP 13083-970, Brazil

2 Institute of Science and Technology of Sorocaba (ICTS), Univ. Estadual Paulista (UNESP), Av. Três de Março, 511, Sorocaba, SP 18087-180, Brazil

3 Department of Electrical Engineering, Colorado School of Mines, Golden, CO 80401, USA

An important issue is the identification and classification of a residential load connected to any installation (Fernandes et al. 2013; Dong et al. 2012; Huang et al. 2015; Belley et al. 2015), in such a way that the behavior and contribution of each appliance to the energy consumption could be determined. This information might be embedded into smart metering devices to help utilities and consumers to get constructive feedback for the power management (generation, operation, storage and consumption).

From the utility point of view, the residential load identification and characterization may allow detailed analysis and prediction of consumers' behavior, which may help to improve the power management and the estimation of actual power losses.

From the consumer's point of view, comprehensive information from the loads may help planning energy savings, as well as getting detailed consumption information in a given time frame (hourly, daily, monthly and yearly). According to the example presented in Fig. 1, the electric shower (6 kW resistive load) may be responsible for 19% of monthly residential electrical consumption. Based on this information and considering a nonintrusive system, the consumer could try to reduce hot shower time to save electricity. In case of hourly seasonal pricing, the consumers may save money if they were able to identify which appliances could or should be turned OFF when the energy price is higher. Moreover, the energy bill would be more transparent and informative for the consumers.

In this context and considering the constant evolution of embedded systems, especially regarding memory and processing capabilities, it is possible to implement sophisticated algorithms to improve the "smart" functionalities of a smart meter. This way, new methodologies have been proposed for appliance classification, such as harmonic decomposition technique using neural networks (NN) (Fernandes et al. 2013; Suppitaksakul and Saelee 2009) and event window monitoring techniques (Fernandes et al. 2013; Dong et al. 2012). These studies are usually based on NIALM (nonintrusive

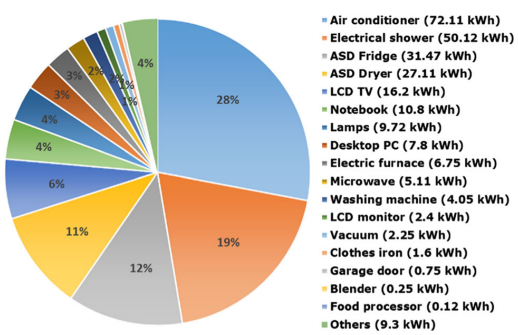

Fig. 1 Example of residential consumption discretization in 1 month

appliance load monitoring or also called NILM—nonintrusive load monitoring) technique (Fernandes et al. 2013; Dong et al. 2012; Huang et al. 2015; Belley et al. 2015), which tracks the load power behavior over time. Concerning pattern recognition algorithm, NN not always ensures good results or accuracy. Therefore, assuming the aim of residential load identification, it is necessary to take into account other algorithms, comparing them to obtain the most suitable for an effective classification.

As well as NILM techniques, there are other known disaggregation datasets, such as DRED, UK-DALE, GREEND, HES (Batra et al. 2014; Kelly and Knottenbelt 2014a, b; Anderson et al. 2012), however, under the load disaggregation scenario, these datasets provide just macroscopic information related to power consumption and execution time.

On the other hand, the dataset proposed in this paper is based on voltage and current waveforms (and related decompositions) and provides much more information than the active power. This data extraction method may be considered as a microscopic analysis under the load disaggregation scenario.

Most methods of NILM use macroscopic information and the features extraction from the current and voltage waveforms is an interesting way to increase the accuracy of load classification. Studies from (Guedes et al. 2015, 2016) use higher-order statistics and the results show high accuracy of the load classification.

Therefore, regarding smart meter improvements and appliance identification, this work presents two significant contributions:

1. The creation of a novel appliance dataset using the conservative power theory (CPT; Tenti et al. 2011a, b; Marafao et al. 2013). CPT is a useful tool for load characterization through orthogonal power components that can describe each appliance. In other words, each appliance has a kind of signature that can be obtained by applying the CPT definitions, and then, it is possible to create features for an original data collection.
2. A comprehensive review and comparison of Pattern Recognition Algorithms (PRA) under the proposed appliance dataset, on which the proposed dataset was applied to allow a better understanding among the considered PRA. This comparison shows the importance of recognizing which PRA is the most suitable for each application.

Finally, considering these two contributions, this paper presents a new computational approach to detect appliances connected to a residential installation through the application of PRA on a novel dataset composed by characteristics of

each load, such as power signatures, "ON" and "OFF" steps, CPT power components and others.

2 The Considered Smart Meter Concept and Applied Techniques

This work is related to the development of a significant methodology, intended to be applied in cognitive smart meters. According to the authors' conception of such meters, they are expected to be able to recognize different residential appliances connected to the grid through nonintrusive methods and PRA. Therefore, by proposing the use of CPT to create a proper dataset and then comparing the performance of different PRAs to be applied on such dataset, this paper defines an alternative method to identify each residential appliance after voltage and current measurements. If wanted or needed, this method can also be adapted to use NIALM technique, which would improve accuracy in the appliance recognition.

Figure 2 presents the authors' conception of a cognitive smart power meter (CSPM), which should be installed at the point of common coupling (PCC), i.e., at the same place where the conventional residential power meters are installed. The CSPM measures current and voltage signals at PCC and sends them to an internal embedded system responsible for data processing, storage, and communication. The proposed methodology (dashed square in Fig. 2 called Appliance Recognition Technique) is based on calculating the power components from CPT and creating a novel dataset (feature vector) for the training/prediction stage of the PRA. In this paper, the term sample is defined as a signal acquisition from the voltage and current waveforms, and the term instance represents a dataset sample with the respective features.

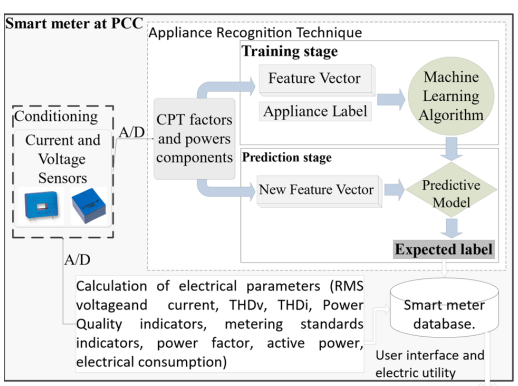

Fig. 2 Diagram of the proposed cognitive smart meter

During the training stage, PRA should receive the previously known appliances labels, and the set with features and label corresponds to one dataset instance. Thus, the supervised classification and the prediction model are built during the training stage using the dataset. It is also possible to use a previously built-in dataset, with real data, to create the prediction model.

In the prediction stage, the classifier receives the new feature vector instance and applies the prediction model to determine an appliance label for this instance.

For the dataset evaluation, five well-known machine learning methods: OPF—optimum-path forest (Papa et al. 2009); MLP—multilayer perceptron (Windeatt 2006); SVM—support vector machine (Alkan and Günay 2012); KNN—*K*-nearest neighbor (Cover and Hart 1967) and DT—decision tree (Azar and El-Metwally 2013; Zhang et al. 2011), have been compared in this work. Confusion matrix and the decision boundary were used to assess performance and accuracy characterization. The principal component analysis (PCA; Hotelling 1933) was used as a preprocessing step to reduce the overlaps.

The methods used in this work—CPT, SVM, OPF, MLP, KNN, DT and PCA—are shortly reviewed in the next section.

3 CPT: Conservative Power Theory Overview

Each residential load has a specific signature, i.e., a characteristic electric current waveform. CPT helps to define some features such as active, reactive, nonlinearity and unbalance behavior from the load signature. Theoretical foundations about the CPT can be found in (Tenti et al. 2011a, b; Marafao et al. 2013), and they will be briefly reviewed in the following.

Considering the signal sample k, the basic quantities defined by the CPT are the instantaneous active power, which is expressed by the scalar product of instantaneous voltages and currents:

$$p[k] = u[k]i[k] \tag{1}$$

and the instantaneous reactive energy, which is the result of the scalar product of unbiased integral of voltages and the instantaneous currents:

$$w[k] = \hat{u}[k]i[k] \tag{2}$$

on which:

$u[k]$ is the voltage sampling value; $i[k]$ is the current sampling value; $\hat{u}[k]$ is the unbiased integral value.

The unbiased phase integral is defined as in (3):

$$\hat{u}[k] = u[k] - \bar{u}[k] \tag{3}$$

on which $u_{\int} = \sum_{k}^{k+N} u[k]$ is the time integral and $\bar{u}_{k\int} = \frac{1}{N}\sum_{k}^{k+N} u_{\int}[k]$ is the average value of time integral. In this case, N is the quantity of samples in one cycle.

The average values of (1) and (2) result in the active power (P) and average reactive energy (W), respectively, and they are expressed as in (4) and (5).

$$P = \bar{p} = \frac{1}{N}\sum_{k}^{k+N} p[k] \tag{4}$$

$$W = \bar{w} = \frac{1}{N}\sum_{k}^{k+N} w[k]. \tag{5}$$

3.1 Current Components from CPT

Based on the quantities defined in (4) and (5) and as shown in (Tenti et al. 2011a), CPT offers a current decomposition in orthogonal components that represent different load characteristics. These components are described as follows:

- *Active current* (i_a): is the minimum current responsible for active power consumption in each phase of a circuit;
- *Reactive current* (i_r): is the minimum current responsible for reactive energy flowing in each phase of a circuit;
- *Void current* (i_v): this current component is neither related to active power nor reactive energy and appears due to nonlinearities between voltages and currents.

These three current components are orthogonal to each other, i.e., the average scalar product among then results in zero. Therefore, it is possible to express an equation that relates the RMS values of the current components and the total current, as follows:

$$I^2 = I_a^2 + I_r^2 + I_v^2 \tag{6}$$

The terms in (6) are calculated by the square root of RMS values from the phase of the circuit.

3.2 Power Components from CPT

Each current component indicated in (6) is associated with a power component through the product of RMS values of the correspondent current components and voltage. Thus, the apparent power (A) can be expressed as the sum of active power (P), reactive power (Q), and distortion power (D):

$$A^2 = U^2 I^2 = P^2 + Q^2 + D^2. \tag{7}$$

3.3 Load Conformity Factors

Since the CPT power components can be calculated under distorted and/or unbalanced networks, its power components can be beneficial to outline performance or conformity factors (indexes) that allow load characterization under different operating conditions. Thus, two possible performance factors (Tenti et al. 2011b) are summarized in the following.

The distortion (nonlinearity) factor can be calculated by:

$$\lambda_D = 1 - \frac{I_V}{I} \tag{8}$$

Regarding load analysis, such factor represents the presence of distortion power (or void current), which does not contribute to active or reactive powers. It is mainly related to voltage and current's nonlinearities, which may increase power losses on the circuit, decreasing its efficiency. Such factor is unitary only if $I_V = 0$, which occurs only in case of linear circuits supplied by sinusoidal voltages.

The reactivity factor can be defined as:

$$\lambda_Q = 1 - \frac{I_r^b}{I} \tag{9}$$

This factor indicates the presence of reactive energy from inductive and capacitive loads, or even from nonlinear loads.

Considering single-phase circuits, with sinusoidal supply voltages, the reactivity factor could be calculated directly from $\lambda_Q = \sin\phi$, being ϕ the phase angle between any of the phase voltages and currents.

Finally, the general (total) power factor can be calculated as follows:

$$\lambda = \frac{P}{A} = \frac{P}{\sqrt{P^2 + Q^2 + D^2}} = \lambda_D \lambda_Q \tag{10}$$

This power factor relates balanced active current to all other current components and equals to unity only if the load is purely resistive and balanced, irrespective of supply voltages. The presence of any other types of load affects the total power factor. Moreover, a balanced pure resistive load may have unitary power factor even in the presence of nonsinusoidal and/or asymmetry source voltages.

Considering normal operating conditions of distribution systems, this is a much more appropriate definition of power factor, as an efficiency factor, than several others in international standards or literature. Besides, through (10) and the previously defined conformity factors, it is also possible to understand the influence of reactive power, load unbalances and nonlinearities on the power factor value.

The CPT conformity factors are used to create the appliance characterization dataset presented in Sect. 5. The next section presents the PRA and the performance indexes used

in this work. The PRA validate the appliance dataset, and the performance indexes assess the best PRA for this methodology.

4 Pattern Recognition and Performance Algorithms: A Brief Overview

To validate the proposed appliance dataset, different PRA, and the PCA techniques are used. Thus, the following sections summarize the main idea behind each applied method:

4.1 Optimum-Path Forest

The optimum-path forest (OPF) was proposed in (Papa et al. 2009), and it is based on the IFT (image foresting transform) proposed in (Falcão et al. 2004). However, the OPF can be applied to any dataset (Luz et al. 2013), unlike the IFT that is only used for images.

The OPF algorithm is efficient in the training process (fit) and effective in the classification process (predict). Its mathematical approach is simple and based on graph theory, as well as other classical algorithms, such as minimum spanning tree (MST) and shortest path forest (SPF).

In this method, there are two stages: training (fit) and classification (predict). The fit stage consists in applying a distance algorithm between each instance to the others of a given dataset with labels (classes); thus, creating a complete graph. After determining the MST of the graph, the algorithm looks for each connection (edge) that have two nodes (vertices) with different labels and cut up that connection; thus these two nodes become prototypes (roots) which will be used as parameters for the pattern classification in the predicted process. In other words, the minimum spanning tree is broken into several minimum trees with the same label, thus becoming an optimum-path forest.

The OPF predict phase consists of assigning a label to every new instance. For this, the distance between the instance and each prototype is calculated, and the instance receives the label of the root prototype that has the smallest distance to it. In the end, all dataset instances will be labeled and consequently classified. Figure 3 shows the OPF training and classification process. All the mathematical background can be found in (Papa et al. 2009).

4.2 Multilayer Perceptron

Formally, a one-hidden-layer MLP constitutes a function $f{:}R^D \rightarrow R^L$, where D is the size of input vector x and L is the size of the output vector $f(x)$, which in matrix notation, is expressed in (11).

$$f(x) = G\left\{b^{(2)} + W^{(2)}\left[s\left(b^{(1)} + W^{(1)}x\right)\right]\right\} \tag{11}$$

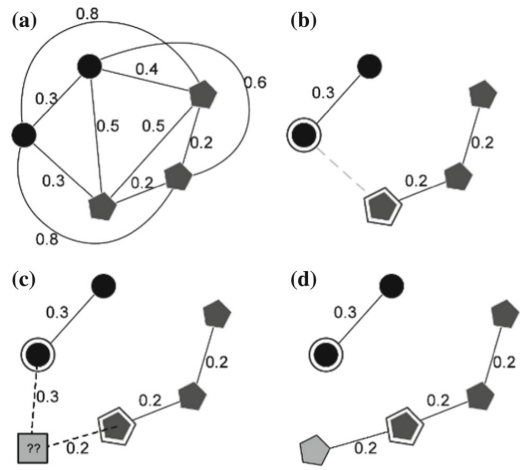

Fig. 3 OPF fit and predict phases: **a** complete graph; **b** MST with partitioning and selection of root prototypes; **c** predict step with a new instance and its distance to the prototypes, **d** the nearest prototype determines the label of that instance

with bias vectors $b^{(1)}$, $b^{(2)}$; weight matrices $W^{(1)}$, $W^{(2)}$ and activation functions G and s.

The vector $h(x) = \phi(x) = s(b^{(1)} + W^{(1)}x)$ consists in the hidden layer, while $W^{(1)} \in R^{D \times D_h}$ is the weight matrix connecting the input vector to the hidden layer.

Each column $W_i^{(1)}$ represents the weights from the input units to the i-th hidden unit. Typical choices for s include hyperbolic tangent $\tanh(a) = (\exp(a) - \exp(-a))/(\exp(a) + \exp(-a))$, or the logistic sigmoid function $\text{sigmoid}(a) = 1/(1 + \exp(-a))$. In this application, the *tanh* will be used because it typically yields to faster training. Both *tanh* and *sigmoid* are scalar-to-scalar functions, but their natural extension to vectors and tensors consists in applying them element-wise, e.g., independently on each element of a vector, yielding to a same-size vector. The output vector is then obtained as $o(x) = G[b^{(2)} + W^{(2)}h(x)]$. More information about the MLP method can be found in Windeatt (2006).

4.3 Support Vector Machine

SVM is a mathematical tool that can also be applied to pattern recognition, once that it is based on the structural risk minimization principle and tries to find a hyperplane in high-dimensional feature space to solve some linearly inseparable problems (Alkan and Günay 2012). The kernel function is introduced into the SVM so that the original input space can be linearized into a higher dimensional feature space where linear methods may be applied. The objective function adopted in this study is the Gaussian radial basis function (RBF) since their effectiveness has been proved in many clas-

sification problems (Alkan and Günay 2012). It is expressed in (12):

$$K(x_i \cdot x) = \exp\left(-\gamma x_i - x^2\right) \tag{12}$$

on which γ is the RBF kernel parameter.

The main advantages of support vector machine are:

- Effectiveness in high-dimensional spaces.
- Still effective in cases on which the number of dimensions (features) is higher than the number of instances.
- Uses a subset of training points in the decision function (called support vectors), so it is also memory efficient.
- Versatile: different Kernel functions can be specified for the decision function. Common kernels are provided, but it is also possible to specify custom kernels.

The disadvantages of support vector machines include:

- If the number of features is much higher than the number of instances, the method usually has poor performances.
- SVMs do not directly provide probability estimation, which is calculated using an expensive fivefold cross-validation.

4.4 *K*-Nearest Neighbor

K-nearest neighbor is a nonparametric classifier that has been extensively studied and used in the literature (Cover and Hart 1967). The 1-NN is a specific case of *K*NN, on which the neighborhood level is 1 ($K = 1$). In the *K*NN case, a new instance is classified according to the class of the nearest instance that is in the training group. Therefore, the prediction is made based on the label of the nearest neighbor. Figure 4 shows the classifier behavior when the neighbor's level is one, three and five.

This classifier is very similar to the OPF because both methods are based on the minimum distance between instances. However, the OPF uses a graph structure, graph theory and the concept of prototypes. OPF becomes equivalent to 1-NN when all the training instances as prototypes are defined in the classification process. Thus, the significant difference between OPF and 1-NN is the existence of a maximum number of one type of prototypes using the minimum distances between instances and prototypes.

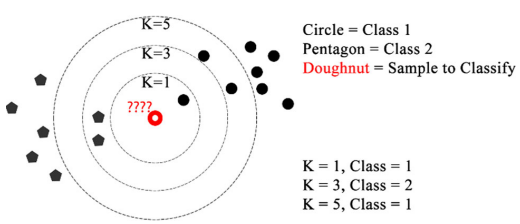

Fig. 4 KNN classifier behavior when $K = 1$, $K = 3$ and $K = 5$

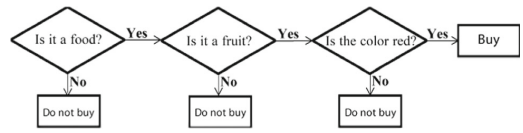

Fig. 5 A DT example

4.5 Decision Tree

Primarily used in classification algorithms, the decision trees are simple knowledge representations and an efficient way to build classifiers that predict or indicate classes or information based on the featured values of a data set. They are very useful for data mining, i.e., the process of extracting unknown information from large databases. Applications of this technique can be seen in several areas, from business scenarios to autopilot systems of aircraft and medical diagnostics (Azar and El-Metwally 2013; Zhang et al. 2011).

A decision tree is a series of if-else statements applied to each instance from a dataset, resulting in their classification. The most interesting thing about decision trees is their ability of easy learning. When the training process is completed, it is possible to feed the decision tree constructed from particular examples with new ones to classify them. Figure 5 shows one representation of DT behavior for one dataset with two classes ("buy" or "do not buy") and three features ("Food?", "Fruit?" and "Is red?").

4.6 Principal Component Analysis

The principal component analysis (PCA) is a method that aims to analyze the dataset to reduce it by removing overlaps and choosing ways of representing data from linear combinations of the original variables.

It is also called Karhunen–Loève transform (KLT) or Hotelling Transform in honor of Kari Karhunen, Michel Loève, and Harold Hotelling. The PCA transforms the discrete variables into uncorrelated coefficients.

PCA is one of the most straightforward and commonly used methods for multivariate statistical models, and it is also considered as an optimal linear transformation (therefore is a good solution for the pattern recognition algorithms that have linear behavior). The mathematical formulation can be found in (Hotelling 1933).

All the methods presented in this section were used with the dataset presented in Sect. 5, and the results are discussed in Sect. 6.

Table 1 List of considered appliances and corresponding average active power and CPT factors

Appliance	Class	P (W)	λ	λ_Q	λ_D	Appliance	Class	P (W)	λ	λ_Q	λ_D
Light bulb	1	55.4	0.735	0.832	0.851	Sodium lamp	19	69.5	0.860	0.988	0.871
Air conditioning	2	928.3	0.804	0.804	1.000	ASD dryer	20	433.3	0.868	0.981	0.878
Refrigerator	3	113.9	0.656	0.656	1.000	ASD fridge	21	102.1	0.856	0.873	0.982
Microwave	4	1071.0	0.942	0.990	0.950	Blender	22	118.5	0.967	0.972	0.995
CRT TV	5	91.0	0.635	0.998	0.635	Bread maker	23	85.4	0.695	0.704	0.993
LCD TV	6	143.1	0.997	0.997	0.998	Desktop PC	24	102.3	0.710	1.000	0.710
Plasma TV	7	174.5	0.995	1.000	0.995	Electronic ball lamp	25	22.5	0.560	0.932	0.601
Electrical shower	8	4765.4	1.000	1.000	1.000	Food processor	26	146.9	0.968	0.981	0.987
RL load 1	9	1012.7	0.844	0.844	1.000	Freezer	27	135.3	0.733	0.738	0.995
NL load 1	10	74.0	0.537	0.994	0.539	Furnace	28	468.2	0.834	0.838	0.995
NL load 2	11	145.2	0.615	0.993	0.621	Garage door	29	433.6	0.851	0.859	0.991
RL load 2	12	504.7	0.967	0.967	1.000	Laptop	30	72.1	0.597	0.962	0.622
Iron	13	1424.9	1.000	1.000	1.000	LCD monitor	31	38.5	0.592	0.966	0.624
Washing machine	14	1951.3	0.732	0.732	1.000	Regular dryer	32	1799.1	0.782	0.782	1.000
Hairdryer	15	812.5	0.942	0.942	1.000	Regular fridge	33	119.6	0.937	0.942	0.987
Fluorescent lamp	16	100.0	0.607	0.814	0.752	Vacuum	34	954.5	0.975	0.982	0.992
Mix lamp	17	93.2	0.950	0.995	0.951	Washer	35	256.7	0.355	0.441	0.805
Mercury lamp	18	64.5	0.929	0.991	0.938						

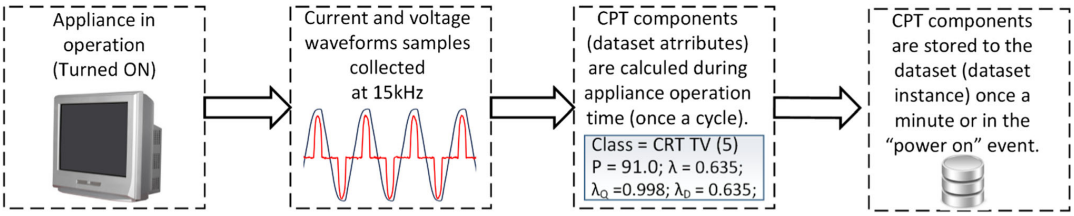

Fig. 6 Methodology for creating the proposed dataset by means of the CPT decompositions

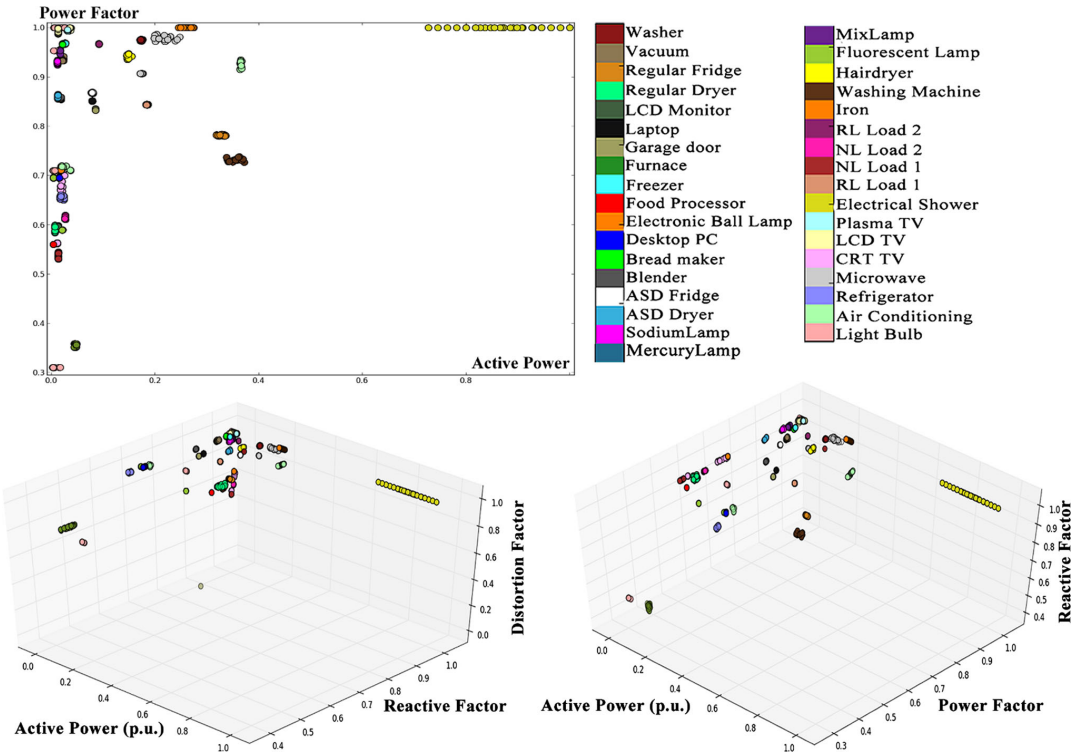

Fig. 7 Dimensional representation of the created dataset

4.7 Confusion Matrix

The confusion matrix evaluates the classifier output quality when applied to a dataset, showing how the pattern recognition method confuses one class to another. Typically, the confusion matrix is of the form $(m \times m)$, where m is the number of classes defined. The Confusion Matrix represents the instances of a predicted class while each row represents the actual class; it is used to measure the quality of the classification. The main diagonal elements represent the number of points for which the predicted label is equal to the right label, while off-diagonal elements are those that are mislabeled by the classifier. The higher the diagonal values of the confusion matrix, the better is the classifier performance, regarding correct predictions. One of the most important features of these matrices is that they summarize the commission errors (also known as inclusion errors which are the instances that do not belong to the class and were assigned to it) and omission errors (instances belonging to the class concerned and were not assigned to it).

From the confusion matrix, it is possible to calculate an index of precision (accuracy) of the total score, as the Global

Error Index, the Kappa and Tau Index. For validation and calculation accuracy in this paper, the confusion matrices of each method are presented in graphical mode.

4.8 Decision Boundary

A decision boundary is a hyperplane or hypersurface that separates space into class-labeled decision regions, which represents the instances fitting a particular region. This feature can provide visual perception about separation of two or more classes, and it can present instances that would be incorrectly classified when they have misclassified color instances in different color regions. Moreover, the classifiers' difference can also be measured by comparing their decision boundary curvature.

5 Proposed Dataset for Residential Loads

5.1 Dataset Establishment

The dataset was established using voltage and current measurements from a real installation considering single-phase circuits, on which the nominal voltage has a 127 Vrms/60 Hz sinusoidal waveform. The current was acquired through an SCT-03 sensor with sample rate equal to 15 kHz (250 *samples for each cycle of* 60 Hz). Thus, the corresponding power terms and conformity factors from CPT were calculated. Table 1 shows the most relevant information for each considered appliance, which was used to establish the proposed dataset, according to the diagram of Fig. 6.

Each instance collected and recorded in the dataset according to Fig. 6 has five features: class; P—active power (4); λ—power factor (10); λ_Q—reactive factor (9) and λ_D—distortion factor (8). The dataset stores 100 instances for each class (or appliance) with all features. Their average values are shown in Table 1, and they help to understand the representative data and CPT quantities. The stored data were used as input for the training and classification stages of each evaluated PRA.

The first feature corresponds to the appliance class number that varies from 1 to 35 according to Table 1 (e.g., if the class is 5, the instance corresponds to a "CRT TV" measurement). In this paper, the instances were collected from different appliance models and types, thus the base becomes more comprehensive. The flexibility of pattern recognition by class approximation assists the accurate load identification.

5.2 Data Normalization

A normalization process was applied in the dataset to equalize the dataset dimensions and to normalize the distance between the instances. Therefore, the active power (P) in each instance was normalized to p.u. (per unit), i.e., it was compressed between 0 and 1, since different residential appliances may have entirely different values of active power. The normalization of all features results in scaled data, and it improves the performance of metric functions.

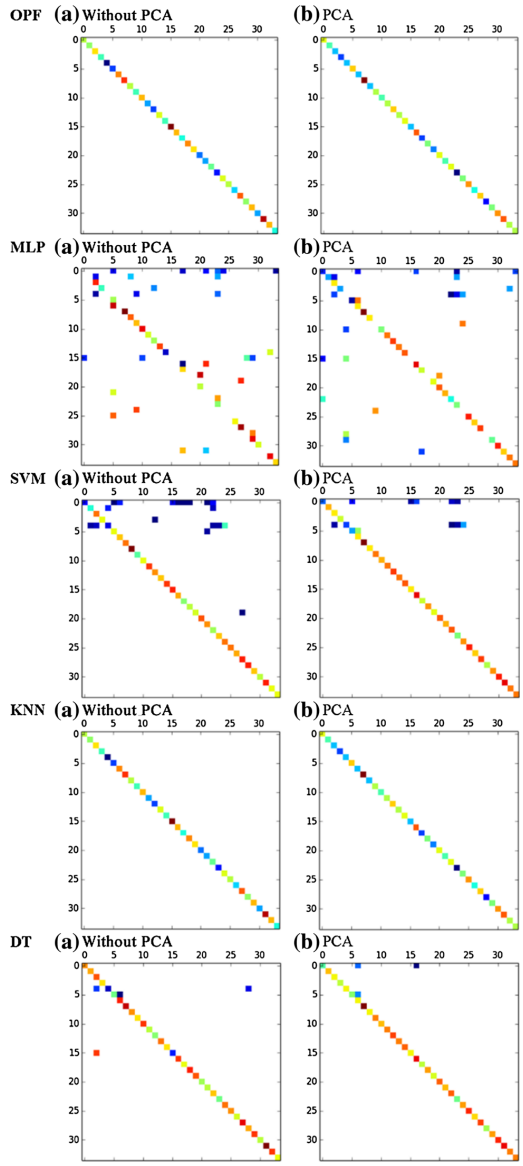

Fig. 8 Results using the confusion matrix

Table 2 Accuracy and average computational time (in s)

Method	Accuracy	Fit execution time (avg.)	Predict execution time (avg.)	One instance predict execution time (avg.)
OPF	0.9982 ± 0.0014	9.7074 ± 1.0983	4.8087 ± 0.2339	0.0048 ± 0.0146
OPF (PCA)	0.9971 ± 0.0005	9.5534 ± 1.2298	3.8482 ± 0.3801	0.0033 ± 0.0101
MLP	0.8875 ± 0.1192	8.2209 ± 1.3394	0.0883 ± 0.0127	0.0377 ± 0.0114
MLP (PCA)	0.9122 ± 0.0738	7.9821 ± 1.2287	0.1179 ± 0.0101	0.0389 ± 0.0093
SVM	0.9098 ± 0.0382	0.0578 ± 0.0092	0.1175 ± 0.0285	0.0459 ± 0.0193
SVM (PCA)	0.9152 ± 0.0302	0.0681 ± 0.0083	0.0994 ± 0.0184	0.0567 ± 0.0115
KNN	0.9987 ± 0.0011	N/A	0.0399 ± 0.0093	0.0073 ± 0.0018
KNN (PCA)	0.9988 ± 0.0009	N/A	0.0384 ± 0.0083	0.0101 ± 0.0077
DT	0.9161 ± 0.0228	0.0145 ± 0.0098	0.0297 ± 0.0018	0.0160 ± 0.0088
DT (PCA)	0.9227 ± 0.0294	0.0271 ± 0.0081	0.0108 ± 0.0022	0.0073 ± 0.0010

The dataset has a typical dimensional format as shown in Fig. 7.

It is possible to observe in Fig. 7 that some patterns are close and do not allow linear separation, in such a way that some PRA methods may not get reasonable accuracy. There is also some cases of overlap, but the classes are separable by some PRA methods when is using all the dataset features.

6 Comparison of Different PRA: Results and Discussion

Considering the proposed dataset and studied pattern recognition methods, this section aims to spot the most suitable PRA to identify residential loads from voltage and current measurements in a smart meter.

For results, the dataset was randomly split into two sets:

- *Training dataset* the majority (70%) was used to estimate the predictive model parameters;
- *Testing dataset* the remaining data (30%) were reserved to evaluate the predictive model and to perform the classification.

The training stage is done considering the training dataset containing all attributes including the classes (supervised learning). The training stage is done considering the testing data without the classes. In the training stage, the machine learning algorithm is responsible for the class identification through the classifier model created in the training stage.

Figure 8 presents the confusion matrices of the testing data, while Table 2 presents the percent accuracy and the average time of the testing data effort when each algorithm was executed fifteen times.

Figure 9 presents the resultant decision boundaries of each classifier described in Sect. 4 when applied to the testing data of the proposed dataset with and without the PCA decomposition. Usually, a pattern classifier tessellates the feature space into volumes called decision boundaries (or decision regions). All feature vectors in a decision boundary are assigned to the same category (same color in Fig. 9). The decision boundaries in this paper are used to observe the classifier behavior and accuracy.

The graph analyses and results were performed on an Ubuntu Linux emulator with two cores i5-3317U and 2 GB of dedicated RAM and the programming language applied for the evaluation was Python 2.7.

From Figs. 8 and 9, Tables 2 and 3, which presents the strengths and weaknesses of each PRA for the proposed dataset, two conclusions arise from the PRA comparison.

First, one may conclude that OPF and KNN algorithms have the best classification levels (with better effectiveness and better efficiency), and the KNN is the fastest algorithm to classify the proposed dataset.

Second, when analyzing the errors of each algorithm, mainly looking at the confusion matrices of Fig. 9, one may notice that there are some confusion possibilities, especially because the current waveforms of some residential loads have very similar characteristics, as discussed in the following:

- Incandescent lamp, LCD TV, and Plasma TV: the incandescent lamp without dimmer has purely resistive behavior, so the power factor, reactivity and nonlinearity factors will be close to 1. Besides, LCD and Plasma TVs with Power Factor Pre-regulators have the current behavior close to the resistive characteristic of incandescent lamps.
- Incandescent lamp with dimmer and fluorescent lamp: the dimmer used in the incandescent lamp decreases the power factor and nonlinearity factor considerably. Due to the low value of the active power of an incandescent lamp, some classifiers may mix it with the fluorescent lamp.

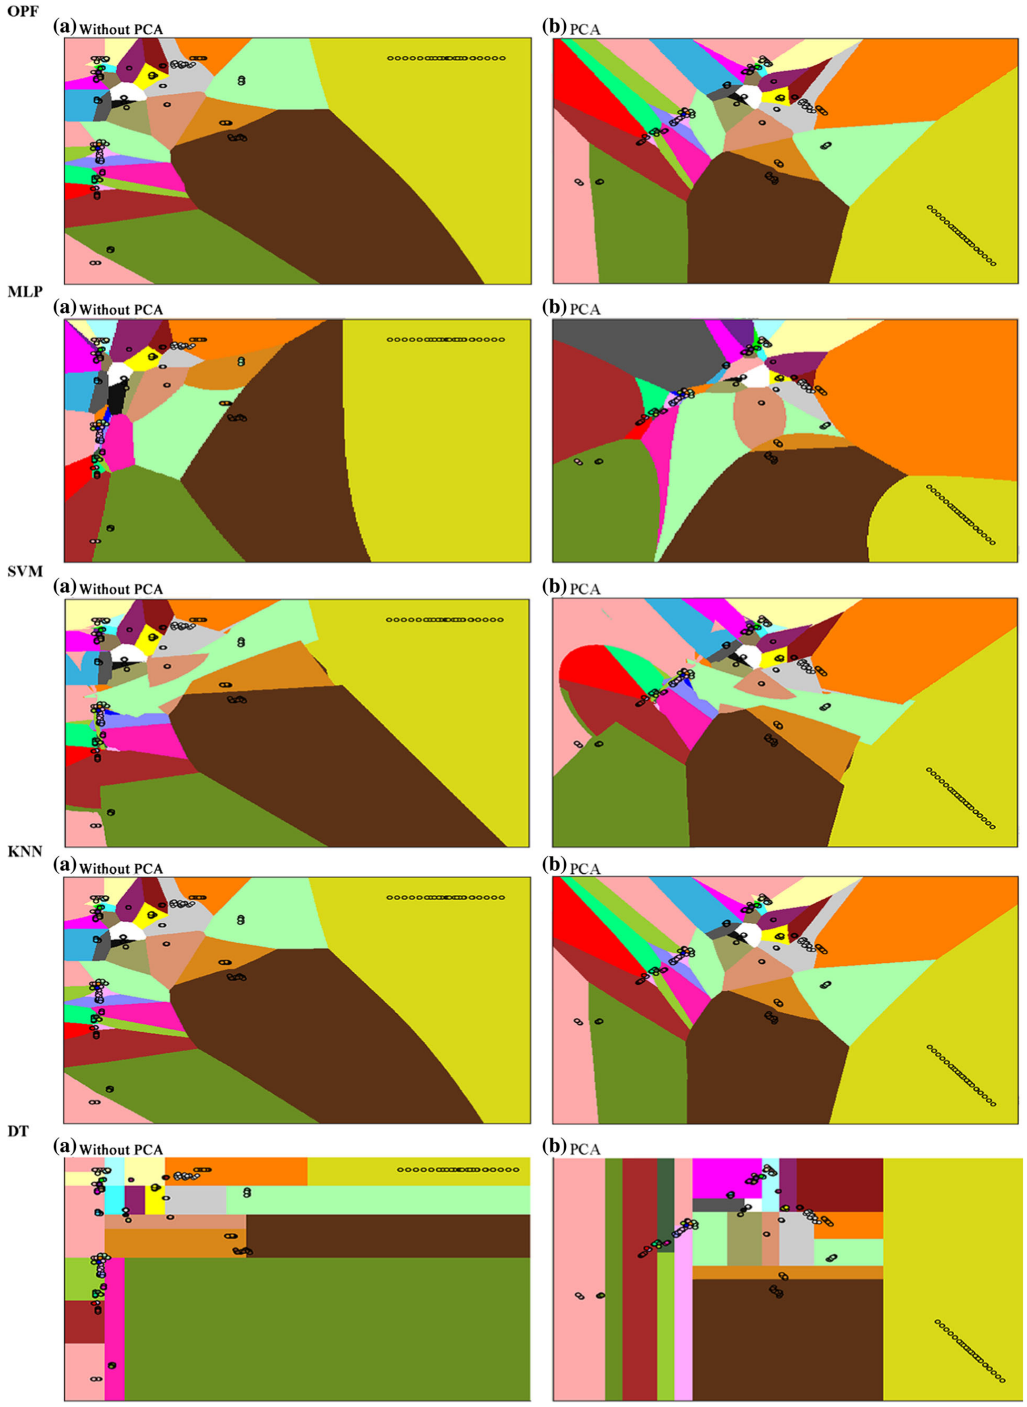

Fig. 9 Decisions boundaries of the appliance dataset based on different PRA techniques, with and without PCA decomposition

Table 3 Strengths and weakness of the evaluated pattern recognition algorithms

Algorithm	Strengths and weakness
PCA	(a) The decomposition makes a rotation in the points, which helps the pattern recognition algorithms with linear behavior like DT
	(b) DT, MLP and SVM confusion matrices were noticeably improved when using the PCA decomposition
DT	(c) The DT is purely linear and did not obtain a good accuracy for the proposed dataset. The PCA decomposition increases the DT accuracy, but not enough compared to other evaluated PRA
	Items (a), (b), (h) and (k) are also highlighted
MLP	(d) The MLP was not very good for the classification, because some classes are very close and also have some intersections to the others
	Items (b), (h), (i) and (j) are also highlighted
SVM	(e) The SVM algorithm has a radial basis function, on which the PCA did not help as expected and did not obtain a reasonable level of classification, as the most accurate methods
	Items (b) and (h) are also highlighted
KNN ($K = 1$)	(f) KNN (where $K = 1$) and OPF algorithms have the decision boundary almost identical, as mentioned in Sect. 4. These methods made more effective classification of instances
	(g) The KNN and OPF confusion matrices had almost no off-diagonal elements, thus presenting a high level of accuracy. Therefore, these algorithms are more effective for this dataset
	(h) The KNN and OPF accuracy are higher than the MLP, DT, and SVM because KNN and OPF do not have linear behavior
	(i) In the prediction process of each instance, the MLP has the highest computational time, and the KNN and OPF are the fastest ones
	Item (j) is also highlighted
OPF	(j) The OPF and MLP methods are less efficient (more considerable computational time) than the others in the fit process, and the KNN is the most efficient (fast) because it does not have the fitting stage
	(k) In the prediction process, OPF has the highest computational time, and DT has the lowest
	Items (g), (h) and (i) are also highlighted

- Furnace and garage door: their conformity factors and power terms have closer values, as it can be seen in Table 1. Thus, some methods have confused these two appliances. The same happens with the vacuum and microwaves, the RL1 and the washing machine, and among mixed lamps, mercury vapor and sodium vapor.

7 Conclusion

A new dataset to detect and classify residential appliances is presented in this paper, by calculating CPT power indicators and applying a proper classifier algorithm over them. CPT offers an interesting mathematical modeling for the dataset definition, because it decomposes the apparent power in resistive, reactive and nonlinear terms, like an equivalent circuit. For this reason, it was possible to create a novel machine learning dataset, allowing the use of pattern recognition algorithms to classify different appliances under operation.

Five pattern recognition algorithms were implemented, tested and compared regarding accuracy, effectiveness and computational efficiency when applied to classify the created appliance dataset. The comparison results indicate that KNN is the most suitable for the proposed dataset, due to their higher efficiency and effectiveness concerning other algorithms.

Finally, when embedded in a programmable modern smart meter, the proposed methodology may allow disaggregating any residential appliance connected to a determined PCC. Therefore, the information of each appliance (e.g., its power consumption, time of use, and others) may be available to consumers for managing the power consumption and searching for possible economic and energy savings.

Acknowledgements This work was supported in part by the São Paulo Research Foundation (FAPESP), Grants 2012/19375-1 and 2016/08645-9, and by Companhia Paulista de Força e Luz, Grant PD ANEEL-0063-3032/2017.

References

Alkan, A., & Günay, M. (2012). Identification of EMG signals using discriminant analysis and SVM classifier. *Expert Systems with Applications, 39*(1), 44–47. https://doi.org/10.1016/j.eswa.2011.06.043.

Anderson, K., Ocneanu, A., Benitez, D., Carlson, D., Rowe, A., & Berges, M. (2012). BLUED: A fully labeled public dataset for event-based non-intrusive load monitoring research. In *Proceedings of the 2nd KDD workshop on data mining applications in sustainability* (*SustKDD*). August.

Azar, A. T., & El-Metwally, S. M. (2013). Decision tree classifiers for automated medical diagnosis. *Neural Computing and Applications, 23,* 2387–2403. https://doi.org/10.1007/s00521-012-1196-7.

Bamachandran, B., Srivastava, S. K., & Cartes, D. A. (2013). Intelligent power management in micro grids with EV penetration. *Expert Systems with Applications, 40*(16), 6631–6640. https://doi.org/10.1016/j.eswa.2013.06.007.

Batra, N., Kelly, J., Parson, O., Dutta, H., Knottenbelt, A., Rogers, A., Singh, A., & Srivastava, M. (2014). *NILMTK*: *An open source toolkit for non-intrusive load monitoring*. In *Proceedings of the 5th international conference on future energy systems* (*ACM e-energy*). Cambridge.

Belley, C., Gaboury, S., Bouchard, B., & Bouzouane, A. (2015). Non-intrusive system for assistance and guidance in smart homes based on electrical devices identification. *Expert Systems with Applications, 42*(19), 6552–6577. https://doi.org/10.1016/j.eswa.2015.04.024.

Bilal Shahid, E., Ahmed, Z., Faroqi, A., & Navid-ur-Rehman, R. M. (2012). Implementation of smart system based on smart grid smart meter and smart appliances. In *IEEE Iranian conference on smart grids* (*ICSG*). Tehran.

Bollen, M. H. J. (2000). *Understanding power quality problems. Voltage sags and interruptions. Power engineering*. New York: IEEE Press.

Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory, 13*(1), 21–27. https://doi.org/10.1109/TIT.1967.1053964.

Depuru, S. S. S. R., Wang, L., & Devabhaktuni, V. (2011). Smart meters for power grid: Challenges, issues, advantages and status. *Renewable and Sustainable Energy Reviews, 15*(6), 2736–2742. https://doi.org/10.1016/j.rser.2011.02.039.

Dong, M., Meira, P. C. M., Xu, W., & Freitas, W. (2012). An event window based load monitoring technique for smart meters. *IEEE Transactions on Smart Grid, 3*(2), 787–796. https://doi.org/10.1109/TSG.2012.2185522.

Dugan, R. C., Mcgranaghan, M. F., & Beaty, H. W. (2000). *Electrical power systems quality* (2nd ed.). New York: Mcgraw Hill.

Falcão, A. X., Stolfi, J., & Lotufo, R. A. (2004). The image foresting transform: Theory, algorithms, and applications. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 26*(1), 19–29. https://doi.org/10.1109/TPAMI.2004.1261076.

Fernandes, R. A. S., Silva, I. N., & Oleskovicz, M. (2013). Load profile identification interface for consumer online monitoring purposes in smart grids. *IEEE Transactions on Industrial Informatics, 9*(3), 1507–1517. https://doi.org/10.1109/TII.2012.2234469.

Guedes, J. D. S., Ferreira, D. D., & Barbosa, B. H. G. (2016). A non-intrusive approach to classify electrical appliances based on higher-order statistics and genetic algorithm: A smart grid perspective. *Electric Power Systems Research, 140,* 65–69. https://doi.org/10.1016/j.epsr.2016.06.042.

Guedes, J. D. S., Ferreira, D. D., Barbosa, D. H. G., & Duque, C. A. (2015). Non-intrusive appliance load identification based on higher-order statistics. *IEEE Latin America Transactions, 13,* 3343–3349. https://doi.org/10.1109/TLA.2015.7387241.

Hotelling, H. (1933). Analysis of a complex of statistical variables into principal components. *Journal of Educational Psychology, 24,* 417–441. https://doi.org/10.1037/h0071325. **(pp. 498–520)**.

Huang, T. D., Wang, W. S., & Lian, K. L. (2015). A new power signature for nonintrusive appliance load monitoring. *IEEE Transactions on Smart Grid, 6*(4), 1994–1995. https://doi.org/10.1109/TSG.2015.2415456.

Kelly, J., & Knottenbelt, W. (2014). '*UK-DALE*': *A dataset recording UK domestic appliance-level electricity demand and whole-house demand*. ArXiv e-prints.

Kelly, J., & Knottenbelt, W. (2014). *Metadata for energy disaggregation*. ArXiv e-prints, March.

Liberado, E. V., Marafão, F. P., Simões, M. G., Souza, W. A., & Pomilio, J. A. (2015). Novel expert system for defining power quality compensators. *Expert Systems with Applications, 42*(7), 3562–3570. https://doi.org/10.1016/j.eswa.2014.12.032.

Lima, M. A. A., Cerqueira, A. S., Coury, D. V., & Duque, C. A. (2012). A novel method for power quality multiple disturbance decomposition based on independent component analysis. *International Journal of Electrical Power and Energy Systems, 42*(1), 593–604. https://doi.org/10.1016/j.ijepes.2012.05.004.

Luz, E. J. S., Nunes, T. M., Albuquerque, V. H. C., Papa, J. P., & Menotti, D. (2013). ECG arrhythmia classification based on optimum-path forest. *Expert Systems with Applications, 40*(9), 3561–3573. https://doi.org/10.1016/j.eswa.2012.12.063.

Marafao, F. P., Souza, W. A., Liberado, E. V., Silva, L. C. P., & Paredes, H. K. M. (2013). Load analyser using conservative power theory. *Przeglad Elektrotechniczny, 89*(12), 1–6.

Moreira, A. C., Paredes, H. K. M., de Souza, W. A., et al. (2018). Evaluation of pattern recognition algorithms for applications on power factor compensation. *Journal of Control, Automation and Electrical Systems, 29,* 75. https://doi.org/10.1007/s40313-017-0352-9.

Nanlin, J., Flach, P., Wilcox, T., Sellman, R., Thumim, J., & Knobbe, A. (2014). Subgroup discovery in smart electricity meter data. *IEEE Transactions on Industrial Informatics, 10*(2), 1327–1336. https://doi.org/10.1109/TII.2014.2311968.

Papa, J. P., Falcão, A. X., & Suzuki, C. T. N. (2009). Supervised pattern classification based on optimum-path forest. *International Journal of Imaging Systems and Technology, 19*(2), 120–131. https://doi.org/10.1002/ima.20188.

Souza, W. A., Marafao, F. P., Liberado, E. V., Diniz, I. S., & Serni, P. J. A. (2015). Power quality, smart meters and additional information from different power terms. *IEEE Latin America Transactions, 13*(1), 158–165. https://doi.org/10.1109/TLA.2015.7040643.

Suppitaksakul, C., & Saelee, V. (2009). Application of artificial neural networks for electrical losses estimation in three-phase transformer. *International Conference on Electrical Engineering/Electronics, Computer, Telecommunications and Information Technology (ECTI-CON), 1,* 248–251. https://doi.org/10.1109/ECTICON.2009.5137002.

Tenti, P., Paredes, H. K. M., Marafão, F. P., & Mattavelli, P. (2011a). Accountability in smart microgrids based on conservative power theory. *IEEE Transactions on Instrumentation and Measurement*. https://doi.org/10.1109/TIM.2011.2162351.

Tenti, P., Paredes, H. K. M., & Mattavelli, P. (2011b). Conservative power theory, a framework to approach control and accountability issues in smart microgrids. *IEEE Transactions on Power Electronics, 26*(3), 664–673. https://doi.org/10.1109/TPEL.2010.2093153.

Windeatt, T. (2006). Accuracy/diversity and ensemble MLP classifier design. *IEEE Transactions on Neural Networks, 17*(5), 1194–1211. https://doi.org/10.1109/TNN.2006.875979.

Zhang, S., She, W., Wang, M., & Duan, Z. (2011). A two-stage decision tree algorithm on constructing hyper-plane. *Applied Informatics and Communication*. https://doi.org/10.1007/978-3-642-23220-6_40.

Journal of Control, Automation and Electrical Systems (2018) 29:75–90
https://doi.org/10.1007/s40313-017-0352-9

Evaluation of Pattern Recognition Algorithms for Applications on Power Factor Compensation

Alexandre C. Moreira[1] · Helmo K. M. Paredes[2] · Wesley A. de Souza[3] · Pedro H. J. Nardelli[4] · Fernando P. Marafão[2] · Luiz C. P. da Silva[3]

Received: 29 June 2017 / Revised: 18 October 2017 / Accepted: 18 November 2017 / Published online: 5 December 2017
© Brazilian Society for Automatics–SBA 2017

Abstract
This paper assesses different applied pattern recognition algorithms to decide the most appropriate power factor compensator for a particular point of common coupling. Power factor, current unbalance factor, total demand distortion, voltage harmonic distortion and reactive power daily variation, as well as human expertise, are the key parameters used to set each recognition algorithm. These algorithms are then trained with a series of both simulation and experimental data. Numerical results consistently indicate the decision-tree algorithm with depth 20 as the best classifier for power factor improvement in terms of all metrics considered in this work.

Keywords Active compensators · Passive compensators · Pattern recognition · Power factor · Reactive and harmonic compensation

Alexandre C. Moreira
amoreira@ufsj.edu.br

Helmo K. M. Paredes
hmorales@sorocaba.unesp.br

Wesley A. de Souza
wesley@fc.unesp.br

Pedro H. J. Nardelli
nardelli@ee.oulu.fi

Fernando P. Marafão
fmarafao@sorocaba.unesp.br

Luiz C. P. da Silva
lui@dsee.fee.unicamp.br

1 Telecommunications and Mechatronic Engineering Department (DETEM), Federal University of São João del-Rei (UFSJ), Rodovia MG 443, KM 7, Ouro Branco, MG 36420-000, Brazil

2 Institute of Science and Technology, São Paulo State University (Unesp), Av. Três de Março, 511, Sorocaba, SP 18087-180, Brazil

3 Department of Energy and Systems (DSE), School of Electrical and Computer Engineering (FEEC), University of Campinas (UNICAMP), Av. Albert Einstein, 400, Campinas, SP 13083-970, Brazil

4 Centre for Wireless Communications (CWC), University of Oulu, Erkki Koiso-Kanttilan katu 3, 90570 Oulu, Finland

1 Introduction

The increase in nonlinear loads, the severity of harmonic pollution, and the load unbalance in electrical power systems have attracted the attention of power system engineers to develop proper solutions for modern electrical power systems. Some examples of industrial nonlinear loads that might generate harmonic currents or load unbalance are: arc furnace, induction furnace, adjustable-speed drives (ASDs), welding machines, and power electronic loads.

Regarding the harmonic currents, it is known that the flow through the system impedance results in nonsinusoidal voltage drops, which can affect the grid voltage quality (Das 2015; IEEE P519 2015). In three-phase systems, harmonics can also cause current unbalance and excessive neutral currents. Consequently, the injected harmonics, reactive power, unbalance, and excessive neutral currents may decrease the system efficiency and the power factor (IEEE 2010; Tenti et al. 2011). They may also cause severe disturbances to other consumers. Thus, this subject has become extremely important regarding power quality (PQ) aspects, revenue metering, and measurement issues (IEEE 2010).

Different from the reactive power drawn by a linear balanced load, the harmonic currents cannot be easily compensated by the use of capacitors and inductors. In this case, passive or active harmonic filters are usually required

to minimize harmonic and reactive power flow. Moreover, if unbalanced three-phase loads are considered, the definition of the compensator may be even more sophisticated.

In this scenario, the decision of which compensator should be used is generally based on the expertise of the power system engineers. By means of careful analysis and simulations, these specialists might indicate proper solutions in order to mitigate the disturbances and control PQ indices according to the standards limits. Thus, the specialist's knowledge plays a critical role in the decision-making process. This professional, however, needs to deal with an enormous amount of data. In such context, the development of automatic analytic tools becomes very important for evaluating and identifying several PQ disturbances and their respective suitable solution.

Indeed, the growing number of pattern recognition applications in the last few decades is noteworthy, specially due to the increasing need for automation in different segments of society. This demand has been met by the evolution of digital processors, signal processing techniques, as well as the amount of digital information on the Internet. Applications of pattern recognition can be found in machine vision, robotics, biometrics, information retrieval, and instrumentation, likewise in power systems (Ribeiro et al. 2013; Bollen and Gu 2006).

Several researchers have published power system applications based on pattern recognition algorithms (PRAs) (Samantaray 2013; Jamehbozorg and Shahrtash 2010; Samantaray 2009; Galil et al. 2004; Biet 2013; Gaouda et al. 2002, 2001; Moravej et al. 2015; Livani and Evrenosoglu 2013; Cerqueira et al. 2008; Axelberg et al. 2007; Rodriguez et al. 2014; Monedero et al. 2007; Hajian and Foroud 2014; Lieberman et al. 2011). For example, different classification methods such as decision tree (DT) (Samantaray 2013; Jamehbozorg and Shahrtash 2010; Samantaray 2009; Galil et al. 2004; Barbosa and Ferreira 2013), k-nearest neighbor (K-NN) (Biet 2013; Gaouda et al. 2002, 2001), support vector machines (SVMs) (Moravej et al. 2015; Livani and Evrenosoglu 2013; Cerqueira et al. 2008; Axelberg et al. 2007), and different types of artificial neural networks (ANNs) (Gaouda et al. 2001; Rodriguez et al. 2014; Monedero et al. 2007; Andreoli et al. 2013) have been developed for different PQ applications. However, for power factor improvement, this approach is still missing. The choice of a suitable classifier in this case is very important to avoid a bad classification, resulting in an inappropriate compensator, which could be less effective than other potential options or could lead to unstable conditions.

Therefore, assuming the use of PRA, the aim of this paper is to determine the most suitable classifier for the development of an automatic system, which may be able to indicate the most appropriate power factor compensator for a certain point of common coupling.

Following, Sect. 2 presents some examples of pattern recognition applications in power systems. In Sect. 3, the authors present the main characteristics of the proposed methodology to evaluate different PRAs regarding the problem of power factor improvement. Section 4 presents the performance indices used for classifiers evaluation. In Sect. 5, the authors compare the classification results by means of computational simulations. Experimental results are discussed in Sect. 6, while the main conclusions are described in Sect. 7.

2 Pattern Recognition Applications in Power Systems

Pattern recognition techniques are automated tools for decision-making processes (Ribeiro et al. 2013; Bollen and Gu 2006). In recent years, pattern recognition methods have been widely used in power systems. Examples in power systems include fault analysis (Jamehbozorg and Shahrtash 2010; Moravej et al. 2015; Livani and Evrenosoglu 2013), power quality (Galil et al. 2004; Gaouda et al. 2001; Cerqueira et al. 2008; Axelberg et al. 2007; Rodriguez et al. 2014; Monedero et al. 2007; Hajian and Foroud 2014; Upadhyaya et al. 2015), electrical machines (Biet 2013; Junior et al. 2014; Palácios et al. 2016; Santana et al. 2017), and flexible AC transmission systems (FACTS) (Samantaray 2013). Pattern recognition provides tremendous flexibility benefits. This section provides some of the theoretical concepts that will be referred to in subsequent sections. Examples and strategies will be given to support the process of adopting pattern recognition in the context of power systems.

2.1 Decision Tree Classifier

Decision tree is a data structure consisting of a root node, decision nodes, and leaf nodes. The DT algorithm allows for simplification by pruning techniques, which reduce the size of the tree according to a user-defined level. The algorithm can produce either DT or rules in the form of: "if," "then" or "else." The advantage of this proposal is the representation, which is more understandable than other methods like neural networks (NNs) (Galil et al. 2004). However, DT has the disadvantage of only working with linearly separable data.

Recently, DT has been found highly successful for power system applications as FACTS (Samantaray 2013), fault classification (Jamehbozorg and Shahrtash 2010; Samantaray 2009) and power quality (Galil et al. 2004). In (Samantaray 2013), the authors presented a data-mining model for

fault-zone identification of a flexible AC transmission system. Moreover, a comparison between DT and SVM, which will be discussed later on, is performed for this kind of problem.

In (Jamehbozorg and Shahrtash 2010), researchers consider fault classification in single-circuit transmission lines in which conventional methods as mathematical operations on voltages and current could not classify the faults. By means of DT, however, the authors showed that the proposed method could classify the faults with reasonable accuracy. In (Samantaray 2009), a new approach for fault-zone classification on transmission lines equipped with thyristor-controlled series compensator (TCSC) and unified power flow controller (UPFC) using DT is presented. The authors showed that the processing time of SVM is higher compared to the proposed DT.

In (Galil et al. 2004), DT has been utilized for the classification of PQ. The wavelet transform is utilized to produce representative attribute vectors. The DT results for classification are compared with the artificial neural networks' results.

2.2 *K*-Nearest Neighbor Classifier

K-nearest neighbor (*K*-NN) is a supervised learning algorithm that finds the first K minimum distances' points, and the decision is made based on the group that has the majority minimum distances. It can produce any arbitrary complex surface to separate the classes based on the configuration of the sample points and their distance relations to each other. The closeness is usually measured in terms of Euclidean distances.

The literature is very rich with solutions that use the *K*-NN pattern recognition technique. Regarding power system applications (Biet 2013), *K*-NN was applied to a diagnosis method to find rotor faults. In (Gaouda et al. 2002), *K*-NN is applied to classify different power quality disturbances such as sags, swell, and harmonics. The wavelet transform and multiresolution signal decomposition are used for extracting attributes from different distorted signals.

The main advantage of *K*-NN in comparison with other algorithms is its good classification accuracy for mixed power quality problems (Gaouda et al. 2001). On the other hand, *K*-NN is computationally expensive in the search for the *K* nearest neighbors, mainly when the data set is very large. In addition, *K*-NN may provide inaccurate results for high-dimensional spaces (more than 10–15 dimensions) (Beyer et al. 1999).

2.3 Support Vector Machines Classifier

Cortes and Vapnik introduced SVM as a pattern recognition method. This supervised learning technique can be applied to either classification or regression. When it is used for pattern recognition, it searches a hyperplane that completely separates a data set. SVMs can also extend this to a nonlinear decision boundary using the kernel method.

Applications within power systems using SVM are, for instance, fault analysis or classification (Moravej et al. 2015; Livani and Evrenosoglu 2013), power quality event classification (Cerqueira et al. 2008), and voltage disturbances classification (Axelberg et al. 2007). In (Moravej et al. 2015), the authors presented the limitation of some distance relay functions in the presence of UPFC. The SVM classifier is employed for fault-type identification, fault-loop status supervision, and fault-zone detection.

In (Livani and Evrenosoglu 2013), the wavelet transform is utilized to extract transient information from the recorded voltages, and SVM is used to classify the fault type in the transmission networks. In (Cerqueira et al. 2008), the authors presented two versions of a novel classification method for power quality event classification based on SVM. In (Axelberg et al. 2007), the authors suggested a SVM classification system for voltage disturbances such as fault or transformer energizing.

The SVMs based on the decision boundary margin maximization have better generalization ability compared to DT and neural network (NN). Besides, the SVMs do not need expert knowledge for classification purpose in contrast to fuzzy-based approaches (Moravej et al. 2015). As advantages, the number of support vectors increases when the size of the training set increases.

2.4 Multilayer Perceptron Classifier

Multilayer perceptron (MLP) is a feed-forward NN typically consisting of an input layer, one or several hidden layers, and one output layer. MLP networks are very useful for the classification of input signals when these cannot be defined mathematically. The algorithm can be trained to learn the existing relationships between input and output data (including nonlinear). Once they have been learned by example, they can be generalized. However, MLP has difficulties in determining a proper architecture, such as the number of hidden layers and nodes. Training MLPs is time-consuming without guaranteeing the global minimum (Lieberman et al. 2011).

Artificial neural networks for the classification of power system disturbances and faults have been extensively studied; some of the previous work can be found in (Rodriguez et al. 2014) and (Monedero et al. 2007). In (Rodriguez et al. 2014), a new dual neural network-based methodology to detect and classify single and combined PQ disturbances is proposed. A neural network is used to classify sags, swells, spikes, notching, flickers, harmonics, and inter-harmonics. In (Monedero et al. 2007), the researchers presented a system based on neural networks for the classification of electrical disturbances in real time.

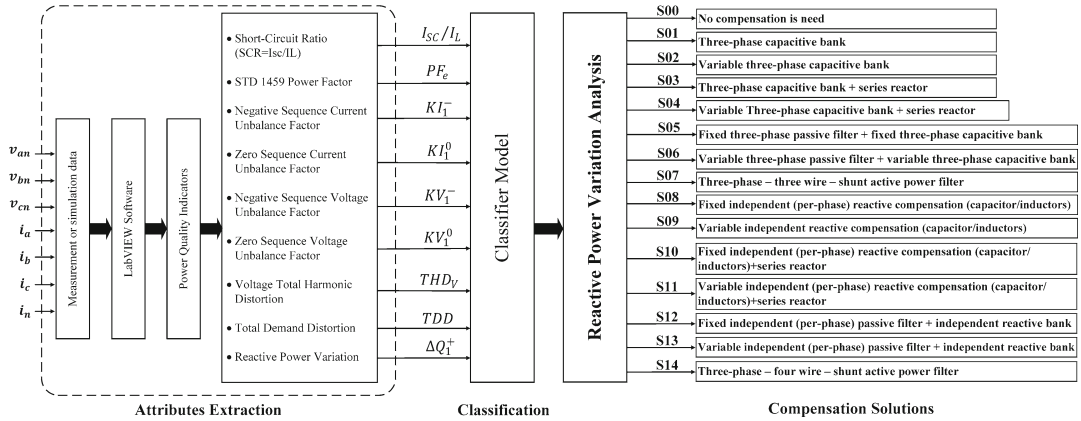

Fig. 1 Schematic diagram of the proposed methodology

All in all, many challenges in power systems have already been solved using different pattern recognition algorithms. However, power factor improvement, reactive and harmonic compensation are still open challenges.

3 Proposed Methodology for Evaluating Pattern Recognition Algorithm for Power Factor Improvement

Considering each previously mentioned PRA, one at a time, this section proposes a methodology to develop eleven different classifier models, which will be compared to each other, in order to determine the most suitable classifier for the development of an specialized system capable of pointing out the most proper power factor compensator for a certain installation. The proposed work consists of two stages: training and testing. In the first stage, we show the generation of an historical database with a known set of input-labeled and known responses (labels or classes) used in off-line training and development of classifier models. In the test stage, the generated classifying models are evaluated using a test database by means of computational simulation. Finally, the models are tested using real data samples, in order to evaluate the PRA algorithms with real cases.

Figure 1 shows four blocks that are used in the proposed methodology to evaluate each classifier model (DT, K-NN, SVM, and MLP).

3.1 Attributes Extraction

Distribution power systems comprise numerous classes of disturbances, such as voltage or current unbalance, voltage or current distortion, and low power factor, which will be considered as relevant attributes for designing a suitable compensator, as shown in Fig. 1. Hence, the applied attributes are described as follows:

- Short-circuit ratio ($I_{\mathrm{SC}}/I_{\mathrm{L}}$) : given by the ratio of short-circuit current (I_{SC}) and the fundamental component of the maximum load current (I_{L}) (average value of maximum demand over the previous 12 months) (IEEE 2014);
- Voltage total harmonic distortion (THD_V) : This attribute is used in order to quantify and evaluate the harmonic distortion in voltage waveforms;
- Total demand distortion (TDD): given by the harmonic distortion of current expressed as a percentage of the maximum load current. Limits on current distortion depend on the power of the load compared with the power of the supply system at the PCC. The short-circuit currents at the PCC should be calculated to apply IEEE criteria of TDD at PCC (IEEE 2014);
- Equivalent Power factor ($\mathrm{PF_e}$) : It represents the fraction of the power supplied by a utility that is used to perform a useful work. It is frequently used by the utilities to penalize the customer. In this work, the power factor is calculated according to STD 1459 (IEEE 2010);
- Voltage unbalance factors $\left(\mathrm{KV}_1^-\right)$ or $\left(\mathrm{KV}_1^0\right)$: indicate unequal voltage magnitudes at the fundamental frequency, fundamental phase angle deviation, and imbalanced levels of harmonic distortion among phases. These are other important attributes used in this work to indicate the uneven distribution of load through a three-phase power system. These terms consider the RMS value of the fundamental positive, negative, or zero sequence and can be obtained using Fortescue's symmetrical components;
- Current unbalance factor $\left(\mathrm{KI}_1^-\right)$ or $\left(\mathrm{KI}_1^0\right)$: may be caused by large or unequal distribution of single phase load,

phase to phase loads or unbalanced three-phase loads. They are used to evaluate the load unbalance condition and can also be calculated based on symmetrical components;

- Positive-sequence reactive power variation $\left(\Delta Q_1^+\right)$: This attribute will be used in order to analyze the reactive power over the time.

3.1.1 Classification: Standards and Adopted Limits

According to Fig. 1, this block is responsible for classifying the input data, by means of the chosen and trained PRA, Fig. 1, and the calculated attributes, before the final classification in terms of the reactive power's variability. At this point, the specialist's knowledge is already considered in the classifier and there is no need for any adaptation of the classifier rules.

3.1.2 Reactive Power Variation

In order to evaluate the reactive power variations over time, this step is responsible to check whether the variations are above or below $\pm 30\%$ average over 24 h. Thus, this stage provides information regarding the required compensator. If the reactive power variation is above 30%, the compensator should be "switched" (like thyristor-switched capacitors) to provide exactly the right amount of reactive power at the right time according to load requirements. Otherwise, the compensator should provide a constant value of reactive power (like fixed capacitor banks).

3.1.3 Compensation Solutions

The chosen compensator or solution have a vital role to play in maintaining supply voltages within the specified limits, improving the power factor, reducing the harmonic distortion, and balancing the load currents. Thus, the last step in Fig. 1 presents a list of possible solutions according to the "classification block" and the "reactive power variation analysis." Notice that the solution includes low-frequency compensators ("Fixed" and/or "Switched") and high-frequency compensators (like active power filters).

For a particular set of input data, it is clear that the proposed solution partly depends on the available attributes and limits during the training and classification, but mostly on the chosen PRA for the classifier construction, as discussed in next sections.

3.2 Training Stage

This stage is responsible for the training of the chosen PRA based on the applicable attributes, specialized knowledge, and a set of historical simulation and measurement data, in such a way that the resulting decision rules can classify new samples of a test data, automatically, by simply using the test data attributes, Fig. 2.

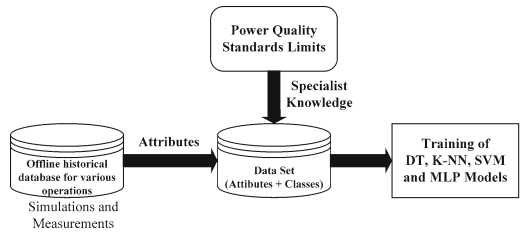

Fig. 2 Flowchart of the training stage

It is worth mentioning that the decision rules for each PRA are dynamically defined during this stage. Taking, for example, the DT method, the training process results in an automatic self-structured DT.

The training data set was developed considering several simulations of different compensation examples, which have been generated and characterized by a human specialist, in order to perform a supervised learning by means of supplying a known set of input-labeled training data (power quality indicators) and known responses (compensation cases). The specialist, taking into account the PQ standards limits: equivalent power factor ($PF_e > 0.92$) , the unbalance factors for the voltages (KV_1^- or $KV_1^0 < 2\%$), the unbalance factors for the currents (KI_1^- or $KI_1^0 < 20\%$), total demand distortion , voltage total harmonic distortion ($THD_V < 5\%$), evaluates extensively the successful simulations and measurement cases. All simulations were performed at a voltage level between 120 V and 69 kV. For each type of disturbing load, a subset of attributes was generated (1355154 samples) using PSCAD environment. The PSCAD software allows the use of various control tools to perform parameter modification simulation. In addition, the PSCAD allows to perform the simulation of large power systems. Besides, several real measurements, evaluated by the specialist, were also added to this database. The classifier models were built and trained using the tool "Classification Learner" included in the MATLAB software (Statistics and Machine Learning Toolbox 2017). The Classification Learner App is an application that can be used to train models for classification of data using supervised machine learning methods. By using Classification Learner, it is possible to explore data, select features, specify validation schemes, train models, and assess results. The prediction models developed in this study have been trained, tested, and evaluated using a fivefold cross-validation technique.

The decision tree models were developed using the *Classification and Regression Tree* (CART) algorithm (Breiman et al. 1984). Hence, the leaves represent the classification results (compensation solutions), and the nodes represent

attributes. A CART algorithm searches all variables for all possible values, in order to find the best split. The split criterion used is Gini's diversity index. Three decision tree models have been developed using different depths (4, 20, and 100), which are the highest number of levels used in the decision tree.

In this work, three K-NN models have been developed using different K values (1, 3, and 10), which are the number of neighbors. In addition, the Euclidean distance metric was used to measure the distance between patterns in this study.

The prediction SVM model developed in this study has been developed using the linear kernel function and "one-versus-one" multiclass strategy.

For MLP training, we used as function fitting a two-layer feed-forward network, with a sigmoid transfer function in the hidden layer and a linear transfer function in the output layer. The number of hidden neurons for each MLP model was 10, 20, 40, and 50, respectively. In addition, for the MLP training, we used up to 1000 epochs and the backpropagation learning algorithm.

Regarding the limits used by the specialist to be applied for the chosen attributes, some come directly from particular standards, while others do not have specific boundaries in the literature, and the specialist would usually define them in each case. In such cases, during the training stage, the classifier can also set the lacking limits automatically, in order to achieve the compensation results according to the input training data.

Regardless of the source, high harmonic voltage levels and harmonic load currents will lead to operational problems in the electric power distribution system. These problems include equipment-heating, over voltage, and load disruption and have been discussed in IEEE 519 (IEEE 2014). This standard provides recommended practices for the harmonic evaluation of electrical power systems and is widely accepted by industry and utilities. European standard (EN 50160 2004) sets the boundaries for harmonic voltages. IEEE 519 has 5% to the voltage total harmonic distortion limit and 3% to individual harmonic voltage. In this work, the authors adopted a conservative limit of 5% for total harmonic distortion (THD_V) to avoid excessive voltage distortion on capacitor banks.

Concerning the limits for harmonic current, it is observed that both IEC (IEC 2008, 1996) and IEEE (IEEE 2014) deal with the limitation of harmonic currents in low voltage (LV). However, IEEE 519 considers the short-circuit ratio (I_{SC}/I_L) to take into account the size of the load in regard to the system, when setting the limits on the harmonic current emission. In this way, the current harmonic distortion will be evaluated according to IEEE 519 by means of TDD.

The power factor is considered by the utility for billing purposes and may lead to monthly charges for the consumers. In this work, the adopted power factor limit was 0.92, according to the Brazilian Electrical Regulatory Agency (ANEEL 2017).

Table 1 Accuracy and speed of classification methods for the training set

Classification method	Training time (s)	Accuracy (%)
DT (depth = 4)	14	71.70 ± 1.53
DT (depth = 20)	11	100 ± 0.01
DT (depth = 100)	12	100 ± 0.01
K-NN ($K = 1$)	N/A	100 ± 0.00
K-NN ($K = 3$)	N/A	100 ± 0.01
K-NN ($K = 10$)	N/A	100 ± 0.01
Linear SVM	4987	100 ± 0.01
MLP (10 neurons)	2224	99.90 ± 0.08
MLP (20 neurons)	2648	99.80 ± 0.08
MLP (40 neurons)	3364	99.80 ± 0.08
MLP (50 neurons)	3091	99.89 ± 0.07

Regarding the voltage unbalance, the ANSI C84.1-2006 standard recommends that electrical supply systems should operate with a maximum voltage unbalance limit of 3% (ANSI 2006). The IEC standard recommends that the maximum voltage unbalance of electrical supply systems should be limited to 2% (IEC 2008, 1996). In "IEEE Recommended Practice for Electric Power Distribution for Industrial Plants" (IEEE 1993), and ANSI/IEEE Std. 241-1990, "IEEE Recommended Practice for Electric Power Systems in Commercial Buildings" (IEEE 1990), both the Red Book and the Gray Book indicate that some electronic equipment (like computers) may experience problems if the voltage unbalance is more than 2–2.5%. Therefore, based on (IEEE 1993, 1990; NEMA 1993), the authors adopted 2% as a limit for the attribute voltage unbalance.

To evaluate the unbalanced load, the authors propose the current unbalance factor. This attribute is not defined in standards. However, the National Equipment Manufacturers Association (NEMA) (NEMA 1993) states that 1% of voltage unbalance can create 6–10% current unbalance. Thus, by limiting the voltage unbalance to 2%, the authors propose the limit of 20% as current unbalance factor.

The accuracy and speed of the training process are given in Table 1, for each PRA. It becomes evident that DT, K-NN, and SVM can correctly classify the possible cases using the training data. However, it is important to test the models for different data sets in order to evaluate the performance for imbalance data. The problem with the imbalance class has been recognized as a crucial problem in machine learning and pattern recognition areas. Significant differences in class prior probabilities may produce an important deterioration of the classification systems' performance. A two-class data set is imbalanced when one of the classes (the minority one) is heavily underrepresented in comparison with another

Table 2 Confusion matrix (Sokolova and Lapalme 2009)

Data class	Classified as positives	Classified as negatives
Real positives	TP	FN
Real negatives	FP	TN

class (the majority one). This issue is particularly important in real-world applications where it is costly to misclassify examples from the minority class, such as diagnosis of rare diseases, detection of fraudulent telephone calls, and filtering tasks. In the experimental results section, this problem will be discussed considering real-world data. Note that SVM and MLP need a large training time increasing the computation cost.

After the training process, each resulting decision-maker was ready to be used as a tool for identifying the compensation solutions for power factor improvement.

4 Performance Indices for Classifiers Evaluation

Designing a classifier is mathematically equivalent to finding a mapping function between the input space and the attribute space, followed by applying decision rules that then map the attribute space into the decision space. In this way, the four pattern recognition classifiers presented in Sect. 2 (DT, *K*-NN, SVM, and MLP) were used in the classification task, and their results compared in order to find the best classifier in the PQ problem studied here.

Regarding the performance evaluation, many metrics have been employed to assess the classification effectiveness. All of them are based on the confusion matrix as shown in Table 2. The correctness of a classification can be evaluated by computing the number of correctly recognized class examples (*TP*—true positives), the number of correctly recognized examples that do not belong to the class (*TN*—true negatives), and examples that either were incorrectly assigned to the class (*FP*—false positives) or were not recognized as class examples (*FN*—false negatives) (Sokolova and Lapalme 2009).

Accordingly, from Table 2, the overall effectiveness of a classifier can be measured as:

$$\text{accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{FN} + \text{TN}} \tag{1}$$

In order to evaluate how effectively a classifier identifies negative labels, we consider:

$$\text{specificity} = \frac{\text{TN}}{\text{FP} + \text{TN}} \tag{2}$$

The corresponding effectiveness of a classifier to identify positive labels is as follows:

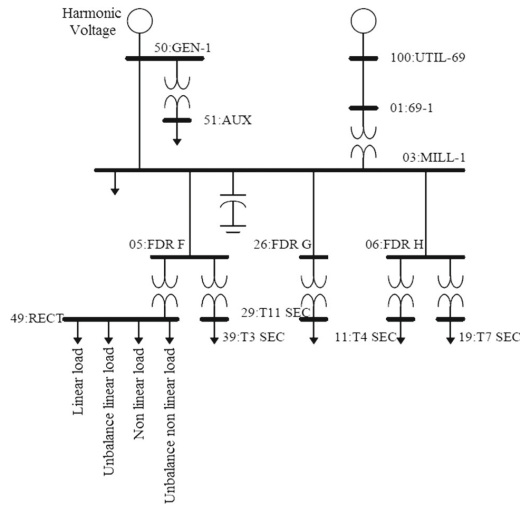

Fig. 3 Modified IEEE 13-bus balanced industrial system test feeder

$$\text{recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \tag{3}$$

It is important to find the performance measurement that has not been influenced by the imbalanced data. Thus, *G*-mean is a measure of the classifier's ability to balance sensitivity and specificity and can be defined as follows:

$$G\text{-mean} = \sqrt{\text{recall} \cdot \text{specificity}} \tag{4}$$

Area under the curve (AUC) is the area below the receiver operating characteristic (ROC) (Sokolova and Lapalme 2009) curve that depicts the performance of a classifier. It has been proved to be a reliable performance measure for class imbalance problem. It can measure the classifier's ability to avoid false classification and can be expressed by:

$$\text{AUC} = \frac{1}{2}\left(\frac{\text{TP}}{\text{TP} + \text{FN}} + \frac{\text{TN}}{\text{TN} + \text{FP}}\right) \tag{5}$$

5 Computational Results

At this point, the specialist's knowledge is already considered in the classifier and there is no need for any adaptation of the classifier rules. After training the classifier models, in order to verify the generalization capacity of the developed classifiers, a new test database was developed using the IEEE 13-Bus Balanced Industrial System, shown in Fig. 3.

The IEEE 13-bus system was used to create a validation balanced data set (111,055 samples) used to compare the

Table 3 Expected versus predicted classification of different methods on IEEE 13 bus data set

Compensation solutions	Expected class	Predicted class										
		DT (4)	DT (20)	DT (100)	K-NN ($K = 1$)	K-NN ($K = 3$)	K-NN ($K = 10$)	Linear SVM	MLP 10	MLP 20	MLP 40	MLP 50
S00	7403	7540	7403	7403	6936	6936	6935	7412	12068	7403	7499	15064
S01	7404	15955	7404	7404	6950	6950	6949	7438	7696	7408	7409	7831
S02	7404	15955	7404	7404	6950	6950	6949	7438	7696	7408	7409	7831
S03	7403	–	7403	7403	6977	6977	6977	7412	7670	7411	7412	7835
S04	7403	–	7403	7403	6977	6977	6977	7412	7670	7411	7412	7835
S05	7403	14169	7402	7402	7152	7151	7155	7411	7655	7388	7396	7812
S06	7403	14169	7402	7402	7152	7151	7155	7411	7655	7388	7396	7812
S07	7404	14934	7447	7448	6864	6864	6861	14655	7806	7455	7402	7855
S08	7404	14167	7404	7404	13088	13088	13088	7396	7675	7577	7395	7836
S09	7404	14167	7404	7404	13088	13088	13088	7396	7675	7577	7395	7836
S10	7404	–	7404	7404	–	–	–	7410	7666	7408	7424	7826
S11	7404	–	7404	7404	–	–	–	7410	7666	7408	7424	7826
S12	7404	–	7405	7405	14414	14413	14413	7417	3482	7228	7335	1072
S13	7404	–	7405	7405	14414	14413	14413	7417	3482	7228	7335	1072
S14	7404	–	7362	7361	96	96	95	22	7494	7358	7412	7712
Number of observations	111055	111055	111055	111055	111055	111055	111055	111055	111055	111055	111055	111055

Table 4 Evaluation of different classification methods on IEEE 13 bus data set

Classification methods	Performance metrics (%)			
	Accuracy	Specificity	*G*-mean	AUC
DT (depth = 4)	55.93 ± 2.39	51.07	71.47	75.54
DT (depth = 20)	99.93 ± 0.03	99.92	99.96	99.96
DT (depth = 100)	99.93 ± 0.03	99.92	99.96	99.96
K-NN ($K = 1$)	76.79 ± 1.78	74.24	86.13	87.08
K-NN ($K = 3$)	76.80 ± 1.83	74.25	86.13	87.08
K-NN ($K = 10$)	76.79 ± 1.63	74.25	86.13	87.08
Linear SVM	88.48 ± 0.59	87.21	93.39	93.61
MLP (10 neurons)	93.96 ± 0.41	93.30	96.59	96.65
MLP (20 neurons)	99.57 ± 0.08	99.53	99.76	99.76
MLP (40 neurons)	99.77 ± 0.04	99.75	99.87	99.87
MLP (50 neurons)	90.76 ± 0.47	89.74	94.73	94.87

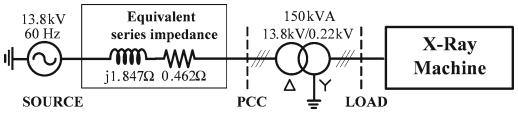

Fig. 4 Single-line diagram of the power system

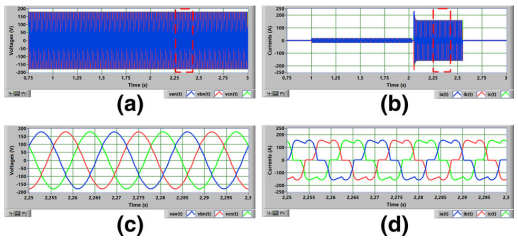

Fig. 5 Three-phase X-ray machine voltages and currents

performance of trained classifiers, by means of a supervised test, and decide which one to take, thus allowing the classifier's performance evaluation by means of simulation results. This system consists of 13 buses, 69 kV power supply from the utility, and seven transformers. A 6 MVAr rated power factor capacitor is connected at bus 3 in medium voltage (13.8 kV). Specific issues related to cables, transformers, and load characteristics are described by the data in (Abu-Hashim et al. 1999). In order to take into account the load variation effects and the possible disturbances (harmonic current, harmonic voltage, current unbalance, voltage unbalance, a low power factor, and their combinations), a group of linear and nonlinear loads has been inserted at 49:RECT bus. Besides, in order to simulate the voltage distortions from the utility perspective, a programmable voltage source was inserted at 50:GEN-1 bus. In this way, it is possible to reproduce different combinations of disturbances to be analyzed by the developed classifier model. In addition, with the combination of the different types of loads, it is possible to generate samples for all classes (S00 to S14), since the objective is to analyze the capacity of the classifiers in separating the samples from the respective classes.

By applying the proposed methodology, the voltages and currents were measured at 49:RECT bus with a sampling frequency of 12.6 kHz. According to Fig. 1, the required voltage, current, and power attributes were calculated and stored (attributes extraction).

Table 3 shows the classification results performed by each technique chosen in this work. The compensation solutions column represents the possible classes. The expected class column represents the known responses defined by power engineer (expert) during the creation of the testing database. In this stage, the attributes described in Sect. 3.1 are provided to the classifier models developed in the training phase. Thus, the classifier under analysis performs the separation of the respective classes. The output of each classifier is then compared to the known response. It can be seen from Table 3 that the DT with depth (4) has difficulties in identifying the cases S01, S02, S05, S06, S07, S08, and S09. In addition, this classifier model was unable to identify the samples present in classes S03, S04, S10, S11, S12, S13, and S14. As the depth of the decision tree is increased, it is possible to observe the classifier ability to separate classes correctly, according to results obtained through the use of the DT with depth (100). In the case of the K-NN, it is difficult for the classifier to identify classes S10 and S11, even with the increase in the value of K. In the case of the linear SVM technique, an improvement in the identification of the classes S10 and S11 is verified when compared to the K-NN technique. However, this classifier cannot correctly identify the samples present in class S14, that is, there is a difficulty in identifying the solution "Three-phase - four wire shunt active power filter." In the case of the MLP technique with ten neurons, it is observed that the classifier identified

Table 5 Expected versus predicted classification on three-phase X-ray data set

Compensation solutions	Expected class	Predicted class										
		DT (4)	DT (20)	DT (100)	K-NN ($K = 1$)	K-NN ($K = 3$)	K-NN ($K = 10$)	Linear SVM	MLP 10	MLP 20	MLP 40	MLP 50
S00	16710	16710	17437	16710	15762	15724	15706	16673	16926	16611	16628	17007
S01	–	–	–	–	–	–	–	–	–	–	–	–
S02	72878	72878	72878	72878	73378	73423	73445	72869	72842	72847	72861	72889
S03	–	–	–	–	–	–	–	–	–	–	–	–
S04	–	–	–	–	436	429	425	–	–	129	138	1
S05	–	–	–	–	–	–	–	–	–	–	–	–
S06	6727	7075	6727	6727	6740	6742	6746	6718	6745	6718	6697	6677
S07	403	727	–	404	403	402	398	406	399	405	377	416
S08	–	–	–	–	–	–	–	–	–	–	–	–
S09	16	16	16	16	28	28	28	62	75	163	168	108
S10	–	–	–	–	–	–	–	–	–	–	–	–
S11	–	–	–	–	–	–	–	–	–	86	–	84
S12	–	–	–	–	–	–	–	–	–	–	–	–
S13	348	–	348	348	659	658	658	403	188	212	350	203
S14	324	–	–	323	–	–	–	275	231	235	187	21
Number of observations	97406	97406	97406	97406	97406	97406	97406	97406	97406	97406	97406	97406

Table 6 Evaluation of different classification methods on X-ray data set

Classification methods	Performance metrics (%)			
	Accuracy	Specificity	*G*-mean	AUC
DT (depth = 4)	99.31 ± 0.62	97.26	98.62	98.64
DT (depth = 20)	100 ± 0.01	100	100	100
DT (depth = 100)	100 ± 0.00	100	100	100
K-NN ($K = 1$)	98.94 ± 0.05	99.91	97.05	97.09
K-NN ($K = 3$)	98.90 ± 0.04	99.91	96.93	96.97
K-NN ($K = 10$)	98.88 ± 0.05	99.91	96.86	96.91
Linear SVM	99.95 ± 0.03	99.99	99.87	99.87
MLP (10 neurons)	99.78 ± 0.06	99.73	99.87	99.87
MLP (20 neurons)	99.73 ± 0.05	99.85	99.52	99.52
MLP (40 neurons)	99.80 ± 0.03	99.93	99.54	99.55
MLP (50 neurons)	99.42 ± 0.01	99.41	99.43	99.43

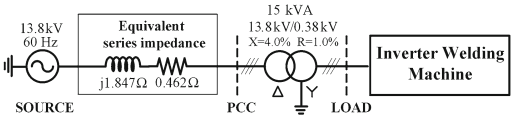

Fig. 6 Single-line diagram of the power system

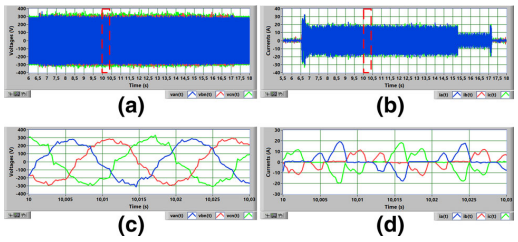

Fig. 7 Inverter welding machine voltages and currents

12068 samples for class 0, that is, 4665 samples classified incorrectly. In addition, a difficulty of this classifier in correctly identifying the samples of classes S12 and S13 is observed. With the increase in the number of neurons for the MLP, it is possible to observe the improvement in the capacity of the classifier model to identify classes S0, S12, and S13.

The objective of any classifier is the maximization of accuracy, specificity, *G*-mean, and AUC. In this way, these criteria will be applied for assessing the algorithms' performance. Table 4 shows the results of several classification methods when the IEEE 13-bus data set is considered. We can observe that DT with depth 4 has the worst accuracy (55.93%) and AUC criterion (75.54%). However, when the tree depth is increased to 20, we observe that the DT classifier obtains the best performance compared to other methods.

6 Experimental Results

Looking for the evaluation of each classifier performance in practical applications, three actual test sets composed by three disturbing loads, which result in imbalanced data sets, were analyzed by means of supervised classification. The measurements have been performed in different installations in Brazil, which claim lack of power quality in their respective facilities.

As shown in Fig. 1, the voltages and currents are measured by means of a data acquisition system and used to calculate the attributes described in Section 3.1. Following, these attributes are classified according to the resulting classifier models.

6.1 Three-Phase X-Ray Machine

The first measurement is related to an X-ray machine. This kind of load is considered as disturbing due to its operation mode. During the time of radiography, the required electrical power is high and can produce voltage sags or even damage the operation of other sensitive equipment connected to the circuit. Figure 4 shows the single-line diagram of the power system under analysis. The measurements were performed on the low-voltage side (220V).

Figure 5 shows the load instantaneous currents, measured in X-ray equipment 220 V, 60 Hz, during the execution of radiography (Moreira et al. 2015). Note from Fig. 5 that the current has amplitude variant over time, which may result in different compensation solutions over time.

Table 5 presents the known responses (expected class) versus predictions made by the trained models. Note that the pattern recognition decision-tree algorithm (depth = 4) fails to identify S13 and S14 solutions.

From Table 6, we observe that all classifiers reach high accuracy. Observe that the pattern recognition decision-tree

Table 7 Expected versus predicted classification on three-phase inverter welding machine data set

Compensation solutions	Expected class	Predicted class										
		DT (4)	DT (20)	DT (100)	K-NN ($K = 1$)	K-NN ($K = 3$)	K-NN ($K = 10$)	Linear SVM	MLP 10	MLP 20	MLP 40	MLP 50
S00	–	–	–	–	–	–	–	–	–	–	–	–
S01	–	–	–	–	–	–	–	–	–	–	–	–
S02	–	301	–	–	–	–	–	–	–	–	–	–
S03	–	–	–	–	–	–	–	–	–	–	–	–
S04	–	–	–	–	–	52	51	170	2	–	83	2004
S05	–	–	–	–	–	–	–	–	–	–	–	–
S06	–	–	–	–	–	–	–	–	–	–	–	–
S07	282	50223	282	282	282	819	909	243	2	112	103	29
S08	–	–	–	–	–	–	–	–	–	–	–	–
S09	–	36356	–	–	–	2765	2822	–	–	–	–	–
S10	–	–	–	–	–	–	–	–	–	–	–	–
S11	36657	–	36657	36657	36657	33634	33625	36487	36655	36657	36574	34653
S12	–	–	–	–	–	–	–	–	–	–	–	–
S13	–	–	–	–	–	1987	1931	–	–	–	–	–
S14	49941	–	49941	49941	49941	47623	47542	49980	50221	50111	50120	50194
Number of observations	86880	86880	86880	86880	86880	86880	86880	86880	86880	86880	86880	86880

Table 8 Evaluation of different classification methods on three-phase inverter welding machine data set

Classification methods	Performance metrics (%)			
	Accuracy	Specificity	G-mean	AUC
DT (depth = 4)	0.32 ± 3.44	0.00	0.00	50.00
DT (depth = 20)	100 ± 0.00	100	100	100
DT (depth = 100)	100 ± 0.01	100	100	100
K-NN ($K = 1$)	93.37 ± 0.07	93.58	51.52	60.97
K-NN ($K = 3$)	93.38 ± 0.11	93.60	50.88	60.63
K-NN ($K = 10$)	93.27 ± 0.12	93.49	50.20	60.22
Linear SVM	99.76 ± 0.03	99.80	92.74	92.99
MLP (10 neurons)	99.68 ± 0.02	100	8.42	50.35
MLP (20 neurons)	99.72 ± 0.09	99.96	51.21	63.10
MLP (40 neurons)	99.70 ± 0.10	99.90	60.41	68.21
MLP (50 neurons)	97.37 ± 0.14	97.67	23.54	51.67

algorithm (depth = 20 and 100) has the best results for all metrics resulting in compensation solution S02, due to PF_e and ΔQ_1^+ violations. As we can see, increasing the number of neurons does not result in a better accuracy or AUC.

6.2 Inverter Welding Machine

The second measurement is related to a welding machine. This equipment can be connected at any point of the electrical distribution system, resulting in high distortions levels on the grid (Fig. 6).

Figure 7 shows voltages and currents measured at load terminals for a 380 V, 60 Hz inverter welding machine. The voltages and currents are distorted, while the currents are also unbalanced.

For this data set, the known responses versus the predicted classification are shown in Table 7. In this case, the compensation solution suggested is S14 due to higher incidence of PF_e, KI_1^-, THD_I, THD_V, and ΔQ_1^+ violations. Note that DT (depth = 4) has misclassified 36356 samples as S09.

Table 8 summarizes the metrics for all classifiers when applied to the welding machine data set. Again, one can observe that DT (depth = 4) has the worst accuracy and AUC. This means that the solution provided by this PRA, in this case, will be S07 with 50,223 samples misclassified, Table 7. In this instance, we can perceive the importance of all different metrics. The MLP (ten neurons) has a high accuracy (99.68%), however with a low AUC (50.35). This occurs because this PRA only classified two samples as S07 instead of 282 samples. The K-NN model has misclassified some samples as S09, resulting in a low AUC. In contrast, the decision tree (depth 20 and 100) has a 100% result for all metrics, in other words, all attributes were correctly classified.

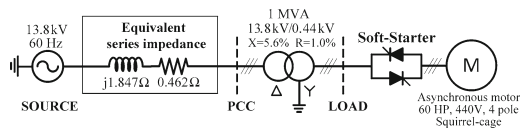

Fig. 8 Single-line diagram of the power system

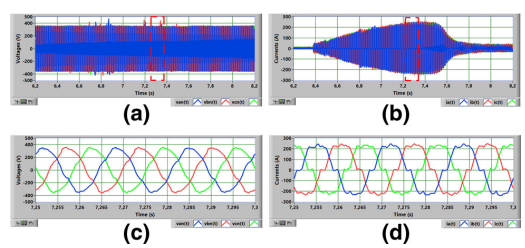

Fig. 9 Soft-starter voltages and currents

6.3 Soft Starter

Soft starters are generally employed in large capacity induction motors to limit the initial current and to achieve smooth starting. However, they cause severe pollution on the supply such as harmonic distortion.

Figure 8 shows the single-line diagram of the power system under analysis for the induction motor 60 HP, 440 V, 60 Hz with soft starter. The measurements were performed in the low-voltage side (440 V), as can be seen in Fig. 8.

Figure 9 shows the voltages and currents' waveforms for the induction motor 60 HP, 440 V, 60 Hz with soft starter. Note that voltages and currents are distorted and variant over time.

For this data set, the known responses are S05 (140122 samples), S07 (64500 samples), and S01 (466 samples) with

Table 9 Expected versus predicted classification on soft-starter data set

Compensation solutions	Expected class	Predicted class										
		DT (4)	DT (20)	DT (100)	K-NN ($K = 1$)	K-NN ($K = 3$)	K-NN ($K = 10$)	Linear SVM	MLP 10	MLP 20	MLP 40	MLP 50
S00	–	–	–	–	–	–	–	–	–	–	–	–
S01	466	626	466	466	466	88	31	438	617	609	38038	71
S02	–	–	–	–	–	–	–	–	–	–	–	–
S03	160	–	160	160	160	188	185	188	9	17	127	555
S04	–	–	–	–	–	–	–	–	–	–	–	–
S05	140122	140125	140125	140125	140125	13637	14013	144916	10644	71258	125869	6376
S06	–	–	–	–	–	–	–	–	–	–	–	–
S07	64500	64497	64497	64497	64497	191335	191019	59706	193842	133364	41214	198246
S08	–	–	–	–	–	–	–	–	136	–	–	–
S09	–	–	–	–	–	–	–	–	–	–	–	–
S10	–	–	–	–	–	–	–	–	–	–	–	–
S11	–	–	–	–	–	–	–	–	–	–	–	–
S12	–	–	–	–	–	–	–	–	–	–	–	–
S13	–	–	–	–	–	–	–	–	–	–	–	–
S14	–	–	–	–	–	–	–	–	–	–	–	–
Number of observations	205248	205248	205248	205248	205248	205248	205248	205248	205248	205248	205248	205248

Table 10 Evaluation of different classification methods on soft-starter data set

Classification methods	Performance metrics (%)			
	Accuracy	Specificity	G-mean	AUC
DT (depth = 4)	99.92 ± 0.02	99.92	99.96	99.96
DT (depth = 20)	100 ± 0.00	100	100	100
DT (depth = 100)	100 ± 0.01	100	100	100
K-NN ($K = 1$)	99.76 ± 0.02	99.97	24.51	52.99
K-NN ($K = 3$)	99.76 ± 0.03	99.97	24.51	52.99
K-NN ($K = 10$)	99.79 ± 0.02	100	25.79	53.33
Linear SVM	99.99 ± 0.01	100	96.95	97.00
MLP (10 neurons)	99.86 ± 0.05	99.86	99.93	99.93
MLP (20 neurons)	99.93 ± 0.04	99.93	99.97	99.97
MLP (40 neurons)	81.69 ± 0.05	81.65	90.36	90.83
MLP (50 neurons)	99.81 ± 0.06	100	39.03	57.62

PF_e, THD_I, and THD_V violations, Table 9. Note that MLP (ten neurons) has misclassified 136 samples as S08.

Table 10 shows the classifiers metrics for this data set. It is interesting to observe that the K-NN accuracy is improved for this kind of load, as well as the linear SVM classifier. However, the AUC for K-NN is around 53% and the G-mean metric about 24%, meaning that K-NN ($K = 1$, 3, and 10), MLP (10, 20, and 50 neurons) will result in S07 as first compensation solution (higher incidence) instead of S05. On the other hand, the decision-tree algorithm with depth 4 has reached 99.92% of accuracy and 99.96% of AUC. However, by increasing the tree depth, we can observe a performance improvement, so that the AUC reaches 100% for depths 20 and 100.

7 Conclusion

In this paper, we compared several pattern recognition algorithms in order to automate the usual human decision-making process on power factor improvement in distribution systems. We have employed international standards as IEEE, IEC, ANSI, and NEMA to assess the different power quality indicators in order to analyze the power system's behavior. The decision-making process about the reactive, unbalanced, and harmonic compensation was performed using different algorithms, and our results indicate that an automatic self-structured decision-tree algorithm, with depth 20, is highly effective and reliable to classify the chosen attributes. The developed tool may also decrease the need for power system or power quality experts to perform the compensation analysis insofar as our proposed framework indicates (quasi-autonomously) the most suitable compensation solution, directly obtained from the input data.

Acknowledgements The authors gratefully acknowledge the contributions of São Paulo Research Foundation (FAPESP) under Grant 2016/08645-9 and by Finnish Academy and CNPq/Brazil (n.490235/2012-3) as part of the joint project SUSTAIN, by Strategic Research Council/Aka BC-DC project (n.292854) for their financial support toward the development of this research.

References

Abu-Hashim, R., et al. (1999). Test systems for harmonics modelling and simulations. *IEEE Transactions on Power Delivery*, *14*(2), 579–587.

Andreoli, A. L., Coury, D. V., Oleskovicz, M., & Serni, P. A. (2013). Artificial neural network model of discharge lamps in the power quality context. *Journal of Control, Automation and Electrical Systems*, *24*(3), 272–285.

ANEEL. (2017). Procedimentos de Distribuição de Energia Elétrica no Sistema Elétrico Nacional—PRODIST, Módulo 8—Qualidade da Energia Elétrica. Agência Nacional de Energia Elétrica – ANEEL, revisão 8, vigente a partir de January 01, 2017.

ANSI. (2006). Electric power systems and equipment—voltage ratings (60 Hertz). ANSI Standard C84.1-2011 (Revision of ANSI C84.1-2006).

Axelberg, P. G. V., Gu, I. Y. H., & Bollen, M. H. J. (2007). Support vector machine for classification of voltage disturbances. *IEEE Transactions on Power Delivery*, *22*(3), 1297–1303.

Barbosa, B. H. G., & Ferreira, D. D. (2013). Classification of multiple and single power quality disturbances using a decision tree-based approach. *Journal of Control, Automation and Electrical Systems*, *24*(5), 638–648.

Beyer, K., Goldstein J., Ramakrishnan, R., & Shaft U. (1999). When is nearest neighbor meaningful? In *Proceedings of the 7th international conference on database theory* (pp. 217–235).

Biet, M. (2013). Rotor faults diagnosis using feature selection and nearest neighbors rule: application to a turbogenerator. *IEEE Transactions on Industrial Electronics*, *60*(9), 4063–4073.

Bollen, M. H. J., & Gu, I. Y. H. (2006). *Signal processing of power quality disturbances* (1st ed.). Hoboken: Wiley.

Breiman, L., Friedman, J., Stone, C. J., Olshen, R. A., & Stone, C. I. (1984). *Classification and regression trees* (1st ed.). Boca Raton: Chapman and Hall/CRC.

Cerqueira, A. S., Ferreira, D. D., Ribeiro, M. V., & Duque, C. A. (2008). Power quality events recognition using a svm-based method. *Elsevier Electric Power Systems Research*, *78*, 1546–1552.

Das, J. C. (2015). *Power system harmonics and passive filter designs* (1st ed.). Hoboken: Wiley.

EN 50160. (2004). Voltage characteristics of electricity supplied by public distribution systems. Standard EN 50160.

Galil, T. A., Kamel, M., Youssef, A. M., Saadany, E. F. E., & Salama, M. M. A. (2004). Power quality disturbance classification using the inductive inference approach. *IEEE Transactions on Power Delivery*, *19*(4), 1812–1818.

Gaouda, A. M., Kanoun, S. H., & Salama, M. M. A. (2001). On-line disturbance classification using nearest neighbor rule. *Elsevier Electric Power Systems Research*, *57*(1), 1–8.

Gaouda, A. M., Kanoun, S. H., Salama, M. M. A., & Chikhani, A. Y. (2002). Pattern recognition applications for power system disturbance classification. *IEEE Transactions on Power Delivery*, *17*(3), 677–683.

Hajian, M., & Foroud, A. A. (2014). A new hybrid pattern recognition scheme for automatic discrimination of power quality disturbances. *Elsevier Electric Power Systems Research*, *51*, 265–280.

IEC. (1996). *Electromagnetic Compatibility (EMC)—Limits—Assessment of emission limits for distorting loads in MV and HV power systems*. International Electro Technical Commission Standard, 61000-3-6.

IEC. (2008). *Electromagnetic Compatibility (EMC)—Limits—Assessment of emission limits for the connection of unbalanced installations to MV, HV and EHV power systems*. International Electro Technical Commission Standard, 61000-3-13.

IEEE. (1990). *IEEE recommended practice for electric power systems in commercial buildings*, ANSI/IEEE Std. 241-1990 (Gray Book).

IEEE. (1993). *IEEE recommended practice for electric power distribution for industrial plants*, ANSI/IEEE Std. 141-1993 (Red Book).

IEEE. (2010). *Standard definitions for the measurement of electric power quantities under sinusoidal, nonsinusoidal, balanced or unbalanced conditions*. STD 1459-2010.

IEEE. (2014). *Recommended practice and requirements for harmonic control in electric power systems*. IEEE Std 519-2014 (Revision of IEEE Std 519-1992).

IEEE P519. (2015). *IEEE draft guide for applying harmonic limits on power systems*. IEEE P519.1/D12, 1-124.

Jamehbozorg, A., & Shahrtash, S. M. (2010). A decision-tree-based method for fault classification in single-circuit transmission lines. *IEEE Transactions on Power Delivery*, *25*(4), 2190–2196.

Junior, A. M. G., Silva, V. V. R., Baccarini, L. M. R., & Reis, M. L. F. (2014). Three-phase induction motors faults recognition and classification using neural networks and response surface models. *Journal of Control, Automation and Electrical Systems*, *25*(3), 330–338.

Lieberman, D. G., Troncoso, R. J. R., Rios, R. A. O., Perez, A. G., & Yepez, E. C. (2011). Techniques and methodologies for power quality analysis and disturbances classification in power systems: A review. *IET Generation, Transmission & Distribution*, *5*(4), 519–529.

Livani, H., & Evrenosoglu, C. Y. (2013). A fault classification and localization method for three-terminal circuits using machine learning. *IEEE Transactions on Power Delivery*, *28*(4), 2282–2290.

Monedero, I., Leon, C., Ropero, J., Garcia, A., Elena, J. M., & Montano, J. C. (2007). Classification of electrical disturbances in real time using neural networks. *IEEE Transactions on Power Delivery*, *22*(3), 1288–1296.

Moravej, Z., Pazoki, M., & Khederzadeh, M. (2015). New pattern-recognition method for fault analysis in transmission line with upfc. *IEEE Transactions on Power Delivery*, *30*(3), 1231–1242.

Moreira, A. C., Paredes, H. K. M., & Silva, L. C. P. (2015). Applying conservative power theory for analyzing three-phase x-ray machine impact on distribution systems. *Elsevier Electric Power Systems Research*, *129*, 114–125.

NEMA. (1993). *Motors and generators*. NEMA Standards Publication no. MG1-1993.

Palácios, R. H. C., Goedtel, A., Godoy, W. F., & Fabri, J. A. (2016). Fault identification in the stator winding of induction motors using pca with artificial neural networks. *Journal of Control, Automation and Electrical Systems*, *27*(4), 406–418.

Ribeiro, P. F., Duque, C. A., Silveira, P. M., & Cerqueira, A. S. (2013). *Power systems processing for smart grids* (1st ed.). Hoboken: Wiley.

Rodriguez, M. V., Troncoso, R. J. R., Rios, R. A. O., & Perez, A. G. (2014). Detection and classification of single and combined power quality disturbances using neural networks. *IEEE Transactions on Industrial Electronics*, *61*(5), 2473–2482.

Samantaray, S. R. (2009). Decision tree-based fault zone identification and fault classification in flexible ac transmissions-based transmission line. *IET Generation, Transmission & Distribution*, *3*(5), 425–436.

Samantaray, S. R. (2013). A data-mining model for protection of facts-based transmission line. *IEEE Transactions on Power Delivery*, *28*(2), 612–618.

Santana, M. P., Monteiro, J. R. B. A., Borges, F. A. S., Paula, G. T., Almeida, T. E. P., Pereira, W. C. A., et al. (2017). Fault identification in doubly fed induction generator using fft and neural networks. *Journal of Control, Automation and Electrical Systems*, *28*(2), 228–237.

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Elsevier Information Processing & Management*, *45*(4), 427–437.

Statistics and Machine Learning Toolbox for MATLAB. (2017) *MATLAB classification learner application mathworks*. Retrieved October 03, 2017 from https://www.mathworks.com/help/stats/classification-learner-app.html.

Tenti, P., Paredes, H. K. M., & Matavelli, P. (2011). Conservative power theory, a framework to approach control and accountability issues in smart micro-grids. *IEEE Transactions on Power Electronics*, *26*(3), 664–673.

Upadhyaya, S., Mohanty, S., & Bhende, C. N. (2015). Hybrid methods for fast detection and characterization of power quality disturbances. *Journal of Control, Automation and Electrical Systems*, *26*(5), 556–566.

Intelligent Expert System for Power Quality Improvement Under Distorted and Unbalanced Conditions in Three-Phase AC Microgrids

Alexandre C. Moreira, *Student Member, IEEE*, Helmo K. M. Paredes, *Member, IEEE*, Wesley A. de Souza, *Student Member, IEEE*, Fernando P. Marafão, *Member, IEEE*, and Luiz C. P. da Silva

***Abstract*—This paper presents an expert system (ES) based on decoupled power/current decomposition and the *k*-nearest neighbor pattern recognition method to identify and choose the correct mitigation solution for power quality improvement in three-phase ac microgrids under non-sinusoidal current and voltage operations. By using power/current terms, load conformity factors and a *k*-nearest neighbor classifier, the proposed ES achieved 99.98% classification accuracy. Simulation studies were carried out in a PSCAD/EMTDC environment, where the IEEE 13-bus feeder test system was in a grid connected microgrid mode. The obtained results indicate that the proposed ES is robust and able to easily select an appropriate/adequate compensation solution.**

***Index Terms*—Conservative power theory, distributed generation, expert system, k-NN classifier, harmonics, microgrid, power factor, reactive power, unbalance loads.**

I. Introduction

IN RECENT years, traditional power systems have been changing due to the massive penetration of renewable energy-based Distributed Generators (DGs), electric vehicles and energy storage systems, which characterizes a scenario of smart microgrids [1]–[7]. A microgrid consists of energy supplies that can come from different sources such as: renewables, energy storage units, etc. and linear and nonlinear loads (balanced or unbalanced). Many industries, institutions, universities and housing projects have started to develop their own microgrids to have a more reliable and flexible supply. A typical structure of a microgrid is shown in Fig. 1.

Power electronic based devices are rapidly emerging as key components in modern distributed generation power systems [1], [3], [8], [9]. Power electronic interfaces offer vast advantages such as flexible control, cost reduction, overall size optimization, etc. On the other hand, operating these devices in modern power systems (smart grids) could be more damaging than traditional power systems, causing voltage and current distortions, thus drastically affecting the power quality of the supply system [10]–[12]. Thus, the combinations of distorted currents and voltages progressively reduce the power factor, increase the voltage and current distortion levels, voltage and current unbalances and reactive power consumption, which can deteriorate and hinder the microgrid power quality control.

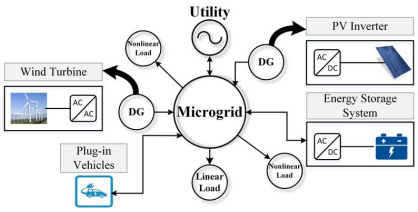

Fig. 1. Typical AC microgrid structure.

The main challenge in this new environment of smart microgrids, besides adopting more stringent standards for nonlinear loads, is to develop algorithms that are designed to provide helpful guidance concerning compensation solutions and engineering decisions considering economic aspects.

Traditionally, choosing and designing a compensator requires analyzing a large amount of data, power quality indicators, standards, computational simulations and power system engineers' experience.

Considering this, various specific solutions have been developed, such as passive filters [13], [14], static VAR compensators [15], [16] active power filter [17]–[19] and hybrid power filters [20], [21], etc. All these proposals have contributed greatly to improving Power Quality (PQ). However, these solutions still fail to meet the analysis focused on selecting which compensator is most appropriate for improving the quality of energy in modern smart grids.

Therefore, considering solutions for reactive, harmonic and imbalanced compensation, this paper proposes an Expert

Manuscript received May 25, 2017; revised September 27, 2017; accepted October 27, 2017. Date of publication November 8, 2017; date of current version October 19, 2018. This work was supported by São Paulo Research Foundation under Grant 2013/08545-6 and Grant 2016/08645-9. Paper no. TSG-00727-2017. *(Corresponding author: Alexandre C. Moreira.)*

A. C. Moreira is with the Federal University of São João del-Rei, Ouro Branco 36420000, Brazil (e-mail: amoreira@ufsj.edu.br).

H. K. M. Paredes and F. P. Marafão are with the Institute of Science and Technology, São Paulo State University, Sorocaba 18087-180, Brazil (e-mail: hmorales@sorocaba.unesp.br; fmarafao@sorocaba.unesp.br).

W. A. de Souza and L. C. P. da Silva are with the School of Electrical and Computer Engineering, University of Campinas, Campinas 13081-970, Brazil.

Color versions of one or more of the figures in this paper are available online at http://ieeexplore.ieee.org.

Digital Object Identifier 10.1109/TSG.2017.2771146

1949-3053 © 2017 IEEE. Personal use is permitted, but republication/redistribution requires IEEE permission.
See http://www.ieee.org/publications_standards/publications/rights/index.html for more information.

System (ES) that automatically provides the most adequate compensator in order to minimize losses and improve the power factor in modern power systems. Some solutions were presented in [22] and [23], but these approaches were discussed considering only distorted current compensation. Differently from previous papers [22], [23], in this paper the Conservative Power Theory (CPT) [24], [25] is used to extract the necessary information to train the algorithms and then choose the appropriate technology (compensator) for power quality improvement (current and voltage compensation).

Thus, the main contributions of this paper are:

1) to propose an automatic tool to help power system engineers to choose a proper compensator to improve the power quality in modern electrical power systems;
2) to propose the CPT as an appropriate attribute extraction to ensure the distorted currents and voltages are properly compensated and also for decision making processes of utilities and/or industrial customers to develop a suitable compensation solution;
3) to propose the k-nearest neighbor (K-NN) pattern recognition algorithm in order to replace (represent) human expertise and avoid studying and analyzing large quantities of data.

The remainder of this paper is organized as follows. Section II describes the parameters used in the developed ES. The possible compensation solutions are presented and discussed in Section III. Section IV presents the developed expert system based on K-NN. A modified IEEE 13-node test feeder is briefly described and the simulation results obtained from various case studies are presented and discussed in Section V. Finally, Section VI shows the main conclusions and contributions of this paper.

II. Parameters Used in the Developed Expert System

Normally, choosing an appropriate compensation solution among existing products and technology depends on expert knowledge. On the other hand, expert systems are a branch of Artificial Intelligence (AI) that aim to simulate the reasoning of an expert to solve real problems [26]. Therefore, the ES proposed in this paper integrates the expert knowledge with AI abilities of learning and choosing the most appropriate compensation solutions, so as to make comprehensible and correct decisions. Thus, based on the power engineer's (experts) knowledge of various cases of power factor compensations are performed through computational simulations. The decision regarding the best compensation solution is made based on the analysis of the following microgrid parameters:

- Short-circuit ratio (SCR);
- Fundamental negative-sequence voltage unbalance factor (KV_1^-);
- Fundamental zero-sequence voltage unbalance factor (KV_1^0);
- Voltage total harmonic distortion (THD_V);
- Reactive power variation ($\triangle Q$);
- CPT power terms and load conformity factors.

The parameters of the successful compensation solutions are stored in a training dataset that will be used to train a classifier algorithm. Once the classifier model is generated, it will be used in the ES in order to provide the compensation solution based on the input of new parameters.

A. CPT Load Conformity Factors

As the proposed ES should be able to identify the suitable compensation solution not only for traditional power systems, but also for modern ones, the conventional approaches do not provide adequate fundamentals for designing and developing compensators for new power system environments, mainly due to the supply voltage distortion. Moreover, as discussed in [27], depending on the nonlinear load characteristics, the usual connection of a shunt compensator is not able to significantly improve the current on the grid side. Thus, the representation of nonlinear loads as a simple combination of harmonic current sources or harmonic voltages sources [19], [28] may be reliable if any modification is introduced into the circuit, such as a connection of local source, filter or a change in the load condition. This certainly limits the usefulness of these models to study and analyze the modern power system.

The CPT presented in [24] provides power and current terms related to energy flow for smart microgrids. Moreover, the CPT makes an accountability approach possible, which models the load in a way that allows separation of load and supply responsibility [25]. Besides, the CPT "reactive energy" (W) concept can identify whether the load is a harmonic voltage source or harmonic current source. Therefore, the first advantage of the CPT is the load models presented in [25], which are more general than those proposed in [19] and [28].

In [29] and [30], novel load conformity factors were devised, which identify disturbances directly proportional to load characteristics, such as nonlinearities, reactivity and unbalance (three phase load), regardless of supply voltage conditions. For example, unlike traditional unbalanced indexes, based on the negative and zero-sequence components, the CPT unbalanced factor is a general index, which includes both negative- and zero-sequence components (at fundamental and harmonic components) [30]. This is another advantage of the CPT.

In this context, this paper proposes to use CPT factors as an alternative framework to develop methodologies to define adequate compensators, which minimize power quality problems. Thus, the load conformity factors are summarized in the following paragraphs.

1) The *General power factor* is defined taking into account all non-active powers (reactive power, Q; unbalanced power, N and distortion power, D):

$$\lambda = \frac{P}{\sqrt{P^2 + Q^2 + N^2 + D^2}} \tag{1}$$

2) The *Distortion factor* is defined as the ratio between distortion power (D) and apparent power (A):

$$\lambda_D = \frac{D}{A} = \frac{D}{\sqrt{P^2 + Q^2 + N^2 + D^2}} \tag{2}$$

3) The *Unbalance factor* is defined as:

$$\lambda_N = \frac{N}{\sqrt{P^2 + Q^2 + N^2}} \tag{3}$$

Notice that the load conformity factors, defined above, represent the information of how a generic load affects the current and power terms, focusing on the identification and quantification of the load phenomena at the Point of Common Coupling (PCC).

For this reason, load conformity factors are used in this study instead of traditional power quality indices–current total harmonic distortion (THD_I), total demand distortion (TDD) [31], [32] and current unbalance factors (KI_1^- and KI_1^0), as proposed in [22] and [23]. In weak grids (microgrid scenario), the harmonic currents generated by the nonlinear load will lead to voltage distortion (the same applies to unbalanced currents, which generate unbalanced voltages). In this case, the CPT factors are concentrated on the load (behaviors) characteristics and not just on the current waveforms, which can be influenced by voltage conditions.

III. Solutions to Develop Expert System

The main task of the ES is to determine the compensation solution for power quality improvement. In order to do this, the parameters described in the previous section are measured every minute setting pre-established limits (voltages and load conformity factors). The results are classified according to possible compensation solutions presented as follows.

The products and technologies considered for compensation are based on passive solutions (capacitor banks, tuned filters, TSC-thyristor switched capacitors, TCR-thyristor controlled reactors) and active power filters [16]. Thus, in order to maintain the PQ indicators within pre-established limits according to standards or microgrid requirements, these solutions can perform the reactive, unbalance and/or harmonic compensation.

A. Solution 01

The developed ES should indicate "no compensation is needed". In other words, when there is no need to install a particular compensator (equipment).

B. Solution 02

This solution will be suggested by the ES when there is a violation of the power factor (λ). The adopted power factor limit was 0.92, according to the Brazilian Electrical Regulatory Agency (ANEEL) [33]. In this case, the solution is a three-phase capacitor bank (Fig. 2). This configuration (delta capacitors) is used for greater use in terms of the reactive power converted per unit of installed capacitance. Moreover, this configuration does not absorb zero sequence components and is, therefore, intrinsically protected against third-order harmonics.

C. Solution 03

For power factor compensation of fast varying loads with reactive behavior, the ES must indicate a "thyristor-switched capacitor" (TSC) as a solution (Fig. 3). The design of this solution will be based on the load reactive power profile.

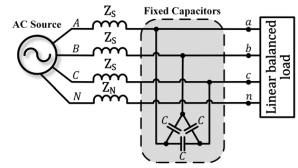

Fig. 2. Three-phase capacitor bank.

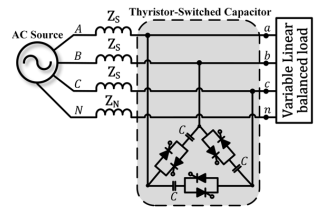

Fig. 3. Thyristor-switched capacitor.

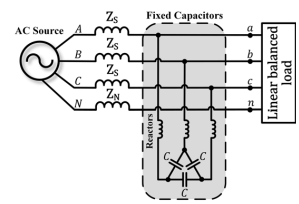

Fig. 4. Fixed three-phase capacitor bank and series reactor.

D. Solution 04

When a linear load requires reactive compensation and the power factor is lower than 0.92, as indicated in solution 01, the ES must indicate a three-phase capacitor bank. However, if the grid is strong and the voltage distortions (THD_V) are above 5% [31], [32], series reactors need to be used with capacitor banks in order to limit the harmonic currents, Fig. 4.

The series reactor must be connected and adjusted to a lower frequency than the low-order harmonic. The reactor is used to protect the capacitor bank against the harmonic overcurrent. This eliminates any risk of resonance and helps eliminate harmonics. This solution is called capacitor bank detuning.

E. Solution 05

If the linear load presents a low power factor (λ<0.92), voltage distortion (THD_V) and a load profile with large reactive variations ($\triangle Q$) over time, the proposed ES must indicate a "variable three-phase capacitor bank and series reactor" (Fig. 5).

F. Solution 06

In order to control the harmonics injection into the grid, passive filters must be recommended by the ES. For this, the power factor (λ) and distortion factor (λ_D) should be less than the minimum limits. In addition, the grid must have a high SCR (strong grid). As discussed in Section II-A, the load behavior may be the harmonic current source or harmonic

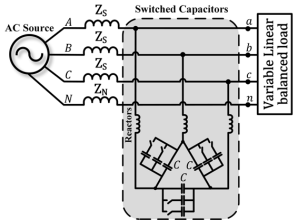

Fig. 5. Variable three-phase capacitor bank and series reactor.

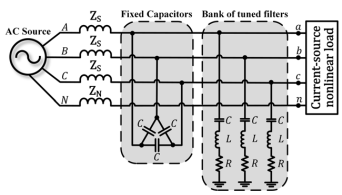

Fig. 6. Three-phase shunt passive filter and fixed three-phase capacitor bank.

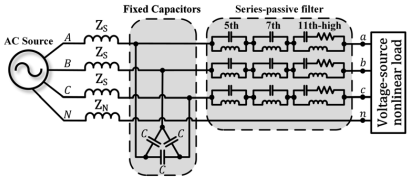

Fig. 7. Three-phase series filter and fixed three-phase capacitor bank.

voltage source. In this case, the correct configuration (series or shunt) of the passive filter is indicated by the reactive energy (W) signal. In other words, the ES must indicate the solution and how it should be connected to the PCC (series or shunt).

Therefore, if $W>0$, the ES must be indicated (Fig. 6). The objective of this solution is to design a system of filters that provide an adequate reduction of harmonic currents and supply a portion of reactive power at the fundamental frequency. Both objectives should be reached within a minimum cost.

The filters can be wye (Y) connected or delta (Δ). The (Y) connection is the most used as it can easily monitor the neutral current. In distribution systems, a slight purposeful filter detuning is important to control the natural resonant frequencies [33].

The higher the intensity of the harmonics, the lower their order, which leads to the use of low impedance filters for frequencies equal or close to these harmonics. Using individual filters for each (low order) harmonic is more economical than using a single wide band filter which provides sufficiently low impedances at various frequencies.

G. Solution 07

Differently to the previous solution, if $W<0$ (harmonic voltage source) and the power factor (λ) and distortion factor (λ_D) are lower than the limits, the recommended solution will be a "series passive filter and a fixed capacitor bank" (Fig. 7).

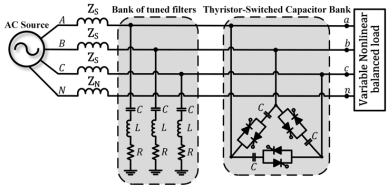

Fig. 8. Thyristor-switched capacitor bank and passive filter.

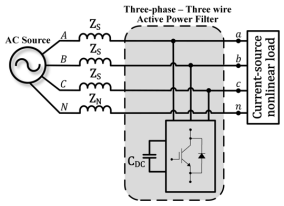

Fig. 9. Three-phase three wire shunt active power filter.

H. Solution 08

The following solution (Fig. 8), as solution 03, shows a cycle of reactive demand variations over time (ΔQ), however due to the presence of the nonlinear load there are violations in the current harmonic distortion (λ_D) and consequently power factor violations (λ).

It should be noted that the grid must have a high SCR (strong grid) for this solution. The proposed ES should take this information into account for correct decision making.

I. Solution 09

The following solution (Fig. 9) should be recommended when there is a power factor (λ) violation and high current harmonic distortion (λ_D). In addition, the grid must have a low SCR (weak grid).

It should be mentioned that the ES must be able to suggest its connection topology, similarly to solutions 06 and 07.

This solution ($W>0$) has a fast dynamic response, which compensates sudden current variations and a wide range of harmonics compensation. When properly controlled, no restrictions are required on the voltage waveform (harmonics or asymmetry) for the shunt compensator to reach its objectives in terms of current compensation.

J. Solution 10

When $W < 0$ (harmonic voltage source), the power factor is below the threshold, the current harmonic distortion is below the threshold and the grid has a low SCR, the recommended solution is to install a three-phase three wire series active power filter, Fig. 10.

K. Solution 11

The ES must indicate this type of solution when there is a violation of the current unbalance (λ_N) and of the power factor (λ). The purpose of this solution is to balance the phases of an unbalanced circuit (Fig. 11).

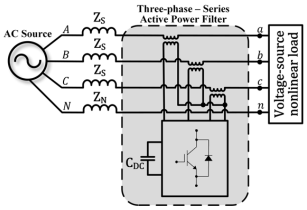

Fig. 10. Three-phase three wire series active power filter.

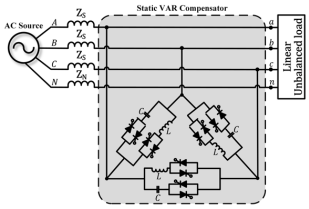

Fig. 11. Static VAR compensator.

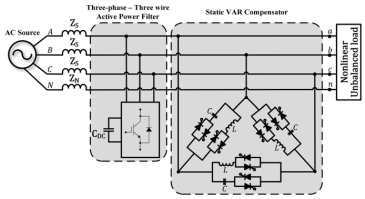

Fig. 12. Static VAR compensator and active power filter.

L. Solution 12

In the previous case (solution 11), when voltage distortion (THD_V), current unbalance (λ_N) and power factor (λ) violation are present, the recommended solution is a static VAR compensator and active power filter (Fig. 12).

M. Solution 13

Solution 13 must be recommended by the ES when phase balancing is required due to current unbalance (λ_N), and the need to compensate the current harmonics (λ_D) generated by the non-linear load (Fig. 13).

It should be noted that for this solution, the grid must have a high SCR (strong grid).

N. Solution 14

In case of power factor violations (λ), the current unbalance (λ_N), distortion factor (λ_D) and voltage distortion (THD_V), the recommended solution for the compensation must be a "four-wire shunt active power filter", Fig. 14.

It is important to mention that the electronic compensator would have functions similar to the passive compensators previously presented. However, this compensator will be able to compensate even inter-harmonics of the current, which is not possible using tuned passive filters.

In case of imbalances and asymmetries, the compensator is able to minimize such disturbances, even in the case of systems

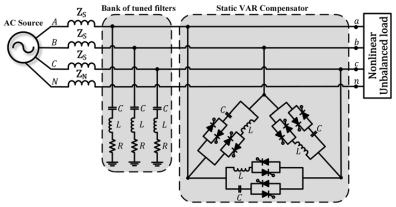

Fig. 13. Static VAR compensator and passive filter.

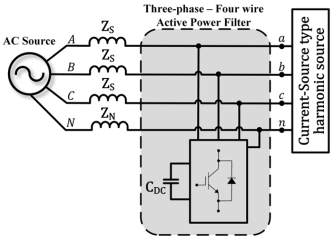

Fig. 14. Four wire shunt active power filter.

with return conductors. In order to maximize the power factor, it may be necessary to compensate harmonics, unbalances and reactive power, and this can be done through a single electronic compensator.

IV. Developed Expert System Based on K-Nearest Neighbor Classifier

Based on the power systems engineer's knowledge and human experience, the CPT load conformity factors can be related with the mitigation devices. Table I shows the possible solutions according to the indicators violated over time and the analysis of the signal of the reactive energy.

For the solution diagnosis, it is assumed that 1440 daily values are enough to characterize the evolution of the variable loads. This amount of daily values is also enough to decide the typical variation ranges of the quantities during the work cycle of these loads and which compensator should be used. Thus, in practice, the meter should store one sample of the indicators every minute.

As previously mentioned, 0.92 was adopted as a limit for the power factor (λ), 5% for voltage harmonic distortion (THD_V) and 2% for voltage unbalance (KV_1^- or KV_1^0) [34]. In the case of the reactive variation (ΔQ), values above or below 30% of the daily average were considered.

Regarding the distortion factor, there is no specific limit as this indicator, as well as the TDD [31], [32] should have a limit for each SCR band. Similarly, for current imbalance, there is no specific limit or range of values defined by standards that limit this indicator.

To sidestep this problem and define acceptable limits for (λ_D) and (λ_N), this study proposes the use of the k-nearest neighbor (K-NN) pattern recognition technique, which is explained as follows.

K-Nearest Neighbor (K-NN) is a supervised learning algorithm that finds the first K minimum distance points, makes

TABLE I
MITIGATION SOLUTIONS FOR REACTIVE AND HARMONICS COMPENSATION ACCORDING TO THE PROPOSED METHODOLOGY

Solution	Mitigation Device	λ	λ_D	λ_N	THD_V	ΔQ	KV_1^- or KV_1^0	Reactive Energy
1	*No compensation is need*							
2	*Capacitor bank*	•						
3	*Thyristor-switched capacitor*	•				•		
4	*Capacitor bank and series reactor*	•			•			
5	*Variable capacitor bank and series reactor*	•			•	•		
6	*Shunt passive filter and fixed capacitors*	•	•					>0
7	*Series passive filter and fixed capacitors*	•	•					<0
8	*Thyristor-switched capacitor and passive filter*	•	•			•		
9	*Shunt three-phase three wire active power filter*	•	•		•			>0
10	*Series three-phase three wire active power filter*	•	•		•		•	<0
11	*Static VAR compensator*	•		•				
12	*Static VAR compensator and active power filter*	•		•	•			
13	*Static VAR compensator and passive filter*	•	•	•				
14	*Four wire shunt active power filter*	•	•	•	•			

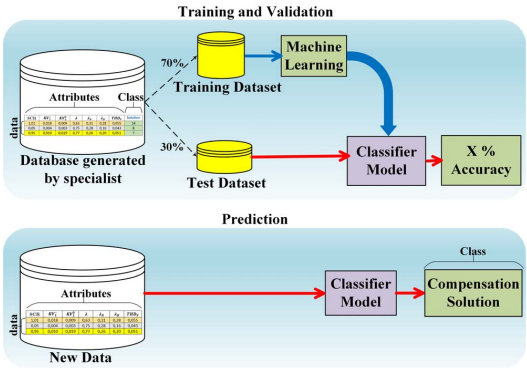

Fig. 15. Block diagram of supervised learning with specialist.

a decision based on the group that has the majority of the minimum distances. It can produce any arbitrary complex surface to separate the classes based on the configuration of the sample points and their distance relations to each other. The closeness is usually measured in terms of Euclidean distances. In order to map and define regions for each compensation solution, a database was initially developed containing the input parameters of the classifier: SCR, KV_1^-, KV_1^0, λ, λ_N, λ_D, THD_V, ΔQ and W. The learning process previously described is summarized in Fig. 15. These parameters are extracted through several simulations in the computational tools PSCAD/EMTDC and MATLAB/Simulink. For each set of inputs inserted in the database, the power system engineer (specialist) defines the respective compensation solution. This solution is then verified through a careful analysis of various PQ indexes and new simulations in the electrical system containing the compensation solution (compensator) for a particular PQ disturbance. The specialist verifies if all PQ indices are within the limits established by standards [31], [32], [35].

Once the disturbances in the current or voltage are corrected, these attributes are labeled with their corresponding class (compensation solution), that is, for each entry (attributes) the expert will indicate the correct answer (class). In conclusion, each database line represents a simulated electrical system, analyzed by the specialist, and its respective compensation solution (class). Thus, the dataset for training the algorithm will have always a corresponding response for each entry. In other words, the power system engineer's reasoning for decision making will be simulated through the ES.

After the classifier model is implemented, new input parameters will be provided to the model, however, without the presence of the corresponding answers (compensation solutions).

The database generated by the specialist is fundamental for training and evaluating algorithms, and also for developing classifier models. The aim of the algorithms evaluated in this paper is to extract knowledge from the information contained in this database. This database has been developed using various computational simulations and has benefitted from more than 15 years of specialist experience (research project between university and utility). Thus, various electrical power systems were implemented with voltage levels between 120 V-69 kV with different short-circuit levels (strong and weak grid), distorted voltages, unbalanced voltages, nonlinear loads and unbalanced loads. In addition, to improve the performance and minimize the errors of the proposed methodology a set of disturbing load models were used [30], [36]. It is important to underline that these models are not available in the PSCAD or MATLAB software. Thus, from the combination of different voltage supply conditions and different types of loads, a variety of operation conditions can be simulated for database generation (Fig. 16).

The complete process of the proposed methodology for detecting and classifying the appropriate compensation solution is shown in Fig. 17.

The user can choose between performing data acquisition or carrying out a computational simulation. Voltage and current signals are measured using a Virtual Instrument (VI) that will process the signals through a data acquisition board [37], [38]. Using a VI, an interface of data acquisition was developed for real time processing of CPT terms extracted from voltage and current signals measured from the grid. Digital processing algorithms were implemented to calculate rms and average quantities using the moving average filter, therefore all CPT quantities are calculated with a 12.6 kHz sampling frequency, but the data are stored once a minute. The attributes extracted

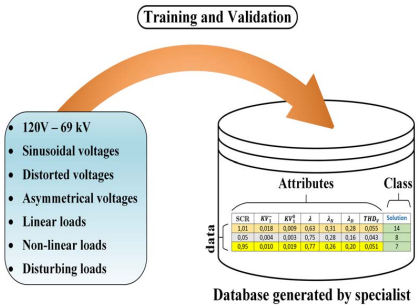

Fig. 16. Database generated by specialist.

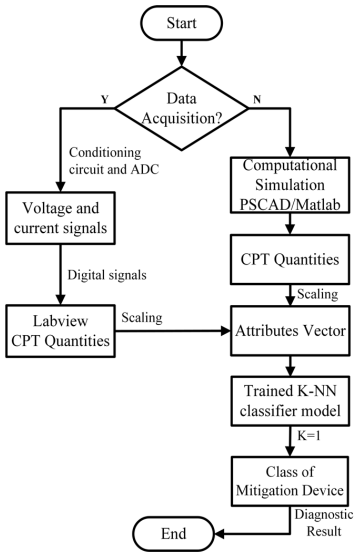

Fig. 17. Flowchart of the proposed methodology.

are normalized in [0, 1] and can be sent to the trained classifier model. Finally, these attribute vectors generated every minute are classified according to their respective violated limits. This information about the class of compensation device may be sent to a management center of the microgrid, on where it may become available for the users or used in a dataset to perform online non-supervised classification.

A. Evaluation of ES

As previously mentioned, defining regions for the distortion and asymmetry factors is a great challenge in this study due to the non-linearity of these variables and their relation to voltage distortion. Thus, three pattern recognition methods were evaluated in order to find the method with the highest accuracy.

The comparison of classification accuracies among the evaluated methods are depicted in Table II. The balanced dataset was evaluated using 10-fold cross validation. In this study, multi-layer perceptron (MLP) training was used as function fitting a two-layer feed-forward network, with a sigmoid transfer function in the hidden layer and a linear transfer function in the output layer. The number of hidden neurons chosen for the MLP model was 10. In addition, for the MLP training we used up to 1000 epochs. It can be observed that K-NN(K = 1) provides maximum classification accuracy of 99.984% with 90–10%, compared to all other training and testing data sets. It can also be observed that the K-NN classification accuracy increases up to 90−10%, whereas the decision tree (DT) decreases to 94.342%. This occurs due to the non-linearity of the distortion and asymmetry factors. In relation to K-NN, the best results are achieved with k = 1.

TABLE II
ACCURACY COMPARISON OF DIFFERENT CLASSIFICATION METHODS

Classifier	Accuracy (%)	
	Training	Test
50 % training and 50% testing		
Decision Tree	96.600	96.523
1-Nearest neighbour	100	99.977
3-Nearest neighbour	100	99.969
10-Nearest neighbour	99.900	99.916
Multi-layer perceptron	95.480	95.460
60 % training and 40% testing		
Decision Tree	96.400	95.708
1-Nearest neighbour	100	99.978
3-Nearest neighbour	100	99.974
10-Nearest neighbour	99.900	99.935
Multi-layer perceptron	93.100	93.040
70 % training and 30% testing		
Decision Tree	95.100	94.428
1-Nearest neighbour	100	99.979
3-Nearest neighbour	100	99.977
10-Nearest neighbour	99.900	99.945
Multi-layer perceptron	97.780	97.820
90 % training and 10% testing		
Decision Tree	94.400	94.342
1-Nearest neighbour	100	99.984
3-Nearest neighbour	100	99.980
10-Nearest neighbour	99.900	99.965
Multi-layer perceptron	95.230	95.370

V. APPLICATION OF ES FOR CLASSIFICATION OF COMPENSATION CASES

For the evaluation of the proposed ES, the modified IEEE 13 node test feeder was considered, as shown in Fig. 18. This feeder is highly unbalanced for a small 4.16 kV system and consists of a mix of loads, capacitor banks and a substation voltage regulator [39]. The modifications are the inclusion of the power electronic interface to renewable-based distributed energy resource (DER), such as solar photovoltaic (PV).

The PV system used for the proposed test feeder has 125 strings and each string has 4 series of connected panels. The Maximum Power Point (MPP) for a single panel at 1000 W/m^2 and 25°C is 200W. Hence, the maximum power of the PV generator is 0.1 MVA. The MPP varies according to the change in irradiance level and cell temperature. In node 634, a nonlinear load (induction furnace [36]) was inserted in order to generate harmonic currents.

A. Preliminary Assessment

A set of voltage and current measurements was performed at nodes 632, 634 and 680, respectively. The purpose of these

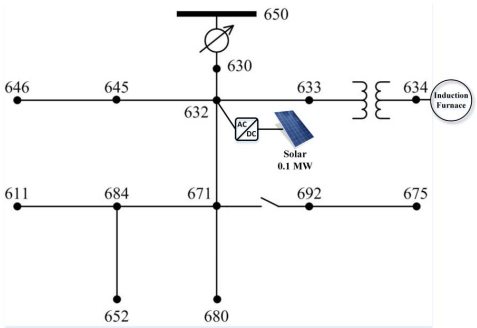

Fig. 18. Modified IEEE 13 node test feeder used to evaluate the proposed ES.

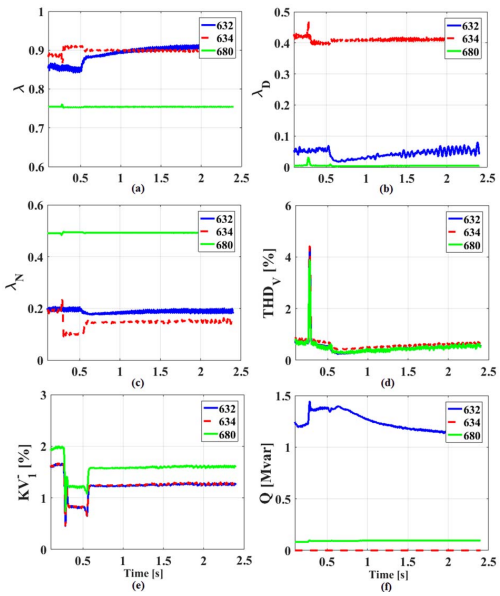

Fig. 19. Parameter evolution before compensation. (a) CPT power factor. (b) Distortion factor. (c) Unbalance factor. (d) Voltage total harmonic distortion. (e) Fundamental negative-sequence voltage unbalance factor. (f) Reactive Power.

measurements is to present the different compensation solutions that can be provided by the ES. Fig. 19 shows the main indicators evaluated for decision making. It is important to underline that the values were obtained from the instantaneous current and voltage waveforms measured at nodes 632, 634 and 680 by means of CPT. For each case, the total simulation and measurement time was 2.4s in order to represent 24 hours.

Fig. 19(a) shows the evolution of power factor (λ) for the three nodes. Node 632 has around 0.90 of power factor (below than 0.92). Node 634, due to the presence of the induction furnace, has 0.897 of power factor, while node 680 has the lowest power factor, 0.754.

Fig. 19(b) shows that bar 632 has a high distortion level due to the induction furnace. This harmonic distortion in the current produces distortion power (D), which reduces the power factor. In these cases, a correct power factor compensation and harmonic current minimization must be performed. Node 632 has a smaller current distortion to node 634 due to the Y/Y transformer between nodes 633 and 634.

The ES will evaluate the unbalance of current in the load through the unbalanced factor (λ_N). It can be seen from Fig. 19(c) that node 680 has a high load unbalance, which affects the power factor (λ). Thus, because it is a linear load, it is unbalanced.

Regarding the harmonic voltage distortion, Fig. 19(d) shows that all evaluated nodes are within the 5% limit defined for the ES. The same occurs with the voltage unbalance as it is below 2% [35] Fig. 19(e).

Fig. 19(f) shows the evolution of the reactive power for the three nodes under analysis. It can be seen that there are no large reactive variations (ΔQ) at nodes 634 and 680. In the case of node 632, the load variations can be observed during the measurement time. The maximum, average and minimum reactive power are 1.44 MVA, 1.23 MVA and 1.22 respectively. These terms are within the limits set for $\pm$ 30% reactive variations.

B. Mitigation Analysis

This section presents the solutions proposed by the ES based on the preliminary evaluation performed at nodes 632, 634 and 680. In addition, the results of the application of the mitigation solutions in the respective nodes are presented in Fig. 20.

Considering the 2.4s simulation time and the parameters mentioned in the previous section, the ES suggested solution 2 for node 632. Fig. 20 (a) shows the evolution of the power factor at node 632 with the presence of the "Fixed Three- Phase Capacitor Bank" at this node. As can be seen, the power factor is corrected to 0.93. Thus, the result was that the ES reached the desired goal when choosing to perform the compensation at node 632.

For node 634, the ES suggests solution 7, if the choice is made by performing the compensation in this node. The developed algorithm identifies that there was a violation of the solution of the power factor and the distortion factor during 100% of the measurement period – Fig. 19(b). In this case, one must proceed with the installation of passive filters, however the ES is able to identify that this passive filter must be installed in series with the load. This decision is made based on the analysis of the reactive energy signal which, in this case, identified the load as a voltage source at this furnace operating frequency (6 kHz). Fig. 20(b) shows the evolution of the distortion factor for a new computational simulation containing solution 7 implemented at node 634. Solution 7 was designed in order to eliminate 5th order harmonics.

Analyzing node 680, the expert system identified a violation of the power factor and asymmetry factor during 100% of the measurement period (Fig. 19). Therefore, if the choice of performing the power factor compensation at node 680 is made, the expert system indicates solution 11 (SVC). It can be seen from Fig. 20(a) that, after installing the SVC at node 680, the power factor is corrected to 0.95. In addition, the

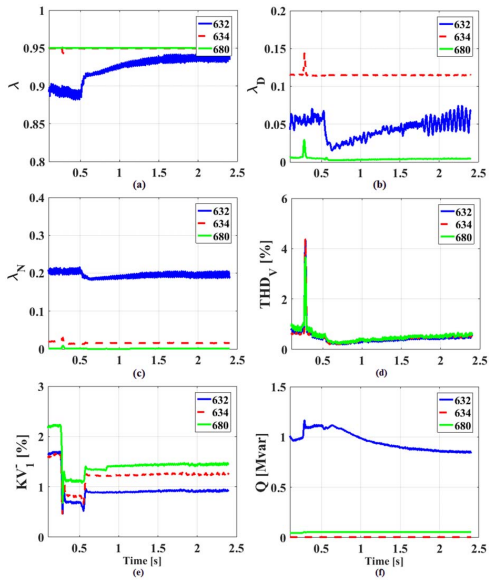

Fig. 20. Parameter evolution after compensation. (a) CPT power factor. (b) Distortion factor. (c) Unbalance factor. (d) Voltage total harmonic distortion. (e) Fundamental negative-sequence voltage unbalance factor. (f) Reactive Power.

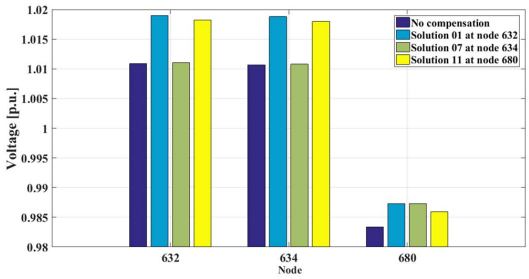

Fig. 21. Voltage profiles.

load unbalance has also been corrected after installing this equipment – Fig. 20(c).

Fig. 21 summarizes the voltage profile at the nodes. It can be seen that nodes 632, 634 and 680 are within the acceptable level (±5%). The lowest voltage compared to the other nodes can be observed at node 680 when there are no compensation solutions connected in the power system. Moreover, the suggested solutions effectively improve the voltage nodes.

VI. Conclusion

This paper has proposed a new approach for the classification and recognition of power system disturbance related to power quality improvement using the Conservative Power Theory and K-NN ES in the context of smart grids. CPT conformity factors were used to measure and quantify the load which becomes the inputs for the K-NN model to classify the proper solution. The ES yields a robust and accurate classification scheme for several of the simulated cases containing harmonic distortions, imbalance, low power factor and different levels of SCR in the grid. The intelligent classification system is found to be more accurate than other techniques, such as the decision tree and artificial neural network.

Choosing the best compensation device is fundamentally important for the best operation of the microgrid, the distributed generation (DG) technologies, as well as the reduction of losses.

Considering the absence of standards that limit the current unbalance and the variation of reactives, the ES was able to identify the correct compensation solution through the K-NN pattern recognition technique and the power system engineer's experience. In addition, a relationship between the CPT conformity factors and the power conditioner devices was presented (Table I).

It should be noted that the proposed ES is capable of suggesting the compensation solution in a microgrid environment and also how this solution will be connected in the grid (series or shunt). This decision is only possible by analyzing the behavior of the load (voltage source or current), which is possible through the signal of the reactive energy.

References

[1] D. E. Olivares *et al.*, "Trends in microgrid control," *IEEE Trans. Smart Grid*, vol. 5, no. 4, pp. 1905–1919, Jul. 2014.

[2] M. Yazdanian and A. Mehrizi-Sani, "Distributed control techniques in microgrids," *IEEE Trans. Smart Grid*, vol. 5, no. 6, pp. 2901–2909, Nov. 2014.

[3] K. Moslehi and R. Kumar, "A reliability perspective of the smart grid," *IEEE Trans. Smart Grid*, vol. 1, no. 1, pp. 57–64, Jun. 2010.

[4] J. Han, S. Khushalani-Solanki, J. Solanki, and J. Liang, "Adaptive critic design-based dynamic stochastic optimal control design for a microgrid with multiple renewable resources," *IEEE Trans. Smart Grid*, vol. 6, no. 6, pp. 2694–2703, Nov. 2015.

[5] M. M. Hashempour, M. Savaghebi, J. C. Vasquez, and J. M. Guerrero, "A control architecture to coordinate distributed generators and active power filters coexisting in a microgrid," *IEEE Trans. Smart Grid*, vol. 7, no. 5, pp. 2325–2336, Sep. 2016.

[6] M. Hong, X. Yu, N.-P. Yu, and K. A. Loparo, "An energy scheduling algorithm supporting power quality management in commercial building microgrids," *IEEE Trans. Smart Grid*, vol. 7, no. 2, pp. 1044–1056, Mar. 2016.

[7] A. Khodaei, "Provisional microgrids," *IEEE Trans. Smart Grid*, vol. 6, no. 3, pp. 1107–1115, May 2015.

[8] B. Ferreira, "Understanding the challenges of converter networks and systems: Better opportunities in the future," *IEEE Power Electron. Mag.*, vol. 3, no. 2, pp. 46–49, Jun. 2016.

[9] J. M. Guerrero *et al.*, "Distributed generation: Toward a new energy paradigm," *IEEE Ind. Electron. Mag.*, vol. 4, no. 1, pp. 52–64, Mar. 2010.

[10] M. H. J. Bollen *et al.*, "Power quality concerns in implementing smart distribution-grid applications," *IEEE Trans. Smart Grid*, vol. 8, no. 1, pp. 391–399, Jan. 2017.

[11] N. R. Watson, T. L. Scott, and S. J. J. Hirsch, "Implications for distribution networks of high penetration of compact fluorescent lamps," *IEEE Trans. Power Del.*, vol. 24, no. 3, pp. 1521–1528, Jul. 2009.

[12] C. Muscas, "Power quality monitoring in modern electric distribution systems," *IEEE Instrum. Meas. Mag.*, vol. 13, no. 5, pp. 19–27, Oct. 2010.

[13] J. C. Das, "Passive filters—Potentialities and limitations," *IEEE Trans. Ind. Appl.*, vol. 40, no. 1, pp. 232–241, Jan./Feb. 2004.

[14] F. Z. Peng, G.-J. Su, and G. Farquharson, "A series LC filter for harmonic compensation of AC drives," in *Proc. 30th Annu. IEEE Power Electron. Specialists Conf. (PESC)*, vol. 1. Charleston, SC, USA, Aug. 1999, pp. 213–218.

[15] D. Jovcic, N. Pahalawaththa, M. Zavahir, and H. A. Hassan, "SVC dynamic analytical model," *IEEE Trans. Power Del.*, vol. 18, no. 4, pp. 1455–1461, Oct. 2003.

[16] J. Dixon, L. Moran, J. Rodriguez, and R. Domke, "Reactive power compensation technologies: state-of-the-art review," *Proc. IEEE*, vol. 93, no. 12, pp. 2144–2164, Dec. 2005.

[17] B. Singh, K. Al-Haddad, and A. Chandra, "A review of active filters for power quality improvement," *IEEE Trans. Ind. Electron.*, vol. 46, no. 5, pp. 960–971, Oct. 1999.

[18] H. Akagi, "Control strategy and site selection of a shunt active filter for damping of harmonic propagation in power distribution systems," *IEEE Trans. Power Del.*, vol. 12, no. 1, pp. 354–363, Jan. 1997.

[19] F. Z. Peng, "Application issues of active power filters," *IEEE Ind. Appl. Mag.*, vol. 4, no. 5, pp. 21–30, Sep./Oct. 1998.

[20] F. Z. Peng, H. Akagi, and A. Nabae, "A new approach to harmonic compensation in power systems-a combined system of shunt passive and series active filters," *IEEE Trans. Ind. Appl.*, vol. 26, no. 6, pp. 983–990, Nov./Dec. 1990.

[21] B. Singh, V. Verma, A. Chandra, and K. Al-Haddad, "Hybrid filters for power quality improvement," *IEE Proc. Gener. Transm. Distrib.*, vol. 152, no. 3, pp. 365–378, May 2005.

[22] E. V. Liberado, F. P. Marafão, M. G. Simões, W. A. de Souza, and J. A. Pomilio, "Novel expert system for defining power quality compensators," *Expert Syst. Appl.*, vol. 42, no. 7, pp. 3562–3570, Mar. 2015.

[23] A. C. Moreira, S. M. Deckmann, F. P. Marafão, L. C. P. da Silva, and H. K. M. Paredes, "Decision tree based expert system for power factor improvement under distorted and unbalanced current conditions," *Przeglad Elektrotechniczny*, vol. 91, no. 11, pp. 109–114, 2015.

[24] P. Tenti, H. K. M. Paredes, and P. Mattavelli, "Conservative power theory, a framework to approach control and accountability issues in smart microgrids," *IEEE Trans. Power Electron.*, vol. 26, no. 3, pp. 664–673, Mar. 2011.

[25] P. Tenti, H. K. M. Paredes, F. P. Marafao, and P. Mattavelli, "Accountability in smart microgrids based on conservative power theory," *IEEE Trans. Instrum. Meas.*, vol. 60, no. 9, pp. 3058–3069, Sep. 2011.

[26] M. H. J. Bollen and I. Y.-H. Gu, *Signal Processing of Power Quality Disturbances*. Piscataway, NJ, USA: Wiley, 2006, pp. 726–733.

[27] J. A. Pomilio and S. M. Deckmann, "Characterization and compensation of harmonics and reactive power of residential and commercial loads," *IEEE Trans. Power Del.*, vol. 22, no. 2, pp. 1049–1055, Apr. 2007.

[28] F. Z Peng, "Harmonic sources and filtering approaches," *IEEE Ind. Appl. Mag.*, vol. 7, no. 4, pp. 18–25, Jul./Aug. 2001.

[29] H. K. M. Paredes, F. P. Marafão, P. Mattavelli, and P. Tenti, "Application of conservative power theory to load and line characterization and revenue metering," in *Proc. IEEE Int. Workshop Appl. Meas. Power Syst. (AMPS)*, Aachen, Germany, Sep. 2012, pp. 1–6.

[30] A. C. Moreira, H. K. M. Paredes, and L. C. P. da Silva, "Applying conservative power theory for analyzing three-phase X-ray machine impact on distribution systems," *Elect. Power Syst. Res.*, vol. 129, pp. 114–125, Dec. 2015.

[31] *IEEE Recommended Practice and Requirements for Harmonic Control in Electric Power Systems*, IEEE Standard 519-2014, Jun. 2014.

[32] *IEEE Draft Guide for Applying Harmonic Limits on Power Systems*, IEEE Standard P519.1/D12, Feb. 2015, pp. 1–124.

[33] A: ANEEL. (Nov. 2000). *Rule Resolution N° 456, (in Portuguese)*. Accessed: Nov. 2017. [Online]. Available: http://www2.aneel.gov.br/cedoc/bres2000456.pdf

[34] *IEEE Guide for Application and Specification of Harmonic Filters*, IEEE Standard 1531-2003, 2003, pp. 1–60.

[35] "Electromagnetic compatibility (EMC)—Part 3-2: Limits—Assessment of emission limits for the connection of unbalanced installations to MV, HV and EHV power systems," IEC, Geneva, Switzerland, Tech. Rep. 61000-3-13, 2008.

[36] A. C. Moreira, L. C. P. da Silva, and H. K. M. Paredes, "Electrical modelling and power quality analysis of three-phase induction furnace," in *Proc. 16th Int. Conf. Harmonics Qual. Power (ICHQP)*, Bucharest, Romania, 2014, pp. 415–419.

[37] A. C. Moreira *et al.*, "Making use of virtual instrumentation for the evaluation of Std-1459 and FBD method in three-phase four-wire circuits," in *Proc. 12th IEEE Int. Conf. Ind. Appl. (INDUSCON)*, Curitiba, Brazil, 2016, pp. 1–7.

[38] H. K. M. Paredes, F. P. Marafão, D. I. Brandão, and I. S. Diniz, "Conservative power theory discussion and evaluation by means of virtual instrumentation," in *Proc. Brazil. Power Electron. Conf.*, Bonito, Brazil, 2009, pp. 423–430.

[39] W. H. Kersting, "Radial distribution test feeders," in *Proc. IEEE Power Eng. Soc. Win. Meeting*, Columbus, OH, USA, 2001, pp. 908–912.

Alexandre C. Moreira (S'14) received the B.S. degree in electrical engineering from the Federal University of Goiás, Brazil, in 2003 and the M.S. and Ph.D. degrees from the University of Campinas, Brazil, in 2006 and 2017, respectively. From 2015 to 2016, he was a Visiting Doctoral Scholar with the University of Oulu, Finland. Since 2010, he has been a Professor with the Federal University of São João del-Rei, Brazil. His research interests include machine learning, power quality, power theories, electrical machines, and power electronics.

Helmo K. M. Paredes (S'09–M'11) received the B.S. degree in electrical engineering from the National University of Saint Agustine, Arequipa, Perú, in 2002 and the M.S. and Ph.D. degrees from the University of Campinas, Campinas, Brazil, in 2006 and 2011, respectively. In 2009, he joined the Department of Information Engineering, University of Padova, Padova, Italy, as a visiting student. In 2014, he joined the PEMC Group, Department of Electrical and Electronic Engineering, University of Nottingham, Nottingham, U.K., as a Visiting Scholar. Since 2011, he has been an Assistant Professor with the Institute of Science and Technology, São Paulo State University, Sorocaba, Brazil, where he is the Leader of the Group of Automation and Integrating Systems. His current research interests include power quality, power theories, and power electronics applied to power systems. He was a recipient of the Prize Paper Award from the IEEE TRANSACTIONS ON POWER ELECTRONICS in 2011. He is a member of the Brazilian Power Electronics Society and Brazilian Automatic Society.

Wesley A. de Souza (S'15) received the B.S. degree in computer science from the School of Sciences (FC), Universidade Estadual Paulista (UNESP), Bauru, the M.S. degree in electrical engineering from the School of Engineering, UNESP, and the Ph.D. degree in electrical engineering from the School of Electrical and Computer Engineering (FEEC), State University of Campinas (UNICAMP). He was a Visiting Researcher with the University of Padua, Italy. He is a Post-Doctoral Research Fellow in electrical engineering from FEEC/UNICAMP. His research interests include embedded systems, electrical metering, smart metering, cognitive metering, artificial intelligence, pattern recognition algorithms, hardware, instrumentation, high and low-level programming and Web development.

Fernando P. Marafão (S'95–M'05) received the B.S. degree in electrical engineering from the Univ Estadual Paulista (UNESP), Sorocaba, Brazil, in 1998 and the M.Sc. and Ph.D. degrees from the University of Campinas, Brazil, in 2000 and 2004, respectively. In 2002, he joined the Power Electronics Group, University of Padova, Italy, as a visiting student. In 2013, he joined the ACEPS Group, Colorado School of Mines, USA, as a Visiting Scholar. He is an Associate Professor with UNESP, where he has been teaching since 2005 and had led the Group of Automation and Integrated Systems from 2007 to 2011. His research interests include power theories, power quality, and power electronics. He is a member of the Brazilian Power Electronics Society and Brazilian Automatic Society.

Luiz C. P. da Silva received the B.S. degree in electrical engineering from the Federal University of Goiás, Brazil, in 1995 and the M.S. and Ph.D. degrees in power systems engineering from the University of Campinas, Brazil, in 1997 and 2001, respectively. He was a Visiting Researcher with the University of Alberta, Canada, from 1999 to 2000, and as a Guest Professor with the Technical University of Denmark, in 2008. Since 2002, he has been with the University of Campinas, where he is an Associate Professor. His research interests include power system stability and control and distributed generation.

Automatic Consumption Management for Prepaid Electricity Meter with NILM

W. A. Souza, *Member, IEEE*, F. D. Garcia, A. C. Moreira, *Member, IEEE*, F. P. Marafão, *Member, IEEE*, and L. C. P. Silva, *Member, IEEE*

***Abstract*— Recently, the Brazilian Electricity Regulatory Agency (ANEEL) regularized the electricity prepayment system and opened a general discussion about the technologies, resources, and implementations for the prepayment metering system. In several countries, the consumer charges the value equivalent to the kilowatt-hours that he wishes to buy for use. However, some consumers purchase credit with the expectation that the charge remains for a specific time, but they may be surprised with the credit end before the expected time. For this reason, this paper proposes automatic consumption management for prepaid meters that analyzes the consumer appliance behavior, performs the temporal analysis of consumption by appliances, defines the cost management per load with high energy consumption and sends sound signals to the consumer ends the appliance usage. The objective of this management system is to ensure that the credit will be used for the consumer expected time.**

***Index Terms*— cognitive meter, electric consumption management, pre-paid electric meter, smart metering system.**

I. Introdução

DEVIDO à demanda crescente de energia elétrica, existe a necessidade de melhorar a gestão e promover o consumo sustentável [1-3]. Para isso, buscam-se alternativas para aprimorar tanto o sistema elétrico quanto oferecer novos recursos que promovam a eficiência energética.

Neste contexto, foi desenvolvida uma nova geração de medidores de energia elétrica dentro do modelo de redes inteligentes [1,4,5], que podem ser utilizados em qualquer ponto do sistema elétrico: na geração, transmissão, distribuição ou no uso final de energia elétrica. Como os pontos de medição necessitam informar dados confiáveis e precisos para a gestão de energia elétrica, os equipamentos modernos de medição são capazes de: armazenar dados e transmiti-los a centrais de controle e monitoramento; integrar-se com os dispositivos elétricos existentes no sistema; realizar procedimentos remotamente; e agregar funções inteligentes [1, 5, 6]. Para isso, tem-se os medidores inteligentes de energia elétrica, que são dispositivos eletrônicos com comunicação bidirecional e medição de energia em quadrantes [2, 7].

No Brasil, mesmo com a evolução dos medidores inteligentes, os consumidores cativos ainda não possuem detalhamento ou opções sobre o faturamento de consumo. A energia elétrica é cobrada atualmente como um sistema pós-pago, em que a cobrança ocorre após o uso. Portanto, visando propor novas alternativas para o consumidor, como também a redução de inadimplências e perdas não técnicas, tem-se a proposta de implantação do sistema de pré-pagamento de energia elétrica. Tal modelo é análogo ao sistema de telefonia pré-paga, porém a regulamentação é recente e estão sendo abertas consultas com empresas e com a população para entender a demanda e recursos para essa nova opção.

Como motivação à implantação dessa nova tecnologia, destaca-se a redução de perdas não técnicas, provenientes sobretudo de furto. Por exemplo, houve em 2015 cerca de 5% de perdas não técnicas de energia elétrica, equivalente a uma perda de R$ 8 bilhões. Ainda, no mesmo ano, houve o percentual de inadimplência e não pagamento de 1,74%, correspondente a uma perda de aproximadamente R$ 3 bilhões [8]. Portanto, com a implantação de novas tecnologias e soluções, pode-se buscar meios para a redução das perdas, bem como os custos operacionais provenientes de faturas por estimativa, de cobrança por inadimplência e cortes indevidos.

Embora o modelo atual de medidor pré-pago seja eficiente, não é o ideal para alguns consumidores, sobretudo àqueles com baixa renda, pois o consumidor pode estar desprevenido financeiramente no momento em que o valor creditado acabar, ainda mais se os créditos acabarem antes do tempo previsto pelo consumidor. Desta maneira, é necessária a existência de um sistema gerenciador que permita ao consumidor estar ciente do consumo como também possibilitar restrições de uso, para que o crédito realizado pelo consumidor do sistema pré-pago atinja a expectativa de dias.

Desta forma, este artigo apresenta um sistema pré-pago que integra técnicas de desagregação de cargas com a estimação de uso de energia, de acordo com o perfil do consumidor ou da classe social. Caso o consumidor adote o gerenciamento do consumo para que o crédito dure por um determinado período, a estimação permite a restrição do consumo diário de cada carga (eletrodoméstico). Desta forma, não haverá interrupção da energia de forma inesperada ou antes da expectativa.

Como desenvolvimento do trabalho, a seção II apresenta o uso do sistema pré-pago em diversos países, as vantagens e métodos. A seção III apresenta a metodologia implementada neste trabalho. A seção IV apresenta os resultados deste sistema e a seção V apresenta as conclusões.

W. A. Souza and L. C. Pereira da Silva are with the State University of Campinas, Campinas, São Paulo, Brazil, {wesley,lui}@dsee.fee.unicamp.br.

A. C. Moreira is with the Federal University of São João Del-Rei, Ouro Branco, Minas Gerais, Brazil, amoreira@gmail.com

F. D. Garcia and F. P. Marafão are with the Univ Estadual Paulista, Campus Sorocaba, São Paulo, Brazil, fmarafao@sorocaba.unesp.br

II. O SISTEMA PRÉ-PAGO

A. *Sistema Pré-pago no mundo*

O modelo de negócios visado pelas concessionárias de energia elétrica ao redor do mundo envolve os tipos de pagamento pós-pago e pré-pago. A diferença entre os dois está no modo de pagamento que pode ser efetuado o pagamento previamente (pré-pago) ou após o uso do serviço (pós-pago). No caso do sistema pré-pago, se o crédito estiver esgotado, o fornecimento da energia elétrica é interrompido, geralmente pela atuação de um relé.

Historicamente o sistema pré-pago de energia não é uma novidade. No Reino Unido, tal sistema já existe desde a década de 1970 [9], com medidores eletromecânicos pré-pagos creditados por moedas e eram utilizados, sobretudo, em acomodações alugadas de baixo custo. Porém, com novos países aderindo a este sistema, os propósitos começaram a se distinguir e ficar característico, de acordo com a situação econômica, social ou emergente em cada país.

Com base nos dados levantados em [9, 10], as Tabelas I, II e III apresentam as principais motivações, os públicos-alvo e as tecnologias existentes ao redor do mundo. Os tipos de tecnologias de medidores são apresentados na Figura 1.

De acordo com as Tabelas I, II e III, observa-se que nos países desenvolvidos o objetivo principal é oferecer às famílias pobres opções e treinamentos para melhorar a gestão de consumo de energia elétrica, evitando assim que a conta a ser paga seja alta como também minimizar inadimplências e atrasos com o pagamento [11-15].

Já nos países subdesenvolvidos e em desenvolvimento, o principal objetivo é atender a demanda de energia elétricas em áreas de difícil acesso, sobretudo áreas rurais, além de oferecer alternativas para redução de fraudes e roubos de energia elétrica [13-15].

Em comum entre países desenvolvidos, subdesenvolvidos e em desenvolvimento está o foco em aumentar a eficiência da concessionária de energia elétrica, reduzir custos operacionais e perdas comerciais. Outra semelhança é em relação ao público alvo, que são pessoas que geralmente são de baixa renda ou habitam regiões de difícil acesso.

Mas essa não é uma regra, na Irlanda do Norte há uma alta penetração dos medidores pré-pagos entre classes sociais média e alta, sendo que cerca de 41% dos clientes são residenciais [16]. Na Holanda, as concessionárias estão atraindo os clientes de alta renda para utilização do medidor pré-pago com a justificativa de auxiliar na conscientização do consumo de energia elétrica e também promover o uso de um cartão portátil, do tipo "*pay as you go*", para ser usado onde o consumidor desejar [9, 16].

Outro ponto em comum entre os países é a modernização da infraestrutura de medição de energia elétrica. Os medidores pré-pagos possuem a comunicação bidirecional, remetendo a interação entre a concessionária e o ponto de consumo, permitindo a conscientização sobre a energia elétrica e o aumento da eficiência do sistema [9, 10, 17, 18].

A mudança de comportamento do sistema elétrico representa o agrupamento de variáveis quantitativas (como as econômicas, logísticas ou de controle) e qualitativas (decorrentes das relações com a sociedade e inclusão de aspectos voltados à consciência de consumo) [9, 18]. Estudos sobre o comportamento do consumidor diante de informações dinâmicas de consumo e preços usando sistemas de pré-

TABELA I
MOTIVAÇÃO PARA A IMPLANTAÇÃO DO MEDIDOR PRÉ-PAGO

Motivação	Países
Expandir a área de fornecimento de energia elétrica e diminuir o número de consumidores sem medidor	África do Sul, Austrália, Colômbia, Índia, Moçambique e Peru
Reduzir as perdas (técnicas e não técnicas), fraudes e roubos de energia elétrica	África do Sul, Angola, Bangladesh, Colômbia, Gana, Índia, Moçambique, Nigéria, Peru, Reino Unido e Uganda
Reorganização do setor elétrico	Angola, Etiópia, Nigéria e Uganda
Garantia do pagamento pelo serviço utilizado	Austrália, Irlanda, Holanda, Nova Zelândia e Reino Unido
Reduzir atrasos de pagamento	África do Sul, Angola, Gana, Moçambique e Uganda
Reduzir inadimplências	Argentina, Austrália, Estados Unidos, Holanda, Irlanda, Nova Zelândia e Reino Unido
Reduzir custos com desconexão	Estados Unidos e República Dominicana
Resolver custos e problemas no sistema de medição	Gana, Moçambique e Nigéria
Aprimorar a qualidade do serviço	Etiópia e Peru
Induzir à população a utilizar a energia de maneira mais eficaz	Austrália, Colômbia, Holanda, Irlanda, Nova Zelândia e Reino Unido
Mudança do cenário devido a uma grande crise financeira	Argentina

TABELA II
PÚBLICOS-ALVO PARA A INSTALAÇÃO DO MEDIDOR PRÉ-PAGO

Grupo-alvo	Países
Rural, tribos e em áreas remotas	África do Sul, Argentina, Austrália, Índia, Peru e República Dominicana
Localizado em grandes cidades	Gana
Baixa renda ou de pobreza	África do Sul, Estados Unidos, Nova Zelândia e Peru
População hispânica	Estados Unidos
Consumidores que já tiveram histórico de inadimplência	Colômbia, Estados Unidos, Reino Unido e República Dominicana
Perfis residenciais e comerciais	Gana
Todas as classes	Bangladesh, Etiópia, Holanda, Irlanda, Moçambique, Nigéria e Uganda

TABELA III
TECNOLOGIAS DE MEDIDOR PRÉ-PAGO (FIGURA 1)

Tecnologia	Países
Medidor com *Smartcard* (cartão com chip) **(a)**	África do Sul, Austrália, Bangladesh, Estados Unidos, Etiópia, Peru e Reino Unido
Medidor com cartão magnético **(a)**	Austrália e Reino Unido
Medidor eletrônico com teclado e recarga por ativação de crédito **(b)**	África do Sul, Argentina, Bangladesh, Colômbia, Gana, Índia, Irlanda, Moçambique, Nigéria, Nova Zelândia, Peru, Reino Unido e República Dominicana
Medidor em duas partes (teclado separado do medidor) e recarga por ativação de crédito **(c)**	Argentina, Colômbia, Peru, República Dominicana
Medidor inteligente (*Smart meter)* **(d)**	Estados Unidos e Peru
Medidor com chave eletrônica **(e)**	Reino Unido

a) Medidor com *smartcard* Medidor com cartão magnético b) Medidor com teclado acoplado e exemplo de cartão de recarga c) Medidor de duas partes (teclado separado do medidor) d) Medidor inteligente e) Medidor com chave eletrônica

Fig. 1. Modelos de medidores com sistema de pré-pagamento.

pagamento concluíram que a resposta da demanda à variação do preço da eletricidade poderia atingir a redução de 30% em relação a uma situação sem este tipo de informação [17].

Entre as tecnologias de medidores, conforme apresentadas na Figura 1, tem-se:

a) Medidores com *smartcard* / Medidor com cartão magnético: insere-se, neste caso, um cartão com crédito no medidor para que ele forneça energia elétrica. Este cartão pode ser comercializado em pontos autorizados de venda ou pela internet. Os cartões podem ser de um determinado valor de consumo ou podem ser recarregáveis que identificam o usuário e o valor de crédito;

b) e **c) Medidor com teclado / Medidor com teclado separado (em duas partes):** Neste tipo de medidor, o consumidor digita um código no teclado (acoplado no medidor ou em um terminal separado fisicamente do medidor, mas conectado ao medidor) para inserir créditos no medidor. O código alfanumérico é geralmente um código de 16 ou 20 dígitos. Esta tecnologia permite a compra de créditos pela internet e através de pontos autorizados de venda. Este tipo de cartão é semelhante àquele que se utiliza para realizar a carga da telefonia móvel pré-paga;

d) Medidor inteligente: Neste caso, o medidor inteligente possui comunicação bidirecional e deve-se pagar o crédito pelo sistema da concessionária. A concessionária realiza a conexão automática do ponto na rede elétrica e quando o crédito expirar, o sistema da concessionária realiza a desconexão automática, por ação de relés.

e) Medidor com chave eletrônica: Neste caso, há uma chave eletrônica que o consumidor adquire e pode levá-la onde utilizar os serviços de eletricidade, gás e água. Para creditar valor na chave eletrônica, o usuário vai a um ponto autorizado de venda, apresenta a chave e paga o valor a ser creditado. Em 2010, existiam 2,4 milhões de medidores com a tecnologia da chave eletrônica no Reino Unido [19].

Vale destacar que, no Reino Unido, é possível encontrar alguns medidores que recebem créditos por moedas, porém alguns especialistas não consideram este método como um sistema pré-pago por não haver praticidade, pois neste método as concessionárias necessitam ir em cada medidor para coletar as moedas depositadas [9]. No mundo, tem-se vantagens no uso do medidor pré-pago conforme apresentada na Tabela I. No sistema de pré-pagamento, o consumidor é o gerenciador do próprio consumo de energia elétrica e as concessionárias reduzem o custo operacional, diminuem as taxas de perdas, diminuem a lista de inadimplência, entre outros.

B. Sistema Pré-pago no Brasil

No Brasil, iniciou-se o uso do sistema pré-pago de forma pontual, no final da década de 2000, em algumas localizações nos estados do Amazonas e no Pará, onde foram instalados medidores pré-pagos para permitir o acesso à energia em comunidades isoladas e de difícil acesso [20,21].

Para amplo uso, em 2014 houve a publicação da resolução nº 610/2014 que regulamenta o serviço de pré-pagamento através de medidores eletrônicos. A resolução é exclusiva para unidades do grupo B (baixa tensão) e tem como objetivo de ampliar o oferecimento do serviço de energia elétrica para qualquer público-alvo, podendo ser pessoas que moram em áreas remotas, zonas rurais, zonas urbanas residenciais, comerciais e industriais. O consumidor poderá opcionalmente e gratuitamente aderir ao sistema e poderá voltar ao sistema pós-pago a qualquer momento, e a concessionária tem 30 dias para readaptar o ponto de medição. O consumidor poderá realizar a compra de créditos a partir de 20kWh e também existirá o crédito emergencial, que corresponde a um valor extra que mantém o fornecimento de energia para que o consumidor possa comprar a recarga sem transtorno.

Em 2017, a ANEEL abriu a consulta pública nº 16/2017 entre o mês de dezembro de 2017 a março de 2018, formulando um questionário com os seguintes itens:

- A opção de faturamento pré-pago deve ou não existir;
- Há vantagem ou desvantagem para o sistema pré-pago em:
  - Não haver leitura manual do consumo;
  - Não haver impressão da fatura;
  - Não haver entrega da conta da fatura;
  - Instalação de um novo medidor;
  - Corte e religamento automático de energia;
  - Custos administrativos do sistema para a aquisição de créditos;
  - Redução do furto e fraude da energia elétrica;
  - Não pagamento, inadimplência e juros;
  - Maior controle da energia elétrica;
  - Pagamento adiantado do consumo.
- O pré-pagamento deve ser opcional ou obrigatório para as distribuidoras e se a adesão ao sistema pré-pago deve ser opcional ou obrigatória ao consumidor;
- O pré-pagamento deve ser oferecido a todos os consumidores, sendo aqueles que atendam critérios da ANEEL ou que atendam os critérios da distribuidora;
- Quais seriam os critérios técnicos, econômicos, geográficos para seleção dos consumidores;
- Os requisitos do sistema devem ser flexibilizados. Se sim, quais serão as alternativas dos requisitos do sistema do

medidor (tele medição, corte e religamento ou outros). Ainda, se sim, quais serão as alternativas dos requisitos tecnológicos de *software* (aplicativo para celular, agência virtual ou outros);

- Se existe algum critério restritivo técnico ou econômico que deve ser explicitado no regulamento;
- Se a concessionária pode condicionar a adesão ao consumidor ao pré-pagamento para a quitação de débitos pendentes.

Portanto, busca-se no Brasil expectativas do público frente à real aplicabilidade do sistema de pré-pagamento, quais serão os benefícios, o público alvo, os custos e as especificações de *hardware* e *software*.

Como o pré-pagamento é algo que está começando a ser consolidado no Brasil, há tendência às novas implementações. Com as novas gerações de medidores inteligentes, é possível a sua adaptação ao sistema de pré-pagamento. Os medidores cognitivos [2,22-25] são evoluções dos medidores inteligentes, apresentando funções e comportamentos inteligentes, tais como: desagregação de cargas e estratégias para a economia de energia [24,25]. Este tipo de medidor é uma interessante abordagem para o sistema de pré-pagamento, sobretudo na maximização da duração dos créditos efetuados. Com base nesta proposição, que é a contribuição principal deste artigo, a seção III apresenta a metodologia proposta neste artigo.

III. Sistema de Gerenciamento Automático de Medidores Pré-pagos

A desagregação de cargas corresponde ao processo de reconhecimento do uso de uma carga em um determinado período [26]. Assim, é possível estipular o consumo de energia e o estado de funcionamento para cada carga, também é possível analisar o comportamento, fornecer o controle e monitoramento [27]. Desta forma, estão sendo desenvolvidas novas propostas de desagregação de cargas [1,6,7,24,28], que podem ser classificadas de três maneiras:

- **NILM**: do inglês *Nonintrusive Load Monitoring*, chamada de técnica não intrusiva ou concentrada. Esta metodologia possui um único medidor alocado no ponto de entrada de energia na residência (Ponto de Acoplamento Comum). Como existe um único ponto de medição, há a análise por algoritmos de características para a identificação das cargas que consumiram energia elétrica. São encontradas na literatura técnicas de análise macroscópica (extração de características pela assinatura de potência) [28-30] e microscópica (extração de características pela análise das formas de onda de tensão e corrente) [24].
- **ILM**: do inglês *Intrusive Load Monitoring*, chamada de técnica intrusiva ou distribuída. Esta metodologia possui diversos pontos de medição distribuídos, sendo cada ponto exclusivo para uma única carga. A desagregação é feita por *hardware* utilizando sensores individuais, diferente da técnica concentrada em que a desagregação é realizada por *software* (algoritmos de desagregação) [31]. Por ser feito o monitoramento por equipamento, o método possui maior precisão e permite interação (criar regras de automação, conexão, desconexão das cargas);
- **sILM**: do inglês *Semi-Intrusive Load Monitoring*, chamada de técnica semi-intrusiva ou parcialmente distribuída, é equivalente com uma versão intermediária entre as técnicas concentrada e distribuída. A sILM consiste na medição por circuitos ou grupos de cargas (exemplo: um cômodo de uma residência). Neste caso, a desagregação é feita por software, mas a desagregação será feita em cada medição de circuito, permitindo com que os erros no processo de classificação diminuam.

Entre as três técnicas apresentadas, tem-se a NILM como promissora para implantação nos medidores das residências. Desta forma, será necessária a troca dos medidores elétricos atuais para esta nova geração de medidores com desagregação de cargas. Para o sistema de pré-pagamento, o medidor com NILM poderia apresentar vantagens na gestão do consumo e na expectativa de economia para o consumidor.

Para este projeto, tem-se adaptação da implementação do sistema de desagregação proposto por Souza em [24], apresentado na Figura 2. Neste sistema, há a extração microscópica de dados (ou seja, pela análise das formas de onda de tensão e corrente) e, junto com a assinatura de potência, é

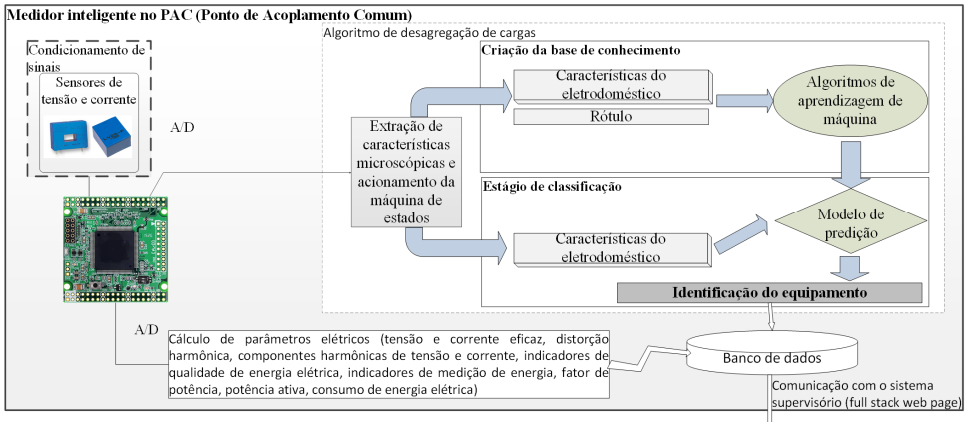

Fig. 2. Arquitetura do medidor cognitivo proposto em [24].

feita a detecção de cargas por algoritmos de máquina de estados e de reconhecimento de padrões.

No caso da arquitetura do medidor cognitivo apresentada na Figura 2, há a aquisição de sinais, a análise da assinatura de potência em conjunto com o armazenamento de: indicadores de consumo, de qualidade da energia elétrica, de continuidade e do consumo integrado). Quando há um evento de carga ligada, carga desligada ou mudança de nível de potência da carga, há a detecção de rampa, as características das formas de onda são extraídas para o novo evento e são enviadas ao algoritmo de reconhecimento de padrões. Em [24] com as características e o conjunto de dados criado, o algoritmo de aprendizagem de máquina que obteve maior exatidão foi o KNN (*k-nearest neighbor*) [24,32].

Após o reconhecimento de carga, dados referentes à carga são armazenados em um banco de dados. Estes dados contém a identificação da carga, a potência média da carga, o horário de início do ciclo de funcionamento, o horário de fim do funcionamento e o tipo de carga (potência constante, variável, múltiplos estágios). Tais dados são armazenados no sistema embarcado do medidor criado em [24], mas podem ser enviados à nuvem ou para um servidor local. Para visualização de informações, há um sistema supervisório, no qual o consumidor pode realizar as seguintes ações: verificar as cargas que consumiram energia em diversos períodos (diário, semanal, mensal, semestral), previsão de consumo no mês, seguir sugestões para economia de energia elétrica, confrontar os indicadores de continuidade do fornecimento, entre outros.

No contexto do sistema de pré-pagamento de energia elétrica, a arquitetura do medidor se manteve, porém foi adicionado um dispositivo sonoro, como o apresentado na Figura 3. A função do dispositivo sonoro é avisar ao consumidor que é momento de desligar a carga que está utilizando. Também foram adaptadas técnicas para o gerenciamento de consumo de acordo com a flexibilidade, ou seja, o consumidor pode ser induzido a reduzir o consumo de algumas cargas (por exemplo, o tempo de uso do chuveiro) para buscar a redução do consumo de energia elétrica.

O sistema de gestão que está sendo proposto neste trabalho tem a necessidade de conhecer previamente o padrão de consumo desagregado de energia elétrica do consumidor ou da região. Portanto, há a aprendizagem comportamental de uso de eletrodomésticos do consumidor para que o sistema possa gerenciar o consumo e restringir conforme a necessidade configurada pelo consumidor. Essa etapa é importante para indicar quais são as cargas que permitem a flexibilidade ou redução de uso. Esta análise tem como objetivo:

- Separar as cargas que não permitem a flexibilidade, como a geladeira, que possui ciclos ao decorrer do dia e se for desligada pode estragar os alimentos do consumidor.
- Identificar as cargas que não permitem flexibilidade por ser pouco utilizada ou que necessita funcionar durante um tempo pré-estabelecido ou definido para realizar uma tarefa, como o micro-ondas e a máquina de lavar roupas.
- Identificar as cargas responsáveis por uma grande parcela de consumo ou por uso frequente. São exemplo destas cargas o chuveiro, o ar condicionado e o ferro de passar roupas. Estas são as cargas de interesse que o sistema indica para a redução de uso para alcançar o objetivo de consumo, tanto na redução de consumo quanto na duração de créditos, de acordo com a expectativa do consumidor.

Fig. 3. Dispositivo emissor de som sem fio D-Link DHC-S220.

Após conhecer o comportamento do consumidor, o sistema pré-pago fica disponível. Há uma interface na qual o consumidor coloca crédito e a expectativa de duração, junto com a ciência de que o sistema será intrusivo e emitirá sons para policiar o consumidor no uso ponderado de seus equipamentos. Após isso, o sistema fica responsável em verificar a factibilidade do consumo cadenciado, de acordo com a expectativa, e ajudar o consumidor a reduzir o consumo. Através do comportamento levantado de consumo, o sistema analisa o histórico, quais cargas que poderão sofrer a redução de uso e estabelece a redução de uso das cargas.

A seção IV apresenta dois resultados: conforme a análise do comportamento de consumo de uma residência, utilizando o medidor desenvolvido em [24] e; conforme o histórico médio de consumo de uma região, através dos dados do SINPHA (Sistema de Informações de Posses de Eletrodomésticos e Hábitos de Consumo) do Procel (Programa Nacional de Conservação de Energia Elétrica) [33].

IV. Resultados

A. *Caso 1 – Dados coletados de uma residência*

Para este caso, foram coletados o consumo desagregado de uma residência por três meses, no período de abril a junho de 2018. A Tabela IV apresenta os valores da média mensal do consumo na residência separado por equipamentos.

Com os resultados de desagregação da Tabela IV, o sistema consulta, em uma tabela no banco de dados, os equipamentos a serem classificados como "flexível", "parcialmente flexível" e "não flexível", conforme apresenta a Tabela V.

TABELA IV
Consumo Médio Mensal das Cargas na Residência Utilizada como Estudo de Caso

Carga / Eletrodoméstico	Potência Nominal (W)	Consumo no mês (kWh)	Tempo médio de uso por operação (minutos)
Ar condicionado	1200	48,0	77,8
Chuveiro	5500	46,1	9,4
Televisão	120	29,7	111,4
Geladeira	135	28,2	-
Ferro de passar roupas	1300	15,1	48,4
Laptop	40	13,0	490
Forno elétrico	3000	12,1	60,5
Iluminação	4 a 30	9,3	-
Máquina de lavar roupas	400	7,2	240,2
Micro-ondas	1250	5,2	8,05
Outros	-	11,3	-
Consumo total	-	**225,2**	-

As cargas “flexíveis” são aquelas que o sistema faz a programação para a redução de uso. As consideradas “parcialmente flexíveis” são aquelas que podem ser sugerida a redução de consumo, caso o consumidor não esteja respeitando as ordens de redução de uso ou dependendo da política rígida do consumo, de acordo com a expectativa de duração. As cargas “não flexíveis” são aquelas que o sistema não fará a redução. A categoria “outros” não há flexibilidade, pois podem ocorrer erros na detecção junto com a soma de equipamentos que consomem pouca energia elétrica.

De acordo com os três meses, o consumo médio mensal na residência é equivalente a 225,2 kWh, tendo as cargas:

- **Flexíveis**: 133,1 kWh, correspondente a 59,1% do consumo total;
- **Parcialmente flexíveis** e **não flexíveis**: 92,1 kWh, correspondente a 40,9% do consumo total.

O sistema reserva 92,1 kWh como consumos que não poderão ser ajustados. O restante será reajustado para a redução de consumo e alcançar as metas. Para este propósito, foi considerado o valor de crédito de 200 kWh e a expectativa de duração do crédito por 30 dias. Nesta aplicação, o protótipo do medidor está ligado no PAC, mas não está substituindo o medidor convencional. Assim sendo, o sistema solicita que o usuário coloque o código de recarga e a expectativa de uso, conforme a interface apresentada na Figura 4.

Após a verificação do código de recarga, o sistema confirma ao consumidor o valor creditado e oferece a opção ao gerenciamento automático do consumo, de acordo com o tempo de expectativa do usuário, conforme a Figura 5.

Se o consumidor optar pelo gerenciamento, o sistema se adaptará às situações de cargas flexíveis. Esta técnica é simples, pois subtrai-se do crédito o consumo médio das cargas que não possuem flexibilidade. Tem-se 92,1 kWh de consumo das cargas “parcialmente flexíveis” e “não flexíveis”. Assim, o sistema faz a gestão das cargas “flexíveis” dentro do valor remanescente de 107,9 kWh. Em seguida, o sistema coleta do banco de dados do medidor o histórico de uso dos equipamentos na residência e retorna uma tabela com o tempo de uso diário, quantas vezes a carga foi utilizada em média por dia e cria uma tabela com estimativas de redução proporcional ao consumo médio do consumidor. A Tabela VI apresenta as informações que o sistema coleta para o início da gestão e a Tabela VII apresenta o ajuste do sistema para controlar o tempo reduzido de uso das cargas.

Após a criação das regras de redução, o sistema permanece realizando a desagregação e detecta o instante em que a carga foi ligada, iniciando uma espécie de “cronômetro”. Quando o tempo de uso estiver a um minuto do tempo determinado pelo sistema, é enviado um comando para o dispositivo emissor de som, que toca continuamente por cinco segundos, deixando o consumidor ciente de que o tempo de uso do eletrodoméstico está se esgotando. Como se trata de um sistema não intrusivo, dá-se ao consumidor a opção de ignorar o sinal. Para alcançar as metas de duração do crédito, o atendimento ao alerta sonoro é primordial. Neste estudo de caso, foi feito o atendimento ao alerta, havendo uma significativa redução de consumo e a meta de consumo foi atingida, conforme apresenta a conta de energia elétrica da Figura 6.

Portanto, o alerta ajudou o consumidor a alcançar o objetivo de consumo abaixo de 200 kWh dentro do tempo esperado. A Tabela VIII apresenta o consumo desagregado no mês.

Houve redução maior do que a meta estabelecida por razões climáticas, pois no mês de junho é inverno e o ar condicionado foi pouco utilizado. Mesmo assim, houve a preocupação do consumidor em reduzir os gastos com energia e os valores de

TABELA V
FLEXIBILIDADE DAS CARGAS PARA A REDUÇÃO DE CONSUMO

Carga / Eletrodoméstico	Condição
Ar condicionado	Flexível
Chuveiro	Flexível
Televisão	Flexível
Geladeira	Não flexível
Ferro de passar roupas	Parcialmente flexível
Laptop	Parcialmente flexível
Forno elétrico	Não flexível
Iluminação	Flexível
Máquina de lavar roupas	Não flexível
Micro-ondas	Não flexível
Outros	Não flexível

TABELA VI
PLANO DE REDUÇÃO DE CONSUMO DO GERENCIADOR

Carga / Eletrodoméstico	Uso médio diário	Consumo Atual	Meta de consumo
Ar condicionado	0,6	48,0	36,0
Chuveiro	1,8	46,1	34,6
Televisão	4,3	29,7	22,3
Iluminação	35,4	9,3	7,0
Cargas não flexíveis	-	92,1	92,1
Total do consumo	-	225,2	200,0

TABELA VII
PLANO DE REDUÇÃO DE TEMPO DE USO DE CARGAS

Carga / Eletrodoméstico	Tempo de uso por operação atual (minutos)	Tempo de uso por operação ajustado (minutos)
Ar condicionado	77,8	58,0
Chuveiro	9,4	7,0
Televisão	111,4	83,5
Iluminação	-	-

Fig. 4. Interface para a inserção de créditos e de expectativa de duração.

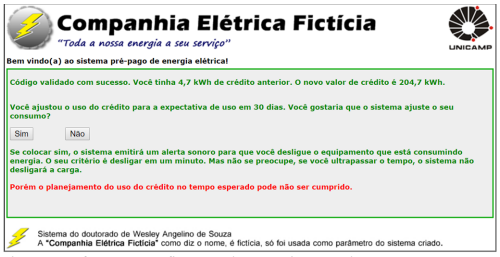

Fig. 5. Interface para confirmação do gerenciamento do consumo.

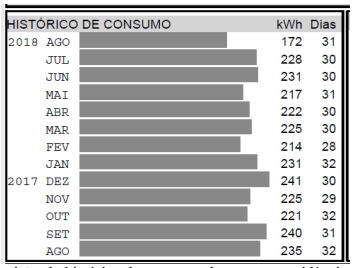

Fig. 6. Descrição do histórico de consumo da conta na residência.

TABELA VIII
CONSUMO MÉDIO MENSAL DAS CARGAS NA RESIDÊNCIA APÓS O MÊS DE TESTES DO SISTEMA GERENCIADOR DE CONSUMO

Carga / Eletrodoméstico	Consumo no mês (kWh)	Tempo médio de uso por operação (minutos)
Ar condicionado	14,2	53,8
Chuveiro	33,7	7,3
Televisão	22,7	103,4
Geladeira	25,9	-
Ferro de passar roupas	13,7	43,8
Laptop	15,0	450
Forno elétrico	5,7	63,3
Iluminação	10,9	-
Máquina de lavar roupas	8,7	230,1
Micro-ondas	3,7	6,0
Outros	17,9	-
Consumo total	172,2	-

uso definidos como meta ficaram próximos ao consumo na residência. A seguir serão apresentados resultados para o perfil de curva de carga da região. Portanto, os dados de consumo desagregados não foram coletados pelo medidor de energia e tampouco utilizado o comportamento padrão do consumidor.

B. Caso 2 - Dados com base na curva de carga da região

No ano de 2005, o Procel fez um levantamento da curva de carga no país (SINPHA) [33], dividido por regiões. Por ser um estudo feito em 2005, os dados de cargas tendem a não ser equivalente às cargas atuais, pois os eletrodomésticos foram aperfeiçoados, alguns substituídos ou inutilizados desde 2005. A Figura 7 apresenta a curva de cargas do SINPHA para a região Sudeste e a Tabela IX apresenta o consumo, de acordo com dados do SINPHA [33] e do governo federal [34].

Se considerar o consumo médio da residência nos três meses anteriores (225,3 kWh), o consumo desagregado seria de acordo com a Tabela X. A Tabela X também apresenta a meta de consumo. As cargas "Som" e "Freezer", por não existirem na residência, são classificadas como "outros", portanto considerada como carga "não flexível". Assim, tem-se 32,9% (74,05 kWh) de consumo de cargas "não flexíveis", restando 125,95 kWh para as cargas "flexíveis".

Após a criação da estimativa, o sistema estabelece o tempo de uso das cargas de acordo com a alimentação de dados do consumidor, da análise socioeconômica e das estações do ano (por exemplo, o uso do ar condicionado é maior no verão).

Na residência do estudo de caso, tem-se dois moradores, ar condicionado, não há freezer, o mês é de inverno e as duas pessoas passam período integral fora da residência. Desta forma, é feito um cronograma de uso para atingir as metas, seguindo as potências nominais das cargas na residência, conforme apresenta a Tabela XI. Tomando como referência o consumo da residência em estudo no mês de agosto, as metas foram alcançadas, conforme apresenta a Tabela XII.

O consumo com ar condicionado, chuveiro e iluminação foi menor, mas o consumo com televisão e cargas não flexíveis foi maior. Desta maneira, o sistema permite a aproximação da meta quando se utilizam valores médios das curvas de carga, porém

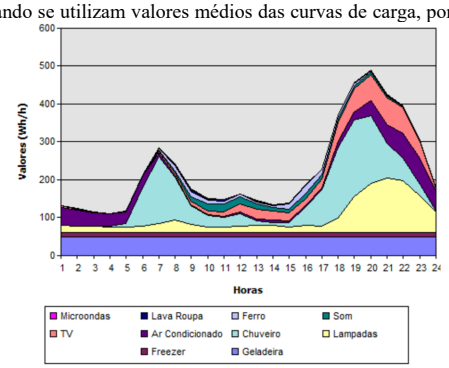

Fig. 7. Curva de cargas na região Sudeste, em 2005, SINPHA [33].

TABELA IX
CONSUMO MENSAL DAS CARGAS CONFORME O SINPHA [33,34]

Carga / Eletrodoméstico	Condição	Consumo (%)
Chuveiro	Flexível	27,5%
Geladeira	Não flexível	22,2%
Lâmpadas (Iluminação)	Flexível	20,7%
Ar condicionado	Flexível	11,1%
Televisor	Flexível	7,8%
Freezer	Não flexível	4,8%
Ferro de passar roupas	Parcialmente flexível	2,9%
Som	Não flexível	2,2%
Máquina de lavar roupas	Não flexível	0,6%
Micro-ondas	Não flexível	0,2%

TABELA X
METAS DE CONSUMO POR CARGAS

Carga / Eletrodoméstico	Consumo "atual" (kWh)	Meta de consumo (kWh)
Chuveiro	62,1	51,7
Lâmpadas (Iluminação)	46,6	38,8
Ar condicionado	25,0	20,8
Televisor	17,6	14,7
"Não flexíveis"	74,0	74,0
Consumo total	225,3	200,0

TABELA XI
METAS DE CONSUMO E TEMPO DE USO POR CARGAS

Carga / Eletrodoméstico	Potência nominal (W)	Uso médio diário	Meta de consumo (kWh)	Tempo de uso (min)
Chuveiro	5500	2,00	51,7	9,4
Lâmpadas	-	-	38,8	-
Ar condicionado	1200	0,33	20,8	104
Televisor	120	1,50	14,7	163,3

TABELA XII
META DE CONSUMO E CONSUMO MENSAL NA RESIDÊNCIA

Carga / Eletrodoméstico	Consumo no mês (kWh)	Meta de Consumo (kWh)	Expectativa
Ar condicionado	14,2	20,8	Atingida
Chuveiro	33,7	51,7	Atingida
		14,7	Não
Televisão	22,7		atingida
Iluminação	10,9	38,8	Atingida
Não flexíveis	90,7	74,0	-
Consumo total	172,2	200,0	Atingida

não garante a expectativa. Portanto, o ideal é conhecer previamente o consumo do consumidor ou uma análise atualizada do consumo das cargas da região.

V. Conclusão

Este artigo mostrou um estudo sobre a tecnologia de medidores de energia elétrica com o sistema de pré-pagamento no mundo, bem como os motivos da adoção, as classes de interesse e as tecnologias utilizadas. No Brasil, o sistema de pré-pagamento de energia começou a ser regulamentado e analisadas futuras aplicações e tecnologias.

Frente a esta nova opção, o artigo apresentou uma nova técnica para a gestão de consumo baseada na desagregação não intrusiva de cargas. O gerenciador recebe do consumidor o valor creditado e a expectativa de duração do crédito. O gerenciador obtém informações de histórico de consumo, analisa as cargas que permitem a flexibilidade da redução de uso e determina o tempo máximo de uso para cada carga flexível. Quando o tempo de uso está próximo ao limite, um sinal é enviado à sirene, que toca por cinco segundos e avisa o consumidor que a carga que está em uso deve ser desligada.

Os resultados em uma residência, utilizando o protótipo do medidor cognitivo de [24] que foi ajustado para este projeto, demonstraram que o sistema alcançou o objetivo, a redução de consumo e a expectativa dos créditos durarem o tempo definido pelo consumidor. Porém, é necessário que o histórico de consumo seja compatível com o consumidor, por isso o primeiro resultado se mostrou factível e atingiu o objetivo, enquanto o segundo resultado atingiu parte do objetivo. A curva de carga do SINPHA, por ser de 2005, pode ser também o motivo deste problema, pois houve uma considerável evolução das cargas residenciais desde o ano de 2005.

Agradecimento

Os autores agradecem a FAPESP (Fundação de Amparo à Pesquisa do Estado de São Paulo, processo 2012/19375-1) e a CPFL (Companhia Paulista de Força e Luz, processo PD ANEEL-0063-3020/2017) pelos recursos destinados ao desenvolvimento desta pesquisa.

Referências

[1] Barai, G. R.; Krishnan, S. and Venkatesh, B. Smart metering and functionalities of smart meters in smart grid - a review. *IEEE Electrical Power and Energy Conference (EPEC)*, pp. 138-145, 2015.

[2] Makonin, S.; Popowich F. and Gill, B. The cognitive power meter: Looking beyond the smart meter. *26th IEEE Canadian Conference on Electrical and Computer Engineering (CCECE)*, pp. 1-5, 2013.

[3] Platt, G.; West, S. and Moore, T. The real-world challenges and opportunities of distributed generation. *IEEE Energy Conversion Congress and Exposition (ECCE)*, pp. 1112-1116, 2015.

[4] Souza, W. A. et al. Power Quality, Smart Meters and Additional Information from Different Power Terms. *IEEE Latin America Transactions*, vol. 13, no. 1, pp. 158-165, 2015.

[5] Zheng, J.; Gao D. W. and Lin, L. Smart Meters in Smart Grid: An Overview. *IEEE Green Technologies Conference (GreenTech)*, Denver, CO, pp. 57-64, 2013.

[6] Opriş, I. and Caracasian, L. On the implementation of the functionalities of smart metering systems. *8th International Symposium on Advanced Topics in Electrical Engineering (ATEE)*, Bucharest, pp. 1-6, 2013.

[7] Opriş, I. and Caracasian, L. The relation between smart meters and electricity consumers. *12th International Conference on Environment and Electrical Engineering*, Wroclaw, pp. 325-329, 2013.

[8] Instituto Acende Brasil. Perdas Comerciais e Inadimplência no Setor Elétrico. *White Paper 18*, São Paulo, 40 p. 2017.

[9] Esteves, G. R. T. et al. An overview of electricity prepayment experiences and the Brazilian new regulatory framework. *Renewable and Sustainable Energy Reviews*, vol 54, pp. 704-722, 2016.

[10] Kambule, N.; Yessoufou, K.; Nwulu, N. A review and identification of persistent and emerging prepaid electricity meter trends. *Energy for Sustainable Development*, vol 43, pp. 173-185, 2018.

[11] Tewari, D. D.; Shah, T. An assessment of South African prepaid electricity experiment, lessons learned, and their policy implications for developing countries. *Energy Policy*, vol 31, pp. 911-927, 2003.

[12] Gaunt, C. T. Electricity distribution industry restructuring in South Africa: A case study. *Energy Policy*, vol 36, pp. 3448-3459, 2008.

[13] Baptista, I. We Live on Estimates': Everyday Practices of Prepaid Electricity and the Urban Condition in Maputo, Mozambique. *Int. Journal of Urban and Regional Research*, vol 39, pp. 1004-1019, 2015.

[14] Darby, S. J. Metering: EU policy and implications for fuel poor households. *Energy Policy*, vol 49, pp. 98-106, 2012.

[15] Deloitee. Evolving measures for the effective implementation of Prepaid Metering in the country. *Report to 'Forum of Regulators' on Pre-paid Meter*, pages 96, 2011.

[16] Gans, W.; Alberini, A.; Longo A. Smart meter devices and the effect of feedback on residential electricity consumption: Evidence from a natural experiment in Northern Ireland. *Energy Economics*, pp. 729-743, 2013.

[17] Chinomona, R.; Sandada, M. Customers' Perceptions on ESKOM's Pre-Paid Billing System and the Effects on Their Satisfaction and Trust. *Mediterranean Journal of Social Sciences*, vol 5, pp. 119, 2014.

[18] Never, B. Social norms, trust and control of power theft in Uganda: Does bulk metering work for MSEs? *Energy Policy*, vol 82, pp. 197-206, 2015.

[19] Owen, G.; Ward, J. Smart pre-payment in Great Britain. *Sustainability first*, p 38, 2010.

[20] ANEEL, Resolução Autorizativa nº 2150 de 4 de novembro de 2009, *Agência Nacional de Energia Elétrica*, 2009.

[21] ANEEL, Resolução Autorizativa nº 1822 de 3 de março de 2009, *Agência Nacional de Energia Elétrica*, 2009.

[22] Garcia, F. D. Medidor cognitivo de energia para aplicações em eficiência energética. *Dissertação de Mestrado*, FEB/UNESP, 2018

[23] Paes, F. L. et al. Arquitetura do Medidor Cognitivo de Energia. *Revista Brasileira de Energias Renováveis*. Vol 7, n.2, pp. 189-198, 2018.

[24] Souza, W. A. Estudos de Técnicas de Análise e Tecnologias para o Desenvolvimento de Medidores Inteligentes de Energia Residenciais. *Tese de Doutorado*. UNICAMP. Campinas, São Paulo. 2016.

[25] Garcia F. D. et al. Power Metering: History and Future Trends. *Ninth Annual IEEE Green Technologies Conference (GreenTech)*, Denver, CO, pp. 26-33, 2017.

[26] Rathmair, M. and Haase, J. Load identification and management framework for private households. *39th Annual Conference of the IEEE Industrial Electronics Society (IECON)*, Vienna, pp. 5729-5734, 2013.

[27] Abubakar, I. et al. Application of load monitoring in appliances' energy management – A review. *Renewable and Sustainable Energy Reviews*, vol 67, pp. 235-245, 2017.

[28] Dong, M. et al. An Event Window Based Load Monitoring Technique for Smart Meters. *IEEE Transactions on Smart Grid*, pp. 787-796, 2012.

[29] Fernandes, R. A. S.; da Silva, I. and Oleskovicz, M. Load Profile Identification Interface for Consumer Online Monitoring Purposes in Smart Grids. *IEEE Transactions on Industrial Informatics*, vol. 9, no. 3, pp.1507-1517, 2013.

[30] Huang, T. D.; Wang, W. S. and Lian, K. L. A New Power Signature for Nonintrusive Appliance Load Monitoring. *IEEE Transactions on in Smart Grid*, vol.6, no.4, pp.1994-1995, 2015.

[31] Ridi, A.; Gisler C. and Hennebert, J. A Survey on Intrusive Load Monitoring for Appliance Recognition. *22nd International Conference on Pattern Recognition*, Stockholm, pp. 3702-3707, 2014.

[32] Souza, W. A. et al. A NILM dataset for cognitive meters based on conservative power theory and pattern recognition techniques. *Journal of Control, Automation and Electrical Systems*, pp.1-14, 2018.

[33] Procel Info, Sistema de Informações de Posses de Eletrodomésticos e Hábitos de Consumo. *Centro Brasileiro de Informação de Eficiência Energética,* 2005. Acessado em 25/07/2018. Disponível em < http://www.procelinfo.com.br/Sinpha/Home.asp>.

[34] Brasil. Avaliação do Mercado de Eficiência Energética no Brasil. *Pesquisa de Posse de Equipamentos e hábitos de consumo.* Ano base 2005. Classe Residencial. Governo Federal, 2007.

12 Anexo II – Artigos publicados em congressos ou eventos no período de pós-doutorado

COMPARAÇÃO DAS TÉCNICAS DE MONITORAMENTO DE CARGAS PARA A DESAGREGAÇÃO DO CONSUMO DE ENERGIA ELÉTRICA

Hader Aguiar Dias Azzini*, João Guilherme Ito Cypriano*, Wesley Angelino de Souza*, Rafael Cuerda Monzani*, Luiz Carlos Pereira da Silva*, Augusto Chierice Venerando da Silva†

*Departamento de Sistemas e Energia - FEEC - UNICAMP
Av. Albert Einstein, 400, Barão Geraldo, Campinas, SP, Brasil

†Companhia Paulista de Força e Luz - CPFL
Campinas, SP, Brasil

Emails: hader@dsee.fee.unicamp.br, joao.ito@dsee.fee.unicamp.br, wesley@dsee.fee.unicamp.br, rcmonzani@gmail.com, lui@dsee.fee.unicamp.br, augustov@cpfl.com.br

Abstract— This study compares, analyses and validates three major Appliance Load Monitoring (ALM) approaches, their benefits and the difficulties encountered in the implementation. The Non-Intrusive Load Monitoring (NILM) introduces the use of a single meter per house installed on the Point of Common Coupling (PCC), where the consumption data is collected in aggregate form to perform ALM. The Intrusive Load Monitoring (ILM) uses distributed sensing points per appliance within the entire residence. The third proposal - Semi-Intrusive Load Monitoring (SILM) - is intermediate to the others, with data collection per circuit on the power distribution board. This study also presents advantages, costs, benefits and available technologies about these approaches. However the most adequate and greater potential for use is the NILM, based on individual identification of appliances by software disaggregation.

Keywords— Load Disagreggation, Load Monitoring, Smart Meters, Smart Plug.

Resumo— Este artigo compara e avalia as três abordagens para o monitoramento de cargas mais conhecidas, indicando os benefícios e dificuldades encontradas na implementação. O monitoramento não intrusivo (concentrado) indica o uso de um único medidor por residência, instalado no Ponto de Acoplamento Comum (PAC), local onde os dados de consumo coletivo são coletados e depois é realizada a desagregação de cargas. O monitoramento intrusivo (distribuído) usa pontos de sensoriamento por cada eletrodoméstico instalado na residência. A terceira proposta - monitoramento semi intrusivo (parcialmente distribuído) - é intermediária às duas anteriores, com os dados sendo coletados por cada circuito, no quadro de distribuição. Este artigo também apresenta vantagens, custos, benefícios e as tecnologias disponíveis no mercado para estas abordagens e é apresentado um exemplo aplicado para cada técnica. Entretanto, a técnica concentrada, baseada na identificação das cargas elétrica por *software*, apresentou-se como a mais adequada e com maior potencial entre as três.

Palavras-chave— Desagregação de cargas, Monitoramento de cargas, Medidor inteligente, Tomada inteligente.

1 Introdução

A energia elétrica é um pilar importante para o desenvolvimento socioeconômico (Barai et al., 2015) (Makonin et al., 2013) (Platt et al., 2015) e a crescente demanda exige o uso cada vez mais otimizado e sustentável (Platt et al., 2015). Para isso, intensifica-se a necessidade de detalhar o uso da energia para suportar alternativas que permitam a eficiência energética.

Neste contexto, surgem os medidores de energia elétrica como elementos importantes para o modelo de redes inteligentes (Barai et al., 2015) (de Souza et al., 2015) (Zheng et al., 2013), sendo utilizados em qualquer ponto do sistema, seja na geração, transmissão, distribuição ou no uso final de energia elétrica. Como estes pontos de medição necessitam informar dados confiáveis e precisos, para a gestão de energia elétrica, os equipamentos de medição devem ser capazes de: armazenar dados e transmiti-los a centrais de controle e monitoramento; integrar-se com os dispositivos elétricos existentes no sistema; realizar procedimentos remotamente; e permitir a implantação de "inteligência" no mesmo (Barai et al., 2015) (Zheng et al., 2013) (Opris and Caracasian, 2013b).

Assim, tem-se os medidores inteligentes de energia elétrica, que são dispositivos eletrônicos com comunicação bidirecional e medição de energia em quadrantes (Makonin et al., 2013) (Opris and Caracasian, 2013a). Lembrando que este conceito é aceito, pois não há um consenso sobre as características essenciais que o medidor deve ter devido ao termo "inteligente".

Desta forma, estão surgindo novas propostas com o intuito de ampliar o uso do termo inteligente nessa classe de medidores e uma das propostas que mais se destaca é o monitoramento do consumo por cargas (eletrodomésticos) (Opris and Caracasian, 2013b) (Makonin et al., 2013) (Opris and Caracasian, 2013a) (Basu et al., 2015) (Dong et al., 2012) (Hart, 1992) (Garcia et al., 2017), que corresponde a um processo de identificação e aquisição da medição elétrica de uma carga em um sistema de energia em um certo período de tempo(Rathmair and Haase, 2013), estipulando o consumo de energia e o estado de funcionamento de cada equipamento, promovendo a compreensão do comportamento, manutenção, controle e monitoramento (Abubakar et al., 2017).

Existem três principais metodologias de desagregação do consumo: a técnica de monitoramento não-intrusiva ou concentrada; a técnica de monitoramento intrusivo ou distribuído e; a técnica de monitoramento semi-intrusivo ou parcialmente distribuído.

A técnica de monitoramento concentrado envolve um único medidor alocado no Ponto de Acoplamento Comum (PAC), nas residenciais é o ponto de entrada de energia do consumidor. Desta forma, através da análise do consumo total, das

formas de onda da tensão e corrente e da identificação da assinatura de potência característica para cada carga, é possível implementar algoritmos embarcados no medidor para realizar a desagregação do consumo elétrico por equipamento e também implementar outras funções (e.g. identificação de faltas e perdas não técnicas) (Opris and Caracasian, 2013b) (Garcia et al., 2017). O consumo separado por cargas possibilita o desenvolvimento de interfaces amigáveis para o usuário final, que forneça sugestões para a eficiência energética e estratégias de economia de energia, em conjunto com relatórios que permitam o gerenciamento do uso da energia elétrica (Opris and Caracasian, 2013b). Na literatura, a técnica de monitoramento concentrado tem direcionado a novas nomenclaturas de medidores, entre elas os medidores cognitivos (Opris and Caracasian, 2013b) (Durling et al., 2010) (Garcia et al., 2017).

A segunda técnica de monitoramento é a distribuída, isto é, existem diversos pontos de medição distribuído no prédio, sendo cada ponto voltado diretamente a uma única carga. A desagregação ocorre por meio de *hardware* (sensores individuais), diferente da técnica concentrada que se baseia na desagregação por *software*. Deste modo, possui mais precisão e possibilidade de interação com os equipamentos (automação), porém o custo de implantação e manutenção é maior e há a necessidade de tempo para a completa instalação dentro da residência, por essa necessidade esta técnica é amplamente conhecida como "intrusiva".

A última técnica que será abordada é a mescla das duas anteriores, a técnica de monitoramento parcialmente distribuído, que consiste na medição por circuitos ou grupo de cargas (e.g. um cômodo da residência). Por ser intermediária, apresenta a desagregação baseada em *hardware* e *software* integrados e instalação semelhante à do sistema distribuído.

As três técnicas de monitoramento permitem gerar relatórios de detalhamento do consumo por eletrodomésticos, conforme apresenta a Figura 1, através de um sistema supervisório com relatórios de consumo total ou por cargas. Este conceito de desagregação do consumo de energia elétrica indica a tendência da nova geração de monitoramento e medição da energia, podendo assim beneficiar tanto aos consumidores quanto às concessionárias.

Portanto, este artigo apresenta o conceito, tipos e vantagens do monitoramento de cargas. A Seção II destaca os benefícios para consumidores quanto para concessionárias. A Seção III descreve as técnicas de monitoramento de cargas e apresenta um caso de estudo para cada técnica. E por fim, a Seção IV ressalta os principais pontos das abordagens de desagregação de cargas e qual delas apresentou um cenário promissor para a instalação e uso dessa nova tecnologia de medição inteligente.

2 Benefícios da Desagregação de Cargas

Os benefícios da medição inteligente podem, de maneira simples, ser divididos em duas principais categorias (Alahakoon and Yu, 2016): Consumidores e Companhias de Energia Elétrica (setores de geração, transmissão e distribuição). No entanto, faz-se necessário observar e acompanhar os desafios e dificuldades encontradas no desenvolvimento, implantação e manutenção de novos conceitos e tecnologias.

A aceitação pode ser demorada e delicada, pois as pessoas e empresas precisarão antes conhecer os novos dispositivos, compreender os motivos da substituição e as mudanças que ocorrerão para depois aceitá-los e, finalmente, utilizá-los (Barai et al., 2015) (Opris and Caracasian, 2013b) (Depuru et al., 2011). Alguns desafios e inseguranças são listados a seguir:

- Justificar os investimentos;
- Impactos causados na transição das tecnologias;
- Medo de perder a privacidade e com os riscos que isso pode gerar;
- Insegurança em relação ao preço da energia;
- Redução de empregos;
- Segurança das informações.

Apesar destas inseguranças, o sucesso da aplicação dos medidores inteligentes depende da análise e confiabilidade dos dados coletados, permitindo com que os benefícios sejam proporcionais às funcionalidades e ao uso dos medidores. Estas vantagens serão abordadas sob o ponto de vista do consumidor e da concessionária de energia elétrica.

2.1 Benefícios para o Consumidor

Além da decomposição percentual do consumo para cada equipamento, um sistema que contenha a desagregação de cargas permitirá que o consumidor realize a própria gestão do consumo de energia elétrica.

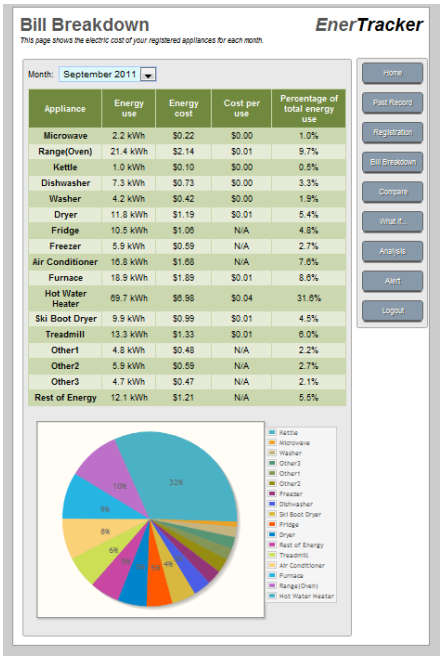

Figura 1: Desagregação do consumo mensal por uso individual de equipamentos (*EnergyTracker*).

Tendo em mãos informações detalhadas, é possível analisar e identificar o perfil de uso de cada equipamento, o padrão de consumo, os gargalos nas instalações, equipamentos obsoletos e/ou com mau uso e o modelo de tarifação de energia elétrica utilizado. Com estas informações, o usuário poderá definir a substituição de equipamentos, mudanças de hábitos de uso, a tarifação mais adequada ao consumo (tarifa branca, como exemplo) e medidas que possam melhorar a eficiência energética da residência.

Uma das características deste sistema é a interconexão da rede a outros medidores, permitindo que os dados coletados possa auxiliar no diagnóstico de eficiência energética de equipamentos, comparando-os com o padrão médio de similares. O acesso à esta informação disponível na base de medição, permite que o sistema indique ao consumidor a classificação de eficiência energética comparada ao padrão médio de consumo do grupo no qual se encontra (por consumo, por região, etc.) e quais as possíveis ações de melhoria (troca de equipamento, alteração nos horários de uso), que este consumidor poderá tomar, de modo a melhorar as características de consumo, em comparação ao grupo de consumo.

Diversas funcionalidades são permitidas quando se utiliza a desagregação de cargas. Por exemplo, na segurança residencial, através do monitoramento da utilização de portões automáticos, ou na saúde das pessoas com dificuldades de comunicação e locomoção, como idosos, que através do acompanhamento do perfil de consumo destes usuários pode-se enviar alarmes em caso de inoperância de determinados equipamentos por tempo prolongado. Desta forma, a possibilidade da gestão e da consciência do uso de energia permitem minimizar os gastos, melhorar a qualidade de vida e garantir sustentabilidade no uso da energia.

A Figura 2 apresenta os percentuais de economia que podem ser atingidos de acordo com o nível de informação fornecida para o consumidor residencial (Garcia et al., 2017) (Armel et al., 2013). É possível perceber que a informação desagregada pode atingir economia de 12% ou mais.

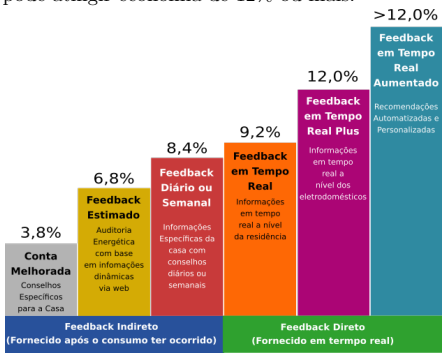

Figura 2: Economia de Energia para o Consumidor Residência devido ao *Feedback* (Fonte: Armel et al. 2013).

2.2 Benefícios para a Concessionária

Para a concessionária, o nível de detalhamento do consumo de energia elétrica poderá trazer diversos benefícios na operação e planejamento da rede elétrica, de forma eficiente.

Um dos benefícios mais perceptíveis é a redução do consumo de energia elétrica no período do pico de demanda, resultando nos seguintes benefícios: redução das perdas técnicas; postergação de investimentos em expansão das redes e da capacidade dos transformadores; melhoria do perfil de tensão; e facilita o controle do sistema. Vale lembrar que a redução do pico de demanda não implica em redução do consumo, e sim no deslocamento do horário de uso do equipamento ao longo do dia. Portanto, o gerenciamento da demanda não implica diretamente em perdas no faturamento para a empresa fornecedora de energia.

Um exemplo da percepção do perfil de consumo diz respeito ao conhecimento da curva de carga dos consumidores. No modelo atual a empresa realiza uma campanha de medição, por amostragem, para compor curvas de cargas típicas para cada classe e subclasse de consumidor. Esta campanha é realizada a cada quatro anos, e mede o consumo a cada 15 minutos pelo período de uma semana. Este pequeno conjunto de curvas amostradas é utilizado para compor curvas típicas que serão usadas para representar qualquer consumidor da concessionária, as quais são atualizadas, na melhor das hipóteses, a cada quatro anos. O resultado disto é um erro significativo nos estudos de planejamento e operação das redes, uma vez que existe erro importante nas curvas de carga e este é incorporado nos cálculos subsequentes de planejamento. Também, a resolução das curvas de carga será elevada, permitindo precisão na análise dos dados e nos modelos a serem adotados para a revisão tarifária, sem a necessidade da campanha de medição realizada a cada quatro anos.

Além da discussão sobre as curvas de carga, é importante também o conhecimento da composição da carga. Ou seja, a concessionária passa a ter o conhecimento dos equipamentos e eletrodomésticos utilizados pelos clientes, bem como sobre o perfil de uso de cada um deles, sem que seja necessário realizar campanhas para levantamento de posse de equipamentos e hábitos de consumo. Este tipo de informação também é exigido pela ANEEL em cada ciclo de revisão tarifária, e também tem um custo elevado, em função da enorme quantidade de consumidores que devem ser entrevistados, sem falar na perda de precisão da informação, pelo fato de ser uma entrevista longa e cansativa para o consumidor.

O conhecimento da composição da carga para um grande número de consumidores permite a realização de mais uma tarefa complexa e importante para a concessionária, que é a modelagem da carga. Este aspecto é fundamental para qualquer estudo de planejamento ou operação, pois realiza cálculos de perdas técnicas, estudos de alocação de capacitores, dimensionamento de redes e transformadores, etc.

Com as vantagens destacadas, serão apresentadas na seção a seguir as três principais abordagens de monitoramento de cargas, bem como casos de estudo em cada abordagem.

3 Técnicas de Monitoramento de Cargas

3.1 Monitoramento Distribuído

A abordagem tradicional para monitoramento detalhado de cargas elétricas é chamada na literatura técnica de monitoramento intrusivo, devido à necessidade da instalação de um sensor em cada ponto de consumo com acesso físico aos equipa-

mentos medidos, consequentemente sendo necessário a entrada no ambiente residencial ou comercial.

Porém, iremos referir ao modelo intrusivo como monitoramento distribuído, por questões de apreciação por parte dos consumidores e sem alterar o conceito real. Portanto, a medição distribuída se baseia na distribuição de um sensor por eletrodoméstico/tomada, conforme demonstra a Figura 3. Os equipamentos (c) são conectados às tomadas inteligentes (b), estas coletam informações de potência e enviam a uma central (a), que apresenta gráficos de consumo por cada tomada inteligente (ID). Depois de efetuadas as medidas, os dados de cada sensor são reunidos e analisados por um *software* que os organiza e os exibe em gráficos e tabelas.

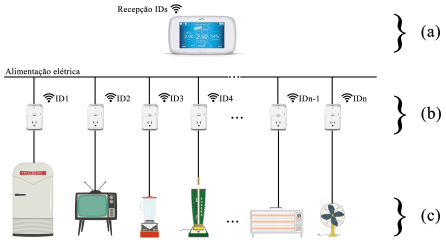

Figura 3: Representação do sistema de monitoramento distribuído.

Este sistema é composto por sensores, comumente conhecidos por tomadas inteligentes, com medição de tensão e corrente e que se comunicam de forma sem fio. Algumas tomadas inteligentes repassam dados para um receptor e concentrador de dados, que tem a função de transmitir os dados para uma base a um servidor dedicado, onde é realizada a análise do consumo. Outras funcionam de forma independente como servidores *web* e cada tomada hospeda um *website* onde exibem o consumo do equipamento monitorado.

No monitoramento distribuído, as tomadas inteligentes devem ser conectadas às tomadas convencionais, sendo os equipamentos,estes conectados na tomada inteligente. Um aspecto interessante deste modelo é que em geral ele inclui um relé interno que possibilita o acionamento remoto, de forma que o equipamento possa ser conectado ou desconectado remotamente, via celular, computador, consumidor ou pela concessionária, conforme modelo de negócio adotado em cada contrato. Esta funcionalidade abre possibilidade para a gestão da demanda para atender objetivos do consumidor ou da concessionária, por exemplo, visando obter redução da demanda no período de pico de consumo, ou para priorizar o consumo em períodos em que a tarifa de energia é mais econômica.

A Figura 4 exibe um quadro comparativo das tomadas inteligentes disponíveis comercialmente, sendo possível observar que, de todos os fabricantes analisados, apenas um modelo se apresenta no padrão brasileiro de tomadas, porém com um custo de aquisição superior aos demais modelos. Mesmo assim, para a aplicação de tomadas inteligentes para desagregação do consumo, o custo médio de cada aparelho se torna um alto investimento e que, muitas vezes, não possibilita um retorno financeiro adequado para o usuário final.

Por fim, observa-se então que os sistemas de monitoramento distribuídos geralmente apresentam uma estrutura de *hardware* mais complexa e um *software* mais simples. Assim, um sistema de monitoramento distribuído, desde que seja projetado de modo adequado, obtém medidas precisas e detalhadas sobre o uso de energia na residência. No entanto, pode-se dizer que existe menor nível de inteligência computacional associada a este método, além de maior custo associado à rede de sensores e incômodo aos usuários associados à instalação e manutenção de tal rede. A vantagem, é a precisão nos dados desagregados.

3.2 Monitoramento Concentrado

Em contraste com o monitoramento distribuído, existe na literatura a técnica chamada de monitoramento não intrusivo de cargas elétricas, porém, este trabalho utilizará o nome de monitoramento concentrado de cargas elétricas. Novamente, sem alterar o conceito, a medição concentrada é baseada na instalação de um único sensor inteligente no ramal principal da residência. Esta análise é baseada na identificação de características elétricas específicas, comumente chamadas de assinaturas elétricas, que permitem identificar qual carga foi ligada ou desligada e o instante que elas operaram. É importante destacar que o termo "não intrusivo" está relacionado à ausência de acesso físico ao interior da instalação elétrica e, consequentemente, a cada uma das cargas.

A Figura 5 ilustra a técnica de monitoramento concentrado. Desta forma, é colocado um medidor no ponto de acoplamento comum da residência (a), onde se encontra o medidor de energia na residência. Com o uso dos equipamentos na residência (b) utilizam-se técnicas para a detecção dos equipamentos ligados (c) como, por exemplo, de decomposição de harmônicas com rede neurais artificiais (Fernandes et al., 2013), decomposição em indicadores elétricos com aprendizagem de máquina (Souza, 2016), técnicas de monitoramento de janelas de potências (Dong et al., 2012) (Fernandes et al., 2013) (Zeifman, 2012), obtendo nestas técnicas exatidão satisfatória.

Na abordagem concentrada, apenas um sensor é colocado no ramal principal e a desagregação é realizada através de *software*, que efetua a análise dos dados e separa as informações de cada

Tomada	Ankoo - Neo Pro	Edimax SP-2101W	Smart-ME Plug	Hs110	DSP W215 - D Link	ThinkEco - s Modlet	Peanut	Wemo	Beyond POWER
Foto									
Padrão Brasileiro	NÃO	NÃO	NÃO	NÃO	NÃO	NÃO	NÃO	NÃO	SIM
Monitoramento de Consumo	SIM	SIM	SIM	SIM	SIM	SIM	SIM	SIM	SIM
Acionamento Remoto	SIM	SIM	SIM	SIM	SIM	SIM	SIM	SIM	SIM
Conexão direta WiFi	NÃO	SIM	SIM	SIM	SIM	NÃO	NÃO	SIM	SIM
Preço aproximado (US$)	27	32	105	39	40	50	40	50	375*

** Valor original disponível em reais: R$ 1200,00. Cálculo de conversão feito usando cotação do dólar R$ 3,20.*

Figura 4: Quadro comparativo de tomadas inteligentes disponíveis comercialmente.

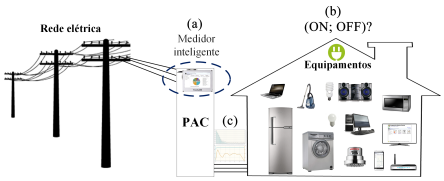

Figura 5: Representação do sistema de monitoramento concentrado.

carga. Este modelo baseado no *software* é mais complexo e justifica a atribuição do termo "medidor inteligente", quando integrado com um único *hardware*, reduzindo custos com aquisição e instalação de sensores. Um sistema de monitoramento concentrado, geralmente, tem precisão inferior a um sistema de monitoramento distribuído, contudo, o grau de imprecisão pode ser tolerado para muitas aplicações. Tal abordagem não permite a gestão remota das cargas, mas viabiliza mudanças de hábitos dos consumidores de maneira a resultar em ganhos em termos de conservação de energia (Alahakoon and Yu, 2016).

Recentemente, o monitoramento concentrado tem recebido atenção significativa no contexto de redes inteligentes, devido ao desenvolvimento da nova geração de medidores (Armel et al., 2013) (Ipakchi and Albuyeh, 2009). Mas, como indicado em (Zeifman, 2012), existe um algoritmo capaz de detectar eventos de ligar/desligar para todos os tipos de cargas em residência. Entretanto, devido ao potencial apresentado pelo monitoramento concentrado, o tema tem sido pesquisado intensamente por vários grupos de pesquisa e ainda existem diferentes empresas oferecendo este tipo de serviço. Em (*Companies offering NILM products and services*, 2018) são listadas mais de 50 empresas que tem trabalhado com monitoramento concentrado, espalhadas ao redor do mundo.

A seguir será apresentada a técnica de monitoramento parcialmente distribuído.

3.3 Monitoramento Parcialmente Distribuído

O monitoramento semi-intrusivo, abordado neste estudo como monitoramento parcialmente distribuído, é baseado na distribuição de um sensor inteligente por circuito ou disjuntor de uma instalação elétrica, exigindo um número intermediário de sensores, isto é, sem alcançar o nível do monitoramento por equipamento ou tomada.

Por não requerer a instalação de sensores em cada ponto de consumo, e sim em cada circuito ou cada disjuntor da instalação, este modelo representa um estágio intermediário entre o monitoramento distribuído e o concentrado, com precisão e custo também intermediários. Apesar de possuir precisão maior na desagregação, levando em conta a medição por circuitos, não há gestão remota dos equipamentos, mas como mencionado no modelo concentrado, viabiliza mudanças de hábitos dos consumidores de maneira a resultando em ganhos na conservação de energia devido ao modo de uso.

Um exemplo de de tecnologia, ilustrado na Figura 6, é oferecida pela empresa Israelense *Panoramic Power*, representada no Brasil pela empresa *ATME Eco Solutions*, a qual é composta por minúsculos sensores de corrente sem fio alimentados pela própria corrente monitorada, e que se comunicam e repassam dados para um receptor e concentrador de dados, que transmite os dados para uma base na nuvem ou em servidor dedicado, onde é realizada a análise e desagregação do consumo.

3.4 Comparativo das Técnicas de Desagregação

Em (Wong et al., 2013) é discutido quais seriam as melhores formas de obter as informações de consumo a nível dos eletrodomésticos. A Tabela 1 apresenta o comparativo feito em (Wong et al., 2013) com algumas adaptações. Uma inovação no setor residencial é a presença de eletrodomésticos inteligentes, os quais, além de fornecerem diversas vantagens e comodidades, podem também fornecer estimativas de consumo, entretanto são em geral US$ 100 mais caros que os eletrodomésticos convencionais. Assim sendo, devido ao custo elevado e esforço mediano para se fazer a instalação destes novos equipamentos, essa abordagem tem uma taxa de adoção baixa. Estima-se que serão necessários de 10 a 15 anos para adoção ampla após a introdução no mercado de massa.

Tabela 1: Comparativo das Abordagens de Monitoramento.

Abordagem	**Investimento**	**Nível de Esforço de Instalação**	**Taxa de Adoção**
Eletrodomésticos Inteligentes	Preço em média US$ 100 maior que os eletrodomésticos convencionais	Médio	Baixa (10 a 15 anos)
Monitoramento Distribuído	US$ 25 a US$ 375 por tomada	Médio para tomadas monofásicas / Alto para tomadas bifásicas	Baixa (7 a 8 anos)
Monitoramento Parcialmente Distribuído	US$ 150 a US$ 300 por casa	Alto	Baixa
Monitoramento Concentrado	US$ 50 a US$ 300	Baixo	Alta

O monitoramento distribuído apresenta um investimento variável de acordo com o número de tomadas que se deseja monitorar. Entretanto, isso pode implicar na tendência de se monitorar apenas as cargas que tradicionalmente apresentam alto consumo, negligenciando as de pequeno consumo, as quais somadas podem ser responsáveis por uma parcela expressiva do consumo (Armel et al., 2013). Outro aspecto importante é que esta abordagem apresenta um problema para o monitoramento de tomadas bifásicas. Em geral as tomadas apresentadas na Figura 3 são monofásicas e o monitoramento de tomadas bifásicas implica em alterações na instalação elétrica ou na aquisição de equipamentos específicos.

O monitoramento parcialmente distribuído em geral requer um esforço maior para instalação devido à quantidade de sensores instalados e ao espaço reduzido nos quadros de distribuição residenciais. Além disso, a carcaça metálica de alguns quadros tende a dificultar a comunicação sem fio.

O monitoramento concentrado em geral é o mais simples para se efetuar a instalação e por ter um investimento menor, tende a ter uma adoção alta. Contudo, é importante que o algoritmo de desagregação seja desenvolvido corretamente pois existem diversos desafios envolvidos para se obter alta precisão no reconhecimento de assinaturas dos eletrodomésticos.

Figura 6: Solução de sistema parcialmente distribuído da empresa Panoramic Power.

3.5 Estudo de Caso das Técnicas de Desagregação

3.5.1 Monitoramento distribuído

Conforme apresentado na seção III, o sistema de monitoramento intrusivo possui como principal característica a instalação de tomadas inteligentes em cada equipamento. Na Figura 4 foram apresentadas algumas soluções comerciais para as tomadas inteligentes e para os resultados foi utilizada a tomada *peanut*, da empresa *securifi*. Para obter as leituras e mais informações da tomada inteligente, bem como o acesso remoto a ela, é necessário o uso de um roteador chamado *almond*, também da *securifi*.

Com a solução instalada, a empresa fabricante disponibiliza um aplicativo proprietário, com a interface apresentada na Figura 7. Na Figura 7, (a) apresenta os valores momentâneos de uma tomada inteligente, nomeada como "refrigerador". (b) indica as atualizações de consumo a cada evento de alteração no valor de potência, corrente ou tensão. O aplicativo permite outras opções, como ligar ou desligar remotamente a tomada e também criar regras para que a tomada seja ligada ou desligada, de acordo com o horário do dia. Desta forma, por possuir limitações na apresentação de informações, o aplicativo *almond* auxilia no monitoramento da tomada inteligente dentro da domótica, mas não é adequada para o uso na desagregação de cargas.

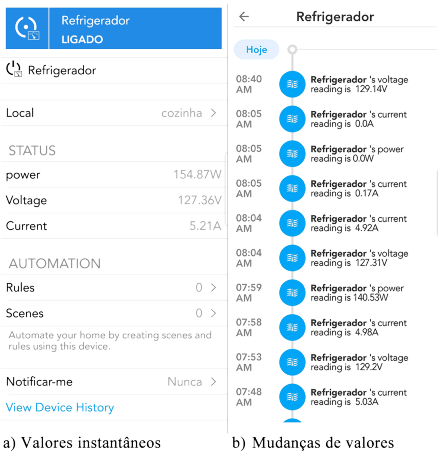

a) Valores instantâneos b) Mudanças de valores

Figura 7: Aplicativo Almond para o monitoramento das tomadas peanut.

Para atender a utilidade da tomada inteligente *peanut* para a desagregação de cargas, existe a alternativa da extração de dados (potência, corrente, tensão, data, horário, temperatura e estado) por acesso direto à tomada inteligente. Desta forma, foi realizado neste artigo um algoritmo para a extração dos dados da tomada inteligente, que possibilitou armazenar estes dados e no cálculo de consumo por tomada inteligente, conforme a Figura 8. Por se tratar de um sistema distribuído, não há necessidade de um algoritmo que efetue a desagregação de cargas, mas é possível obter a estimativa de consumo confrontando a soma do consumo na tomada com o valor total do consumo na residência.

É válido ressaltar que não há erros na detecção e, para acontecer a desagregação completa, é necessário o monitoramento de todos os pontos de consumo de energia elétrica.

3.5.2 Monitoramento concentrado

Conforme apresentado na seção III, o sistema de monitoramento concentrado possui como principal característica algoritmos que permitem a detecção de cargas utilizando somente um ponto de medição, o ponto de acoplamento comum (PAC). Neste caso, não foi possível obter resultados de medidores comerciais, mas em (Souza, 2016) foi construído um protótipo de medidor inteligente, com a metodologia de desagregação de cargas utilizando o monitoramento concentrado. A Figura 9 apresenta o perfil de consumo em uma residência correspondente ao valor total no PAC.

A técnica utiliza a desagregação utilizando tanto a assinatura de potência quanto a análise de indicadores de energia elétrica, que permitem a identificação do equipamento utilizando algoritmos de reconhecimento de padrões. Nesta situação, foram identificados nove equipamentos utilizados ao decorrer do dia: chuveiro elétrico, refrigerador, lâmpadas (fluorescente e incandescente), laptop, TV LCD, lavadora de roupas, secadora de roupas, forno elétrico e aspirador de pó. A Tabela 2 apresenta o horário de funcionamento de cada equipamento e o tempo de uso.

Tabela 2: Funcionamento de cargas para o estudo de caso.

Equipamento	Horário de funcionamento	Tempo total de uso
Chuveiro elétrico	08:42 às 08:57 e 20:02 às 20:04	26 minutos
Laptop	00:00 às 02:08, 17:55 às 19:40 e 22:10 às 23:59	344 minutos
Aspirador de pó	15:27 às 15:32	5 minutos
Lavadora de roupas	10:13 às 11:04	49 minutos
Secadora de roupas	11:19 às 12:11	52 minutos
Lâmpadas	Diversas lâmpadas com ciclos entre 17:49 às 01:48	717 minutos* (diversas lâmpadas)
Refrigerador	Diversos ciclos no dia	455 minutos
TV LCD	10:18 às 13:50 e 20:40 às 23:30	382 minutos
Forno elétrico	12:20 às 12:51	31 minutos

O supervisório do protótipo do medidor apresenta o gráfico de consumo desagregado, conforme

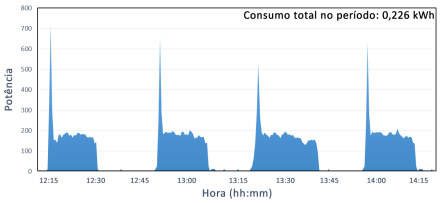

Figura 8: Gráfico de consumo do refrigerador com a tomada inteligente peanut entre 12:15 e 14:15 utilizando *software* de extração de dados e armazenamento de consumo.

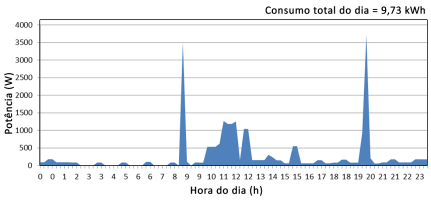

Figura 9: Perfil de consumo em uma residência, obtidos no PAC.

a Figura 10. Nota-se que há a existência do rótulo "Outros". Essa informação vem de erros na classificação e na integralização do consumo. Neste exemplo houve a correta classificação em 97.2% dos casos e houve o acerto na integralização do consumo em 97.8%.

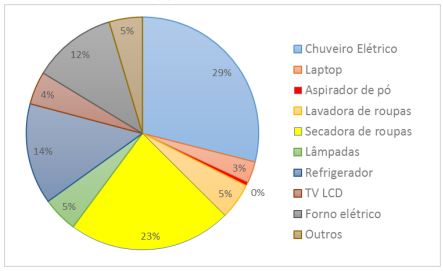

Figura 10: Consumo desagregado por cargas.

3.5.3 Monitoramento parcialmente distribuído

Nesta técnica de desagregação, há a instalação de sensores para cada disjuntor no quadro de distribuição. Desta forma, existe a concentração do consumo das cargas que estão conectadas no subcircuito de cada disjuntor. Se a instalação elétrica do ponto consumidor foi bem realizada e o quadro de distribuição foi bem projetado, esta técnica de monitoramento se torna eficiente para a realização da desagregação de cargas.

Para os resultados dessa subseção, foram instalados os sensores da empresa *EnergyBox* e a Figura 11 apresentam os resultados da medição em uma fase e em sub-circuitos, utilizando o método de medição parcialmente distribuído.

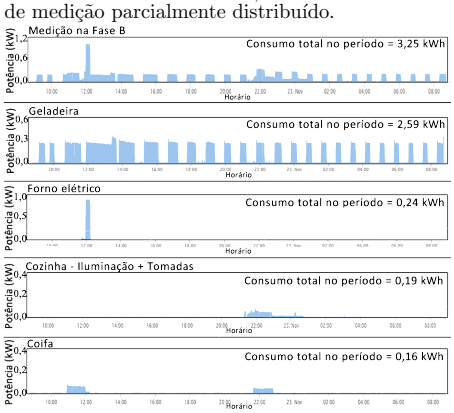

Figura 11: Consumo na Fase B por sub circuitos (disjuntores).

É possível perceber que no primeiro gráfico, rotulado como "Medição na Fase B" há a equivalência de consumo correspondente à soma dos outros gráficos, rotulados como "Geladeira", "Forno Elétrico", "Cozinha -Iluminação + Tomadas" e "Coifa". Neste caso, a "Medição na Frase B" corresponde à fase que está alimentando eletricamente uma cozinha. Destas medições, existem disjuntores que já foram instalados ou estão sendo utilizados para um único equipamento, como a geladeira, forno elétrico e coifa. No caso do disjuntor "Iluminação + Tomadas", os dados de medição deverão ser enviados a algum algoritmo de desagregação de cargas, semelhante ao algoritmo do sistema concentrado (Souza, 2016), com a vantagem de realizar o reconhecimento de menos cargas, devido à possibilidade de cargas instaladas em uma cozinha (iluminação e cargas que podem ser utilizadas em uma cozinha).

Desta forma, o sistema de monitoramento parcialmente distribuído ajuda na apresentação do consumo por setores, conforme a Figura 12. O monitoramento parcialmente distribuído também permite com a desagregação por setor ou cargas.

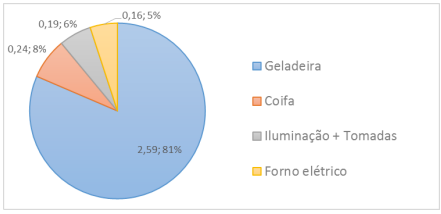

Figura 12: Consumo desagregado por setores.

Analisando os três sistemas de monitoramento, o concentrado permite a análise detalhada do consumo por cargas e o custo de implementação é menor, mas, há a necessidade de maior processamento devido aos algoritmos de detecção de eventos e de cargas. O sistema de monitoramento distribuído e parcialmente distribuído permitem a análise por pontos de medição, o processamento é menor devido ao uso baixo de algoritmos de detecção de cargas. A desvantagem das técnicas distribuída e semi distribuída é o alto custo na implementação se comparada à técnica concentrada.

4 Conclusões

Este artigo descreveu os modelos e os benefícios de se realizar a desagregação do consumo de energia, bem como as vantagens e dificuldades de cada metodologia, tanto na metodologia de desagregação quanto na complexidade de instalação.

A análise do consumo desagregado de cargas muda a forma com que os consumidores observam o consumo de energia elétrica e, consequentemente, como ampliar o atual conceito de energia elétrica como serviço, que pode ser monitorado e utilizado de forma otimizada. Para as concessionárias, a desagregação de cargas permite o gerenciamento melhorado da rede elétrica e cria uma nova relação com o consumidor, permitindo, em alguns casos, o gerenciamento pelo lado da demanda.

Dentro do contexto, as técnicas de desagregação de cargas apresentam vantagens para os consumidores e para as concessionárias de energia elétrica e são divididas em três técnicas: concentrada, parcialmente distribuída e distribuída. Cada solução de monitoramento necessita de um estudo de análise da viabilidade de implantação, custo de equipamentos, tecnologias, precisão e atuação direta sobre a carga elétrica.

No mercado brasileiro, o desenvolvimento das tecnologias distribuídas e parcialmente distribuídas estão defasadas em relação às existentes no exterior. A ausência de sensores com precisão na medição e que estão dentro do padrão brasileiro de tomadas dificulta a utilização para as técnicas de desagregação de cargas. O mesmo pode-se dizer sobre os medidores de sub-circuitos que, apesar do

avanço da tecnologia, o tempo de integralização da medição ainda é insuficiente para a realização da desagregação de cargas, além da dificuldade de instalação nos quadros de disjuntores atuais.

A tecnologia que mais tem avançado no mundo é a técnica concentrada, através dos medidores inteligentes com módulos avançados de processamento, permitindo a desagregação e integralização do consumo, possibilitando maior precisão nas análises de consumo por equipamento. Neste trabalho foi apresentado que a técnica concentrada, baseada em desagregação por *software*, é a mais adequada e com maior potencial entre as três.

Referências

Abubakar, I., Khalid, S., Mustafa, M., Shareef, H. and Mustapha, M. (2017). Application of load monitoring in appliances' energy management - a review, *Renewable and Sustainable Energy Reviews* **67**: 235–245.

Alahakoon, D. and Yu, X. (2016). Smart electricity meter data intelligence for future energy systems: A survey, *IEEE Transactions on Industrial Informatics* **12**(1): 425–436.

Armel, K. C., Gupta, A., Shrimali, G. and Albert, A. (2013). Is disaggregation the holy grail of energy efficiency? the case of electricity, *Energy Policy* **52**: 213–234. Special Section: Transition Pathways to a Low Carbon Economy.

Barai, G. R., Krishnan, S. and Venkatesh, B. (2015). Smart metering and functionalities of smart meters in smart grid - a review, *2015 IEEE Electrical Power and Energy Conference (EPEC)*, pp. 138–145.

Basu, K., Debusschere, V., Bacha, S., Maulik, U. and Bondyopadhyay, S. (2015). Nonintrusive load monitoring: A temporal multilabel classification approach, *IEEE Transactions on Industrial Informatics* **11**(1): 262–270.

Companies offering NILM products and services (2018).

de Souza, W. A., Marafao, F. P., Liberado, E. V., Diniz, I. S. and Serni, P. J. A. (2015). Power quality, smart meters and additional information from different power terms, *IEEE Latin America Transactions* **13**(1): 158–165.

Depuru, S. S. S. R., Wang, L., Devabhaktuni, V. and Gudi, N. (2011). Smart meters for power grid; challenges, issues, advantages and status, *2011 IEEE/PES Power Systems Conference and Exposition*, pp. 1–7.

Dong, M., Meira, P. C. M., Xu, W. and Freitas, W. (2012). An event window based load monitoring technique for smart meters, *IEEE Transactions on Smart Grid* **3**(2): 787–796.

Durling, M., Ren, Z., Visnevski, N. and Ray, L. (2010). Cognitive electric power mete.

Fernandes, R. A. S., da Silva, I. N. and Oleskovicz, M. (2013). Load profile identification interface for consumer online monitoring purposes in smart grids, *IEEE Transactions on Industrial Informatics* **9**(3): 1507–1517.

Garcia, F. D., Marafao, F. P., d. Souza, W. A. and d. Silva, L. C. P. (2017). Power metering: History and future trends, *2017 Ninth Annual IEEE Green Technologies Conference (GreenTech)*, pp. 26–33.

Hart, G. W. (1992). Nonintrusive appliance load monitoring, *Proceedings of the IEEE* **80**(12): 1870–1891.

Ipakchi, A. and Albuyeh, F. (2009). Grid of the future, *IEEE Power and Energy Magazine* **7**(2): 52–62.

Makonin, S., Popowich, F., Moon, T. and Gill, B. (2013). Inspiring energy conservation through open source power monitoring and in-home display, *2013 IEEE Power Energy Society General Meeting*, pp. 1–5.

Opris, I. and Caracasian, L. (2013a). On the implementation of the functionalities of smart metering systems, *2013 8TH INTERNATIONAL SYMPOSIUM ON ADVANCED TOPICS IN ELECTRICAL ENGINEERING (ATEE)*, pp. 1–6.

Opris, I. and Caracasian, L. (2013b). The relation between smart meters and electricity consumers, *2013 12th International Conference on Environment and Electrical Engineering*, pp. 325–329.

Platt, G., West, S. and Moore, T. (2015). The real-world challenges and opportunities of distributed generation, *2015 IEEE Energy Conversion Congress and Exposition (ECCE)*, pp. 1112–1116.

Rathmair, M. and Haase, J. (2013). Load identification and management framework for private households, *IECON 2013 - 39th Annual Conference of the IEEE Industrial Electronics Society*, pp. 5729–5734.

Souza, W. A. (2016). *Estudo de Tecnicas de Analise e Tecnologias para o Desenvolvimento de Medidores Inteligentes de Energia Residenciais*, PhD thesis, FEEC/UNICAMP.

Wong, Y. F., Sekercioglu, Y. A., Drummond, T. and Wong, V. S. (2013). Recent approaches to non-intrusive load monitoring techniques in residential settings, *2013 IEEE Computational Intelligence Applications in Smart Grid (CIASG)*, pp. 73–79.

Zeifman, M. (2012). Disaggregation of home energy display data using probabilistic approach, *IEEE Transactions on Consumer Electronics* **58**(1): 23–31.

Zheng, J., Gao, D. W. and Lin, L. (2013). Smart meters in smart grid: An overview, *2013 IEEE Green Technologies Conference (GreenTech)*, pp. 57–64.

GERENCIAMENTO DE CONSUMO BASEADO EM MEDIDORES COGNITIVOS DE ENERGIA ELÉTRICA

Wesley Angelino de Souza*, Fernando Pinhabel Marafão†, Fernando Deluno Garcia†, Felipe Leite Paes†

*Departamento de Sistemas e Energia - FEEC - UNICAMP
Av. Albert Einstein, 400, Barão Geraldo, Campinas, SP, Brasil

†GASI - ICTS - UNESP
Av Três de Março 511, Aparecidinha, 18087-180
Sorocaba, São Paulo, Brasil

Emails: wesley@dsee.fee.unicamp.br, fmarafao@sorocaba.unesp.br, fernando.delunogarcia@gmail.com, paes.felipe@hotmail.com

Abstract— The cognitive power meter indicates a new generation of electronic meters with high processing, storage, and data communication, which make use of advanced techniques concerning data mining and data processing, leading with other things, the disaggregation of the power consumption to provide consumers and utilities with more detailed information. In this context, this paper reviews the main subsystems involved in this technology and describes the proposal of an energy consumption management system based on cognitive energy meters.

Keywords— Cognitive meter, Electric load disaggregation, Energy management, Power consumption management, Smart meter.

Resumo— Medidores cognitivos de energia elétrica indicam para uma nova geração de medidores eletrônicos, com elevada capacidade de processamento, armazenamento e comunicação de dados, os quais fazem uso de técnicas avançadas de mineração, tratamento e processamento de dados, visando dentre outras coisas, a desagregação do consumo de energia para prover consumidores e fornecedores de energia de informações mais detalhadas que possam ser utilizadas no gerenciamento energético das instalações e redes. Neste contexto, este trabalho faz uma revisão dos principais subsistemas envolvidos e, descreve a proposta de um sistema de gerenciamento de consumo de energia, baseado em medidores cognitivos de energia.

Palavras-chave— Desagregação de cargas elétricas, Medidor cognitivo de energia, Medidor inteligente de energia, Gerenciamento energético, Gerenciamento do consumo de energia.

1 Introdução

Os conceitos de Redes Inteligentes de Energia e da Infraestrutura de Medição Inteligente (Barai et al., 2015) vêm se consolidando no sentido de atender as necessidades atuais de melhoria na gestão e no uso eficiente da energia elétrica. Nesse contexto, há um grande interesse em desenvolver tecnologias que possibilitem aos consumidores residenciais a se conscientizarem em relação aos seus hábitos de consumo e ao uso racional desse recurso (Weranga et al., 2012). Diante disso, novos medidores de energia elétrica vêm sendo desenvolvidos para prover informações detalhadas sobre o consumo de energia elétrica em comparação aos medidores tradicionais. Tais dispositivos são conhecidos como medidores inteligentes de energia (do inglês, *smart meters*) e possibilitam maior exatidão de medição, capacidade de armazenamento, envio automático de informações de consumo e integração com sistemas de gerenciamento de energia (Barai et al., 2015) (Opris and Caracasian, 2013a) (Zheng et al., 2013). Dos medidores inteligentes, destacam-se as seguintes características:

- Qualidade e clareza das informações coletadas;
- Disponibilização de informações que impactem diretamente sob o comportamento do consumidor;
- Possibilidade de consulta dos consumos anteriores, ou ainda das médias de consumo;
- Previsões baseadas no histórico comportamental da residência e também da região onde está localizado;
- Controle dos gastos.

Atualmente, um dos principais temas destacados na literatura é a utilização dos medidores inteligentes de energia para realizar a desagregação do consumo por cargas (Xu and Milanović, 2015). Tal função também é destacada como um aprimoramento dos medidores inteligentes, denominado medidor cognitivo de energia (Makonin et al., 2013) (Garcia et al., 2017).

Entre as principais aplicações dos medidores cognitivos destacam-se: o monitoramento do consumo de energia no ambiente residencial e a criação de mecanismos que possibilitem os consumidores entenderem seus hábitos de consumo e reduzirem gastos com energia elétrica (Ehrhardt-Martinez et al., 2010) (Weranga et al., 2012). Para tal, é fundamental a criação de uma ferramenta que indique ao usuário estratégias e sobretudo para fornecer a consciência do consumo de energia elétrica (de Souza, 2010).

Com esta demanda, esse trabalho apresenta o conceito de um sistema para o medidor cognitivo de energia elétrica no contexto residencial. Portanto, será apresentada a integração entre algoritmos de inteligência artificial com um sistema intuitivo, que permite ao consumidor ter a íntegra consciência do consumo de energia elétrica. Para tal, há a integração de algoritmos de desagregação de cargas, indicadores da Qualidade da Energia Elétrica, cálculos de eficiência energética, sugestões de economia e previsão de consumo. As seções 2 e 3 apresentam os conceitos de medidores inteligentes e cognitivos, destacando as evoluções e diferenças. A seção 4 apresenta o conceito do sistema para a consciência do consumo com alguns resultados e a seção 5 apresenta as conclusões.

2 Estrutura e operação dos atuais medidores inteligentes

Um medidor inteligente é composto por um conjunto de hardware, software e sistemas de medição. O medidor inteligente tipicamente inclui os seguintes elementos (Barai et al., 2015) (Durling et al., 2009) (Weranga et al., 2012) (Devices, 2011):

- Sensores de corrente e tensão;
- Circuitos analógicos de condicionamento e pré-processamento de sinais;
- Circuito de alimentação;
- Unidade de processamento e aquisição de dados;
- Módulo de comunicação;
- Relógio de tempo real.

O diagrama simplificado de um medidor inteligente pode ser visto na Figura 1.

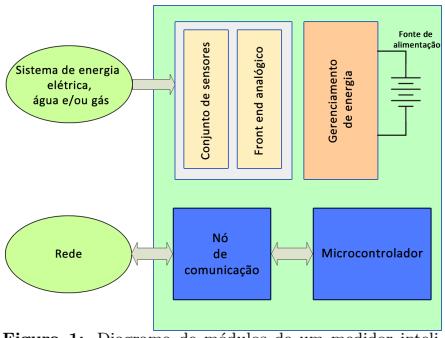

Figura 1: Diagrama de módulos de um medidor inteligente. (Fonte: Analog, 2011).

Especificamente, as unidades de sensoriamento e condicionamento dos sinais são utilizadas para adequar as grandezas medidas aos circuitos de conversão de sinais analógico-digital (AD) e posteriormente fornecer os valores convertidos de corrente e tensão para unidade de processamento. Além das grandezas, o relógio de tempo real (RTC) é utilizado para fornecer a data e horário das medições.

A unidade de processamento é o principal módulo do medidor inteligente, sendo utilizada para aquisição e processamento de dados de tensão e corrente, e armazenamento e transmissão de informações de consumo. Tal módulo pode ser composto por dispositivos como: microcontrolador, processador digital de sinal (DSP) ou *System-On-Chip* (SOC).

Dentre as tecnologias de comunicação, os dois meios de transmissão mais promissores são (Harney, 2009) (Devices, 2011) (Gungor et al., 2011): sem fio para curtas distâncias ou pela própria linha elétrica (PLC - *Power Line Communication*). Quando comparados, esses métodos apresentam algumas vantagens e desvantagens, por exemplo, a infraestrutura da comunicação sem fio tem custo menor e pode ser utilizada em áreas de difícil acesso. Por outro lado, são dependentes de energia e podem sofrer interferências do meio de propagação do sinal (Gungor et al., 2011). Já o método PLC, pode ser utilizado para alcançar área remotas, contudo apresentam alto custo de implantação e não oferecem altas taxas de transmissão (Barai et al., 2015).

3 Medidores Cognitivos de Energia Elétrica

A tecnologia SMS (*Smart Metering System*) — dos atuais medidores inteligentes — trouxe diversas evoluções aos sistemas de medição de energia elétrica, porém, o termo "inteligente" ainda requer consolidação para que identifique, de fato, à classe de medidores necessária ao desenvolvimento do sistema elétrico do futuro. A capacidade de leitura de energia em quatro quadrantes, de forma remota ou local, não é suficiente para que os medidores recebam tal denominação.

Neste contexto, diversas formas de agregar maior inteligência aos medidores têm sido apresentadas na literatura, destacando-se as técnicas de desagregação do consumo de energia elétrica por equipamentos como um dos cernes desta evolução. Tal funcionalidade pode ser obtida a partir do método chamado monitoramento de carga não intrusivo (NILM — *Non-Intrusive Load Monitoring*) ou monitoramento concentrado. Proposto inicialmente por Hart (Hart, 1992), o método NILM faz o uso dos padrões de assinaturas de potência dos eletrodomésticos (Dong et al., 2012) (Souza, 2016), utilizando-se de um único ponto de medição. Outro método de monitoramento é denominado intrusivo (ILM — *Intrusive Load Monitoring*) ou monitoramento distribuído, sendo caracterizado pela distribuição de sensores em pontos de medição por tomada ou equipamentos. Esse método é dito intrusivo devido à necessidade de se utilizar dispositivos de medição em cada carga que se deseja analisar (Naghibi and Deilam, 2014).

Dos dois métodos de monitoramento, o NILM tem despertado mais interesse por ser mais prático para aplicações residenciais, principalmente pela vantagem de se utilizar somente um dispositivo de medição (Naghibi and Deilam, 2014).

Para desenvolvimento do NILM, as técnicas mais simples como (Hart, 1992), envolvem a identificação da alteração de estado nas cargas, isto é, quando são ligadas ou desligadas. Esses métodos possuem diversas vantagens, pois possibilitam criar modelos representativos de uma residência na forma de uma máquina de estados. Tais modelos podem ser utilizados para análise de dados por meio de diversas técnicas (Dong et al., 2012) (Hart, 1992) (Barker et al., 2014). Embora simples, não apresentam boa exatidão em relação ao consumo individual para cargas que apresentam um padrão de consumo complexo, por exemplo, uma televisão LCD. Nesse sentido, modelos de máquina de estados descartam informações importantes que podem ser utilizadas para análise (Dong et al., 2012) (Barker et al., 2014) (Souza, 2016). Para o monitoramento exato é necessário considerar as cargas que apresentam variações ao longo do tempo ou vários estados (Dong et al., 2012) (Souza, 2016) (Hart, 1992).

A técnica NILM analisa a rede de forma contínua com o objetivo de detectar os eventos que caracterizam a assinatura de potência das cargas.Tal procedimento pode ser exemplificado por 6 estágios de execução. No primeiro estágio, tensão e corrente são amostrados. Em seguida, as amostras são processadas e preparadas para análise que envolve a detecção de eventos na assinatura de potência. Sempre que um evento é detectado um al-

goritmo é executado para extrair informações que permitem identificar a carga. Por fim, ocorre a estimação do consumo individual considerando os eventos monitorados.

Diante disso, a técnica NILM pode ser considerada como uma ferramenta efetiva para coletar informações de cargas e pode ainda potencializar outras aplicações (Dong et al., 2012). Assim sendo, o conceito de medidor inteligente pode ser redefinido, sendo chamado de medidor cognitivo. A partir dos medidores cognitivos é possível extrair informações relevantes sobre o consumo de energia elétrica de cada tipo de carga (Makonin et al., 2013).

Deve-se destacar que essas informações são extremamente importantes para que os consumidores conheçam seus hábitos e tomem decisões eficientes em relação ao consumo de energia elétrica. Portanto, o próprio medidor pode ser utilizado para fornecer sugestões de consumo, com base em dados estatísticos e do conhecimento dos hábitos dos consumidores (Opris and Caracasian, 2013b).

Para interação com os consumidores, pode-se utilizar interfaces IHD (*In-Home Display*) (Makonin et al., 2013) (Alahakoon and Yu, 2015), como ilustrado na Figura 2. É importante que as interfaces sejam intuitivas, facilitando o entendimento das informações pelos consumidores (Opris and Caracasian, 2013b) (Zhou et al., 2010). Além disso, a conectividade e a acessibilidade serão essenciais para potencializar a experiência dos usuários. Tais requisitos são favorecidos pelo avanço das tecnologias de comunicação, principalmente, a tecnologia wireless. Nesse sentido, a interface com o usuário também pode ser realizada por meio de sistemas WEB ou aplicativos de celulares (Isa et al., 2015) (Landi et al., 2011).

Figura 2: Sistema de Gerenciamento - IHD (GreenAnt).

As interfaces têm como objetivo aumentar a interação entre o consumidor, o dispositivo e a companhia de energia elétrica. Assim, essas informações de consumo podem ser exibidas com base em comparações à períodos anteriores, isto é, os consumidores não devem se preocupar em saber o que é kWh (Makonin et al., 2013). Portanto, é possível personalizar o sistema para fornecer recomendações ao usuário (Kádár, 2011) (Souza, 2016), por exemplo:

- Esse final de semana o seu consumo foi superior ao da semana passada. Você estava em casa?
- O seu consumo semanal está 30% superior que o padrão.
- Amanhã a temperatura máxima será de 39°C. Evite aberturas desnecessárias de janelas e portas.
- O seu consumo nesta madrugada foi baixo, porém foi duas vezes maior que o dia anterior. Você apagou todas as luzes?

Essa interação e capacidade de gerenciamento de cargas permite aos consumidores regularem seu próprio consumo, de acordo com o grau de conforto desejado (Basu et al., 2015). Além disso, o conhecimento do consumo individual de cada carga é pré-requisito para o desenvolvimento de técnicas sofisticadas de controle que podem aumentar a eficiência energética (Hart, 1992) (Barker et al., 2014).

Do ponto de vista da concessionária, a modelagem e previsão de cargas podem auxiliar no planejamento, operação e aumento da eficiência da rede elétrica. Dessa forma, a estratégia de desagregação de carga traz muitos benefícios e pode se tornar uma interessante tendência para uma futura geração de medidores inteligentes.

Portanto, um medidor de energia elétrica pode se tornar uma ferramenta que vai além daquele que é instalado no Ponto de Acoplamento Comum (PAC) em uma residência. Além disso, a existência de um sistema que auxilie o consumidor a entender o consumo é uma tendência. Considerando isso, e a seção a seguir apresenta uma proposta de um sistema para a próxima geração de medidores, denominados medidores cognitivos.

4 Aspectos Relevantes e Benefícios que justificam a evolução para os medidores cognitivos

Os benefícios da medição inteligente de energia elétrica são inúmeros para todos os integrantes do sistema, que podem de maneira simples, ser divididos em três categorias (Alahakoon and Yu, 2015): Consumidores, Companhias de Energia Elétrica (setores de geração, transmissão e distribuição), meio ambiente e sociedade. No entanto, o projeto, o desenvolvimento e a manutenção de um sistema de medição inteligente envolvem muitos problemas e desafios. A aceitação pode ser demorada e delicada, pois as pessoas e empresas precisarão antes conhecer os novos dispositivos, compreender os motivos da substituição e as mudanças que ocorrerão para depois aceitá-los e, finalmente, utilizá-los (Barai et al., 2015) (Opris and Caracasian, 2013b) (Depuru et al., 2011). Alguns desafios e inseguranças são listados a seguir:

- Justificar os investimentos;
- Impactos causados na transição das tecnologias;
- Medo de perder a privacidade e com os riscos que isso pode gerar;
- Insegurança em relação ao preço da energia;
- Redução de empregos;
- Segurança das informações.

Diante disso, cabe ainda ressaltar que os valores que podem ser gerados com a adoção da medição inteligente são proporcionais às suas funcionalidades e ao seu uso correto (Opris and Caracasian, 2013b). Neste sentido, um dos principais fatores que irão determinar o sucesso da aplicação dos medidores inteligentes é a análise de dados, que consiste na aquisição de dados, transmissão, processamento e interpretação (Mohassel et al., 2014) (Alahakoon and Yu, 2015).

4.1 Consumidores

Os consumidores podem se beneficiar, pois estarão aptos a estimar suas contas de energia, gerenciar o consumo de energia e receber informações que levem ao conhecimento dos hábitos de consumo (Zheng et al., 2013) (Opris and Caracasian, 2013a).

Entre as novas funcionalidades, a capacidade de receber informações favorece os programas de *feedback*. Tais programas apresentam potencial para reduzir o consumo de energia a partir da interação que pode ser criada com o consumidor (Makonin et al., 2013) (Zhou et al., 2010).

Medidores inteligentes convencionais enviam somente dados de medição de potência e de consumo da energia elétrica em intervalos que podem ser de 15 minutos, a cada hora, por dia, por mês, entre outros. Tal abordagem é uma evolução ao ser comparada com o método de coleta manual, no qual o operador vai ao ponto de medição mensalmente para obter o consumo de energia elétrica.

Como apresentado na seção anterior, o medidor cognitivo é capaz de realizar o monitoramento e desagregação do consumo de cargas residenciais. Tais características podem ser exploradas a partir de uma combinação entre tecnologia e serviços de modo que o consumidor seja motivado, informado e engajado a atuar no próprio controle do consumo de energia (Ehrhardt-Martinez et al., 2010).

Diante disso, é necessário que os usuários conheçam bem os dispositivos usados. De modo geral, os consumidores podem ser influenciados a partir de informações disponibilizadas antecipadamente ou por consequência de alguma ação. No primeiro caso, qualquer meio de comunicação que apresente informação sobre modos de reduzir o consumo de energia pode afetar o comportamento do consumidor. Já o segundo está relacionado diretamente com o comportamento do consumidor, principalmente com informações que possibilitem sua conscientização em relação aos seus hábitos de consumo (Wood and Newborough, 2002).

Nesse contexto, as iniciativas voltadas à criação de programas de sugestões e recomendações tem se mostrado importantes (Ehrhardt-Martinez et al., 2010). Informações coletadas em 36 estudos indicam que essas ações já obtiveram resultado positivo, apresentando potencial de redução de consumo entre 4% a 12% (Figura 3).

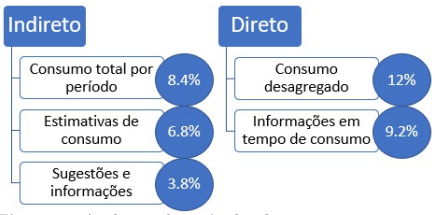

Figura 3: Avaliação dos métodos de sugestões e recomendações. (Fonte: Ehrhardt-Martinez, Donnelly and Laitne, 2010).

No contexto residencial, esses programas representam um passo fundamental em direção à criação de produtos e serviços que aumentem a conscientização dos consumidores em relação aos seus hábitos de consumo (Ehrhardt-Martinez et al., 2010). Essas técnicas podem ser categorizadas como diretas ou indiretas. No método indireto, as informações sobre consumo são fornecidas de forma periódica e após o consumo ter ocorrido. No método direto, as notificações são geradas em tempo real e apresentam maior potencial de redução de consumo do que o método indireto. A seguir estão indicadas algumas das principais características destes dois métodos, segundo (Ehrhardt-Martinez et al., 2010).

- **Métodos Indiretos**:
  - **Contas de energia detalhadas**: Notificação de informações detalhadas e sugestões para reduzir o consumo têm potencial de redução do consumo médio em até 3,8%. De modo geral, esse tipo de abordagem apresenta comparações que podem ser realizadas com base no próprio histórico de consumo ou em relação a outros consumidores.
  - **Estimativas de consumo**: Uso de técnicas para extrair a informação de consumo, de acordo com a categoria do consumidor, dos eletrodomésticos utilizados e do histórico de consumo. Tal método tem potencial de redução do consumo em 6,8% e é recomendado o uso de uma interface que contabilize o consumo individual de cada equipamento;
  - **Relatório de consumo diário/semanal**: A notificação detalhada do consumo diário e/ou semanal, segundo o estudo, possibilita a redução do consumo em cerca de 8,4%. Diante disso, o consumidor pode adquirir novos hábitos e gerenciar melhor o consumo de energia.
- **Métodos Diretos**:
  - **Informações em tempo real**: Esse método apresentou redução de 9,2%. De modo geral, o consumidor é notificado periodicamente sobre o consumo total. Isso é feito utilizando uma interface, por exemplo, in-home display;
  - **Informações detalhadas em tempo real**: Em comparação com o método anterior, esse apresenta estimação de consumo a nível de eletrodomésticos. Esse método apresentou, no estudo, o maior potencial de redução de consumo em cerca de 12%.

Isso mostra que a apresentação de informações detalhadas em relação aos elementos que estão consumindo energia propicia a redução de consumo, pois possibilita criar recomendações e informações personalizadas (CarrieArmel et al., 2013).

Uma plataforma que fornece poucas sugestões e recomendações para o consumidor não tem muito potencial para reduzir os gastos de consumo, pois com a baixa frequência dessa interação é difícil estabelecer ou observar a relação entre o comportamento do consumidor e seus impactos no consumo de energia. Diante disso, a frequência e a granularidade dessas informações determinam o potencial da plataforma em fornecer sugestões e recomendações que realmente impactem no comportamento do consumidor. Isto é, definem a fronteira entre informação útil e a informação vaga de valores sobre consumo de energia elétrica (ACEEE, 2017).

De modo geral, os métodos de sugestões e recomendações que são capazes de gerar mais economia estão associados com a utilização de ferramentas como medidores e telas informativas. No entanto, a redução de consumo pode ser potencializada ainda mais se forem criados mecanismos que utilizem de técnicas motivacionais e comportamentais como definição de de metas, compara-

ções sociais, mensagens normativas, entre outros (Ehrhardt-Martinez et al., 2010). Nesse sentido, procedimentos de diagnósticos podem ser criados tendo como objetivo o aumento da eficiência energética Pois, com acesso às informações de consumo, os eletrodomésticos podem ser avaliados se estão consumindo mais energia do que deveriam.

Além disso, notificações podem ser enviadas ao consumidor para informar se determinado equipamento pode ser trocado por outro mais eficiente. Para isso, tais recomendações podem levar em consideração o custo com a redução de consumo, estimativa sobre potencial de redução em um determinado período, entre outros (CarrieArmel et al., 2013).

4.2 Companhias de Energia Elétrica

Para as companhias de energia, as informações das unidades consumidoras poderão ser coletadas de modo remoto e em tempo real. Isso possibilitará a criação de novos programas de tarifação e também a redução dos custos operacionais (Barai et al., 2015) (Zheng et al., 2013) (Weranga et al., 2012).

Os dados de consumo poderá ser utilizados para prover informações que encorajará os consumidores a utilizar a energia de modo racional, deste modo, reduzindo no curto prazo a necessidade de expansão da oferta e da infraestrutura das redes. Outra função é a de monitoramento da unidade consumidora, isto é, a capacidade de conectar/desconectar a unidade consumidora da rede elétrica, ou até mesmo controlar cargas individuais ou conjunto destas (Depuru et al., 2011).

Além disso, os picos de consumo poderão ser acompanhados e gerenciados de modo efetivo (Zheng et al., 2013) (Weranga et al., 2012). Essa técnica é chamada de resposta em demanda e é vista como parte da solução para reduzir a demanda de energia elétrica, assegurando o melhor uso dos recursos existentes, aumentando a eficiência energética e possibilitando a redução dos custos da energia elétrica (Barai et al., 2015) (Weranga et al., 2012) (Kempener et al., 2013).

As companhias distribuidoras poderão se beneficiar ainda das informações, sofisticando e melhorando seus modelos de compra de energia, em função do mapeamento mais detalhado do consumo.

Para o mercado de eletricidade, novos programas de tarifação podem ser criados, como, por exemplo, a tarifação dinâmica CPP (do inglês, Critical Peak Pricing) no qual as concessionárias notificam seus clientes quando a demanda de energia está próxima de valores pré-estabelecidos e, nesse caso, os consumidores que reduzirem seu consumo são compensados (Kempener et al., 2013) (Deconinck and Decroix, 2009). Outra proposta é a tarifação por tempo de uso ToU (do inglês, Time-of-Use) em que o preço da energia é estabelecido com relação ao período do dia. Ou ainda, a tarifação em tempo real RTP (do inglês, Real Time Pricing) em que o preço da energia é regularmente ajustado durante o dia (Deconinck and Decroix, 2009).

Assim, os principais benefícios do medidor inteligente, do ponto de vista da concessionária, são destacados a seguir:

- Facilita a detecção de falta de energia e a restauração pode ser realizada rapidamente;
- Facilita a localização e identificação de falhas;
- Mantém os consumidores informados sobre o estado de operação da rede elétrica, por exemplo, causa da queda de energia e tempo para restauração do serviço;
- Melhora no planejamento e gerenciamento do sistema;
- Permite a redução de picos de demanda;
- Permite a leitura automática e remota dos medidores;
- Possibilita a gestão eficiente dos recursos para geração de energia;
- Reduz a necessidade de construção de novas plantas de energia;
- Capacidade de conectar/desconectar a unidade consumidora da rede;
- Aumenta o volume de informações sobre consumo nas redes de baixa tensão;
- Reduz os custos operacionais.

4.3 Meio Ambiente e Sociedade

A medição inteligente é considerada uma das principais funções da Rede Inteligente de Energia (Weranga et al., 2012), sendo um dos principais objetivos alcançar uma maior eficiência energética (Barai et al., 2015). Nesse sentido, os benefícios que podem ser gerados estão além dos destacados anteriormente, pois afetam a sociedade como um todo. Os principais benefícios são (Barai et al., 2015) (Zheng et al., 2013) (Opris and Caracasian, 2013b):

- Aumentar a eficiência e qualidade dos serviços;
- Reduzir a demanda de energia elétrica devido a conscientização sobre o consumo de energia elétrica;
- Estimular o desenvolvimento de novas tecnologias;
- Desenvolver novas técnicas para previsão de demanda de energia elétrica;
- Aprimorar o uso dos recursos energéticos existentes;
- Está indiretamente relacionado com a redução da emissão CO2.

5 Sistema de gerenciamento de energia proposto

O sistema de gerenciamento de energia proposto e implementado de acordo com o esquema da Figura 1, utilizou-se de um sistema embarcado *Beagle Bone Black* como unidade de processamento do medidor cognitivo. O dispositivo embarcado é responsável pelo processamento e tratamento dos dados medidos para os algoritmos de desagregação de cargas, armazenamento dos dados (banco de dados) e para a execução do sistema supervisório do medidor.

A Figura 4 apresenta o funcionamento do medidor cognitivo com três áreas em destaque. A área **(a)** correspondente a uma máquina de estados que analisa a assinatura de potência e a tendência comportamental do consumo. Quando

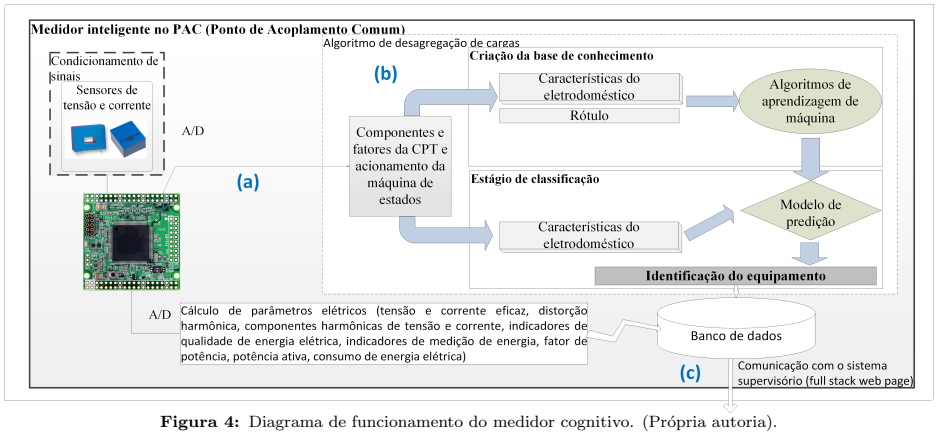

Figura 4: Diagrama de funcionamento do medidor cognitivo. (Própria autoria).

existe a detecção de "carga ligada" ou "carga desligada", o sistema envia atributos calculados a partir da CPT (*Conservative Power Theory*) à área **(b)**, que corresponde ao sistema de identificação de padrões. Cabe ressaltar que CPT generaliza as definições de potência e fator de potência, considerando ainda os efeitos de desbalanço de carga, assimetria de tensão e variação de frequência.

De modo geral, os eventos são caracterizados por apresentar uma mudança de nível no valor médio de potência ativa. Quando analisados continuamente, são formados segmentos contíguos e consecutivos, representado a assinatura de potência do equipamento. Portanto, a função da área **(b)** é identificar os parâmetros que foram alterados entre dois segmentos.

É importante destacar que os indicadores da CPT auxiliam no estágio de identificação dos equipamentos, pois analisam não somente a assinatura de potência ativa como também a assinatura de potência reativa e residual. Com esses indicadores, é possível criar uma base de dados de equipamentos utilizando informações de potência do equipamento em componentes ativa, reativa e de não linearidade, representando a assinatura da carga no seu momento de uso. Assim, na área **(b)** é utilizado um algoritmo de reconhecimento de padrões **KNN** para identificar o equipamento que gerou o evento.

Todo evento identificado tem o período registrado em um banco de dados. Ao reconhecer que o eletrodoméstico foi desligado, informações sobre o período de operação e consumo médio são utilizadas para estimar o consumo total do equipamento. Cabe ressaltar que o banco de dados pode ser local (medidor) ou externo (na nuvem ou em um servidor local). Esse cenário reforça o termo cognitivo, em que técnicas de inteligência computacional e artificial são aplicadas à geração de conhecimento a partir da interpretação e extração de significado dos dados coletados.

Em **(c)**, há um sistema no formato de *web app* responsivo, ou seja, pode ser utilizado por qualquer dispositivo que esteja conectado na rede: computadores pessoais, dispositivos portáteis, entre outros.

Para apresentar as informações descritas nesta seção, propõe-se o uso de um sistema de gerenciamento de consumo, como mostrado na Figura 5.

Figura 5: Sistema supervisório - Interface com o usuário.

Conforme destacado, os métodos diretos em tempo real possuem maior potencial para a redução de consumo e são utilizadas as técnicas de desagregação de cargas mais próximas ao tempo real. Para isso, utilizou-se a metodologia de desagregação proposta por (Souza, 2016). Utilizando essa técnica em conjunto com o sistema para o gerenciamento, é possível apresentar gráficos e informações ao consumidor acerca do consumo da energia elétrica.

O sistema pode apresentar o consumo total da energia elétrica, desagregado por cargas e em tempo real, conforme apresenta a Figura 6. Esta informação auxilia o consumidor a entender o seu consumo instantâneo de energia elétrica e verificar a real necessidade de uso dos equipamentos que estão ligados. No caso da Figura 6, o consumidor pode perceber o alto consumo do ar condicionado no intervalo e, caso não exista a necessidade de uso, ele pode desligar obtendo economia de energia.

Ainda na análise em tempo real, o sistema pode apresentar dados referentes à carga ligada e no impacto dela na conta, tanto como estimativa de consumo no mês quanto com a análise estatística, de acordo com o histórico de consumo. Junto a isso, o sistema busca no banco de dados algumas sugestões para o melhor uso do equipamento, conforme apresenta a Figura 7. Além disso, podem também indicar formas de melhorar a eficiência energética do equipamento (Ehrhardt-

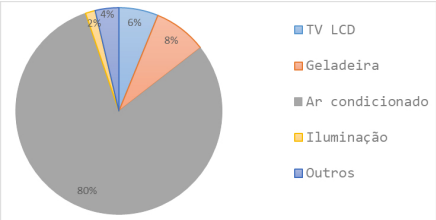

Figura 6: Consumo em tempo real de uma residência.

Martinez et al., 2010).

Ar Condicionado

Nos últimos 7 dias a média de uso do Ar Condicionado foi de 5,3 hora(s). No mês passado, o equipamento Ar Condicionado foi responsável por 21% do consumo total da residência, possui um alto impacto no consumo de energia elétrica.
Portanto, fique atento! Quanto maior o tempo de uso, maior será o consumo de energia elétrica.
Confira algumas dicas:

- Desligue o aparelho quando o ambiente estiver desocupado;
- Mantenha portas e janelas fechadas quando o ar condicionado estiver funcionando.
- Evite o calor do sol no ambiente fechando cortinas e persianas;
- Não tape a saída do ar condicionado;
- Proteja a parte externa do ar condicionado da incidência solar, mas não bloqueie as grades de ventilação.

Figura 7: Sugestões e recomendações para equipamentos que estão ligados.

Outra vantagem do sistema de gerenciamento do consumo de um medidor cognitivo é apresentar informações do consumo de energia elétrica em períodos que podem ser do dia, da semana, do mês e até no ano, conforme apresenta a Figura 8, correspondente ao consumo desagregado no mês anterior.

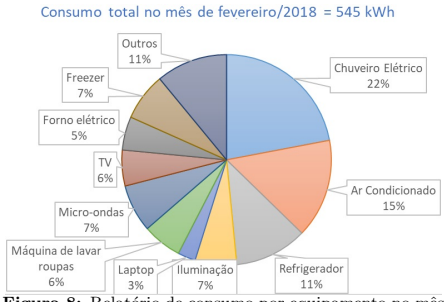

Figura 8: Relatório de consumo por equipamento no mês anterior.

Além das informações do consumo desagregado, o medidor cognitivo pode também apresentar o histórico de consumo diário, semanal, mensal. Com isso, é possível prever o consumo no mês, de acordo com o comportamento do consumidor (Figura 10). O medidor cognitivo também pode coletar e apresentar informações de continuidade do serviço de energia (Figura 11), verificação da eficiência energética de equipamentos, entre outros relatórios.

6 Conclusões

Considerando os avanços em tecnologias de hardware e software, em especial o uso de técnicas de inteligência artificial e otimização, as novas gerações de medidores de energia darão muito mais sentido ao termo "inteligente", visando beneficiar

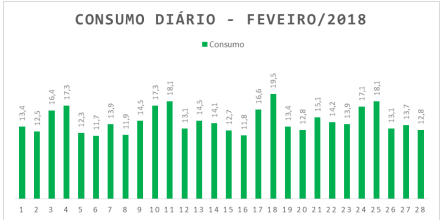

Figura 9: Relatório de consumo total diário no mês anterior.

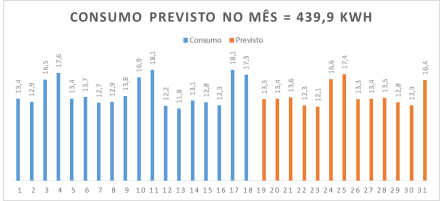

Figura 10: Relatório de previsão do consumo total diário para o mês.

Indicadores de continuidade de fornecimento de energia (segundo o PRODIST8):

Indicador	Período	Padrão	Apurado
DIC	Mensal	4.71	3.39
DIC	Trimestral	9.43	7.8
DIC	Anual	18.86	17.5
FIC	Mensal	3.11	2
FIC	Trimestral	6.22	5
FIC	Anual	12.45	8

Figura 11: Indicadores de continuidade.

de diferentes perspectivas, tanto os consumidores, quanto os fornecedores de energia, bem como empresas do ramo de gerenciamento energético.

Uma das abordagens é o medidor cognitivo, que apresenta como principal evolução a possibilidade da desagregação do consumo da energia elétrica por eletrodomésticos.

Entre as técnicas de desagregação, foi utilizada uma técnica que permite a detecção do equipamento ligado em tempo real e realiza o registro de desagregação de equipamentos e de consumo.

Para dar utilidade às técnicas de desagregação, foi apresentada uma proposta de sistema de gerenciamento de consumo, a qual indica que é possível retornar ao consumidor informações que permitam a conscientização do consumo de energia elétrica e, sobretudo, na busca pela redução e uso otimizado da energia elétrica.

Agradecimentos

Os autores agradecem à FAPESP (Processos 2016/08645-9 e 2012/19375-1) pelo financiamento a este projeto.

Referências

ACEEE (2017). State regulators can play a critical role in unleashing building energy data.

Alahakoon, D. and Yu, X. (2015). Smart electricity meter data intelligence for future energy systems: A survey, *IEEE Transactions on Industrial Informatics* pp. 425–436.

Barai, G. R., Krishnan, S. and Venkatesh, B. (2015). Smart metering andfunctionalities of smart meters in smart grid - a review, *Electrical Power and Energy Conference (EPEC)* pp. 138–145.

Barker, S., Kalra, S. and Shenoy, D. I. P. (2014). Empirical characterization, modeling, and analysis of smart meter data, *IEEE Journal on Selected Areas in Communications* **32**(7).

Basu, K., Debusschere, V., Bacha, S., Maulik, U. and Bondyopadhyay, S. (2015). Nonintrusive load monitoring: A temporal multilabel classification approach, *IEEE Transactions on Industrial Informatics* **11**(1).

CarrieArmel, K., Gupta, A., Shrimali, G. and Albert, A. (2013). Is disaggregation the holy grail of energy efficiency? the case of electricity, *Energy Policy* (52).

de Souza, E. P. (2010). *Economia de energia em ar condicionado no brasil: Eficiência e economicidade*, Dissertação de mestrado, Universidade Federal de Itajubá.

Deconinck, G. and Decroix, B. (2009). Smart metering tariff schemes combined with distributed energy resources, *Fourth International Conference on Critical Infrastructures* (1): 1–8.

Depuru, S. S. S. R., Wang, L., Devabhaktuni, V. and Gudi, N. (2011). Smart meters for power grid - challenges, issues, advantages and status, *Power Systems Conference and Exposition (PSCE), IEEE/PES* .

Devices, A. (2011). Wireless technologies for smart meters.

Dong, M., Meira, P. C. M. and andWalmir Freitas, W. X. (2012). An eventwindow based load monitoring techniquefor smart meters, *IEEE Transactions on Smart Grid* **3**(2): 787–796.

Durling, M. R., Ren, Z., Visnevski, N. and Ray, L. E. (2009). Cognitive electric power meter.

Ehrhardt-Martinez, K., Donnelly, K. A. and Laitner, J. A. (2010). Advanced metering initiatives and residential feedback programs: A meta-review for household electricity-saving opportunities.

Garcia, F. D., Marafao, F. P., d. Souza, W. A. and d. Silva, L. C. P. (2017). Power metering: History and future trends, *2017 Ninth Annual IEEE Green Technologies Conference (GreenTech)*, pp. 26–33.

Gungor, V. C., Sahin, D., Kocak, T., Ergut, S., Buccella, C., Cecati, C. and Hancke, G. P. (2011). Smart grid technologies: Communication technologies and standards.

Harney, A. (2009). Analog dialogue: Smart metering technology promotes energy efficiency for a greener world.

Hart, G. W. (1992). Nonintrusive appliance load monitoring, *Proceedings of the IEEE* **80**(12): 1870–1891.

Isa, M. A. H. M., Latip, M. F. A., Zaini, N. and Alias, Y. F. (2015). Android-based application for real time energymonitoring of domestic electricity, *IEEE Conference on Systems, Process and Control (ICSPC 2015)* .

Kádár, P. (2011). Smart meter based energy management system.

Kempener, R., Komor, P. and Hoke, A. (2013). Smart grids and renewables: A guide for effective deployment.

Landi, C., Merola, P. and Ianniello, G. (2011). Arm-based energy management system using smart meter and web server, *IEEE International Instrumentation and Measurement Technology Conference* .

Makonin, S., Popowich, F. and Gill, B. (2013). The cognitive power meter:looking beyond the smart meter, *26th Annual IEEE Canadian Conference on Electrical and Computer Engineering (CCECE)* pp. 1–5.

Mohassel, R. R., Fung, A., Mohammadi, F. and Raahemifar, K. (2014). A survey on advanced metering infrastructure, *International Journal of Electrical Power & Energy Systems* pp. 473–484.

Naghibi, B. and Deilam, S. (2014). Non-intrusive load monitoring and supplementary techniques for home energy management, *Australasian Universities Power Engineering Conference (AUPEC)* .

Opris, I. and Caracasian, L. (2013a). On the implementation of the functionalities of smart metering systems, *8th International Symposium on Advanced Topics in Electrical Engineering (ATEE)* pp. 1–6.

Opris, I. and Caracasian, L. (2013b). The relation between smart meters and electricity consumers, *12th International Conference on Environment and Electrical Engineering (EEEIC)* **1**(1): 325–329.

Souza, W. A. (2016). *Estudo de Técnicas de Análise e Tecnologias para o Desenvolvimento de Medidores Inteligentes de Energia Residenciais*, PhD thesis, FEEC/UNICAMP.

Weranga, K. S. K., Chandima, D. P. and Kumarawadu, S. P. (2012). Smart metering for next generation energy efficiency & conservation, *IEEE PES Innovative Smart Grid Technologies* (1): 1–8.

Wood, G. and Newborough, M. (2002). Dynamic energy-consumption indicators for domestic appliances: environment, behaviour and design, *Energy and Buildings* .

Xu, Y. and Milanović, J. V. (2015). Artificial-intelligence-based methodology for loaddisaggregation at bulk supply point, *IEEE Transactions on Power Systems* **30**(2).

Zheng, J., Gao, D. W. and Lin, L. (2013). Smart meters in smart grid: An overview, *IEEE Green Technologies Conference* pp. 57–64.

Zhou, L., Xu, F.-Y. and Ma, Y.-N. (2010). Impact of smart metering on energy efficiency.

2017 Ninth Annual IEEE Green Technologies Conference

Power Metering: History and Future Trends

Fernando Deluno Garcia, Fernando Pinhabel Marafão
GASI – Group of Automation and Integrated Systems
Univ Estadual Paulista (UNESP)
Sorocaba, Brazil
fernando.delunogarcia@gmail.com,
fmarafao@sorocaba.unesp.br

Wesley Angelino de Souza, Luiz Carlos Pereira da Silva
DSE/FEEC – Department of Systems and Energy
State University of Campinas
Campinas, Brazil
{wesley, lui}@dsee.fee.unicamp.br

***Abstract*—Considering the rising demand for electricity around the world, several technologies have been developed to provide a more efficient and modern power system. In this context, the smart grid concept is related to the integration and management of different power system devices, aiming to provide technical, economic, social and environmental benefits. Thus, the smart meter has become one of the main elements in smart grids and it may provide much more capabilities than the conventional electromechanical and electronic energy meters. Therefore, this paper discusses the main differences between smart and conventional power meters, pointing to the new features, methodologies and applications of modern smart meters. Moreover, this paper deals with the definition of "smart", introducing possible functionalities and applications that can effectively impact on the understanding of the energy consumption, while allowing to improve power management and energy efficiency.**

Keywords- cognitive meter; energy meter; smart grid; smart meter; power meter.

I. INTRODUCTION

The world growing demand for electricity brings up important issues about how to supply such energy needs in a sustainable manner [1]. It has been necessary to look for alternatives that allow the efficient use of energy, following the sustainable development concept, on which the electricity is considered a fundamental resource for the socioeconomic development and an essential asset for the maintenance of life in society [1-3].

Consequently, the improvement of the electrical system by means of all possible high-tech advances is imperative. Therefore, several modifications in the existing network infrastructure and operational procedures are expected for the future smart grids, what may ensure that all entities are interconnected and operating to guarantee the best use of primary energy resources and all other infrastructure related to generation, transmission, distribution and use (GTDU) of energy, from producers to consumers.

In such context, the power meters are very important elements in the smart grid concept [2, 4], since they are the basic device to connect different GTDU equipment over the grid, either point-to-point or by means of hierarchical supervisory systems. Thus, electromechanical meters have been replaced by electronic meters to meet the needs of the modern power grids [5-6]. Recently, these electronic meters have been called as smart meters and among other features, they should provide superior accurate measurements, data storage, automatic data reading and integration to local or wide-area energy management systems [2, 4, 7].

Regarding to the "smart" definition and considering worldwide utilities and manufactures, there is no consensus about what should "smart" mean and which features should be essential. In some cases, the smart meter is an electronic meter that differs from traditional devices just by its bidirectional communication link or four-quadrant power metering [5, 8, 45]. This issue has been highlighted in the literature and possible enhancements have been proposed for real smart meters. One of the major innovations proposed focuses on consumption disaggregation in terms of appliances or residential loads [5, 8-11] and this new feature has driven to a new concept of smart meters called cognitive meters [5,12].

Therefore, assuming that a cognitive meter and its related supervisory system should be able to provide detailed reports of consumption, load disaggregation, power quality indicators and other relevant information, this concept points to the next generation of smart meters, which may benefit both consumers and utilities.

Although the increased complexity, such idea of cognitive smart metering and its interface with supervisory and energy management systems may motivate the development of novel equipment and methodologies in order to improve power systems controllability, efficiency, reliability, sustainability and safety. It should also inspire new markets and demand for a revolution in the operation of energy distribution utilities and their integration to local distributed generators and wide-area transmission and generation systems. In this sense, power meter modernization is an essential issue for the electricity market and for the modern society.

Following the evolution of the new smart meters, standards have being developed with the intention of establishing procedures for devices and communication technologies to guarantee the consumer acceptance of the smart meters in their homes and business.

Hence, considering that present power meter technologies are still much behind their potentials, in terms of functionalities and what they could provide for consumers and utilities in modern power grids, this paper presents a brief review of power meters' history and the limitations of conventional technologies and discusses the potentials of new "smart" technologies and related issues.

2166-5478/17 $31.00 © 2017 IEEE
DOI 10.1109/GreenTech.2017.10

II. A BRIEF OUTLINE OF POWER METERS EVOLUTION

The ability to manage and control electric power GTDU has always been related to this basic element, the power meter [13,14]. These devices are developed to measure and record the energy consumption in single-phase or three-phase consumer units, independently of their current and voltage levels or frequency definition. Such information is traditionally used for the power system plaining, operation and for charging consumer's use of energy. Thus, next sections present a brief overview of the energy meter evolution in the last decades.

A. Electromechanical Meter

Considering the international scenario, the electromechanical power meters are still a widely applied technology, especially for residential consumers. Although a well-known technology, the electromechanical meter shown in Fig. 1 (a) presents several limitations due to its constructive characteristics. In general, electromechanical meters are not highly accurate and its measurement may be affected by many factors, such as: waveform distortions or imbalance, operation temperature, among others. In addition, this category of energy meter can only measure the active or average power component and basically considering unidirectional power flow, mostly for revenue purposes [15].

As depicted in Fig, 1 (b), other important limitation related to this technology is the fact that the energy measurement typically requires manual or human reading (by the utility personnel), what is certainly more susceptible to reading errors. Besides, it should be emphasized that such process represents a high operational cost for the utilities, which are basically transferred to the consumers in the energy tariffs.

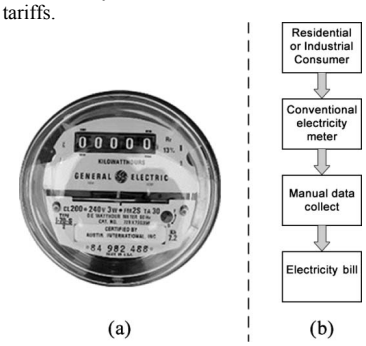

Figure 1. (a) Electromechanical meter and (b) The conventional electricity metering system [18, 25].

B. Electronic power meters

Considering the evolution of electronic and microelectronic devices in the last decades, several solutions have arisen for the problems related to the electromechanical meter. Thus, the first electronic meters were developed, as shown in Fig. 2, and the main goals were associated to the improvement of measurement accuracy and the reduction of operational measuring costs.

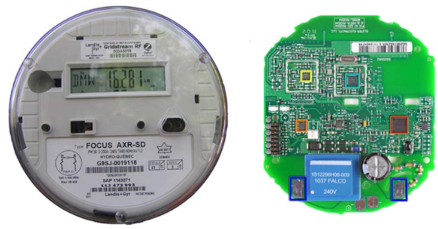

Figure 2. Solid state electronic meter [18].

The concept of electronic meters was called AMR (Automated Meter Reading) [16]. Specifically, AMR is a system that enables utilities to access remotely the data generated by electronic meters at consumer units [17-18]. The data can be transmitted from the meter to the utility company by radio frequency, telephone, power line or satellite communication [14].

The evolution of the AMR concept was called AMI (Advanced Metering Infrastructure). The main difference between these categories is in the communication approach, since the AMI enables the possibility of data exchange between utility and consumer, in bidirectional mode. Thus, the AMI shown in Fig. 3 can be represented as a system with electronic meters, data storage, management system and communication infrastructure [14].

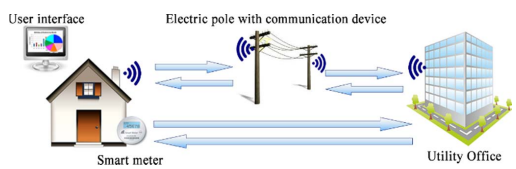

Figure 3. AMI. (source: edgefx.in).

The main features of the AMR/AMI systems are [17]:

- **Electronic meters**: perform energy measurements and provide communication between consumer and utility.
- **Management system**: is composed of a data concentrator and signal processing unit.
- **Communication infrastructure**: Establish the means of communication for the data transmission between the network elements.

C. "Smart" Measurement of the Electric Power

With the dissemination of the electrical smart grids, AMI has being known as Smart Metering System (SMS), as illustrated in Fig. 4. This new concept has been developed in a fast way during the last years and it has been driven by the technological progress and by the need to obtain data that cannot be provided by the traditional metering systems [8]. In this scenario, the smart meter is considered a pillar of the smart grid evollution [4].

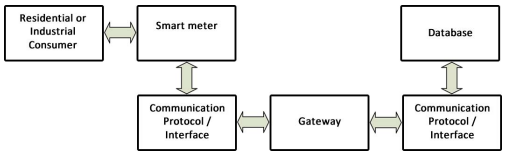

Figure 4. Smart Metering System [25]. (bidirecional communication between utility and consumer point).

Several new methods have been proposed and applied to obtain innovative data concerning to the energy consumption and/or power quality. Therefore, smart meters can be seen as a power meters sophistication used to solve or point to energy transfer or consumption problems [19]. Table I brings up the main issues of smart metering by a quick comparison between the AMR and AMI.

TABLE I. COMPARISON AMONG ENERGY METERING TECHNOLOGIES

	Technologies		
	Manual/AMR		***AMI/SMS***
Power Meter	Eletro-mechanical	Eletronic	Eletronic/Solid State
Data Collection	Manual	Drive-by Systems	Fixed Network Systems
Data Recording	Monthly	Hourly or more frequently	Hourly or more frequently
Data Transfer	None	Single way	bi-directional
Customer feedback	Monthly energy consumption		In-home display, detailed feedback on energy use
Bills	Monthly bill		Pricing Programs
Fault Detection	Customer contact		Automatic
Demand Management	None		Power peaks rebate, load control
Security/ Threats	Meter tampering only		Meter tampering, false data injection, cyber security threat, personal data privacy
Problems and Challenges	Lack of control and monitoring operations		Transitioning to new technology and systems, disposal of the old meters

However, despite of the great advancements, the rapid development of these new technologies (AMR, AMI and SMS) has not allowed the consolidation of smart metering methodologies and related technologies. Thus, the smart meter development has been boosted by numerous technical publications [2-8, 18-19, 27-31] and recommendations from different associations [40-42], while proper standards are still being established in different countries, according to the conditions and intentions of use. Unfortunately, many utilities are substituting their power meters, mostly transferring the costs to the consumers, without any guarantees that this will not be necessary again in the near future, for matching new requirements for managing and controlling the modern and smart grid scenario as shown in Fig. 5.

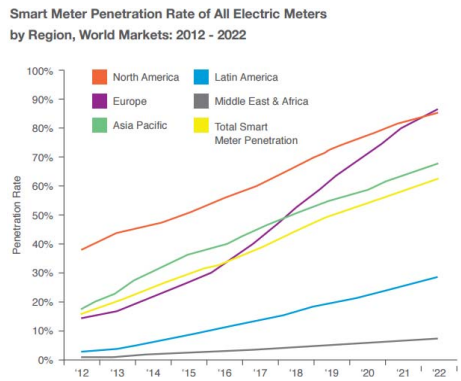

Figure 5. Smart Meter Penetration Rate (source: Navigant Research).

There is an estimate of almost 800 million smart meter will be installed by 2020 around the world. The penetration rate of these devices varies among regions and it is increased by policy and legislative incentives, such as in Europe and North America [46]. Despite the great initial investments in North America, it is estimated an almost constant development for the near future, especially due to the cautiousness perspective for the uncertain future approaches. However, other countries like China and Japan have being doing substantial incentives for the smart meters use. The lowest penetration rate is in Latin America, Middle Est and Africa, where the use of smart meters is set to steady growth [46].

III. ENERGY SMART METERS

Smart meters are different from each other in three basic characteristics [20]: The possibility of consumption reading in a higher frequency, regular data communication and bidirectional communication (usually between the utility and the smart meter). Fig. 6 presents a commercial smart meter.

Figure 6. Commercial smart meter.

A. General features

Regarding the elementary functions, a smart meter should record, in real time, active power consumption and also other relevant information, such as: voltage and current phasors, reactive power, maximum power demand, frequency and power factor [21]. In general, commercial smart meters have the following characteristics [4]:

- User interface display.
- Internal memory for data storage.
- Capability of remote connection or disconnection of the consumer installation.
- Bidirectional communication between utility and consumer.

Moreover, many technologies have been evaluated and many manufactures are producing smart meters with additional functionalities. Among several commercial smart meters around the globe, the authors identified the following additional features [22]:

- Power quality monitoring, especially for fault detection and voltage quality analysis.
- Different time events recording, especially for fraud detection, energy price time changing, violation of maximum contracted power, etc.
- Demand control with capability to limit the load power at the measurement point.
- Programmable acquisition sampling rate.
- Data storage in memory.
- Calendar-based electricity bill calculated in the smart meter.
- Two-way communication for remote reading or for pre-payment systems, credit purchase, software upgrade, etc.
- Microgeneration support.
- Immunity to phase inversion.
- Automatic low voltage and voltage fault detection.
- Remote firmware update.

Regarding to the construction of a smart meter, in general it includes a set of hardware, software and metering system [2, 12, 15, 23], consisting on:

- Current and voltage sensors.
- Analogue and signal pre-processing circuits.
- Supply circuit.
- Data acquisition and processing unit.
- Communication module.
- Real time clock.

A simplified smart meter diagram can be seen in Fig. 7.

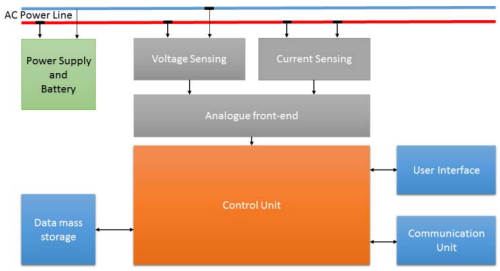

Figure 7. Smart meter modules diagram [23].

Specifically, the signal conditioning and sensors units are used to match the measured quantities to the analog-to-digital conversion (ADC) circuits and then to provide the converted current and voltage values to the processing unit. In addition, it is uses the real-time clock (RTC) to provide the measurements date and time.

The smart meter main module is the processing unit, on which the data acquisition, data processing, data storage and data transmission are performed. Devices such as microcontrollers, digital signal processors (DSP) or systems-on-chip (SOC) can constitute the processing unit.

Among the communication technologies, two most promising communication technologies for smart meters are [18, 23-24]: wireless for short distances and the power line communication (PLC). These technologies have some advantages and disadvantages, for example, the wireless communication infrastructure has lower cost and it can be used in difficult access areas. However, wireless is energy dependent and it may suffer interferences from the means of signal propagation [24]. On the other hand, PLC can be used to reach remote areas, but it has a high cost of implementation and it does not offer high transmission rate [2].

Therefore, factors like transmission bandwidth, transmittable range, communication security and need for signal repeaters should be analyzed to determine the most efficient choice [25]. Other possible transmission technologies are [24-27]: Broadband over Power Lines (BPL), Optical fiber, Cellular networks, WiMAX, Bluetooth, GPRS, Internet, Satellite, Peer-To-Peer, ZigBee, IEEE 802.16e, Long-rage RF (LRRF), 6LowPAn and Z-wave.

IV. Relevant Aspects and Benefits

The paybacks of energy smart metering benefits are numerous and may benefit [28]: a) consumers, b) power utilities (sectors of power generation, transmission and distribution), c) environment and society. However, the design, development and maintenance of a smart metering system involve many problems and challenges. The society acceptance can be challenging and delayed because people and companies must be clearly persuaded and aware of possible advantages of these new devices. They need to understand the reasons for the replacement and the changes that will occur to accept and install them [2, 8, 25]. There are some challenges and uncertainties, such as:

- Investments justification.
- Impacts caused during the technology transition.
- Fear of losing privacy and the risks that smart meters can generate.
- Uncertainty about the energy prices and information security.
- Fear of jobs reduction due to automated data collection.

Therefore, it should be emphasized the value that can be generated with the smart metering are proportional to its functionalities and its correct use [7]. In this sense, data analysis is one of the main factors that will determine the success of the application of smart meters, which consists of data acquisition, transmission, processing and interpretation [28]. Following, some advantages will be mentioned from three different points of view: consumers, energy utilities, environment and society.

A. Consumers

Consumers can have benefits in several ways, since they may be able to estimate their electricity bills, to manage their energy consumption and to receive information that can be used to review their consumption behavior [4, 7].

Among the new features, the ability to receive information can favor feedback programs. These programs have potential to reduce electrical energy consumption by the interaction created with the consumer [3, 29].

In [30], results of 36 studies completed from 1995 to 2010 point that the possibility of reducing electricity consumption in households can reach values between 4% and 12%. The employed techniques can be categorized in direct and indirect methods. In indirect method, the consumption information is provided periodically after consumption has occurred. In direct method, the notifications are generated in real time. The direct method presented a great reduction potential.

In general, consumers can have benefits such as:

- Knowledge of consumption behavior.
- Better quality of electric service.
- Remote measurement.
- Assistance about use of appliances in peak hours.
- Adaptive billing mechanisms.
- More information in energy bills.
- Energy awareness and rational use.

B. Electric Power Utilities

To the energy utilities, information about consumer units can be collected remotely and in real time. This allows the creation of new pricing programs and may result in operational costs reduction [2, 4, 19].

Consumption data can be used to provide information that can encourage consumers to use energy in a rational way, thereby, in short time it reduces the need to expand the grid infrastructure. Another function is the consumer unit monitoring, that is, the ability to connect/disconnect the consumer unit from the power grid or to control non priority loads [25].

In addition, the consumption peak can be monitored and managed in an efficient way [4, 19]. This technique is called "Demand Response" and it has been seen as a solution for reducing the power demand and for ensuring the best use of existing resources, in order to increase energy efficiency and to reduce energy costs [2, 19-20].

Distribution companies can benefit and improve their market models and pricing, based on power consumption mapping.

From the market point of view, new energy pricing programs can be created, such as the Critical Peak Pricing (CPP), in which utilities notify the customers when the power demand is close to the pre-set values. In this case, the consumers that reduce consumption are rewarded [20, 31]. Other charging proposal is about the Time-of-Use (TOU) where the energy price is established in relation to the period of the day. Other solution is the Real Time Pricing (RTP), on which the energy price is regularly adjusted during the day [31]. Thus, the main smart meter benefits from the utility point of view are:

- Facilitates failure detection, reducing the restoration time.
- Keeps consumers informed about the operation status of the power grid, for example, when there is a blackout and the estimated time to reestablish the service.
- Improves the planning and management of the power system.
- Allows power peaks demand reduction.
- Allows automatic and remote meter reading.
- Enables the efficient management of power resources for the power generation.
- Allows the consumer connection/disconnection from the utility remote controllers.
- Increases the information about consumption in low voltage grids.
- Reduces operational costs.

C. Environment and Society

The smart metering is considered one of the main functions of a smart power grid [15] and the main goal is to achieve greater energy efficiency [2]. In that sense, the benefits that can be generated are beyond of those highlighted before, because they can affect the entire society. So, the main benefits from the society point of view are [2, 4, 7]:

- The increasing of efficiency and quality of electric service.
- The improvement of existing energy resources use.
- Indirectly related to CO2 emission reduction.
- Reducing of the electricity demand due to the electrical consumption awareness.
- New technologies development stimulation.
- The development of new forecast techniques to the electricity demand.

D. Privacy and Standards

Fig. 8 presents the communication structure of a smart meter system, most of them wireless.

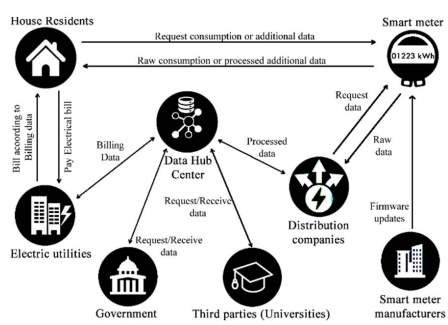

Figure 8. Communication diagram of a Smart Metering System.

In this way, there are several communication channels between the smart meter and utility. In this structure the data passes to distribution systems, data hub center, and it was possible to have data requests from the government and third parties. All these channels become susceptible to have interference, intrusions and ethical issues related to the use of data from smart meters, leading to a real of privacy violation and other distrusts.

Several organizations around the world are opposing the smart meters installation, like StopSmartMeters! [36] that strongly condemns the use of smart meters raising several issues as privacy violation, exposure to microwave radiation from the wireless signals, jobs losses and the increase of the bill by the accuracy metering. Other associations around the world are following the same line of ideas as in United Kingdom [37] and some doctors emphasize health effects [38]. As several other new technologies have suffered negative criticism [39], the smart meters utilization and development may not be discontinued because there are several expected benefits to consumers and power utilities.

In this context, a common standard used around the world is the International Electrotechnical Commission (IEC). The IEC, with the Technical Committee 13 (TC 13), provide specifications for Equipment for electrical energy measurement, tariff and load control [40]. Another standard is the American National Standards Institute (ANSI), with the ANSIC12. Like the IEC, the ANSIC12 covers aspects about electrical energy measurement and communications protocols. This standard is mostly used in North American markets, mainly in Canada, Mexico and the United States [41].

Some countries use different sets of standards. In Europe, the European Committee for Standardization (CEN) and the European Committee for Electrotechnical Standardization (CENELEC) are responsible for the development of European Standards and standardization in the electrotechnical field, respectively. However, the CENELEC also have a close collaboration with the IEC [42]. Other countries like Australia use a mix of ANSI and IEC standards [40], while the Brazilian Market is standardized by ABNT (Standard 14522, Brazilian Association for Technical Standards) [43] and by ANEEL (Normative Resolution 502, Brazilian National Agency of Electrical Energy) [44].

Therefore, it is imperative an initiative to synchronize current standards, to prevent the development of different standards with the same purpose and to ensure the long-term viability of these applications.

V. Cognitive Energy Meters

As previously mentioned, the SMS technology has undoubtedly brought several evolutions to the electricity metering systems, but the "smart" term requires consolidation to identify the meter class required to develop the future power system. The ability to read apparent power in four quadrants, locally or remotely, is not enough to be considered a smart meter.

Thus, several ways of adding more intelligence to the meters have been presented [8-35]. One of the keys to the smart meter evolution is certainly the load disaggregation capability. This functionality can be obtained using the method called Non-Intrusive Load Monitoring (NILM) initially proposed by Hart [10], which makes use of a pattern recognition method to identify appliances power signature [9], simply using the metering point at the Point of Common Coupling (PCC). Other method of load monitoring is called Intrusive Load Monitoring (ILM) or distributed monitoring, which is based on sensors distribution at measuring points as electrical sockets or appliances. The ILM is said intrusive because has the need to install measuring devices at each point of interest [32].

Between the ILM and NILM, the NILM has attracted more interest because it is more practical for residential applications mainly due to the advantages of using only one measuring instrument and connection [32]. The simplest NILM method involves identifying the changing of the load power state, that is, when the load changes the power consumption or it is on or off. This method has several advantages because it enables to create representative models of a residence using state machine concept. Such models can be used for data analysis through several techniques found in literature [9, 10, 33].

Although these models are simple and they do not show high accuracy in relation to the individual consumption of appliances with complex power signatures, like a LCD television. In this sense, state machine models discard significant information that can be used for analysis [9, 33]. For the accuracy detection and exact monitoring, it is necessary to consider that the loads have variations over the time [9, 10].

The NILM technique analyzes the power grid in order to detect events that characterize the load power signature. This procedure can be seen in Fig.9 and it is represented by six states. Briefly, first the voltage and current data are collected. Next, this data is processed to detect appliances that are operating. After that, an algorithm is executed to identify which appliance (load) is consuming energy according to the power values over the time (appliance power signature). Finally, the appliance consumption is evaluated.

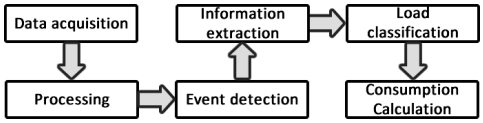

Figure 9. Stages of the Non-Intrusive Load Monitoring (NILM) process.

Therefore, the NILM technique can be considered as an effective tool for collecting load information and can also encourage other applications [10]. Thus, from this point of view, the concept of smart meter can be redefined, being called cognitive meter. With the cognitive meters concept and implementation, it is possible to extract relevant information about the electric energy consumption of each type of load [5].

It should be noted that this information is extremely important for consumers to know their habits and to make efficient decisions regarding the consumption of electricity. Therefore, the cognitive meter can be used to provide

consumption suggestions, based on statistical data and knowledge of consumer habits [7].

In order to interact with consumers, it is possible to use In-Home-Display (IHD) interfaces [3, 28], as shown in Fig. 10. These meter interfaces must be intuitive and must provide information in a representative way, facilitating the understanding of the data by the consumers [7, 29]. In addition, connectivity and accessibility will be essential to empower the user experience. Such requirements are favored by the advancement of communication technologies, especially by the wireless technology. In this sense, the user interface can be also performed through web systems or mobile applications [34-35].

Figure 10. In-home Display. (Source: iecetech.org).

Interfaces aim to increase the interaction among the consumer, the device and the utility. Thus, this consumption information can be displayed based on comparisons with previous periods, meaning that consumers should not worry about what is, e.g., a kWh [3]. Therefore, it is possible to customize the system to provide some recommendations to the consumer [27], as for example:

- This weekend's consumption was higher than last week.
- Your weekly consumption is 30% higher than the standard.
- Tomorrow the maximum temperature will be 39ºC. When you "turn on" the air conditioning, try to avoid unnecessary window and door openings.
- Your consumption this morning was low, but was twice as high as the previous day.
- Your refrigerator is draining 20% more power than specified on its category certification.

This interaction and capacity of load management allow consumers to regulate their own consumption according to the desired degree of comfort [11]. In addition, consumption awareness of each load is a prerequisite for the development of sophisticated energy management techniques that can increase energy efficiency [10, 33].

With consumption reports, consumption strategies, and consumption forecasting, the consumers may be concerned about the correct electricity use and they may seek ways to save electricity. From the utility's point of view, the modeling and prediction of loads can aid the planning, operation and increase of the power grid efficiency. In this way, the load disaggregation strategy has many benefits and may become an interesting trend for the future generation of truly smart meters.

VI. Conclusion

This paper presented an overview of electrical energy metering systems emphasizing its basic element: the power meter. Measurement of electricity is essential to the electrical system operation, being important both for the power management and energy charging, and to ensure the reliability and safety to the system.

Due to the development of smart grids and the latent needs for power management improvements and maximum energy efficiency, the use of smart meters was emphasized. Then, possible advantages and benefits that can be obtained from the consumers' perspective, power utilities' and society's points of view were discussed.

In addition, the new features that characterize the meter as "smart" have been put in perspective in order to present new solutions that can enhance the use of these type of meters, mainly for the ability to extract relevant information about the electricity consumption. Therefore, the use of these devices transcends their basic function, breaking the current paradigm of electric energy meters and creating a new concept of meters: the cognitive meter. This meter can become an essential element to ensure the consumers' awareness about the electric energy consumption and to increase the energy efficiency. From the utilities point of view, especially the distributors, the installation of truly smart meters may allow a more efficient grid management, while renewing the entire consumer-provider relation.

References

[1] G. Platt, S. West, T. Moore, "The real-world challenges and opportunities of distributed generation", IEEE Energy Conversion Congress and Exposition, pp. 1112-1116, September 2015.

[2] G. R. Barai, S. Krishnan and B. Venkatesh, "Smart Metering and Functionalities of Smart Meters in Smart Grid - A Review," *Electrical Power and Energy Conference (EPEC)*, pp. 138-145, 26-28 October 2015.

[3] S. Makonin, F. Popowich, T. Moon and B. Gill, "Inspiring Energy Conservation Through Open Source Power Monitoring and In-Home Display," *IEEE Power & Energy Society General Meeting*, pp. 1-5, 21-25 July 2013.

[4] J. Zheng, D. W. Gao and L. Lin, "Smart Meters in Smart Grid: An Overview," *IEEE Green Technologies Conference*, pp. 57-64, 4-5 April 2013.

[5] S. Makonin, F. Popowich and B. Gill, "The cognitive power meter: Looking beyond the smart meter," *26th Annual IEEE Canadian Conference on Electrical and Computer Engineering (CCECE)*, pp. 1-5, 5-8 May 2013.

[6] S. Makonin, L. G. Flores, R. Gill, R. A. Clapp, L. Bartram and B. Gill, "A Consumer Bill of Rights for Energy Conservation," *IEEE Canada International Humanitarian Technology Conference - (IHTC)*, pp. 1-6, 1-4 June 2014.

[7] I. Opris and L. Caracasian, "The relation between smart meters and electricity consumers," *12th International Conference on Environment and Electrical Engineering (EEEIC)*, pp. 325-329, 5-8 May 2013.

[8] I. Opris and L. Caracasian, "On the implementation of the functionalities of smart metering systems," *8th International Symposium on Advanced Topics in Electrical Engineering (ATEE)*, pp. 1-6, 23-25 May 2013.

[9] W. Xu, M. Dong, P. Meira and W. Freitas, "An event window based load monitoring technique for smart meters," *IEEE PES General Meeting | Conference & Exposition*, p. 1, 27-31 July 2014.
[10] G. W. Hart, "Nonintrusive appliance load monitoring," *Proceedings of the IEEE*, vol. 80, nº 12, pp. 1870-1891, 1992.
[11] K. Basu, V. Debusschere, S. Bacha, U. Maulik and S. Bondyopadhyay, "Nonintrusive Load Monitoring: A Temporal Multilabel Classification Approach," *IEEE Transactions on Industrial Informatics*, vol. 11, nº 1, pp. 262-270, 2014.
[12] M. R. Durling, Z. Ren, N. Visnevski and L. E. Ray, "Cognitive electric power meter". *Patente US* 11/893,170, 2009.
[13] Electric Power Research Institute (EPRI), "Accuracy of Digital Electricity Meters". May 2010. [Online]. Available: http://www.silverspringnet.com/pdfs/smart_meters_epri.pdf.
[14] N. S. Živic, O. Ur-Rehman and C. Ruland, "Evolution of smart metering systems," *Telecommunications Forum Telfor (TELFOR)*, 23rd, pp. 635-638, 24-26 November 2015.
[15] K. S. K. Weranga, S. Kumarawadu and D. P. Chandima, Smart Metering Design and Applications, *Springer*, 2014.
[16] L. Li, X. Hu, J. Huang and K. He, "Research on the architecture of Automatic Meter Reading in Next Generation Network," *6th IEEE International Conference on Industrial Informatics*, pp. 92-97, 13-16 July 2008.
[17] H. A. Foudeh and A. S. Mokhtar, "Automated Meter Reading and Advanced Metering Infrastructure projects," *9th Jordanian International Electrical and Electronics Engineering Conference (JIEEEC)*, pp. 1-6, 12-14 October 2015.
[18] A. Harney, "Analog Dialogue: Smart Metering Technology Promotes Energy Efficiency for a Greener World," January 2009. [Online]. Available: http://www.analog.com/library/analogdialogue/archives/43-01/smart_metering.pdf.
[19] K. S. K. Weranga, D. P. Chandima and S. P. Kumarawadu, "Smart metering for next generation energy efficiency & conservation," *IEEE PES Innovative Smart Grid Technologies*, pp. 1-8, 21-24 May 2012.
[20] R. Kempener, P. Komor and A. Hoke, "SMART GRIDS AND RENEWABLES: A Guide for Effective Deployment," *International Renewable Energy Agency (IRENA)*, 2013.
[21] Y. Kabalci, "A survey on smart metering and smart grid communication," *Renewable and Sustainable Energy Reviews*, vol. 57, pp. 302-318, 2016.
[22] Centro de Gestão e Estudos Estratégicos (CGEE), "Redes Elétricas Inteligentes: Contexto Nacional," 2013. *In Portuguese.*
[23] Analog Devices, "Wireless Technologies for Smart Meters," August 2011. [Online]. Available: http://www.analog.com/media/en/technical-documentation/technical-articles/MS-2200.pdf.
[24] V. C. Gungor, D. Sahin, T. Kocak, S. Ergut, C. Buccella, C. Cecati and G. P. Hancke, "Smart Grid Technologies: Communication Technologies and Standards," *IEEE Transactions on Industrial Informatics*, vol. 7, nº 4, pp. 529-539, 2011.
[25] S. S. S. R. Depuru, L. Wang, V. Devabhaktuni e N. Gudi, "Smart meters for power grid — Challenges, issues, advantages and status," *Power Systems Conference and Exposition (PSCE)*, IEEE/PES, pp. 1-7, 20-23 March 2011.
[26] R. R. Mohassel, A. Fung, F. Mohammadi and K. Raahemifar, "A survey on Advanced Metering Infrastructure," *International Journal of Electrical Power & Energy Systems*, vol. 63, pp. 473-484, 2014.
[27] P. Kádár, "Smart meter based energy management system," *International Conference on Renewable Energies and Power Quality (ICREPQ'11)*, 13-15 April 2011.
[28] D. Alahakoon and X. Yu, "Smart Electricity Meter Data Intelligence for Future Energy Systems: A Survey," *IEEE Transactions on Industrial Informatics*, vol. 12, nº 1, pp. 425-436, 18 March 2015.
[29] L. Zhou, F.-Y. Xu and Y.-N. Ma, "Impact of smart metering on energy efficiency," *2010 International Conference on Machine Learning and Cybernetics*, pp. 3213-3218, 11-14 July 2010.
[30] K. Ehrhardt-Martinez, K. A. Donnelly and J. A. ". Laitner, "Advanced Metering Initiatives and Residential Feedback Programs: A Meta-Review for Household Electricity-Saving Opportunities," *American Council for an Energy-Efficient Economy (ACEEE)*, 2010.
[31] G. Deconinck and B. Decroix, "Smart metering tariff schemes combined with distributed energy resources," *Fourth International Conference on Critical Infrastructures*, 2009. CRIS 2009, pp. 1-8, 27-30 March 2009.
[32] B. Naghibi and S. Deilami, "Non-intrusive load monitoring and supplementary techniques for home energy management," *Power Engineering Conference (AUPEC), 2014 Australasian Universities*, pp. 1-5, 28 October 2014.
[33] S. Barker, S. Kalra, D. Irwin and P. Shenoy, "Empirical Characterization, Modeling, and Analysis of Smart Meter Data," *IEEE Journal on Selected Areas in Communications*, vol. 32, nº 7, pp. 1312-1327, 2014.
[34] M. A. H. M. Isa, M. F. A. Latip, N. Zaini and Y. F. Alias, "Android-based application for real time energy monitoring of domestic electricity," *IEEE Conference on Systems, Process and Control (ICSPC)*, pp. 134-139, 18-20 December 2015.
[35] C. Landi, P. Merola and G. Ianniello, "ARM-based energy management system using smart meter and Web server," *IEEE Instrumentation and Measurement Technology Conference (I2MTC)*, pp. 1-5, 10-12 May 2011.
[36] Stop Smart Meters! Organization, Portola, California, United States, available on http://stopsmartmeters.org/about/
[37] Stop Smart Meters United Kingdom Organization [Online]. Available: http://stopsmartmeters.org.uk/
[38] Hudson, G., "Not-so-smartmeters", *What Doctors Don't Tell You Magazine*, pp 52-54, May 2014.
[39] Ray, B., "Why the Apple phone will fail, and fail badly," *The register*, 2007.
[40] A comparative introduction to ANSI metering standards [Online]. Available: https://www.metering.com/a-comparative-introduction-to-ansi-metering-standards/
[41] USITC, "Global Market for Smart Electricity Meters: Government Policies Driving Strong Growth", *U.S. International Trade Commission*, 2014.
[42] CEN/CENELEC/ETSI, "Recommendations for smart grid standardization in Europe Standards for Smart Grids", *CEN/CENELEC/ETSI Joint Work Group on Standards for Smart Meters*, 2011.
[43] ABNT, "NBR 15522 - Data exchange for electricity metering systems", *Brazilian Association for Technical Standards*, 2008. *In Portuguese.*
[44] ANEEL, "Normative Resolution 502 - Regulates electric energy metering systems of Group B consumer units," *Brazilian National Agency of Electrical Energy*, 2012. *In Portuguese.*
[45] IEC 61968-2, "Application integration at electric utilities - System interfaces for distribution management - Part 2: Glossary", *IEC - International Electrotechnical Commission*, 2011.
[46] GSGF, "Smart Meter Security Survey", *The Global Smart Grid Federation*, 2016. Available: http://www.globalsmartgridfederation.org.

Refrigeradores residenciais: monitoramento e análise comparativa entre modelos distintos

Rafael Cuerda Monzani, João G. Ito Cypriano, Hader A. D. Azzini, Wesley A. Souza, Augusto C. Venerando, Rodrigo Marssola Garbelotti, Luiz Carlos Pereira da Silva

[1]***Resumo* – A presença de refrigeradores em residências no Brasil superou a margem de 96% do total existente, com crescimento linear desde 2001. O uso de refrigeradores representa uma parcela significativa do consumo de energia elétrica, atingindo em certos casos, proporções em torno de 25% do total consumido. Este artigo analisa o consumo de energia de diferentes tipos de refrigeradores, observando aspectos qualitativos como característica de funcionamento, modelos e quantitativos como capacidade, número de portas e comportamento dos residentes. A aquisição dos sinais de tensão e corrente foi obtida por meio de um analisador de energia. Dados complementares (potência ativa e reativa, fator de potência, correntes harmônicas) responsáveis por construir o perfil elétrico de cada refrigerador também foram fornecidos. Com base na curva de carga e nas características da assinatura elétrica, premissas são estabelecidas visando obter recursos para avaliar os diferentes modelos monitorados, estabelecendo uma análise comparativa entre capacidade, consumo e eficiência.**

***Palavras-chave* –Análise comparativa, Aquisição de sinais, Assinatura elétrica, Consumo de energia, Monitoramento de cargas.**

I. Introdução

Conhecer o comportamento das variáveis associadas à dinâmica de um equipamento possibilita a antecipação e a solução de possíveis falhas, isto é, quando o comportamento se desvia do padrão conhecido isso sugere a existência de falhas e as características do desvio podem ser usadas para se decidir quais ações devem ser tomadas. Em relação às cargas elétricas residenciais, para conhecer as variáveis que as caracterizam, torna-se necessário realizar processos de monitoramento a fim de construir um perfil da assinatura elétrica [1] das cargas de interesse. Diferentes metodologias de monitoramento podem ser aplicadas às medições de cargas elétricas residenciais [2]-[4].

Os medidores inteligentes (*smart meters*) atuais mostram apenas o consumo total de energia elétrica, sem apresentar detalhes de como tal energia é consumida. A discriminação do uso individual de cargas elétricas permite ao consumidor conhecer seu padrão de consumo [5] e este conhecimento pode ser utilizado para numerosos fins, entre os quais se destacam: redução dos gastos com energia elétrica, tarifação diferenciada por horário [6], segurança residencial e eficiência das cargas residenciais em relação a energia consumida.

Desta forma, para determinar a eficiência energética de uma residência, podemos levantar o consumo real dos equipamentos de uso doméstico através de técnicas de monitoramento, verificando se uma carga consome mais energia elétrica do que o seu especificado, ou seja, se ela está operando de forma eficiente ou não. Por exemplo, o consumo elevado de um refrigerador pode ser caracterizado por diversos fatores, entre os quais se destacam vazamentos na tubulação do líquido refrigerante e problemas com a vedação das portas. Assim, conhecendo-se quais são os reflexos nas variáveis elétricas destes defeitos, pode-se informar e alertar o consumidor através de um relatório simples sobre a baixa eficiência (e.g. refrigeradores com vazamentos), de modo a diminuir as perdas de energia por equipamentos com mal funcionamento.

A discriminação do consumo de energia elétrica de cada carga pode ser obtida utilizando dois tipos de técnicas: (a) monitoramento intrusivo (ou distribuído); (b) monitoramento não intrusivo (ou concentrado).

No monitoramento intrusivo (ou distribuído), sensores são instalados no interior da residência para identificar cargas elétricas ativas [7]. Cada sensor instalado é identificado por um rótulo e associado a uma tomada ou local da residência. De modo geral, a informação (instante que um equipamento liga) de cada sensor, em conjunto com os dados monitorados na entrada da residência, é enviada a um dispositivo central que contém um programa computacional responsável por obter o consumo de energia individual de cada equipamento doméstico monitorado. Esta solução aumenta o custo de hardware devido ao número de sensores, contudo o programa computacional para determinar o consumo de energia elétrica individual é relativamente simples. Outro fator que torna essa técnica inconveniente é a entrada de funcionários de empresas responsáveis para a instalação e manutenção dos sensores no interior da residência, causando incômodo quanto à privacidade do consumidor.

Por outro lado, o monitoramento não intrusivo (ou concentrado) utiliza a instalação de apenas um único sensor no painel de entrada de energia do consumidor [7]. A vantagem desta técnica em relação à mencionada anteriormente é a redução significativa no custo de hardware e maior privacidade para o consumidor. Contudo, a principal limitação consiste em discriminar com apenas um único sensor os instantes em que cada equipamento doméstico é ligado e desligado. Dessa forma, o programa computacional para processamento dos dados torna-se complexo, fazendo

Este trabalho foi desenvolvido no âmbito do Programa de Pesquisa e Desenvolvimento Tecnológico do Setor de Energia Elétrica PD-00063-3020/2016 - PA3020 - Desenvolvimento de sistemas inteligentes para monitoramento, desagregação e análise de consumo utilizando tecnologias modernas de sensoriamento, regulado pela ANEEL e consta dos Anais do IX Congresso de Inovação Tecnológica em Energia Elétrica (IX CITENEL).

R. C. Monzani trabalha no Instituto Federal de São Paulo – IFSP (cuerda@ifsp.edu.br)

J. G. I. Cypriano, H. A. D. Azzini, W. A. Souza e L. C. P. Silva trabalham na Universidade Estadual de Campinas – UNICAMP (e-mail: joao.ito@dsee.fee.unicamp.br, hader@dsee.fee.unicamp.br, wesley@dsee.fee.unicamp.br, lui@dsce.fee.unicamp.br)

Augusto C. V. da Silva e Rodrigo M. Garbelotti trabalham na Companhia Paulista de Força e Luz – CPFL (e-mail: augustov@cpfl.com.br, rodrigomg@cpfl.com.br)

uso de técnicas computacionais robustas que envolvem inteligência artificial, acarretando em alto custo de desenvolvimento.

Independente do uso da técnica de monitoramento, a principal informação extraída é a assinatura elétrica das cargas de interesse, auxiliando na construção de modelos para, por exemplo, identificação do consumo individual de cargas quando a aquisição dos sinais de tensão e corrente for concentrada e também na verificação de eficiência em relação ao consumo de determinados equipamentos.

Este artigo tem por finalidade estudar e analisar a assinatura elétrica de uma carga particular presente em quase todas as residências, os refrigeradores, relacionando as informações elétricas com aspectos físicos e funcionais de cada modelo analisado. Contudo, uma abordagem generalista acerca do escopo do projeto é apresentada na Seção II, discorrendo sobre os principais aspectos atrelados ao fundamento da pesquisa e desenvolvimento, explicitando a metodologia utilizada e os resultados esperados a longo prazo, considerando a proposta estabelecida junto à ANEEL.

Este artigo está organizado em seções com a estrutura disposta na sequência. Após a definição do escopo do projeto na Seção II, a metodologia de monitoramento dos sinais do refrigerador é discutida na Seção III. A Seção IV aborda as características da assinatura elétrica, construindo modelos para análise com base nos aspectos construtivos. O conjunto de refrigeradores monitorados é apresentado na Seção V. A seção VI compara os diferentes modelos em relação às características físicas. Aspectos relacionados às falhas observadas são discutidos na Seção VII. A Seção VIII encerra este artigo ressaltando os principais tópicos observados.

II. Escopo do Projeto PD-00063-3020/2016

O projeto de P&D (PD-00063-3020/2016 - PA3020, "Desenvolvimento de sistemas inteligentes para monitoramento, desagregação e análise de consumo utilizando tecnologias modernas de sensoriamento") proposto junto à ANEEL, busca desenvolver metodologias para identificação do consumo individualizado de cargas residenciais, ou seja, a desagregação do consumo mensal por equipamento, bem como o perfil diário de uso de cada equipamento.

Após a identificação do consumo individualizado por equipamento ou família de equipamentos, é necessário fornecer ao consumidor propostas para melhorar o seu desempenho energético, ou seja, melhorar a eficiência energética. Portanto, o sistema deve fornecer alternativas para estimular a eficiência energética e/ou econômica pelo cliente.

Diferentes técnicas podem ser empregadas dependendo do tipo de equipamento e do sistema de tarifação escolhido pelo consumidor, como redução de uso, substituição de equipamento e alteração de sistema tarifário e horário de uso.

Esses aspectos representam motivadores importantes para o desenvolvimento de sistemas de monitoramento e gerenciamento do consumo de energia elétrica, resultando em ganhos claros para consumidores e concessionárias de energia elétrica.

A abordagem tradicional para monitoramento detalhado das cargas de um dado consumidor requer a instalação de um sensor em cada ponto de consumo e acesso físico às cargas e, consequentemente entrada na residência ou comércio. Este tipo de monitoramento denomina-se Monitoramento Distribuído, por basear-se na distribuição de um sensor inteligente por eletrodoméstico/tomada. Depois de efetuadas as medidas, os dados de cada sensor são reunidos e analisados por um software que os organiza e os exibe. Pode-se afirmar que os sistemas de monitoramento distribuídos geralmente apresentam uma estrutura de hardware mais complexa e um software mais simples. Quanto à simplicidade do software, ela está no fato de que ele apenas organiza os dados fornecidos por cada sensor. Um sistema de Monitoramento Distribuído, desde que seja bem projetado, obtém medidas precisas e detalhadas sobre o uso de energia na residência. No entanto, pode-se dizer que existe menor nível de inteligência computacional associada a este método, além do maior custo associado à rede de sensores e maior incômodo aos usuários associados à instalação e manutenção da rede de sensores. A vantagem clara deste método está associada à sua maior precisão.

Um exemplo de sensores de monitoramento distribuído é o uso de tomadas inteligentes (Figura 1), essa tomada, em específico, foi desenvolvida pela empresa canadense Securifi [8] e possui a capacidade de medir potência ativa, tensão eficaz e corrente eficaz em um intervalo de 5 minutos. As tomadas inteligentes constituídas por sensores de tensão e corrente são alimentadas pela própria corrente monitorada, e podem se comunicar e repassar dados para um receptor e concentrador de dados por meio de uma rede sem fio. Os dados são enviados do concentrador para um servidor dedicado, onde é realizada a análise do consumo.

Figura 1 – Tomada inteligente Peanut [8].

Outro aspecto interessante da tomada inteligente é que a mesma inclui um relé interno com possibilidade de acionamento remoto. Isso permite que o equipamento possa ser conectado ou desconectado remotamente, via celular ou computador, pelo consumidor ou pela concessionária, conforme modelo de negócio adotado em cada contrato. Esta funcionalidade abre possibilidade para a gestão da demanda atendendo os objetivos do consumidor ou da concessionária, por exemplo, para obter redução do pico de consumo ou para priorizar o consumo em períodos em que a tarifa de energia é mais barata.

Em contraste com o Monitoramento Distribuído existe o Monitoramento Concentrado, por ser baseado na instalação de um único sensor inteligente no ramal principal da residência. Neste caso, o objetivo básico é determinar o

consumo individual de cada carga sem ter acesso físico a cada equipamento. Isto é feito a partir da análise detalhada da tensão e da corrente na interface da instalação elétrica com a fonte de energia. As formas de onda da corrente e da tensão no ramal principal são registradas e analisadas. Tal análise das formas de onda da carga total gera estimativas do consumo individual das cargas e outras estatísticas. Esta análise é baseada na identificação de características elétricas específicas, comumente chamadas de assinaturas, que permitam identificar a carga que foi ligada ou desligada em determinados instantes. A Figura 2 ilustra as duas abordagens de monitoramento.

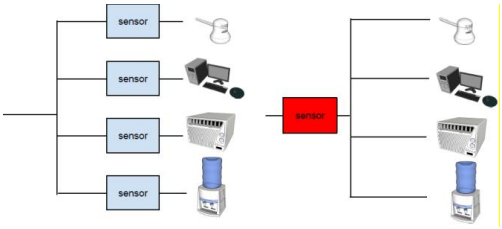

(a) Distribuído (b) Concentrado

Figura 2 – Estrutura dos sistemas de monitoramento.

Na abordagem concentrada apenas um sensor é colocado no ramal principal. Contudo o software que efetua a análise dos dados, a fim de desagregar as informações de cada carga, é complexo e justifica a atribuição do termo "medidor inteligente". Alguns softwares são baseados em ferramentas de reconhecimento de padrões e técnicas de inteligência artificial. A reversão de balanço entre hardware e software representa grande benefício, pois permite a redução de custo com aquisição e instalação dos sensores. Um sistema de Monitoramento Concentrado, geralmente, tem precisão inferior a um sistema de Monitoramento Distribuído, contudo, o seu grau de imprecisão pode ser tolerado para muitas aplicações. A técnica de monitoramento concentrado não permite a gestão remota das cargas, mas viabiliza mudanças de hábitos dos consumidores de maneira a resultar em ganhos em termos de conservação de energia.

Outro conceito é o uso de Monitoramento Parcialmente Distribuído, por ser baseado na distribuição de um sensor inteligente por circuito (ou disjuntor), exigindo maior número de sensores, contudo sem alcançar o nível do monitoramento por equipamento (ou tomada). Esta tecnologia utiliza sensores de corrente por efeito Hall, resultando em diminuição significativa de custo e na miniaturização dos sensores. O monitoramento parcialmente distribuído não requer a instalação de sensores em cada ponto de consumo, e sim em cada circuito da instalação, representando um estágio intermediário entre o distribuído e o concentrado, com precisão e custo intermediários. Ainda, por disponibilizar mais dados sobre o consumo, é menos dependente do uso de software para o reconhecimento das assinaturas elétricas, além de fornecer, nesse caso sem nenhum erro significativo, a desagregação do consumo por circuito.

A técnica de monitoramento parcialmente distribuído não permite a gestão remota das cargas, mas viabiliza mudanças de hábitos dos consumidores de maneira a resultar em ganhos em termos de conservação de energia.

Um exemplo de monitoramento parcialmente distribuído consiste em utilizar sensores, como os da Figura 3. Os sensores são simplesmente colados nos disjuntores, sem nenhuma necessidade de obra ou modificação na instalação. O sistema é compacto, podendo ser acomodado em qualquer quadro de distribuição. Para cada quadro adiciona-se um concentrador de dados, responsável por coletar a corrente estimada por cada sensor e transmitir para um servidor, disponibilizando informações através de dispositivos móveis de dados, computadores, etc. Como o sistema exige a entrada na residência, mas não exige nenhuma alteração na instalação e nem a instalação de sensores em cada ponto de consumo, pode ser classificado como um sistema de monitoramento parcialmente distribuído.

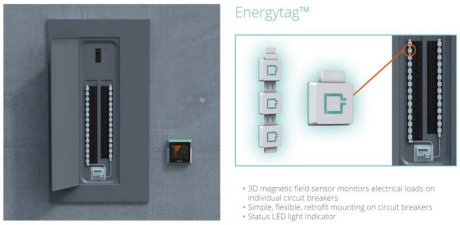

Figura 3 – Sistema de monitoramento parcialmente distribuído [9].

Neste projeto, os três tipos de sistemas de monitoramento são considerados; concentrado, parcialmente distribuído e distribuído. O projeto consiste em avaliar o consumo de diferentes residências utilizando as metodologias de aquisição de dados anunciadas anteriormente.

Após a identificação do consumo individualizado por equipamento ou família de equipamentos, pode-se fornecer ao consumidor propostas para melhorar o seu desempenho energético, ou seja, melhorar a eficiência energética. O sistema pode sugerir diferentes técnicas dependendo do tipo de equipamento e do sistema de tarifação escolhido pelo consumidor, como discutido a seguir:

Redução de uso: dependendo do tipo de equipamento, é possível melhorar o desempenho energético e econômico através da redução do uso do dispositivo sem causar maiores transtornos ao consumidor. Por exemplo, no caso do chuveiro elétrico, o sistema pode indicar que a redução do uso diário em X minutos implica na redução da conta de energia em Y reais (Z kWh).

Substituição de equipamento: no caso do consumo de um refrigerador, por exemplo, não é possível sugerir a redução do uso ou seu uso em horário alternativo por se tratar de uma carga continuamente conectada à rede e de operação cíclica automática. Por outro lado, o sistema pode sugerir a substituição por outro equipamento similar mais eficiente. Para esta solução, o sistema calcula a redução do custo mensal com a substituição e o retorno do investimento em função do custo do novo equipamento.

Alteração de sistema tarifário e horário de uso: no caso de equipamentos que podem ter seu horário de uso alterado, como por exemplo, máquina de lavar e secar roupas, o sistema pode sugerir ao usuário a adesão ao sistema de tarifa branca assim como o melhor horário de uso. Neste caso, o sistema fornecerá a redução do custo mensal, cabendo ao usuário decidir se o trabalho de programar o equipamento é benéfico ou não.

Estes são apenas alguns exemplos de alternativas de estímulo ao consumidor, porém outras metodologias para aumentar a eficiência energética e econômica serão desenvolvidas no decorrer da execução do projeto.

Como proposta inicial para este artigo, visando analisar os dados obtidos até o presente momento, as próximas Seções, descrevem a metodologia de monitoramento adotada, formalizando a definição de assinatura elétrica, e o processo de monitoramento da carga de particular interesse, os refrigeradores residenciais. Aspectos qualitativos e quantitativos foram observados nas análises, e uma relação entre o volume do refrigerador e o consumo de energia elétrica foi estabelecida. Ainda, um caso particular de refrigerador sob falha foi observado no processo de medição executado.

III. Metodologia de monitoramento

A desagregação de carga é sumarizada pelo fluxograma apresentado na Figura 4. Após a aquisição dos dados de entrada (corrente e tensão por fase) amostrados no tempo, os seguintes passos são executados: detecção e filtragem de eventos; classificação; estimação do consumo de energia; análises e geração de relatórios.

O primeiro passo consiste em avaliar o sinal monitorado, detectando os eventos, sem se preocupar com os equipamentos associados nestes instantes. Na sequência, os dados são filtrados de modo a reduzir ruídos na aquisição e erros na detecção, e em seguida, o conjunto de dados é classificado de acordo com sua assinatura elétrica. Essa etapa, denominada desagregação de carga, associa os eventos às cargas de interesse.

O próximo passo consiste em estimar o consumo de energia elétrica das cargas identificadas. Uma vez que os eventos de início e término foram associados às cargas de interesse e com base na assinatura elétrica e nos modelos construídos, o consumo de energia é estimado. Contudo, certas cargas possuem características elétricas semelhantes, o que dificulta o processo de classificação e estimação de energia, sendo necessário propor novas soluções para sanar este problema.

Ainda, após a detecção, classificação e estimação do consumo de energia, diferentes análises podem ser executadas, visando destacar informações sobre o padrão de consumo de energia da residência como: consumo individual comparado a valores médios disponíveis na literatura; horário de uso; consumo entre cargas semelhantes; segurança por desvio de padrão; avaliação do impacto ambiental em relação ao consumo de energia, entre outros aspectos.

Na etapa final, as análises realizadas são fornecidas aos consumidores através de relatórios disponibilizados, por exemplo, por meio de soluções online.

A. Assinatura elétrica

Diferentes tipos de cargas estão presentes em ambientes residenciais. Para entender o padrão de consumo individual é preciso monitorar e identificar o uso de energia de cada carga. O processo de monitoramento possui três estágios [10]. O primeiro está relacionado com o aprendizado sobre a característica de cada carga, ou seja, sua assinatura elétrica. Os outros dois processos são a aquisição de eventos e a identificação de carga, respectivamente.

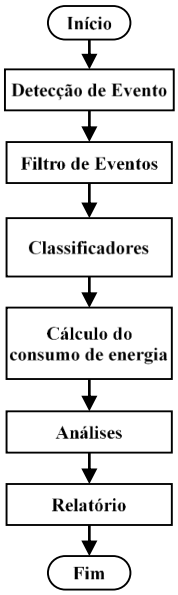

Figura 4 – Fluxograma da identificação de cargas elétricas.

O monitoramento de cargas traz como informação a assinatura elétrica [11]-[12]. Tal informação é o registro chave de uma carga na qual estão contidas características necessárias para sua identificação. A assinatura elétrica permite identificar o funcionamento da carga em regime e, dependendo da taxa de amostragem, informações suplementares como detecção de transitório de partida e componentes harmônicos.

As cargas monitoradas podem ser agrupadas em diferentes tipos de classes quanto ao funcionamento em regime. Com relação às cargas residenciais e ao comportamento da potência ativa, essas são agrupadas em três tipos diferentes (Tabela 1).

Tabela 1 – Modos de operação de cargas residenciais.

Tipo de Carga	Exemplos	Eventos	Demanda de Potência
Estado único	Lâmpadas, torradeiras, chuveiro.	$ON = OFF$	Plana
Variação contínua	Geladeira; freezer.	$ON \neq OFF$	Variante
Estados múltiplos	Máquina de lavar; aquecedor.	Eventos múltiplos	Variante ou plana

Cargas com alto valor de componente resistiva apresentam estado único, ou seja, a potência ativa consumida é constante. Desse modo, a demanda de potência para esse tipo de carga é plana. Assim, a potência consumida para acionar (estado *ON*) a carga tem o mesmo valor no momento de desligá-la (estado *OFF*).

Em cargas de variação contínua (geladeira, freezer, e outras acionadas por motor), a potência reativa está presente. Tem como característica valores diferentes de potência ativa

para ligar e desligar a carga, fazendo com que a demanda de potência seja variante no tempo.

Cargas com diferentes modos de operação possuem múltiplos estados. Esse tipo de carga exibe demanda de potência variante ou plana.

Os três diferentes tipos de carga são sintetizados na Figura 5.

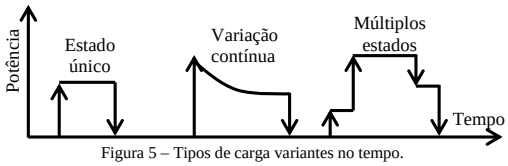

Figura 5 – Tipos de carga variantes no tempo.

A assinatura elétrica da carga contém importantes informações para sua identificação. Quando observado o sinal monitorado em regime permanente, informações como nível de potência ativa e reativa são obtidas e podem ser usadas como um primeiro filtro. Outras informações presentes na assinatura elétrica da carga auxiliam em sua identificação, entre essas, a forma de onda da corrente, admitância da carga, transitório de partida, componentes harmônicos de corrente, etc. Tais informações possibilitam a confecção de modelos de cargas residenciais, a próxima seção aborda esse tema.

B. Processo de monitoramento dos refrigeradores

O processo de monitoramento dos refrigeradores analisados por este trabalho foi realizado localmente em cada residência utilizando um analisador de energia genérico. Ressalta-se que o processo de monitoramento se estendeu a outros tipos de cargas elétricas instaladas no interior da residência, contudo este trabalho limita-se a demonstrar as relações entre consumo de energia e características físicas e ou comportamentais de usuários apenas para o grupo de refrigeradores domésticos. Esta seção aborda em detalhes a metodologia do processo de monitoramento.

O analisador de energia utilizado para realizar as medições das cargas residenciais de interesse é composto por um conjunto de 3 transformadores de corrente (TC) em formato de alicate e 5 ponteiras de tensão (3 ponteiras para as fases, 1 para neutro e 1 para terra).

Para facilitar o processo de monitoramento das cargas, foi criada uma maleta do tipo *plug and play*, na qual foram instaladas tomadas com padrão brasileiro para cargas monofásicas ou bifásicas, considerando ainda o nível de corrente do equipamento. Internamente os transformadores de corrente foram alocados de modo a automatizar o processo de aquisição dos sinais. A Figura 6 exibe o ponto de conexão da carga e a estrutura interna da ferramenta utilizada.

Os sinais de tensão e corrente foram amostrados no tempo, utilizando a taxa de 15kHz para aquisição dos sinais. Para reduzir a quantidade de dados armazenados, os sinais amostrados são processados localmente utilizando a transformada discreta de Fourier [13], integrando o conjunto de dados obtido em 1 amostra por segundo.

Figura 6 – Ferramenta utilizada para automatizar o processo de monitoramento de cargas elétricas residenciais.

O conjunto de dados observado compreende os valores eficazes da componente fundamental de tensão e corrente, das componentes harmônicas de tensão e corrente até a 25ª ordem, inclui também a potência ativa, potência reativa, potência aparente e ainda o fator de potência e as distorções harmônicas totais de corrente e tensão.

A aquisição dos sinais elétricos e integração do conjunto de dados é registrada internamente ao analisador de energia, posteriormente os dados são extraídos utilizando software de processamento próprio do analisador de energia. Contudo, a fim de comparar os diferentes tipos de cargas monitoradas, os dados são exportados para um arquivo e processados por meio de uma ferramenta matemática para analisar as relações entre as características elétricas e físicas dos refrigeradores.

A Figura 7 demonstra os sinais de tensão e corrente da componente fundamental no tempo para um refrigerador qualquer. Observa-se que o refrigerador opera em ciclos e que no instante de partida, apresenta um pico de corrente e uma queda de tensão, retornando à operação em regime no instante subsequente.

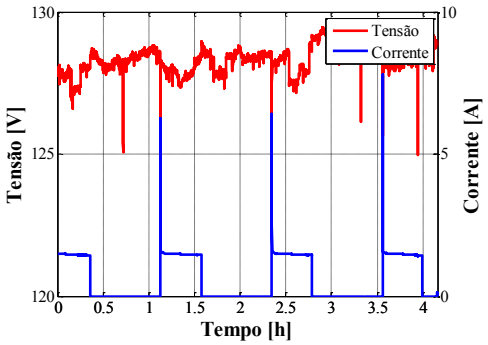

Figura 7 – Tensão e corrente de um refrigerador no tempo.

A assinatura elétrica da carga contém importantes informações para sua identificação. Quando observado o sinal monitorado em regime permanente, informações como nível de potência ativa e reativa são obtidas e podem ser usadas como um primeiro filtro. Outras informações presentes na assinatura elétrica da carga auxiliam em sua identificação, entre essas, a forma de onda da corrente, admitância da carga, transitório de partida, componentes harmônicos de corrente, etc. Tais informações possibilitam a

confecção de modelos de cargas residenciais, a próxima seção aborda esse tema.

IV. Refrigeradores residenciais

De acordo com a Empresa de Pesquisa Energética (EPE) a média mensal do consumo de energia elétrica residencial em 2016 foi de 161±8 kWh [14]. Entre os diversos tipos de cargas elétricas presentes em residências brasileiras, algumas possuem maior nível de destaque, entre as quais pode-se listar o chuveiro elétrico, refrigerador e o grupo de iluminação. Dentre essas cargas, o consumo médio de energia elétrica de refrigeradores é de 46 kWh [15], representando um consumo médio de aproximadamente 30% em relação ao total consumido por uma residência padrão.

De acordo com as séries estatísticas [16] do Instituto Brasileiro de Geografia e Estatística (IBGE), observa-se a partir gráfico da Figura 8 que o número de domicílios particulares permanentes, por posse de refrigeradores, demonstrou crescimento praticamente linear desde 2001 a 2011.

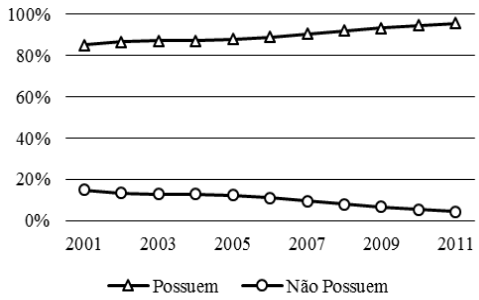

Figura 8 – Domicílios particulares brasileiros que possuem ou não a presença de refrigeradores de acordo com o IBGE [16].

Apesar das informações obtidas a partir das séries estatísticas do IBGE não serem recentes, sendo o último dado disponível referente ao ano de 2011 com a presença de 96% de refrigeradores em domicílios particulares no Brasil, com base no crescimento linear demonstrado pelo gráfico, pode-se inferir que o número de refrigeradores aumentou atingindo patamares expressivos, abrangendo quase a totalidade de residências brasileiras existentes.

Desse modo, uma análise mais robusta referente a essa carga deve ser desenvolvida. Este artigo tem por finalidade monitorar diferentes tipos de refrigeradores existentes em domicílios e analisar o consumo de energia observando aspectos qualitativos como característica de funcionamento e quantitativos como capacidade, número de portas e comportamento dos residentes.

O conhecimento da característica de funcionamento do refrigerador permite elaborar um modelo de assinatura elétrica e desse modo relacionar o consumo de energia com aspectos físicos. Ainda, a partir do monitoramento de refrigeradores, é possível diagnosticar quando os mesmos estão propensos a falhas, tais como problemas de vedação ou consumo de energia além do normal.

A curva característica dos refrigeradores residenciais identifica-se por uma forma de onda periódica e trapezoidal. A periodicidade varia conforme o modelo, isolação e utilização dos refrigeradores (quantidade de alimentos no interior do equipamento e abertura da porta), com média de 1 a 3 ciclos de operação por hora (refrigeração e modo espera).

No instante de acionamento, o refrigerador apresenta corrente de partida da ordem de 2 a 5 vezes a corrente em regime, sendo uma característica de motores em geral. Em regime, a potência ativa instantânea varia ao longo do tempo na forma de uma rampa declinada, isto é, o valor médio de potência ativa no instante anterior ao desligamento do refrigerador é inferior ao valor médio do momento inicial. Esta inclinação depende do modelo do refrigerador. O consumo de potência reativa é da ordem de 150% a 170% do consumo de potência ativa (Figura 9).

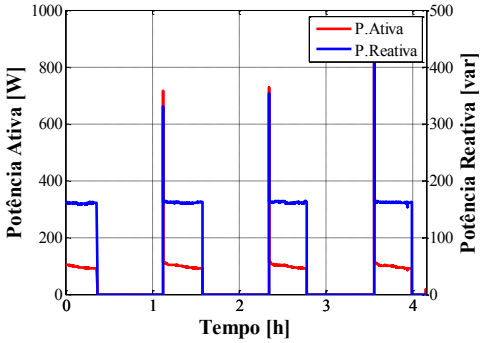

Figura 9 – Potência ativa e potência reativa para um refrigerador qualquer.

Outra característica dos refrigeradores é o alto consumo de correntes harmônicas, em especial, a corrente harmônica de terceira ordem representa em torno de 10% do consumo de corrente da componente fundamental (Figura 10). Esse fenômeno foi observado considerando praticamente todos os refrigeradores monitorados. Em seguida, a componente harmônica de quinta ordem atingiu maior destaque do que as demais componentes harmônicas. A distorção harmônica total de corrente permaneceu em torno de 10% e a distorção harmônica total de tensão não apresentou variações significativas.

Em relação ao fator de potência, o valor observado para os equipamentos de refrigeração monitorados foi em torno de 0,45 a 0,7 indutivo, caracterizando um possível parâmetro para auxiliar na identificação desse tipo de carga, considerando o procedimento de aquisição de dados de modo concentrado. A Figura 11 demonstra o fator de potência ao longo do tempo para o refrigerador em destaque nesta seção.

Demais parâmetros referentes à qualidade de energia e/ou distúrbios de consumo não foram analisados.

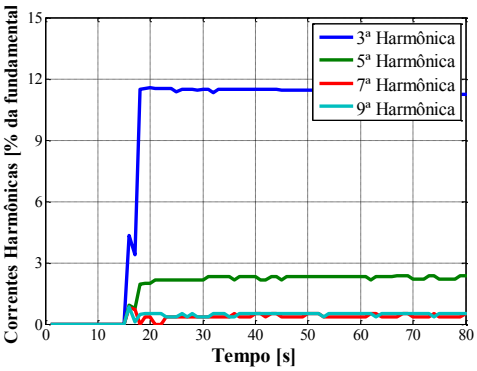

Figura 10 – Correntes harmônicas de um refrigerador qualquer.

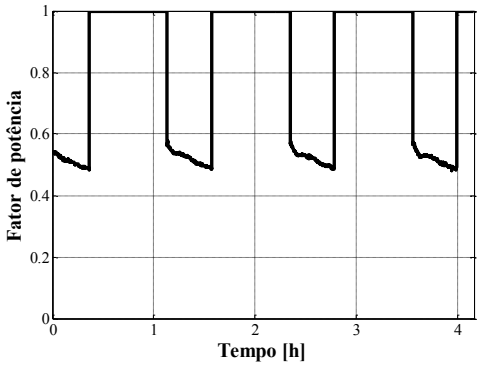

Figura 11 – Fator de potência para um refrigerador qualquer.

No instante em que os refrigeradores são abertos a lâmpada interna é acesa, observando consumo somente de potência ativa devido ao uso de lâmpadas incandescentes (Figura 12), ou ainda consumo de potência ativa com baixo consumo de potência reativa, devido ao uso de lâmpadas LED.

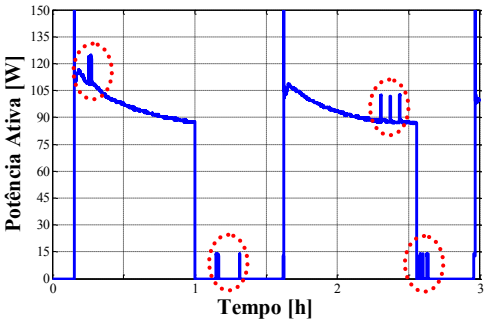

Figura 12 - Detalhe durante a abertura do refrigerador

Ainda, pode-se observar a partir da Figura 12, que o tempo de funcionamento do compressor ou intervalo em repouso é diretamente proporcional à abertura da porta do refrigerador. No primeiro ciclo, o refrigerador opera durante 3.060 segundos e a porta ficou aberta durante 30 segundos, no segundo ciclo o refrigerador opera durante 3.355 segundos e a porta ficou aberta durante 50 segundos. Em relação ao tempo em repouso, observa-se que o tempo para acionamento do terceiro ciclo é inferior ao tempo para o acionamento do segundo ciclo, devido ao tempo em que a porta do refrigerador permaneceu aberta entre o segundo e terceiro ciclo.

Para os refrigeradores com tecnologia *Frost Free* o consumo de potência ativa aumenta, devido à resistência interna de aquecimento para degelo do refrigerador. No caso de consumo de potência reativa, pode ser zero para tecnologias com apenas uma resistência, ou reduzida (abaixo do consumo de potência ativa) para tecnologias que utilizam bomba de aquecimento.

O funcionamento do *Frost Free* é determinado por um intervalo de tempo que varia de acordo com cada fabricante e seus modelos. A Figura 13 exibe a forma de onda de potência ativa e reativa para um refrigerador com funcionamento *Frost Free*, observa-se em destaque, que o instante em que o compressor é desligado, devido à ausência de potência reativa coincide com o instante em que a resistência responsável pelo funcionamento *Frost Free* é acionada.

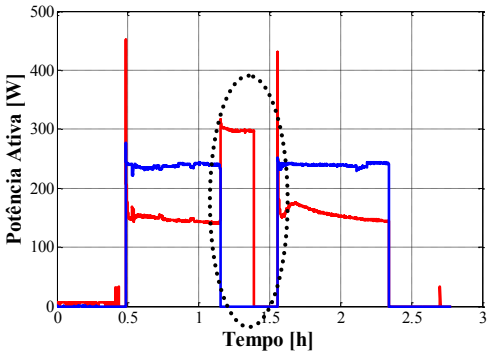

Figura 13 - Comportamento da potência ativa e reativa no Frost Free.

V. Refrigeradores analisados

Esta seção demonstra as curvas de consumo de potência ativa e reativa por um período de duas horas, com dados coletados a cada um segundo de 12 modelos diferentes de refrigeradores, dentre 5 marcas distintas.

A Tabela 2 cataloga os equipamentos de refrigeração monitorados em consumo de energia elétrica (kWh), volume interno (litros), quantidade de portas e se possui ou não a tecnologia *Frost Free*. Os refrigeradores estão organizados primeiramente pelo número de portas e na sequência por volume.

A Figura 14 mostra o comportamento da potência ativa e reativa dos refrigeradores monitorados de acordo com os dados da Tabela 2.

Observa-se a partir da Tabela 2 que os refrigeradores monitorados neste artigo apresentam entre 1 a 3 ciclos de operação por hora de uso e que para todos os refrigeradores monitorados, o valor da potência reativa é sempre superior ao valor da potência ativa, reduzindo significativamente o fator de potência, conforme demonstrado anteriormente na Seção III.

Tabela 2 – Equipamentos de refrigeração monitorados.

Refrigerador	Consumo (kWh)	Volume (Litros)	Nº de Portas	*Frost Free*
(a)	23,4	239	1	Não
(b)	24,4	263	1	Não
(c)	36,6	280	1	Não
(d)	48,6	334	2	Não
(e)	46,5	341	2	Sim
(f)	45,0	360	2	Não
(g)	45,5	380	2	Não
(h)	48,8	380	2	Sim
(i)	54,4	382	2	Sim
(j)	55,5	411	2	Sim
(k)	62,4	417	2	Sim
(l)	68,0	460	2	Não

Os dados de consumo de energia elétrica dos refrigeradores monitorados, presentes na Tabela 2, foram computados considerando o consumo mensal de tais refrigeradores. O procedimento para o cálculo do consumo de energia tomou como base as medições realizadas pelo analisador de energia durante o período de 24 horas corrido para cada refrigerador de modo independente. O consumo foi calculado integrando a curva de potência ativa durante o período e multiplicado por trinta dias, considerando um mês padrão.

Este artigo propõe um índice para fins de uma análise comparativa entre os diferentes modelos de refrigeradores monitorados. O índice compreende observar o consumo de energia elétrica dos refrigeradores em relação à sua capacidade em litros. Desse modo, a Tabela 3 demonstra os valores obtidos ao estabelecer tal relação.

Tabela 3 – Relação entre consumo de energia elétrica e volume dos refrigeradores monitorados.

Refrigerador	Consumo (kWh)	Volume (Litros)	Relação entre consumo e volume
(a)	23,4	239	0,10
(b)	24,4	263	0,09
(c)	36,6	280	0,13
(d)	48,6	334	0,15
(e)	46,5	341	0,14
(f)	45,0	360	0,13
(g)	45,5	380	0,12
(h)	48,8	380	0,13
(i)	54,4	382	0,14
(j)	55,5	411	0,14
(k)	62,4	417	0,15
(l)	68,0	460	0,15

Observa-se que em geral, o consumo em kWh (mensal) por litro é semelhante para os refrigeradores analisados, contudo, analisando os valores obtidos, verifica-se que o refrigerador (c), comparado na categoria de refrigeradores de 1 porta, demonstra alto consumo, isto deve-se ao fato de que este refrigerador em específico ser de um modelo antigo, possuindo mais de 15 anos de uso. Ainda, observa-se que os refrigeradores com tecnologia *Frost Free* apresentam consumo semelhante entre si e superior aos demais (refrigeradores *e*, *h*, *i*, *j* e *k*), isto deve-se ao fato da característica presente em tais equipamentos, um sistema com a necessidade de uma resistência ou uma bomba de aquecimento. Ainda, a partir da Tabela 3, verifica-se que o refrigerador (l) é o que possui a maior capacidade em litros e possui uma relação entre consumo de energia e volume alta, novamente, essa característica deve-se ao fato de que este refrigerador de 2 portas também ser um modelo antigo de uma das fabricantes analisadas.

Outro aspecto interessante, observado ao realizar o monitoramento dos diferentes modelos de refrigeradores, foi a identificação de falhas, a próxima seção discute alguns aspectos de tais falhas, e como o monitoramento de energia pode auxiliar em tal identificação.

VI. Falhas em refrigeradores

O monitoramento de cargas elétricas residenciais pode auxiliar na identificação de equipamentos que consomem mais energia do que deveriam, fornecendo informações ao consumidor com relação à eficiência das cargas de interesse. Ainda, o monitoramento de cargas elétricas residenciais permite identificar cargas sujeitas à problemas adversos de funcionamento.

Os refrigeradores estão expostos a diferentes tipos de falhas, entre as quais, o contínuo funcionamento do compressor devido a problemas com vedação das portas e/ou mesmo falha em sensores.

Entre os refrigeradores monitorados durante a execução deste trabalho, observou-se que um equipamento permanecia com o compressor sempre ligado (Figura 15). Verificou-se que tal equipamento apresentava problemas no sensor do termostato. De acordo com o manual do fabricante, o consumo de energia deste equipamento era de 62,4kWh por mês, todavia, devido aos problemas de funcionamento contínuo apresentados e observados durante a etapa de monitoramento, calculando o consumo de energia elétrica do refrigerador ao longo de um mês, obteve-se o valor de 90,6kWh, ou seja, aproximadamente 45% a mais de consumo de energia do que o estabelecido pelo fabricante.

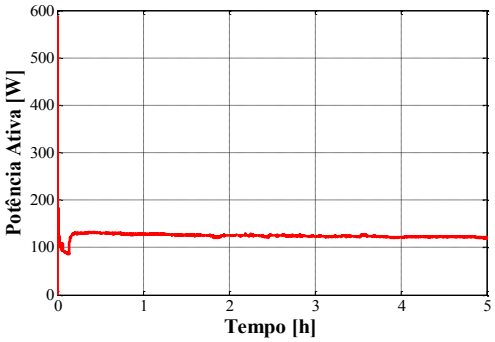

Figura 15 – Refrigerador com falha.

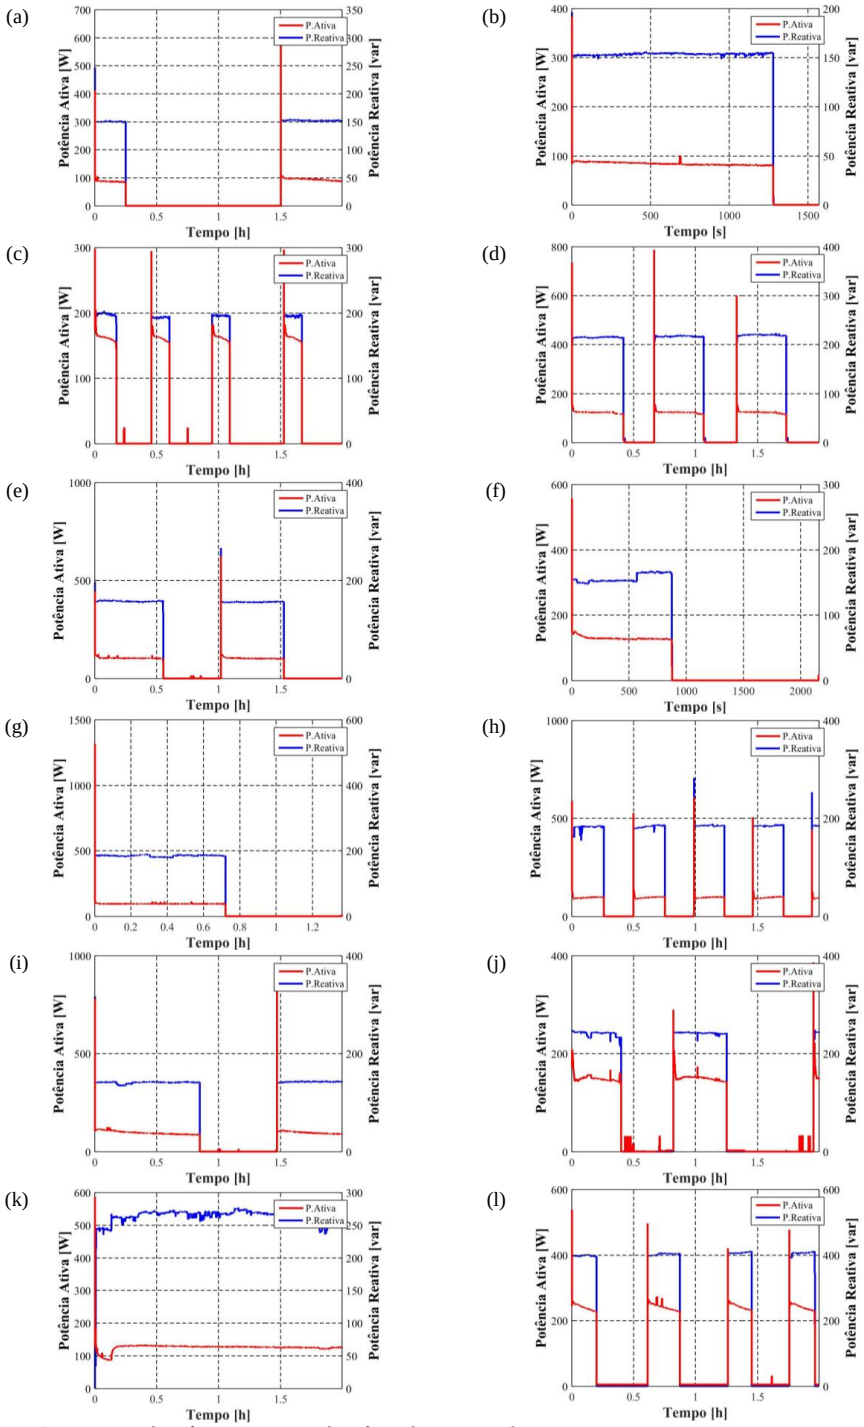

Figura 14 – Comportamento da potência ativa e reativa dos refrigeradores monitorados.

Considerando o período de um ano, este defeito representa um desperdício de energia de aproximadamente 340kWh, todavia, sem o processo de monitoramento, o consumidor residencial seria incapaz de diagnosticar a falha do equipamento por uma simples análise da fatura de energia.

VII. Conclusão

As assinaturas elétricas descrevem o funcionamento completo dos equipamentos proporcionando seu acompanhamento e a avaliação do seu estado de operação e até mesmo da sua vida útil.

Nos aspectos qualitativos, as análises, de comportamento elétrico realizadas em diferentes tipos e modelos de refrigeradores permitiram identificar padrões específicos de funcionamento, como: a relação da variação do tempo de ciclo (encurtamento do período de espera) com o tempo de abertura de portas (perdas térmicas); o funcionamento, consumo e comportamento elétrico dos modelos *frost free*; e identificação de possíveis falhas nos equipamentos. Outro aspecto que influencia no consumo e comportamento dos equipamentos é o tempo de uso, como nos casos (c) e (l) apresentados na Seção IV.

No âmbito dos aspectos quantitativos, não foi possível encontrar uma relação direta entre consumo e volume interno dos refrigeradores. Todavia, percebe-se que a relação entre consumo e volume melhora para geladeiras de uma porta (com valor médio de 0,11 kWh/L) em relação às geladeiras de duas portas com e sem tecnologia *frost free* (valor médio de 0,14 kWh/L para ambas categorias).

Desta forma, estes dados e análises trazem benefícios tanto para o consumidor quanto para a concessionária de energia elétrica. Para os usuários, o conhecimento do quanto cada equipamento de grande porte consome e sua relação com a fatura total é de extrema importância, permitindo a participação e atuação do mesmo em ações de eficiência energética, como: cálculo de retorno financeiro na troca do refrigerador antigo por um novo; conhecimento de que seu refrigerador pode estar com problemas no motor, vazamento e/ou vedação, permitem execuções rápidas a fim de sanar o defeito no curto prazo.

Os benefícios para a concessionária são: identificar as regiões de menor eficiência energética e com maior quantidade de equipamentos defeituosos, permitindo ações diretas com menor custo; dar suporte ao consumidor no detalhamento de sua fatura de consumo energético; simulações de balanceamento das redes de distribuição conforme comportamento e potência de consumo de cada residência.

VIII. Referências

[1] Hart, G. W. “Non-intrusive Appliance Load Monitoring”, Proc. IEEE, vol. 80, pp. 1870-1891, 1992.

[2] Salles, D., and Xu, W. “Information Extraction from PQ Disturbances an Emerging Direction of Power Quality Research”, Proc. IEEE International Conference on Harmonics and Quality of Power, pp. 1-7, 2012.

[3] Wischkaemper, J. A., Benner, C. L., Russell, B. D., and Manivannan, K. M. “Application of Advanced Electrical Waveform Monitoring and Analytics for Reduction of Wildfire Risk,” Proc. IEEE PES, pp. 1-6, 2014.

[4] Santoso, S. and Sabin, D. D. “Power quality data analytics: Tracking, interpreting, and predicting performance,” Proc. IEEE PES General Meeting, pp. 1-7, 2012.

[5] D. Rahayu; B. Narayanaswamy; S. Krishnaswamy; C. Labbe; D. P. Seetharam, "Learning to be energy-wise: Discriminative methods for load disaggregation", 2012 Third International Conference on Future Energy Systems: Where Energy, Computing and Communication Meet (e-Energy), pp.1-4, May 2012.

[6] ANEEL. Resolução Normativa n. 043/2013. Tarifa Branca. Disponível em: http://www.aneel.gov.br. Acesso em dezembro/2016.

[7] Y. Xu and J. V. Milanović, "Artificial-Intelligence-Based Methodology for Load Disaggregation at Bulk Supply Point," in IEEE Transactions on Power Systems, vol. 30, no. 2, pp. 795-803, March 2015.

[8] Securefi Peanut Plug. Disponível em: http://www.securifi.com/rg/securifi-peanut-plug. Acesso em: dezembro/2016.

[9] Energybox. Disponível: http://www.energybox.com. Acesso em: dezembro/2016.

[10] Sultanem, F. “Using appliance signatures for monitoring residential loads at meter panel level,” IEEE Transactions on Power Delivery, vol. 6, pp. 1380-1385, 1991.

[11] Liang, J., Ng, S.K.K., Kendall, G. and Cheng, J.W.M. “Load signature study Part I: Basic concept, structure, and methodology”. IEEE Trans. Power Del. Vol. 25, pp. 551–560, 2010.

[12] Liang, J., Ng, S.K.K., Kendall, G. and Cheng, J.W.M. “Load Signature Study - Part II: Disaggregation Framework, Simulation, and Applications”. IEEE Transactions on Power Delivery. vol. 25, pp. 561-569, 2010.

[13] S. N. Patel; T. Robertson; J. A. Kientz; M. S. Reynolds; G. D. Abowd, “At the Flick of a Switch : Detecting and Classifying Unique Electrical Events on the Residential Power Line”, Conference on Ubiquitous Computing, pp. 139-148, 2010.

[14] EPE. Consumo mensal de energia elétrica por classe (regiões e subsistemas) – 2004 a 2016. Disponível em: <http://www.epe.gov.br>. Acesso em dezembro/2016.

[15] INMETRO. Etiqueta Nacional de Conservação de Energia (ENCE) - Selo PROCEL de economia de energia. Tabela de refrigeradores. Disponível em: <http://www.inmetro.gov.br/consumidor/pbe/refrigeradores.pdf>. Acesso em dezembro/2016.

[16] IBGE. Séries estatísticas - Domicílios particulares permanentes, por posse de geladeira. Disponível em: <http://seriesestatisticas.ibge.gov.br>. Acesso em dezembro/2016.

ANÁLISE COMPARATIVA ENTRE MEDIÇÕES DE ENERGIA ELÉTRICA PARA CARGAS NÃO LINEARES DE ILUMINAÇÃO: MEDIÇÃO COMERCIAL X TEORIA CPT

MATEUS S. QUINALIA, VÍNICIUS H. F. BRITO, GUILHERME Y. KUME, MATEUS A. SACHETTI, ROBERTO P. B. SILVA

Departamento de Engenharia Elétrica, Universidade Federal de Mato Grosso
Rua Fernando Côrrea da Costa, 2367, Cuiabá – MT, CEP 78060-900
E-mails: viniciushfb2@gmail.com, guilhermeyujikume@hotmail.com, mateusqinalia@gmail.com, mateus.sachetti@gmail.com, *perillo@ufmt.br*

WESLEY A. SOUZA, LUIZ C. P. SILVA

DSE, Faculdade de Engenharia Elétrica e de Computação, Universidade Estadual de Campinas
Avenida Albert Einsten 400, Cidade Universitária Zeferino Vaz, Campinas – SP, CEP 13083-852
E-mails: wesley@fc.unesp.br, lui@dsee.fee.unicamp.br

Abstract— Through laboratory measurements with compact fluorescent lamp and the tubular LED lamp and using meters and electric energy analyzers it was possible to measure power values of these loads, which were compared with the parameters presented through computer simulation based on Conservative Power Theory (CPT). This article discusses the difference between the values found by CPT and by commercial meters, with the focus on the reactive power value, because this power quantity is the greater divergence in results. Thereafter, analysis was performed regarding the impact of the discrepancy in electricity billing.

Keywords— Non-linear loads, electric energy, lamps, meter, power theory

Resumo— Através de medições de lâmpadas fluorescente compacta e LED tubular, realizadas em laboratório, e utilizando medidores e analisadores de energia elétrica, pôde-se aferir os valores de potências destas cargas, os quais foram comparados com os parâmetros apresentados através de simulação computacional com base na Teoria de Potência Conservativa (TPC ou CPT, em inglês). Este artigo discute a diferença entre os valores encontrados para a CPT e os dados dos medidores comerciais, com enfoque no valor da potência reativa, uma vez que esta grandeza é a que apresenta maior divergência entre os resultados. Além disso, foi realizada análise referente ao impacto desta discrepância no faturamento da energia elétrica.

Palavras -chave— Cargas não lineares, energia elétrica, lâmpadas, medidores, teoria de potência

1 Introdução

Nos últimos anos, a eletrônica de potência vem se desenvolvendo cada vez mais e, juntamente com os avanços tecnológicos de dispositivos semicondutores, microprocessados e microcontrolados, foram introduzidos novos equipamentos eletroeletrônicos nas unidades consumidoras (Mendonça, 2012), como por exemplo, as lâmpadas fluorescentes compactas (LFC) e as lâmpadas LED (*Light Emitting Diode*).

A LFC contribui para uma maior eficiência energética, sendo mais econômica que a lâmpada incandescente e possuindo um maior tempo de vida útil (Galhardo e Pinho, 2008). A lâmpada LED é feita de um material semicondutor, portanto, apresenta baixa taxa de perda em relação a outros modelos de lâmpadas (Revista Sodebras, 2015). E mais, nos últimos anos, a característica luminosa desse tipo de lâmpada vem sendo consideravelmente melhorada, como por exemplo, o aumento do fluxo luminoso. Tais fatos contribuíram para que o interesse por esse dispositivo aumentasse notavelmente (Monteiro, 2015).

É também indispensável a análise da qualidade de energia elétrica destes equipamentos (Nascimento *et al*., 2014). Estas cargas eletrônicas possuem a característica de não linearidade, provocando a distorção das formas de onda de corrente e tensão do sistema e, desta forma, gerando nos circuitos secundários de distribuição das concessionárias de energia, as chamadas frequências harmônicas (Oliveira e Vilela, 2015; Cerqueira *et al*., 2006).

A não linearidade de cargas eletrônicas deve-se às interações dos componentes internos ao equipamento no decorrer do tempo. Alguns destes elementos podem variar em função da temperatura, saturação, tempo de operação ou curva de carga. Consequentemente, a forma de onda da corrente não possuirá mais um formato puramente senoidal, apresentando assim componentes harmônicas.

Esta característica não linear gera um elevado conteúdo harmônico de corrente no sistema elétrico de potência, que, ao nível de qualidade, resulta em distorções na tensão, redução do fator de potência e elevado nível de harmônicas múltiplas de três na corrente no neutro (Nascimento *et al*., 2014; Irianto e Setiabudy, 2011). Tais fenômenos podem ocasionar superaquecimento de transformadores, explosão de

bancos de capacitores, mau funcionamento de equipamentos utilizados na proteção de sistemas elétricos (como disjuntores, fusíveis e relés), baixo rendimento de máquinas elétricas e afetam também os medidores de energia ativa e reativa, reduzindo sua vida útil e influenciando na medição, em função dos métodos utilizados atualmente (Nascimento *et al*., 2014).

Nota-se que as formas de onda de múltiplas frequências vêm sendo cada vez mais comuns no setor elétrico. Sendo assim, o cálculo das potências para estes casos é um aspecto muito importante e, desta forma, existem diversas teorias de potência, na tentativa de compreender esse e diversos outros fenômenos. Segundo a Agência Nacional de Energia Elétrica (ANEEL), as definições de potência ativa e aparente estão, atualmente, bem consolidadas (ANEEL, 2012). O principal ponto de discussão em sistemas não lineares se refere à potência reativa e ao fator de potência. Ou seja, não há um consenso quando se trata de potência reativa, com formas de ondas distorcidas. Logo, o foco da discussão deste trabalho refere-se à potência reativa e ao fator de potência.

Portanto, este artigo apresenta os resultados das grandezas elétricas a respeito de uma LFC e uma LED tubular, para a Teoria da Potência Conservativa (do inglês, *Conservative Power Theory* - CPT) (Tenti, Paredes e Mattavelli, 2011) e para medidores e analisadores de energia elétrica. Estes medidores mostram resultados muito similares ao analisador de qualidade de energia FLUKE 434, que está em conformidade com a norma IEEE 1459 (FLUKE, 2012) e foi utilizado como base no trabalho para a comparação com os valores encontrados através da CPT. O medidor FLUKE apresenta um parâmetro chamado potência não ativa, que se refere à toda parcela diferente da potência ativa e é numericamente igual a potência reativa, segundo os medidores comerciais utilizados pelas concessionárias distribuidoras de energia elétrica no Brasil, podendo-se inferir que os resultados referentes ao FLUKE podem ser aplicados aos medidores de forma geral. Por fim, faz-se uma comparação entre os resultados, destacando as diferenças entre si e os impactos em relação ao faturamento de excedentes de potência reativas.

2 Faturamento da Energia Reativa Excedente no Sistema Elétrico Brasileiro

O fator de potência de referência "f_R", que pode ser indutivo ou capacitivo, tem como limite mínimo permitido, o valor de 0,92. Os artigos 96 e 97 da Resolução nº 414 da ANEEL estabelecem as cobranças no faturamento devido aos montantes de energia elétrica e demanda de potência reativa que excederem o limite permitido (ANEEL, 2010). Tem-se:

"Art. 96. - Para unidade consumidora que possua equipamento de medição apropriado, incluída aquela cujo titular tenha celebrado o CUSD, os valores correspondentes à energia elétrica e demanda de potência reativas excedentes são apurados conforme as seguintes equações:"

$$E_{RE} = \sum_{T=1}^{n1} \left[EEAM_T \times \left(\frac{f_R}{f_T} - 1 \right) \right] \times VR_{ERE} \quad (1)$$

$$D_{RE}(p) = \left[\underset{T=1}{\overset{n2}{MAX}} \left(PAM_T \times \frac{f_R}{f_T} \right) - PAF(p) \right] \times VR_{DRE} \quad (2)$$

Sendo:

- E_{RE} = valor correspondente à energia elétrica reativa excedente à quantidade permitida pelo fator de potência de referência "f_R", no período de faturamento, em Reais (R$);
- $EEAM_T$ = montante de energia elétrica ativa medida em cada intervalo "*T*" de 1 (uma) hora, durante o período de faturamento, em megawatt-hora (MWh);
- f_R = fator de potência de referência (0,92);
- f_T = fator de potência da unidade consumidora, calculado em cada intervalo "*T*" de uma hora, durante o período de faturamento;
- VR_{ERE} = valor de referência equivalente à tarifa de energia "TE" aplicável ao subgrupo B1 (R$/MWh);
- $D_{RE}(p)$ = valor, por posto horário "*p*", correspondente à demanda de potência reativa excedente à quantidade permitida pelo fator de potência de referência "f_R" no período de faturamento, em Reais (R$);
- PAM_T = demanda de potência ativa medida no intervalo de integralização de 1 (uma) hora "*T*", durante o período de faturamento, em quilowatt (kW);
- $PAF(p)$ = demanda de potência ativa faturável, em cada posto horário "*p*" no período de faturamento, em quilowatt (kW);
- VR_{DRE} = valor de referência, em Reais por quilowatt (R$/kW), equivalente às tarifas de demanda de potência, para o posto horário fora de ponta, das tarifas de fornecimento aplicáveis aos subgrupos do grupo A, para a modalidade tarifária horária azul e das TUSD-Consumidores-Livres, conforme esteja em vigor o Contrato de Fornecimento ou o CUSD, respectivamente;
- *MAX* = função que identifica o valor máximo da equação, dentro dos parênteses correspondentes, em cada posto horário "*p*";
- *T* = indica intervalo de 1 (uma) hora, no período de faturamento;
- *p* = indica posto horário, ponta ou fora de ponta, para as modalidades tarifárias horárias ou período de faturamento para a modalidade tarifária convencional binômia;
- *n1* = número de intervalos de integralização "*T*" do período de faturamento, para o posto horário de ponta e fora de ponta;

- *n2* = número de intervalos de integralização "*T*", por posto horário "*p*", no período de faturamento.

Adiante, as equações (1) e (2) serão utilizadas para indicar quais grandezas o consumidor está pagando por excesso de reativo. Frente à essas equações, tem-se outras abordagens para o cálculo da potência reativa, que permitem uma análise diferente da teoria IEEE 1459. Na seção 3 será apresentada a CPT, que permitirá a comparação e a discussão dos cálculos de reativos apresentados pela ANEEL.

3 Teoria da Potência Conservativa

Esta teoria, proposta por *Tenti et al.* (Tenti, Paredes e Mattavelli, 2011), visa generalizar as definições de potência e fator de potência para circuitos elétricos lineares e não lineares, balanceados e desbalanceados, sob condições distintas de fornecimento de energia, tratando cada distúrbio separadamente. A corrente é decomposta basicamente nas seguintes parcelas de corrente instantâneas:

- Corrente ativa (i_a): mínima corrente necessária ao consumo de uma dada potência ativa, em cada fase no circuito;
- Corrente reativa (i_r): responsável pelo fluxo mínimo de energia reativa por fase no circuito;
- Corrente residual (i_d): aquela que não transfere potência ativa, nem energia reativa. É a parcela de corrente que representa as não linearidades entre a tensão fornecida e a corrente consumida pela carga.

Nos circuitos polifásicos (com ou sem condutor de retorno), as parcelas de corrente ativa e reativa podem ainda ser decompostas em parcelas balanceadas e desbalanceadas:

- Corrente ativa balanceada (i_a^b): responsável pela transferência mínima da potência ativa coletiva da fonte para a carga, além de ser proporcional e estar em fase com a tensão;
- Corrente reativa balanceada (i_r^b): responsável pelo fluxo mínimo de energia reativa coletiva no circuito. Tal parcela de corrente pode ser distorcida e é sempre ortogonal à tensão;
- Corrente de desbalanço (i^u): é composta por uma parcela ativa e outra reativa ($i^{u^2} = i_a^{u^2} + i_r^{u^2}$), respectivamente, e representam os diferentes valores de condutância e reatividade equivalente por fase.

Para cada parcela de corrente, tem-se associada uma parcela de potência, obtida pelo produto entre o valor eficaz da tensão e o valor eficaz da corrente corresponde, como segue:

- Potência ativa ($P=VI_a^b$): é o consumo médio de potência do circuito, representando a realização de trabalho útil na carga.
- Potência reativa ($Q=VI_r^b$): parcela de potência característica que representa a defasagem entre tensões e correntes;
- Potência de desbalanço ($N = \sqrt{N_a^2 + N_r^2}$, na qual $N_a = VI_a^u$ e $N_r=VI_r^u$): parcela de potência que representa o desbalanço da carga. Este termo é nulo no caso de circuitos monofásicos;
- Potência residual ($D=VI_d$): parcela de potência consumida devido à presença de não-linearidades no circuito;
- Potência aparente ($A=VI$): potência total do circuito. Algebricamente, o quadrado da potência aparente é igual à soma dos quadrados de todas as parcelas mencionadas.

Além da análise dos circuitos através do cálculo das componentes das potências, estas ainda podem ser usadas para definir fatores de conformidade (ou desempenho), os quais permitem caracterizar as cargas, em função de suas condições de operação. Podem-se se citar como fatores:

- Fator de não linearidade (λ_D): será zero apenas se $i_d = 0$. Este fator representa a presença de potência de distorção;
- Fator de assimetria (λ_U): será zero somente se a carga for balanceada;
- Fator de reatividade (λ_Q): será zero na ausência de defasagem entre as tensões e correntes;
- Fator de potência (λ): é calculado considerando as potências ativa e aparente totais (coletivas).

Toda a formulação matemática para as parcelas de corrente, de potências e indicadores pode ser encontrada em (Tenti, Paredes e Mattavelli, 2011; Tenti *et al*., 2011; Marafão *et al*., 2013). A partir dos valores obtidos pela CPT, na seção 4 apresenta-se a comparação com os analisadores e medidores de energia.

4 Analisadores e Medidores de Energia Elétrica

O analisador de qualidade de energia FLUKE 434, que está em conformidade com a teoria IEEE 1459, apresenta um parâmetro chamado potência não ativa, sendo esta toda a parcela diferente da potência ativa. Como já comentado, esta potência reativa é numericamente igual a potência não ativa, segundo os medidores de energia elétrica.

5 Obtenção dos Dados

A medição das grandezas elétricas foi realizada em laboratório. Para garantir um sinal senoidal de tensão, foi utilizada uma Fonte CA Programável,

modelo Chroma 61702. Foram adquiridos os sinais de tensão e corrente das cargas em estudos – LFC de 11 W e LED tubular de 11 W. Para isso, foi utilizado o analisador de energia RMS, modelo MARH 21. As Figuras 1 ,2 e 3 se referem às cargas utilizadas e analisador RMS.

Figura 1. Lâmpada fluorescente compacta (LFC) 11 W

Figura 2. Lâmpada LED tubular 11 W

Figura 3. Analisador de Energia RMS MARH 21

Com os dados coletados, foi realizada a modelagem da carga para, então, simular via software PSIM. Para tal simulação, foi criado um circuito com uma fonte monofásica e uma carga configurada com a forma de onda da corrente equivalente com as duas lâmpadas medidas. Desta forma, os parâmetros de tensão e corrente foram coletados no ponto de acoplamento comum, entre a fonte e a carga e tais parâmetros foram enviados a um bloco de medição das parcelas de potência da CPT (potência aparente, potência ativa, potência residual, fator de potência, fator de reatividade e fator de não linearidade). Além disto, foram analisados os dados medidos pelos aparelhos apresentados na Tabela 1.

Tabela 1 - Medidores e analisadores de energia utilizados

Analisador de Qualidade da Energia (FLUKE 434)
Medidor de Energia SAGA 1000 (Landis+Gyr)
Medidor de Energia SAGA 3000 (Landis+Gyr)
Medidor de Energia E34A (Landis+Gyr)
Medidor de Energia SL7000 (Actaris)

Os resultados obtidos através das medições em laboratório e das simulações, tais como potência ativa, potência reativa, fator de potência e outros parâmetros, se tornaram objetos de estudos para a formulação dos resultados e discussões.

6 Resultados e Discussões

Para ambas as lâmpadas, a taxa de amostragem dos gráficos foi de 210 amostras por ciclo (frequência de amostragem equivalente a 12,6 kHz). A primeira carga analisada foi a LFC que possui as formas de onda para corrente e tensão conforme Figura 4.

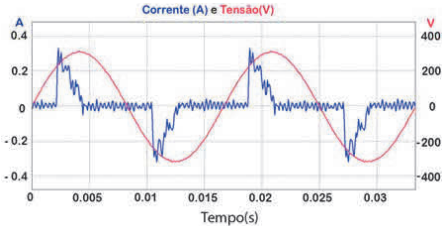

Figura 4. Corrente e tensão x tempo, na lâmpada LFC de 11 W

Conforme a Figura 4, a LFC possui uma forma de onda de corrente bastante distorcida, como mostram os resultados para a CPT e para os medidores - Tabela 2. Os valores das potências estão em pu (por unidade) tendo como base a potência aparente (A). Como pode ser visto na Tabela 2, os valores de potência ativa (P) e aparente (A) são os mesmos, tanto para a CPT, quanto para os medidores comerciais.

Tabela 2 - Lâmpada fluorescente compacta (LFC) 11 W

CPT		Medidores	
Parâmetros	Valor	Parâmetros	Valor
Potência Aparente (A)	1	Potência Aparente (A)	1
Potência Ativa (P)	0,56	Potência Ativa (P)	0,56
Potência Reativa (Q)	0,285	Potência Reativa (Q)	0,823
Potência Residual (D)	0,77	-	-
Fator de Potência (λ)	0,566	Fator de Potência (λ)	0,566
Fator de Reatividade (λ_Q)	0,450	-	-
Fator de não Linearidade (λ_D)	0,774	-	-

Logo, o fator de potência (λ) também será igual. O que difere bastante é o valor da potência reativa (Q). Isto se dá porque a CPT analisa um outro tipo de potência, chamada de potência residual (D), que está ligada diretamente à distorção na forma de onda da corrente. Assim, quanto maior for a distorção harmônica na corrente, maior será o valor desta potên-

cia. Além do mais, a CPT calcula outros dois parâmetros que demonstram a influência da potência reativa e da potência residual na potência aparente. Tais fatores são: fator de reatividade (λ_Q) e o fator de não linearidade (λ_D) que neste caso é maior que a potência residual e mais significativo do que a potência reativa.

A segunda carga analisada foi a lâmpada LED, do tipo tubular. As formas de onda de tensão e corrente são apresentadas na Figura 5.

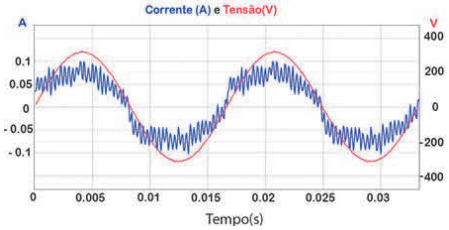

Figura 5. Corrente e tensão x tempo na lâmpada LED de 11W

De acordo com a Figura 5, nota-se que a distorção de corrente é menor que a corrente da LFC (Figura 4), uma vez que a corrente está mais parecida com uma onda senoidal e apresenta também componentes harmônicas. A Tabela 3 apresenta as grandezas elétricas medidas e calculadas para esta carga.

Tabela 3 - Lâmpada LED tubular 11W

CPT		Medidores	
Parâmetros	Valor	Parâmetros	Valor
Potência Aparente (*A*)	1	Potência Aparente (*A*)	1
Potência Ativa (*P*)	0,941	Potência Ativa (*P*)	0,941
Potência Reativa (*Q*)	0,142	Potência Reativa (*Q*)	0,337
Potência Residual (*D*)	0,306	-	-
Fator de Potência (λ)	0,941	Fator de Potência (λ)	0,941
Fator de Reatividade (λ_Q)	0,150	-	-
Fator de não Linearidade (λ_D)	0,306	-	-

Na Tabela 3, os valores de potência ativa (P), potência aparente (A) e fator de potência (λ) continuam iguais, e mesmo essa carga possuindo um alto fator de potência, a CPT identifica uma potência residual, mostrando que a potência reativa, segundo a CPT, é menor que a metade da potência reativa segundo os medidores comerciais. Este baixo valor está evidenciado no fator de reatividade e é compensado pelo valor apresentado no fator de não linearidade.

Para efeitos de tarifação, com base nas equações (1) e (2) apresentadas na seção 2, tanto para os medidores de energia, quanto para teoria CPT, o valor mensurado será o mesmo, pois apenas o fator de potência e a potência ativa são utilizados como base de cálculo. Mas, analisando o comportamento típico de uma unidade consumidora, com muitas cargas não lineares em que o fator de potência é similar ao da LFC, a mesma deverá pagar pelo excedente de reativo e esse valor pago será o mesmo, independente das duas teorias apresentadas neste artigo, se for observado o Fator de Potência. Porém, segundo a CPT, o consumidor não estará pagando apenas o reativo, mas também a potência de distorção, ou seja, ele estaria pagando por excedentes além do estabelecido pela resolução normativa da ANEEL.

Isto ocorre porque os parâmetros utilizados para o cálculo do excedente de reativo (fator de potência e potência ativa), segundo a ANEEL, são suficientes para estimar a potência reativa. Porém, esse cálculo não faz a análise sobre a qualidade da energia elétrica, que deveria conter outras variáveis e fatores para quantificar o reativo e outras supostas grandezas.

O mesmo não ocorre na CPT, pois esta contém o fator de reatividade e não linearidade para a devida mensuração do fator de potência. Tanto a CPT, quanto os medidores de energia elétrica, confirmam ainda mais a necessidade de discussões sobre a potência reativa para diferentes cargas. A CPT apresenta o fator de potência correlacionado aos fatores de conformidade, conforme apresenta a equação (3) (Marafão *et al*., 2013), que se leva em consideração os fatores de reatividade (λ_Q), de assimetria (λ_U) e de não linearidade (λ_D), que foram apresentados na seção 3.

$$\lambda = \sqrt{(1-\lambda_Q{}^2)(1-\lambda_U{}^2)(1-\lambda_D{}^2)} \qquad (3)$$

Considerando os fatores de conformidade da CPT, utiliza-se uma proposta para analisar a influência da potência reativa no fator de potência, em cargas com comportamento não linear. Para tal, deve-se desconsiderar o fator de não linearidade e o fator de assimetria da equação (3). Assim, o cálculo do fator de potência para o faturamento de reativos fica conforme a equação (4):

$$\lambda = \sqrt{(1-\lambda_Q{}^2)} \qquad (4)$$

O fator de potência, conforme a equação 4, para as duas lâmpadas, são apresentados na Tabela 4 e diferem do fator de potência convencional.

Tabela 4. Fator de potência para as duas lâmpadas de acordo com a equação (4)

	LFC	LED
λ	0.8928	0.9887

Conclui-se que, quando o fator de potência é calculado considerando apenas a interferência do

reativo e não considerando a potência de distorção, a lâmpada LED teria um fator de potência acima do permitido, não existindo, portanto, o excedente de reativo. A LFC teria um fator de potência mais elevado, porém, ainda abaixo do regulamentado.

Logo, percebe-se que há uma incoerência na forma de medição e de faturamento existente, dado que em situações de cargas com presença de harmônicas, é cobrado, além dos excedentes de reativo, a distorção da forma de onda da corrente, através das parcelas ERE e DRE.

Ainda há muito que se discutir a respeito da definição da potência reativa e seu significado físico. Contudo, é inegável que há discrepâncias dos dados de medição, conforme apresentado neste artigo. Desta forma, este trabalho afirma a necessidade de estudos a respeito da metodologia utilizada para a tarifação, quando há sinais não senoidais envolvidos na medição.

7 Conclusões

Os dados expostos neste artigo revelam que, ao analisar uma carga com característica não linear, os efeitos desta não linearidade na medição da energia elétrica podem ser significativos. A influência desta grandeza na medição irá variar em função da sua magnitude. Essencialmente, discute-se a questão da parcela de potência denominada de reativa, utilizada para fins de faturamento da energia elétrica.

As análises mostraram que, aplicando-se a CPT, os dados medidos podem ser detalhados e, posteriormente, discutidos e interpretados de uma nova maneira. Já a teoria IEEE 1459 não permite a separação entre as grandezas de forma prática. Ou seja, nos atuais medidores comerciais de energia elétrica, a parcela de potência que não é ativa pode ser interpretada como reativa, englobando aqui a parcela de potência denominada não ativa.

Consequentemente, quando se calcula o fator de potência da unidade consumidora e em seguida os excedentes de reativo, a não linearidade da carga (distorções harmônicas) são embutidas na parcela a ser cobrada do consumidor, o que não está normatizado pela ANEEL e, portanto, é passível de discussões e, principalmente, de novos estudos.

No artigo também são realizadas simulações, utilizando para tal a teoria CPT, no intuito de discutir uma proposta de cálculo do fator de potência, utilizando apenas a parcela denominada de reatividade (λ_Q), eliminando assim, para esta finalidade, a influência da não linearidade (λ_D).

Conclui-se, portanto, que a proposta de cálculo do fator de potência com base na CPT altera, de maneira significativa, o valor do fator de potência medido, o que reforça a necessidade de continuidade dos estudos e discussões que estão sendo desenvolvidos a respeito deste tema, não somente em nível nacional, como também internacionalmente.

Referências Bibliográficas

ANEEL, Agência Nacional de Energia Elétrica, (2010), Resolução Normativa nº 414 – ANEEL, Brasília.

ANEEL, Agência Nacional de Energia Elétrica, (2012). Nota Técnica nº 0083/2012 – SRD/ANEEL. Nota Técnica. Brasília.

Cerqueira, A. S., Duque, C. A., Ribeiro, M. V. e Trindade, R. M., (2006). Sistema Digital de Detecção e Classificação de Eventos de Qualidade de Energia. IEEE Latin America Transaction, Vol. 4, No. 5.

FLUKE, Fluke Corporation, (2012). Manual do Usuário: Analisadores de Qualidade de Potência e Energia Trifásicos.

Galhardo, M. A. B. e Pinho, J. T., (2008). Mutual Influence between Harmonics and Nonlinear Loads. IEEE Latin America Transaction, Vol. 6, No. 7.

Irianto, C. G. e Setiabudy, R., (2011). Design Dtz transformer that compatible with nonlinear load in modern electrical systems. 2011 International Conference on Electrical Engineering and Informatics (ICEEI). Bandung, pp. 1-6.

Marafão, F.P., Souza, W.A., Liberado, E.V., da Silva, L.C.P., Paredes, H.K.M., (2013), "Load analyser using conservative power theory," Przeglad Elektrotechniczny, Vol 12, pp 1-6, 2013.

Mendonça, L., (2012). A força das águas. Revista O Setor Elétrico, Ed. 80.

Monteiro, R. V. A., (2015). Lâmpadas Tubulares LED x Fluorescente – Estudos de Viabilidade, na Perspectiva da Qualidade da Energia e Eficiência Elétrica. Dissertação de Mestrado. Universidade Federal de Mato Grosso. Cuiabá.

Nascimento, C. F., Belati, E. A., Dietrich, A. B., Faria, H. e Goedtel, A., (2014). Evaluating Harmonic Voltage in Electric Distribution System due to Six-Pulse Static Power Converter. IEEE Latin America Transaction, Vol. 12, No. 6.

Oliveira, M. F. e Vilela J. A., (2015). Active Filters for Harmonic Current Compensation in Low-Voltrage Grid. IEEE Latin America Transactions, Vol. 13, No. 5.

Revista Sodebras, (2015). Soluções para desenvolvimento do país. Vol. 10, No. 113.

Tenti, P., Paredes, H. K. M., Marafão, F. e Mattavelli P., (2011). Accountability in Smart Microgrids Based on Conservative Power Theory. IEEE Transactions on Instrumentation and Measurement, pp. 3058-3069.

Tenti, P., Paredes, H. K. M. e Mattavelli, P., (2011). Conservative Power Theory, a Framework to Approach Control and Accountability Issues in Smart Microgrids. IEEE Transactions on Power Electronics, Vol.26, No.3, pp.664-673.

View publication stats

Analysis of the Influence of Non-Linear Loads on the Measurement and Billing of Electrical Energy Compared with the CPT

V. H. F. Brito, G. Y. Kume, M. S. Quinalia e M. A. Sachetti and R. P. B. Silva.
Faculty of Architecture, Engineering and Technology, UFMT - Federal University of Mato Grosso
Cuiabá/MT, Brazil

W. A. Souza and L. C. P. Silva
School of Electrical and Computer Engineering, UNICAMP - State University of Campinas, Campinas/SP, Brazil

***Abstract*— This article analyzes the impact of electronic loads, particularly CRT, LCD and LED televisions, regarding the measurements of reactive power in energy meters of Brazilian Electric Power companies and consequently the influence of those measurements in the reactive surplus Billing (Reactive Energy Excess and Demand Energy Excess). Later, the values obtained from the energy meter are compared to the CPT power components. For the reactive surplus calculation, it is considered not only the reactive power, but also the distortion in the system. It is concluded that the harmonic distortion causes significant interference in measurements of reactive power in energy meters, and that the calculation of reactive power surplus through power factor allows certain inconsistencies in the billing.**

Keywords— Non-linear loads, Measurement, Power, Power factor, power theory.

I. Introduction

The use of semiconductors brought advances on power electronics technology and it allows to an increasing use of the electronic devices in the consumer units. In this manner, equipment such as televisions, which use solid state power supplies, compact fluorescent lamps (CFLs), electronic ballasts, air conditioners that are driven by frequency converter and microcomputers began to be developed and widely used by the population [1]. These devices have the common characteristic of non-linearity, in other words, the current waveforms have high levels of harmonic distortion, which impacts the power quality [2]. In addition, they cause the flow of current harmonics in the secondary distribution networks of electric utilities [3], called harmonic frequencies [4].

The nonlinearity of these devices has a significant harmonic content of current in the electric power system [5], resulting on decreased power factor, distorted voltage waveform, high level of harmonics multiple of third order at the neutral conductor, overheating transformers, increased temperature and possibility of explosion of capacitor banks, improper functioning of the devices used in the protection of electrical systems, such as circuit breakers, fuses and relays, reduction in the yield of electrical machines, due to mechanical stress beyond the expected and electromagnetic interference, influencing also the equipment of active and reactive energy measurement, in order to reduce its useful lifetime and entering deviations in measurement, according to the current measurement methods.

Moreover, the increasing use of non-linear loads results in an extensive discussion about the calculation of the electrical power components in electrical systems under non-sinusoidal conditions. According to the Brazilian Electricity Regulatory Agency (ANEEL) [6], the definition of active and apparent power are well consolidated. But, the discussion point on the nonlinear systems is about the reactive power and power factor. That is, there is no consensus about reactive power when exists loads with distorted waveforms. In this context, various power theories for circuits with non-linear loads [7-8-9] have been presented over the years, with highlights for IEEE 1459-2010; Conservative Power Theory (CPT); FBD theory and PQ or Instant theory.

Among the theories mentioned, the CPT presents a possible approach to the non-sinusoidal problem. The CPT is a time domain theory that decomposes the current in orthogonal parts that can be associated with different load characteristics (lagging current, harmonics and unbalance) [10].

In this context, this article presents a study about the power measurement of non-linear loads, specifically three different technologies of televisions. It was used commercial meters that are also used by the Brazilian utilities and power analyzers companies. Subsequently, computer simulations for the same loads were performed to obtain the CPT power components and their respective factors. Finally, the powers results were compared between the power meters and the CPT, thus analyzing the harmonics influence on the recorded power values by the measuring equipment and hence the distortion relevance in the actual Brazilian billing system, focusing on portions relating to the reactive surplus.

II. Billing of Reactive Energy Surplus in the Brazilian Electric System

For this work, it is essential to understand about the billing related to the payment of reactive surplus that is stablished by the ANEEL, the Brazilian electrical regulatory agency.

According to ANEEL. the minimum allowed for the reference power factor "f_R", capacitive or inductive, is 0.92. So, it is applied the charges legislated in articles 96 and 97 for the electricity

978-1-5090-3792-6/16/$31.00 ©2016 IEEE

amounts and reactive power demand that exceeds the permitted limit, then adding to the regular billing.

From: "Art. 96. - For the consumer unit that has appropriate measuring equipment, including one whose owner has signed the CUSD, the values corresponding to power and surplus reactive power demand are calculated according to the following equations: "

$$E_{RE} = \sum_{T=1}^{n1} \left[EEAM_T \times \left(\frac{f_R}{f_T} - 1 \right) \right] \times VR_{ERE} \quad (1)$$

$$D_{RE}(p) = \left[\underset{T=1}{\overset{n2}{MAX}} \left(PAM_T \times \frac{f_R}{f_T} \right) - PAF(p) \right] \times VR_{DRE} \quad (2)$$

Where:

- E_{RE} = value corresponding to the reactive power over the allowed value by the reference power factor " f_R " in the billing period in Brazilian currency (Real - R$);
- EEAMT = amount of active power measured in each one hour interval "*T*" for the billing period, in megawatt-hour (MWh);
- f_R = reference power factor of 0.92;
- f_T = power factor of the consumer unit, calculated in one hour interval "*T*" for the billing period;
- VR_{ERE} = reference value equivalent to the energy tariff "*TE*" applicable to subgroup B1, in Brazilian real (R$) for megawatt-hour (R$/MWh);
- $D_{RE}(p)$ = value, by post time "*p*" corresponding to the demand for reactive power over the amount allowed by the reference power factor " f_R " in the billing period in Brazilian real (R$);
- PAM_T = active power demand as the payment interval of one (1) hour "*T*" during the billing period in kilowatt (kW);
- *PAF(p)* = demand for billable active power in each time put "*p*" in the billing period in kilowatt (kW);
- VR_{DRE} = reference value in real per kilowatt (R$ / kW), equivalent to the power demand charges, for the post off-peak time, the supply tariffs for subgroups of group A, for the hourly tariff mode blue and TUSD-Consumers-free, as is in force the Supply Agreement or the CUSD, respectively;
- *MAX* = function that identifies the maximum value of the equation within the brackets corresponding in each time position "p";
- *T* = indicates the range of one (1) hour in the billing period;
- *p* = indicates time position, on-peak or off-peak, to the hourly tariff arrangements or billing period for conventional tariff mode binomial;
- *n1* = number of payment intervals "*T*" billing period to the peak hours and off-peak;
- *n2* = number of payment intervals "*T*" for post time "p" in the billing period.

During of this work, the equation (1) and (2) will be used to mean a function of which consumer is paying for the reactive excess. Compared with these equations, other approaches exist to calculate the reactive power that allow different analysis of IEEE 1459. In the section III will be presented the CPT approach, which will enable the comparison and discussion of the reactive energy values presented by ANEEL.

III. CPT (Conservative Power Theory)

The Conservative Power Theory (CPT) is a recent power theory that was proposed by Tenti et. al. (presented in 2003 and reformulated in 2010 [7]). It applies for sinusoidal or non-sinusoidal conditions, balanced and unbalanced loads, single phase and three phase systems (with or without return conductor). Therefore, this theory decomposes the current into orthogonal current terms and aims to represent the physical phenomena related to the linear and nonlinear load behavior. These terms are the following:

Active current (i_a): It is the minimum current required for consuming a particular active power in each phase of the circuit.

Reactive Current (i_r): It is responsible for the minimum flow of reactive power per phase in the circuit.

Residual current (i_d)**:** It does not transfer active or reactive power. It is the portion of the current that represents the non-linearity between supply voltage and load current.

In polyphase circuits (with or without return conductor), the active and reactive current can be still decomposed into the following balanced and unbalanced parts:

Balanced Active Current (i_a^b): It is responsible for the minimum transfer of collective active power from the source to the load; besides, it is proportional and in phase with the voltage.

Balanced Reactive Current (i_r^b): It is responsible for the minimum flow of collective reactive power in the circuit.

Unbalanced current (i^u): It consists of an active and reactive part ($i^{u^2} = i_a^{u^2} + i_r^{u^2}$) and represents different conductance and reactivity values per phase.

For each current part, it has been associated with a power obtained by the product of the effective voltage value and the correspondent effective current value, as follows:

Active Power ($P=VI_a^b$): It is the average consumption of power in the circuit, representing the useful work of the load.

Reactive Power ($Q=VI_r^b$): It is the power portion that represents the phase difference between voltages and currents.

Unbalanced Power (where $N_a = VI_a^u$ and $N_r=VI_r^u$): It is the power portion that represents the load unbalance. This term will be void in case of single-phase circuits.

Distortion Power ($D=VI_d$): It is the power portion consumed due to the presence of nonlinearities in the circuit; it does no useful work or energy and does not characterize energy storage.

Apparent Power (A=VI): It is the total power of the circuit. Algebraically, the square of the apparent power is equal to the sum of all the squares of the power terms mentioned.

Using the power terms, the CPT defines a new concept of power factor, which can characterize the loads. These factors are as follows:

Nonlinearity Factor (λ_D): It will be zero only if $i_d = 0$. This

factor represents the presence of distortion power, in other words, currents that do not contribute to active or reactive power, but cause losses in the distribution system.

Unbalance Power (λ_U): It will be zero only if the load is balanced. It determines the existence of an unbalanced among the loads of a polyphase system.

Reactivity Factor (λ_Q): It will be zero when there is no phase difference between voltages and currents, that is, the reactive current absent. It reveals the presence of reactive energy in inductors, capacitors, or the effect of non-linear loads.

Power Factor (λ): It is calculate considering total active and apparent power.

More detailed information about Conservative Power Theory and its mathematical formulation can be found at [7].

With the theoretical basis was possible to perform the comparative analyzes of measurements for each analyzed load.

IV. Experiments

Through the power meters and power analyzers presented in Table 1, there were made laboratory measurements of three televisions with different technologies, CRT (Cathode Ray Tube), LED (Light Emitting Diode) and LCD (Liquid Crystal Display). Furthermore, electrical quantities data were collected for the comparison between the power values and power factor obtained by electrical energy meters and the CPT power values and their respective factors.

The Table 1 presents the TV models and the power meters used for the experiment; these power meters there was correspondence between the values of power measured in all devices. Moreover, in accordance with the Fluke 434 power quality analyzer manual [11], the measurement algorithms of this device are compatible with the IEEE 1459.

Table 1. Loads and Equipments used.

Equipments
Programmable Source CA Chroma 61702
21 inches CRT TV, 77 W
32 inches LCD TV, 150 W
32 inches LED TV, 55 W
Power Meter E34A (Landis+Gyr)
Power Meter SL7000 (Actaris)
Power Quality Analyzer (FLUKE 434)
Power Quality Analyzer (RMS MARH 21)
Power Meter SAGA 1000 (Landis+Gyr)
Power Meter SAGA 3000 (Landis+Gyr)

For accomplishment of the study the instantaneous voltage and current data of the loads cited in Table 1 have also been used. These values were acquired through the meters RMS and Fluke, in which it has been stored 192 points in a cycle (sampling frequency is 11.52 kHz). Thus, with the values obtained, it was possible to create a model for the three types of TV in the computer simulator PSIM® and to determine the electrical quantities involved of the CPT, mainly the power and the factors involved.

Therefore, the objective of this work is to analyze the influence of certain non-linear loads in the current measuring and billing system. In addition, the objective is to compare the results obtained with the power values, according the CPT, throughout computer simulation. The study of reactive power will be emphasized, considering that it has been under discussion among the various power theories.

V. Experimental Results

Figures 1, 2 and 3 show the waveforms of the voltage and current measured by the Fluke energy analyzer, for each television technology. In addition, it is important to emphasize that, to eliminate the deviations caused by voltage waveform distortion, a programmable source was used to supply the loads. Thus, only the load in question causes the waveform distortion of the electric current.

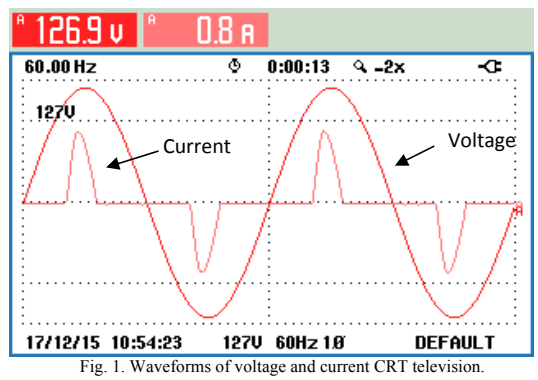

Fig. 1. Waveforms of voltage and current CRT television.

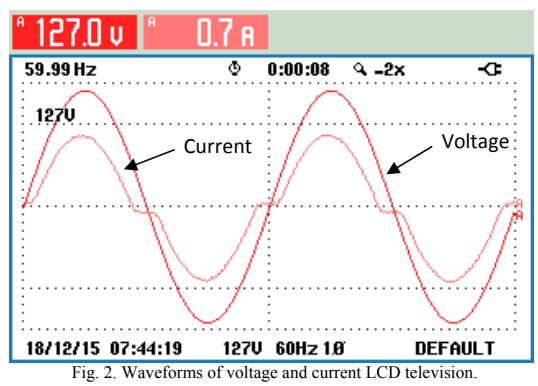

Fig. 2. Waveforms of voltage and current LCD television.

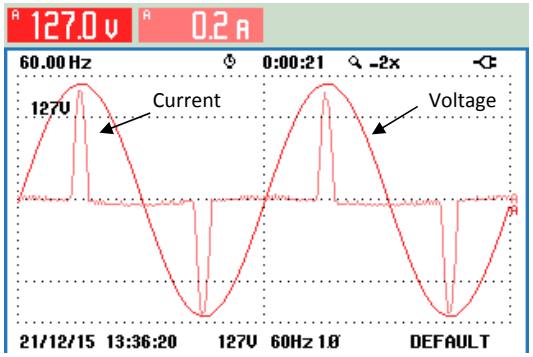

Fig. 3. Waveforms of voltage and current LED television.

Initially, it was verified a high current distortion caused by nonlinear characteristic of the load in question, that is, the harmonics and that it occurs for the three presented TV types. Table 2 indicates that measurements have high Total Harmonic Distortion of Current (THDi), being more significant for televisions with CRT and LED technology, which has 125.5% and 177.88% of THDI respectively. The LCD TV has a THDI of 17.2%.

TABLE 2. TOTAL HARMONIC DISTORTION OF CURRENT FOR THREE TV TECHNOLOGIES.

TELEVISOR	CURRENT DISTORTION
CRT	125.5%
LCD	17.2%
LED	177.88%

The harmonics present in the current waveform, that is, the high levels of total distortion of current for the loads in question, substantially influences the measurements of the electrical quantities. Based on this, the data obtained by the electricity meters will be presented first, according to Table 3, and then the CPT simulations results will be presented, allowing the verification of the interference in the measured powers due to non-linearity characteristic.

TABLE 3. DATA OF POWERS TO THE THREE TV TECHNOLOGIES, ACCORDING TO THE ELECTRICITY METERS.

	CRT TV	LCD TV	LED TV
S [pu]	1	1	1
P [pu]	0.6222	0.9805	0.4757
Q [pu]	0.7828	0.1967	0.8796
PF	0.6222	0.9807	0.4757

Through Table 3, it can be shown that the power factor (PF) is relatively low for the CRT and LED technologies compared to LCD TV, i.e. the most preponderant part of the apparent power on the television with liquid crystal display is the active power, this being greater than the reactive power. For other cases, it is noted that the reactive power is significantly greater than the active. Therefore, it is plausible to conclude that for the present billing method, if a consumer unit has loads with nonlinear characteristics, with significant harmonic distortion, equivalent to cases of CRT or LED televisions, it will have a power factor below the allowed and pay the reactive surpluses, according equations (1) and (2).

It is necessary to include also that reactive excess billing is determined, primarily, by the power factor, in which that for nonlinear loads, according to the IEEE 1459 (theory that the Fluke energy analyzer takes as basis to calculation), is obtained by:

$$FP = \frac{P}{S} \tag{3}$$

$$S^2 = P^2 + N^2 \tag{4}$$

The factor power considers the non-active power in the calculation. However, the non-active power is determinate not only by the reactive power, but also by the system distortion. Moreover, it was also noted that for the electricity meters of Brazilian power utilities, the reactive power is numerically equal to the non-active power of the IEEE 1459 theory.

The non-linearity load influence in question, in the powers calculation, becomes even more evident when compared whit values found by the CPT, as shown in Table 4.

TABLE 4. SIMULATION DATA AS THE CPT FOR THE THREE TELEVISION TECHNOLOGIES.

	CRT TV	LCD TV	LED TV
A [pu]	1	1	1
P [pu]	0.6222	0.9805	0.4757
Q [pu]	0.0877	0.0991	0.1165
D [pu]	0.7779	0.1699	0.8719
N [pu]	0	0	0
λ	0.6222	0.9805	0.4757
λ_Q	0.1396	0.1005	0.3398
λ_U	0	0	0
λ_D	0.7779	0.1699	0.8719

The results obtained for the diverse powers and their respective factors in the CPT are an important form of measure and an efficient analysis tool, because they represent the circuit characteristics, in other words, the physical phenomena, related to the behavior of the linear and nonlinear elements of the load [12,13].

Regarding the values of table 4, it is important to highlight that the power mismatch is null, as the asymmetry factor, once that the utilized loads are monophasic. Moreover, both the active power and apparent power are numerically equal to the meters and to the CPT. Thus, the power factor is also identical. However, the greater difference is found in the CPT reactive power in comparison with the reactive power meters, once that for all types of televisions, the reactive power of the CPT is lower than the measuring equipment, being this difference more noticeable for the CRT technology TV, in which the measuring equipment recorded a reactive power approximately 10 times

greater than the one calculated based on CPT.

Therefore, the CPT reveals that the low power factor is not caused by the reactive excess, once that the reactivity factor is considerably lower when compared with the nonlinearity factor. These reactive values from the measuring equipment carry the nonlinear behavior.

As a demonstration form, a linear RL monophasic load is used for analysis, with a 0.92 power factor, in other words, the allowed limit for not acquiring a reactive excess. The parameters are displayed in the Table 5.

TABLE 5. SIMULATION DATA ACCORDING TO CPT FOR A RL LOAD.

	RL Load
A [pu]	1
P [pu]	0.92
Q [pu]	0.3919
D [pu]	0
λ	0.92
λ_Q	0.3919
λ_D	0

It is fundamental to highlight by the Table 4 that, both the CTR TV and the LCD TV possess a considerably lower reactivity factor when compared with the RL load of Table 5. In other words, the presence of reactive power is significantly greater in the RL load compared to the nonlinear loads cited. However, to the existing billing system, the CRT and LCD television possess a reactive excess, unlike the RL load

One suggestion to analyze the influence of reactive power in the power factor of nonlinear loads, is to disregard the non-linearity factor in the equation (3), based on CPT:

$$\lambda = \sqrt{(1 - \lambda_Q^2)(1 - \lambda_D^2)} \quad (5)$$

Therefore, the power factor calculation would be as in equation (4):

$$\lambda = \sqrt{(1 - \lambda_Q^2)} \quad (6)$$

The calculated power factor for the three television types, according to the equation (4), is displayed in Table 6.

TABLE 6. POWER FACTORS FOR THE THREE TELEVISION TECHNOLOGIES ACCORDING TO EQUATION 4.

	CRT TV	LCD TV	LED TV
λ	0.9902	0.9949	0.9405

It is possible to conclude that, when the factor power is calculated considering only the interference of the reactive and disregarding the distortion power, is the most plausible procedure when it comes to reactive excess. Hence, it can be verified that all measured loads have a power factor above the allowed, therefore not existing the reactive excess.

Then, it is noticed that there is an incoherence on the measuring method and the existent billing, given that in situations where loads with presence of harmonics are charged, both the reactive and distortion of the voltage and current waveform through the parcels ERE and DRE. Moreover, as the ANEEL affirms on its technical note [6], the consumer could have its billing increased due to distortion on the voltage signal that powers his consumer unit whose responsibility is not attributed to him. The obtained results corroborate with [14], in wich a similar analysis for compact fluorescent lamps was carried out, since the purpose for this research group is to study the influence of various non-linear loads residential on the measurement and billing.

There is much more to be discussed about the definition of the reactive power and its physical meaning. However, it is undeniable that there are discrepancies of measurements data, as presented in this article. This way, this work affirms the need for studies towards the methodology used for billing, when there are non-sinusoidal signals involved in the measurement.

VI. CONCLUSION

The results presented in this study show the effect that nonlinear loads cause in the measurement and billing of electricity, mainly when it refers to reactive power. The experiment was performed in laboratory, using three TV technologies. It was compared the active, reactive and apparent power, of all technologies, measured with energy meters of Brazilian Electric Power companies to the power values according to CPT.

In face of the current Brazilian measuring system for non-sinusoidal cases, it has been found that the presence of nonlinear loads considerably interferes with the power factor value and, according to the work presented in this paper, it is noted that there was inconsistency when the power factor method is used to determine the reactive surplus.

The loads considered in this study have low power when compared to all the power measured in a consumer unit of group A (where it is charged the reactive surplus). Thus, when a load of low power that has harmonics components is placed in a strongly sinusoidal system, the interference of the non-linearity is minimal. However, the analyses made in this work can be extended to the consumer units that have a load profile mainly non-sinusoidal, not forgetting that in these cases, there are contradictions within the measurement of the reactive surplus in billing. Therefore, in systems with high level of non-linearity, the actual billing method charges both the reactive power and distortion as shown in equations (1) and (2), which refer to reactive power excess. However, it should be noted that this charge is not standardized according to the Brazilian legislation. Thus, it is more coherent to use another billing system methodology that the non-linearity does not interfere the billing of the reactive power excess. An alternative to this inconsistency, is to change the power factor in equations (1) and (2) by equation (6), which is numerically equal to the displacement factor from IEEE theory used by the Fluke Power Quality Analyzer.

Therefore, it is of extremely importance the development of studies that analyze the variety of the existing power theories, aiming to identify which of them presents the best physic meaning of the quantities stated in this work and to avoid the inconsistencies of the current measurement method.

REFERENCES

[1] J. Guo, X. Xiao, S. Tao, "Discussion on Instantaneous Reactive Power Theory and Current's Physical Component Theory", *2012 IEEE 15th International Conference on Harmonics and Quality of Power (ICHQP)*, June 17-20, 2012.

[2] C. F. Nascimento, E. A. Belati, A. B. Dietrich, H. Faria and A. Goedtel, "Evaluating Harmonic Voltage in Electric Distribution System due to Six-Pulse Static Power Converte," *IEEE Latin America Transactions*, Vol. 12, No. 6, Sep. 2014.

[3] M. F. Oliveira and J. A. Vilela, "Active Filters for Harmonic Current Compensation in Low-Voltage Grid," *IEEE Latin America Transactions*, Vol. 13, No. 5, May. 2015.

[4] A. S. Cerqueira, C. A. Duque, M. V. Ribeiro and R. M. Trindade, "Sistema Digital de Detecção e Classificação de Eventos de Qualidade de Energia," *IEEE Latin America Transaction,* Vol. 4, No. 5, Sep. 2006.

[5] A. B. de Vasconcello, B. C. Carvalho, W. C. G. A. Martins, E. T. Anabuki, L. T. Marques, "The Influence of the Non-linearity of Electric Loads on Capacitive Compensation", *2012 IEEE 15th International Conference on Harmonics and Quality of Power (ICHQP)*, June 17-20, 2012.

[6] ANEEL, "Nota Técnica nº 0083/2012 – SRD/ANEEL," Agência Nacional de Energia Elétrica. *Technical Note*. Brasília, June 2012. In portuguese.

[7] P. Tenti, H. K. M. Paredes and P. Mattavelli, "Conservative Power Theory, a Framework to Approach Control and Accountability Issues in Smart Microgrids," *IEEE Transactions on Power Electronics*, vol. 26, no. 3, pp. 664-673, 2011.

[8] D. Vieira, "Comparação de Técnicas de Medição de Potência Reativa sob Condições Não-Senoidais na Transformada Wavelet," Brasília, Brasil: M. S. thesis, 2012. In portuguese.

[9] M. R. Suhett," Análise de Técnicas de Medição de Potência Reativa em Medidores Eletrônicos," UFRJ, Rio de Janeiro, Brasil: M. S. thesis, 2008. In portuguese.

[10] T. V. Fogaça, H. K. M. Paredes, A. C. Moreira and L. C. P. da Silva, "Estudo da CPT para Caracterização de Circuitos Elétricos Monofásicos em Condições Não Senoidais", *XX Congresso Brasileiro de Automática,* Belo Horizonte, MG, Sep. 20-24, 2014. In portuguese.

[11] FLUKE, "Manual do Usuário. Analisadores de Qualidade de Potência e Energia Trifásicos," *Fluke Corporation*, Jan. 2012. In portuguese.

[12] W. A. Souza, E. V. Liberado, L. C. P. da Silva, H. K. M. Paredes and F. P. Marafão, "Load analyser using conservative power theory," *International School on Nonsinusoidal Currents and Compensation 2013 (ISNCC 2013)*, Zielona Gora, pp. 1-6, 2013.

[13] W. A. Souza, F. P. Marafao, E. V. Liberado, I. S. Diniz and P. J. A. Serni, "Power Quality, Smart Meters and Additional Information from Different Power Terms," *in IEEE Latin America Transactions*, vol. 13, no. 1, pp. 158-165, Jan. 2015.

[14] R. P. B. Silva, L. C. P. Silva, V. H. F. Brito, M. A. Sachetti, G. Y. Kume and M. S. Quinalia, "Análise Comparativa entre Medições de Energia Elétrica para Cargas Não Lineares de Iluminação: Medição Comercial x CPT," *XXI Congresso Brasileiro de Automática* Vitória, ES, Oct. 03-07, 2016. (Subject). In portuguese.